**UNIVERSIDADE FEDERAL DA FRONTEIRA SUL**
**CAMPUS LARANJEIRAS DO SUL**
**CIÊNCIAS ECONÔMICAS**

**LEONILSO FANDRES WRUBLAK**

# AS MÁQUINAS ECONÔMICAS: PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

**LARANJEIRAS DO SUL - PR**
**2026**

**LEONILSO FANDRES WRUBLAK**

# AS MÁQUINAS ECONÔMICAS: PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado ao Curso de Ciências Econômicas da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciências Econômicas.

Orientador: Prof. Dr. Alexandre Manoel dos Santos (UFFS)

LARANJEIRAS DO SUL - PR

2026

**LEONILSO FANDRES WRUBLAK**

# AS MÁQUINAS ECONÔMICAS:

## PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado ao Curso de Ciências Econômicas da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciências Econômicas.

Este trabalho foi defendido e aprovado pela banca em DD/MM/AAAA.

BANCA EXAMINADORA

---

Prof. Dr. Alexandre Manoel dos Santos - UFFS
Orientador

---

Professor(a) 1
Avaliador

---

Professor(a) 2
Avaliador

Dedico esse trabalho a todos que um dia sonharam em construir um mundo melhor com base no esforço e no trabalho!

## AGRADECIMENTOS

Agradeço primeiramente a Deus por me permitir viver e poder construir este trabalho, seguidamente a minha esposa Bruna Raphaelle Fernandes Wrublak, que me apoiou durante as noites em que estava sentado escrevendo, ao meu pai Leonildo Savoldi Wrublak e minha mãe Eli Piltz Fandres Wrublak que sempre me inspiraram e me incentivaram a estudar cada vez mais, a minha irmã Leoneli Fandres Wrublak dos Santos e meu cunhado Bruno dos Santos que foram espelhos de trabalho e dedicação, e a todo restante de minha família que esteve comigo nessa jornada. Um agradecimento especial ao meu orientador professor Doutor Alexandre Manoel dos Santos por me dar o suporte necessário para a construção dessa pesquisa, assim como agradeço a todos os meus outros professores, saibam que a profissão que escolheram para a vida inspiram milhões de pessoas pelo mundo todos os dias. Agradeço também aos meus colegas e amigos, que me acompanharam nas matérias difíceis e nos momentos especiais dentro dessa Universidade. A todos o meu profundo e sincero muito obrigado!

"De fato, sabemos muito pouco sobre o futuro. A base real para formar expectativas sobre o rendimento futuro de um investimento é extremamente frágil. Nossas decisões de investimento [...] dependem de um estado de confiança. Muitas vezes, sabemos que não sabemos; mas mesmo assim temos que agir."

(Keynes, 1936, p. 161)

## RESUMO

A incerteza é um desafio grande na vida dos gestores, sejam eles públicos ou privados, e o combate a incerteza se da pela busca de informações, o risco é inversamente proporcional ao conhecimento que temos sobre determinado assunto,e o conhecimento só se da pela interpretação das informações obtidas através de um processo de mineração de dados, quando falamos de poucos dados, os modelos tradicionais de previsão conseguem acertar com um determinado nível de precisão, mas quando queremos resultados mais precisos, ou que nossos dados são mais complexos, evento este, cada vez mais comum na era do *big-data*, os modelos tradicionais de previsão encontram limitações, nesse sentido a presente monografia busca responder como desenvolver um modelo preditivo baseado em IA para efetivamente estimar o PIB brasileiro, considerando as diferenças e semelhanças significativas entre os modelos tradicionais VAR, ARIMA, DFM e MIDAS. Para isso se utilizará de métodos quantitativos visando estimar a acurácia, custo computacional e interpretabilidade dos modelos testados, para enfim determinar se modelos de IA conseguem reduzir a incerteza.



**Palavras-chave**: Inteligência Artificial; PIB brasileiro; Métodos Quantitativos; Testes de modelos.

**ABSTRACT**

Uncertainty poses a major challenge for managers in both the public and private sectors, and addressing it requires the pursuit of information; risk is inversely proportional to one's knowledge of a given subject, and such knowledge is gained by interpreting information obtained through data mining. While traditional forecasting models achieve a certain level of accuracy when dealing with limited datasets, they encounter limitations when higher precision is required or when dealing with complex data—a scenario increasingly common in the era of big data. Accordingly, this study aims to determine how to develop an AI-based predictive model to effectively estimate Brazil's GDP, taking into account the significant differences and similarities among traditional models such as VAR, ARIMA, DFM, and MIDAS. To this end, quantitative methods will be employed to assess the accuracy, computational cost, and interpretability of the models tested, ultimately determining whether AI models can reduce uncertainty.

**Keywords**: Artificial Intelligence; Brazilian GDP; Quantitative methods; Model testing.

## LISTA DE ILUSTRAÇÕES


Figura 1 – Perceptron . . . . . 44
Figura 2 – Função Sigmoide . . . . . 47
Figura 3 – Função de erro quadrático. . . . . 48
Figura 4 – Função de erro quadrático e segmentos de retas tangentes representando a derivada em diferentes pontos. . . . . 48
Figura 5 – Superfície de erro . . . . . 49
Figura 6 – Teste FAC e FACP . . . . . 65
Figura 7 – PIB em volume deflacionado . . . . . 69
Figura 8 – PIB na primeira diferença . . . . . 69
Figura 9 – Previsão de crescimento percentual do PIB ARIMA(1, 1, 1) . . . . . 70
Figura 10 – Previsão do PIB em nível utilizando ARIMA(1, 1, 1) . . . . . 71
Figura 11 – Variáveis candidatas ao modelo VAR . . . . . 74
Figura 12 – Predição do crescimento do PIB escalado utilizando o VAR(1) — Crescimento do PIB + balança corrente (% PIB) . . . . . 77
Figura 13 – VAR(1) — PIB + balança corrente (% PIB) — Previsão de 5 anos . . . . . 78
Figura 14 – Resposta do crescimento do PIB a um choque ortogonalizado na balança de transações correntes . . . . . 79
Figura 15 – Série histórica da taxa de desocupação trimestral com quebra no ano de 2012 81
Figura 16 – Série histórica do PIB em volume anual . . . . . 82
Figura 17 – Série histórica do IPCA mensal . . . . . 82
Figura 18 – Série histórica da dívida pública (% PIB) mensal . . . . . 83
Figura 19 – Previsão do crescimento do PIB para o modelo MIDAS . . . . . 84
Figura 20 – Previsão do PIB em volume para o modelo modelo MIDAS . . . . . 85
Figura 21 – Erro de previsão do PIB para o modelo modelo MIDAS . . . . . 85
Figura 22 – Validação temporal com reestimação anual . . . . . 90
Figura 23 – Previsão crescimento do PIB fora do treino . . . . . 90
Figura 24 – Erro de previsão no período de validação . . . . . 91
Figura 25 – Ajuste do modelo no treinamento . . . . . 91
Figura 26 – Erro do modelo no treinamento . . . . . 92
Figura 27 – Cargas fatoriais do DFM . . . . . 92
Figura 28 – Erro do modelo no treinamento . . . . . 93

Figura 29 – Função de ativação Tangente Hiperbólica . . . . . 95
Figura 30 – Função de ativação ReLu . . . . . 96
Figura 31 – Ajuste do modelo durante a validação . . . . . 98
Figura 32 – Erros do modelo durante a validação . . . . . 98
Figura 33 – Previsão do crescimento do PIB utilizando redes neurais . . . . . 99
Figura 34 – Erro da previsão do crescimento do PIB utilizando redes neurais . . . . . 99
Figura 35 – Previsão em nível do PIB utilizando redes neurais . . . . . 100
Figura 36 – Previsão do crescimento do PIB utilizando o Random Forest (PIB_externo) 102
Figura 37 – Previsão do PIB em nível utilizando o Random Forest (PIB_externo) . . . . 102
Figura 38 – Importância relativa das variáveis no Random Forest (PIB_externo) . . . . . 103
Figura 39 – Ajuste durante o treinamento do Random Forest (completo) . . . . . 103
Figura 40 – Previsão de crescimento do PIB no Random Forest (completo) . . . . . 104
Figura 41 – Previsão do PIB em nível utilizando o Random Forest (completo) . . . . . 104
Figura 42 – Importância relativa das variáveis no Random Forest (completo) . . . . . 105
Figura 43 – Dependência parcial da Liberdade Monetária . . . . . 107
Figura 44 – Dependência parcial da Balança Corrente (% PIB) . . . . . 108
Figura 45 – Dependência parcial da Investimento Estrangeiro Direto (% PIB) . . . . . 109

## LISTA DE TABELAS

Tabela 1 – Tabela verdade da operação XOR . . . . . 45
Tabela 2 – Fontes de dados utilizadas nas APIs do IBGE, BACEN, World Bank e Heritage Foundation . . . . . 59
Tabela 3 – Constructo da pesquisa . . . . . 62
Tabela 4 – Valores da Função de Autocorrelação (FAC) e Autocorrelação Parcial (FACP) 66
Tabela 5 – Melhores modelos ARIMA nos critérios AIC e BIC . . . . . 66
Tabela 6 – Diagnóstico dos resíduos do modelo: testes de Ljung-Box e Jarque-Bera . . 67
Tabela 7 – Resumo do modelo ARIMA(1, 1, 1) . . . . . 67
Tabela 8 – Componentes do modelo ARIMA(1, 1, 1) . . . . . 67
Tabela 9 – Análise dos resíduos do modelo ARIMA(1, 1, 1) . . . . . 67
Tabela 10 – Previsão e erro fora do treinamento para o ARIMA (1, 1, 1) . . . . . 71

## LISTA DE SIGLAS

**ADF** Dickey-Fuller aumentado

**AIC** Critério de Informação de Akaike

**AR** Auto-Regressivo

**ARIMA** *AutoRegressive Integrated Moving Average*

**BEA** *Bureau of Economic Analysis*

**BIC** Critério de Informação Baysiano

**DCA** Declaração de contas Anuais

**DFM** *Dynamic Factor Model*

**EUA** Estados Unidos da América

**FAC** Função de Autocorrelação

**FACP** Função de Autocorrelação Parcial

**FMI** Fundo Monetário Internacional

**FRED** *Federal Reserve Economic Data*

**GDP** *Gross Domestic Product*

**IA** Inteligência Artificial

**IBGE** Instituto Brasileiro de Geografia e Estatística

**IPCA** Indíce de Preços ao Consumidor Amplo

**IPEA** Instituto de Pesquisa Econômica Aplicada

**LTS** *Long-Short Term*

**MA** Média Móvel

**MCMC** *Markov Chain Monte Carlo*

**OCDE** Organização para a Cooperação e Desenvolvimento Econômico

**PDP** *Partial Dependence Plot*

**PIB** Produto Interno Bruto

**PIM** Produto Industrial Mensal

**PNB** Produto Nacional Bruto

**PP** Phillips Perron

**QDCC** Quadro de Detalhamento das Contas Contábeis

**RMSE** *Root Mean Square Error*

**RNN** *Recurrent Neural Network*

**SELIC** Sistema Especial de Liquidação e Custódia

**SIDRA** Sistema de Recuperação Automática de dados

**VAR** Vetores Autoregressivos

**VEC** Modelo Vetorial de Correção de Erro

**SUMÁRIO**


**1 INTRODUÇÃO** . . . . . 15
**1.1 Problema de pesquisa** . . . . . 16
**1.2 Objetivos** . . . . . 17
***1.2.1 Objetivo Geral*** . . . . . 17
***1.2.2 Objetivos Específicos*** . . . . . 17
**1.3 Justificativa** . . . . . 17
**2 REVISÃO DE LITERATURA** . . . . . 19
**2.1 Predição Econômica: O PIB** . . . . . 19
**2.2 Modelos preditivos** . . . . . 22
***2.2.1 Modelos Tradicionais: Uma explanação*** . . . . . 23
*2.2.1.1 ARIMA* . . . . . *23*
*2.2.1.2 VAR* . . . . . *29*
*2.2.1.3 MIDAS* . . . . . *37*
*2.2.1.4 DFM* . . . . . *40*
***2.2.2 Modelos de Inteligência Artificial (IA): Uma explanação*** . . . . . 41
*2.2.2.1 Redes Neurais* . . . . . *43*
*2.2.2.2 Random Forest* . . . . . *55*
**3 METODOLOGIA** . . . . . 57
**3.1 Delineamento de pesquisa** . . . . . 57
**3.2 Procedimento de coleta de dados** . . . . . 57
**3.3 Procedimento de análise de dados** . . . . . 58
**3.4 Constructo da pesquisa** . . . . . 61
**4 RESULTADOS E DISCUSSÕES** . . . . . 63
**4.1 ARIMA** . . . . . 63
**4.2 VAR** . . . . . 72
**4.3 MIDAS** . . . . . 80
**4.4 DFM** . . . . . 86
**4.5 Redes Neurais** . . . . . 92
**4.6 Random Forest** . . . . . 100
**5 CONCLUSÕES E TRABALHOS FUTUROS** . . . . . 110

**REFERÊNCIAS** . . . . . 113

# 1 INTRODUÇÃO

Para onde vamos? uma das questões fundamentais da natureza humana, estudada pelas mais diferentes ciências, desde exatas às sociais. Dentre as ciências que buscam a resposta do para onde iremos, temos a economia, uma ciência que encontra-se no meio termo, a chamada social aplicada. Inicialmente pode parecer estranho, mas boa parte do trabalho de um economista é entender os fatos passados e presentes para predizer (ou tentar) o futuro, mas a pergunta que fica é por quê a economia se preocupa tanto com o futuro?

Para Mankiw (2025, p. 1) "a economia é o estudo de como a sociedade administra seus recursos escassos", é essa escassez [1] que é o motivador para a preocupação com o futuro, afinal se tivéssemos recursos ilimitados não haveria motivo para estudar economia. Mas este não é o caso, existe limitação de recursos, e devemos saber qual é a melhor maneira de alocar esses recursos.

Para um melhor enfoque, a economia se subdivide em duas grandes áreas, a microeconomia, voltada para o estudo da firma (empresas), e a macroeconomia, que estuda os agregados econômicos (Vasconcelos, 2020)

No presente trabalho nos voltaremos para a macroeconomia, área da economia que surge no inicio do século XX, devido as intensas mudanças sociais, políticas e econômicas que ocorreram no período, a principal obra referência da macroeconomia é o livro de John Maynard Keynes: *Teoria Geral do Emprego, do Juro e da Moeda* 1936, onde o autor traz os principais fundamentos da macroeconomia que é estudada hoje na academia e executada nos governos.

Um desses conceitos fundamentais que Keynes aborda é a noção de incerteza

> De fato, sabemos muito pouco sobre o futuro. A base real para formar expectativas sobre o rendimento futuro de um investimento é extremamente frágil. Nossas decisões de investimento [...] dependem de um estado de confiança. Muitas vezes, sabemos que não sabemos; mas mesmo assim temos que agir. (Keynes, 1936, p. 161)

Com essa noção de incerteza definida por Keynes podemos relacionar com aquela nossa questão fundamental, gestores mundiais, sejam eles públicos ou privados, buscam maneiras de observar dados históricos e com um certo intervalo de confiança tentar "prever o futuro", para justamente, combater a incerteza.

A incerteza gera perguntas, e encontrar as respostas para essas perguntas vai muito além da impressão pessoal do gestor. Os gestores precisam de informação para suas decisões, e

[1] escassez: natureza limitada dos recursos da sociedade (Mankiw, 2025, p. 1)

para Laudon e Laudon (2022) os sistemas de informação são essenciais para alcançar objetivos estratégicos dos negócios. Na era digital, o grande volume de dados gerados pelos sistemas de informação podem ser usados como fontes, praticamente inesgotáveis de dados.

Esses grandes volumes de dados, gerados pelos sistemas de informação, são chamados de *big data*. Para (Vasconcelos, 2017, p. 9) "O *big data* caracterizado por grandes bases de dados com um número elevado de preditores relativos às observações disponíveis". Contudo, somente ter os dados não é o suficiente, e converter esse grande volume de dados em informações não é uma tarefa simples, e exige técnicas sofisticadas de coleta, tratamento e modelagem. Os processos de coleta e tratamento, apesar de fundamentais, serão usados somente como passos anteriores ao da modelagem, que é o enfoque desse texto.

## 1.1 Problema de pesquisa

Avaliar modelos na previsão de variáveis econômicas não é um processo novo, muitos autores já usaram diversas vezes esses modelos.

Em sua dissertação, Azevedo (2020) usou o modelo modelo de vetores auto-regressivos (VAR) para análise de séries temporais com variáveis macroeconômicas. Já Fialho *et al.* (2024) usaram o VAR para entender a dinâmica entre incerteza, spread bancário, crédito, consumo, rendimento e taxa de desocupação.

Ciquini *et al.* (2023) avaliou o uso do modelo auto-regressivo de médias móveis (do inglês *AutoRegressive Integrated Moving Average* - ARIMA) para tomada de decisões econômicas. Agora Silva *et al.* (2025) apoiaram-se no ARIMA para a predição do PIB brasileiro.

Alves (2009) em sua dissertação de mestrado abordou modelos de fatores dinâmicos (do inglês *Dynamic Factor Models* - DFM) para entender o núcleo da inflação brasileira. Por outro lado Moura *et al.* (2020) avaliou os ciclos econômicos brasileiros usando uma combinação entre o DFM e o VAR.

Castelli (2022) abordou o uso do modelo de amostragem de dados mistos (do inglês *Mixed Data Sampling* - MIDAS) para predizer o PIB com a pesquisa industrial mensal. Assim como Micheletti (2024) usou modelos de *ensemble stacking* [2] (dentre eles o MIDAS) para prever o PIB.

A maioria desses autores trabalharam com o que se chamam modelos tradicionais de predição, esses modelos se baseiam em variáveis e proposições bem definidas, o que pode

[2] *ensemble stacking*: modelos combinados

não ser o caso na era do *big data*. Nesse contexto, em que os modelos tradicionais encontram-se limitados, que a inovação surge, nesse caso o uso de técnicas de IA para modelar variáveis econômicas.

Diante do disso a presente pesquisa tende a seguir os passos de Kava (2022) e de Rebelo (2022) que comparam, em suas dissertações, modelos de IA com os chamados modelos tradicionais. Contudo, a nossa pesquisa se diferencia dos trabalhos produzidos por testar outros modelos e focar especificamente no PIB brasileiro, para isso norteia-se pela seguinte pergunta: Como desenvolver um modelo preditivo baseado em IA para efetivamente estimar o PIB brasileiro, considerando as diferenças e semelhanças significativas entre os modelos tradicionais VAR, ARIMA, DFM e MIDAS.

## 1.2 Objetivos

### *1.2.1 Objetivo Geral*

Desenvolver um modelo preditivo baseado em IA para efetivamente estimar o PIB brasileiro, considerando as diferenças e semelhanças significativas entre os modelos tradicionais VAR, ARIMA, DFM e MIDAS.

### *1.2.2 Objetivos Específicos*

a) Caracterizar os modelos econométricos tradicionais (VAR, ARIMA, DFM e MIDAS) e de IA para a predição do PIB;
b) Identificar as diferentes variáveis determinantes na estimativa do PIB;
c) Desenvolver um ciclo de vida para a produção de um novo modelo econométrico de IA para a predição do PIB;
d) Comparar o desempenho dos modelos de IA e tradicionais usando diferentes métricas, como desempenho computacional, precisão e interpretabilidade.

## 1.3 Justificativa

O presente trabalho justifica-se empiricamente, pois permite que gestores, sejam eles públicos ou privados, utilizem-se de ferramentas estatísticas para tomarem decisões fundamentadas. "A tomada de decisões empresariais é uma tarefa complexa e fundamental para a

sobrevivência de uma organização"(Santana *et al.*, 2023, p. 3).

Portanto, a tomada de decisões pode ser fundamentada através dos modelos. Os modelos, mesmo que sejam uma simplificação da realidade, podem aumentar a confiança dos agentes. Segundo Keynes (1936), essa confiança é um fator que afeta as decisões de investimento.

Já contribuição teórica desse trabalho está alinhada com a avaliação dos diferentes modelos estatísticos para a predição econômica, além é claro, de explorar as novas fronteiras da ciência, com a avaliação de modelos inovadores como os que usam a IA.

Embora Kava (2022), Castelli (2022), Rebelo (2022), Vasconcelos (2017), Carmo e Lopacinski (2023), entre outros. Já se debruçaram sobre a análise macroeconômica utilizando modelos de IA, ainda falta investigar onde modelos baseados em IA se encaixam na predição do PIB brasileiro, portanto este estudo pretende preencher essa lacuna, investigando se a construção de um modelo baseado em IA consegue predizer o PIB brasileiro com eficiência, utilizando como métrica, o desempenho relativo aos modelos chamados tradicionais.

O presente trabalho busca mesclar diferentes modelos, ranqueando seu desempenho, e possibilitando a identificação dos modelos mais adequados para previsão econômica. Para isso é necessário a avaliação métricas estatísticas comuns, semelhante ao que Castelli (2022) fez, ao comparar modelos de IA com modelos tradicionais, aplicando métricas como coeficiente de determinação ($R^2$), Erro Médio Absoluto (MAE), Erro Quadrático Médio (MSE) para classificar os modelos.

# 2 REVISÃO DE LITERATURA

A presente sessão busca avaliar os estudos até então construídos que perpassam sobre as temáticas correlatas, desde a evolução dos modelos preditivos, a variável estudada: o Produto Interno Bruto (PIB), o uso de modelos preditivos em variáveis macroeconômicas, por fim a avaliação e comparação de modelos preditivos.

Dado esse contexto, a presente revisão de literatura se estruturará da seguinte forma, primeiramente iremos tratar sobre predição econômica de um modo geral e seus principais autores, logo em seguida discutiremos sobre nossa variável foco o PIB, posteriormente classificaremos os modelos em tradicionais e não-tradicionais, onde será descrito cada modelo o conceito, o histórico, o modelo matemático e a aplicação do mesmo no contexto de predição do PIB. Após essa conceituação será analisado as métricas de comparação dos modelos, e como elas vem sendo aplicadas. Após a conceituação e análise das métricas de avaliação, serão abordados os trabalhos acadêmicos que já compararam modelos tradicionais e não tradicionais.

## 2.1 Predição Econômica: O PIB

A predição de variáveis econômicas não é uma tarefa nova, na realidade estipular o comportamento de variáveis econômicas ao decorrer do tempo é um desejo dos economistas desde o início do século XX. Em seu artigo, Frisch (1929) [1] trata do conceito da teoria dinâmica, que se subdivide em analítica e histórica, a primeira lida com as leis que regem as flutuações das variáveis, já a segunda trata de aplicar as leis para descrever/prever as variáveis. Essa conceituação teórica de Frisch (1929) é justamente o que hoje é considerado como econometria, e foi a base para os futuros modelos econométricos e suas aplicações.

Contudo, a economia ficou mais complexa desde 1929, conforme Almeida (2001) a economia do início século XX passou por sua fase madura de industrialização incorporou uma grande quantidade de inovações tecnológicas advindos da Segunda Revolução Industrial. Ainda segundo o autor, "a estrutura da produção foi radicalmente transformada pelas mudanças introduzidas nos padrões de trabalho (especialização) e pelos avanços tecnológicos, que aumentaram dramaticamente o produto per capita."(Almeida, 2001, p. 2).

Esse processo se repetiu durante a Terceira Revolução Industrial, Júnior (2017) aponta que esse processo não foi hegemônico, mas foi caracterizado por uma revolução tecno-

[1] Frisch é considerado um dos fundadores da econometria moderna, é a ele atribuído a formulação do termo econometria

científica, não só nas fábricas como na maioria das atividades sócio-econômicas. Durante esse período houve intensas mudanças na atividade produtiva. Contudo alguns autores apontam que a humanidade passou por mais uma revolução, a Quarta Revolução Industrial, ou também chamada de Indústria 4.0.

O termo industria 4.0[2] é citado pela primeira vez na feira de Hannover como uma nova política Alemã para industrialização (Kagermann *et al.*, 2013). Um dos autores defensores de uma nova fase da industria é Martins (2021), onde ele argumenta que a Indústria 4.0 traz muitas mudanças no contexto onde ela é aplicada, como novos modelos de negócio e mercados cada vez mais exigentes.

Mas não somente a economia ficou mais complexa, o advento da indústria 4.0 trouxe a possibilidade de coletar e processar grandes volumes de dados através do que chamamos de sistemas de informação. Que para Laudon e Laudon (2022) são essenciais para alcançar objetivos estratégicos dos negócios. Essas informações são fundamentais para toda decisão, seja ela do setor público ou privado.

> A eficácia das políticas depende do uso de todas as informações disponíveis em qualquer momento, incluindo informações prospectivas, como desempenho do mercado de ações e a incerteza da política econômica, disponíveis no ponto de estimativa. (Ghosh e Ranjan, 2023, p. 19)

Nesse sentido da importância das informações, muitos indicadores econômicos foram criados, melhorados ou superados, tanto no sentido microeconômico dentro das firmas, assim como indicadores macroeconômicos dos grandes agregados. E um desses indicadores macroeconômicos que evoluiu com o tempo busca estimar a produção total interna de uma localidade, o chamado PIB. Segundo o Instituto Brasileiro de Geografia e Estatística (IBGE) "o PIB é a soma de todos os bens e serviços finais produzidos por um país, estado ou cidade, geralmente em um ano."(IBGE, 2026, p. 1).

O Banco Central do Brasil trás dois conceitos para o PIB: "a preços de mercado, (o PIB) mede o total de bens e serviços produzidos pelas unidades produtoras residentes destinados ao consumo final (exclui o consumo intermediário)."(Banco Central do Brasil, 2026, p. 1). Além disso o Banco Central do Brasil (2026) trás também a ideia do PIB em reais correntes que se refere ao valor dos bens e serviços finais produzidos em determinado período e valorados a preços de mercado do respectivo período, ou seja sem retirar a inflação. Ambos representam

[2] Industria 4.0: é a transformação digital na indústria, onde a mesma integra tecnologias como a própria Inteligência Artificial

a totalidade de bens e serviços produzidos, e tem o mesmo quantitativo quando analisados no mesmo ano base, mas quando se análisa em períodos de tempo diferentes o PIB a preços de mercado é considerado o PIB real, pois exige um calculo para retirar a inflação das medições do PIB, enquanto o PIB em reais correntes sempre se refere ao valor nominal do PIB naquela data, esse geralmente é o valor divulgado pelas bases de dados, como o próprio Banco Central ou o IBGE.

O conceito internacional de PIB é semelhante com os conceitos do Banco Central do Brasil e do IBGE. Segundo o U.S. Bureau of Economic Analysis (2026) o PIB mede o valor dos bens e serviços finais produzidos, sem contar os bens e serviços intermediários. A agência estadunidense de divulgação e análise econômica também trás o motivo pelo qual o PIB é tão importante afinal "as mudanças no PIB são o indicador mais popular da saúde econômica geral do país"(U.S. Bureau of Economic Analysis, 2026, p. 1)

Nesse sentido o PIB funciona como um termômetro da atividade econômica, e se indicadores refletem a realidade, é lógico pensar que conforme a economia fica complexa, seus indicadores as acompanham, assim como as tentativas de tentar prever seu comportamento.

E nesse contexto temos a predição do PIB, que é algo estudado por diversos pesquisadores, muitos dos quais veremos no decorrer dessa revisão de literatura, mas também de órgãos e instituições públicas e privadas, como é o caso do Instituto de Pesquisa Econômica Aplicada (IPEA) que pontua a importância da predição do PIB "para a definição dos parâmetros para o planejamento fiscal e orçamentário do setor público, bem como para a formação de expectativas no setor privado."(Santos e Nolau, 2022, p. 6).

Dado toda essa evolução, é natural perceber a complexificação desse indicador, desde o século XX com o início da econometria, até os dias atuais com os grandes volumes de dados e a necessidade de decisões fundamentadas, esses fenômenos complexos atuais implicam que métodos tradicionais de predição podem não conseguir descrever a realidade com a mesma precisão da época da qual foram elaborados.

Deste modo, chegamos a um momento de inflexão. Complexidade sistêmica combinada ao grande volume de dados pode fazer com que modelos econométricos tradicionais[3] não consigam representar a realidade, pois, até que ponto uma simplificação pode representar realmente o comportamento econômico.

Dessa forma, se o tradicional não tem o comportamento esperado recorre-se ao

[3] No presente trabalho trataremos que os modelos econométricos tradicionais são aqueles baseados na linearidade das variáveis, ausência de multicolinearidade, homocedasticidade e normalidade dos resíduos

inovador. Essa inovação, no contexto dos modelos econométricos, vem através da incorporação de modelos estatísticos que suportam a complexidade econômica, além de tecnologias computacionais que conseguem tratar esse volume de dados gerados pelos sistemas de informação.

## 2.2 Modelos preditivos

Antes de partirmos para inovação devemos entender o que de fato são esses modelos preditivos. Tomando como princípio o texto de Frisch (1929) a econometria surge justamente para aplicar as leis que regem a economia. Para o autor é a teoria dinâmica histórica, que busca evidenciar as relações entre as variáveis, não por suposição cega, mas sim, baseando-se em séries temporais já existentes. Frisch (1929) trata do que ainda viria se tornar a econometria moderna, ademais, existem diversos tipos de modelos econométricos, e os modelos preditivos fazem parte desse conjunto. Portanto se faz necessário identificar exatamente do que se tratam esses modelos.

Para Assunção (2012, p. 8) esses modelos "correspondem a uma equação (ou regra) na qual através de informações históricas ou atuais predize-se um determinado evento futuro a respeito de um indivíduo". Deste modo, a partir do conceito de Assunção (2012) entendemos que independente do modelo: Sempre haverá uma entrada (*input*) de variáveis, sejam elas históricas ou contemporâneas; Haverá também, um processamento desses dados pelo modelo, seja por uma equação matemática ou um preceito estabelecido; E sempre ocasionará em uma saída (*output*), e no caso de modelos preditivos, essa saída terá por objetivo estipular uma variável no tempo futuro.

Com essa definição, retomamos nossos objetivos, como desejamos estimar o PIB nossa saída sempre será um valor numérico que estimará como o PIB brasileiro se comporta. Portanto as únicas variações possíveis nos modelos são: a estrutura; e as variáveis de entrada. Durante a explanação dos modelos trataremos especificamente sobre suas estruturas e estradas, e poderemos nos debruçar melhor sobre o que diferencia cada modelo preditivo.

Entendido o que são modelos preditivos partiremos para diferenciar modelos tradicionais dos de IA, assim como a explanação específica de cada modelo usado no presente estudo, seu histórico, sua construção matemática, por fim a aplicação desses modelos na predição do PIB. Para atendermos esses pontos e concluir nossos objetivos deveríamos seguir algum tipo de sequência lógica para apresentar tais modelos, a abordagem mais simples seria em uma sequência temporal de surgimento, contudo, muitos modelos complexos surgiram antes de versões mais simplificadas. Dessa forma optamos por apresentar os modelos em uma sequência didática,

primeiro tratando dos modelos tradicionais, em seguida os que são baseados em IA, de um forma que julgamos facilitar o entendimento.

### *2.2.1 Modelos Tradicionais: Uma explanação*

Os modelos tradicionais, são modelos simples, geralmente associados a métodos lineares de aprendizado de máquina[4] "tem esse nome porque assumem que a função que define $E(Y|X)$ é linear nos preditores $X1, X2, ..., Xp$."(Vasconcelos, 2017, p. 14). Rebelo (2022) ainda aponta que os modelos chamados tradicionais possuem uma interpretabilidade natural[5], e não possuem a necessidade de um método de interpretação adicional.

Segundo Braga (2025) os modelos tradicionais dominaram o mundo, quando o assunto era predição de variáveis durante muitos anos. Entretanto conforme a complexidade econômica aumentava, novas alternativas foram surgindo, para a autora "Apesar da eficácia desses modelos tradicionais em determinados cenários, os avanços computacionais e a crescente disponibilidade de dados favorecem o desenvolvimento de abordagens mais sofisticadas"(Braga, 2025, p. 12).

Dado o tempo em que os modelos tradicionais eram as únicas opções, essas técnicas ganharam muitas variações, algumas mais sofisticadas, outras mais simplificadas, dessa forma, para o presente estudo nos limitaremos a abordar quatro modelos tradicionais, um modelo temporal univariado (ARIMA), um modelo temporal multivariado (VAR), um modelo baseado em fatores dinâmicos (DFM) e um modelo de frequência mista (MIDAS). A escolha desses modelos se deve a diferença entre como eles processam as entradas, sendo excelente para apresentar como métodos diferentes se comportam na previsão de uma variável macroeconômica como o PIB.

#### *2.2.1.1 ARIMA*

Seguindo a proposta didática, começaremos pelo ARIMA, no sentido de simplicidade de interpretação e complexidade em geral, o ARIMA é o modelo mais simples que será tratado nesse trabalho, a sigla ARIMA vem do inglês *AutoRegressive Integrated Moving Average*

[4] Muitos autores argumentam que o aprendizado de máquina, ou *machine learning* é um parte da grande área da IA, o que de certa fora toda econometria tradicional poderia ser enquadrada como Inteligência Artificial, mas na realidade o que chamamos de IA são modelos não-lineares modernos, mas trataremos disso mais profundamente na subseção 2.2.2

[5] A definição de Rebelo (2022) de certa forma é mais precisa, pois modelos não-lineares como árvores de decisão são classificadas como modelos tradicionais pela sua interpretabilidade.

(ARIMA) que significa Média Móvel Integrada Autorregressiva, a sua simplicidade se deve ao fato de que ele tenta predizer a variável estudada usando sua própria série histórica. Nesse caso usaremos a série histórica do PIB para prever o possível valor futuro do mesmo.

O modelo ARIMA nos servirá como um ótimo parâmetro de comparação, por se tratar de um modelo simples, com baixo custo computacional e alta interpretabilidade, ele poderá ser usado para avaliar outros modelos testados. Se um modelo complexo com alto custo computacional e interpretabilidade baixa, se sair pior ou semelhante ao ARIMA na previsão do PIB, poderá ser um indicador que aquele método não apresenta uma relação custo-benefício favorável, levando a crer que o modelo não é adequado[6] para a predição do PIB.

Segundo Braga (2025) o modelo ARIMA é sistematizado em 1970 no livro de Box e Jenkins (1970). Neste livro os autores afirmam que os modelos do tipo ARIMA fazem parte do conjunto a cujo a $d$-ésima diferença da série é um processo estacionário misto autorregressivo de média móvel (Box e Jenkins, 1970). Além disso os autores apontam a necessidade desses modelos em aplicações reais.

> Muitas séries temporais empíricas (por exemplo, séries de preços de ações) se comportam como se não tivessem uma média fixa. No entanto, elas exibem homogeneidade no sentido de que, além do nível local, ou talvez nível local e tendência, uma parte da série se comporta de forma muito semelhante a qualquer outra parte. Modelos que descrevem tal comportamento não estacionário homogêneo podem ser obtidos assumindo que alguma diferença adequada do processo é estacionária. (Box e Jenkins, 1970, p. 88, tradução nossa)

No sentido de definição e contexto para nosso trabalho, o modelo ARIMA tem um grande potencial para a predição do PIB, pois o comportamento sazonal[7] do PIB, torna ele uma variável parecida com a descrita no exemplo de Box e Jenkins (1970), sem uma média fixa aparente, mas uma certa homogeneidade de nível local e tendência, semelhante ao decorrer da série. Contudo Box e Jenkins (1970) não somente descreveram em que caso o modelo ARIMA seria adequado, mas também sua formulação matemática e metodologia de aplicação.

O modelo ARIMA(p,d,q) pode ser representado pela seguinte forma geral (Box e Jenkins, 1970, p. 94):

$$\varphi(B)z_t = \phi(B)\nabla^d z_t = 0_0 + 0(B)a_t \tag{2.1}$$

[6] Isso parte de um pressuposto simples, porém para descartar completamente o modelo, seriam necessários outros testes, com outros dados para efetivar com clareza essa suposição, porém isso fugiria do escopo do nosso trabalho.

[7] Observaremos as variações do PIB nos nossos resultados.

onde

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$$
$$O(B) = 1 - 0_1 B - 0_2 B^2 - \cdots - 0_p B^p$$

Em que:

a) $\phi(B)$ operador autorregressivo (AR)[8]

b) $\varphi(B) = \phi(B)\nabla^d$ operador autorregressivo generalizado

c) $0(B)$ operador de média móvel

Desse modo utilizaremos a formulação de Box e Jenkins (1970) para a predição do PIB, assim como os testes que comprovam a aplicabilidade do ARIMA no contexto do PIB. Todavia o trabalho de submeter a predição do PIB ao modelo ARIMA já foi realizado por outros autores.

Nesse sentido, revisaremos o trabalho de Silva *et al.* (2025) que apoiaram-se no ARIMA para a predição do PIB brasileiro, no trabalho foi analisado a série histórica do PIB brasileiro de 1990 até 2023[9] sendo uma fonte metodológica e comparativa para nossa pesquisa.

O primeiro passo dos autores na aplicação do modelo foi uma análise visual da série temporal, os autores consideraram o comportamento de volatilidade do PIB, com crescimentos e decrescimentos, propondo a possibilidade de uso do modelo ARIMA. Para confirmar essa hipótese eles aplicaram o teste Dickey-Fuller aumentado (ADF)[10] em que evidenciou-se ADF= -0.848 e o Valor-p= 0.804, como o Valor-p é superior ao valor crítico de 0.05, indica-se que não se pode rejeitar a hipótese nula de que a série possui uma raiz unitária, indicando que a série não é estacionária no estado original.

A partir do resultados da não estacionaridade seria necessária a diferenciação da série original para tornar a série estacionária, isso implica no uso do modelo ARIMA (p, d, q) com d = 1. Após a primeira diferenciação os autores obtiveram um teste ADF e um Valor-p[11] que configuram uma série estacionária confirmando a abertura para utilização do modelo ARIMA.

Após a confirmação do uso do modelo ARIMA, os autores utilizaram a metodologia Box-Jenkins, essa metodologia é "um processo sistemático de identificar, estimar e diagnosticar

[8] Assume-se que é estacionário.

[9] Enquanto o recorte de Silva *et al.* (2025) foi de cerca de 33 anos (1990-2023), o nosso será relativamente menor, de 2007 à 2022 (15 anos), devido a disponibilidades de outras variáveis que não somente o PIB.

[10] A fim de organizar nossa pesquisa trataremos de forma compilada todos os testes na sessão **??**, nela esmiuçaremos os testes que comprovam a utilização dos modelos, assim como os testes que serão usados para comparar os diferentes modelos.

[11] A fim de curiosidade os valores dos teste foram: teste ADF (Série Diferenciada): -3.771 e um Valor-p: 0.00321.

modelos de séries temporais ARIMA"(Silva *et al.*, 2025, p. 6). São quatro passos para aplicação dessa metodologia: identificação, estimação, diagnóstico e previsão.

Na fase de identificação os autores usam a Função de Autocorrelação (FAC) e a Função de Autocorrelação Parcial (FACP) para determinar a estrutura do modelo. A seleção do modelo é feita a partir de critérios de informação, como o Critério de Informação de Akaike (AIC) e Critério de Informação Baysiano (BIC). Para a avaliação dos resíduos[12] usaram o teste Ljung-Box e o teste Jarque-Bera. O último passo é a previsão, passo esse que os autores fizeram uma extrapolação de 6 anos[13] e compararam com a estimativa do PIB realizada pelo Fundo Monetário Internacional (FMI).

Na fase de identificação os testes FAC e FACP apresentaram ambos com um pico no lag 1, com um decaimento nos lags seguintes. O pico no lag 1 no teste FAC apresenta um comportamento de Média Móvel (MA) fora do intervalo de confiança, assim apresentam que o parâmetro $(q)$ da MA seria igual a 1. Já no teste FACP o pico no lag 1, sugere um comportamento de Auto-Regressivo (AR) de ordem 1, ou seja $(p = 1)$. Configurando o modelo obtido sendo ARIMA(1,1,1).

Contudo os autores não somente estimaram o modelo ARIMA(1,1,1). No processo de estimativa, os atores testaram outros quatro modelos com $p - value < 0.05$. Contudo dentre esses que foram testados, o modelo ARIMA(1,1,1) obteve os resultados mais competitivos, quanto menor melhor, nos critérios AIC e BIC[14]

No sentido dos resíduos os autores aplicaram o teste de Ljung-Box[15], onde foi confirmado a ausência de autocorreção significativa, além disso foi aplicado o teste de Jarque-Bera para verificar a distribuição dos resíduos, contudo o teste indicou que os resíduos não seguem uma distribuição normal, o que por si só não é um problema, que apesar de preferível, a não normalidade dos resíduos não descarta o modelo ARIMA(1,1,1). A partir da análise gráfica e da Função de Autocorrelação dos Resíduos (FAC) os autores chegaram a conclusão que o modelo ARIMA ajustado foi eficiente para remover a estrutura de autocorrelação dos dados, restando somente um ruído branco.

Para validar o modelo os autores compararam a projeção do ARIMA(1,1,1) para os 6 anos seguintes com a projeção feita pelo FMI, como justificava para tal comparação os

[12] Os autores apresentam que o comportamento dos resíduos devem ser independentes, não podem apresentar uma autocorrelação significante e idealmente devem apresentar uma distribuição normal.

[13] De 2024 à 2029.

[14] A fim de curiosidade os valores dos testes são: AIC=1.878.932 e BIC=1.884.038.

[15] Estatística de Ljung-Box = 10,69, valor-p = 0,38

autores elencaram como o FMI utiliza em sua projeções mais variáveis, com complexidade maior. Dessa forma, o modelo ARIMA apresentou uma capacidade satisfatória para capturar a estrutura temporal do PIB brasileiro. Porém os autores ainda elencam possíveis falhas do modelo, como as limitações ao modelar choques econômicos e o viés potencialmente otimista do ARIMA em comparação as projeções do FMI.

Os autores apontam que

> Apesar da utilidade do ARIMA como ferramenta inicial para análise e previsão de séries temporais econômicas, suas estimativas devem ser interpretadas com cautela e, preferencialmente, complementadas por métodos qualitativos e modelos econométricos que considerem o amplo espectro de variáveis que afetam o crescimento do PIB. Essa integração entre abordagens quantitativas e qualitativas potencializa a confiabilidade das projeções e contribui para decisões mais fundamentadas no âmbito da política econômica. (Silva *et al.*, 2025, p. 15)

A conclusão dos autores vai de encontro com o objetivo que propomos para o ARIMA no presente trabalho: atuar como um modelo inicial e de comparação com os modelos seguintes, como uma métrica de simplicidade e eficiência em comparar os padrões do PIB no decorrer do tempo.

Mas não é somente no Brasil que o modelo ARIMA é utilizado, este modelo continua sendo apresentado como alternativa relevante dentro da predição econômica univariada em todo o mundo. A dissertação de mestrado de Li (2024) é uma prova de como o modelo ainda vem sendo utilizado e testado até nos dias presentes, em economias complexas como a estadunidense.

Em seu trabalho Li (2024) avalia o desempenho de diferentes modelos em cenários de choques econômicos, especificamente o mais recente do período[16] que abrangeu a pandemia do COVID-19. Nesse trabalho um dos modelos testados foi o próprio modelo ARIMA para a predição do *Gross Domestic Product* (GDP)[17] ele foi utilizado no mesmo sentido que pretendemos utilizá-lo como um modelo comparativo de teste, para avaliar o desempenho de outros modelos avaliados.

Os dados da dissertação foram obtidos do *Federal Reserve Economic Data* (FRED)[18]. A partir dos testes realizados comprovou-se que "O PIB é uma série temporal estacionária ao nível de significância de 5% pelo ADF"(Li, 2024, p.22, tradução nossa) confirmando uma série estacionária, assim d=0. Na aplicação dos testes FAC e FACP a autora identifica que os picos

[16] O recorte de tempo de Li (2024) foi de 1960 até 2023

[17] O GDP é o equivalente ao nosso PIB

[18] Dados Econômicos da Reserva Federal, trata-se de uma banco de dados americanos com dados financeiros, econômicos e demográficos dos Estados Unidos da América (EUA)

ficaram em 0 para a FAC (MA) e também para FACP (AR) com o lag em 0, configurando o modelo ARIMA(0, 0, 0). No sentido da estatística de Ljung-Box também não apresentou "evidências significativas contra as autocorrelações de defasagem serem 0"(Li, 2024, p.25, tradução nossa).

Ao aplicar os diferentes testes e modificar os parâmetros do ARIMA para os dados de treinamento, comprovou-se que o modelo que mais se aproximou do resultado esperado foi o ARIMA(1, 0, 2), e dentre os modelos de *benchmark* foi o que obteve os melhores resultados[19]. O modelo ARIMA performa de uma maneira satisfatória inclusive contra os modelos de multivariados complexos testados[20].

Assim como apontado por Silva *et al.* (2025) o modelo ARIMA ainda tem suas limitações. A partir dos resultados de Li (2024) conseguimos ver essas limitações, que comparado a alguns modelos multivariados o modelo ARIMA falha em capturar a realidade com precisão devido a suas simplificações.

De todo modo, podemos confirmar o ARIMA como o candidato perfeito como modelo de teste, configurado com um baixo custo computacional, desempenho formidável e relativa aplicação simplificada. O modelo ARIMA será utilizado em nosso trabalho como modelo comparativo. Veremos mais sobre a aplicação do ARIMA no capítulo 4 onde veremos o desempenho do mesmo semelhante ao olhar de Silva *et al.* (2025), mas com o princípio comparativo de Li (2024).

O modelo ARIMA, e no geral todos os modelos univariados têm um problema, a limitação estrutural do modelo. Afinal variáveis complexas, como o próprio PIB, sofrem de influências de diferentes fatores - de todas as naturezas, desde dados intimamente ligados a variável escolhida, até dados que parecem não ter relação alguma. Entretanto para afirmar ou rejeitar essa disposição, são necessários testes de correlação e modelos que realmente suportem indicar um certo grau de predição usando relações que não são univariadas. Esses modelos serão tratados a partir desse ponto no presente estudo.

[19] Os modelos de *benchmark* foram: o modelo ETS e a regressão de transformada de Fourier, e obtiveram resultados parecidos, mas ligeiramente piores que o ARIMA

[20] No caso dessa dissertação os modelos complexos eram do tipo PCA, que são multivariados e mais complexos do que o ARIMA, mesmo assim o modelo performou melhor nos dados de treinamento e validação melhor que modelos de complexidade maior

#### *2.2.1.2 VAR*

O modelo VAR é o primeiro modelo multivariado que nos debruçaremos em sua composição, utilização e aplicabilidade à predição do PIB. Seguindo nossa trilha didática, espera-se que o modelo VAR seja naturalmente mais complexo que modelos univariados - como o ARIMA. E de certa forma é isso que acontece, mas não quer dizer que a interpretabilidade do modelo, no sentido natural, se altere. Muito pelo contrário o VAR continua sendo um modelo intuitivo e explicável no âmbito das relações entre variáveis.

Nesse contexto de sistemas complexo de relações, há uma infinidade de variáveis que podem ser aplicadas. Modelos que conseguem identificar essas relações, mesmo que de forma limitada[21], são essenciais, não se trata mais de modelar a relação da variável e sua série temporal, mas sim identificar a relação de diferentes variáveis umas com as outras e com o tempo.

Entendido onde os modelos multivariados se encaixam na predição estatística, falaremos sobre o modelo escolhido, o VAR. O acrônimo VAR vem de *Vector Autoregression* trata-se de um modelo estatístico descrito pela primeira vez por Sims (1980), surgindo da necessidade de modelar sistemas multivariados reais[22], não em situações puramente hipotéticas e teóricas.

Sims (1980) ajustou séries temporais trimestrais do período pós-guerra dos EUA e da Alemanha Ocidental sobre dinheiro, Produto Nacional Bruto (PNB)[23], taxa de desemprego, nível de preços e índice de preços de importação, usando uma autoregressão vetorial sem restrições.

Esse trabalho nos forneceu a metodologia para aplicar o VAR sem as restrições teóricas fortes de identificação estrutural de modelos anteriores. A partir dessa aplicação Sims (1980) apresentou as características do que hoje chamamos de VAR. Trata-se de um sistema de equações multivariadas que evita impor conhecimentos a *priori*, ou seja, o modelo trata todas as variáveis como endógenas[24].

Sims (1980) discorre sobre a aplicabilidade do VAR, e aponta que modelos anteriores, mesmo os multivariados, assumem a exogeneidade das variáveis. Segundo o autor esses modelos dificultam capturar interdependências dinâmicas entre variáveis como as interações entre o lado

[21] Ao aplicar o VAR não é possível lidar com a "infinidade"de variáveis, somente com algumas dezenas no máximo, contudo existem modelos mais avançados - ainda tradicionais - que lidam bem com centenas de variáveis, veremos esses em breve.

[22] Inclusive surge em um contexto de modelar variáveis macroeconômicas - como o PIB - afinal o título do ensaio de Sims (1980) é justamente Macroeconomia e Realidade

[23] O PNB diferencia-se do PIB, pois o PNB leva em conta renda líquida enviada e recebida do exterior, ou seja para nações com muitas multinacionais a tendencia é PNB > PIB, já em nações dependentes de empresas estrangeiras em solo nacional a tendência é o PIB > PNB

[24] Variáveis endógenas são aquelas determinadas dentro do próprio sistema de equações.

real (produção) e o lado monetário da economia (inflação dos preços).

O modelo VAR descrito por Sims (1980) apesar de conceitualmente definido, ainda sofreu modificações, o modelo atual que usaremos pode ser visualizado pelas equações 2.2 e 2.3, em suas variações com menor e maior defasagem, consultadas de (Costa, s.d.).

Uma série temporal multivariada $\mathbf{r_t} = (r_{1t}, r_{2t}, ..., r_{kt})'$ composta por $k$ componentes no tempo $t$ é um processo VAR(1), que segue o modelo:

$$r_t = \phi_0 + \Phi r_{t-1} + a_t \tag{2.2}$$

onde

a) $\phi_0$ é um vetor de dispersão $k$;
b) $\Phi$ é uma matriz $k \times k$; e
c) $a_t$ é um ruído branco formado por uma sequência de vetores aleatórios independentes, distribuídos de forma idêntica, com média 0 e matriz de covariância $\sum a$.

Já para modelos com uma defasagem maior, usá-se o VAR($p$), nele uma série temporal multivariada $\mathbf{r_t} = (r_{1t}, r_{2t}, ..., r_{kt})'$ com $p > 0$:

$$r_t = \phi_0 + \Phi_1 r_{t-1} + ... + \Phi_p r_{t-p} + a_t \tag{2.3}$$

onde

a) $\phi_0$ é um vetor de dispersão $k$;
b) $\Phi$ são matrizes $k \times k$ para $j = 1, ..., p$; e
c) $a_t$ é um ruído branco formado por uma sequência de vetores aleatórios independentes, distribuídos de forma idêntica, com média 0 e matriz de covariância $\sum a$.

Com o contexto de surgimento do VAR e sua definição matemática, partiremos para a aplicação do VAR na literatura, ao contrário do que fizemos no ARIMA de analisar somente o PIB, referente ao Brasil, e o GDP referente aos EUA. No modelo VAR buscaremos uma análise um pouco mais detalhada com diferentes variáveis em outros contextos.

Trataremos da relação entre variáveis reais, monetárias e da incerteza da com texto de Fialho *et al.* (2024). Observaremos o PIB per capita sob uma análise regional brasileira do ponto de vista de Oliveira e Junior (2024). Por último recorreremos a literatura internacional, para observar como uma variação do modelo VAR é utilizada para estimar o crescimento do GDP estadunidense proposto por Koop *et al.* (2025).

No primeiro trabalho abordado, a proposta dos autores é investigar "a causalidade de Granger entre incerteza, spread bancário e consumo das famílias no Brasil, utilizando um modelo VAR com dados mensais de janeiro de 2013 a janeiro de 2024"(Fialho *et al.*, 2024, p. 1). Nesse trabalho foram selecionadas 6 séries de variáveis, dentre elas: Consumo Aparente - produção doméstica acrecida de importações e deduzido as exportações; Spread Médio para Pessoa Física - diferença entre a taxa média de juros de novas operações de crédito e o custo de captação referencial médio; Incerteza - índice de Incerteza da Política Econômica (EPU); Rendimento - rendimento bruto real médio, recebido no mês de referência, a série foi deflacionada usando o (IPCA); Concessão de Crédito pessoa física - valor das novas operações de crédito realizadas no período de referência; Taxa de desocupação - Percentual de pessoas economicamente ativas que estavam procurando trabalho, percentual de pessoas desocupadas em relação as pessoas na força de trabalho.

Segundo Fialho *et al.* (2024) as variáveis foram submetidas ao modelo VAR devido a capacidade do modelo de lidar com múltiplas variáveis pertencentes a séries temporais, e considerando as mesmas como endógenas. Justamente vem de encontro com a proposta de Sims (1980), confirmando a aplicação do modelo. A metodologia justifica-se pela possibilidade de modelar a interação entre variáveis reais e monetárias, não com uma teoria a *priori*, mas sim buscando investir a interação entre as variáveis. Para confirmar a adequação estatística dos dados, foram aplicados dois testes: Dickey-Fuller e Phillips-Perron para verificar a estacionariedade.

Para os autores

> VAR é um modelo com n variáveis e n equações que expressa cada variável como uma função linear de seus próprios valores passados, dos valores defasados das demais variáveis empregadas e de um termo de erro serialmente não correlacionado. (Fialho *et al.*, 2024, p. 6).

O conceito exposto por Fialho *et al.* (2024) segue a mesma equação 2.2 apresentada anteriormente.

Para o prosseguimento da utilização do modelo VAR é necessário que as variáveis sejam estacionárias, o que foi testado utilizando a estatística Dickey-Fuller. A um nível de significância de 10% quatro variáveis não são estacionárias: spred médio pessoa física (p = 0.6054); incerteza ( p = 0.0844); concessão de crédito pessoa física (p=0.7486 e taxa de desocupação (p= 0.6635). Para testar a hipótese nula em que as séries possuem raízes unitárias, foi utilizado o teste Phillips-Perron, que apresentou spred médio pessoa física (p =0.4832); incerteza (p = 0.0583); concessão de crédito pessoa física (p=0.9137) e taxa de desocupação

(p=0.6320). Com esses resultados, o próximo passo foi realizar o mesmo teste com as variáveis defasadas[25], o que implicou no cumprimento da suposição de estacionariedade e de inexistência de raiz unitária para as variáveis.

Com o cumprimento das suposições estatísticas, seria necessário determinar o número de defasagens para o modelo, afinal se "forem muito pequenas o modelo terá problemas de sobrespecificação e, caso sejam muito grandes, perdem-se graus de liberdade"(Fialho *et al.*, 2024, p. 7). Pelos critérios Akaike, Schwartz e Hannan-Quinn o número ideal de defasagens seria 2. Os resultados obtidos demonstram que que o modelo satisfaz a estabilidade do VAR, pois todas as raízes pertencem ao círculo unitário (são menores que 1). No diagnóstico dos resíduos, a partir do Multiplicador de Lagrange, com a hipótese nula de não autocorrelação, sendo comprovada a 1% de significância. Os resíduos apresentados oscilam em torno de zero no tempo, indicando a inexistência de uma tendência sistemática nos resíduos. A partir desses expostos, foi confirmado que o modelo VAR estimado é adequado para a análise proposta.

Os resultados obtidos apontam que

> Os resultados obtidos demonstram que o rendimento, o crédito e o spread bancário têm um impacto com significância no consumo das famílias. Especificamente, as variáveis rendimento e crédito mostraram-se positivamente correlacionadas com o consumo, enquanto o spread bancário teve um efeito negativo. A incerteza, embora também afete o consumo, exerce uma influência menos pronunciada comparada às variáveis financeiras. Da mesma forma, a taxa de desocupação mostrou-se negativamente correlacionada com o consumo, embora de forma menos significativa. (Fialho *et al.*, 2024, p. 11-12).

No sentido de utilização para o nosso trabalho já é possível obter-se uma ideia de como as variáveis devem se relacionar. Contudo o maior significado do estudo de Fialho *et al.* (2024) certamente é a demonstração de como diferentes variáveis, sejam elas reais ou monetárias, interagem entre si. Essa relação é fundamental para entender a dinâmica econômica. A partir desses pressupostos, absorveremos esses resultados para nosso trabalho: a capacidade do VAR de tratar da interdependência de diversas variáveis.

Por outro lado, para avaliarmos o uso do VAR no contexto do PIB brasileiro, analisaremos o trabalho de Oliveira e Junior (2024), apesar dos autores não usarem o montante completo do PIB, mas sim a versão fracionada pela população, o PIB *per capita*, este estudo trabalha com um outro cenário do que o visto até então, a relação dos investimentos públicos em infraestrutura e a renda da população. Outro diferencial desse trabalho é a análise de choques, para estimar o comportamento real de uma economia dinâmica.

[25] A fim de curiosidade todos os testes tiveram um p-valor de 0 ao utilizar as variáveis defasadas

O período de estudo de Oliveira e Junior (2024) foi o recorte dos anos de 1994 a 2015, com preços atualizados ao ano de 2015. Esse estudo compreendeu duas regiões brasileiras distintas: Sul e Nordeste. As variáveis coletadas para estas regiões foram: o PIB extraído do IPEA; e a população do IBGE. Com ambas em mãos os autores calcularam o PIB *per capita* para as duas regiões.

No sentido do gasto com infraestrutura os autores coletaram três variáveis principais: gasto com comunicação, energia e transporte. Esses dados foram coletados de cada estado das regiões Sul e Nordeste, advindos da Declaração de contas Anuais (DCA) ou do Quadro de Detalhamento das Contas Contábeis (QDCC). Além disso todas as séries foram transformadas em base logarítmica para interpretação natural da elasticidade.

Os autores apontam que a metodologia de Sims (1980) permite verificar "as causalidades de Granger entre as variáveis, decomposição da variância dos resíduos e a função impulso-resposta"(Oliveira e Junior, 2024, p. 7). Sendo na visão deles um método que os auxiliará no entendimento das inter-relações das variáveis estudadas. Além disso, os autores ainda ressaltam que esse modelo lhes permitem avaliar como as variáveis reagem a inovações individuais no sistema, mas também como cada inovação passa a explicar os desvios sucessivos na série temporal das variáveis do modelo.

Ao realizarem os testes ADF e Phillips Perron (PP) ao nível de significância de 5%, todas variáveis apresentaram raízes unitárias, entretanto após a primeira diferenciação, com exceção da série dos gastos com infraestrutura de comunicação na região sul, todas as séries se comportaram como estacionárias. No caso da comunicação na região sul, mesmo na segunda diferença a série não se tornou estacionária, o que ocasionou na decisão dos pesquisadores em descartá-la desse modelo.

Já na determinação do número de defasagens do modelo, para a região nordeste todas os critérios apresentaram uma defasagem ótima sendo igual a 1. No entanto na região, dois critérios apresentaram defasagem ótima igual a 1, dois critérios igual a 4. Os autores autores optaram pela utilização de ordem 1 de defasagem para região Sul, assim como na região Nordeste.

Para a confirmação a ordem de defasagens os autores testaram a hipótese dos resíduos autocorrelacionados usando o critério dos Multiplicadores de Lagrange (Teste LM), o que confirmou a ordem de defasagens igual a 1 para ambas as regiões, já que o teste rejeitou a autocorrelação dos resíduos.

Os autores utilizaram o método de Johansen para verificar relações de longo prazo entre as variáveis, e a um nível de 5% de significância pela estatística traço, foi rejeitado a hipótese nula de inexistência de cointegração. A existência de um vetor cointegração implica na relação de longo prazo entre variáveis, portanto foi necessário a adição do Modelo Vetorial de Correção de Erro (VEC) junto ao Vetores Autoregressivos (VAR).

A estabilidade do modelo VAR/VEC é necessária, e para isso todas as raízes do polinômio devem estar dentro do círculo unitário, o que foi constatado nos testes, configurando assim a não existência de possíveis trajetórias explosivas.

Com esses testes o modelo foi estimado para as regiões Sul e Nordeste, de forma em que o PIB *per capita* como endógeno ao modelo e as variáveis de gastos com infraestrutura como exógenas. Os resultados apontaram que para a região nordeste uma variação de 1% do gasto com transporte pode ocasionar uma variação de 0.07% do PIB *per capita*. No caso da energia, com a mesma variação de 1%, espera-se uma variação de 0.01% do PIB *per capita*. No caso da região Sul as mesmas variação de 1% no gasto de transporte e energia espera-se ocasionar uma variação de 0.005% e 0.007% respectivamente.

Contudo vale ressaltar que no coeficiente relacionado ao gasto com transporte e energia da região Sul apresentou um coeficiente com sinal positivo, indicando que um aumento no gasto com transporte ocasionaria em uma redução do PIB *per capita*, porém a estatística não se apresenta como significativa.

Para além disso, também foi testada a variação que ocorre no PIB *per capita* quanto outras variáveis também flutuam. Na região Nordeste em um primeiro momento a variância do erro de previsão do PIB *per capita* foi auto-explicada em cerca de 92%, contudo ao longo do período, o erro auto-explicado se reduziu, com 12 meses a frente, somente 68% da variância do erro de previsão é explicada pelo PIB *per capita*, enquanto os gastos de de transporte explicam 11%, de energia 1,4% e de comunicação 18%. No caso da região Sul, a variância foi explicada em 98% pelos seus próprios valores. Mas após os mesmos 12 meses, os gastos com energia passam a explicar 75% da variância do erro e os gastos com transporte cerca de 2%.

Com essas relações foi possível simular um choque nos gastos e observar o comportamento do PIB *per capita*, a partir disso foi constatado que no caso do Nordeste gastos com transportes apresentaram efeitos positivos sobre o PIB *per capita*. Para a região sul o gasto com energia que apresenta esses efeitos significativos, enquanto o transporte é pouco significativo.

Oliveira e Junior (2024) concluíram o trabalho levando a consideração da hetero-

geneidade das regiões brasileiras, trazendo como medidas em diferentes setores podem trazer impactos significantes, ou não, para a renda da região. A partir desse artigo e conectando com nosso objetivo da presente pesquisa notamos uma vantagem do VAR, e dos modelos tradicionais multivariados no geral, a explicabilidade, enquanto modelos como ARIMA conseguem identificar tendências e estimar o comportamento de uma única variável no futuro, modelo como o VAR conseguem estimar o impacto da dinâmica entre as variáveis, nesse caso sendo uma ferramenta poderosa para a tomada de decisão.

Na mesma linha de Oliveira e Junior (2024), Koop *et al.* (2025) usaram o VAR para a estimar a renda, porém a renda estadunidense. Contudo o modelo proposto pelos autores é uma versão mais robusta do VAR, o chamado *Bayesian Mixed-frequency* VAR [26] ou MF-VAR. Não entraremos a fundo na metodologia de Koop *et al.* (2025), apesar de mais complexa, ainda seguirá alguns pressupostos do modelo VAR vistos anteriormente.

Contudo, em outros aspectos será completamente diferente, talvez o mais explicito deles seja o tamanho do modelo, enquanto um modelo VAR tradicional terá poucos parâmetros - tentando evitar a hiper-parametrização, perca de graus de liberdade e a possível multicolinearidade. O modelo proposto por EUA Koop *et al.* (2025) de predição em tempo real do PIB estadual tem 50 equações. Outro ponto relevante é a frequência dos dados, como no exemplo constatado pelos autores "O crescimento do PIB estadual (estadunidense) está disponível em frequência anual até 2004, antes do *Bureau of Economic Analysis* (BEA)[27] começar a produzir estimativas trimestrais a partir de 2005."(Koop *et al.*, 2025, p. 6, tradução nossa). Entretanto vale ressaltar que esse comportamento é recorrente. Tanto em variáveis de natureza distintas - como financeiras e reais - assim como variáveis que trocam de frequência com o decorrer da série temporal. Isso pode ser explicado por mudança metodológica na coleta de dados, ou pela simples melhoria na capacidade de coleta de dados pelos órgãos responsáveis, de uma frequência anual para trimestral, como a ocorrida.

Isso conversa com ideia inicial de nosso trabalho, um modelo capaz de estimar o PIB brasileiro, contudo é importante compreender as limitações de coleta que existem, apesar de vivermos a era da *big-data*, nem sempre foi assim. Portanto não se pode esperar séries históricas completas, sem erros de coleta, ou mudanças metodológicas. Isso é válido para economias desenvolvidas pelo mundo, como a estadunidense, ou para economias emergentes

[26] Vetor Autorregressivo de frequência misturada Bayesiano, trata-se de um modelo com capacidade de modelar diversas variáveis, com frequências de observações diferentes

[27] Departamento de Análise Econômica, trata-se do órgão que fornece indicadores macroeconômicos dos Estados Unidos

como a brasileira.

Outra ressalva no trabalho de Koop *et al.* (2025) é a mudança de paradigma, enquanto o trabalho original de Sims (1980) e as aplicações de Oliveira e Junior (2024) e Fialho *et al.* (2024) são frequentistas, baseadas na estatística tradicional. Koop *et al.* (2025) precisaram utilizar uma abordagem Bayesiana, em que pressupostos a prior sobre a distribuição dos parâmetros antes dos dados são exigidos[28]. No trabalho de Koop *et al.* (2025) para conseguirem estimar um modelo VAR com essa quantidade de equações, chamados de grandes VAR, o poder computacional e o tempo de execução começam a se tornar um fator relevante na escolha de um modelo. Para a modelagem computacional, os autores utilizaram o *Markov Chain Monte Carlo* (MCMC), que é frequentemente utilizada como algoritmo para modelos Bayesianos, contudo o MCMC tradicional, com a quantidade de parâmetros e frequências distintas presentes, seria muito lento para a previsão do PIB em tempo real, os autores então adaptaram o algoritmo tradicional para a modelagem específica do VAR proposto.

Entretanto, mesmo com todas essas restrições e adaptações, o modelo de Koop *et al.* (2025) conseguiu estimar o PIB mensal dos estados estadunidense, com um certo grau de precisão. Para avaliação do modelo, os autores utilizaram o *Root Mean Square Error* (RMSE) dos valores estimados comparado aos valores medidos trimestralmente pelo próprio BEA. Vale ressaltar que para os erros dos três primeiros meses a média dos estados foi de m1 = 1.71, m2 = 1.71 e m3 = 1.48. Esse resultado indica uma boa capacidade de estimar o crescimento do PIB estadual dado as circunstâncias. Mas, a qualidade desse trabalho mais evidente é a capacidade interpretativa e possibilidade de estimar choques no espaço - devido a dinâmica estadual estar contida dentro do modelo. Esse grau de modelagem não seria possível em um modelo VAR tradicional.

Nesse contexto, nota-se que o modelo VAR pesquisado por Koop *et al.* (2025) tem qualidades evidentes. Tendo isso em mente, vale ressaltar que a utilização do VAR com uma abordagem Bayesiana não se restringe a economia americana. Na realidade muitos estudos já utilizaram essa abordagem para modelagem macroeconômica brasileira. Como os estudos de Azevedo (2020), Serrano (2014), Borges (2018), Rosa (2025).

Tal perspectiva reflete como o VAR e suas variações são modelos robustos para a predição de variáveis macroeconômicas, o modelo tradicional com suas limitações e suas vantagens de modelagem e rápida execução. E suas variações que suportam um maior número

[28] Não discutiremos sobre qual abordagem é melhor, dentro da estatística e econometria do séc. XXI ambas abordagens são relevantes e se complementam na resolução de problemas quantitativos reais

de variáveis e distintas frequências temporais.

Todavia, para utilizar-se do VAR nesse contexto foi necessário adaptações no paradigma estatístico para a modelagem do problema, a seguir veremos dois modelos que lidam com isso naturalmente o DFM que foi idealizado para lidar com grande quantitativo de variáveis e o MIDAS que suporta diferentes frequências nas séries temporais, com isso concluiremos a sessão de modelos tradicionais e partiremos para os modelos baseados em Inteligência Artificial (IA)

#### *2.2.1.3 MIDAS*

Aplicar um modelo econométrico consiste em etapas, que vão desde a coleta, tratamento, testagem, aplicação, validação e predição. A maioria dessas etapas é administrada pelo pesquisador, se uma variável não passa nos testes, o estatístico pode simplesmente removê-la, ou tratá-la como exógena, se o modelo não tem uma boa acurácia, pode a sua vontade mudá-lo, e é assim para maioria das etapas. Contudo uma dessas etapas, apesar de muito importante, ela é suscetível a erros e variações que muitas vezes não podem ser controladas pelo pesquisador, estamos falando da coleta. Os dados disponíveis, mesmo aqueles de bases oficiais podem conter vícios de medições, dados faltantes e é claro diferentes frequências.

Como os estudiosos da área não podem simplesmente deixar de realizar a pesquisa, novas técnicas cada vez mais sofisticadas surgem para solucionar esse tipo de problema, como visto anteriormente no MF-VAR, existem maneiras de adaptar modelos existentes para as condições da realidade dos dados, mas também surgem modelos específicos para lidar com certas condições frequentes da economia real.

Uma dessas condições, é ironicamente a frequência. Nesse sentido, em algumas bases, uma variável é semanal, naquela é mensal, em outra anual, e assim para qualquer regularidade imaginável. Por exemplo, o censo demográfico no Brasil só ocorre a cada 10 anos, os dados entre esses anos são estimativas. Outro exemplo, a taxa SELIC que é definida a cada 45 dias, muito mais frequente que um censo, mas parece ser uma eternidade comparada aos preços das ações que tem frequência praticamente imediata. Nesse sentido um modelo que consegue incorporar o comportamento econômico com diferentes frequências é algo relevante. Nesse contexto, surge o MIDAS.

> MIDAS envolve regressores com diferentes frequências de amostragem e, portanto, não são modelos autorregressivos, já que a noção de autorregressão pressupõe implicitamente que os dados são amostrados na mesma frequência no passado. (Ghysels *et al.*, 2004, p. 1)

Portanto, o MIDAS se difere dos modelos até agora estudados, tendo em vista que só analisemos modelos autorregressivos.

A responsabilidade sobre o início do desenvolvimento do modelo MIDAS recai justamente sobre os autores da citação anterior, no trabalho de Ghysels *et al.* (2004), com a obra intitulada de "*The MIDAS Touch: Mixed Data Sampling Regression Models*[29]". O contexto do surgimento do MIDAS é justamente a necessidade de um modelo capaz de delinear as diferentes frequências na realidade. Os autores trazem como exemplo o mercado de ações, analise de risco e também a predição macroeconômica pensando na limitação dos dados,

> o interesse em regressões MIDAS também pode surgir por limitações na disponibilidade de dados. Por exemplo, alguns dados macroeconômicos são amostrados mensalmente, como séries de preços e agregados monetários, enquanto outras séries são amostradas trimestralmente ou anualmente, normalmente séries de atividade real como o PIB e seus componentes. (Ghysels *et al.*, 2004, p. 1)

Tendo em vista que o objeto do presente trabalho são os diferentes sistemas de predição, e um modelo pensado para solucionar um problema real da predição com variáveis macroeconômicas é um forte candidato a observação. Mas o que de fato esse modelo faz? "As regressões MIDAS são basicamente regressões de forma reduzida e com parâmetros bem ajustados, que envolvem processos amostrados em diferentes frequências."(Ghysels *et al.*, 2004, p. 4)

Uma regressão linear simples MIDAS pode ser expressa na equação 2.4 proposta por Ghysels *et al.* (2004).

$$Y_t = \beta_0 + \beta_1 B(L^{\frac{1}{m}}) X_{t-1}^{(m)} + \varepsilon_t^{(m)} \tag{2.4}$$

onde

a) $Y_t$ é a variável de baixa frequência a ser estimada;
b) $\beta_0$ é o intercepto;
c) $\beta_1$ é o coeficiente que mede a influência das variável explicativa sobre a variável dependente;
d) $B(L^{\frac{1}{m}}) = \sum_{j_0}^{j_{max}} B(j) L^{\frac{1}{m}}$ é um polinômio de comprimento $L^{\frac{1}{m}}$ no operador $L^{\frac{1}{m}} x_t = x_{t-\frac{j}{m}}$;
e) $X_{t-1}^{(m)}$ é a variável explicativa de alta frequência;
f) $\varepsilon_t^{(m)}$ é o termo do erro.

[29] O nome faz referência a mitologia atrelada ao toque de Midas, associado a habilidade de transformar tudo em sucesso/riqueza

Imaginemos modelar a o PIB trimestral utilizando o Indíce de Preços ao Consumidor Amplo (IPCA) mensal, em uma regressão linear simples, cada mês do IPCA deveria ser modelado como uma variável independente a parte, o que a depender da frequência da variável, se tornaria inviável, com alto risco de sobreajuste. Outra solução seria simplesmente adaptar a frequência mais alta para a mais baixa, por exemplo, calcular a média do IPCA para os meses de observação, porém fazer isso implicaria na perda de informações. O que modelos MIDAS fazem é incorporar as variáveis com frequências diversas em uma função de pesos parametrizados para as defasagens.

Porém escalando o problema, para múltiplas variáveis, a modelagem da maneira tradicional se torna praticamente inviável. Isso vale também para o modelo MIDAS apresentado, o mesmo não foi feito para um conjunto de variáveis. Como pretendemos aplicar em dados reais, e como o modelo MIDAS foi criado justamente nesse contexto, devemos observar sua formulação. Sua forma geral, que representa toda família de modelos MIDAS está representado na equação 2.5 também proposta por Ghysels *et al.* (2004).

$$Y_{t+1} = B_0 + f(\sum_{i=1}^{K}\sum_{j=1}^{L} B_{ij}(L^{\frac{1}{m_i}})g(X_t^{(m_i)},\beta),\beta) + \varepsilon_t + 1 \tag{2.5}$$

onde

a) $Y_{t+1}$ é a variável dependente no período $t+1$;
b) $B_0$ é o intercepto;
c) $X_t^{(m_i)}$ são as variáveis explicativas do modelo;
d) $L^{\frac{1}{m_i}}$ é o operador de defasagem fracionária;
e) $B_{ij}(L^{\frac{1}{m_i}})$ é um polinômio de defasagem que determina o impacto de lags específicos de $X$ sobre $Y$;
f) $g(X_t^{(m_i)},\beta)$ é a função de ponderação dos pesos;
g) $\sum_{i=1}^{K}\sum_{j=1}^{L}$ são os somatórios que acumulam a informação;
h) $f(\ldots,\beta)$ é a função de ligação global[30];
i) $\varepsilon_{t+1}$ é o resíduo no período $t+1$.

A partir dessa forma geral podemos modelar uma variedade de problemas que envolvem variáveis de frequência mista, inclusive, e especialmente situações envolvendo variáveis

[30] Normalmente $f$ é linear, mas na forma geral isso não é obrigatório, ou seja $f$ pode ser uma função não-linear, portanto podem haver modelos MIDAS aplicados a problemas não-lineares, essa possibilidade coloca em cheque a posição do MIDAS nesta sessão do presente trabalho, porém consideramos o MIDAS como um modelo tradicional pela sua ampla aplicação em problemas lineares

macroeconômicas como o PIB. Portanto a partir desse momento veremos aplicações do modelo MIDAS para a predição macroeconômica.

Castelli (2022) abordou o uso do modelo de amostragem de dados mistos (do inglês *Mixed Data Sampling* - MIDAS) para predizer o PIB com a pesquisa industrial mensal. Assim como Micheletti (2024) usou modelos de *ensemble stacking* [31] (dentre eles o MIDAS) para prever o PIB.

#### *2.2.1.4 DFM*

Pensando nos modelos até então apresentados, existe uma certa progressão em complexidade e capacidade do modelo, mas todos os apresentados tem um problema específico, a dificuldade em lidar com muitas variáveis. O modelo ARIMA é univariado, o VAR tradicional consegue lidar com uma dezena de variáveis diferentes, o modelo MIDAS até consegue trabalhar com algumas dezenas de variáveis, porém pode sofrer com a multicolinearidade e o custo computacional, nesse sentido um modelo capaz de incorporar dezenas ou até mesmo centenas de elementos diferentes em um mesmo sistema preditivo teria um apelo respeitável na economia real, é justamente nessa necessidade de modelos que comportam um grande número que variáveis que surge a família dos *Dynamic Factor Model* (DFM).

A noção de utilizar fatores dinâmicos para predição econômica é atribuída a Geweke (1977)[32]. Os DFM surgem como modelos para abarcar a economia em expansão, e ser capaz de modelar dinâmicas que outros modelos falham na incorporação. Os DFM's se mostraram úteis para sintetizar informações de variáveis observadas em diferentes frequências, estimar o ciclo econômico latente, fazer previsões em tempo real e a longo prazo, e estimar probabilidades de recessão e pontos de virada."(Doz e Fuleky, 2019, p. 2).

A forma geral de um modelo DFM pode ser vista na equação 2.7 apresentada por Doz e Fuleky (2019).

$$x_t = \mu + \Lambda_0 f_t + \Lambda_1 f_{t-1} + \cdots + \Lambda_s f_{t-s} + e_t, \tag{2.6}$$

[31] *ensemble stacking*: modelos combinados

[32] Se pensarmos em uma sequência histórica seria: ARIMA - 1970, DFM - 1977, VAR - 1980 e por último o MIDAS - 2004. No presente trabalho não optamos por apresentar modelos em uma sequência histórica, mas sim de forma didática, pensando justamente no nível de complexidade dos modelos, apesar de ser um critério subjetivo a depender do leitor, mas também podemos refletir que estamos apresentando os modelos em uma sequência de capacidades, em que cada modelo consegue fazer um pouco mais do que o anterior, mesmo cada um tendo seu melhor caso de uso. Contudo vale ressaltar a curiosidade, como um modelo mais complexo como o DFM surge antes de modelos mais "simples"comparativamente como o VAR ou o MIDAS.

ou na forma reduzida

$$x_t = \mu + \Lambda(L)F_t + e_t, \tag{2.7}$$

Em que

a) $x_t$ representa o vetor das N variáveis observadas no instante t;

b) $\mu$ é o vetor de interceptos das variáveis observadas;

c) $\Lambda(L)$ é a matriz de polinômios de defasagens;

d) $)F_t$ é o vetor dos *r* fatores comuns latentes;

e) $e_t$ representa o vetor dos componentes idiossincráticos[33].

Dentre os modelos apresentados, tanto em nível de complexidade computacional, assim como a interpretabilidade dos modelos, não no sentido de seus resultados, mas sim de sua construção o DFM é o modelo mais complexo dentre os modelos tradicionais estudados no presente trabalho, desse modo, e seguindo nossa proposta didática ele é o último modelo tradicional que abordaremos. Inclusive a escolha do DFM ser o último é que também o DFM consegue englobar outros modelos em sua composição, inclusive na subsecção 2.2.2 trataremos de um modelo DFM que o autor usou modelos de IA em sua composição, deixando o limiar de tradicionais e de IA mais nebuloso, mas também apresentando um potencial, a combinação de modelos.

Alves (2009) em sua dissertação de mestrado abordou modelos de fatores dinâmicos (do inglês *Dynamic Factor Models* - DFM) para entender o núcleo da inflação brasileira. Por outro lado Moura *et al.* (2020) avaliou os ciclos econômicos brasileiros usando uma combinação entre o DFM e o VAR.

### *2.2.2 Modelos de IA: Uma explanação*

Os modelos que chamamos de IA, são na realidade modelos não-lineares modernos[34], estes não assumem a linearidade nos parâmetros dos preditores do modelo, isso ocasiona implicações na interpretabilidade dos modelos (Vasconcelos, 2017, p. 22). Apesar do termo Inteligência Artificial ter seu uso mais evidente pelos algoritmos baseados em redes neurais e aprendizado profundo, ainda existem modelos que não tem a mesma notoriedade popular que

[33] Não chamamos $e_t$ de vetor de erros, pois no contexto do DFM não se trata só de erro de medição ou ruídos, mas sim a parte da variável que não é explicada por fatores comuns

[34] Existem modelos considerados tradicionais não-lineares como as árvores de decisão, porém sua interpretabilidade é natural

tais algoritmos[35], mas que podem ser tratados como IA, por possuírem características de falta interpretabilidade natural e não linearidade nos preditores, como é o exemplo do Random Forest que trataremos nesse trabalho.

De uma maneira técnica os modelos de IA "utilizam funções específicas que permitem realizar previsões mediante a atribuição de pesos, que são medidos e alterados por uma função de ativação que busca diminuir o erro de um modelo, que tende a ser muito mais preditivo do que analítico."(Carmo e Lopacinski, 2023, p.10). A partir da definição de Carmo e Lopacinski (2023) e de Vasconcelos (2017) já entendemos o contexto onde esses modelos se encaixam, são modelos que buscam estimar a variável escolhida com maior precisão, mas para isso o pesquisador sacrifica a interpretabilidade natural do modelo, e de certa forma, também seu poder decisivo.

O poder preditivo de um modelo de IA permite que modelos possuam muitas variáveis, e capturem um comportamento dinâmico e entrelaçado das observações, algo que a simples análise humana e pressupostos lineares não seriam capazes de observar. Por outro lado, a decisão de utilizar ou não uma variável, dos pesos que cada valor possuí e da interpretação após treinamento foge do controle do pesquisador, sendo de certa forma, atribuído ao modelo essa tarefa. Assim fica evidente onde modelos de IA tem maior possibilidade: problemas complexos, com muitas variáveis, diversos fatores dinâmicos, com alto grau de correlação e que a interpretação é menos importante que a capacidade preditiva.

Usando um exemplo prático, estimar o PIB é um ótimo candidato a modelos de IA, muitas variáveis podem ser usada como preditoras, dinamismo frequente e auto grau de correlação entre elas, se trata de um problema complexo, onde de certa forma pouco interessa a relação interna entre as variáveis, mas muito se interessa o desempenho do próprio PIB. Por outro lado, um modelo para estimar o grau de encadeamentos de uma economia, apesar de ter uma complexidade tremenda e uma grande quantidade de preditores, o que importa nesse tipo de modelo é sua interpretabilidade, e nesse sentido, modelos tradicionais no aspecto da interpretação, provavelmente atenderiam melhor os requisitos dado a natureza do problema.

[35] O uso do termo Inteligência Artificial se popularizou com os modelos grandes de linguagem - LLM (do inglês, *Large Language Models*), mas os algoritmos de IA surgem anteriormente a esses modelos. O nome vem justamente da ideia que essa classe de algoritmos tenta simular o comportamento humano, porém seu funcionamento não poderia ser mais diferente, como veremos na presente sessão. Outro fator que influência o nome IA, é a representação visual do Percéptron, menor unidade das redes neurais, em que seu diagrama lembra a forma de um neurônio humano, que propriamente inspirou o nome redes neurais, e consequentemente, ajudou a popularizar o termo Inteligência Artificial

#### *2.2.2.1 Redes Neurais*

Os modelos baseado em redes neurais são naturalmente complexos, mas tentaremos explicar de uma forma descomplicada como esses modelos surgiram, as inspirações, a aplicação teórica e aplicações práticas para a predição econômica.

Por definição rede neural trata-se de uma modelo baseado em rede composto por diversas camadas, cada camada é composta por nós, e cada nó é calculado usando os nós da camada anterior, e a saída é calculada usando os nós da última camada oculta. Não existe interpretação para esses nós, que são computados usando retropropagação (Ghosh e Ranjan, 2023).

Todavia, redes, nós e retropropagação são conceitos avançados para entender de fato que o são redes neurais. De uma maneira mais humana, redes neurais são utilizadas "para replicar o funcionamento do pensamento humano artificialmente e encontrar respostas ou hipóteses tal qual um humano faria, porém, evitando seus erros e agilizando processos que podem demorar muito tempo quando biologicamente realizados."(Carmo e Lopacinski, 2023, p. 8). A replicação do pensamento humano não ocorre tentando simular as reações físico-químicas que acontecem em nossos cérebros, na realidade trata-se de uma abstração do pensamento humano através de funções matemáticas, uma sequência de combinações lineares que conseguem resolver problemas não-lineares.

Dessa forma o objetivo desse tipo de modelo é justamente "extrair combinações lineares por meio das covariáveis e então modelar a variável que se deseja prever como uma função não linear destas covariáveis."(Kava, 2022, p. 40-41). Isso ocorre por meio da união de pequenos modelos preditivos simples. Esses modelos chamados de neurônios artificiais, são os responsáveis por essa predição. O primeiro neurônio artificial, ou também chamado de perceptron foi descrito inicialmente por Rosenblatt (1958)[36]. A representação visual pode ser verificada na figura 1. Esse modelo consistia em modelo que soma as entradas, obtendo um valor intermediário chamado de z, que passa por uma função de ativação, o perceptron utiliza uma

[36] Chamar o perceptron de Rosenblatt (1958) de primeira IA pode ser um eufemismo, até porque a ideia de IA é mais antiga remetendo as reflexões de Alan Turing, mas principalmente se comparamos aos modelos de redes neurais atuais que são muito mais complexos que o perceptron. Contudo a ideia estava lá, e ela realmente veio a se tornar os modelos computacionais sofisticados que temos no mundo contemporâneo. Mas pensando no perceptron estritamente como modelo matemático criado em 1958, ele surge antes do ARIMA, que é de 1970. Claro ambos tem propostas diferentes, o ARIMA é um modelo autorregressivo univariado, já o perceptron é um classificador linear simples, mas mesmo assim se ignorarmos esse fato por um momento, o modelo que é vendido como inovador, surge como ideia antes de muitos dos modelos tradicionais, mas isso é mais uma reflexão sobre a evolução das técnicas de modelagem do que propriamente uma discussão sobre predição econômica, mas fica a reflexão sobre os modelos vendidos como "inovadores".

função sinal como ativação, mas outros tipos de modelos utilizam outras funções de ativação (Ekman, 2021).

A representação matemática de um perceptron é definida por:

$$f(x) = \phi\left(\sum_{i=0}^{n} w_i x_i\right) \tag{2.8}$$

com

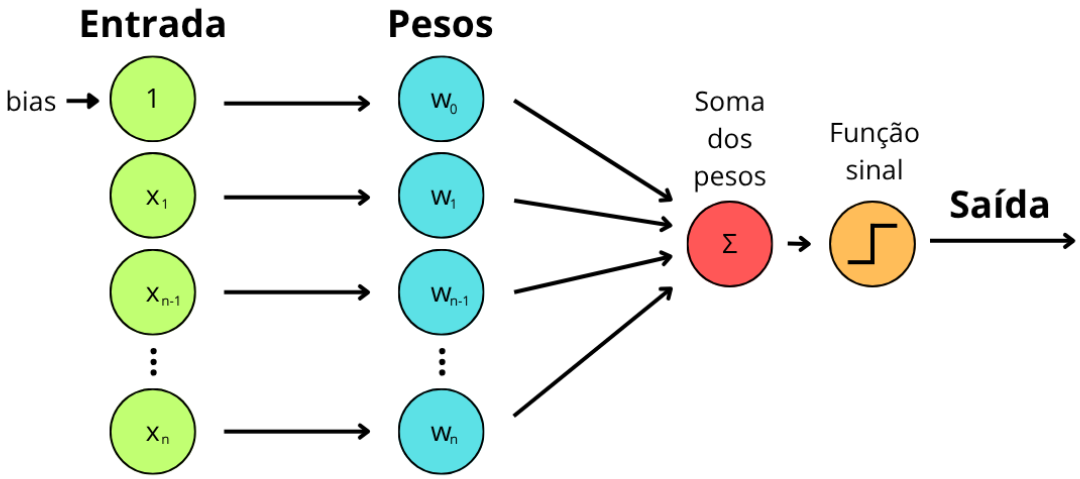
$x_0 = 1$(Bias ou viés)

$x_i =$ Entrada

$w_i =$ Pesos

$\phi =$ Função de ativação

Figura 1 – Perceptron




Fonte: Elaborado pelo autor (2026).

Contudo um perceptron por si só, não consegue resolver problemas não-lineares, afinal a combinação de entradas e saídas realizando uma operação linear não pode ter uma resposta para um problema não-linear. Mas a verdadeira solução para problemas não-lineares começa a partir da combinação de dois perceptrons. Intuitivamente, um perceptron é um classificador linear simples, mas combinando os resultados das respostas de dois perceptrons,

que são lineares, com um terceiro neurônio combinando essas respostas, consegue-se resolver problemas não-lineares. Nesse contexto surge a ideia de redes.

Retomando o conceito de Ghosh e Ranjan (2023) entendemos o que são as redes, e o que são os nós, se tratam dos neurônios conectados e os pesos calculados de cada um. Contudo um conceito relevante que ainda não foi discutido, justamente esse conceito que permitiu a evolução do modelo de Rosenblatt (1958) para as redes multicamadas que existem hoje. O nome desse conceito é a retropropagação, conhecido também como *backpropagation* que é justamente o que permite o aprendizado nessa arquitetura.

Após a invenção do perceptron havia ainda um espaço grande entre um único neurônio e as redes neurais multicamadas . O perceptron tem uma limitação relevante já citada, só consegue resolver problemas que são linearmente separáveis, isso acontece pela maneira como o aprendizado do modelo de Rosenblatt (1958) funciona. As entradas do perceptron eram multiplicadas com o peso e somadas com o viés, passada a uma função sinal ou degrau [37] que resultava na saída. O aprendizado ocorria da seguinte forma: se a saída fosse igual a saída esperada, nenhum peso era alterado, se a saída fosse diferente da saída esperada os pesos eram modificados, até o modelo se ajustar a saída esperada.

Intuitivamente a limitação é explicita, mas para ficar mais evidente suponhamos o problema clássico das redes neurais, resolver o problema do ou-exclusivo, o XOR[38]. A característica do XOR é que quando as entradas binárias são diferentes o resultado é 1, e quando as entradas são iguais o resultado é 0, conforme a tabela verdade:

Tabela 1 – Tabela verdade da operação XOR

| A | B | $A \oplus B$ |
|---|---|---|
| 0 | 0 | 0 |
| 0 | 1 | 1 |
| 1 | 0 | 1 |
| 1 | 1 | 0 |

Fonte: Elaboração própria.

Minsky e Papert (1969) provaram que o perceptron de Rosenblatt (1958) não conse-

[37] A diferença dessas duas funções está na interpretação do 0, enquanto a função sinal tem a seguinte relação $sgn(x)\{-1$ se $x < 0; 0$ se $x = 0$; e 1 se $x > 0$. Já a função degrau considera o 0 como um valor positivo $H(x)\{-1$ se $x < 0$; e $1 sex >= 0$, ambas podem ser usadas no perceptron e ambas tem o mesmo problema que discutiremos no decorrer do texto

[38] O XOR parece ser um problemas simples, mas essa operação é fundamental dentro da computação, sendo utilizada em áreas fundamentais, como a criptografia, mascarás de bits, armazenamento digital, construção de processadores, construção de redundância,etc. Calcular o XOR significa perceber o comportamento computacional, mas para além disso o comportamento humano, que não é linear, assim como, o XOR também não é

guiria resolver um problema que não fosse linearmente separável, como o do XOR, imaginemos o XOR como um problema gráfico, enquanto um problema linear precisa de apenas uma reta para classificar corretamente os valores, para solucionar o XOR seriam necessários duas retas ou mais para classificar corretamente. E é exatamente nesse ponto em que o perceptron falha. A partir da constatação de Minsky e Papert (1969) o mundo viveu uma era conhecida como o "inverno da IA", onde o modelo mais elegante criado até então ficaria estagnado.

Mas essa configuração mudou com a adoção de um método de aprendizado que mudou totalmente a forma como a IA era construída, a retropropagação. A popularização do seu uso é atribuída a Rumelhart *et al.* (1986) que aplicaram o conceito de retropropagação em redes neurais. "O procedimento ajusta repetidamente os pesos das conexões na rede para minimizar uma medida da diferença entre o vetor de saída real da rede e o vetor de saída desejado."(Rumelhart *et al.*, 1986, p. 533, tradução nossa).

Esse marco inicia a construção dos modelos mais avançados de IA, os modelos criados por Rumelhart *et al.* (1986) são redes neurais totalmente conectadas, significa que todos os neurônios de uma camada se conectam com os da camada seguinte. E baseada na arquitetura do *feedforward* em que os dados fluem em uma única direção da entrada para a saída, sem loops, ou recursão.

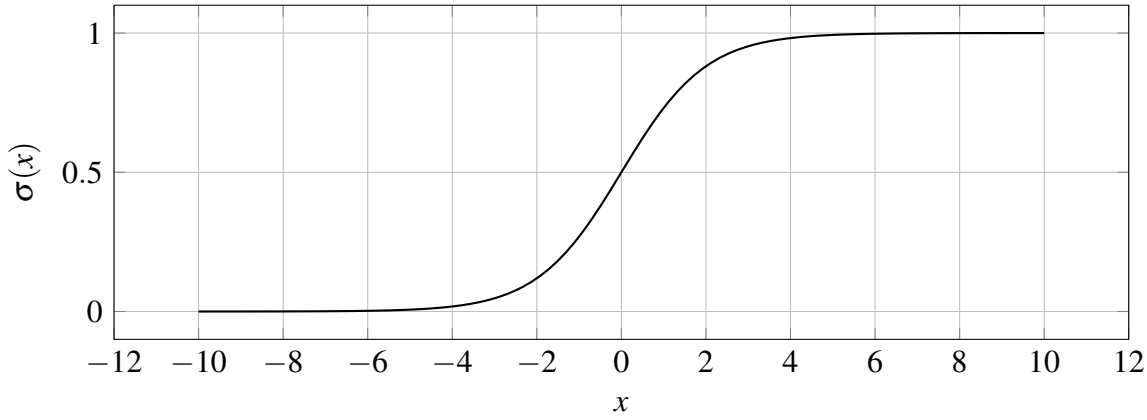
A elegância dessa solução é impressionante, porém aplicar ela a perceptrons combinados não é tão simples, existem algumas alterações do modelo de Rosenblatt (1958). A primeira alteração é a noção de função de ativação, enquanto o perceptron utiliza a função sinal/degrau, a retropropagação não permite o uso desse tipo de função, essas funções não são deriváveis por serem descontinuas em x=0, e o conceito que permite a retropropagação é justamente o uso de derivadas, portanto a primeira alteração é a troca por uma função continua e derivável, como por exemplo a função sigmoide [39] representada na equação 2.9 e na figura 2.

$$f(x) = \frac{1}{1+e^{-x}} \tag{2.9}$$

A segunda alteração é a que permite a combinação dos neurônios, enquanto o perceptron usa o erro direto para recalcular os pesos, redes multicamadas essa noção não é

[39] Existem outras funções que podem ser usadas como ativação, como a ReLU (Unidade Linear Retificada), a TanH (Tangente Hiperbólica), a Softmax, a linear, etc. Não entraremos em detalhes sobre cada uma das funções de ativação, mas elas são uma das decisões que o pesquisador deve tomar ao usar redes neurais, o tipo de função de ativação, o número de camadas, a taxa de aprendizado são o que chamamos de hiperparametros do modelo, e o ajuste deles permite um desempenho melhor ou pior a depender dos dados e do problema.

Figura 2 – Função Sigmoide




Fonte: Elaborado pelo autor (2026).

direta. O erro da camada de saída deve ser utilizado para calcular os pesos da camada oculta anterior, com esses pesos calculados, calcular o erro da camada imediatamente precedente, e assim conseguinte até a primeira camada, esse processo é a retropropagação do erro, camada por camada. Esse processo é repetido inúmeras vezes até os pesos se ajustarem e o erro total for minimizado e é dessa maneira que a rede aprende.

Mas como esse erro é minimizado? É com essa pergunta que conectamos com a necessidade da função de ativação ser derivável. Retomamos o conceito do calculo: A derivada mede a taxa de variação instantânea de uma grandeza em relação a outra, de uma forma geométrica a derivada representa a inclinação da reta tangente ao gráfico função em um ponto específico do plano.

Nesse sentido o conceito de derivada para esse algoritmo funciona como uma bússola. Imaginemos que nossa função do erro é quadrática, como na equação 2.10,

$$E = \frac{1}{2}(y - \hat{y})^2 \tag{2.10}$$

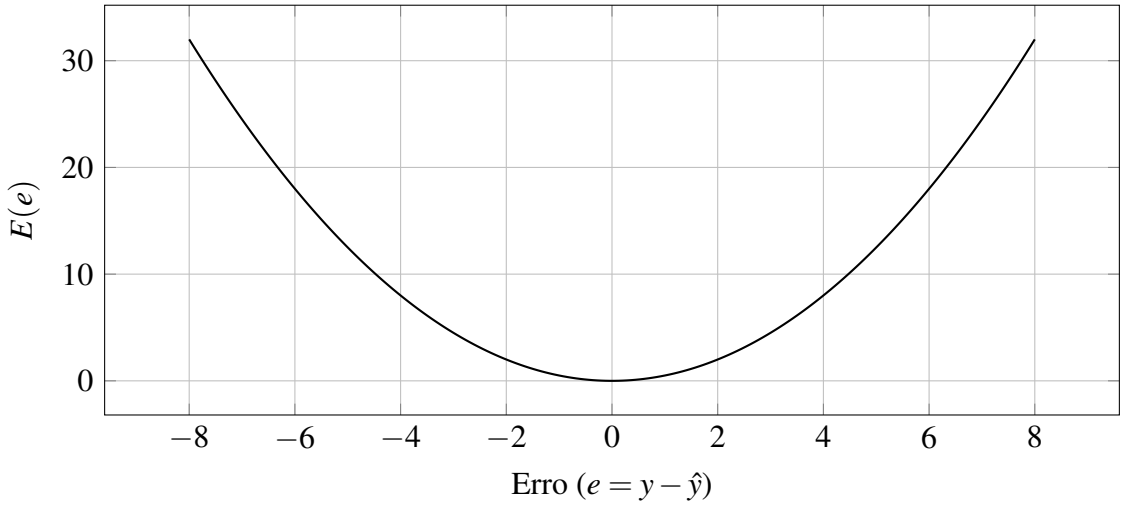
Onde:

- $y$ representa o valor observado;
- $\hat{y}$ representa o valor predito;
- $E$ representa o erro quadrático.

A visualização dessa função pode ser verificado na figura 3.

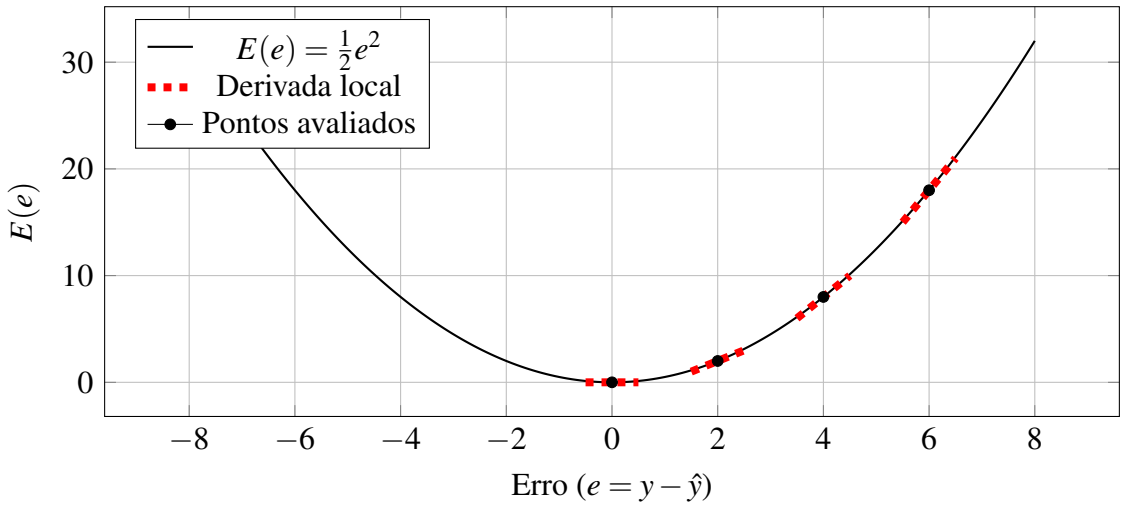
Podemos usar o conceito da derivada para encontramos os valores de $\hat{y}$ que minimizam o erro $E$. Ajustando os coeficientes utilizando a derivada como ponteiro, procurando o melhor valor para que o erro seja minimizado, conforme a figura 4.

Figura 3 – Função de erro quadrático.




Fonte: Elaborado pelo autor (2026).

Figura 4 – Função de erro quadrático e segmentos de retas tangentes representando a derivada em diferentes pontos.

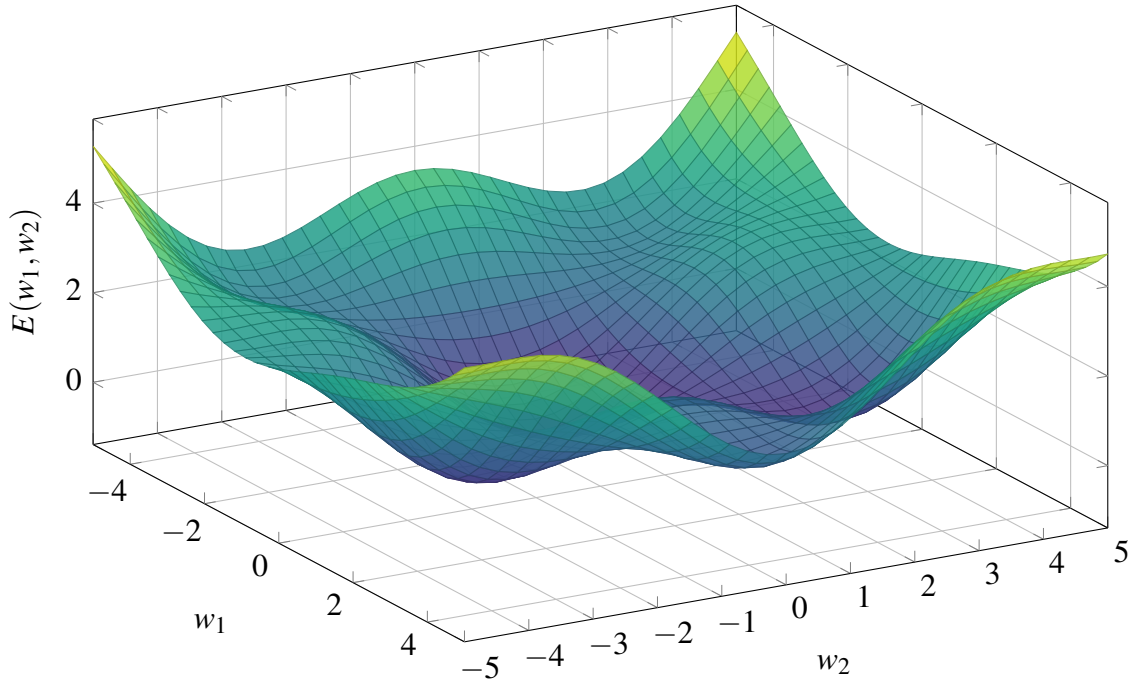



Fonte: Elaborado pelo autor (2026).

Porém a função de erro de uma rede neural não é uma simples função quadrática, afinal se fosse a solução seria trivial, o gráfico seria algo mais parecido com o representado na figura 5, mas mesmo assim a representação é imprecisa, pois redes neurais profundas contam com muitas entradas e camadas, possuem n-dimensões e é praticamente impossível conceber uma representação visual do erro dessas redes. Porém, mesmo que imprecisas, essas representações nos permitem entender a ideia por trás da retropropagração, o chamado gradiente descendente.

O gradiente descendente "É um método iterativo no qual começamos com um palpite inicial da solução e depois refinamos gradualmente."(Ekman, 2021, p. 45, tradução nossa). Para funções simples de uma variável o gradiente descendente é o algoritmo que usa as derivadas das

Figura 5 – Superfície de erro




Fonte: Elaborado pelo autor (2026).

funções para minimizar o erro, por outro lado

> Se tivermos uma função de n variáveis, então nosso gradiente consistirá em n derivadas parciais, e podemos calcular o próximo passo como $x - \eta \nabla y$, onde tanto $x$ quanto $\nabla y$ são vetores com $n$ elementos. (Ekman, 2021, p. 47, tradução nossa)

Uma maneira mais intuitiva de se entender o gradiente descendente seria com uma analogia: O gradiente descendente é como um animal cego e com sede encima de um terreno acidentado, ele não sabe onde tem água, e não sabe onde está, porém ele sabe que a água fica nos vales, e pode usar suas patas para identificar a inclinação do terreno, ele procurará maneiras de sempre ir descendo, e quando chegar no vale encontrará água.

E com essa analogia já entendemos também um dos problemas dessa arquitetura, os mínimos locais. Se o animal encontra uma depressão na montanha, que não tem água, mas que para todos os lados é necessário subir primeiro para posteriormente descer o animal cego acaba morrendo de sede. De certa forma é assim que funciona o gradiente descendente, quando encontra mínimos locais, o algoritmo "pensa" estar na solução ótima, mas é apenas um mínimo local[40].

[40] Existem estudos dedicados a minimizar esses problemas, como encontrar uma taxa de aprendizado ótimo, para evitar mínimos locais e mesmo assim encontrar soluções adequadas, mas essas análises fogem do escopo de nosso trabalho, mas vale a leitura do livro de Ekman (2021) para entender mais sobre redes neurais, funções de ativação, gradiente descendente e outros conteúdos sobre redes neurais na teoria e na prática

Com essa noção de como surgiram os modelos baseados em redes neurais, posteriormente com a evolução das técnicas de IA surgem os algoritmos de *deep learning* (aprendizado profundo), esses modelos não são diferentes das redes neurais estudadas no presente trabalho, a principal diferença é a escala. No *deep learning* são muitas camadas, imagine da seguinte forma, com zero camadas ocultas temos uma regressão logística ou um perceptron, com uma camada oculta temos as redes neurais, com duas ou mais temos o que chamamos de *deep neural networks* que são redes neurais com muitas camadas ocultas. Esses algoritmos que rodam as grandes tecnologias de IA atualmente, como visão computacional, chatbots, carros autônomos, etc. Contudo também apresentam os mesmos problemas apresentados de uma forma geral, a interpretabilidade, mínimos locais, sobreajuste.

Redes com arquiteturas gigantescas podem resolver problemas complexos, porém não tem a interpretabilidade que modelos simples possuem. Nesse ponto toma se a decisão, por exemplo, em um carro autônomo, importa se a IA decide trocar de pista pela proximidade com o retrovisor ou com a roda de outro carro? Se a resposta for não, não existe um problema, pois o resultado foi alcançado, o carro trocou de pista no momento certo e evitou um acidente, não importa se foi pelo retrovisor, pela roda, ou por qualquer outro fator. Nesse sentido a predição econômica caminha pela mesma estrada, e uma pergunta deve ser feita o processo de como eu cheguei no resultado importa? se a resposta for sim, talvez redes neurais não sejam o modelo mais adequado, mas se for não elas apresentam um grande potencial, conforme veremos a seguir.

A partir desse exposto vimos de uma forma simplificada[41] como redes neurais surgiram e como elas funcionam por baixo dos panos, agora podemos ver as aplicações desses modelos para predição econômica.

Começaremos por Vasconcelos (2017) que utilizou modelos de redes neurais em sua tese, diferente de nosso trabalho o autor realizou sua pesquisa em dados de 41 países de 2001 à 2015 (Segundo o autor em alguns casos a série pode até ser mais extensa devido a disponibilidade), essa escolha se deu principalmente por serem membros da Organização para a Cooperação e Desenvolvimento Econômico (OCDE), mais alguns países que apesar de não serem membros possuem relevância econômica e/ou tinham a disponibilidade de dados.

As variáveis selecionadas pelo autor são: pib, seus componentes, comércio internaci-

[41] A formulação matemática dos modelos de IA existe, e vai muito além da forma geral do perceptron apresentada na equação 2.8, na realidade redes neurais profundas envolvem um conhecimento profundo sobre otimização e álgebra linear, que apesar de extremamente relevantes na compreensão do funcionamento das redes neurais, foge completamente do escopo de uma monografia de economia explicar algebricamente o funcionamento dessas redes. Dessa forma sugerimos novamente a leitura de Ekman (2021) que explica de forma mais detalhada, mais do que poderíamos no presente trabalho, o a lógica matemática das redes neurais.

onal, preços, câmbio, juros, títulos públicos, câmbio, mercado futuro, índices de bolsa, demais indicadores de negócios público e privado, qualidade do crédito, operações de crédito do governo em detalhes, operações financeiras como BIS, reservas, balança comercial, fluxo de capitais, CDS[42], VIX[43], preços de commodities. Essas variáveis[44] são de frequência trimestral. Os dados foram coletados a partir de conjunto de bases (Banco Mundial, OCDE, BIS, Bloomberg)

O autor comparou diversos modelos nesse teste, modelos de equações individuais, Fatores comuns, modelos mistos de quadrados mínimos ordinários, Lasso e regressão em árvore e métodos de *machine learning* como *Suport Vector Machine*, *Random Forest* e *deep learning*.

O objetivo do autor era verificar as relações entre Política fiscal, mercado internacional e as flutuações do produto dos países, no sentido de desempenho o autor constatou que os modelos baseados em *deep learning* conseguiram superar os modelos tradicionais de equações individuais e de fatores comuns, porém se saíram piores que os modelos mistos construídos, assim como teria se saído pior que os outros modelos de *machine learning* analisados na tese.

No sentido todos os modelos apontaram a interpretação de que o mercado internacional foi mais determinante do que a política fiscal. O autor aponta que redes neurais são sim métodos robustos para predição de modelos macroeconômicos. Porém conforme os resultados apontados fica evidente que redes neurais tem falhas estruturais como a interpretabilidade e não são necessariamente a melhor solução para todos os problemas.

Carmo e Lopacinski (2023) também comparou modelos, eles os classificaram entre clássicos e contemporâneos. O trabalho examinou dois modelos: regressão linear simples; e redes neurais multicamadas. Assim aplicaram ambos modelos à predição da remuneração média mensal paga aos empregados nas 27 unidades da federação brasileira. Para isso os dados foram extraídos do IBGE através do Sistema de Recuperação Automática de dados (SIDRA). O estudo aponta um desempenho superior das redes neurais em comparação a regressão linear no critério da precisão. Contudo, os autores levantaram o mesmo ponto de Vasconcelos (2017) que a interpretabilidade das redes neurais é limitada.

> Do ponto de vista analítico, a análise de regressão linear é mais dinâmica e informativa que a RNA MLP[45]. Pois, ao identificar os coeficientes do modelo de regressão e seus sinais, é possível compreender o impacto de cada variável independente significativa na explicação do comportamento da variável de estudo. Ao passo que, a RNA MLP somente permite avaliar qual o grau de

[42] *Credit Default Swap* que é um indicador de risco de crédito.
[43] Índice de volatilidade.
[44] Para mais detalhes sobre as variáveis recomendamos a consulta do material original de Vasconcelos (2017)
[45] Redes Neurais Artificiais *Multilayer Perceptron*

> importância das variáveis explicativas do modelo. (Carmo e Lopacinski, 2023, p. 17)

Carmo e Lopacinski (2023) demonstraram que as redes neurais possuem uma capacidade modelar todas as variáveis, enquanto outros métodos como a regressão linear só consideram as variáveis significantes para o modelo. Outro ponto elencado pelos autores é a capacidade de modelar problemas não lineares, sendo uma vantagem em relação so modelo tradicional da regressão linear.

Os autores pontuam que ambos métodos tem vantagens e desvantagens, enquanto modelos tradicionais possuem rigor metodológico e capacidade interpretativa, modelos contemporâneos, como redes neurais podem ser considerada mais flexíveis, adaptando-se a tendências não-lineares, e até a dados incompletos, porém devido a sua complexidade arquitetural possuem baixa interpretabilidade.

Amaral *et al.* (2023) também realizaram testes de modelos baseados em redes neurais, porém ao invés de comparar a outras técnicas tradicionais, os autores testaram diferentes configurações de redes neurais. A principal diferença dos modelos até então apresentados é o métodos de treinamento, enquanto as redes neurais estudadas são do tipo totalmente conectada baseadas no *feedfoward* as três redes testadas por Amaral *et al.* (2023) são do tipo *Recurrent Neural Network* (RNN)[46].

> As RNN são um tipo de rede neural que foi desenvolvida para identificar padrões em um banco de dados. Através dos algoritmos da rede neural, ele é capaz de identificar, dentro de uma sequência de informações, similaridades de palavras, de texto, imagens e números, utilizando esses padrões para aprender e futuramente entender o que o está sendo "apresentado". (Amaral *et al.*, 2023, p. 11)

Para além disso os autores utilizaram um tipo de RNN mais sofisticada, a chamada RNN de Memória *Long-Short Term* (LTS), segundo os autores na arquitetura desse tipo de RNN é possível armazenar memórias de longo e curto prazo. Sendo uma arquitetura adequada para séries temporais econômicas que sofrem influências de curto e longo prazo.

No trabalho os autores testaram três modelos de redes neurais: univariado *stacked*[47]; multivariado; e univariado bidirecional[48]. Os dados foram extraídos do banco central do Brasil e

[46] Redes Neurais Recorrentes

[47] Esse tipo de modelo "possui uma arquitetura de mais de uma camada de neurônio escondida, no qual cada camada contém múltiplas células de memória."(Amaral *et al.*, 2023, p. 13).

[48] Em modelos Univariados bidirecionais, ao invés de um único modelo, existem dois. O primeiro aprende a sequência da entrada e o segundo o inverso, proporcionando um maior quantitativo de informações para o treinamento. (Amaral *et al.*, 2023)

do IBGE no período de janeiro de 2002 até março de 2023. O conjunto de dados compreende: taxa SELIC[49]; IPCA; PIM[50]; e taxa de câmbio.

Os resultados apontados pelos autores indicaram um desempenho relevante das RNN LTS. O melhor dos três modelos foi o multivariado, que apresentou os menores indicadores de erros, possuindo um maior grau de explicabilidade. O segundo com melhor desempenho foi o modelo univariado *stacked*, em que os modelos que usaram a taxa SELIC como entrada, obtiveram os melhores resultados. E o pior dos modelos foi o univariado bidirecional, que não obteve resultados satisfatórios, não superando em nenhuma variável o modelo univariado *stacked*.

A reflexão proposta pelo autor é que mesmo com uma quantidade limitada de dados o modelo baseado em RNN LTS multivariado teve desempenho satisfatório para predição de variáveis econômicas. Mas que mesmo o modelo obtendo um resultado aceitável, ainda assim é necessário uma análise de indicadores históricos e fáticos por um profissional técnico da área.

A partir do exposto de Amaral *et al.* (2023) foi possível notar outro tipo de arquitetura para redes neurais, essa com uma adequação relevante para séries históricas, porém ainda assim com as limitações inerentes a esse tipo de modelo, que apesar de terem uma explicabilidade alta dos fatores envolvidos no modelo e uma capacidade de captar relações quase que imperceptíveis nas variáveis econômicas, ainda se faz necessário o aval do técnico economista, implicando que a interpretabilidade de um modelo é algo importante.

Como nos outros modelos, é importante olhar como a literatura internacional utiliza os modelos. Entretanto, dessa vez, vamos utilizar o material de Ghosh e Ranjan (2023), que realizaram um trabalho com redes neurais para predição do GDP da Índia de janeiro de 2003 a dezembro de 2019. Esse material se assemelha com o que desejamos produzir com o presente trabalho, claro por tratarem de uma série histórica semelhante, mas especialmente, pois tanto o Brasil como a Índia são membros da lista de países emergentes, o que implica em economias complexas com características parecidas.

Os dados do trabalho foram extraídos do Banco da Reserva da Índia ou da CEIC[51], foram analisadas 13 variáveis mais o GDP como variável a ser predita. O modelo proposto pelos pesquisadores da Índia tratava-se de uma combinação de modelos para o *nowcasting*[52], o

[49] Sistema Especial de Liquidação e Custódia (SELIC)
[50] Produto Industrial Mensal (PIM)
[51] Trata-se de uma base de dados de indicadores macroeconômicos globais
[52] *nowcasting* é uma técnica de predição de variáveis de alta frequência, no contexto do estudo predizer o GDP usando variáveis diárias/semanais

modelo principal é um DFM, como visto anteriormente, para estimar valores para cada indicador econômico com base nos valores históricos desses indicadores foram utilizados três varições de modelo: *Random Forest*, ARIMA, Prophet[53]. E como modelo ponte, que conecta os fatores dinâmicos estimados com o GDP, temos o AR(1) e as redes neurais.

Os resultados obtidos pelos pesquisadores apontam que o modelo Prophet se saiu melhor no *nowcasting* do GDP, e que para previsões a partir de um mês as redes neurais apresentaram uma melhoria significativa em relação ao modelo AR(1), mas que para longos períodos, mais de um ano, o erro só aumentou, indicando que esse tipo de modelo de *nowcasting* não é o mais indicado para predição em longos períodos.

Apesar da semelhança dos dados e do contexto de aplicação, o trabalho de Ghosh e Ranjan (2023) busca um outra técnica de predição, buscando a alta frequência das variáveis e informações rápidas para tomadas de decisões fundamentadas. A partir do exposto dos autores é possível notar como diferentes modelos podem ser combinados para encontrar a melhor solução, nesse contexto as redes neurais foram usadas como modelo ponte, não como modelo principal, mas mesmo assim obtiveram resultados melhores que um modelo consolidado como o AR(1) para o *nowcasting*.

A partir dessa exposição de autores fica claro como métodos atuais como as redes neurais tem ganhado espaço dentro da predição econômica, não se tratam de modelos milagrosos que conseguem resolver todos os problemas do mundo. Esses modelos tem sim uma liberdade maior, não se restringindo a metodologias rígidas conforme Carmo e Lopacinski (2023), mas ainda assim dependem de um pesquisador o conduzindo e interpretando seus resultados (Amaral *et al.*, 2023).

Vimos também que talvez sua maior potencialidade não seja como o perceptron de Rosenblatt (1958), mas sim a combinação com outras técnicas e variações, criando modelos com alta capacidade preditiva e robustez conforme Amaral *et al.* (2023) e Ghosh e Ranjan (2023) demonstraram.

[53] O modelo Random Forest ainda veremos mais sobre o mesmo no presente trabalho. O modelo Prophet não será contemplado profundamente, mas afim de curiosidade esse é um procedimento baseado em modelos aditivos com ampla capacidade para aplicação em *nowcasting* por conseguir ajustar tendências não-lineares usando a sazonalidade (Ghosh e Ranjan, 2023).

#### *2.2.2.2 Random Forest*

Até o presente momento vimos diversos modelos, suas histórias e aplicações, desdes os ditos tradicionais, até modelos modernos baseados em IA, nesse sentido abordaremos mais um modelo atual as Florestas Aleatórias, ou mais conhecido como *Random Forest* do inglês.

A criação do *Random Forest* é atribuída a Breiman (2001). Trata-se da designação de uma "combinação de preditores em forma de árvore, de modo que cada árvore depende dos valores de um vetor aleatório amostrado de forma independente e com a mesma distribuição para todas as árvores da floresta."(Breiman, 2001, p. 1, tradução nossa). De uma forma mais simplificada, o *Random Forest* é uma técnica que consiste em criar vários pequenos modelos com preditores escolhidos de forma aleatória, a resposta advém de uma combinação das respostas de todos os modelos, que no caso de modelos regressivos é dada pela média dos valores.

De uma maneira técnica o *Random Forest*

> É um classificador que consiste em uma coleção de classificadores em forma de árvore $\{h(\mathbf{x}, \theta_k), k = 1, ...\}$, onde os $\{k\}$ são vetores aleatórios independentes e identicamente distribuídos, e cada árvore dá um voto unitário para a classe mais popular na entrada $\mathbf{x}$. (Breiman, 2001, p. 6, tradução nossa)

A força desse algoritmo é lidar com a grande quantidade de dados e capturar o comportamento de uma maneira que cada variável tem um pedaço da relevância. Nos modelos *Random Forest* do tipo de regressão[54] o resultado final do modelo será a média do resultado de cada uma das árvores. Essa noção é confirmada por Landowska *et al.* (2025) onde o autor pontua como o algoritmo do "constrói múltiplas árvores de decisão e agrega seus resultados, o que lhe permite lidar com conjuntos de dados de alta dimensão, reduzir o overfitting e fornecer insights valiosos sobre a importância das variáveis."(Landowska *et al.*, 2025, p. 5).

Lemos e Souza (2025) explica que o *Random Forest* é um modelo baseado árvores de regressão, que são um tipo de árvores de decisão. Nesse tipo de modelo "cada nó representa uma condição de decisão baseada em uma variável preditora, fornecendo um valor numérico, que normalmente é a média dos valores observados nas amostras que atingem aquele nó."(Lemos e Souza, 2025, p. 8). Segundo Landowska *et al.* (2025) o *Random Forest* leva vantagem em comparação a modelos econométricos tradicionais, pois conseguem lidar com relação não lineares e interações complexas entre as variáveis.

[54] Em classificações binárias no *Random Forest*, existe um sistema de votação, onde a maioria vence, um modelo democrático, se a maior quantidade de árvores forem um tipo de resposta, a resposta do modelo como um todo é o resultado da maioria

A equação que representa o modelo preditivo do *Random Forest* esta disposta na equação 2.11 apresentada por Vasconcelos (2017).

$$f(X) = \sum_{m=1}^{M} c_m \dot{I}(X \in \mathbb{R}_m) \tag{2.11}$$

O random forest como modelo predito de variáveis macroeconômicas foi utilizado por Landowska *et al.* (2025) no contexto da predição do GDP, por Lemos e Souza (2025) para uma abordagem utilizando as atas do COPOM e por Kava (2022) em sua dissertação como um dos modelos candidatos a predição de variáveis macroeconômicas brasileiras.

Existem centenas de outros modelos que seriam excelentes oportunidades de analises e comparações, porém como tudo na economia os recursos são finitos, e apesar das necessidades humanas ilimitadas, o *Random Forest* será o último modelo a ser abordado no presente trabalho. A partir desse ponto não trataremos mais sobre a literatura produzida como um relato do que foi feito, mas sim nos utilizaremos dessa fundação teórica como alicerces para a construção, aplicação e comparação dos modelos nas sessões futuras.

# 3 METODOLOGIA

## 3.1 Delineamento de pesquisa

Com base nos objetivos da presente pesquisa, a mesma se classifica como explicativa. Esse tipo de pesquisa "têm como preocupação central identificar os fatores que determinam ou que contribuem para a ocorrência dos fenômenos."(Gil, 2002, p. 87). Ao analisarmos o desempenho dos diferentes modelos econométricos voltados para a predição do PIB brasileiro, estamos buscando identificar e compreender os diferentes fatores que explicam esse desempenho, enquadrando-a como explicativa.

Sobre os procedimentos de coleta de dados, a presente pesquisa se enquadra como documental, por utilizar-se de dados que não receberam um tratamento e estão dispostos em repositórios digitais de dados. Segundo Gil (2002) a pesquisa documental apropria-se de diversas fontes, não somente material impresso em bibliotecas, onde os documentos utilizados podem ter um tratamento analítico ou não.

Por fim, ao se tratar de uma pesquisa que compara diferentes modelos econométricos, assim como avalia o desempenho dos mesmos, seguindo o rigor matemático e estatístico, ela se enquadra como uma pesquisa predominantemente quantitativa onde apropria-se do método comparativo e estatístico. Para Lakatos e Marconi (2003) o método estatístico trata-se da redução dos fenômenos a termos quantitativos e a manipulação estatística, onde possibilita a generalizações sobre sua natureza, ocorrência ou significado. Já "o método comparativo é usado tanto para comparações de grupos."(Lakatos e Marconi, 2003, p. 107, 108).

## 3.2 Procedimento de coleta de dados

As variáveis[1] foram escolhidas baseadas na dissertação de Rebelo (2022). As variáveis escolhidas podem ser verificadas na tabela 2. Os dados utilizados na pesquisa foram extraídos de 3 APIs (*Application Programming Interface*, no português, Interface de programação de aplicações), além de uma fonte de dados web, que náo disponibiliza API pública, mas seus

[1] Algumas das variáveis utilizadas por Rebelo (2022) não foram possíveis de se utilizar para o período escolhido para a realidade brasileira, dentre las as despesas do governo com ambiental, Índice de eficiência jurídica e índice de saúde fiscal. Porém vale se ressaltar que a partir de 2012 existe a série histórica do IFGF (Índice Firjan de Gestão Fiscal), assim como o IPC-Jus (Índice de Produtividade Comparada da Justiça), por outro lado as despesas do governo com ambiental são muito mais recentes, mas sendo possíveis variáveis a serem adicionadas em um futuro trabalho, quando os índices tiverem mais registros

dados podem ser salvos em formato de planilha. A relação variável[2] - Fonte - URL dos dados pode ser verificada na mesma tabela.

A primeira fonte foi a API de dados agregados do IBGE, onde nela existem informações econômicas, sociais e demográficas do Brasil.

> O IBGE possui uma Application Program Interface (API) de serviços de dados abertos que disponibiliza dados processáveis por máquina para qualquer cidadão ou sistema, permitindo a interoperabilidade e o enriquecimento a partir dos dados abertos disponibilizados. (Silva e Silva, 2024, p. 2).

A segunda API utilizada foi a API do BACEN (Banco Central do Brasil), onde foram extraídos dados das contas públicas do Brasil. Segundo o próprio BACEN (2025) o "catálogo de dados, permite que os usuários encontrem os conjuntos de informações de seu interesse, entendam sua estrutura e suas limitações, e tenham acesso ao caminho para os dados."

A terceira fonte de dados via API foi o Banco Mundial, onde foram extraídos dados refentes a despesas brasileiras e relação com o comércio exterior. Por último a Heritage Foundation foi a fonte escolhida para os dados de liberdade econômica.

O período analisado foi de 2007 à 2022, devido a disponibilidade de datas nas bases de dados.

## 3.3 Procedimento de análise de dados

A análise dos dados é um processo muito importante ao usar modelos matemáticos, conforme Kilkenny e Robinson (2018) a qualidade das respostas depende diretamente dos dados usados [3]. Ou seja, não basta ter fontes confiáveis como o (BACEN, 2025) e o (IBGE, 2025a), é necessário um procedimento confiável de ponta a ponta. Para esse processamento dos dados, foi utilizado a linguagem de programação *Python* [4] e suas bibliotecas.

O primeiro processo de tratamento foi a conversão dos tipos nativos das APIs para um formato adequado para análise com Python, isso foi feito através da biblioteca Pandas. "Pandas

[2] O índice de desemprego possui um adendo, pois trata-se da combinação de 2 índices devido a troca de metodologia do IBGE e a indisponibilidade de um índice unificado, o primeiro que compreende parte maior do período de 2012 a 202 é extraído da PNAD (Pesquisa Nacional de Amostra de Domicílio) continua, onde a variável em questão é a taxa de desocupação, na semana de referência, das pessoas de 14 anos ou mais de idade, enquanto o período de 2007 até 2011 utilizou-se a média da taxa de desocupação na semana de referência, das pessoas de 10 anos ou mais de idade, principais responsáveis pela família, da PME (Pesquisa Mensal de Emprego) metodologicamente essas variáveis são diferentes, pois a PME tem uma faixa etária e público alvo diferente, além de ser realizada em grandes centros, contudo devido as limitações optou-se por utilizar essas duas, pois são as mais próximas no sentido de aplicação ao nosso modelo

[3] O termo coloquial em inglês para essa situação se chama GIGO ou *Garbage In Garbage Out*, que em tradução livre - lixo entra lixo sai.

[4] Python é amplamente utilizado em computação científica e numérica (Python, 2023)

Tabela 2 – Fontes de dados utilizadas nas APIs do IBGE, BACEN, World Bank e Heritage Foundation

| **Indicador** | **Fonte** | **URL / Endpoint da API** |
|---|---|---|
| PIB | IBGE | https://servicodados.ibge.gov.br/api/v3/agregados/6784/periodos/-20/variaveis/9808?localidades=N1[all] |
| Deflator do PIB | IBGE | https://servicodados.ibge.gov.br/api/v3/agregados/6784/periodos/-20/variaveis/9811?localidades=N1[all] |
| população (milhões) | IBGE | https://servicodados.ibge.gov.br/api/v3/agregados/6579/periodos/-20/variaveis/9324?localidades=N1[all] |
| índice de direitos de propriedade | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Property Rights`) |
| índice de integridade governamental | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Government Integrity`) |
| índice de despesa governamental | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Government Spending`) |
| despesa pública em educação (% PIB) | World Bank | https://api.worldbank.org/v2/country/BRA/indicator/SE.XPD.TOTL.GD.ZS?date=2007:2025&format=json |
| despesa pública em saúde (% PIB) | World Bank | https://api.worldbank.org/v2/country/BRA/indicator/SH.XPD.GHED.GD.ZS?date=2007:2025&format=json |
| índice de carga fiscal | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Tax Burden`) |
| dívida pública (% PIB) | BACEN | https://api.bcb.gov.br/dados/serie/bcdata.sgs.13762/dados?formato=json&dataInicial=01/01/2007 |
| índice de liberdade empresarial | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Business Freedom`) |
| índice de liberdade laboral | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Labor Freedom`) |
| taxa de desemprego | IBGE | https://servicodados.ibge.gov.br/api/v3/agregados/4093/periodos/-20/variaveis/4099?localidades=N1[all] |
| índice de liberdade monetária | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Monetary Freedom`) |
| IPCA | IBGE | https://servicodados.ibge.gov.br/api/v3/agregados/1737/periodos/-20/variaveis/2266?localidades=N1[all] |
| índice de liberdade comercial | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Trade Freedom`) |
| balança corrente (% PIB) | World Bank | https://api.worldbank.org/v2/country/BRA/indicator/BN.CAB.XOKA.GD.ZS?date=2007:2025&format=json |
| Taxa aduaneira (tarifa média aplicada) | World Bank | https://api.worldbank.org/v2/country/BRA/indicator/TM.TAX.MRCH.WM.AR.ZS?date=2007:2025&format=json |
| índice de liberdade de investimento | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Investment Freedom`) |
| investimento direto estrangeiro (% PIB) | World Bank | https://api.worldbank.org/v2/country/BRA/indicator/BX.KLT.DINV.WD.GD.ZS?date=2007:2025&format=json |
| índice de liberdade financeira | Heritage Foundation | https://economicfreedom.heritage.org/pages/all-country-scores (variável `Financial Freedom`) |

é uma biblioteca de Python de estruturas de dados e ferramentas estatísticas, inicialmente desenvolvida para aplicações de finanças quantitativas."(McKinney, 2010, p. 1, *tradução nossa*).

O segundo passo de tratamento foi a inflação dos dados para 2022, último ano da série, isso foi feito através de um índice de preços, que pode verificado na equação 3.1. O IBGE (2025b) traz a definição de deflator do PIB, porém que se aplica as demais variáveis, em que um deflator é a variação do valor corrente da variável no tempo $(t)$ em relação ao valor da varável do ano $(t)$ a preços do ano anterior, ou seja a variação percentual em relação ao mesmo período do ano anterior.

$$\text{Valor real} = \frac{\text{Valor Nominal}}{\text{índice de Preços}} \times 100 \tag{3.1}$$

O terceiro passo de tratamento foi o treinamento dos modelos. Nesse passo foram utilizados as bibliotecas Scikit-learn e Tensorflow, os modelos foram treinados com dados de 2007 à 2017, totalizando 10 anos na série histórica (dados de treinamento), e deixando os últimos 5 anos (2017 à 2022) para a testagem dos resultados do modelo. Para Santos e Nolau (2022) as eficácias dos modelos nos dados de treinamento não são importantes, o que é relevante é como o modelo se sai com os dados de teste, ou seja, se o modelo consegue ser extensivo no período fora da amostra.

O último passo foi o cálculo das métricas de avaliação dos modelos, para esse passo foram avaliadas três dimensões: acurácia, interpretabilidade e custo computacional.

Para a acurácia foram escolhidas as métricas que foram utilizadas por Rebelo (2022): o Erro Quadrático Médio (EQM) descrito na equação 3.2; Erro Absoluto Médio (EAM) descrito na equação 3.3; a Raiz do Erro Quadrático Médio (REQM) descrito na equação 3.4; e por fim, o erro percentual absoluto médio (EPAM) descrito na equação 3.5.

$$\text{EQM} = \frac{1}{n}\sum_{i=1}^{n}(y_i \hat{y}_i)^2 \tag{3.2}$$

$$\text{EQM} = \frac{1}{n}\sum_{i=1}^{n}|y_i \hat{y}_i| \tag{3.3}$$

$$\text{REQM} = \sqrt{\text{EQM}} \tag{3.4}$$

$$\text{EPAM} = \frac{1}{n}\sum_{i=1}^{n} |\frac{y_i \hat{y}_i}{y_i}| \times 100 \tag{3.5}$$

Para Kava (2022) a interpretabilidade está diretamente relacionada a facilidade que um ser humano tem de entender os resultados de um modelo. Para essa dimensão foram usadas as métricas: Efeitos Locais Acumulados (ELA) descrito na equação 3.6; e a interação ente preditores através da estatística-H, descrita na equação 3.7, ambas descritas por Kava (2022).

$$\tilde{f}_j, \text{ELA}(x) = \sum_{k=1}^{k_j(x)} \frac{1}{n_k(k)} \sum_{i:X_j \in N_j(k)} [\hat{f}(z_{k,j}, x_j^{(i)}) - \hat{f}(z_{k-1,j}, x_j^{(i)})] \tag{3.6}$$

$$H_j^2 = \frac{\sum_{i=1}^{n} [\hat{f}(x^{(i)}) - PD_J(X_J^{(I)}) - PD_{-J}(X_{-J}^{(I)})]^2}{\sum_{i=1}^{n} \hat{f}^2(x^{(i)})} \tag{3.7}$$

A última dimensão é o custo computacional, essa se baseará principalmente no tempo de execução dos modelos, e na contagem de operações com ponto flutuantes - FLOPs (do inglês, FLOating Point Operations) em ambas as métricas, quanto mais alto o valor, maior é o custo computacional.

## 3.4 Constructo da pesquisa

A estrutura do constructo pode ser verificado na tabela 3

Tabela 3 – Constructo da pesquisa

| **Pergunta de Pesquisa** | | | |
|---|---|---|---|
| Em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro? | | | |
| **Objetivo Geral** | | | |
| Analisar em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro. | | | |
| **Objetivos específicos** | **variáveis/dados à coletar** | **Como analisar** | **Fonte**. |
| Caracterizar os modelos econométricos tradicionais (VAR, ARIMA, DFM e MIDAS) e de IA para a predição do PIB. | Modelos econométrico com capacidade de predizer séries temporais. | Buscar através da literatura modelos já utilizados com esses fins. | Castelli (2022), Azevedo (2020), Azevedo (2020), Ciquini *et al.* (2023), Silva e Silva (2024), Alves (2009), Moura *et al.* (2020) e Micheletti (2024). |
| Identificar as diferentes variáveis determinantes na estimativa do PIB. | Variáveis com possível influência no PIB com facilidade de coleta e atualização recorrente. | Procurar na literatura quais variáveis são utilizadas para a predição do PIB. | Rebelo (2022), IBGE (2025a) e BACEN (2025). |
| Aplicar diferentes modelos econométricos tradicionais e de IA para a predição do PIB. | Modelos econométricos e variáveis encontradas nos primeiros dois objetivos. | treinar os diferentes modelos usando os dados coletados através da linguagem de programação Python e suas bibliotecas de estatística. | Castelli (2022), Azevedo (2020), Azevedo (2020), Ciquini *et al.* (2023), Silva e Silva (2024), Alves (2009), Moura *et al.* (2020) e Micheletti (2024). |
| Comparar o desempenho dos modelos de IA e econométricos tradicionais usando diferentes métricas, como desempenho computacional, precisão e interpretabilidade. | erro Quadrático Médio (EQM), Erro Absoluto Médio (EAM), a Raiz do Erro Quadrático Médio (REQM), erro percentual absoluto médio (EPAM), Efeitos Locais Acumulados (ELA), estatística-H, tempo de execução e FLOPs | Submeter os modelos a testes nas métricas de acurácia, interpretabilidade e custo computacional. | Rebelo (2022) e Kava (2022). |

# 4 RESULTADOS E DISCUSSÕES

A análise dos resultados da nossa pesquisa não se trata de uma confirmação do melhor modelo possível para predição PIB. Muito menos uma avaliação sobre todas as variáveis macroeconômicas. Na realidade nosso ensaio tenta focar em um ponto focal. Se os modelos atuais, com técnicas sofisticadas e capacidade de modelar relações não lineares, conseguem estimar o comportamento econômico com precisão tão boa quanto, ou superior a dos modelos ditos tradicionais.

Desse modo, a proposta didática iniciada no início de nossa discussão permanece. Não buscamos nesses resultados aprofundar na álgebra ou na programação envolvida no desenvolvimento desse trabalho. Na realidade buscamos uma interpretação econômica dos resultados apontados, compreendendo que o modelo é uma ferramenta para o economista. Já que o foco é comparar os modelos, em um cenário que o economista no exercício de sua profissão o encontrará.

Acreditamos que essa perspectiva não trará prejuízo ao leitor. Tendo em vista que nossa revisão de literatura atinge esse papel de fonte de conhecimento técnico, que permite o aprofundamento sobre os nuances matemáticos[1] que fundamentam as ferramentas abordadas.

Esse trabalho busca muito mais apresentar um uso real desses conceitos. Ou seja existe esse conhecimento no mundo das ideias, agora queremos trazê-lo para fora da caverna. Vamos iniciar a avaliação desses resultados, e entender como esse conhecimento pode ajudar um economista a reduzir o risco.

## 4.1 ARIMA

Para começarmos falaremos do modelo base de comparação. Conforme apontado em nossa revisão, o ARIMA é um modelo do tipo autorregressivo univariado, ou seja, usa a própria série histórica da variável para determinar qual será o seu possível valor futuro. É um modelo relativamente simples[2], tem um objetivo enxuto, estimar uma única variável.

Os prós de modelos dessa natureza é justamente sua simplicidade. Pois além dos

[1] Em relação ao código, atualmente com o uso de ferramentas de IA generativa, o economista que conhece o conceito, consegue aplicar o conhecimento em forma de código sem muita resistência, inclusive os testes e aplicações dos modelos em Python foram construídos com auxílio de ferramentas generativas de código, mais especificamente o Gemini e o ChatGPT, com suas ferramentas agênticas, a do Gemini aplicada diretamente no Google Colab e a do ChatGPT por meio do Codex.

[2] Comparado aos outros modelos que serão nossos alvos de comparação

custos computacionais serem reduzidos. Esse tipo de modelo tem um custo de coleta de variáveis menor, afinal é apenas uma série, e está é justamente o alvo. A série é o PIB anual de 2002 à 2022, como teste e os anos de 2023 a 2025 como validação. Como apontado na metodologia a série é deflacionada com o ano de 2023 de base. Nos anos de 2024 e 2025 foram reconstruídos a partir da série trimestral do PIB e deflacionada usando uma metodologia de índices inspirada no deflator do PIB do IBGE.

Contudo a implementação de um modelo, por mais simples que ele possa ser, exige fundamentação. Não é somente colocar a série e esperar o resultado de erro mínimo. O primeiro procedimento fundamental é a verificação de estacionariedade[3]. A justificativa para esse teste é lógica, entende-se que séries temporais tem uma tendencia natural relacionado ao tempo, ou seja, o próprio tempo é um componente do modelo.

Quando falamos de modelos multivariados, usamos séries estacionárias, para eliminar o tempo, e impedir erros do tipo I da estatística de correlação entre variáveis que na realidade se relacionam com o tempo. Mas no caso de modelos univariados, por que isso é importante?

Ai que entra o ARIMA, o I de *Integrated* (integrado) é justamente a ideia de usar a diferenciação dos dados, para obter séries estacionárias, ou seja o ARIMA incorpora a diferença em sua estrutura. Isso se deve justamente ao parâmetro $d$ de uma ARIMA($p$, $d$, $q$). Com d sendo o nível da diferença[4].

É de se imaginar que o PIB seja uma série não estacionária, afinal ela tem uma forte relação com o tempo. Todavia achismos não são científicos, para comprovar devemos testar a série. Para isso utilizaremos o Teste de Dickey-Fuller aumentado (ADF). O teste ADF aplicado na série do PIB para as 22 observações a um nível de confiança de 5%.

Nesse caso a estatística ADF foi de $-1.3615$. E para um nível de confiança de 5%: $-3.0054$, não há evidência estatística para rejeitar a raiz unitária. Desse modo precisamos diferenciar a série, e testaremos novamente.

Com a série do PIB diferenciada obtivemos que ADF $= -3.3254$, e com valor crítico de 5% : $-3.0131$, ou seja rejeita-se a hipótese de raiz unitária, levando a crer que a série na primeira diferença é estacionária. Essa evidência é suficientemente forte para usarmos o parâmetro $d = 1$, ou seja, primeira diferença[5].

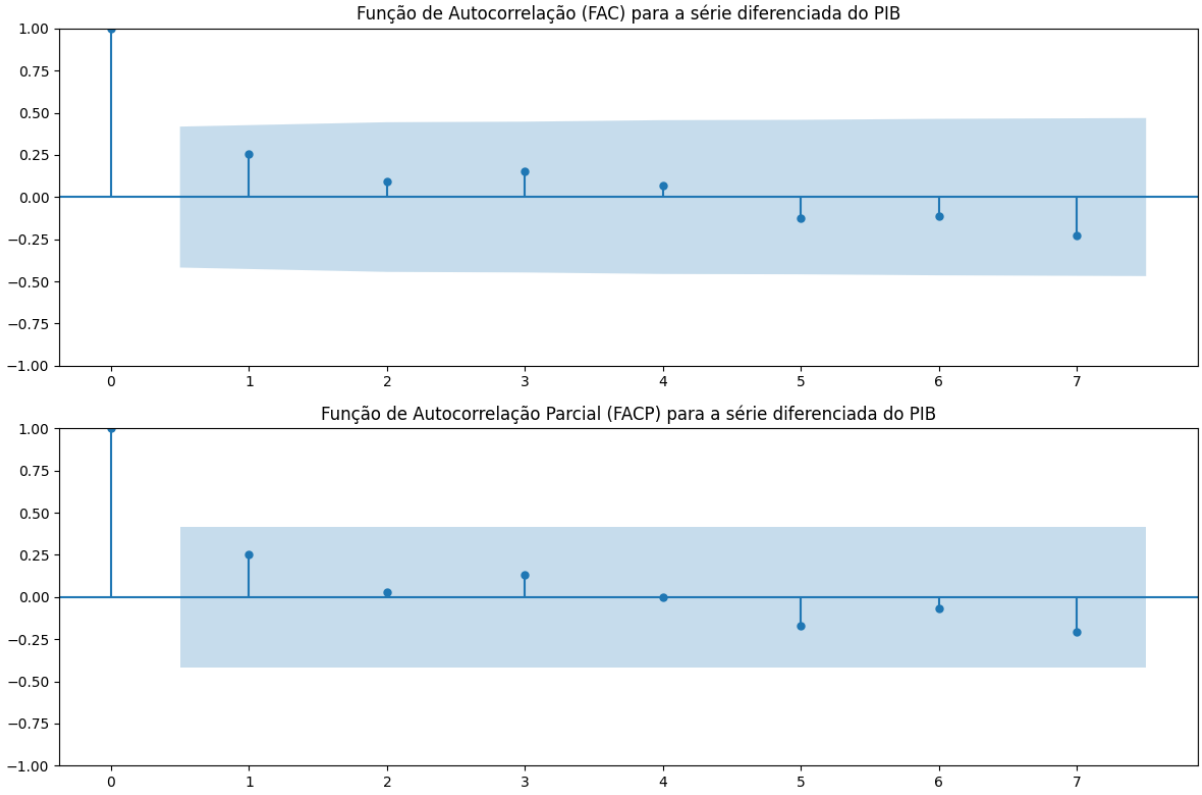
[3] Esse teste é recorrente em análise de séries temporais

[4] $p$ e $q$ retomaremos a diante, mas relembrando, $p$ refere-se a parte autoregressiva (AR) e $q$ a parte referente a média-móvel(MA)

[5] Ao invés de usarmos a diferença, poderíamos utilizar a variação do PIB em forma de crescimento, contudo como o ARIMA tem justamente essa ideia de acoplar a possibilidade de tratar séries não estacionárias, deixaremos o

Porém, tendo o $d$, ainda falta estimar os parâmetros $p$ e $q$. Esses valores podem ser entendidos como o fator autorregressivo, e o fator da média móvel. Para estimar o valor deles utilizaremos o Fator de autocorrelação (FAC) e o Fator de Autocorrelação Parcial (FACP) para identificar os cortes nos lags e tentar identificar os parâmetros faltantes do ARIMA.

Figura 6 – Teste FAC e FACP




Fonte: Elaborado pelo autor (2026).

A palavra "tentar"foi cuidadosamente escolhida, pis nem sempre tentar é conseguir e esse é um ponto que o economista se deparará. Como na imagem, em que parece não haver uma quebra significativa, na realidade ambos os teste se assemelham a um ruído branco. O mesmo comportamento pode ser verificado na tabela 4.

Todavia, apesar dos teste FAC e FACP serem úteis para estimação, eles não são determinantes dos parâmetros $p$ e $q$. Para além disso o ARIMA apresenta sua vantagem de ser uma modelo leve, podemos testar várias combinações de ARIMA, com valores variados de $p$ e $q$, e verificar o que se sai melhor[6].

Para encontrar o melhor modelo nesse momento utilizamos os critérios de o AIC

PIB em volume.

[6] Apesar de falarmos isso sobre os modelos leves, essa metodologia de repetição e teste de força bruta, se repetiu até em modelos mais pesados, porém o teste desses parâmetros no ARIMA levou 323ms na máquina de testes

Tabela 4 – Valores da Função de Autocorrelação (FAC) e Autocorrelação Parcial (FACP)

| Lag | FAC | FACP |
|---|---|---|
| 0 | 1.0000 | 1.0000 |
| 1 | 0.2318 | 0.2318 |
| 2 | 0.0490 | -0.0050 |
| 3 | 0.1739 | 0.1730 |
| 4 | 0.1388 | 0.0656 |
| 5 | -0.1258 | -0.1885 |
| 6 | -0.1138 | -0.0796 |
| 7 | -0.1767 | -0.1899 |

Fonte: Elaborado pelo autor (2026).

(Critério de Informação de Akaike) e o BIC (Critério de Informação Bayesiano). E com base em ambos o modelo ARIMA(1,1,1) foi o modelo que obteve o melhor desempenho. Os melhores modelos podem ser verificados na tabela 5.

Tabela 5 – Melhores modelos ARIMA nos critérios AIC e BIC

| p | d | q | Modelo | AIC | BIC |
|---|---|---|---|---|---|
| 1 | 1 | 1 | ARIMA(1,1,1) | 477.622452 | 480.609649 |
| 1 | 1 | 2 | ARIMA(1,1,2) | 477.765507 | 481.748436 |
| 2 | 1 | 1 | ARIMA(2,1,1) | 478.245759 | 482.228688 |
| 2 | 1 | 2 | ARIMA(2,1,2) | 478.883565 | 483.862226 |
| 0 | 1 | 0 | ARIMA(0,1,0) | 481.837388 | 482.833120 |
| 2 | 1 | 0 | ARIMA(2,1,0) | 483.320427 | 486.307623 |
| 0 | 1 | 1 | ARIMA(0,1,1) | 483.427673 | 485.419138 |
| 1 | 1 | 0 | ARIMA(1,1,0) | 483.690754 | 485.682219 |
| 0 | 1 | 2 | ARIMA(0,1,2) | 484.203456 | 487.190653 |

Fonte: Elaborado pelo autor (2026).

Mas além do modelo se sair bem, uma boa prática é testar seus resíduos, utilizaremos para isso os testes Ljung-Box para verificar autocorrelação dos resíduos, e Jarque-Bera para constatar normalidade dos resíduos. Essas informações são evidenciadas na tabela 6.

A partir dos resultados de Ljung-Box, não há evidências estatísticas de autocorrelação nos resíduos até o lag 5. E pela estatística Jarque-Bera, não há evidências estatísticas suficientes, para rejeitar a hipótese de normalidade dos resíduos ao nível de 5%. Ou seja o modelo ARIMA(1,1,1) parece ser um ótimo candidato. Nas tabelas 7, 8 e 9 podemos ver respectivamente o resumo do modelo, os valores dos fatores de média móvel e autorregressivo, e por último, a análise dos resíduos.

Porém esse modelo ainda tem alguns problemas. Primeiramente realizamos esses

Tabela 6 – Diagnóstico dos resíduos do modelo: testes de Ljung-Box e Jarque-Bera

| **Teste de Ljung-Box** | | |
|---|---|---|
| **Lag** | **Estatística ($Q$)** | **p-valor** |
| 1 | 0,0311 | 0,8600 |
| 2 | 0,0334 | 0,9834 |
| 3 | 0,0371 | 0,9981 |
| 4 | 0,0372 | 0,9998 |
| 5 | 0,0467 | 1,0000 |
| **Teste de Jarque-Bera (Normalidade)** | | |
| Estatística JB | | 252,6057 |
| p-valor | | $<$ 0,0001 |
| Assimetria | | 4,0389 |
| Curtose | | 17,9479 |

Fonte: Elaborado pelo autor (2026).

Tabela 7 – Resumo do modelo ARIMA(1, 1, 1)

| | | | |
|---|---|---|---|
| Dep. Variable: | PIB Real | No. Observations: | 21 |
| Model: | ARIMA(1, 1, 1) | Log Likelihood | -235.811 |
| Date: | Wed, 11 Nov 2026 | AIC | 477.622 |
| Time: | 21:23:14 | BIC | 480.610 |
| Sample: | 0 | HQIC | 478.206 |
| | - 21 | | |
| Covariance Type: | opg | | |

Fonte: Elaborado pelo autor (2026).

Tabela 8 – Componentes do modelo ARIMA(1, 1, 1)

| | coef | std err | z | P>\|z\| | [0.025 | 0.975] |
|---|---|---|---|---|---|---|
| ar.L1 | 0.9285 | 0.081 | 11.493 | 0.000 | 0.770 | 1.087 |
| ma.L1 | -0.8896 | 0.108 | -8.203 | 0.000 | -1.102 | -0.677 |
| sigma2 | 1.307e+09 | 8.72e-12 | 1.5e+20 | 0.000 | 1.31e+09 | 1.31e+09 |

Fonte: Elaborado pelo autor (2026).

Tabela 9 – Análise dos resíduos do modelo ARIMA(1, 1, 1)

| | | | |
|---|---|---|---|
| Ljung-Box (L1) (Q): | 0.23 | Jarque-Bera (JB): | 0.75 |
| Prob(Q): | 0.63 | Prob(JB): | 0.69 |
| Heteroskedasticity (H): | 2.65 | Skew: | -0.40 |
| Prob(H) (two-sided): | 0.22 | Kurtosis: | 2.49 |

Fonte: Elaborado pelo autor (2026).

testes com apenas 23 observações, isso reduz a confiabilidade do modelo. Porém isso é uma realidade econômica enfrentada pelos economistas. As agências de coleta de dados não tem séries contínuas em décadas[7] para ser possível ter uma modelo com uma margem considerável de observações nessa configuração de frequência.

Outro problema é o AR calculado, que é muito próximo de 1, isso implica que o fator autoregressivo é muito persistente. Em uma série como o PIB isso significa um choque ocorrido hoje tende a continuar influenciando a série por vários períodos. Mas por outro lado o MA quase anula o AR, ou seja, o fator MA ser $-0.9210$, está praticamente anulando o AR:0.9541, os choques tem um efeito contrário muito forte. Esse cancelamento de fatores leva uma matriz de covariância quase singular, indicando uma forte relação dos dois fatores.

Esses problemas são reais, mas falam mais da natureza da série do que propriamente de uma falha do ARIMA, estamos falando de uma série anual do PIB que é tem uma frequência baixa naturalmente. E ainda optamos por trunca-la, pois haviam observações anteriores à 2002 do PIB anual. Porém para haver uma parcimônia entre modelos, no sentido tamanho da série, optamos por cortar esses anos. E mesmo assim encontramos um modelo relativamente bom, inclusive capturando um comportamento típico do PIB brasileiro.

A conclusão que pode ser obtida do ARIMA é: A série do PIB brasileiro tem uma forte tendência de manter o comportamento das séries anteriores apontado pelo AR, isso é explicado pelas tendências de crescimento e queda que existiram durante o período analisado, mas para além disso o MA tem um força puxando para equalizar, ou seja a tendência inercial é anulada por fator de média móvel. Veremos na série temporal isso mais de perto.

Com toda a análise do ARIMA, ainda não conhecemos a série, falamos do modelo, de sua aplicação mas não do seu foco. Entretanto agora podemos olhar a série na figura **??**, não somente como um gráfico de linha do PIB, mas sim como uma economia real e a interpretação econométrica sobre essa série[8].

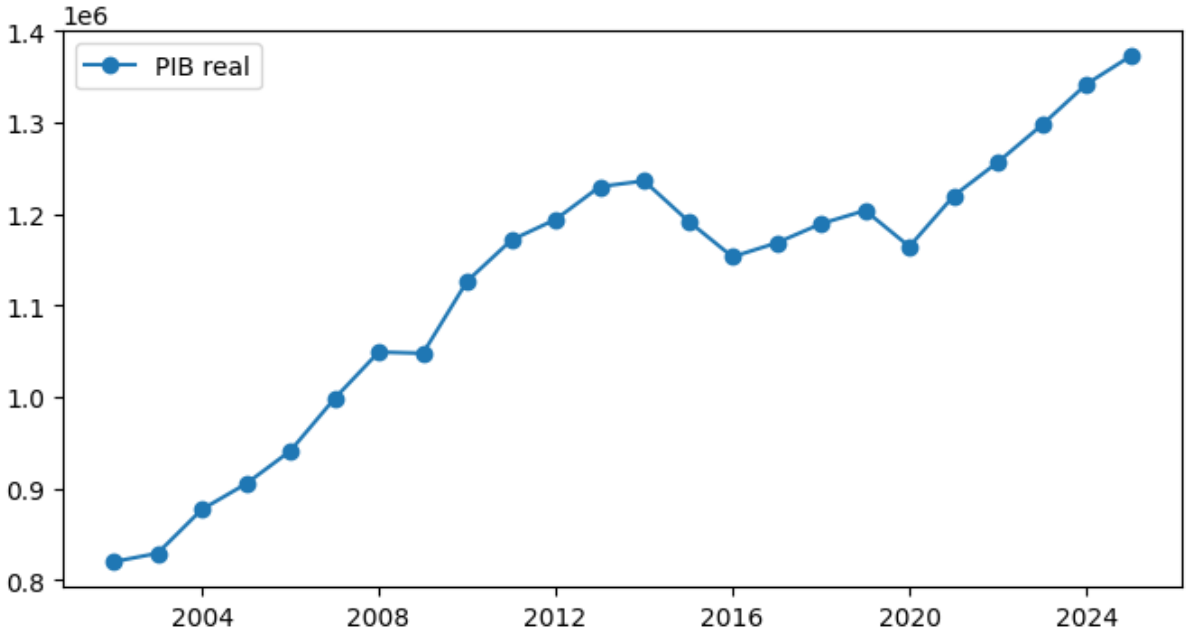
Podemos ver como a série tem uma forte influência temporal. Para entender melhor o comportamento do modelo e do PIB vamos visualizar a série com a primeira diferença, que é como o ARIMA a utiliza, na figura 8. Notem como o comportamento do PIB, possui tendências de crescimento e de queda mas que são de certa forma segurados pela média móvel.

A interpretação econômica do ARIMA capta diretamente uma economia instável como a brasileira. Os impactos do mercado externo como o *boom* das commodities no início

[7] teremos um problema muito grande com isso em uma série específica, mas trataremos disso posteriormente

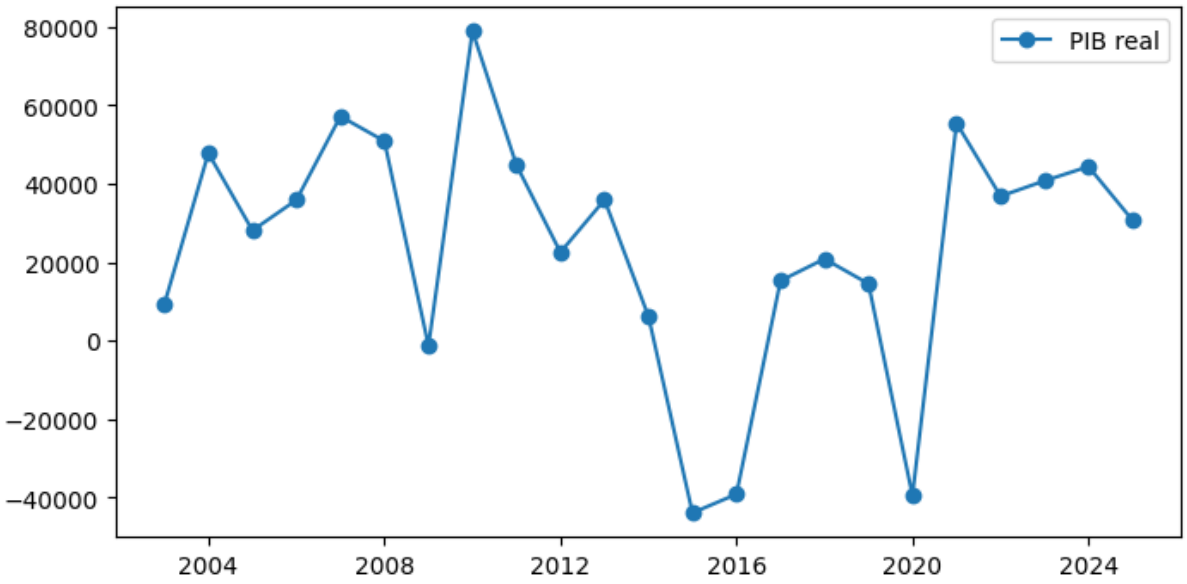
[8] A unidade do PIB nesse gráfico é em milhões de reais

Figura 7 – PIB em volume deflacionado




Fonte: Elaborado pelo autor (2026).

Figura 8 – PIB na primeira diferença




Fonte: Dados do IBGE (2025a) elaborado pelo autor (2026).

dos anos 2000, e o impacto da crise de 2008 nos anos futuros, além das crises políticas que aconteceram a partir de 2014 até 2017, e também a crise sanitárias da COVID-19 em 2020-2021. Notemos que por se tratar de uma economia emergente[9], esses eventos tem uma influência explicita sobre o PIB.

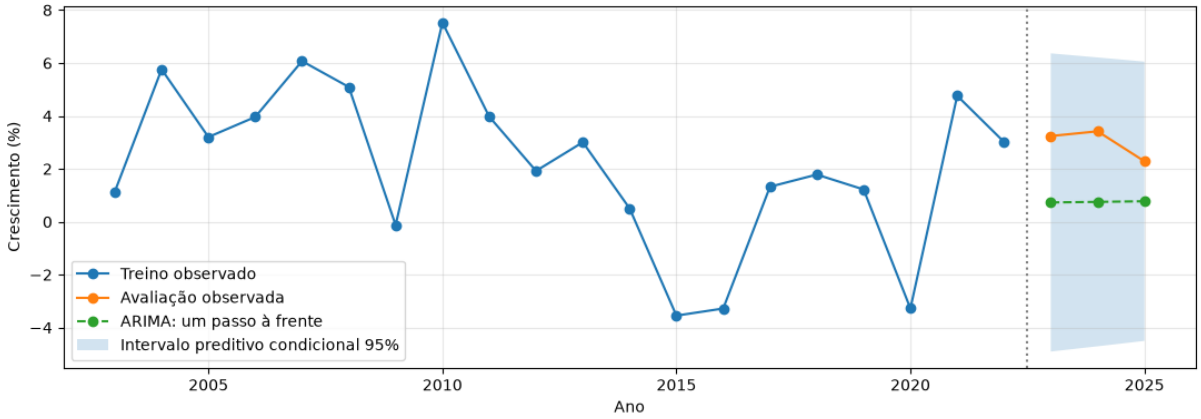
Essa análise, em grande medida, apesar de necessitar de uma base econômica,

[9] Mais volátil a crises e ao cenário externo

histórica e política, aponta como o modelo consegue captar o comportamento da variável. E a conclusão é que mesmo não tendo um volume comparável ao *big data*, um modelo com apenas uma variável ainda pode apontar para tendências e comportamentos de uma economia real.

Por último, mas não reduzindo sua importância, podemos ver a extrapolação do PIB utilizando o ARIMA. Nessa previsão optamos por utilizar a chamada previsão um passo a frente, nela o modelo é usado para prever um único valor imediatamente. No método que utilizamos, após prever o ano de 2023, o valor real medido é introduzido na série e é realizado a previsão, do ano de 2024 e assim por diante[10]. Além disso apesar de no modelo internamente utilizar a primeira diferença conforme visto na figura 8, para a visualização externa e interpretação econômica utilizaremos o crescimento percentual do PIB, isso inclusive permitirá a comparação direta entre os modelos.

Figura 9 – Previsão de crescimento percentual do PIB ARIMA(1, 1, 1)



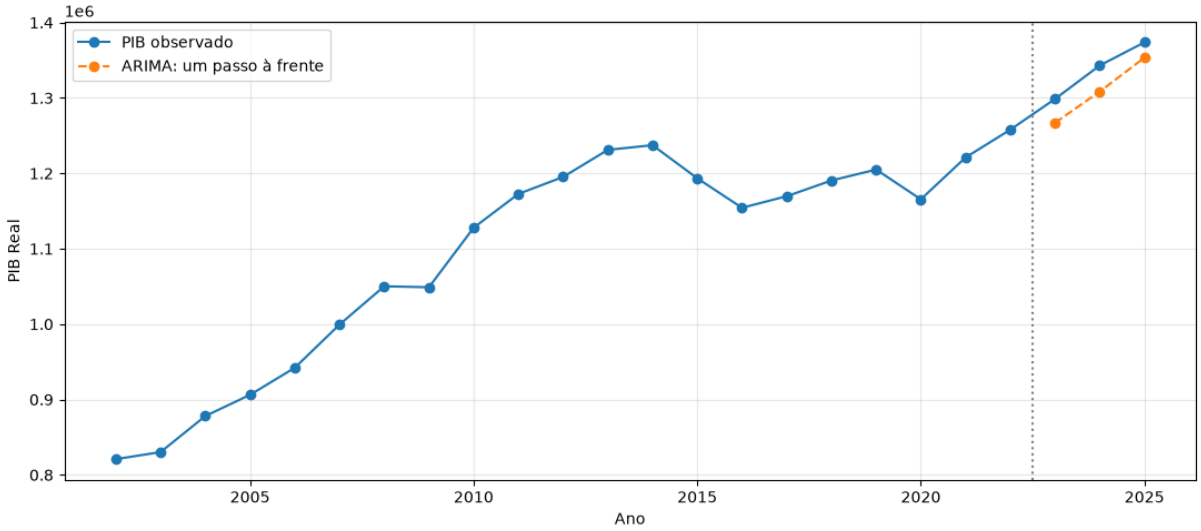

Fonte: Elaborado pelo autor (2026).

Na figura 9 vemos justamente a previsão um passo a frente do ARIMA estimando para baixo, e o valor efetivamente medido pelo IBGE. Notamos que o ARIMA subestima o crescimento do PIB nos 3 anos, e tem uma estimativa praticamente igual para os 3 anos. Já na figura 10 notamos a estimativa do PIB em nível, a estimativa em nível, apesar de não ser tão reveladora, ela fornece uma forma visual de compreender o acerto do modelo.

Uma métrica importante que podemos analisar são os erros do modelo, na figura **??**. Esses erros são relativamente altos, porém fica evidente como, mesmo um modelo "simples", com acesso limitado a informações por ser univariado, ainda assim consegue ter uma qualidade, e estimar mesmo que subestimando o comportamento do PIB brasileiro.

[10] Esse método só foi escolhido pois iremos fazer algo parecido com modelos futuros, e estamos buscando parcimônia entre modelos

Figura 10 – Previsão do PIB em nível utilizando ARIMA(1, 1, 1)




Fonte: Elaborado pelo autor (2026).

O erro de previsão ficou com as métricas finais de MAE: 2.2296 e RMSE: 2.2876. A tabela de erro por ano previsto pode ser verificada em 10. Notemos uma previsão subestimada, e um erro percentual alto.

Tabela 10 – Previsão e erro fora do treinamento para o ARIMA (1, 1, 1)

| ano | crescimento_real | crescimento_previsto | erro | erro_abs |
|---|---|---|---|---|
| 2023 | 3.240708 | 0.730640 | 2.510068 | 2.510068 |
| 2024 | 3.419152 | 0.751827 | 2.667325 | 2.667325 |
| 2025 | 2.286924 | 0.775439 | 1.511485 | 1.511485 |

Fonte: Elaborado pelo autor (2026).

Contudo, esse resultado confirma a hipótese levantada em nossa revisão de literatura. Usar o modelo ARIMA como um *benchmark* para outros modelos, tendo em vista sua simplicidade e capacidade preditiva formidável. Um modelo mais complexo com resultado pior ou semelhante ao ARIMA não parece ser adequado a esse contexto, já modelos melhores deve-se analisar o ganho e os custos de análise.

A partir dessa exposição, terminamos o primeiro modelo, o ARIMA. Muitas das etapas que foram um pouco mais detalhadas nesse primeiro modelo, como o teste de estacionariedade, os fatores de autocorrelação serão utilizados nos próximos modelos, mas não daremos tanto detalhamento. Optaremos por detalhar mais os modelos do que propriamente os testes. Agora precisamos subir a escada dos modelos, se testamos com um, agora vamos com dois, ou mais.

## 4.2 VAR

O VAR diferentemente do ARIMA é multivariado, ou seja, dois ou mais, nele podemos utilizar várias variáveis para a predição econômica do PIB. Por isso um pensamento natural seria pegar todas as variáveis coletadas e colocá-las em um único modelo VAR, contudo devido a limitação de disponibilidade dos dados para alguma das variáveis coletadas, as observações são reduzidas, algo já constato quando analisamos os resultados do ARIMA, porém quando estamos falando do uso de diversas variáveis, os graus de liberdade são reduzidos, perdendo qualidade no resultado da estimação.

Esse comportamento limitante leva-nos a escolher as "melhores"variáveis para o modelo, mas o que seriam essas melhores variáveis, primeiramente vamos verificar a nossa lista novamente, em nosso trabalho, conforme indicado na metodologia coletamos as seguintes variáveis: população (milhões), taxa de desemprego, IPCA, PIB Real, balança corrente (% PIB), investimento direto estrangeiro (% PIB), dívida pública (% PIB), índice de direitos de propriedade, índice de integridade governamental, índice de despesa governamental, índice de carga fiscal, índice de liberdade empresarial, índice de liberdade monetária, índice de liberdade comercia,l índice de liberdade de investimento, índice de liberdade financeira.

Porém só de olhar nesses dados já encontramos 3 varáveis com potenciais problemas: a população, o IPCA e o PIB. Isso mesmo, a nossa variável alvo, é um potencialmente problemática, no caso da população estamos falando de um valor quantitativos de brasileiros, além de ser um número fora da escala, é um valor que atrapalharia o modelo nesse formato. A segunda variável IPCA é um fator acumulado, e dessa forma também não irá ser útil nesse formato. E por último o PIB nossa variável alvo está em volume e também pode não ser a melhor forma de utiliza-lo em um modelo econométrico.

Uma solução simples seria remover essas variáveis do modelo, mas essa estratégia parece ser um pouco radical, afinal remover o nosso alvo de predição, não é uma decisão muito assertiva de uma perspectiva de cumprir nossos objetivos. Para além desse fator, o IPCA parece ser uma varável candidata muito interessante da perspectiva econômica, afinal entender como a inflação afeta o PIB, para além do valor nominal, é um estudo relevante para os economistas. E pelo outro lado, apesar da população ser mais uma variável demográfica do que econômica, faz sentido de uma perspectiva humana, analisar se a população tem alguma relação para além do aumento de consumo e mão de obra no que tange ao PIB.

Dessa forma decidimos por não descartá-las nesse primeiro momento, pelo mínimo

não usando esse critério. Afinal existem maneiras de contornarmos esses problemas, relembremos o modelo ARIMA, nele não precisamos fazer um tratamento no PIB, usamos o valor em volume, mas se bem lembrarmos ele utiliza o fator d, para determinar a diferença da série. Essa seria uma solução utilizar a diferença na série, corrigiríamos os pontos apresentados como preocupantes, porém para além de simplesmente solucionar o problemas, buscamos a interpretação econômica do problema, por isso, podemos ao invés de utilizarmos a diferença, podemos calcular o crescimento da séries, no caso do PIB e da população, e no caso do IPCA, quando falamos de crescimento do índice, na realidade estamos falando da famosa inflação.

Dessa forma alteramos o estado inicial de 3 variáveis, excluindo suas versões originais e agora adotando o crescimento do PIB, crescimento Populacional e a inflação como as variáveis do nosso futuro modelo. Mas ainda assim temos um problema, que é a escala de variáveis, estamos falando de índices, valores de crescimento, indicadores baseados em percentuais do PIB, ou seja temos dados fora de escala, então o próximo procedimento foi colocar todas as variáveis em escala, para podermos prosseguir com a aplicação.

O VAR assim como o ARIMA, por tratar de séries temporais pressupõe a ideia de estacionariedade, o ARIMA faz por meio de uma parâmetro, todavia o var não tem esse valor como entrada, na realidade o VAR espera como entrada as séries já estacionárias, então precisamos testar e descobrir quais séries são estacionárias existem, e o que faremos com as que não são. Aplicando o teste ADF em cada uma das séries obtemos o seguinte resultado:

As variáveis balança corrente (% PIB), crescimento PIB, dívida pública (% PIB), investimento direto estrangeiro (% PIB), taxa de desemprego, índice de direitos de propriedade, índice de integridade governamental, índice de liberdade financeira, índice de liberdade monetária são estacionárias;

As variáveis índice de despesa governamental e a inflação se tornaram estacionárias após a primeira diferença;

As variáveis índice de carga fiscal, índice de liberdade comercial, e índice de liberdade de investimento se tornaram estacionárias após a segunda diferença;

A variável crescimento populacional se tornou estacionária somente após a terceira diferença.

A variável índice de liberdade empresarial não se tornou estacionária mesmo após a terceira diferença.

Dessa forma optamos por utilizar as séries somente até a primeira diferença, des-

cartando as que precisaram de mais de uma diferenciação, para confirmar o resultado obtido pelo teste ADF, optamos por utilizar em conjunto o teste Teste Phillips-Perron para as variáveis que precisaram ser diferenciadas para se tornarem estacionárias. Nesse caso tanto a inflação como o índice de despesa governamental apresentam-se como estacionárias a um nível de 5% de confiança.

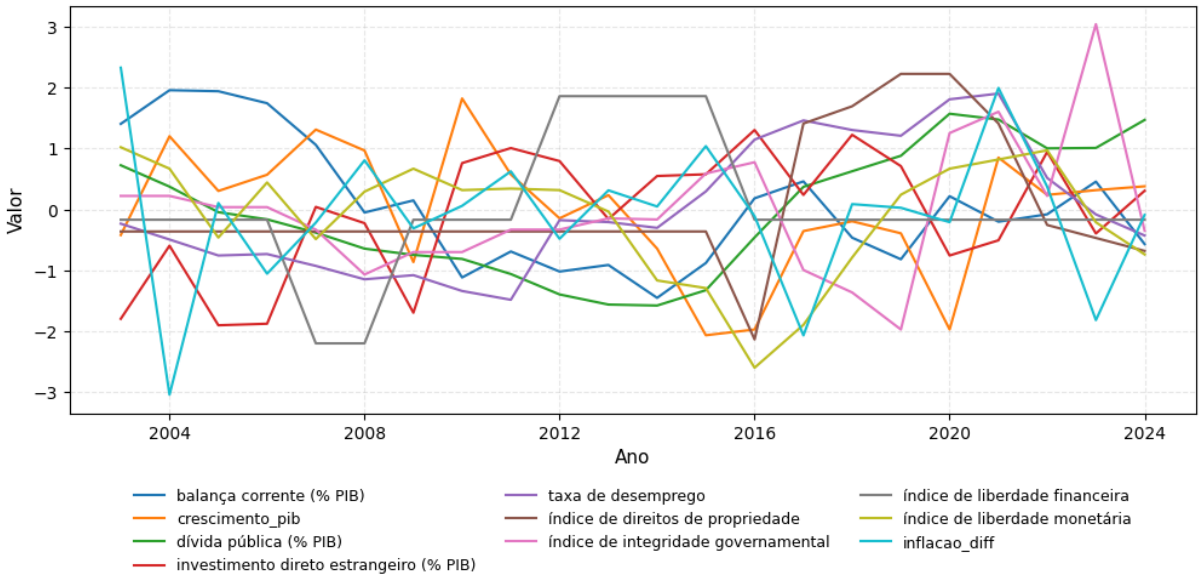
Para garantir a boa utilização dessas variáveis em nosso modelo VAR vamos testar a cointegração de Johansen das variáveis da primeira diferença. O teste apresentou cointegração conforme o quadro **??**:

Desse modo como o: O teste do traço encontrou evidência de 1 cointegração; O teste do máximo autovalor encontrou 1 evidência de cointegração;

Vamos a construção de nosso modelo com apenas 1 dessas variáveis devido a cointegração, optamos pela inflação por ser uma variável de alto interesse econômico, não que índice de despesa governamental não seja importante de uma perspectiva econômica, mas optaremos pela inflação por ter uma relação mais direta com a macroeconomia e por ser um indicador mais usual no dia a dia de um economista.

Ao final desse tratamento/escolha de variáveis obtemos as seguintes variáveis apresentadas nas figura 11.

Figura 11 – Variáveis candidatas ao modelo VAR




Fonte: Elaborado pelo autor (2026).

Porém a visualização de todas essas variáveis em um único gráfico já é complicado, o uso de todas em um único VAR é impraticável sem adaptações, portanto vamos optar por

utilizar um VAR menor, com somente alguma dessas variáveis. Porém agora chegamos a um impasse característico de um econometrista, quais variáveis escolher para o modelo, enquanto na decisão pela variável da primeira diferença fomos arbitrários, utilizando uma justificativa econômica. Nessa escolha não temos esse conforto pois são 9 variáveis com grande potencial preditivo do PIB, não podemos simplesmente coletá-las e partir desse momento escolher a dedo qual será usada.

Entretanto a solução mais adequada é mais simples do que aparenta, basta testar todos os modelos possíveis para esse conjunto de variáveis. Tendo em vista isso testamos um modelo VAR com uma defasagem VAR(1), para todas as 9 variáveis tendo o crescimento do PIB como uma variável alvo:

COMPARAÇÃO DE MODELOS VAR

Observações: 22 Variável alvo: crescimento_pib Candidatas: 9 Máximo de variáveis no VAR: 9 Defasagem utilizada: VAR(1)

Com essas configurações obtivemos os 5 melhores modelos ns critérios de menor RMSE e MAE:

| Variáveis |
|---|
| ['crescimento_pib', 'balança corrente (% PIB)'] |
| ['crescimento_pib', 'balança corrente (% PIB)', 'índice de liberdade financeira'] |
| ['crescimento_pib', 'balança corrente (% PIB)', 'índice de liberdade financeira', 'inflacao_dif |
| ['crescimento_pib', 'balança corrente (% PIB)', 'taxa de desemprego'] |
| ['crescimento_pib', 'investimento direto estrangeiro (% PIB)', 'taxa de desemprego'] |

Podemos notar que os melhores modelos tem como preditor a balança corrente, porém isso tem um sentido muito lógico, afinal balança corrente é definido como uma porcentagem do PIB. Mas para além disso o Brasil é uma economia que tem o setor primário-exportador um grande fator na composição do PIB, portanto faz muito sentido esperar que o crescimento do PIB é explicado em medida pelo comportamento externo, porém para não ficarmos somente na especulação vamos ver o que os modelos tem a dizer.

O cinco melhores modelos tem características em comuns que contribuem para classificá-los como modelos adequados a predição do PIB. Os candidatos apresentam estabilidade em nenhum deles há evidência de autocorrelação dos resíduos, todos apresentam resíduos compatíveis com a normalidade. E nos quatro primeiro em que a balança corrente (% PIB) é um componente do modelo, nesses caso a balança corrente é identificada como uma causadora do

PIB, porém o inverso não acontece, na realidade, nos quatro primeiros modelos ela é a única variável que o modelo classifica como causa do crescimento do PIB.

A fim de curiosidade fizemos também o mesmo teste retirando a variável do balança corrente (% PIB), nesse caso obtivemos modelos mais variados, com variáveis como investimento direto estrangeiro (% PIB), taxa de desemprego, inflacao_diff e índice de liberdade financeira. Porém naturalmente esses modelos tem um RMSE e um MAE ligeiramente maiores do que os modelos que contaram com a balança corrente (% PIB) como um dos seus preditores, nesses modelos sem esta variável, o investimento direto estrangeiro (% PIB) se apresenta como um causador do PIB pela causalidade de Granger.

A partir desses resultados notamos como o mercado externo parece ser um fator de influência no PIB brasileiro. Mas para além disso os 5 modelos que obtiveram melhores resultados ainda contaram perspectivas sobre o comportamento macroeconômico brasileiro. Primeiro é que a balança corrente (% PIB) parece ter influência sobre índice de liberdade financeira e a inflação brasileira, isso é apontado pelo 3 melhor modelo, além disso nos últimos modelos apresenta que o crescimento do PIB tem uma forte relação de causalidade com a taxa de desemprego, o que é natural para um economista, mas é uma comprovação econométrica como o crescimento do PIB é um fator determinante na geração de empregos[11].

Além disso, um último fator curioso observado nesses modelos é que o investimento direto estrangeiro (% PIB) parece ser relacionado com a taxa de desemprego, talvez implicando no papel de empresas multinacionais e no investimento estrangeiro direto na geração de emprego para brasileiros. A interpretação econômica desse VAR é uma visualização do recorte histórico brasileiro dos anos 2000 e a integração do brasil nas Cadeias Globais de Valor com um país primário exportador.

Porém, nosso interesse e objetivo do trabalho é a predição econômica do PIB, então para isso vamos utilizar o melhor modelo classificado nesses dados o VAR(1) com apenas a balança corrente (% PIB) e crescimento do PIB. Nesse caso já atestado pelo quadro **??**, a balança corrente (% PIB) parece anteceder aumentos no crescimento econômico, porém o inverso não acontece.

A extrapolação do PIB descrita por esse VAR é dada por:

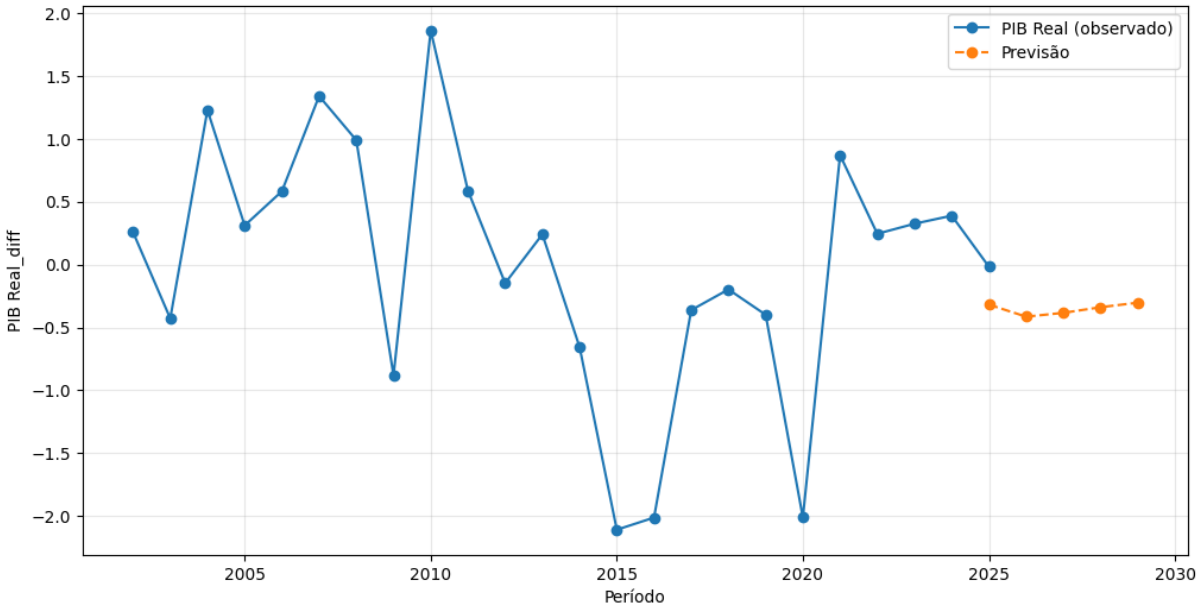
MODELO A crescimento_pib balança corrente (% PIB) ano 2025 -0.318797 -0.543713 2026 -0.414541 -0.466749 2027 -0.383972 -0.399770 2028 -0.339302 -0.350863 2029

[11] Conforme vimos em nossa metodologia, a série do desemprego não é confiável, porém trataremos mais profundamente na sessão do MIDAS onde essa variável será mais importante

-0.303139 -0.316992

Porém vale notar que essa previsão está escalada, conforme fizemos no inicio do procedimento de tratamento com os dados do VAR, o mesmo comportamento pode ser observado pela figura 12.

Figura 12 – Predição do crescimento do PIB escalado utilizando o VAR(1) — Crescimento do PIB + balança corrente (% PIB)




Fonte: Elaborado pelo autor (2026).

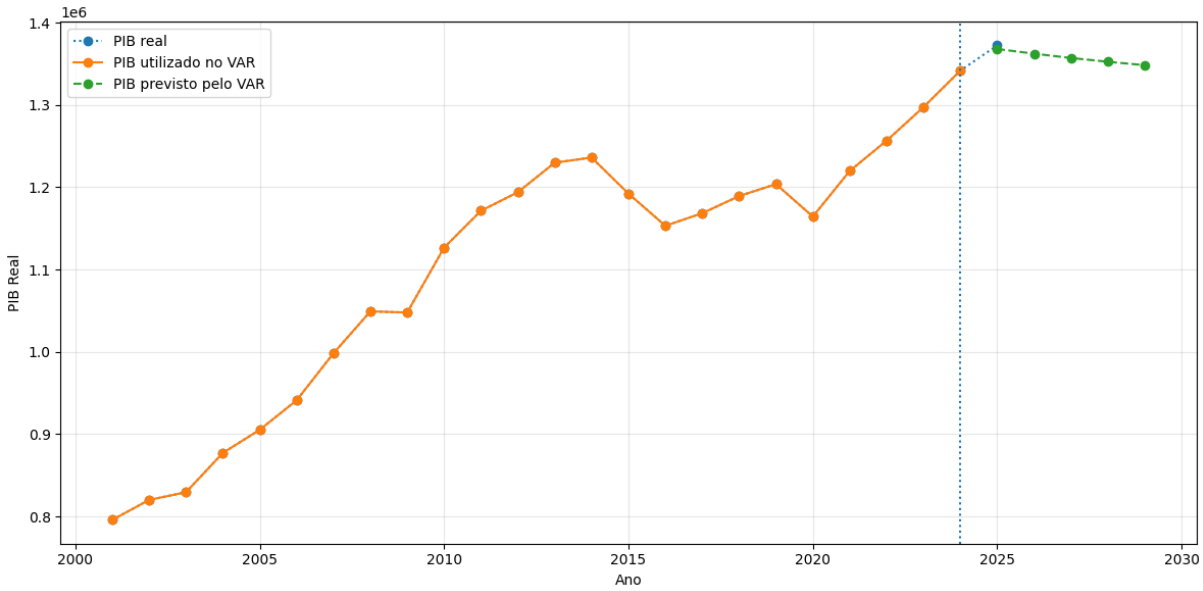
Em sentido interpretativo esse gráfico permite mostrar como o VAR consegue estimar o valor do crescimento real do PIB com um certo grau de precisão. Porém a visualização mais interessante de se analisar o valor estimado do PIB, é predição em volume, que apesar de não ter uma interpretação econômica tão presente, é mais entendível o poder de predição do VAR, conforme a figura 13

Note a proximidade do valor em volume para o ano de 2025 que não foi utilizado durante o treinamento do VAR, e valor previsto.

Poderíamos analisar cada um dos modelos apresentados, e utiliza-los para a predição do PIB, juntamente com cada interpretação de causalidade entre variáveis, porém para não estender nosso trabalho e fugir do escopo proposto, apresentaremos uma última funcionalidade de um modelo VAR que é simular choques em variáveis, e estimar o comportamento das variáveis componentes do modelo. Nesse caso vamos estimar o que um choque na variável balança corrente (% PIB) faria com o PIB no anos seguintes.

A interpretação desse gráfico nos informa o que aconteceria com a economia bra-

Figura 13 – VAR(1) — PIB + balança corrente (% PIB) — Previsão de 5 anos




Fonte: Elaborado pelo autor (2026).

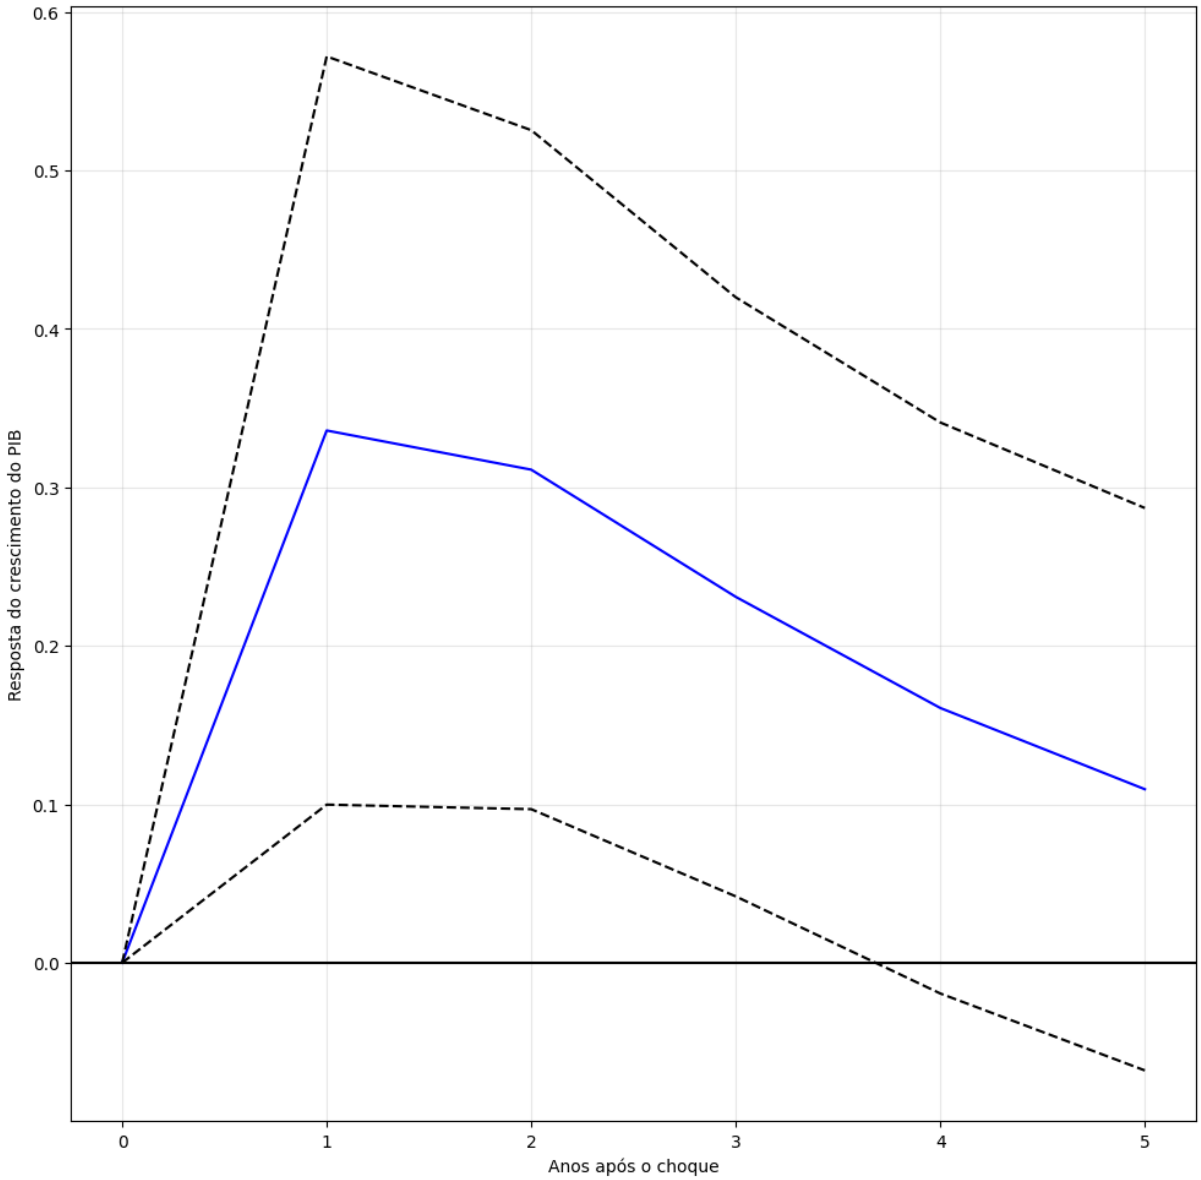
sileira se houvesse um choque de um desvio-padrão nas exportações brasileiras presentes na conta de transações correntes, nesse caso estamos falando de um choque positivo, por exemplo a abertura comercial da China, que se tornou um grande importador de produtos primários brasileiros. Essa possibilidade do VAR abre uma ampla gama de oportunidades e interpretações, desde por exemplo simular o mesmo choque negativo até testar diferentes variáveis e como elas influenciam a variável alvo, seja ela o PIB, ou qualquer outro componente do modelo.

Apesar desses testes terem uma interpretação econômica relevante, optaremos por apresentar esse único choque para demonstrar a possibilidade, afinal nosso objetivo é a predição do PIB, mas deixamos como uma possibilidade de aprofundamento da pesquisa.

Com esse resultados notamos como o VAR tem uma gama de possibilidades muito superior ao ARIMA, a possibilidade de inserir outras variáveis não apenas melhora a predição, na realidade ela da um sentido macroeconômico a econometria aplicada, enquanto o ARIMA consegue explicar o comportamento único da variável, o VAR consegue capitar as relações entre as variáveis, isso permite captar relações mais intrínsecas do comportamento da economia, não se restringindo a falar do comportamento de uma única variável, mas sim da sua relação concomitante.

Porém o VAR ainda tem um problema, a periodicidade, todas as variáveis utilizadas no modelo tem uma frequência anual, isso significa que temos uma observação a cada ano, isso limita nossa aplicação por dois lados, primeiro que só podemos realizar uma nova predição no

Figura 14 – Resposta do crescimento do PIB a um choque ortogonalizado na balança de transações correntes




Fonte: Elaborado pelo autor (2026).

próximo ano onde os dados serão divulgados, segundo que perdemos a oportunidade de utilizar variáveis de frequência maior para a predição.

Para resolver esse problema, ou pelo mínimo tentar vamos nos debruçar sobre o MIDAS, um modelo com a capacidade de incorporar variáveis de frequências diversas em um único modelo.

## 4.3 MIDAS

Para inciarmos a montagem do modelo MIDAS precisamos selecionar as variáveis, e dessa vez não podemos simplesmente pegar as mesmas variáveis do VAR, não por uma limitação do modelo, ou algo relacionado a testes (pelo mínimo ainda não), na realidade estamos falando da eficiência estrutural do modelo. O MIDAS foi pensado para estimar variáveis com frequências diferentes, mas não faz sentido utilizar uma variável de coletada a cada ano para prever um dado divulgado diariamente. Portanto temos a primeira noção do MIDAS, utilizaremos variáveis de alta frequência, para estimar uma variável de baixa frequência, como no nosso caso o PIB anual.

Outra noção é a questão que como nossa variável alvo tem frequência anula, não faz sentido usar variáveis com a mesma frequência do PIB, pensemos na predição, temos que esperar a da balança corrente em porcentagem do PIB ser divulgada para só depois realizarmos a predição do PIB. É uma noção contraproducente. A partir dessa duas noções e baseado na disponibilidade dos dados podemos selecionar as variáveis que utilizaremos.

Dentre o nosso conjunto de coleta exposto na metodologia apenas 3 variáveis tem uma frequência de divulgação maior do que a do PIB, são elas: a taxa de desocupação que é trimestral; a dívida publica (% PIB) mensal; e o IPCA que também é mensal. Apesar de não intencional essas variáveis possuem um sentido econômico bastante presente, para fortalecer o modelo, afinal estamos falando de uma variável macroeconômica o PIB, tentando ser predita por uma variável monetária IPCA que mede inflação, uma variável real, o desemprego, e uma variável do governo a porcentagem da divida pública, vamos ver como essas variáveis se relacionam a partir do modelo MIDAS.

Entretanto, como exposto em nossa metodologia, uma dessas variáveis tem um problema grave em sua série, estamos falando da taxa de desemprego trimestral do IBGE, infelizmente o IBGE descontinuou a pesquisa mensal de emprego em 2016, que foi substituída pela PNAD continua (Pesquisa Nacional por Amostra de Domicílios Contínua). Não entraremos em detalhes sobre as questões relacionadas a pesquisa e as metodologias de coleta e continuidade de pesquisa pelas entidades de coleta, mas infelizmente isso causa uma quebra em nossa série no ano de 2012, afinal optamos por utilizar os dados da PNAD continua em seu primeiro ano de coleta, mesmo que pesquisa mensal de emprego continuasse até 2016, como pode ser observado na figura 15

Essa quebra em nossa série se dá, pois até 2012 o dado se tratava da taxa de desocupação na semana de referência, das pessoas de 10 anos ou mais de idade, principais

Figura 15 – Série histórica da taxa de desocupação trimestral com quebra no ano de 2012




Fonte: Dados do IBGE (2026) elaborado pelo autor (2026).

responsáveis pela família. E quando adotamos a PNAD continua o dado passou a ser Taxa de desocupação, na semana de referência, das pessoas de 14 anos ou mais de idade. A alteração se dá tanto pela faixa etária, como pela população englobada, antes eram somente os responsáveis da família, agora todas as pessoas com 14 anos ou mais.

Uma solução seria truncar a série e utilizar somente 2012 para frente, porém isso reduziria os graus de liberdade do modelo, podendo ocasionar resultados com menos poder de explicação estatístico. Outra solução seria modelar com apenas o IPCA e a dívida pública. Porém decidimos, para colocar o modelo a prova, utilizar a série como está, e validar se mesmo com um erro de continuidade o modelo ainda consegue predizer o PIB.

A fim de curiosidade podemos ver as demais séries: a do PIB[12] na figura 16; a do IPCA na figura 17; e da dívida pública (% PIB) na figura 18.

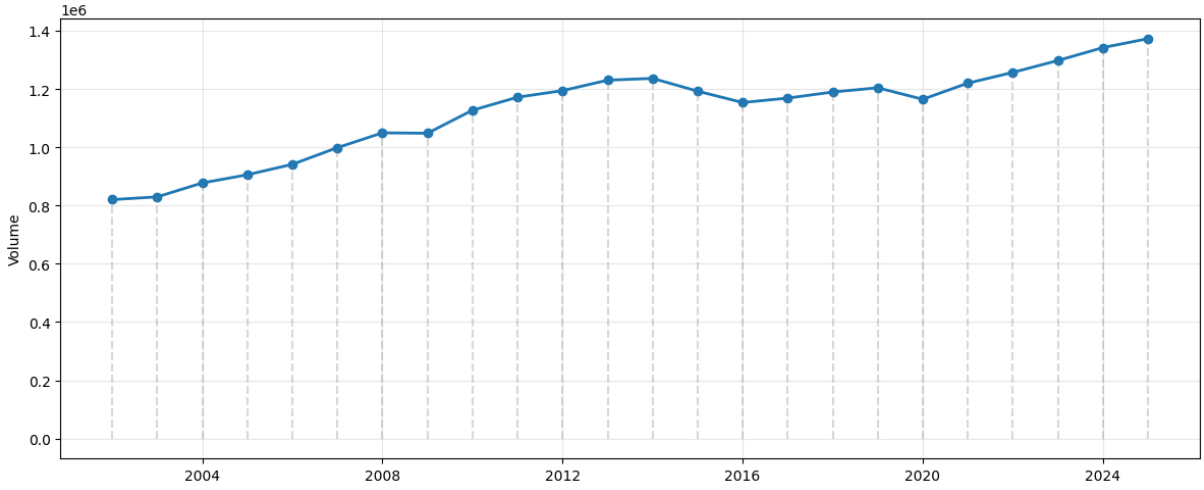
Somente a partir da visualização das séries já é possível apontar uma possível relação com o tempo, isso pode indicar que as séries não são estacionárias[13]

Nos testes ADF nenhuma das séries originais são estacionárias, dessa forma optamos por transformá-las, no caso do desemprego e da dívida aplicamos a primeira diferença, chamando as variáveis de delta da dívida e delta do desemprego, para o caso do IPCA e do PIB, optamos

[12] Notemos como ao utilizar o gráfico do PIB com o eixo y iniciando de 0, o PIB brasileiro parece ser muito mais estável com uma tendência de crescimento mais definida do que por exemplo o mesmo gráfico do PIB na figura 7, isso nos leva a um ponto importante, não precisamos mentir alterando os dados basta usar uma escala diferente e a percepção do leitor sobre uma mesma variável pode se alterar, deixaremos as duas formas como uma questão de reflexão, sobre como os gráficos são uma maneira excelente de se visualizar dados, porém podem causar vieses na percepção do leitor

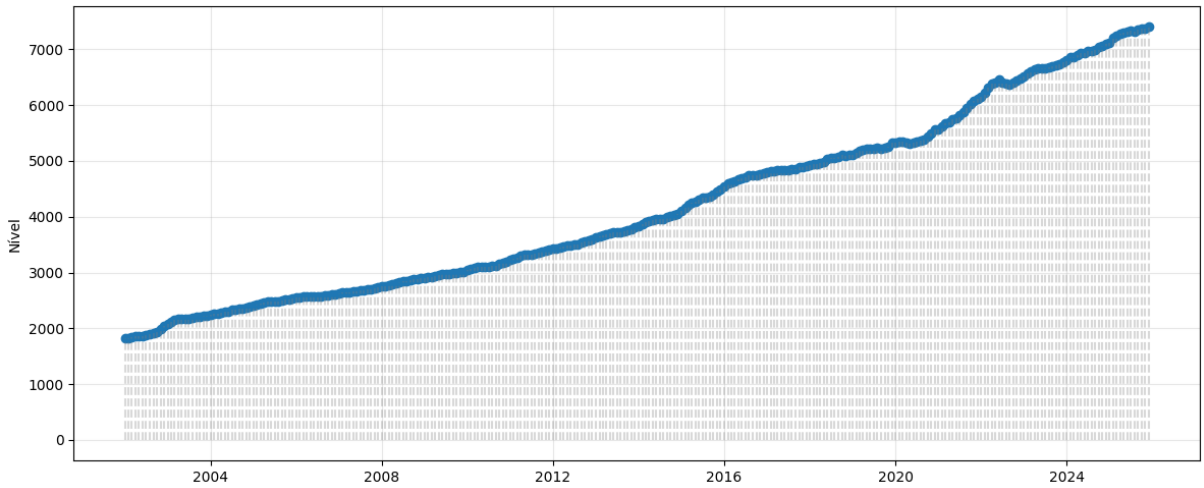
[13] já fizemos estes testes antes, para essas variáveis, inclusive sabemos que o PIB em volume não é estacionário, mas testaremos novamente, pois dessa vez, além de serem séries com frequência maior, vamos utilizar outros testes além do ADF e PP.

Figura 16 – Série histórica do PIB em volume anual




Fonte: Dados do IBGE (2026) elaborado pelo autor (2026).

Figura 17 – Série histórica do IPCA mensal



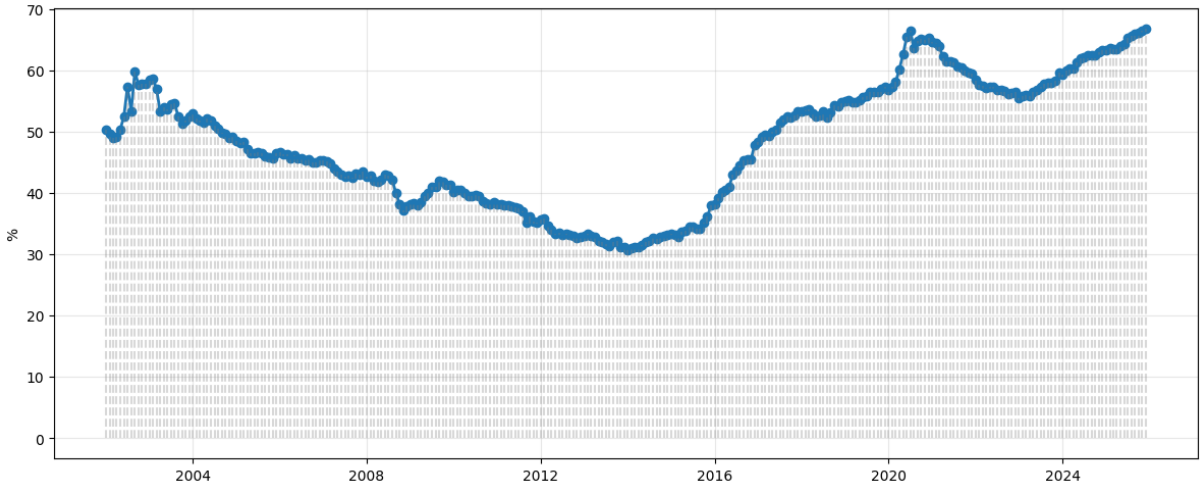

Fonte: Dados do IBGE (2026) elaborado pelo autor (2026).

por utilizar o crescimento do PIB e a inflação, dessa forma para o teste ADF todos as séries se comportaram como estacionárias.

Entretanto também aplicamos o teste KPSS, e nesse caso o delta da dívida apresenta evidências estatísticas de não estacionariedade ao nível de significância de 5%, enquanto as demais variáveis confirma a estacionariedade apresentada no teste ADF. Para concluir se precisamos de mais uma diferença, ou talvez descartar o delta da dívida, aplicamos o teste PP, e nesse caso obtivemos um resultado a favor da estacionariedade, como PP e ADF apontaram para uma série estacionária a um nível de 5% de significância e KPSS apresenta também considera o delta da dívida como estacionária a 2,5% de significância, optamos por manter a série dessa forma.

O próximo passo é determinar os lags do modelo, para isso utilizaremos os testes

Figura 18 – Série histórica da dívida pública (% PIB) mensal




Fonte: Dados do BACEN (2026) elaborado pelo autor (2026).

FAC e FACP, conforme as figuras a seguir:

Os resultados dos testes FAC e FACP não foram conclusivos, vamos testar todos os modelos com diferentes lags. Para isso dividimos nossos dados em treinamento e validação, de 2002 até 2022, será nosso treinamento, enquanto de 2023 até 2025 nossa validação. Dentro dos nossos dados de treinamento obtivemos um resultado curioso a soma dos quadrados dos erros para 6 meses foi menor do que para 12:SSE dentro da amostra por horizonte: h= 0 meses -> SSE treino = 6.8085 h= 6 meses -> SSE treino = 3.7662 h=12 meses -> SSE treino = 3.8716

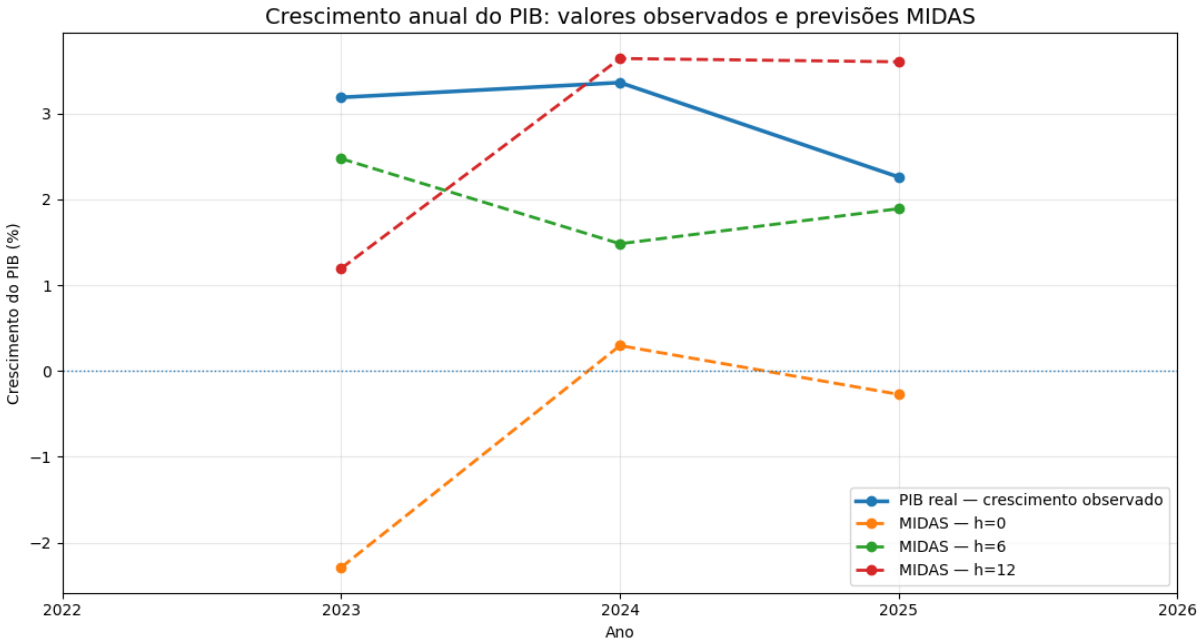
Enquanto na validação o RSME e o MAE também foram menores para 6 meses:

rmse horizonte mae horizonte horizonte meses 0 3.907629 3.691726 6 1.179675 0.987185 12 1.397829 1.206148

Notemos as previsões para 6 meses nos anos de validacão: horizonte meses ano y obs y prev rmse horizonte mae horizonte 0 0 2023 3.189305 -2.287651 3.907629 3.691726 3 6 2023 3.189305 2.475212 1.179675 0.987185 6 12 2023 3.189305 1.194448 1.397829 1.206148 1 0 2024 3.361998 0.296787 3.907629 3.691726 4 6 2024 3.361998 1.483472 1.179675 0.987185 7 12 2024 3.361998 3.642610 1.397829 1.206148 2 0 2025 2.261166 -0.271844 3.907629 3.691726 5 6 2025 2.261166 1.892231 1.179675 0.987185 8 12 2025 2.261166 3.604142 1.397829 1.206148

Notemos como essa figura 19 parece nos contar como as previsões com diferentes horizontes parecem ter uma previsão que capita comportamos distintos, enquanto para um horizonte de 0 meses, ou *nowcasting*, o modelo erra o valor, mas de certa forma acerta o comportamento de crescimento e queda, porém os resultados interessantes estão em 6 e 12 de

Figura 19 – Previsão do crescimento do PIB para o modelo MIDAS




Fonte: Elaborado pelo autor (2026).

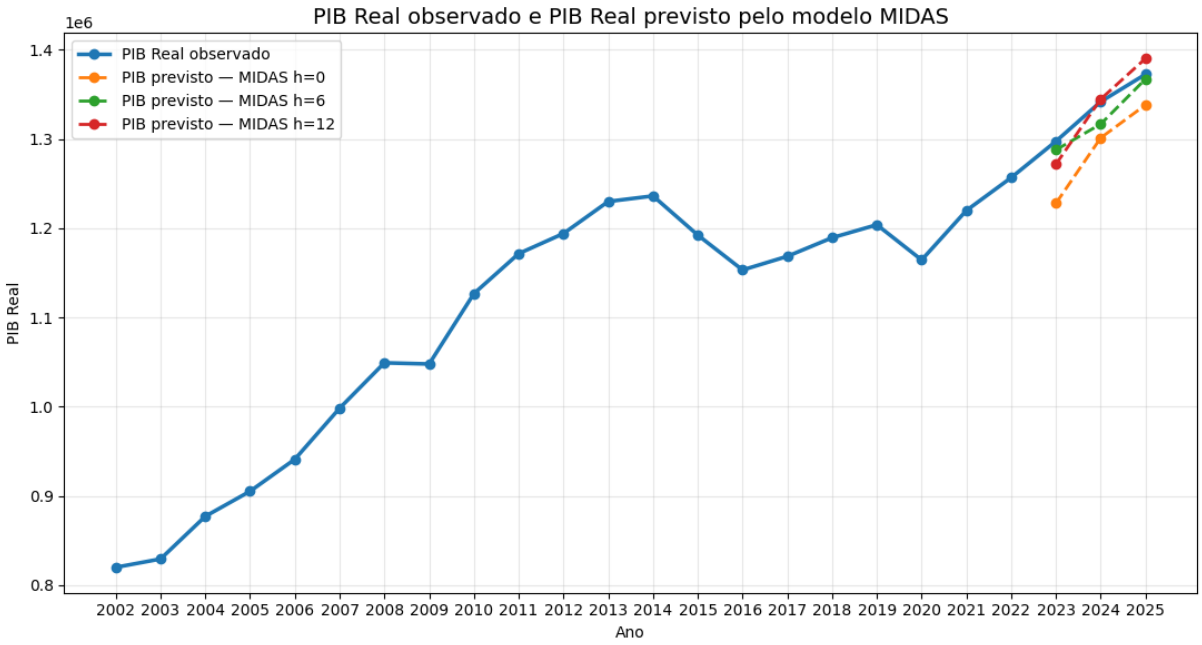
horizonte, enquanto o horizonte de 6 meses tem um erro menor de previsão, ele acaba errando o comportamento da variável, enquanto em um horizonte de 12 meses, acerta o comportamento o PIB porém tem um erro maior.

Essa previsão através do MIDAS tem uma caraterística, precisamos das variáveis que compõem o modelo para podermos estimar o PIB, de certa forma isso é muito útil para estimativas onde parte das informações já são dadas, mas é visível, que para nosso conjunto de dados, tendo em vista a quebra da série do desemprego, o *nowcasting* que é um dos pontos fortes do MIDAS parece não ter desempenhado tão bem, quanto em outros horizontes de tempo, porém fica evidente como o MIDAS consegue lidar bem, além de variáveis com frequência diferentes, e com uma quebra de metodologia em uma série o modelo ainda foi robusto na predição.

Na figura 20 podemos notar como os horizontes de de 6 e 12 meses parecem acertar mais o comportamento do PIB, enquanto o de 0 meses até acerta o comportamento, mas não o valor.

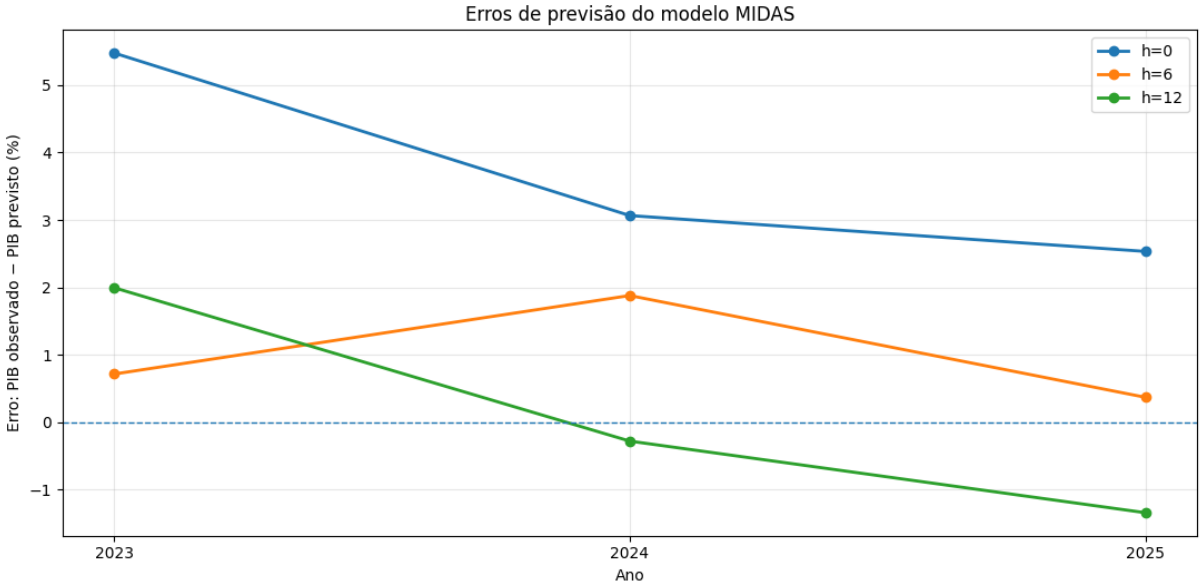
Além da previsão podemos olhar também o erro do modelo 21 que confirma a interpretação inicial, onde o erro de h=6 é menor, e o erro de h=0 é maior. Além de ambos subestimarem o crescimento do PIB. Enquanto h = 12 parece ser uma modelo mais otimista, que superestima o PIB em 2025, e praticamente acerta o valor em 2024, apesar de como os outros subestimar o crescimento em 2023.

Figura 20 – Previsão do PIB em volume para o modelo modelo MIDAS




Fonte: Elaborado pelo autor (2026).

Figura 21 – Erro de previsão do PIB para o modelo modelo MIDAS




Fonte: Elaborado pelo autor (2026).

A tendência de subestimar o crescimento talvez não seja um erro dos modelos, mas sim um comportamento das séries, que parecem sempre que há um crescimento, há uma estabilização ou queda.

## 4.4 DFM

Dentre os modelos que chamamos de tradicionais, o DFM é o último deles, mas é claro não menos importante. Na realidade dentre os modelos apresentados até então, o DFM é o modelo mais complexo, ele possui como ideia extrair de um grade conjunto de variáveis distintas um conjunto de fatores que podem explicar a tendência de um determinado grupo de variáveis. O DFM pode ser tanto aplicado para *nowcasting* como no midas ou *forecasting* como feito com o ARIMA e VAR, nesse caso de aplicação utilizaremos ele para *forecasting*.

A principal vantagem do DFM em comparação aos outros modelos é a capacidade de lidar com um conjunto de variáveis mais volumoso. Comparemos com outro modelo multivariado, enquanto no VAR precisamos limitar a quantidade de variáveis pela restrição dos graus de liberdade modelo. O DFM lida com isso criando índices compostos internos do modelo, que podem ser usados para fazer a predição da variável alvo.

Porém o DFM continua sendo um modelo tradicional, ou seja as regras continuam, devemos testar a estacionariedade das séries e selecionar somente aqueles que consideramos estacionárias. Entretanto já fizemos isso com o VAR, e diferentemente do MIDAS, utilizaremos as mesmas séries com a mesma frequência, nesse sentido podemos utilizar as mesmas variáveis já testadas: 'crescimento pib', 'inflacao', 'variacao desemprego', 'balança corrente (% PIB)', 'índice de despesa governamental', 'índice de liberdade financeira', 'índice de liberdade monetária', 'índice de direitos de propriedade', 'investimento direto estrangeiro (% PIB)', 'dívida pública (% PIB)'.

lembrando que a inflação e o índice de despesa governamental estão usando a primeira diferença, conforme os testes realizados anteriormente. Nesse momento estaríamos escolhendo os parâmetros do modelo, para ai tentarmos aplicar para essas variáveis, porém chegamos a primeira barreira quando começamos a apelar para modelos mais robustos, o tempo.

Nas primeiras execuções em testes realizados, utilizamos a mesma técnica utilizada pelo VAR para encontrarmos o melhor resultado, testar alguns os modelos possíveis, com distintas quantidades de variáveis e parâmetros. Porém, testar isso levou cerca de 2 horas, para rodar o modelo. Não que esse tempo seja um real limitador, pois bastaria uma máquina um pouco mais potente, um paralelismo maior, e o tempo se reduziria muito, mas para fazer pequenos ajustes e testar os melhores resultados nesse primeiro momento isso se torna uma barreira.

Porém o real motivo, acaba se tornando muito mais metodológico do que o tempo de execução estamos falando da interpretação econômica de um modelo. Suponhamos que por um

acaso estatístico, as variáveis de população, e índice de liberdade empresarial fossem disparado, para esse conjunto de dados os melhores preditores do crescimento do PIB, o DFM capturasse o fator latente, e o RSME e MAE fossem muito próximo de 0. Porém com mais 5 anos de dados existe uma grande variação no índice de liberdade empresarial e as previsões do modelo DFM simplesmente não correspondessem as expectativas.

Na realidade isso não é um problema só do DFM, isso é um problema estatístico. Primeiro um conjunto pequeno de dados, eles podem não ter observações o suficiente para descrever a realidade. E segundo acreditar que a relação entre variáveis são funcionais, em que uma alteração em uma, necessariamente irá causar um perturbação em outra que poder ser descrita por uma curva determinística.

Voltando ao DFM, faz pouco ou nenhum sentido testar todas as combinações possíveis, e mesmo que encontremos uma relação que tenha um erro pequeno, pode ser que aquelas variáveis não tenham um sentido econômico relevante para uma análise de uma perspectiva da realidade. Tomemos como um exemplo fictício absurdo, um determinado econometrista estava fazendo suas analises e observou que uma fábrica de pelúcias produzia determinada quantidade de ursos, o econometrista observou por um modelo que a relação entre quantidade de ursinhos e o PIB da cidade pareciam ter uma forte relação entre elas, a medida que a quantidade de ursos aumentava, o PIB também crescia. Um político observando a situação ficou maravilhado e determinou via decreto que se abrissem outras 10 fábricas de ursos prometendo que o PIB da cidade iria se multiplicar por um fator de 10. O que aconteceu é que todas as fábricas faliram pois ninguém mais queria comprar ursinhos e o PIB da cidade caiu.

O erro dessa história é primeiro acreditar que existe uma relação de causa e efeito entre variáveis, segundo é a lógica determinista aplicada, não se pode afirmar que uma variável é necessariamente causadora da outra, talvez as vendas de urso aumentassem pois os pais tinham maiores condições de presentear seus filhos, ou talvez seja somente uma coincidência. A única coisa possível de se afirmar é, que para aquele recorte de tempo, com aquelas observações, parece que a venda de ursos parece caminhar junto ao PIB municipal.

Essa história pode ser fantasiosa, porém quantas decisões empresarias e governamentais não são tomadas por gestores pensando em causa e efeito. Para isso o trabalho de um estatístico/econometrista é também determinar que variáveis utilizar, ou seja, será que se ao inés de utilizar a produção de ursos, o pesquisador utilizasse os salários dos funcionários das fábricas da cidade, será que o sentido econômico da análise não seria mais robusto e fundamentado?

Todo esse contexto se deve a justificativa de porque escolher determinadas variáveis para o modelo, assim realizamos da seguinte forma: 'PIB inflacao': ['crescimento pib', 'inflacao'], 'PIB inflacao desemprego': ['crescimento pib', 'inflacao', 'variacao desemprego'], 'PIB governo': ['crescimento pib', 'índice de despesa governamental', 'dívida pública (% PIB)'], 'PIB externo': ['crescimento pib', 'balança corrente (% PIB)', 'investimento direto estrangeiro (% PIB)'], 'PIB liberdade': ['crescimento pib', 'índice de liberdade monetária', 'índice de liberdade financeira', 'índice de direitos de propriedade'], 'PIB todas variaveis': 'crescimento pib', 'inflacao', 'variacao desemprego', 'balança corrente (% PIB)', 'índice de despesa governamental', 'índice de liberdade financeira', 'índice de liberdade monetária', 'índice de direitos de propriedade', 'investimento direto estrangeiro % PIB)', 'dívida pública (% PIB)',

Optamos dessa forma para segregar as variáveis em determinados campos de estudo da economia, primeiro com um modelo relativamente simples com o PIB e a inflação, depois o PIB a inflação e o desemprego[14]. Um modelo tratando sobre o governo, com a dívida pública e a despesa governamental. Um modelo sobre mercado externo, um modelo de indicadores de liberdade. Por último um modelo tratando de todas as variáveis.

Como range de treino utilizamos o inicio da série em 2001, até 2022, como validação utilizamos de 2014 até 2022, e para avaliação de 2023 até 2025. Como número máximo de iterações utilizados 300, com até 3 fatores, e até de segunda ordem, pensando em simplificar o modelo ao máximo para não correr o risco de sobreajuste.

Os fatores são as variáveis "virtuais"que o modelo cria, são como um indicador que representa um determinado conjunto de variáveis com uma tendência. Já as ordens no contexto do DFM são as defasagens dos fatores, seriam o equivalente as LAGs de um modelo VAR.

E no geral modelos com mais de 2 fatores para essa quantidade de observações foram inadequados, quase que em sua maioria não convergiram para um resultado. Esse resultado é esperado, mas como o DFM já realiza esse procedimento de unir o comportamento das variáveis, isso não será um problema.

[14] Lembrando que o desemprego é uma variáveis suspeita como já descrido na metodologia e no modelo MIDAS

| | config_id | grupo | variaveis |
|---|---|---|---|
| 19 | 20 | PIB_externo | (’crescimento_pib’, ’balança corrente (% PIB)’, |
| 18 | 19 | PIB_externo | (’crescimento_pib’, ’balança corrente (% PIB)’, |
| 1 | 2 | PIB_inflacao | (’crescimento_pib’, ’inflacao’) |
| 0 | 1 | PIB_inflacao | (’crescimento_pib’, ’inflacao’) |
| 12 | 13 | PIB_governo | (’crescimento_pib’, ’índice de despesa governar |
| 6 | 7 | PIB_inflacao_desemprego | (’crescimento_pib’, ’inflacao’, ’variacao_desem |
| 13 | 14 | PIB_governo | (’crescimento_pib’, ’índice de despesa governar |
| 7 | 8 | PIB_inflacao_desemprego | (’crescimento_pib’, ’inflacao’, ’variacao_desem |

Notemos que o modelo com o menor RSME é o PIB_externo, tendo como componentes o crescimento_pib, balança corrente (% PIB)’, investimento direto estrangeiro (% PIB), com um fator de ordem 2. Esse modelos obteve um RSME de 3.722192 no treinamento, o que é razoável para um modelo nesse sentido.

Nos anos de validação obtivemos os seguintes resultados na tabela a seguir:

| | ano | crescimento_previsto | limite_inferior | limite_superior | crescimento_real | |
|---|---|---|---|---|---|---|
| 0 | 2023 | 2.185479 | -3.557493 | 7.928452 | 3.240708 | 1.05 |
| 1 | 2024 | 2.209100 | -3.568040 | 7.986241 | 3.419152 | 1.21 |
| 2 | 2025 | 2.223303 | -3.569880 | 8.016487 | 2.286924 | 0.06 |

Em todos os anos o DFM subestimou o crescimento do PIB. Para testarmos a autocorrelação dos resíduos desse modelo utilizamos Ljung–Box. Conforme aponta a tabela.

| | lb_stat | lb_pvalue |
|---|---|---|
| 1 | 1.205734 | 0.272179 |
| 2 | 1.466123 | 0.480436 |

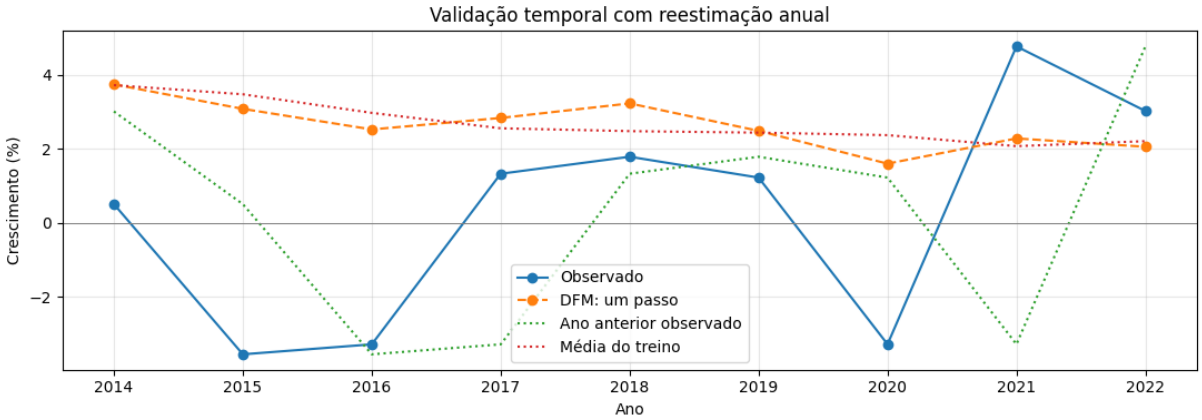
A partir desses testes a um nível de significância de 5% não foi detectada dependência linear temporal significativa nos erros até a segunda defasagem. Vejamos esse modelo em forma gráfica. Primeiramente notamos um comportamento relativamente estável do modelo ao tentar estimar as variações do PIB, podemos notar tanto na figura 22 quanto na 25 se comportou praticamente como uma média móvel.

Se olharmos diretamente para o resultado o modelo parece subestimar o crescimento do PIB, figura 23, assim como os erros do 2023 e 2024, foram maiores do que os de 2025, mas mesmo assim o DFM parece não conseguir capturar o comportamento do PIB, nem mesmo no

sentido de erro, como no próprio comportamento da série.

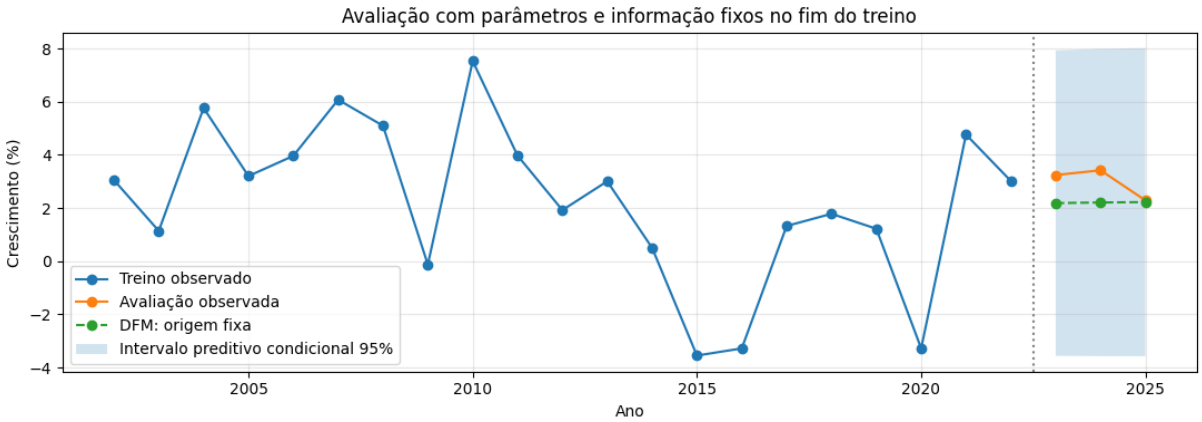
Nesse sentido testamos os demais modelos DFM que tiveram solução, e nenhum deles obteve um resultado evidentemente superior do que o modelo com menor RSME. Portanto fica evidente como o DFM parece não se ajustar bem para nossa coleção de variáveis.

Figura 22 – Validação temporal com reestimação anual




Fonte: Elaborado pelo autor (2026).

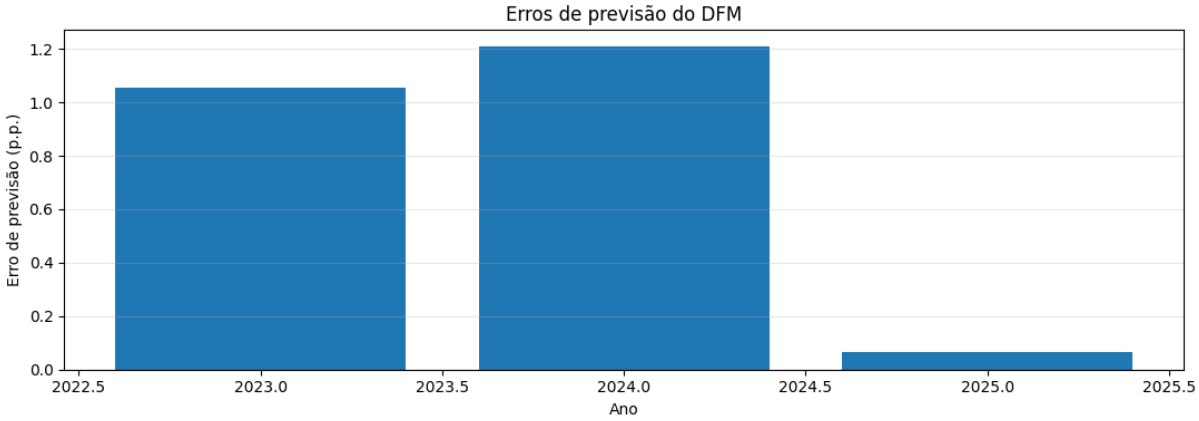
Figura 23 – Previsão crescimento do PIB fora do treino




Fonte: Elaborado pelo autor (2026).

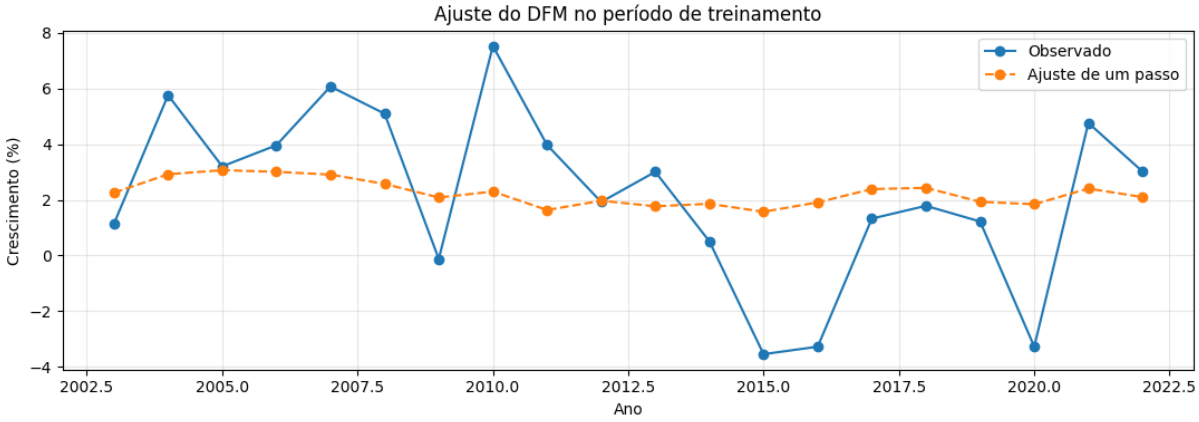
Por fim temos a figura 28 que mostra o a previsão do PIB em nível, que como ja esperado foi subestimada pelo modelo. A partir desses resultados podemos chegar a uma realidade dos testes, nem todos os modelos serão adequados. Esse modelo apresentado teve todos os testes de estacionariedade, as variáveis foram selecionadas por um sentido econômico, o modelo é robusto, e tem uma aplicação direcionada para casos onde existem muitas variáveis, mas mesmo com esses pontos a favor, para esse conjunto de dados, o modelo DFM, obteve um resultado razoável.

Figura 24 – Erro de previsão no período de validação




Fonte: Elaborado pelo autor (2026).

Figura 25 – Ajuste do modelo no treinamento

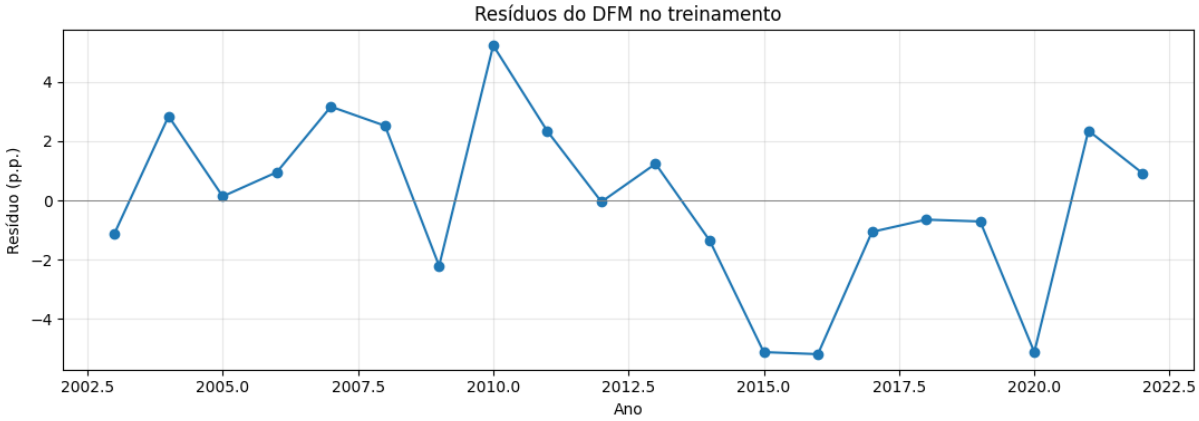



Fonte: Elaborado pelo autor (2026).

Porém, apesar de não ser excelente ainda podemos retirar um significado econômico do DFM, primeiro, o mesmo caso apresentado pelo VAR, o mercado externo parece ser um bom preditor do PIB, mas para além disso podemos interpretar a carga de cada variável no fator latente, como o modelo possui apenas um fator podemos visualizar na figura 27. Essa figura apresenta um comportamento curioso, enquanto a balança corrente e o PIB tem um relação + com o fator, o investimento estrangeiro direto tem uma relação negativa com o fator. Novamente isso não é um relação causal, que aumento no investimento estrangeiro direto irá causar uma queda no PIB ou na balança corrente.

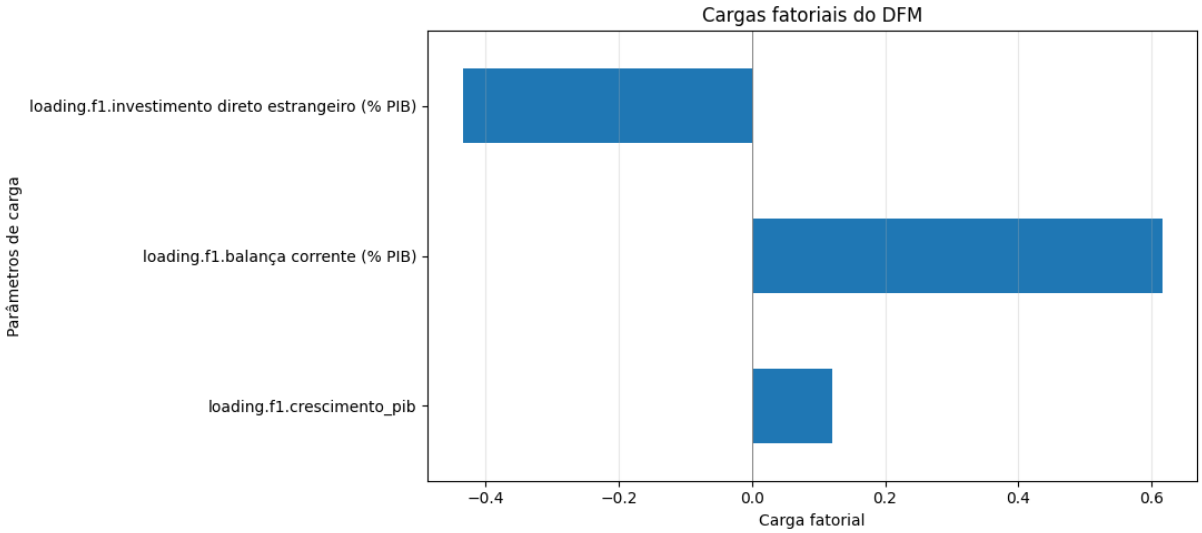
Porém podemos formular uma hipótese que a relação positiva da balança corrente, tem haver com o Brasil ser uma país cujo a economia tem um forte componente primário exportador, então naturalmente uma balança corrente positiva, significa um aumento em volume no PIB. E também poderíamos formular uma relação em que balanços positivos na conta corrente, podem influenciar na menor necessidade investimento estrangeiro direto.

Figura 26 – Erro do modelo no treinamento




Fonte: Elaborado pelo autor (2026).

Figura 27 – Cargas fatoriais do DFM



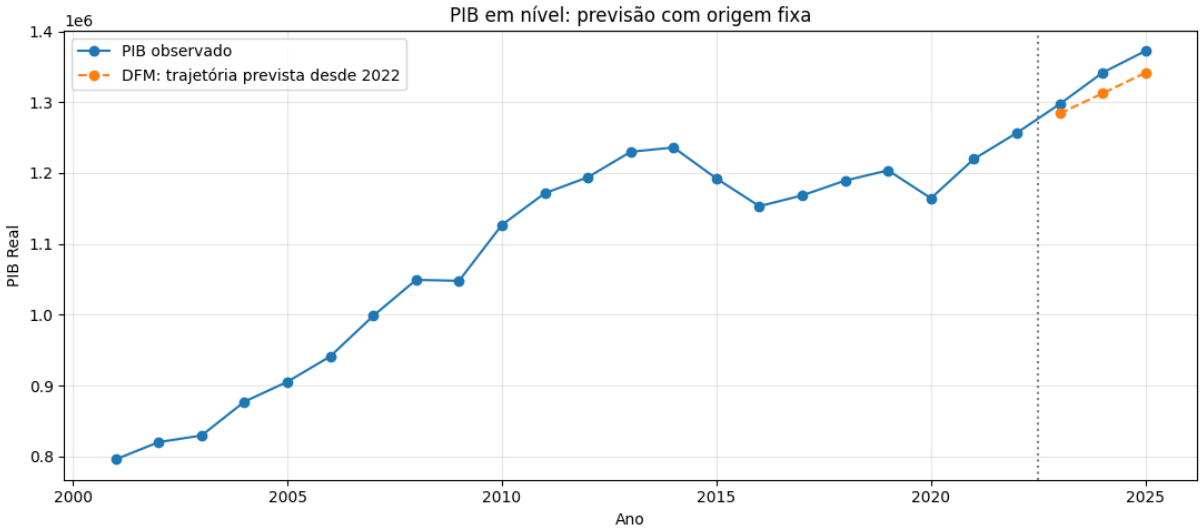

Fonte: Elaborado pelo autor (2026).

Contudo, lembramos, que não podemos afirmar essa relação, pela próprias limitações dos modelos, mas também pela limitação dos dados, ou seja, pouco mais de 20 observações ainda que possibilitem o modelo convergir, não significam necessariamente um confiança absoluta nos resultados do modelo.

## 4.5 Redes Neurais

Chegamos agora no primeiro modelo do que chamamos de modelos de IA, ou modelos modernos, o primeiro deles não poderia ser diferente, as redes neurais, esse tipo de estrutura possibilitou avanços em muitas áreas das ciências, e durante esse trabalho, pegaremos um tipo restrito de rede neural, e aplicaremos a um tipo restrito de problema, e vamos verificar

Figura 28 – Erro do modelo no treinamento




Fonte: Elaborado pelo autor (2026).

se esse tipo de modelo consegue ser tão bom, quanto modelos robustos e tradicionais como os até então estudados.

Antes de inciarmos com a discussão sobre como utilizaremos as redes neurais, vale a pena ressaltar que o método que aplicamos para esse modelo, talvez não tenha obtido os melhores resultados possíveis para esse tipo de modelagem, pois decidimos testar o limite da proposição do modelo. Enquanto ARIMA, possui simplicidade, o VAR a capacidade de modelar choques, o MIDAS de trabalhar com frequências mistas, e o DFM de modelar um conjunto massivo de variáveis, a rede neural tem uma característica que por uma lado pode ser muito boa, por outro pode ser limitante, estamos falando do poder de decisão do modelo.

Não decisão no sentido humano, de avaliar hipóteses e decidir por caminhos, mas sim uma decisão no sentido matemático, quem avalia quais variáveis utilizar é a própria rede. É durante o processo de treinamento que a rede decide qual peso atribuir para cada neurônio isso é a conhecida "aprendizagem"desse tipo de modelo. Isso é bom por uma lado, pois podemos simplesmente inserir todas as variáveis e esperar que a rede decida o que fazer com elas. Contudo isso também é limitante, primeiro pela questão da interpretabilidade[15], mas além disso, a falta de controle, não podemos forçar a rede a usar determinada variável, para estimarmos o comportamento daqueles alvos.

Outro limitante das redes neurais é o tempo, assim como o DFM, as redes neurais são modelos que exigem muito poder computacional, inclusive os primeiros testes giravam em

[15] Falaremos disso mais adiante

torno de cerca de 1 hora para rodar por completo. Dessa forma chegamos aquele mesmo impasse, testar todos modelos e decidir quais são os conjuntos de variáveis com os melhores resultados, ou podemos testar modelos com um certo sentido econômico, optamos novamente pela segunda opção.

Porém, durante a aplicação não simplesmente aplicamos as variáveis no modelo, fizemos transformações em 3 séries originais, utilizando as variações, já realizamos isso anteriormente, e seguimos com: crescimento_pib, crescimento_pop, inflacao. Assim optamos por remover da rede as variáveis originais (PIB, população e IPCA).

Os períodos utilizados pela rede são de 2001 a 2013 como treinamento inicial, de 2014 à 2022 como a validação expansiva, e por último 2023 à 2025 a avaliação do modelo. Testamos 6 modelos distintos, com determinada interpretação econômica. São eles:

'PIB': ['crescimento_pib'], 'PIB_inflacao': ['crescimento_pib', 'inflacao'], 'PIB_inflacao_desem ['crescimento_pib', 'inflacao', 'taxa de desemprego'], 'PIB_governo': ['crescimento_pib', 'índice de despesa governamental', 'dívida pública (% PIB)'], 'PIB_externo': ['crescimento_pib', 'balança corrente (% PIB)', 'investimento direto estrangeiro (% PIB)'], 'PIB_liberdade': ['crescimento_pib', 'índice de liberdade empresarial', 'índice de liberdade monetária', 'índice de liberdade comercial', 'índice de liberdade financeira', 'índice de direitos de propriedade'], 'PIB_todas_variaveis': 'taxa de desemprego', 'balança corrente (% PIB)', 'investimento direto estrangeiro (% PIB)', 'dívida pública (% PIB)', 'índice de direitos de propriedade', 'índice de integridade governamental', 'índice de despesa governamental', 'índice de carga fiscal', 'índice de liberdade empresarial', 'índice de liberdade monetária', 'índice de liberdade comercial', 'índice de liberdade de investimento', 'índice de liberdade financeira', 'crescimento_pib', 'crescimento_pop', 'inflacao'

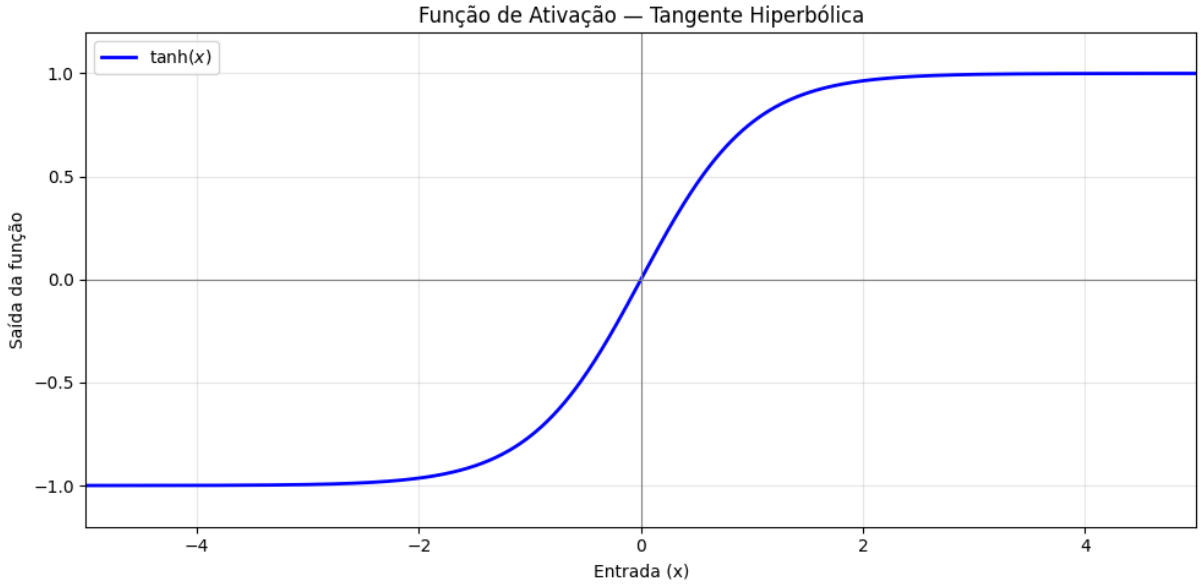
Separamos dessa forma, pois apesar de não existir controle sobre os pesos do modelo, podemos ainda assim escolher quais variáveis seriam modeladas. Os hiperparâmetros do nosso teste são:

Arquiteturas = [(1,), (2,), (3,), (3, 2), (5, 3, 2)]. Para arquiteturas utilizamos 5 configurações diferentes, cada uma dessa configurações refere-se a estrutura da rede, como visto na revisão de literatura, esse hiperparâmetros são a quantidade de neurônios e camadas ocultas na rede, o modelo (1,) possui apenas uma camada com apenas um neurônio na camada oculta, enquanto o modelo (5, 3, 2) possuí três camadas ocultas com cinco neurônios na primeira, 3 na segunda, e 2 na terceira. Um modelo simples tem menos chance de sobreajuste, porém pode não

conseguir captar todas as dinâmica da realidade, enquanto modelos maiores conseguem captar relações mais diversas, contudo com grande risco de sobreajuste.

Funções de ativação = ['tanh', 'relu']. tanh refere-se a função tangente hiperbólica ela pode ser visualizada na figura 29. E ReLU é a Unidade Linear Retificada que pode ser visualizada na figura 30. Ambas são funções de ativação dos neurônios, no contexto de aplicação da pedição econômica optamos por testar apenas essas duas, pois tanh permite representar respostas não lineares suaves, já a ReLU permite a rede representar mudanças de comportamento em determinados cortes.

Figura 29 – Função de ativação Tangente Hiperbólica

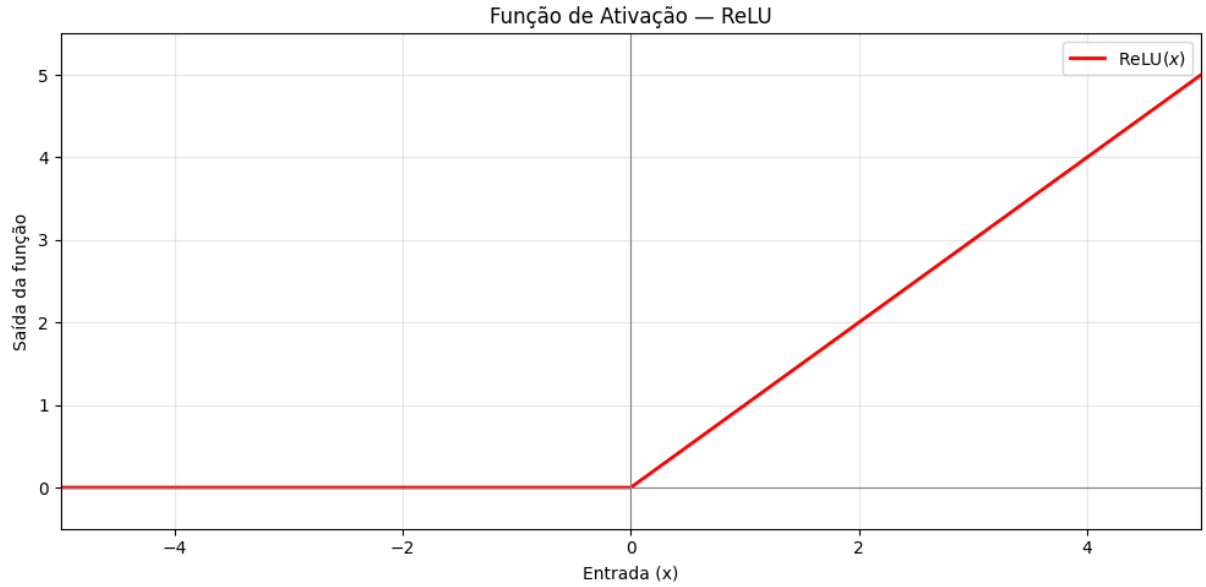



Fonte: Elaborado pelo autor (2026).

alphas = [0.1, 1.0, 10.0]. Os alphas por falta seriam os passos da rede, ou seja, o quão largo é o ajuste dos pesos, existem diferenças, um alpha pequeno é favorável ao sobreajuste a armadilha do mínimos locais, enquanto um alpha grande demais pode nunca convergir para um resultado.

random_states = [1, 42, 123]. Esses hiperparâmetros talvez sejam os mais subjetivos e tem um peso menor na qualidade do modelo, a ideia é que a rede precisa de uma valor inicial de pesos, para que no processo de treinamento eles possam ser ajustados conforme o algoritmo de *backpropagation*. De toda forma, se a rede teve passos o suficiente a tendência é que os resultados independente do estado inicial cheguem ao mínimo global, de toda forma utilizamos nesse trabalho a média dos erros desses três estados.

Figura 30 – Função de ativação ReLu




Fonte: Elaborado pelo autor (2026).

Com essas configurações[16] testamos cerca de 210 modelos, levando cerca de 4 minutos para rodar todos, número muito menor do que os primeiros testes com cerca de 1 hora de treinamento.

Dentre esses selecionamos os 5 melhores:

| | config_id | grupo_variaveis | n_variaveis | variaveis |
|---|---|---|---|---|
| 0 | 130 | PIB_externo | 3 | (’crescimento_pib’, ’balança corrente (% PIB |
| 1 | 136 | PIB_externo | 3 | (’crescimento_pib’, ’balança corrente (% PIB |
| 2 | 133 | PIB_externo | 3 | (’crescimento_pib’, ’balança corrente (% PIB |
| 3 | 121 | PIB_externo | 3 | (’crescimento_pib’, ’balança corrente (% PIB |
| 4 | 127 | PIB_externo | 3 | (’crescimento_pib’, ’balança corrente (% PIB |

Notemos que os melhores modelos em relação ao treinamento são todos modelos que utilizam as variáveis do grupo PIB_externo. Podemos também ver na tabela a seguir os melhores modelos por grupos de variáveis, notem como os erros são maiores, e as posições no ranking global de modelos, isso demonstra que a escolha de quais variáveis pode pesar mais do os hiperparâmetros sozinhos.

[16] Ainda existem outros hiperparâmetros da rede como o limite de iterações da otimização de 5000, o algoritmo de solução que é o L-BFGS (Limited-memory Broyden–Fletcher–Goldfarb–Shanno) e o limite de avaliações da função objetivo pelo L-BFGS que foi de 15000, que são hiperparâmetros, optamos por não tratar diretamente deles, pois são questões mais relacionadas aos algoritmos internos que a rede utiliza para encontrar o resultado, para o aprofundamento nesse parâmetros recomendamos a leitura da documentação da biblioteca do Python scikit-learn (Pedregosa *et al.*, 2011), mais especificamente do módulo MLPRegressor que foi o utilizado durante esse trabalho

| | variaveis |
|---|---|
| 1 | (’crescimento_pib’, ’balança corrente (% PIB)’, ’investimento direto estrangeiro (% PIB)’ |
| 4 | (’crescimento_pib’, ’índice de despesa governamental’, ’dívida pública (% PIB)’) |
| 5 | (’crescimento_pib’, ’índice de liberdade empresarial’, ’índice de liberdade monetária’, ’ín |
| 3 | (’crescimento_pib’, ’inflacao’, ’taxa de desemprego’) |
| 6 | (’taxa de desemprego’, ’balança corrente (% PIB)’, ’investimento direto estrangeiro (% PI |
| 2 | (’crescimento_pib’, ’inflacao’) |
| 0 | (’crescimento_pib’,) |

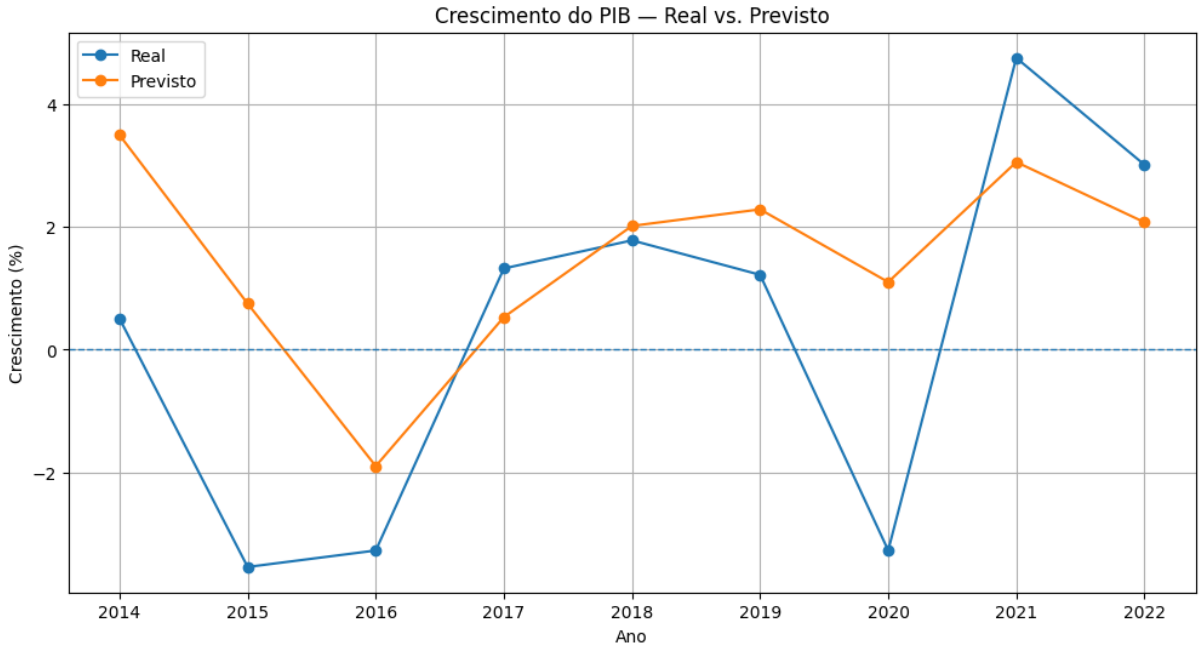
Porém vale ressaltar que se ajustar bem ao treino não significa necessariamente que o modelo é bom, para isso precisamos de validar fora da amostra. Vamos escolher o melhor dos modelos testados:

| | Configuração do modelo escolhido |
|---|---|
| config_id | 130 |
| grupo_variaveis | PIB_externo |
| n_variaveis | 3 |
| variaveis | (’crescimento_pib’, ’balança corrente (% PIB)’, ’investimento dire |
| arquitetura | (2,) |
| activation | relu |
| alpha | 0.100000 |
| sementes | (1, 42, 123) |
| RMSE | 2.452199 |
| MAE | 1.976336 |
| RMSE_treino_medio | 1.134121 |
| MAE_treino_medio | 0.882071 |
| desvio_sementes_medio | 0.987059 |
| convergiu | True |

Como podemos ver na figura 31 O ajuste parece formidável, não parece ter evidências de sobreajuste, na figura 32 podemos ver os erros durante a validação.

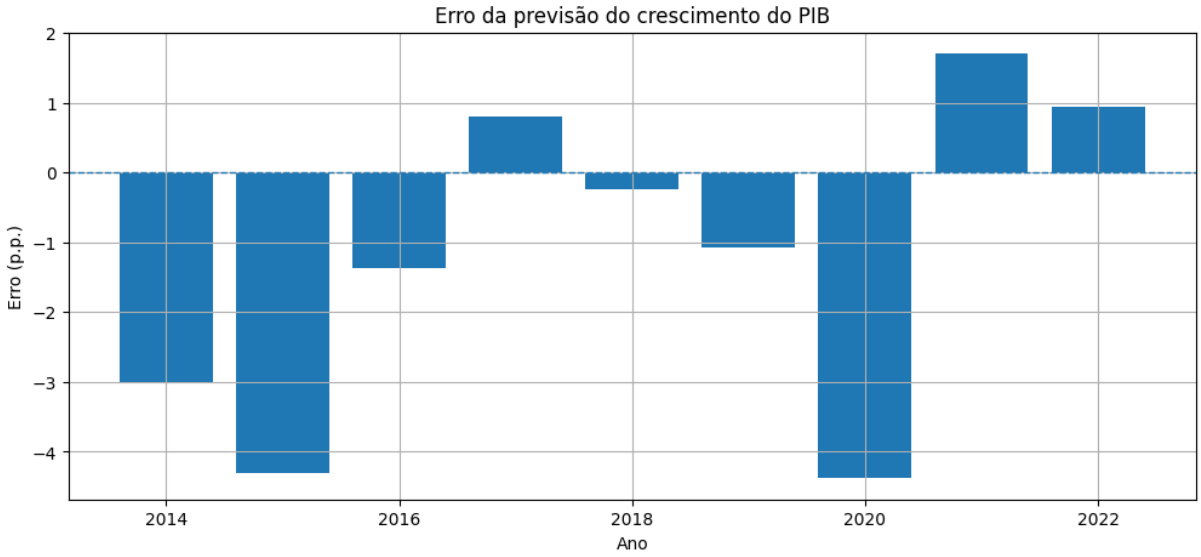
Na tabela a seguir vemos a previsão fora da amostra para os anos de 2023, 2024 e 2025. Podemos notar como obtivemos um erro relativamente pequeno.

Figura 31 – Ajuste do modelo durante a validação




Fonte: Elaborado pelo autor (2026).

Figura 32 – Erros do modelo durante a validação

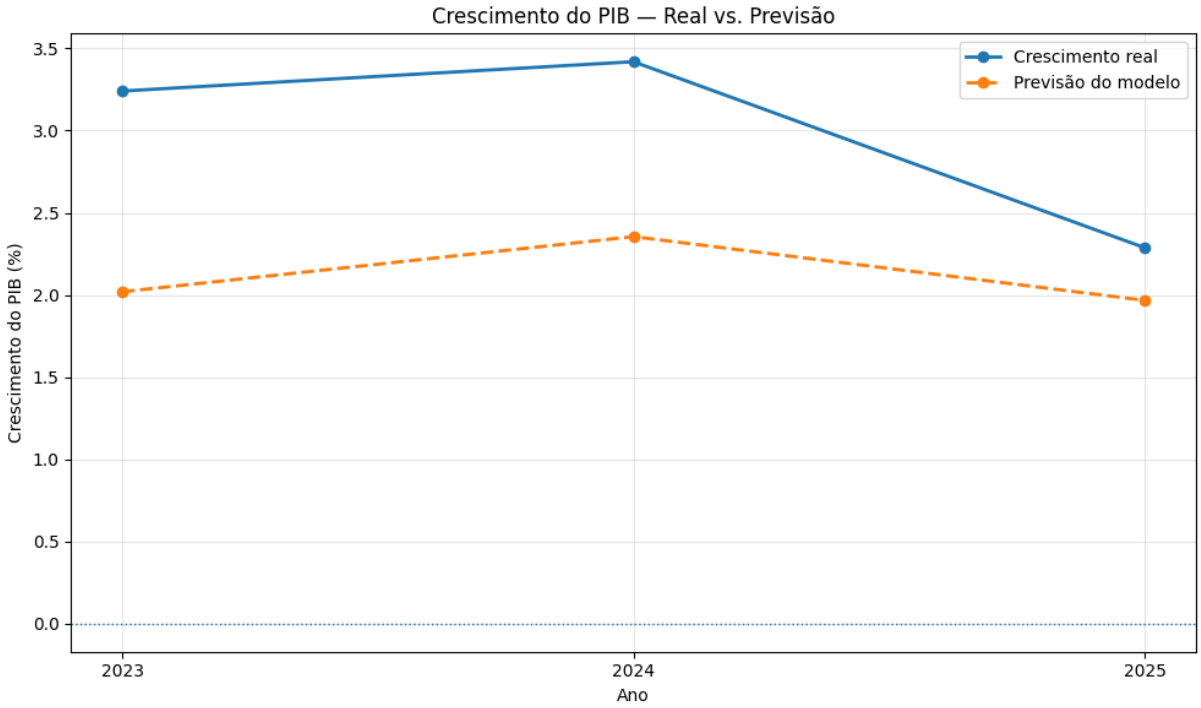



Fonte: Elaborado pelo autor (2026).

| | ano | crescimento_real | crescimento_previsto | desvio_sementes | erro | erro_ab |
|---|---|---|---|---|---|---|
| 0 | 2023 | 3.240708 | 2.019395 | 0.372088 | 1.221313 | 1.2 |
| 1 | 2024 | 3.419152 | 2.354770 | 0.950582 | 1.064382 | 1.0 |
| 2 | 2025 | 2.286924 | 1.966873 | 0.632193 | 0.320051 | 0.3 |

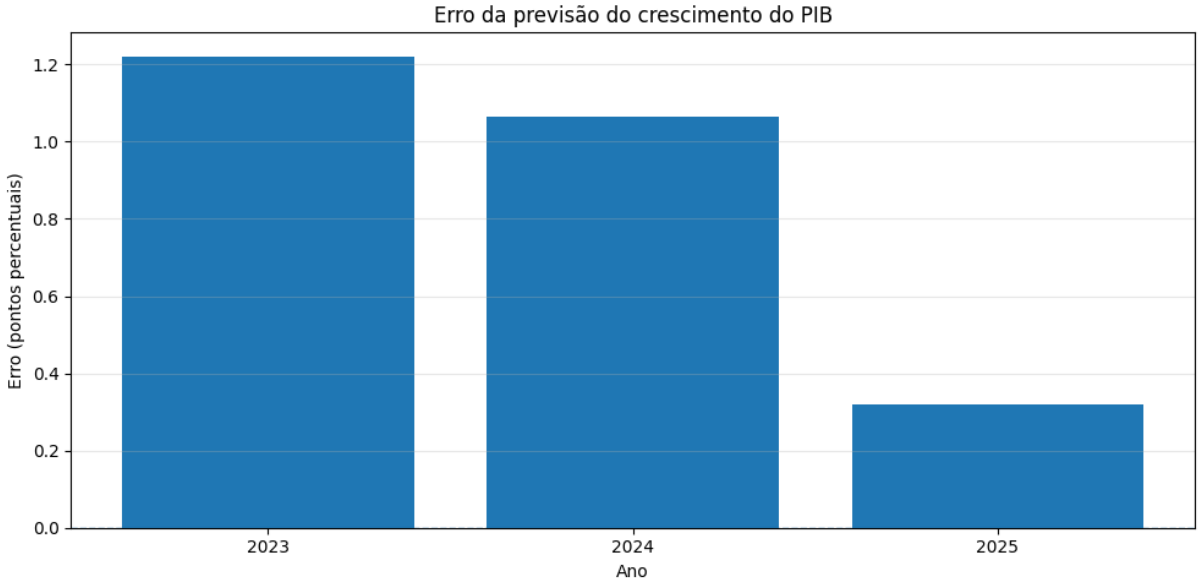
A partir dessa avaliação fica evidente algumas observações, e também a maior limitação das redes neurais. Primeiramente em um sentido econômico, podemos notar como

Figura 33 – Previsão do crescimento do PIB utilizando redes neurais




Fonte: Elaborado pelo autor (2026).

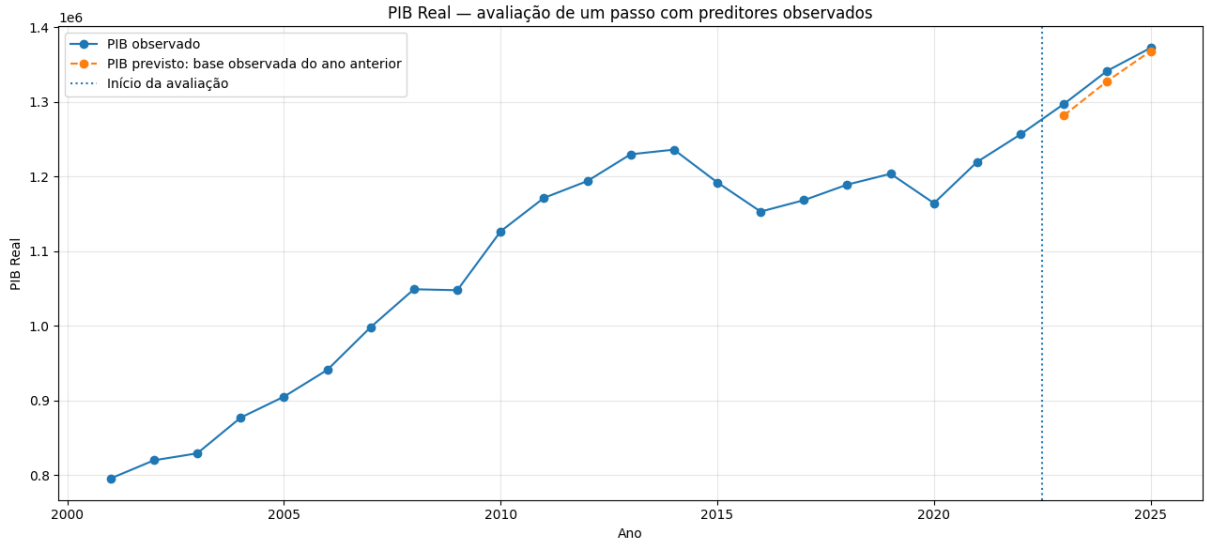
Figura 34 – Erro da previsão do crescimento do PIB utilizando redes neurais




Fonte: Elaborado pelo autor (2026).

o modelo que utiliza as variáveis externas tem um bom poder preditivo para a série do PIB brasileiro, isso é recorrente para os modelos testados anteriormente, para além disso, notamos que o modelo que utiliza somente uma única variável o PIB, um modelo autorregressivo univariado baseado em redes neurais, se mostra como a pior opção, em comparação aos outros, portanto é uma evidência para esses dados, que a rede conseguiu obter resultados melhores com mais de

Figura 35 – Previsão em nível do PIB utilizando redes neurais




Fonte: Elaborado pelo autor (2026).

uma variável, apontando que as variáveis, em determinado grau ajudam na melhora da previsão.

Outro ponto relevante é que para além de um erro de previsão pequeno, a rede consegue estimar o comportamento da variável, acertando quando a variável acelera ou desacelera o crescimento, apesar de errar no sentido numérico. Porém chegamos ao limite da interpretabilidade desse tipo de modelo, poderíamos ainda interpretar sobre os hiperparâmetros, e identificar que sobre arquiteturas de rede, funções de ativação e alphas, mas nesse sentido estaríamos partindo sobre a configuração do modelo, não sobre uma interpretação econômica.

Esse problema é conhecido, é a chamada caixa preta da IA, a falta de interpretabilidade direta de um modelo de rede neural é um dos limitantes dessa arquitetura, porém é inegável que esse tipo de modelo consegue capturar comportamentos nas variáveis macroeconômicas. Para além disso consegue acertar com um certo grau de precisão a extrapolar para fora do período de treinamento.

## 4.6 Random Forest

O último modelo de qual trataremos nesse trabalho, que também é um modelo que chamamos de IA, é o Random Forest, ou floresta aleatória em português, esse modelo também consegue modelar relações não lineares entre variáveis como as redes neurais, assim como consegue lidar com um volume massivo de variáveis. E esse modelo tem uma vantagem a mais, ele tem um sentido interpretativo, ou seja além da predição, esse modelo pode ter um sentido econômico extraído dos seus resultados.

O primeiro procedimento para ao Random forest, como nos outros modelos é transformar as variáveis IPCA, PIB e população em suas respectivas variações: crescimento_pib, inflacao e crescimento_pop. Nesse modelo assim como nas redes neurais, não faremos testes de estacionariedade, ou outros tratamentos, e observaremos como o modelo consegue acertar, utilizando o seu potencial.

Utilizamos os anos de 2003 até 2022, como treinamento, e os anos de 2023 a 2025 como os anos de validação fora do treinamento. O motivo para o início em 2003 é a defasagem das variáveis, que acaba reduzindo o corte inicial do modelo, e como optamos por utilizar todas as variáveis, acaba ocasionando na data de corte ser reduzida.

O modelo Random Forest, assim como as redes neurais possui os chamados hiperparâmtros, no nosso modelo testamos com algumas configurações da mesma forma que testamos as próprias redes, com conjuntos de variáveis, com um significado econômico.

Dentre essas o modelo que obteve o melhor resultado foi o PIB_externo, o que não chega a ser uma surpresa, tendo em vista que em outros modelos também apontaram para essa qualidade do setor externo como preditor do PIB. Esse modelo em questão tem 500 árvores [17], 3 variáveis, uma profundidade máxima de 2 e um número mínimo de observações iguais a 3. Esse modelo obteve um RMSE 2.849158 e um MAE de 2.187947 na validação nos anos de treinamento.

Na validação fora do treinamento temos os seguintes erros

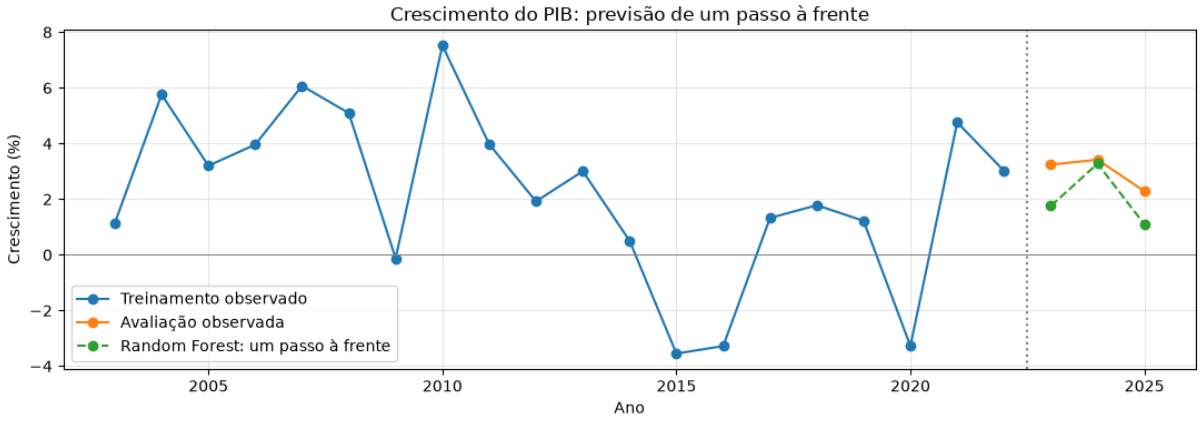
| ano | crescimento_real | crescimento_previsto | erro | erro_abs | erro_quadrado |
|---|---|---|---|---|---|
| 2023 | 3.240708 | 1.756774 | 1.483934 | 1.483934 | 2.202061 |
| 2024 | 3.419152 | 3.276736 | 0.142416 | 0.142416 | 0.020282 |
| 2025 | 2.286924 | 1.094337 | 1.192587 | 1.192587 | 1.422265 |

Notemos como o modelo subestima o crescimento em todos os anos, porém possui um erro relativamente baixo. Notemos na imagem 36 a subestimação nos anos de 2023 e 2025, e um resultado próximo no ano de 2024. Também podemos notar a previsão em nível na figura 37.

Contudo existe uma qualidade do Random Forest que permite avaliar o quanto as variáveis são importantes para as árvores, isso permite uma transparência que não existe nas redes neurais por exemplo. Na figura 38 notamos essa possibilidade. Na figura é possível observar que pra esse modelo, com esse conjunto de variáveis o componente de Investimento Direto Estrangeiro tem uma importância relativa maior que a balança corrente, que por sua vez tem uma

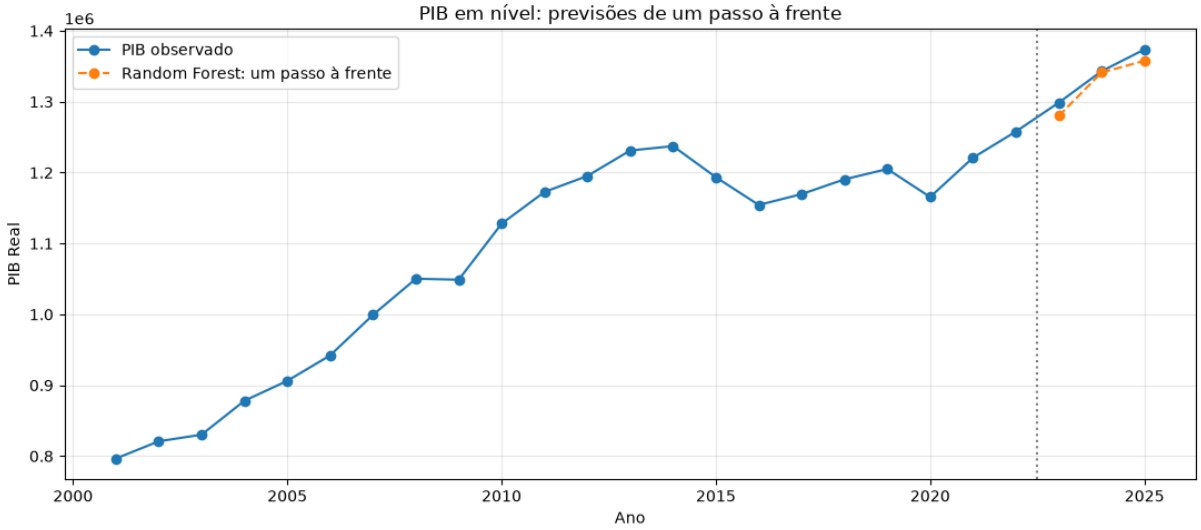
[17] todos os modelos testados tem esse número de árvores

Figura 36 – Previsão do crescimento do PIB utilizando o Random Forest (PIB_externo)




Fonte: Elaborado pelo autor (2026).

Figura 37 – Previsão do PIB em nível utilizando o Random Forest (PIB_externo)

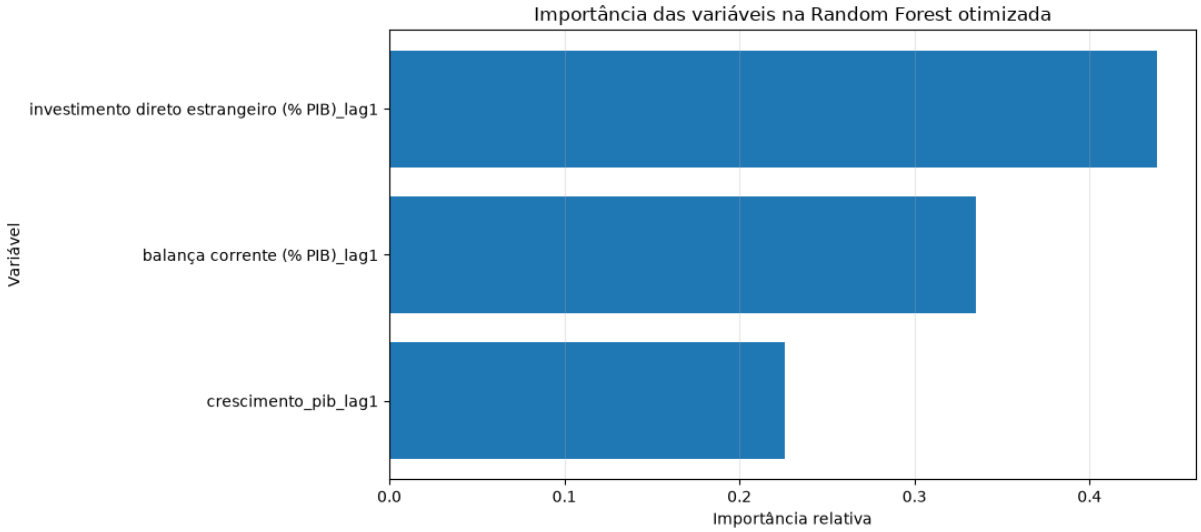



Fonte: Elaborado pelo autor (2026).

importância maior do que o componente autorregressivo.

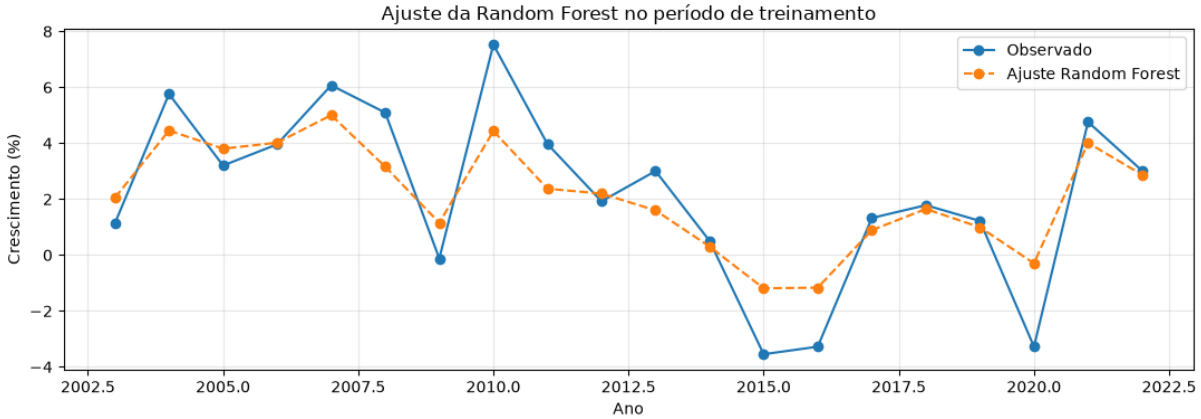
Porém, apesar do modelo apresentado ter os menores erros na validação de treino, o Random Forest é um modelo de IA, e um dos pontos fortes desse modelo é justamente lidar com grandes volumes de variáveis, para isso, vamos testar o melhor modelo com todas as variáveis. Esse modelo completo em questão possui 15 variáveis, uma profundidade máxima de 3 e um número mínimo de observações iguais a 3. O RMSE na validação do treino é de 2.974837 e é ligeiramente maior do que o do PIB externo, assim como o MAE de 2.230485. Na figura 39 notamos como o modelo se ajustou as observações no período de treinamento.

Figura 38 – Importância relativa das variáveis no Random Forest (PIB_externo)




Fonte: Elaborado pelo autor (2026).

Figura 39 – Ajuste durante o treinamento do Random Forest (completo)



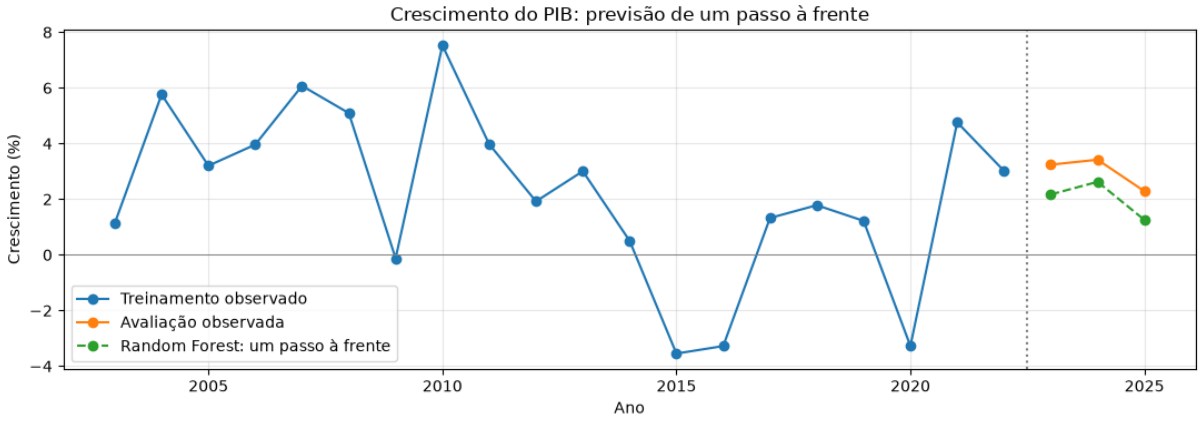

Fonte: Elaborado pelo autor (2026).

| ano | crescimento_real | crescimento_previsto | erro | erro_abs | erro_quadrado |
|---|---|---|---|---|---|
| 2023 | 3.240708 | 2.170664 | 1.070044 | 1.070044 | 1.144994 |
| 2024 | 3.419152 | 2.624301 | 0.794851 | 0.794851 | 0.631788 |
| 2025 | 2.286924 | 1.254914 | 1.032010 | 1.032010 | 1.065044 |

Notemos tanto na tabela, como na figura 40, que esse modelo apesar de ter um erro maior na validação durante o treino, obteve um erro menor na validação fora do período de treinamento. Além disso notemos que a previsão apesar de também subestimar o crescimento do PIB parece captar o comportamento do PIB, mesmo que erre em cerca de um ponto percentual em cada ano. A visualização do PIB em nível na figura 41 é formidável.

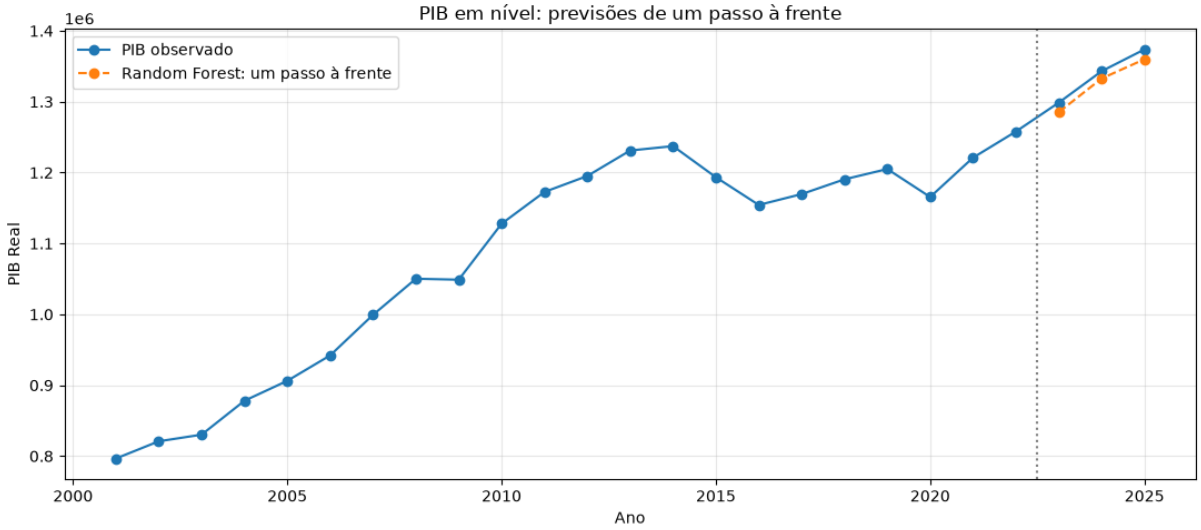
Contudo vale ressaltar que o desempenho do modelo é condicionado as variáveis,

Figura 40 – Previsão de crescimento do PIB no Random Forest (completo)




Fonte: Elaborado pelo autor (2026).

Figura 41 – Previsão do PIB em nível utilizando o Random Forest (completo)



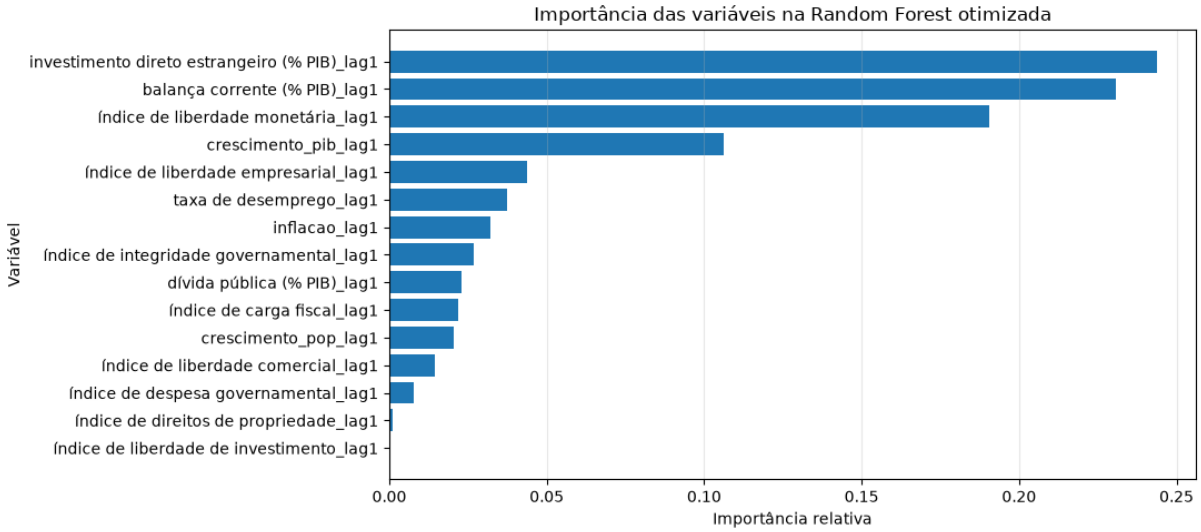

Fonte: Elaborado pelo autor (2026).

o Random forest conseguiu erros pequenos, e uma capacidade de modelar o comportamento da variável alvo com um certo grau de precisão que outros modelos não tiveram resultados tão relevntes, porém é necessário cautela, e testes em outros conjuntos para avaliar a eficácia desse tipo de modelo em outros conjuntos de dados.

Porém, como relatado anteriormente, uma das qualidades do Random forest é a avaliação da importância das variáveis

A partir dessa perspectiva fornecida pelas análises das árvores do Random Forest. Podemos classificar as variáveis em nível de importância, temos um conjunto de 4 variáveis: Investimento Direto Estrangeiro (% PIB), Balança corrente (% PIB), Índice de Liberdade Monetária e o fator autorregressivo são as mais importantes para esse modelo. As duas ligadas ao setor externo tendo um peso maior, seguidas por um indicador de liberdade monetária e por

Figura 42 – Importância relativa das variáveis no Random Forest (completo)




Fonte: Elaborado pelo autor (2026).

último, dentre essas com um maior grau de importância, o próprio crescimento do PIB dos anos anteriores.

Além dessas variáveis, temos também um conjunto de variáveis que possuem uma importância relativa menor que 5%. E duas variáveis Índice de Direitos de Propriedade e o Índice de Liberdade de Investimento que tiveram um importância relativa praticamente nula nesse modelo.

Contudo é importante relembrar que o estudo econométrico não estabelece uma relação causal determinística, não se pode afirmar que esse conjunto de 3 variáveis no topo, são os melhores preditores do PIB, em todos os contextos, e todas as épocas, o que se pode afirmar é quem para nosso conjunto de dados, essas variáveis foram a que tiveram maior importância na estimação do PIB utilizando o Random Forest.

Para buscarmos um sentido econômico nesses resultados podemos trazer a ideia novamente da importância relativa do mercado externo na economia brasileira. Como o setor exportador tem um papel na composição do PIB brasileiro.

Já para o índice de liberdade monetária[18] aponta para um fator de influência da moeda, ou melhor, sobre o papel do governo nas ações sobre moeda, que acabam afetando

[18] Esse índice calculado pela *The Heritage Foundation* trata-se de um índice que estipula o quanto atividades governamentais distorcem os preços, ele é calculado com base em uma taxa média ponderada de inflação dos últimos três anos e um fator qualitativo sobre como o governo intervem na moeda através de controles diretos e subsídios (The Heritage Foundation, 2026). É fato que um destrinchamento de cada um dos indicadores seria um aspecto metodológico relevante sobre determinar o porquê daquele indicador ser um bom estimador do PIB, porém essa avaliação foge do escopo de nosso trabalho, se o leitor tiver curiosidade recomendamos o acesso as bases de dados, onde é detalhado o calculo e a definição de cada uma das variáveis escolhidas no BACEN (2025), IBGE (2025a), The Heritage Foundation (2026) e The World Bank (2026).

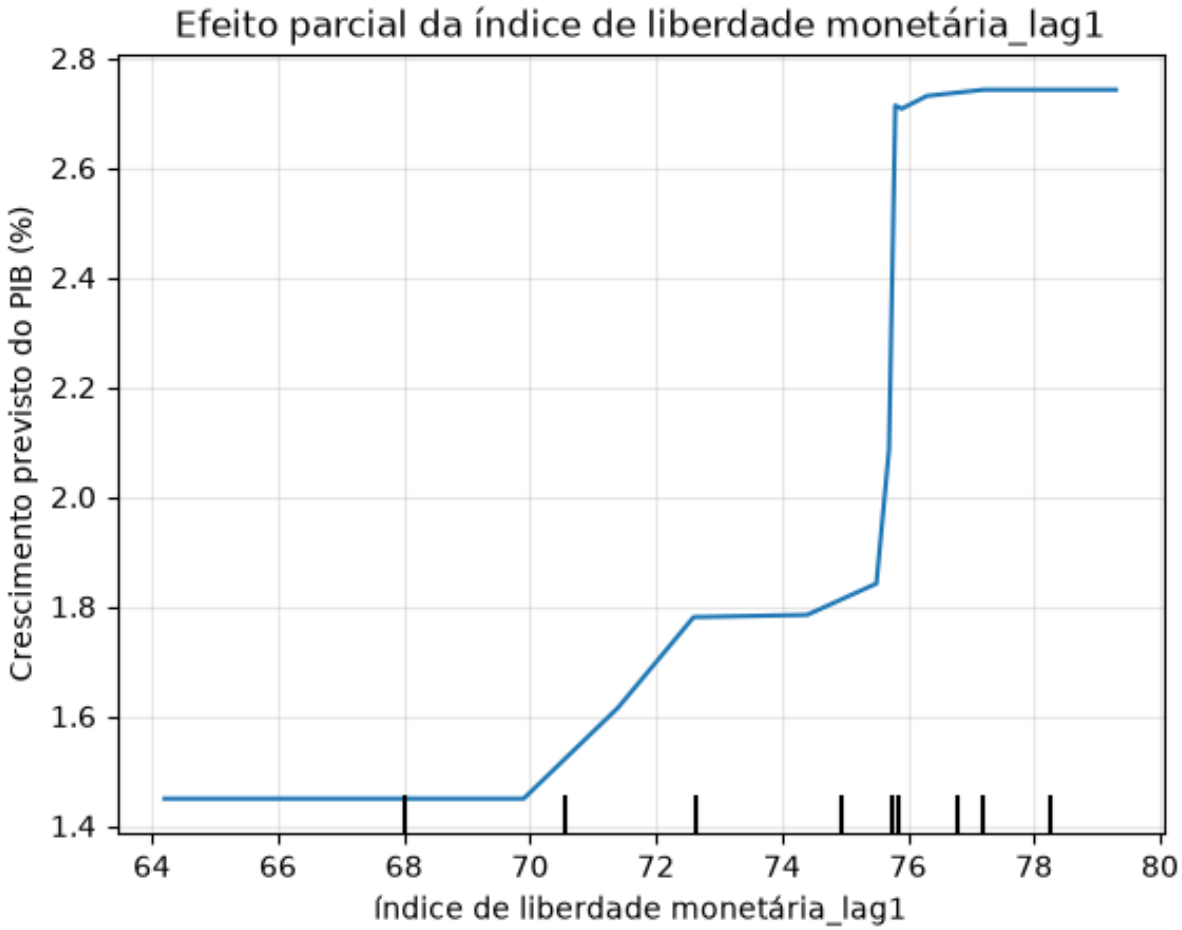
esse indicador. O modelo Random forest capitou que essas intervenções acompanharam o comportamento do PIB.

Porém dizer que uma variável influencia não é a mesma coisa que dizer que a relação dessas variáveis com o PIB é positiva, na realidade o que essa informação nos trás é que elas são boas estimadoras, mas não informa para que direção. Nesse sentido podemos aplicar o teste *Partial Dependence Plot*

(PDP) que nos informa justamente essas relações. Notemos nas figuras 43, 44 e **??**, a partir dessas figuras fica evidente como a balança comercial e a liberdade monetária tem uma relação positiva com o crescimento do PIB, já o contrário acontece com o Investimento Estrangeiro Direto que tem uma relação oposta com o PIB. Essa relação apesar de contraintuitiva pode se justificar primeiramente pela falta de observações. Afinal independentemente da capacidade do modelo, são poucas observações para estabelecer um relação com confiança, podendo ocasionar em possíveis distorções, e esse pode ser uma caso. Outra possibilidade é que nem sempre um investimento direto é significa a construção de um ativo, pode ser somente a troca de mãos, nesse caso além de não ter impacto direto, a renda futura possivelmente sairá do Brasil. Por último o investidor estrangeiro de perfil arrojado pode optar por investir no Brasil justamente em períodos de quedas, buscando uma maior valorização de seu capital e maiores lucros, isso pode causar a percepção de relação negativa entre Investimento estrangeiro direto e o crescimento econômico.

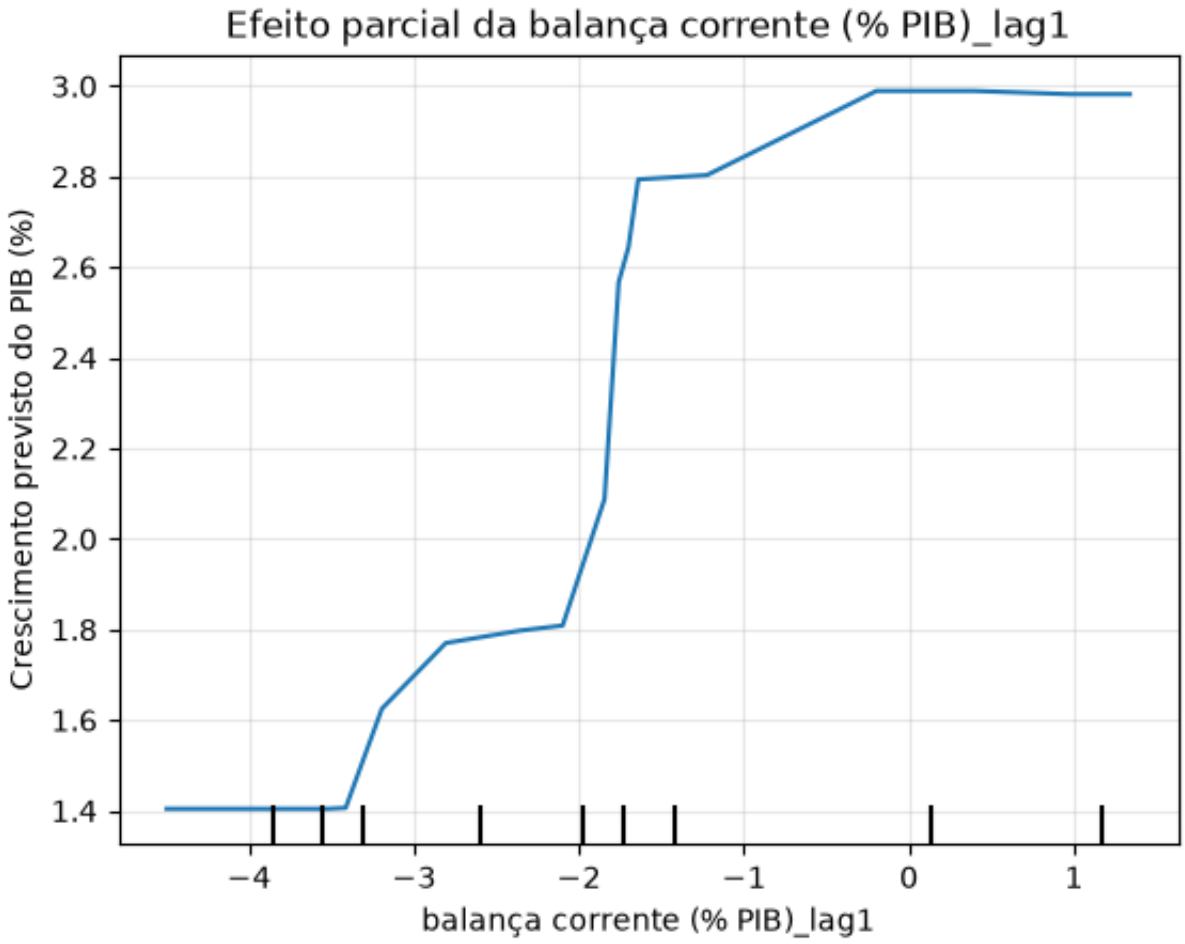
Dessa forma apresentamos o último dos modelos de IA, e também o último modelo econométrico avaliado nesse trabalho. A partir desse ponto no texto, deixaremos de discutir sobre uma avaliação individual de cada modelo, e partiremos para uma conclusão agregada dos resultados, os objetivos concluídos desse trabalho e perspectivas futuras desse tema.

Figura 43 – Dependência parcial da Liberdade Monetária



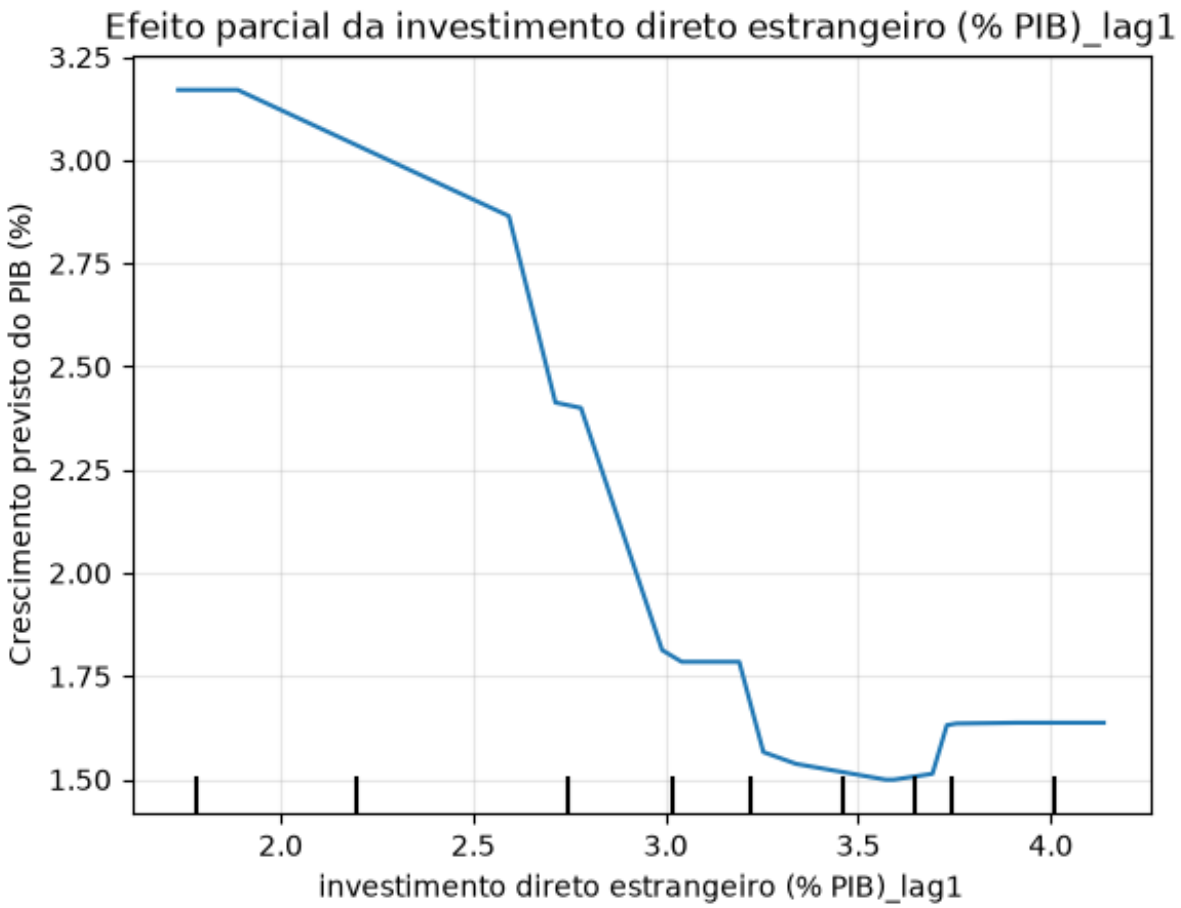

Fonte: Elaborado pelo autor (2026).

Figura 44 – Dependência parcial da Balança Corrente (% PIB)




Fonte: Elaborado pelo autor (2026).

Figura 45 – Dependência parcial da Investimento Estrangeiro Direto (% PIB)




Fonte: Elaborado pelo autor (2026).

# 5 CONCLUSÕES E TRABALHOS FUTUROS

A partir desses resultados fica evidente como os modelos de Inteligência Artificial merecem sua devida atenção, pois conseguiram performar tão bem quanto modelos tradicionais consolidados no mercado. Contudo mesmo diante de um desempenho formidável desses modelos "novos"é de extrema relevância ressaltar que essas novas metodologias não vieram para substituir os chamados modelos tradicionais, mas sim para complementá-las.

Os testes realizados durante esse trabalho podem ser aplicados em contextos reais de problemas econômicos empresarias e governamentais. E nesses ambientes, onde os dados estão presentes em grande volume, a metodologia deixa de ser encontrar o melhor modelo, mas sim testar com todos os presentes, e entender se as respostas apontam para o mesmo caminho. Só com essa informação em mãos os tomadores de decisão poderão decidir entre comprar e vende, investir ou poupar, consumir ou adiar.

Essas decisões que moldam o pensamento econômico quase nunca são estritamente matemáticas, não se trata de uma fórmula mágica, muitas vezes dependem de um feeling, um estalo, uma decisão final baseada em conhecimento tácito sobre o negócio. Esse tipo de decisão não pode ser determinado por relações lineares de modelos tradicionais. Muitas vezes não por uma decisão inteligente, mas por uma falta de capacidade, essas decisões são descartadas por um modelo. Contudo conforme apresentado, os modelos de IA atacam justamente esse ponto, a relevância, o fator não-linear nas relações econômicas.

Existe uma ironia ao refletir sobre esse tema, as relações humanas são tão complexas, que precisamos de uma máquina, que não entende essas relações, para nos auxiliar. Mas não se trata de adivinhação, não é mágica, são as relações humanas históricas do passado que fundamentam as predições futuras. Muito se discute se as máquinas um dia serão inteligentes e pensarão como humanos, porém essa discussão não é relevante para esse problema. O que precisamos realmente discutir é, as máquinas conseguem extrair de um conjunto de dados, não a tendência mecânica e linear de uma economias, mas sim o comportamento humano.

Tendo esse momento de reflexão, é fato também relatar o desempenho dos modelos, é notável que a econometria tem um trabalho relevante anterior ao modelo, a seleção, coleta, tratamento de variáveis é o procedimento mais trabalhoso da aplicação aos modelos. E em sua totalidade é responsável pelo desempenho do modelo e as conclusões que um pesquisador terá sobre o tema. Durante essa pesquisa a proposta inicial era realizar com mais variáveis, mas durante os tratamentos e decisões de cortes, e a própria arquitetura limitante de alguns modelos,

retinge o uso de variáveis.

Além é claro dos problemas enfrentados no que tange a disponibilidade de dados e continuidade das séries, o próprio PIB anual que precisou ser reconstruído com base nos valores trimestrais do IBGE, a falha de continuidade na série do desemprego devido a mudança metodológica, sem falar da disponibilidade reduzida de observações para estimar com confiança uma determinada variável alvo.

Nesse sentido poderíamos testar os modelos com dados fictícios, porém isso primeiro reduziria a perspectiva econômica do trabalho, que acaba sendo parte fundamental, tendo em vista a área de estudo a a finalidade desse trabalho. Porém a testagem laboratorial, sem limitações em condições controladas, tem muito menos a oferecer no quesito realidade. Esse processo de tratamento e escolha de variáveis, a avaliação do comportamento dos modelo quando um problema real é adicionado, seja um dado faltante, uma medição não confiável, uma quebra metodológica, o modelo consegue estimar o alvo com precisão, ou a sensibilidade ao erro é um fator crucial.

Porém não só de problemas vive esse trabalho, mas também de solucioná-los, ou pelo mínimo apontar uma possibilidade no emaranhado de respostas existentes. E o problema que teve uma das respostas apontadas por esse trabalho é como desenvolver um modelo preditivo baseado em IA. Essa explicação não é simples, na realidade ela passou por uma caminho trilhado em 4 objetivos: Desde a caracterização dos modelos que ocorreu em grande parte na revisão de literatura, mas também na apresentação de nossos resultados; A seleção das variáveis tendo em vista as limitações de coleta e período; A construção do modelo em si que envolveu a testagem de diversas variações até encontrar a estrutura mais adequadas aos dados utilizados; Por fim, é claro a apresentação do desempenho de cada modelo, comparativamente, estabelecendo não um pior, ou melhor absoluto, mas um desempenho estrito aos nossos dados e nossas variáveis, que podem futuramente serem complementados e melhorados.

E é a partir dessa complementação e melhoria que esse trabalho pode continuar, o espaço que se abre para uma pesquisa futura é a interpretação de modelos de IA, um das grandes restrições das redes neurais especificamente são as interpretações dos pesos dos modelos. Em aplicações onde a transparência é uma fator relevante como em decisões governamentais, ou decisões bancárias por exemplo, a interpretação é tão importante quanto o acerto. Nesse sentido a avaliação de interpretabilidade é fundamental.

Outro ramo de pesquisa futuro é o campo das IAs generativas, essas tem um espaço

para pesquisa muito vasto e ainda muito inexplorado no âmbito da pesquisa acadêmica. Enquanto as IAs preditiva utilizam os dados históricos para classificar, prever ou tomar decisões baseadas em regras. As IAs generativas tem uma capacidade de sintetizar o conhecimento e gerar "novos conteúdos"baseados no aprendizado durante o treinamento. Isso possui um amplo campo de estudo futuro, em que a combinação dos modelos tradicionais, modelos de IAs preditivas e generativas pode ser o trabalho do economista do futuro.

De toda forma a importância do estudo acadêmico das máquinas econômicas é fundamental, o uso da IA combinado com métodos tradicionais e com o olhar do economista comandando os parâmetros, escolhendo os dados e ajustando os controles é o futuro. E respondendo a pergunta inicial desse trabalho, e parafraseando Keynes. Para onde vamos? não sabemos, mas estamos fazendo algo, para continuar indo para lá.

# REFERÊNCIAS

ALMEIDA, P. R. d. A economia internacional no século xx: um ensaio de síntese. **Revista Brasileira de Política Internacional**, Centro de Estudos Globais da Universidade de Brasília, v. 44, n. 1, p. 112–136, Jan 2001. ISSN 0034-7329. Disponível em: https://doi.org/10.1590/S0034-73292001000100008.

ALVES, A. P. d. A. **Núcleo da inflação como fator comum do IPCA: uma abordagem do modelo de fator dinâmico generalizado**. Dissertação (Mestrado) – Universidade de São Paulo, 2009.

AMARAL, C. P.; SANTOS, D. R. dos; LIMA, E. R.; BARCELLOS, T. Previsão de variáveis econômicas com aprendizado de máquina: previsão com redes neurais. **OBSERVATÓRIO DE LA ECONOMÍA LATINOAMERICANA**, v. 21, n. 9, p. 11279–11299, 2023.

ASSUNÇÃO, F. **Estratégias para tratamento de variáveis com dados faltantes durante o desenvolvimento de modelos preditivos**. 2012.

AZEVEDO, S. H. A. de. **Modelagem de séries temporais macroeconômicas com vetores autorregressivos aumentados com fator e transição suave sob um enfoque bayesiano**. Dissertação (Mestrado) – [sn], 2020.

BACEN, B. C. do B. **Portal de Dados Abertos do Banco Central do Brasil**. 2025. https://dadosabertos.bcb.gov.br. Acesso em: 16 out. 2025.

Banco Central do Brasil. **SGS 1207 – Sistema Gerenciador de Séries Temporais**. Banco Central do Brasil, 2026. Disponível em: https://dadosabertos.bcb.gov.br/dataset/1207-sgs.

BORGES, B. K. Ensaios sobre previsão de séries macroeconômicas para o brasil utilizando modelos var bayesianos. 2018.

BOX, G. E.; JENKINS. **Time series analysis: forecasting and control**. [*S. l.*]: Holden Day, inc, 1970.

BRAGA, I. A. D. **Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning**. 2025.

BREIMAN, L. Random forests. **Machine learning**, Springer, v. 45, n. 1, p. 5–32, 2001.

CARMO, C. R. S.; LOPACINSKI, G. P. Modelagem e previsão de fenômenos socioeconômicos: Uma análise comparativa entre métodos clássicos e contemporâneos. **Revista GeTeC**, v. 13, 2023.

CASTELLI, A. d. C. Modelo midas de projeção do pib brasileiro utilizando a pesquisa industrial mensal. 2022.

CIQUINI, O.; BORBA, A. A. de; GODEGUEZ, P. A. Modelo arima para decisões econômicas. **Proceeding Series of the Brazilian Society of Computational and Applied Mathematics**, v. 10, n. 1, 2023.

COSTA, H. C. **Vector Autoregression (VAR) Tutorial**. s.d. Acesso em: 21 abr. 2026. Disponível em: https://rstudio-pubs-static.s3.amazonaws.com/520691_9092a79ca10245b7bd0d5741d51aa6f8.html.

DOZ, C.; FULEKY, P. Dynamic factor models. **Macroeconomic forecasting in the era of big data: Theory and practice**, Springer, p. 27–64, 2019.

EKMAN, M. **Learning deep learning: Theory and practice of neural networks, computer vision, natural language processing, and transformers using TensorFlow**. [*S. l.*]: Addison-Wesley Professional, 2021.

FIALHO, T. M. M.; CORDEIRO, L. M. C.; TIMOTIO, J. G. M.; REZENDE, L. P. F. de; BOITRAGO, P. R. P. Incerteza, consumo das famílias no brasil e spread bancário: uma análise com o vetor autorregressivo (var). Universidade Federal de Minas Gerais, 2024.

FRISCH, R. Statikk og dynamikk i den økonomiske teori. 1). **Nationalokonomisk Tidsskrift**, v. 37, 1929. Disponível em: https://tidsskrift.dk/nationaloekonomisktidsskrift/article/download/57252/77814.

GEWEKE, J. The dynamic factor analysis of economic time series. **Latent variables in socio-economic models**, North-Holland, 1977.

GHOSH, S.; RANJAN, A. A machine learning approach to gdp nowcasting: An emerging market experience. **Bulletin of Monetary Economics and Banking**, Bank Indonesia, Central Banking Research Department, v. 26, p. 33–54, 2023.

GHYSELS, E.; SANTA-CLARA, P.; VALKANOV, R. **The MIDAS Touch: Mixed Data Sampling Regression Models**. [*S. l.*], 2004. First draft: February 2002. This version: June 22, 2004.

GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Editora Atlas, 2002.

IBGE, I. B. de Geografia e E. **API de dados agregados do IBGE**. 2025. https://servicodados.ibge.gov.br/api/v3/agregados. Acesso em: 16 out. 2025.

IBGE, I. B. de Geografia e E. **Deflator do Produto Interno Bruto - Séries Históricas**. 2025. https://seriesestatisticas.ibge.gov.br/series.aspx?t=pib&vcodigo=scn54. Acesso em: 16 out. 2025.

IBGE, I. B. de Geografia e E. **O que é o PIB?** 2026. Acessado em: 11 abr. 2026. Disponível em: https://www.ibge.gov.br/explica/pib.php.

JúNIOR, M. F. F. A terceira revolução industrial e o novo paradigma produtivo: Algumas considerações sobre o desenvolvimento industrial brasileiro nos anos 90. **Revista da FAE**, v. 3, n. 2, fev. 2017. Disponível em: https://revistafae.fae.edu/revistafae/article/view/501.

KAGERMANN, H.; WAHLSTER, W.; HELBIG, J. *et al.* Recommendations for implementing the strategic initiative industrie 4.0: Final report of the industrie 4.0 working group. **Forschungsunion: Berlin, Germany**, p. 12–25, 2013.

KAVA, L. E. **Além da caixa preta: aprendizagem de máquina interpretável para previsão de séries temporais macroeconômicas brasileiras**. Dissertação (Mestrado) – Universidade Federal de Santa Catarina, 2022.

KEYNES, J. M. **A Teoria Geral do Emprego, do Juro e da Moeda**. [*S. l.*]: Atlas, 1936.

KILKENNY, M. F.; ROBINSON, K. M. Data quality: “garbage in – garbage out”. **Health Information Management Journal**, v. 47, n. 3, p. 103–105, 2018. PMID: 29719995. Disponível em: https://doi.org/10.1177/1833358318774357.

KOOP, G.; MCINTYRE, S.; MITCHELL, J.; RAFTAPOSTOLOS, A. Monthly gdp growth estimates for the u.s. states. 2025. Disponível em: https://arxiv.org/abs/2501.04607.

LAKATOS, E. M.; MARCONI, M. de A. **Fundamentos de metodologia científica**. 5. ed. São Paulo: Editora Atlas, 2003.

LANDOWSKA, A.; KŁOPOTEK, R. A.; FILIP, D.; RACZKOWSKI, K. **GDP-GFCF Dynamics Across Global Economies: A Comparative Study of Panel Regressions and Random Forest**. 2025. Disponível em: https://arxiv.org/abs/2504.20993.

LAUDON, K.; LAUDON, J. **Sistemas de Informação Gerenciais: Administrando a Empresa Digital**. Bookman, 2022. ISBN 9788582606032. Disponível em: https://books.google.com.br/books?id=NIehEAAAQBAJ.

LEMOS, D. C. d. A.; SOUZA, S. A. d. Atas do copom como fonte de previsão do pib: Uma aplicação de processamento de linguagem natural. In: **Nome do Evento**. Cidade: [*S. n.*], 2025.

LI, K. **Forecasting US GDP from 1960 to 2023 using PCA**. 2024. Disponível em: http://dissertations.umi.com/ucla:23601.

MANKIW, N. G. **Introdução à economia**. [*S. l.*]: Bookman Editora, 2025.

MARTINS, G. S. **Indústria 4.0-contribuições tecnológicas para quarta revolução industrial**. [*S. l.*], 2021.

MCKINNEY, W. Data structures for statistical computing in python. **Proceedings of the 9th Python in Science Conference**, p. 51–56, 2010. Disponível em: https://doi.org/10.25080/Majora-92bf1922-00a.

MICHELETTI, A. D. Avaliação de um modelo ensemble stacking de machine learning para previsão do pib do brasil. 2024.

MINSKY, M.; PAPERT, S. **Perceptions: An introduction to computational geometry**. [*S. l.*]: The MIT press, 1969. 311 p.

MOURA, B. A.; TIRYAKI, G. F.; TEIXEIRA, D. N. Fragilidade fiscal e os ciclos econômicos no brasil pós-plano real: evidências de um modelo de fator dinâmico associado à análise var. **Nova Economia**, SciELO Brasil, v. 30, n. 2, p. 517–549, 2020.

OLIVEIRA, M. C.; JUNIOR, S. d. S. P. **Gastos Públicos com Infraestrutura e Disparidades Regionais: Impactos no PIB per capita das Regiões Sul e Nordeste do Brasil**. Natal, RN, 2024.

PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, E. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

PYTHON. **Python Language Reference, version 3.12**. [*S. l.*], 2023. Disponível em: https://www.python.org/doc/. Acesso em: 16 out. 2025.

REBELO, M. A. C. **Interpretabilidade de modelos Machine Learning para a previsão macroeconómica**. Dissertação (Mestrado) – Universidade de Lisboa (Portugal), 2022.

ROSA, Y. C. d. Efeito dinâmico dos gastos tributários sobre a produtividade total dos fatores no brasil. Idp, 2025.

ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological review**, American Psychological Association, v. 65, n. 6, p. 386, 1958.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **nature**, Nature Publishing Group UK London, v. 323, n. 6088, p. 533–536, 1986.

SANTANA, A. A.; SILVA, C. R. da; TIMOTEO, L. C. da S.; OLIVEIRA, R. M. de; NARCISO, R. Aprimorando a tomada de decisões empresariais: o papel dos dados, análises de negócios e novas tecnologias. **Revista Ilustração**, v. 4, n. 2, p. 75–83, 2023.

SANTOS, F.; NOLAU, I. **Previsão de inflação: análise preliminar de desempenho de técnicas de machine learning**. [*S. l.*], 2022.

SERRANO, F. M. **Impacto regional da política monetária no Brasil: uma abordagem bayesiana**. Dissertação (Dissertação (Mestrado em Teoria Econômica)) – Faculdade de Economia, Administração e Contabilidade, Universidade de São Paulo, São Paulo, 2014. Acesso em: 29 abr. 2026. Disponível em: https://doi.org/10.11606/D.12.2014.tde-16032015-132813.

SILVA, P. N.; SILVA, G. V. P. d. Dados abertos do ibge: Recuperação na api de dados agregados. **Encontros Bibli**, SciELO Brasil, v. 29, p. e96185, 2024.

SILVA, T. R. d.; CLERICUZI, A. Z.; CARVALHO, J. N. d. Modelagem de sÉries temporais utilizando arima: PrevisÃo futura do pib brasileiro. **International Contemporary Management Review**, v. 6, n. 2, p. e385, Aug. 2025. Disponível em: https://icmreview.com/icmr/article/view/385.

SIMS, C. A. Macroeconomics and reality. **Econometrica: journal of the Econometric Society**, JSTOR, p. 1–48, 1980.

The Heritage Foundation. **About the Index of Economic Freedom**. 2026. The Heritage Foundation. Accessed: 2026-11-08. Disponível em: https://economicfreedom.heritage.org/pages/about.

The World Bank. **World Bank Open Data**. The World Bank Group, 2026. Accessed: 2026-11-08. Disponível em: https://data.worldbank.org.

U.S. Bureau of Economic Analysis. **Gross Domestic Product**. U.S. Bureau of Economic Analysis, 2026. Disponível em: https://www.bea.gov/data/gdp/gross-domestic-product.

VASCONCELOS, B. F. B. de. **Poder preditivo de métodos de Machine Learning com processos de seleção de variáveis: uma aplicação às projeções de produto de países**. Tese (Tese de Doutorado) – Universidade de Brasília, Brasília, Brasil, ago. 2017. Faculdade de

Economia, Administração, Contabilidade e Gestão de Políticas Públicas (FACE), Departamento de Economia (FACE ECO), Programa de Pós-Graduação em Economia. Disponível em: http://dx.doi.org/10.26512/2017.03.D.23995.

VASCONCELOS, M. **Atlas de Economia**. 2. ed. São Paulo: Editora Atlas, 2020. Define conceitos de macroeconomia e apresenta indicadores econômicos.