UNIVERSIDADE FEDERAL DA FRONTEIRA SUL

CAMPUS LARANJEIRAS DO SUL

CIÊNCIAS ECONÔMICAS

LEONILSO FANDRES WRUBLAK

AS MÁQUINAS ECONÔMICAS: PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

LARANJEIRAS DO SUL - PR

2026

LEONILSO FANDRES WRUBLAK

AS MÁQUINAS ECONÔMICAS: PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado ao Curso de Ciências Econômicas da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciências Econômicas.

Orientador: Prof. Dr. Alexandre Manoel dos Santos (UFFS)

LARANJEIRAS DO SUL - PR

2026

LEONILSO FANDRES WRUBLAK

AS MÁQUINAS ECONÔMICAS:

PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado ao Curso de Ciências Econômicas da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciências Econômicas.

Este trabalho foi defendido e aprovado pela banca em DD/MM/AAAA.

BANCA EXAMINADORA

_____

Prof. Dr. Alexandre Manoel dos Santos - UFFS
Orientador

_____

Professor(a) 1
Avaliador

_____

Professor(a) 2
Avaliador

Dedico esse trabalho a todos que um dia sonharam e construir um mundo melhor com base no esforço e no trabalho!

AGRADECIMENTOS

Agradeço primeiramente a Deus por me permitir viver e poder construir este trabalho, seguidamente a minha esposa Bruna Raphaelle Fernandes Wrublak, que m apoiou durante as noites em que estava sentado escrevendo, ao meu pai leonildo Savoldi Wrublak e minha mãe Eli Piltz Fandres Wrublak que sempre me inspiraram e me incentivaram a estudar cada vez mais, a minha irmã Leoneli Fandres Wrublak dos Santos e meu cunhado Bruno dos Santos que foram espelhos de trabalho e dedicação, e a todo restante de minha família que esteve comigo nessa jornada. Um agradecimento especial ao meu orientador professor Doutor Alexandre Manoel dos Santos por me dar o suporte necessário para a construção dessa pesquisa, assim como agradeço a todos os meus outros professores, saibam que a profissão que escolheram para a vida inspiram milhões de pessoas pelo mundo todos os dias. Agradeço também aos meus colegas e amigos, que me acompanharam nas matérias difíceis e nos momentos especiais dentro dessa Universidade. A todos o meu profundo e sincero muito obrigado!

"De fato, sabemos muito pouco sobre o futuro. A base real para formar expectativas sobre o rendimento futuro de um investimento é extremamente frágil. Nossas decisões de investimento [...] dependem de um estado de confiança. Muitas vezes, sabemos que não sabemos; mas mesmo assim temos que agir."

(Keynes, 1936, p. 161)

RESUMO

A incerteza é um desafio grande na vida dos gestores, sejam eles públicos ou privados, e o combate a incerteza se da pela busca de informações, o risco é inversamente proporcional ao conhecimento que temos sobre determinado assunto,e o conhecimento só se da pela interpretação das informações obtidas através de um processo de mineração de dados, quando falamos de poucos dados, os modelos tradicionais de previsão conseguem acertar com um determinado nível de precisão, mas quando queremos resultados mais precisos, ou que nossos dados são mais complexos, evento cada vez mais comum na era do *big-data*, os modelos tradicionais de previsão encontram limitações, nesse sentido a presente monografia busca responder em que medida modelos preditivos baseados em Inteligência Artificial (IA) conseguem estimar o PIB brasileiro com maior precisão do que os modelos tradicionais VAR, ARIMA, DFM e MIDAS? Para isso se utilizará de métodos quantitativos visando estimar a acurácia, custo computacional e interpretabilidade dos modelos testados, para enfim determinar se modelos de IA conseguem reduzir a incerteza.

Palavras-chave: Inteligência Artificial; PIB brasileiro; Métodos Quantitativos; Testes de modelos.

ABSTRACT

Uncertainty is a major challenge for managers, whether public or private, and combating it involves seeking information. Risk is inversely proportional to one's knowledge about a given subject, and knowledge only comes from interpreting the information obtained through data mining. When we're dealing with limited data, traditional forecasting models can achieve a certain level of accuracy. However, when we want more accurate results or when our data is more complex—an increasingly common occurrence in the era of big data—traditional forecasting models encounter limitations. In this sense, this monograph seeks to answer the question of how predictive models based on artificial intelligence (AI) can estimate Brazilian GDP with greater accuracy than traditional VAR, ARIMA, DFM, and MIDAS models. Quantitative methods will be used to estimate the accuracy, computational cost, and interpretability of the models tested, ultimately determining whether AI models can reduce uncertainty.

Keywords: Artificial Intelligence; Brazilian GDP; Quantitative methods; Model testing.

LISTA DE ILUSTRAÇÕES

LISTA DE TABELAS

Tabela 1 – Fontes de dados utilizadas nas APIs do IBGE e BACEN 30
Tabela 2 – Constructo da pesquisa 32

LISTA DE SIGLAS

ADF Dickey-Fuller aumentado

AIC Critério de Informação de Akaike

AR Auto-Regressivo

BIC Critério de Informação Baysiano

EUA Estados Unidos da América

FAC Função de Autocorrelação

FACP Função de Autocorrelação Parcial

FMI Fundo Monetário Internacional

FRED Federal Reserve Economic Data

GDP Gross Domestic Product

IA Inteligência Artificial

IBGE Instituto Brasileiro de Geografia e Estatística

MA Média Móvel

PIB Produto Interno Bruto

PNB Produto Nacional Bruto

SUMÁRIO

1 INTRODUÇÃO 12
1.1 Problema de pesquisa 13
1.2 Objetivos 14
1.2.1 Objetivo Geral 14
1.2.2 Objetivos Específicos 14
1.3 Justificativa 14
2 REVISÃO DE LITERATURA 16
2.1 Predição Econômica: O PIB 16
2.2 Modelos preditivos 18
2.2.1 Modelos Tradicionais: Uma explanação 19
2.2.1.1 ARIMA *19*
2.2.1.2 VAR *24*
2.2.1.3 DFM *26*
2.2.1.4 MIDAS *26*
2.2.2 Modelos de IA: Uma explanação 27
2.2.2.1 Redes Neurais *27*
2.2.2.2 Florestas Aleatórias *27*
2.3 Testes: Comprovar e comparar modelos 27
2.4 IA vs Tradicional: Uma perspectiva Acadêmica 27
3 METODOLOGIA 28
3.1 Delineamento de pesquisa 28
3.2 Procedimento de coleta de dados 28
3.3 Procedimento de análise de dados 29
3.4 Constructo da pesquisa 32
4 RESULTADOS 33
5 CONCLUSÕES E TRABALHOS FUTUROS 34
REFERÊNCIAS 35

1 INTRODUÇÃO

Para onde vamos? uma das questões fundamentais da natureza humana, estudada pelas mais diferentes ciências, desde exatas às sociais. Dentre as ciências que buscam a resposta do para onde iremos, temos a economia, uma ciência que encontra-se no meio termo, a chamada social aplicada. Inicialmente pode parecer estranho, mas boa parte do trabalho de um economista é entender os fatos passados e presentes para predizer (ou tentar) o futuro, mas a pergunta que fica é por quê a economia se preocupa tanto com o futuro?

Para Mankiw (2025, p. 1) "a economia é o estudo de como a sociedade administra seus recursos escassos", é essa escassez [1] que é o motivador para a preocupação com o futuro, afinal se tivéssemos recursos ilimitados não haveria motivo para estudar economia. Mas este não é o caso, existe limitação de recursos, e devemos saber qual é a melhor maneira de alocar esses recursos.

Para um melhor enfoque, a economia se subdivide em duas grandes áreas, a microeconomia, voltada para o estudo da firma (empresas), e a macroeconomia, que estuda os agregados econômicos (Vasconcelos, 2020)

No presente trabalho nos voltaremos para a macroeconomia, área da economia que surge no inicio do século XX, devido as intensas mudanças sociais, políticas e econômicas que ocorreram no período, a principal obra referência da macroeconomia é o livro de John Maynard Keynes: *Teoria Geral do Emprego, do Juro e da Moeda* 1936, onde o autor traz os principais fundamentos da macroeconomia que é estudada hoje na academia e executada nos governos.

Um desses conceitos fundamentais que Keynes aborda é a noção de incerteza

> De fato, sabemos muito pouco sobre o futuro. A base real para formar expectativas sobre o rendimento futuro de um investimento é extremamente frágil. Nossas decisões de investimento [...] dependem de um estado de confiança. Muitas vezes, sabemos que não sabemos; mas mesmo assim temos que agir. (Keynes, 1936, p. 161)

Com essa noção de incerteza definida por Keynes podemos relacionar com aquela nossa questão fundamental, gestores mundiais, sejam eles públicos ou privados, buscam maneiras de observar dados históricos e com um certo intervalo de confiança tentar "prever o futuro", para justamente, combater a incerteza.

A incerteza gera perguntas, e encontrar as respostas para essas perguntas vai muito além da impressão pessoal do gestor. Os gestores precisam de informação para suas decisões, e

[1] escassez: natureza limitada dos recursos da sociedade (Mankiw, 2025, p. 1)

para Laudon e Laudon (2022) os sistemas de informação são essenciais para alcançar objetivos estratégicos dos negócios. Na era digital, o grande volume de dados gerados pelos sistemas de informação podem ser usados como fontes, praticamente inesgotáveis de dados.

Esses grandes volumes de dados, gerados pelos sistemas de informação, são chamados de *big data*. Para (Vasconcelos, 2017, p. 9) "O *big data* caracterizado por grandes bases de dados com um número elevado de preditores relativos às observações disponíveis". Contudo, somente ter os dados não é o suficiente, e converter esse grande volume de dados em informações não é uma tarefa simples, e exige técnicas sofisticadas de coleta, tratamento e modelagem. Os processos de coleta e tratamento, apesar de fundamentais, serão usados somente como passos anteriores ao da modelagem, que é o enfoque desse texto.

1.1 Problema de pesquisa

Avaliar modelos na previsão de variáveis econômicas não é um processo novo, muitos autores já usaram diversas vezes esses modelos.

Em sua dissertação, Azevedo (2020) usou o modelo modelo de vetores auto-regressivos (VAR) para análise de séries temporais com variáveis macroeconômicas. Já Fialho *et al.* (2024) usaram o VAR para entender a dinâmica entre incerteza, spread bancário, crédito, consumo, rendimento e taxa de desocupação.

Ciquini *et al.* (2023) avaliou o uso do modelo auto-regressivo de médias móveis (do inglês *AutoRegressive Integrated Moving Average* - ARIMA) para tomada de decisões econômicas. Agora Silva *et al.* (2025) apoiaram-se no ARIMA para a predição do PIB brasileiro.

Alves (2009) em sua dissertação de mestrado abordou modelos de fatores dinâmicos (do inglês *Dynamic Factor Models* - DFM) para entender o núcleo da inflação brasileira. Por outro lado Moura *et al.* (2020) avaliou os ciclos econômicos brasileiros usando uma combinação entre o DFM e o VAR.

Castelli (2022) abordou o uso do modelo de amostragem de dados mistos (do inglês *Mixed Data Sampling* - MIDAS) para predizer o PIB com a pesquisa industrial mensal. Assim como Micheletti (2024) usou modelos de *ensemble stacking* [2] (dentre eles o MIDAS) para prever o PIB.

A maioria desses autores trabalharam com o que se chamam modelos tradicionais de predição, esses modelos se baseiam em variáveis e proposições bem definidas, o que pode

[2] *ensemble stacking*: modelos combinados

não ser o caso na era do *big data*. Nesse contexto, em que os modelos tradicionais encontram-se limitados, que a inovação surge, nesse caso o uso de técnicas de IA para modelar variáveis econômicas.

Diante do disso a presente pesquisa tende a seguir os passos de Kava (2022) e de Rebelo (2022) que comparam, em suas dissertações, modelos de IA com os chamados modelos tradicionais. Contudo, a nossa pesquisa se diferencia dos trabalhos produzidos por testar outros modelos e focar especificamente no PIB brasileiro, para isso norteia-se pela seguinte pergunta: Em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro?

1.2 Objetivos

1.2.1 Objetivo Geral

Analisar em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro.

1.2.2 Objetivos Específicos

a) Caracterizar os modelos econométricos tradicionais (VAR, ARIMA, DFM e MIDAS) e de IA para a predição do PIB;
b) Identificar as diferentes variáveis determinantes na estimativa do PIB;
c) Desenvolver um ciclo de vida para a produção de um novo modelo econométrico de IA para a predição do PIB;
d) Comparar o desempenho dos modelos de IA e econométricos tradicionais usando diferentes métricas, como desempenho computacional, precisão e interpretabilidade.

1.3 Justificativa

O presente trabalho justifica-se empiricamente, pois permite que gestores, sejam eles públicos ou privados, utilizem-se de ferramentas estatísticas para tomarem decisões fundamentadas. "A tomada de decisões empresariais é uma tarefa complexa e fundamental para a sobrevivência de uma organização"(Santana *et al.*, 2023, p. 3).

Portanto, a tomada de decisões pode ser fundamentada através dos modelos. Os

modelos, mesmo que sejam uma simplificação da realidade, podem aumentar a confiança dos agentes. Segundo Keynes (1936), essa confiança é um fator que afeta as decisões de investimento.

Já contribuição teórica desse trabalho está alinhada com a avaliação dos diferentes modelos estatísticos para a predição econômica, além é claro, de explorar as novas fronteiras da ciência, com a avaliação de modelos inovadores como os que usam a IA.

O presente trabalho busca mesclar diferentes modelos, ranqueando seu desempenho, e possibilitando a identificação dos modelos mais adequados para previsão econômica. Para isso é necessário a avaliação métricas estatísticas comuns, semelhante ao que Castelli (2022) fez, ao comparar modelos de IA com modelos tradicionais, aplicando métricas como coeficiente de determinação (R^2), Erro Médio Absoluto (MAE), Erro Quadrático Médio (MSE) para classificar os modelos.

2 REVISÃO DE LITERATURA

A presente sessão busca avaliar os estudos até então construídos que perpassam sobre as temáticas correlatas, a evolução dos modelos preditivos, a variável estudada: o Produto Interno Bruto (PIB), o uso de modelos preditivos em variáveis macroeconômicas, por fim a avaliação e comparação de modelos preditivos.

Dado esse contexto, a presente revisão de literatura se estruturará da seguinte forma, primeiramente iremos tratar sobre predição econômica de um modo geral e seus principais autores, logo em seguida discutiremos sobre nossa variável foco o PIB, posteriormente classificaremos os modelos em tradicionais e não-tradicionais, onde será descrito cada modelo o conceito, o histórico, o modelo matemático e a aplicação do mesmo no contexto de predição do PIB. Após essa conceituação será analisado as métricas de comparação dos modelos, e como elas vem sendo aplicadas. Após a conceituação e análise das métricas de avaliação, serão abordados os trabalhos acadêmicos que já compararam modelos tradicionais e não tradicionais.

2.1 Predição Econômica: O PIB

A predição de variáveis econômicas não é uma tarefa nova, na realidade estipular o comportamento de variáveis econômicas ao decorrer do tempo é um desejo dos economistas desde o início do século XX. Em seu artigo, Frisch (1929) [1] trata do conceito da teoria dinâmica, que se subdivide em analítica e histórica, a primeira lida com as leis que regem as flutuações das variáveis, já a segunda trata de aplicar as leis para descrever/prever as variáveis. Essa conceituação teórica de Frisch (1929) é justamente o que hoje é considerado como econometria, e foi a base para os futuros modelos econométricos e suas aplicações.

Contudo, a economia ficou mais complexa desde 1929, conforme Almeida (2001) a economia do início século XX passou por sua fase madura de industrialização incorporou uma grande quantidade de inovações tecnológicas advindos da Segunda Revolução Industrial. Ainda segundo o autor, "a estrutura da produção foi radicalmente transformada pelas mudanças introduzidas nos padrões de trabalho (especialização) e pelos avanços tecnológicos, que aumentaram dramaticamente o produto per capita."(Almeida, 2001, p. 2).

Esse processo se repetiu durante a Terceira Revolução Industrial, Júnior (2017) aponta que esse processo não foi hegemônico, mas foi caracterizado por uma revolução tecno-

[1] Frisch é considerado um dos fundadores da econometria moderna, é a ele atribuído a formulação do termo econometria

científica, não só nas fábricas como na maioria das atividades sócio-econômicas. Durante esse período houve intensas mudanças na atividade produtiva. Contudo alguns autores apontam que a humanidade passou por mais uma revolução, a Quarta Revolução Industrial, ou também chamada de Indústria 4.0.

O termo industria 4.0[2] é citado pela primeira vez na feira de Hannover como uma nova política Alemã para industrialização (Kagermann *et al.*, 2013). Um dos autores defensores de uma nova fase da industria é Martins (2021), onde ele argumenta que a Indústria 4.0 traz muitas mudanças no contexto onde ela é aplicada, como novos modelos de negócio e mercados cada vez mais exigentes.

Mas não somente a economia ficou mais complexa, o advento da indústria 4.0 trouxe a possibilidade de coletar e processar grandes volumes de dados através do que chamamos de sistemas de informação. Que para Laudon e Laudon (2022) são essenciais para alcançar objetivos estratégicos dos negócios.

Seguindo esse caminho racional muitos indicadores econômicos foram criados, melhorados ou superados, tanto no sentido microeconômico dentro das firmas, assim como indicadores macroeconômicos de grandes agregados. E um desses indicadores macroeconômicos que evoluiu com o tempo busca estimar a produção total interna de uma localidade, o chamado PIB. Segundo o Instituto Brasileiro de Geografia e Estatística (IBGE) "o PIB é a soma de todos os bens e serviços finais produzidos por um país, estado ou cidade, geralmente em um ano."(IBGE, 2026, p. 1).

Na realidade o PIB funciona como um termômetro da atividade econômica, e se indicadores refletem a realidade, é lógico pensar que conforme a economia fica complexa, seus indicadores as acompanham, assim como as tentativas de tentar prever seu comportamento.

Dado toda essa evolução, é natural perceber a complexificação desse indicador, e fenômenos complexos implicam que métodos tradicionais de predição podem não conseguir descrever a realidade com a mesma precisão da época da qual foram elaborados.

Deste modo, chegamos a um momento de inflexão. Complexidade sistêmica combinada ao grande volume de dados pode fazer com que modelos econométricos tradicionais[3] não consigam representar a realidade, pois, até que ponto uma simplificação pode representar realmente o comportamento econômico.

---

[2] Industria 4.0: é a transformação digital na indústria, onde a mesma integra tecnologias como a própria Inteligência Artificial

[3] No presente trabalho trataremos que os modelos econométricos tradicionais são aqueles baseados na linearidade das variáveis, ausência de multicolinearidade, homocedasticidade e normalidade dos resíduos

Dessa forma, se o tradicional não tem o comportamento esperado recorre-se ao inovador. Essa inovação, no contexto dos modelos econométricos, vem através da incorporação de modelos estatísticos que suportam a complexidade econômica, além de tecnologias computacionais que conseguem tratar esse volume de dados gerados pelos sistemas de informação.

2.2 Modelos preditivos

Antes de partirmos para inovação devemos entender o que de fato são esses modelos preditivos. Tomando como princípio o texto de Frisch (1929) a econometria surge justamente para aplicar as leis que regem a economia, a teoria dinâmica histórica, busca evidenciar as relações entre as variáveis, não por suposição cega, mas sim, baseando-se em séries temporais já existentes. Frisch (1929) trata do que ainda viria se tornar a econometria moderna, ademais, existem diversos tipos de modelos econométricos, e os modelos preditivos fazem parte desse conjunto. Portanto se faz necessário identificar exatamente do que se tratam esses modelos.

Para Assunção (2012, p. 8) esses modelos "correspondem a uma equação (ou regra) na qual através de informações históricas ou atuais predize-se um determinado evento futuro a respeito de um indivíduo". Deste modo, a partir do conceito de Assunção (2012) entendemos que independente do modelo: Sempre haverá uma entrada (*input*) de variáveis, sejam elas históricas ou contemporâneas; Haverá também, um processamento desses dados pelo modelo, seja por uma equação matemática ou um preceito estabelecido; E sempre ocasionará em uma saída (*output*), e no caso de modelos preditivos, essa saída terá por objetivo estipular uma variável no tempo futuro.

Com essa definição, retomamos nossos objetivos, como desejamos estimar o PIB nossa saída sempre será um valor numérico que estimará como o PIB brasileiro se comporta. Portanto as únicas variações possíveis nos modelos são: a estrutura; e as variáveis de entrada. Durante a explanação dos modelos trataremos especificamente sobre suas estruturas e estradas, e poderemos nos debruçar melhor sobre o que diferencia cada modelo preditivo.

Entendido o que são modelos preditivos partiremos para diferenciar modelos tradicionais dos de IA, assim como a explanação específica de cada modelo usado no presente estudo, seu histórico, sua construção matemática, por fim a aplicação desses modelos na predição do PIB. Para atendermos esses pontos e concluir nossos objetivos deveríamos seguir algum tipo de sequência lógica para apresentar tais modelos, a abordagem mais simples seria em uma sequência temporal de surgimento, contudo, muitos modelos complexos surgiram antes de versões mais

simplificadas. Dessa forma optamos por apresentar os modelos em uma sequência didática, primeiro tratando dos modelos tradicionais, em seguida os que são baseados em IA, de um forma que julgamos facilitar o entendimento.

2.2.1 Modelos Tradicionais: Uma explanação

Os modelos tradicionais, são modelos simples, geralmente associados a métodos lineares de aprendizado de máquina "tem esse nome porque assumem que a função que define $E(Y|X)$ é linear nos preditores $X1, X2, ..., Xp$."(Vasconcelos, 2017, p. 14). Rebelo (2022) ainda aponta que os modelos chamados tradicionais possuem uma interpretabilidade natural[4], e não possuem a necessidade de um método de interpretação adicional.

Segundo Braga (2025) os modelos tradicionais dominaram o mundo, quando o assunto era predição de variáveis durante muitos anos. Entretanto conforme a complexidade econômica aumentava, novas alternativas foram surgindo, para a autora "Apesar da eficácia desses modelos tradicionais em determinados cenários, os avanços computacionais e a crescente disponibilidade de dados favorecem o desenvolvimento de abordagens mais sofisticadas"(Braga, 2025, p. 12).

Dado o tempo em que os modelos tradicionais eram as únicas opções, essas técnicas ganharam muitas variações, algumas mais sofisticadas, outras mais simplificadas, dessa forma, para o presente estudo nos limitaremos a abordar quatro modelos tradicionais, um modelo temporal univariado (ARIMA), um modelo temporal multivariado (VAR), um modelo baseado em fatores (DFM) e um modelo misto (MIDAS). A escolha desses modelos se deve a diferença entre como eles processam as entradas, sendo excelente para apresentar como métodos diferentes se comportam na previsão de uma variável macroeconômica como o PIB.

2.2.1.1 ARIMA

Seguindo a proposta didática, começaremos pelo ARIMA, no sentido de simplicidade de interpretação e complexidade em geral, o ARIMA é o modelo mais simples que será tratado nesse trabalho, a sigla ARIMA vem do inglês *AutoRegressive Integrated Moving Average* que significa Média Móvel Integrada Autorregressiva, a sua simplicidade se deve ao fato que ele tenta predizer a variável estudada usando sua própria série histórica. Nesse caso usaremos a série

[4] A definição de Rebelo (2022) de certa forma é mais precisa, pois modelos não-lineares como árvores de decisão são classificadas como modelos tradicionais pela sua interpretabilidade.

histórica do PIB para prever o possível valor futuro do mesmo.

O modelo ARIMA nos servirá como um ótimo parâmetro de comparação, por se tratar de um modelo simples, com baixo custo computacional e alta interpretabilidade, ele poderá ser usado para avaliar outros modelos testados. Se um modelo complexo com alto custo computacional e interpretabilidade baixa, se sair pior ou semelhante ao ARIMA na previsão do PIB, poderá ser um indicador que aquele modelo não apresenta uma relação custo-benefício favorável, levando a crer que o modelo não é adequado[5] para a predição do PIB.

Segundo Braga (2025) o modelo ARIMA é sistematizado em 1970 no livro de Box e Jenkins (1970). Neste livro os autores afirmam que os modelos do tipo ARIMA fazem parte do conjunto a cujo a d-ésima diferença da série é um processo estacionário misto autorregressivo de média móvel (Box e Jenkins, 1970). Além disso os autores apontam a necessidade desses modelos em aplicações reais.

> Muitas séries temporais empíricas (por exemplo, séries de preços de ações) se comportam como se não tivessem uma média fixa. No entanto, elas exibem homogeneidade no sentido de que, além do nível local, ou talvez nível local e tendência, uma parte da série se comporta de forma muito semelhante a qualquer outra parte. Modelos que descrevem tal comportamento não estacionário homogêneo podem ser obtidos assumindo que alguma diferença adequada do processo é estacionária. (Box e Jenkins, 1970, p. 88, tradução nossa)

No sentido de definição e contexto para nosso trabalho, o modelo ARIMA tem um grande potencial para a predição do PIB, pois o comportamento sazonal[6] do PIB, torna ele uma variável parecida com a descrita no exemplo de Box e Jenkins (1970), sem uma média fixa aparente, mas uma certa homogeneidade de nível local e tendência, semelhante ao decorrer da série. Contudo Box e Jenkins (1970) não somente descreveram em que caso o modelo ARIMA seria adequado, mas também sua formulação matemática e metodologia de aplicação.

O modelo ARIMA(p,d,q) pode ser representado pela seguinte forma geral (Box e Jenkins, 1970, p. 94):

$$\varphi(B)z_t = \phi(B)\nabla^d z_t = 0_0 + 0(B)a_t \tag{2.1}$$

onde

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$$

$$O(B) = 1 - 0_1 B - 0_2 B^2 - \cdots - 0_p B^p$$

[5] Isso parte de um pressuposto simples, porém para descartar completamente o modelo, seriam necessários outros testes, com outros dados para efetivar com clareza essa suposição, porém isso fugiria do escopo do nosso trabalho.

[6] Observaremos as variações do PIB nos nossos resultados.

Em que:

a) $\phi(B)$ operador autorregressivo (AR)[7]

b) $\varphi(B) = \phi(B)\nabla^d$ operador autorregressivo generalizado

c) $0(B)$ operador de média móvel

Desse modo utilizaremos a formulação de Box e Jenkins (1970) para a predição do PIB, assim como os testes que comprovam a aplicabilidade do ARIMA no contexto do PIB. Todavia o trabalho de submeter a predição do PIB ao modelo ARIMA já foi realizado por outros autores.

Nesse sentido, revisaremos o trabalho de Silva *et al.* (2025) que apoiaram-se no ARIMA para a predição do PIB brasileiro, no trabalho foi analisado a série histórica do PIB brasileiro de 1990 até 2023[8] sendo uma fonte metodológica e comparativa para nossa pesquisa.

O primeiro passo dos autores na aplicação do modelo foi uma análise visual da série temporal, os autores consideraram o comportamento de volatilidade do PIB, com crescimentos e decrescimentos, propondo a possibilidade de uso do modelo ARIMA. Para confirmar essa hipótese eles aplicaram o teste Dickey-Fuller aumentado (ADF)[9] em que evidenciou-se ADF= -0.848 e o Valor-p= 0.804, como o Valor-p é superior ao valor crítico de 0.05, indica-se que não se pode rejeitar a hipótese nula de que a série possui uma raiz unitária, indicando que a série não é estacionária no estado original.

A partir do resultados da não estacionaridade seria necessária a diferenciação da série original para tornar a série estacionária, isso implica no uso do modelo ARIMA (p, d, q) com d = 1. Após a primeira diferenciação os autores obtiveram um teste ADF e um Valor-p[10] que configuram uma série estacionária confirmando a abertura para utilização do modelo ARIMA.

Após a confirmação do uso do modelo ARIMA, os autores utilizaram a metodologia Box-Jenkins, essa metodologia é "um processo sistemático de identificar, estimar e diagnosticar modelos de séries temporais ARIMA"(Silva *et al.*, 2025, p. 6). São quatro passos para aplicação dessa metodologia: identificação, estimação, diagnóstico e previsão.

Na fase de identificação os autores usam a Função de Autocorrelação (FAC) e a Função de Autocorrelação Parcial (FACP) para determinar a estrutura do modelo. A seleção do

[7] Assume-se que é estacionário.

[8] Enquanto o recorte de Silva *et al.* (2025) foi de cerca de 33 anos (1990-2023), o nosso será relativamente menor, de 2007 à 2022 (15 anos), devido a disponibilidades de outras variáveis que não somente o PIB.

[9] A fim de organizar nossa pesquisa trataremos de forma compilada todos os testes na sessão 2.3, nela esmiuçaremos os testes que comprovam a utilização dos modelos, assim como os testes que serão usados para comparar os diferentes modelos.

[10] A fim de curiosidade os valores dos teste foram: teste ADF (Série Diferenciada): -3.771 e um Valor-p: 0.00321.

modelo é feita a partir de critérios de informação, como o Critério de Informação de Akaike (AIC) e Critério de Informação Baysiano (BIC). Para a avaliação dos resíduos[11] usaram o teste Ljung-Box e o teste Jarque-Bera. O último passo é a previsão, passo esse que os autores fizeram uma extrapolação de 6 anos[12] e compararam com a estimativa do PIB realizada pelo Fundo Monetário Internacional (FMI).

Na fase de identificação os testes FAC e FACP apresentaram ambos com um pico no lag 1, com um decaimento nos lags seguintes. O pico no lag 1 no teste FAC apresenta um comportamento de Média Móvel (MA) fora do intervalo de confiança, assim apresentam que o parâmetro (q) da MA seria igual a 1. Já no teste FACP o pico no lag 1, sugere um comportamento de Auto-Regressivo (AR) de ordem 1, ou seja $(p = 1)$. Configurando o modelo obtido sendo ARIMA(1,1,1).

Contudo os autores não somente estimaram o modelo ARIMA(1,1,1). No processo de estimativa, os atores testaram outros quatro modelos com $p - value < 0.05$. Contudo dentre esses que foram testados, o modelo ARIMA(1,1,1) obteve os resultados mais competitivos, quanto menor melhor, nos critérios AIC e BIC[13]

No sentido dos resíduos os autores aplicaram o teste de Ljung-Box[14], onde foi confirmado a ausência de autocorreção significativa, além disso foi aplicado o teste de Jarque-Bera para verificar a distribuição dos resíduos, contudo o teste indicou que os resíduos não seguem uma distribuição normal, o que por si só não é um problema, que apesar de preferível, a não normalidade dos resíduos não descarta o modelo ARIMA(1,1,1). A partir da análise gráfica e da Função de Autocorrelação dos Resíduos (FAC) os autores chegaram a conclusão que o modelo ARIMA ajustado foi eficiente para remover a estrutura de autocorrelação dos dados, restando somente um ruído branco.

Para validar o modelo os autores compararam a projeção do ARIMA(1,1,1) para os 6 anos seguintes com a projeção feita pelo FMI, como justificava para tal comparação os autores elencaram como o FMI utiliza em sua projeções mais variáveis, com complexidade maior. Dessa forma, o modelo ARIMA apresentou uma capacidade satisfatória para capturar a estrutura temporal do PIB brasileiro. Porém os autores ainda elencam possíveis falhas do modelo, como as limitações ao modelar choques econômicos e o viés potencialmente otimista do ARIMA em

[11] Os autores apresentam que o comportamento dos resíduos devem ser independentes, não podem apresentar uma autocorrelação significante e idealmente devem apresentar uma distribuição normal.
[12] De 2024 à 2029.
[13] A fim de curiosidade os valores dos testes são: AIC=1.878.932 e BIC=1.884.038.
[14] estatística de Ljung-Box = 10,69, valor-p = 0,38

comparação as projeções do FMI.

Os autores apontam que

> Apesar da utilidade do ARIMA como ferramenta inicial para análise e previsão de séries temporais econômicas, suas estimativas devem ser interpretadas com cautela e, preferencialmente, complementadas por métodos qualitativos e modelos econométricos que considerem o amplo espectro de variáveis que afetam o crescimento do PIB. Essa integração entre abordagens quantitativas e qualitativas potencializa a confiabilidade das projeções e contribui para decisões mais fundamentadas no âmbito da política econômica. (Silva *et al.*, 2025, p. 15)

A conclusão dos autores vai de encontro com o objetivo que propomos para o ARIMA no presente trabalho: atuar como um modelo inicial e de comparação com os modelos seguintes, como uma métrica de simplicidade e eficiência em comparar os padrões do PIB no decorrer do tempo.

Mas não é somente no Brasil que o modelo ARIMA é utilizado, este modelo continua sendo apresentado como alternativa relevante dentro da predição econômica univariada em todo o mundo. A dissertação de mestrado de Li (2024) é uma prova de como o modelo ainda vem sendo utilizado e testado até nos dias presentes, em economias complexas como a estadunidense.

Em seu trabalho Li (2024) avalia o desempenho de diferentes modelos em cenários de choques econômicos, especificamente o mais recente do período[15] que abrangeu a pandemia do COVID-19. Nesse trabalho um dos modelos testados foi o próprio modelo ARIMA para a predição do Gross Domestic Product (GDP)[16] ele foi utilizado no mesmo sentido que pretendemos utilizá-lo como um modelo comparativo de teste, para avaliar o desempenho de outros modelos avaliados.

Os dados da dissertação foram obtidos do Federal Reserve Economic Data (FRED)[17]. A partir dos testes realizados comprovou-se que "O PIB é uma série temporal estacionária ao nível de significância de 5% pelo ADF"(Li, 2024, p.22, tradução nossa) confirmando uma série estacionária, assim d=0. Na aplicação dos testes FAC e FACP a autora identifica que os picos ficaram em 0 para a FAC (MA) e também para FACP (AR) com o lag em 0, configurando o modelo ARIMA(0, 0, 0). No sentido da estatística de Ljung-Box também não apresentou "evidências significativas contra as autocorrelações de defasagem serem 0"(Li, 2024, p.25, tradução nossa).

[15] O recorte de tempo de Li (2024) foi de 1960 até 2023

[16] O GDP é o equivalente ao nosso PIB

[17] Dados Econômicos da Reserva Federal, trata-se de uma banco de dados americanos com dados financeiros, econômicos e demográficos dos Estados Unidos da América (EUA)

Ao aplicar os diferentes testes e modificar os parâmetros do ARIMA para os dados de treinamento, comprovou-se que o modelo que mais se aproximou do resultado esperado foi o ARIMA(1, 0, 2), e dentre os modelos de *benchmark* foi o que obteve os melhores resultados[18]. O modelo ARIMA performa de uma maneira satisfatória inclusive contra os modelos de multivariados complexos testados[19].

Assim como apontado por Silva *et al.* (2025) o modelo ARIMA ainda tem suas limitações. A partir dos resultados de Li (2024) conseguimos ver essas limitações, que comparado a alguns modelos multivariados o modelo ARIMA falha em capturar a realidade com precisão devido a suas simplificações.

De todo modo, podemos confirmar o ARIMA como o candidato perfeito como modelo de teste, configurado com um baixo custo computacional, desempenho formidável e relativa aplicação simplificada. O modelo ARIMA será utilizado em nosso trabalho como modelo comparativo. Veremos mais sobre a aplicação do ARIMA no capítulo 4 onde veremos o desempenho do mesmo semelhante ao olhar de Silva *et al.* (2025), mas com o princípio comparativo de Li (2024).

O modelo ARIMA, e no geral todos os modelos univariados têm um problema, a limitação estrutural do modelo. Afinal variáveis complexas, como o próprio PIB, sofrem de influências de diferentes variáveis - e de todas as naturezas, desde dados intimamente ligados a variável escolhida, até dados que parecem não ter relação alguma. Entretanto para afirmar ou rejeitar essa disposição, são necessários testes de correlação e modelos que realmente suportem indicar um certo grau de predição usando relações que não são univariadas. Esses modelos serão tratados a partir desse ponto no presente estudo.

2.2.1.2 VAR

O modelo VAR é o primeiro modelo multivariado que nos debruçaremos em sua composição, utilização e aplicabilidade à predição do PIB. Seguindo nossa trilha didática, espera-se que o modelo VAR seja naturalmente mais complexo que modelos univariados - como o ARIMA. E de certa forma é isso que acontece, mas não quer dizer que a interpretabilidade do modelo, no sentido natural, se altere. Muito pelo contrário o VAR continua sendo um modelo

[18] Os modelos de *benchmark* foram: o modelo ETS e a regressão de transformada de Fourier, e obtiveram resultados parecidos, mas ligeiramente piores que o ARIMA

[19] No caso dessa dissertação os modelos complexos eram do tipo PCA, que são multivariados e mais complexos do que o ARIMA, mesmo assim o modelo performou melhor nos dados de treinamento e validação melhor que modelos de complexidade maior

intuitivo e explicável no âmbito das relações entre variáveis.

Nesse sistema complexo de relações, há uma infinidade de variáveis podem ser aplicadas, e modelos que conseguem identificar essas relações, mesmo que de forma limitada[20], são essenciais, não se trata mais de modelar a relação da variável e sua série temporal, mas sim identificar a relação de diferentes variáveis umas com as outras e com o tempo.

Entendido onde os modelos multivariados se encaixam na predição estatística, falaremos sobre o modelo escolhido, o VAR. O acrônimo VAR vem de *Vector Autoregression* trata-se de um modelo estatístico descrito pela primeira vez por Sims (1980), surgindo da necessidade de modelar sistemas multivariados reais[21], não em situações puramente hipotéticas e teóricas.

Sims (1980) ajustou séries temporais trimestrais do período pós-guerra dos EUA e da Alemanha Ocidental sobre dinheiro, Produto Nacional Bruto (PNB)[22], taxa de desemprego, nível de preços e índice de preços de importação, usando uma autoregressão vetorial sem restrições.

Esse trabalho nos forneceu a metodologia para aplicar o VAR sem as restrições teóricas fortes de identificação estrutural de modelos anteriores. A partir dessa aplicação Sims (1980) apresentou as características do que hoje chamamos de VAR. Trata-se de um sistema de equações multivariadas que evita impor conhecimentos a *priori*, ou seja, o modelo trata todas as variáveis como endógenas[23].

Sims (1980) discorre sobre a aplicabilidade do VAR, e aponta que modelos anteriores, mesmo os multivariados, assumem a exogeneidade das variáveis. Segundo o autor esses modelos dificultam capturar interdependências dinâmicas entre variáveis como as interações entre o lado real (produção) e o lado monetário da economia (inflação dos preços).

O modelo VAR descrito por Sims (1980) apesar de conceitualmente definido, ainda sofreu modificações, o modelo atual que usaremos pode ser visualizado pelas equações 2.2 e 2.3, em suas variações com menor e maior defasagem, consultadas de (Costa, s.d.).

Uma série temporal multivariada $\mathbf{r_t} = (r_{1t}, r_{2t}, ..., r_{kt})'$ composta por k componentes no tempo t é um processo VAR(1), que segue o modelo:

[20] Ao aplicar o VAR não é possível lidar com a "infinidade"de variáveis, somente com algumas dezenas no máximo, contudo existem modelos mais avançados - ainda tradicionais - que lidam bem com centenas de variáveis, veremos esses em breve.

[21] Inclusive surge em um contexto de modelar variáveis macroeconômicas - como o PIB - afinal o título do ensaio de Sims (1980) é justamente Macroeconomia e Realidade

[22] O PNB diferencia-se do PIB, pois o PNB leva em conta renda líquida enviada e recebida do exterior, ou seja para nações com muitas multinacionais a tendencia é PNB > PIB, já em nações dependentes de empresas estrangeiras em solo nacional a tendência é o PIB > PNB

[23] Variáveis endógenas são aquelas determinadas dentro do próprio sistema de equações.

$$r_t = \phi_0 + \Phi r_{t-1} + a_t \tag{2.2}$$

onde

a) ϕ_0 é um vetor de dispersão k;
b) Φ é uma matriz $k \times k$; e
c) a_t é um ruído branco formado por uma sequência de vetores aleatórios independentes, distribuídos de forma idêntica, com média 0 e matriz de covariância $\sum a$.

Já para modelos com uma defasagem maior, usá-se o VAR(p), nele uma série temporal multivariada $\mathbf{r_t} = (r_{1t}, r_{2t}, ..., r_{kt})'$ com $p > 0$:

$$r_t = \phi_0 + \Phi_1 r_{t-1} + ... + \Phi_p r_{t-p} + a_t \tag{2.3}$$

onde

a) ϕ_0 é um vetor de dispersão k;
b) Φ são matrizes $k \times k$ para $j = 1, ..., p$; e
c) a_t é um ruído branco formado por uma sequência de vetores aleatórios independentes, distribuídos de forma idêntica, com média 0 e matriz de covariância $\sum a$.

Em sua dissertação, Azevedo (2020) usou o modelo modelo de vetores auto-regressivos (VAR) para análise de séries temporais com variáveis macroeconômicas. Já Fialho *et al.* (2024) usaram o VAR para entender a dinâmica entre incerteza, spread bancário, crédito, consumo, rendimento e taxa de desocupação.

2.2.1.3 DFM

Alves (2009) em sua dissertação de mestrado abordou modelos de fatores dinâmicos (do inglês *Dynamic Factor Models* - DFM) para entender o núcleo da inflação brasileira. Por outro lado Moura *et al.* (2020) avaliou os ciclos econômicos brasileiros usando uma combinação entre o DFM e o VAR.

2.2.1.4 MIDAS

Castelli (2022) abordou o uso do modelo de amostragem de dados mistos (do inglês *Mixed Data Sampling* - MIDAS) para predizer o PIB com a pesquisa industrial mensal. Assim

como Micheletti (2024) usou modelos de *ensemble stacking* [24] (dentre eles o MIDAS) para prever o PIB.

2.2.2 Modelos de IA: Uma explanação

Os modelos que chamamos de IA, são na realidade modelos não-lineares modernos[25], estes não assumem a linearidade nos parâmetros dos preditores do modelo, isso ocasiona implicações na interpretabilidade dos modelos (Vasconcelos, 2017, p. 22). Os modelos de IA "utilizam funções específicas que permitem realizar previsões mediante a atribuição de pesos, que são medidos e alterados por uma função de ativação que busca diminuir o erro de um modelo, que tende a ser muito mais preditivo do que analítico."(Carmo e Lopacinski, 2023, p.10)

2.2.2.1 Redes Neurais

As redes neurais tem a capacidade de estimar associações não lineares em seu processo preditivo (Vasconcelos, 2017). Esses modelos se baseiam no aprendizado por

2.2.2.2 Florestas Aleatórias

2.3 Testes: Comprovar e comparar modelos

2.4 IA vs Tradicional: Uma perspectiva Acadêmica

[24] *ensemble stacking*: modelos combinados

[25] Existem modelos considerados tradicionais não-lineares como as árvores de decisão, porém sua interpretabilidade é natural

3 METODOLOGIA

3.1 Delineamento de pesquisa

Com base nos objetivos da presente pesquisa, a mesma se classifica como explicativa. Esse tipo de pesquisa "têm como preocupação central identificar os fatores que determinam ou que contribuem para a ocorrência dos fenômenos."(Gil, 2002, p. 87). Ao analisarmos o desempenho dos diferentes modelos econométricos voltados para a predição do PIB brasileiro, estamos buscando identificar e compreender os diferentes fatores que explicam esse desempenho, enquadrando-a como explicativa.

Sobre os procedimentos de coleta de dados, a presente pesquisa se enquadra como documental, por utilizar-se de dados que não receberam um tratamento e estão dispostos em repositórios digitais de dados. Segundo Gil (2002) a pesquisa documental apropria-se de diversas fontes, não somente material impresso em bibliotecas, onde os documentos utilizados podem ter um tratamento analítico ou não.

Por fim, ao se tratar de uma pesquisa que compara diferentes modelos econométricos, assim como avalia o desempenho dos mesmos, seguindo o rigor matemático e estatístico, ela se enquadra como uma pesquisa predominantemente quantitativa onde apropria-se do método comparativo e estatístico. Para Lakatos e Marconi (2003) o método estatístico trata-se da redução dos fenômenos a termos quantitativos e a manipulação estatística, onde possibilita a generalizações sobre sua natureza, ocorrência ou significado. Já "o método comparativo é usado tanto para comparações de grupos."(Lakatos e Marconi, 2003, p. 107, 108).

3.2 Procedimento de coleta de dados

As variáveis foram escolhidas baseadas na dissertação de Rebelo (2022), descritas mais evidentemente na sessão 2. As variáveis escolhidas podem ser verificadas na tabela 1. Os dados utilizados na pesquisa foram extraídos de duas APIs (*Application Programming Interface*, no português, Interface de programação de aplicações). A relação variável - Fonte - URL da API pode ser vericada na mesma tabela.

A primeira fonte foi a API de dados agregados do IBGE, onde nela existem informações econômicas, sociais e demográficas do Brasil.

O IBGE possui uma Application Program Interface (API) de serviços de dados abertos que disponibiliza dados processáveis por máquina para qualquer cidadão

> ou sistema, permitindo a interoperabilidade e o enriquecimento a partir dos dados abertos disponibilizados. (Silva e Silva, 2024, p. 2).

A segunda API utilizada foi a API do BACEN (Banco Central do Brasil), onde foram extraídos dados financeiros. Segundo o próprio BACEN (2025) o "catálogo de dados, permite que os usuários encontrem os conjuntos de informações de seu interesse, entendam sua estrutura e suas limitações, e tenham acesso ao caminho para os dados."

O período analisado foi de 2007 à 2022, devido a disponibilidade de datas nas bases de dados.

3.3 Procedimento de análise de dados

A análise dos dados é um processo muito importante ao usar modelos matemáticos, conforme Kilkenny e Robinson (2018) a qualidade das respostas depende diretamente dos dados usados [1]. Ou seja, não basta ter fontes confiáveis como o (BACEN, 2025) e o (IBGE, 2025a), é necessário um procedimento confiável de ponta a ponta. Para esse processamento dos dados, foi utilizado a linguagem de programação *Python* [2] e suas bibliotecas.

O primeiro processo de tratamento foi a conversão dos tipos nativos das APIs para um formato adequado para análise com Python, isso foi feito através da biblioteca Pandas. "Pandas é uma biblioteca de Python de estruturas de dados e ferramentas estatísticas, inicialmente desenvolvida para aplicações de finanças quantitativas."(McKinney, 2010, p. 1, *tradução nossa*).

O segundo passo de tratamento foi a inflação dos dados para 2022, último ano da série, isso foi feito através de um índice de preços, que pode verificado na equação 3.1. O IBGE (2025b) traz a definição de deflator do PIB, porém que se aplica as demais variáveis, em que um deflator é a variação do valor corrente da variável no tempo (t) em relação ao valor da varável do ano (t) a preços do ano anterior, ou seja a variação percentual em relação ao mesmo período do ano anterior.

$$\text{Valor real} = \frac{\text{Valor Nominal}}{\text{índice de Preços}} \times 100 \tag{3.1}$$

O terceiro passo de tratamento foi o treinamento dos modelos. Nesse passo foram utilizados as bibliotecas Scikit-learn e Tensorflow, os modelos foram treinados com dados de 2007 à 2017, totalizando 10 anos na série histórica (dados de treinamento), e deixando os últimos

[1] O termo coloquial em inglês para essa situação se chama GIGO ou *Garbage In Garbage Out*, que em tradução livre - lixo entra lixo sai.

[2] Python é amplamente utilizado em computação científica e numérica (Python, 2023)

Tabela 1 – Fontes de dados utilizadas nas APIs do IBGE e BACEN

Indicador	**Fonte**	**URL / Endpoint da API**
PIB	IBGE	https://servicodados.ibge.gov.br/api/v3/agregados/6784/periodos/-20/variaveis/9808?localidades=N1[all]
Deflator do PIB	IBGE	https://servicodados.ibge.gov.br/api/v3/agregados/6784/periodos/-20/variaveis/9811?localidades=N1[all]
população (milhões)	IBGE	Aindanaocoletado
índice de direitos de propriedade	IBGE	Aindanaocoletado
índice de eficiência jurídica	IBGE	Aindanaocoletado
índice de integridade governamental	IBGE	Aindanaocoletado
índice de despesa governamental	IBGE	Aindanaocoletado
despesa pública em educação (% PIB)	IBGE	Aindanaocoletado
despesa pública em saúde (% PIB)	IBGE	Aindanaocoletado
despesa pública em proteção ambiental (% PIB)	IBGE	Aindanaocoletado
índice de carga fiscal	IBGE	Aindanaocoletado
índice de saúde fiscal	IBGE	Aindanaocoletado
dívida publica (% PIB)	IBGE	Aindanaocoletado
índice de liberdade empresarial	IBGE	Aindanaocoletado
índice de liberdade laboral	IBGE	Aindanaocoletado
taxa de desemprego	IBGE	Aindanaocoletado
índice de liberdade monetária	IBGE	Aindanaocoletado
taxa de inflação	IBGE	Aindanaocoletado
índice de liberdade comercial	IBGE	Aindanaocoletado
balança corrente	IBGE	Aindanaocoletado
Taxa aduaneira	IBGE	Aindanaocoletado
índice de liberdade investimento	IBGE	Aindanaocoletado
investimento direto estrangeiro (% PIB)	IBGE	Aindanaocoletado
índice de liberdade financeira	IBGE	Aindanaocoletado

5 anos (2017 à 2022) para a testagem dos resultados do modelo. Para Santos e Nolau (2022) as eficácias dos modelos nos dados de treinamento não são importantes, o que é relevante é como o modelo se sai com os dados de teste, ou seja, se o modelo consegue ser extensivo no período fora da amostra.

O último passo foi o cálculo das métricas de avaliação dos modelos, para esse passo foram avaliadas três dimensões: acurácia, interpretabilidade e custo computacional.

Para a acurácia foram escolhidas as métricas que foram utilizadas por Rebelo (2022): o Erro Quadrático Médio (EQM) descrito na equação 3.2; Erro Absoluto Médio (EAM) descrito na equação 3.3; a Raiz do Erro Quadrático Médio (REQM) descrito na equação 3.4; e por fim, o erro percentual absoluto médio (EPAM) descrito na equação 3.5.

$$\text{EQM} = \frac{1}{n}\sum_{i=1}^{n}(y_i\hat{y}_i)^2 \tag{3.2}$$

$$\text{EQM} = \frac{1}{n}\sum_{i=1}^{n}|y_i\hat{y}_i| \tag{3.3}$$

$$\text{REQM} = \sqrt{\text{EQM}} \tag{3.4}$$

$$\text{EPAM} = \frac{1}{n}\sum_{i=1}^{n}|\frac{y_i\hat{y}_i}{y_i}| \times 100 \tag{3.5}$$

Para Kava (2022) a interpretabilidade está diretamente relacionada a facilidade que um ser humano tem de entender os resultados de um modelo. Para essa dimensão foram usadas as métricas: Efeitos Locais Acumulados (ELA) descrito na equação 3.6; e a interação ente preditores através da estatística-H, descrita na equação 3.7, ambas descritas por Kava (2022).

$$\tilde{f}_j, \text{ELA}(x) = \sum_{k=1}^{k_j(x)} \frac{1}{n_k(k)} \sum_{i:X_j \in N_j(k)} [\hat{f}(z_{k,j}, x_j^{(i)}) - \hat{f}(z_{k-1,j}, x_j^{(i)})] \tag{3.6}$$

$$H_j^2 = \frac{\sum_{i=1}^{n}[\hat{f}(x^{(i)}) - PD_J(X_J^{(I)}) - PD_{-J}(X_{-J}^{(I)})]^2}{\sum_{i=1}^{n}\hat{f}^2(x^{(i)})} \tag{3.7}$$

A última dimensão é o custo computacional, essa se baseará principalmente no tempo de execução dos modelos, e na contagem de operações com ponto flutuantes - FLOPs (do inglês, FLOating Point Operations) em ambas as métricas, quanto mais alto o valor, maior é o custo computacional.

3.4 Constructo da pesquisa

A estrutura do constructo pode ser verificado na tabela 2

Tabela 2 – Constructo da pesquisa

Pergunta de Pesquisa			
Em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro?			
Objetivo Geral			
Analisar em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro.			
Objetivos específicos	**variáveis/dados à coletar**	**Como analisar**	**Fonte**.
Caracterizar os modelos econométricos tradicionais (VAR, ARIMA, DFM e MIDAS) e de IA para a predição do PIB.	Modelos econométrico com capacidade de predizer séries temporais.	Buscar através da literatura modelos já utilizados com esses fins.	Castelli (2022), Azevedo (2020), Azevedo (2020), Ciquini *et al.* (2023), Silva e Silva (2024), Alves (2009), Moura *et al.* (2020) e Micheletti (2024).
Identificar as diferentes variáveis determinantes na estimativa do PIB.	Variáveis com possível influência no PIB com facilidade de coleta e atualização recorrente.	Procurar na literatura quais variáveis são utilizadas para a predição do PIB.	Rebelo (2022), IBGE (2025a) e BACEN (2025).
Aplicar diferentes modelos econométricos tradicionais e de IA para a predição do PIB.	Modelos econométricos e variáveis encontradas nos primeiros dois objetivos.	treinar os diferentes modelos usando os dados coletados através da linguagem de programação Python e suas bibliotecas de estatística.	Castelli (2022), Azevedo (2020), Azevedo (2020), Ciquini *et al.* (2023), Silva e Silva (2024), Alves (2009), Moura *et al.* (2020) e Micheletti (2024).
Comparar o desempenho dos modelos de IA e econométricos tradicionais usando diferentes métricas, como desempenho computacional, precisão e interpretabilidade.	erro Quadrático Médio (EQM), Erro Absoluto Médio (EAM), a Raiz do Erro Quadrático Médio (REQM), erro percentual absoluto médio (EPAM), Efeitos Locais Acumulados (ELA), estatística-H, tempo de execução e FLOPs	Submeter os modelos a testes nas métricas de acurácia, interpretabilidade e custo computacional.	Rebelo (2022) e Kava (2022).

4 RESULTADOS

5 CONCLUSÕES E TRABALHOS FUTUROS

REFERÊNCIAS

ALMEIDA, P. R. d. A economia internacional no século xx: um ensaio de síntese. **Revista Brasileira de Política Internacional**, Centro de Estudos Globais da Universidade de Brasília, v. 44, n. 1, p. 112–136, Jan 2001. ISSN 0034-7329. Disponível em: https://doi.org/10.1590/S0034-73292001000100008.

ALVES, A. P. d. A. **Núcleo da inflação como fator comum do IPCA: uma abordagem do modelo de fator dinâmico generalizado**. Dissertação (Mestrado) – Universidade de São Paulo, 2009.

ASSUNÇÃO, F. **Estratégias para tratamento de variáveis com dados faltantes durante o desenvolvimento de modelos preditivos**. 2012.

AZEVEDO, S. H. A. de. **Modelagem de séries temporais macroeconômicas com vetores autorregressivos aumentados com fator e transição suave sob um enfoque bayesiano**. Dissertação (Mestrado) – [sn], 2020.

BACEN, B. C. do B. **Portal de Dados Abertos do Banco Central do Brasil**. 2025. https://dadosabertos.bcb.gov.br. Acesso em: 16 out. 2025.

BOX, G. E.; JENKINS. **Time series analysis: forecasting and control**. [*S. l.*]: Holden Day, inc, 1970.

BRAGA, I. A. D. **Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning**. 2025.

CARMO, C. R. S.; LOPACINSKI, G. P. Modelagem e previsão de fenômenos socioeconômicos: Uma análise comparativa entre métodos clássicos e contemporâneos. **Revista GeTeC**, v. 13, 2023.

CASTELLI, A. d. C. Modelo midas de projeção do pib brasileiro utilizando a pesquisa industrial mensal. 2022.

CIQUINI, O.; BORBA, A. A. de; GODEGUEZ, P. A. Modelo arima para decisões econômicas. **Proceeding Series of the Brazilian Society of Computational and Applied Mathematics**, v. 10, n. 1, 2023.

COSTA, H. C. **Vector Autoregression (VAR) Tutorial**. s.d. Acesso em: 21 abr. 2026. Disponível em: https://rstudio-pubs-static.s3.amazonaws.com/520691_9092a79ca10245b7bd0d5741d51aa6f8.html.

FIALHO, T. M. M.; CORDEIRO, L. M. C.; TIMOTIO, J. G. M.; REZENDE, L. P. F. de; BOITRAGO, P. R. P. Incerteza, consumo das famílias no brasil e spread bancário: uma análise com o vetor autorregressivo (var). Universidade Federal de Minas Gerais, 2024.

FRISCH, R. Statikk og dynamikk i den økonomiske teori. 1). **Nationalokonomisk Tidsskrift**, v. 37, 1929. Disponível em: https://tidsskrift.dk/nationaloekonomisktidsskrift/article/download/57252/77814.

GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Editora Atlas, 2002.

IBGE, I. B. de Geografia e E. **API de dados agregados do IBGE**. 2025. https://servicodados.ibge.gov.br/api/v3/agregados. Acesso em: 16 out. 2025.

IBGE, I. B. de Geografia e E. **Deflator do Produto Interno Bruto - Séries Históricas**. 2025. https://seriesestatisticas.ibge.gov.br/series.aspx?t=pib&vcodigo=scn54. Acesso em: 16 out. 2025.

IBGE, I. B. de Geografia e E. **O que é o PIB?** 2026. Acessado em: 11 abr. 2026. Disponível em: https://www.ibge.gov.br/explica/pib.php.

JúNIOR, M. F. F. A terceira revolução industrial e o novo paradigma produtivo: Algumas considerações sobre o desenvolvimento industrial brasileiro nos anos 90. **Revista da FAE**, v. 3, n. 2, fev. 2017. Disponível em: https://revistafae.fae.edu/revistafae/article/view/501.

KAGERMANN, H.; WAHLSTER, W.; HELBIG, J. *et al.* Recommendations for implementing the strategic initiative industrie 4.0: Final report of the industrie 4.0 working group. **Forschungsunion: Berlin, Germany**, p. 12–25, 2013.

KAVA, L. E. **Além da caixa preta: aprendizagem de máquina interpretável para previsão de séries temporais macroeconômicas brasileiras**. Dissertação (Mestrado) – Universidade Federal de Santa Catarina, 2022.

KEYNES, J. M. **A Teoria Geral do Emprego, do Juro e da Moeda**. [*S. l.*]: Atlas, 1936.

KILKENNY, M. F.; ROBINSON, K. M. Data quality: "garbage in – garbage out". **Health Information Management Journal**, v. 47, n. 3, p. 103–105, 2018. PMID: 29719995. Disponível em: https://doi.org/10.1177/1833358318774357.

LAKATOS, E. M.; MARCONI, M. de A. **Fundamentos de metodologia científica**. 5. ed. São Paulo: Editora Atlas, 2003.

LAUDON, K.; LAUDON, J. **Sistemas de Informação Gerenciais: Administrando a Empresa Digital**. Bookman, 2022. ISBN 9788582606032. Disponível em: https://books.google.com.br/books?id=NIehEAAAQBAJ.

LI, K. **Forecasting US GDP from 1960 to 2023 using PCA**. 2024. Disponível em: http://dissertations.umi.com/ucla:23601.

MANKIW, N. G. **Introdução à economia**. [*S. l.*]: Bookman Editora, 2025.

MARTINS, G. S. **Indústria 4.0-contribuições tecnológicas para quarta revolução industrial**. [*S. l.*], 2021.

MCKINNEY, W. Data structures for statistical computing in python. **Proceedings of the 9th Python in Science Conference**, p. 51–56, 2010. Disponível em: https://doi.org/10.25080/Majora-92bf1922-00a.

MICHELETTI, A. D. Avaliação de um modelo ensemble stacking de machine learning para previsão do pib do brasil. 2024.

MOURA, B. A.; TIRYAKI, G. F.; TEIXEIRA, D. N. Fragilidade fiscal e os ciclos econômicos no brasil pós-plano real: evidências de um modelo de fator dinâmico associado à análise var. **Nova Economia**, SciELO Brasil, v. 30, n. 2, p. 517–549, 2020.

PYTHON. **Python Language Reference, version 3.12**. [*S. l.*], 2023. Disponível em: https://www.python.org/doc/. Acesso em: 16 out. 2025.

REBELO, M. A. C. **Interpretabilidade de modelos Machine Learning para a previsão macroeconómica**. Dissertação (Mestrado) – Universidade de Lisboa (Portugal), 2022.

SANTANA, A. A.; SILVA, C. R. da; TIMOTEO, L. C. da S.; OLIVEIRA, R. M. de; NARCISO, R. Aprimorando a tomada de decisões empresariais: o papel dos dados, análises de negócios e novas tecnologias. **Revista Ilustração**, v. 4, n. 2, p. 75–83, 2023.

SANTOS, F.; NOLAU, I. **Previsão de inflação: análise preliminar de desempenho de técnicas de machine learning**. [*S. l.*], 2022.

SILVA, P. N.; SILVA, G. V. P. d. Dados abertos do ibge: Recuperação na api de dados agregados. **Encontros Bibli**, SciELO Brasil, v. 29, p. e96185, 2024.

SILVA, T. R. d.; CLERICUZI, A. Z.; CARVALHO, J. N. d. Modelagem de sÉries temporais utilizando arima: PrevisÃo futura do pib brasileiro. **International Contemporary Management Review**, v. 6, n. 2, p. e385, Aug. 2025. Disponível em: https://icmreview.com/icmr/article/view/385.

SIMS, C. A. Macroeconomics and reality. **Econometrica: journal of the Econometric Society**, JSTOR, p. 1–48, 1980.

VASCONCELOS, B. F. B. de. **Poder preditivo de métodos de Machine Learning com processos de seleção de variáveis: uma aplicação às projeções de produto de países**. Tese (Tese de Doutorado) – Universidade de Brasília, Brasília, Brasil, ago. 2017. Faculdade de Economia, Administração, Contabilidade e Gestão de Políticas Públicas (FACE), Departamento de Economia (FACE ECO), Programa de Pós-Graduação em Economia. Disponível em: http://dx.doi.org/10.26512/2017.03.D.23995.

VASCONCELOS, M. **Atlas de Economia**. 2. ed. São Paulo: Editora Atlas, 2020. Define conceitos de macroeconomia e apresenta indicadores econômicos.