



**UNIVERSIDADE FEDERAL DA FRONTEIRA SUL
CAMPUS LARANJEIRAS DO SUL
CIÊNCIAS ECONÔMICAS**

LEONILSO FANDRES WRUBLAK

**AS MÁQUINAS ECONÔMICAS: PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO
INTELIGÊNCIA ARTIFICIAL**

LARANJEIRAS DO SUL - PR

2026

LEONILSO FANDRES WRUBLAK

**AS MÁQUINAS ECONÔMICAS: PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO
INTELIGÊNCIA ARTIFICIAL**

Trabalho de Conclusão de Curso apresentado ao
Curso de Ciências Econômicas da Universidade
Federal da Fronteira Sul (UFFS), como requisito
para obtenção do título de Bacharel em Ciências
Econômicas.

Orientador: Prof. Dr. Alexandre Manoel dos Santos (UFFS)

LARANJEIRAS DO SUL - PR

2026

LEONILSO FANDRES WRUBLAK

AS MÁQUINAS ECONÔMICAS:

PREDIÇÃO DO PIB BRASILEIRO UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado ao Curso de Ciências Econômicas da Universidade Federal da Fronteira Sul (UFFS), como requisito para obtenção do título de Bacharel em Ciências Econômicas.

Este trabalho foi defendido e aprovado pela banca em DD/MM/AAAA.

BANCA EXAMINADORA

Prof. Dr. Alexandre Manoel dos Santos - UFFS
Orientador

Professor(a) 1
Avaliador

Professor(a) 2
Avaliador

Dedico esse trabalho a todos que um dia sonharam em construir um mundo melhor com base no esforço e no trabalho!

AGRADECIMENTOS

Agradeço primeiramente a Deus por me permitir viver e poder construir este trabalho, seguidamente a minha esposa Bruna Raphaella Fernandes Wrublak, que me apoiou durante as noites em que estava sentado escrevendo, ao meu pai Leonildo Savoldi Wrublak e minha mãe Eli Piltz Fandres Wrublak que sempre me inspiraram e me incentivaram a estudar cada vez mais, a minha irmã Leoneli Fandres Wrublak dos Santos e meu cunhado Bruno dos Santos que foram espelhos de trabalho e dedicação, e a todo restante de minha família que esteve comigo nessa jornada. Um agradecimento especial ao meu orientador professor Doutor Alexandre Manoel dos Santos por me dar o suporte necessário para a construção dessa pesquisa, assim como agradeço a todos os meus outros professores, saibam que a profissão que escolheram para a vida inspiram milhões de pessoas pelo mundo todos os dias. Agradeço também aos meus colegas e amigos, que me acompanharam nas matérias difíceis e nos momentos especiais dentro dessa Universidade. A todos o meu profundo e sincero muito obrigado!

"De fato, sabemos muito pouco sobre o futuro. A base real para formar expectativas sobre o rendimento futuro de um investimento é extremamente frágil. Nossas decisões de investimento [...] dependem de um estado de confiança. Muitas vezes, sabemos que não sabemos; mas mesmo assim temos que agir."

(Keynes, 1936, p. 161)

RESUMO

A incerteza é um desafio grande na vida dos gestores, sejam eles públicos ou privados, e o combate a incerteza se dá pela busca de informações, o risco é inversamente proporcional ao conhecimento que temos sobre determinado assunto, e o conhecimento só se dá pela interpretação das informações obtidas através de um processo de mineração de dados, quando falamos de poucos dados, os modelos tradicionais de previsão conseguem acertar com um determinado nível de precisão, mas quando queremos resultados mais precisos, ou que nossos dados são mais complexos, evento este, cada vez mais comum na era do *big-data*, os modelos tradicionais de previsão encontram limitações, nesse sentido a presente monografia busca responder como desenvolver um modelo preditivo baseado em IA para efetivamente estimar o PIB brasileiro, considerando as diferenças e semelhanças significativas entre os modelos tradicionais VAR, ARIMA, DFM e MIDAS. Para isso se utilizará de métodos quantitativos visando estimar a acurácia, custo computacional e interpretabilidade dos modelos testados, para enfim determinar se modelos de IA conseguem reduzir a incerteza.

Palavras-chave: Inteligência Artificial; PIB brasileiro; Métodos Quantitativos; Testes de modelos.

ABSTRACT

Uncertainty poses a major challenge for managers in both the public and private sectors, and addressing it requires the pursuit of information; risk is inversely proportional to one's knowledge of a given subject, and such knowledge is gained by interpreting information obtained through data mining. While traditional forecasting models achieve a certain level of accuracy when dealing with limited datasets, they encounter limitations when higher precision is required or when dealing with complex data—a scenario increasingly common in the era of big data. Accordingly, this study aims to determine how to develop an AI-based predictive model to effectively estimate Brazil's GDP, taking into account the significant differences and similarities among traditional models such as VAR, ARIMA, DFM, and MIDAS. To this end, quantitative methods will be employed to assess the accuracy, computational cost, and interpretability of the models tested, ultimately determining whether AI models can reduce uncertainty.

Keywords: Artificial Intelligence; Brazilian GDP; Quantitative methods; Model testing.

LISTA DE ILUSTRAÇÕES

Figura 1 – Perceptron	42
Figura 2 – Função Sigmoidal	45
Figura 3 – Função de erro quadrático.	46
Figura 4 – Função de erro quadrático e segmentos de retas tangentes representando a derivada em diferentes pontos.	46
Figura 5 – Superfície de erro	47

LISTA DE TABELAS

Tabela 1 – Tabela verdade da operação XOR	43
Tabela 2 – Fontes de dados utilizadas nas APIs do IBGE e BACEN	57
Tabela 3 – Constructo da pesquisa	59

LISTA DE SIGLAS

ADF	Dickey-Fuller aumentado
AIC	Critério de Informação de Akaike
AR	Auto-Regressivo
ARIMA	<i>AutoRegressive Integrated Moving Average</i>
BEA	<i>Bureau of Economic Analysis</i>
BIC	Critério de Informação Baysiano
DCA	Declaração de contas Anuais
DFM	<i>Dynamic Factor Model</i>
EUA	Estados Unidos da América
FAC	Função de Autocorrelação
FACP	Função de Autocorrelação Parcial
FMI	Fundo Monetário Internacional
FRED	<i>Federal Reserve Economic Data</i>
GDP	<i>Gross Domestic Product</i>
IA	Inteligência Artificial
IBGE	Instituto Brasileiro de Geografia e Estatística
IPCA	Índice de Preços ao Consumidor Amplo
IPEA	Instituto de Pesquisa Econômica Aplicada
LTS	<i>Long-Short Term</i>
MA	Média Móvel
MCMC	<i>Markov Chain Monte Carlo</i>
OCDE	Organização para a Cooperação e Desenvolvimento Econômico
PIB	Produto Interno Bruto
PIM	Produto Industrial Mensal
PNB	Produto Nacional Bruto
PP	Phillips Perron
QDCC	Quadro de Detalhamento das Contas Contábeis
RMSE	<i>Root Mean Square Error</i>
RNN	<i>Recurrent Neural Network</i>
SELIC	Sistema Especial de Liquidação e Custódia
SIDRA	Sistema de Recuperação Automática de dados

VAR Vetores Autoregressivos

VEC Modelo Vetorial de Correção de Erro

SUMÁRIO

1	INTRODUÇÃO	13
1.1	Problema de pesquisa	14
1.2	Objetivos	15
1.2.1	<i>Objetivo Geral</i>	15
1.2.2	<i>Objetivos Específicos</i>	15
1.3	Justificativa	15
2	REVISÃO DE LITERATURA	17
2.1	Predição Econômica: O PIB	17
2.2	Modelos preditivos	20
2.2.1	<i>Modelos Tradicionais: Uma explicação</i>	21
2.2.1.1	<i>ARIMA</i>	21
2.2.1.2	<i>VAR</i>	27
2.2.1.3	<i>MIDAS</i>	35
2.2.1.4	<i>DFM</i>	38
2.2.2	<i>Modelos de Inteligência Artificial (IA): Uma explicação</i>	39
2.2.2.1	<i>Redes Neurais</i>	41
2.2.2.2	<i>Random Forest</i>	53
3	METODOLOGIA	55
3.1	Delineamento de pesquisa	55
3.2	Procedimento de coleta de dados	55
3.3	Procedimento de análise de dados	56
3.4	Constructo da pesquisa	59
4	RESULTADOS	60
5	CONCLUSÕES E TRABALHOS FUTUROS	61
	REFERÊNCIAS	62

1 INTRODUÇÃO

Para onde vamos? uma das questões fundamentais da natureza humana, estudada pelas mais diferentes ciências, desde exatas às sociais. Dentre as ciências que buscam a resposta do para onde iremos, temos a economia, uma ciência que encontra-se no meio termo, a chamada social aplicada. Inicialmente pode parecer estranho, mas boa parte do trabalho de um economista é entender os fatos passados e presentes para predizer (ou tentar) o futuro, mas a pergunta que fica é por quê a economia se preocupa tanto com o futuro?

Para Mankiw (2025, p. 1) "a economia é o estudo de como a sociedade administra seus recursos escassos", é essa escassez ¹ que é o motivador para a preocupação com o futuro, afinal se tivéssemos recursos ilimitados não haveria motivo para estudar economia. Mas este não é o caso, existe limitação de recursos, e devemos saber qual é a melhor maneira de alocar esses recursos.

Para um melhor enfoque, a economia se subdivide em duas grandes áreas, a microeconomia, voltada para o estudo da firma (empresas), e a macroeconomia, que estuda os agregados econômicos (Vasconcelos, 2020)

No presente trabalho nos voltaremos para a macroeconomia, área da economia que surge no início do século XX, devido as intensas mudanças sociais, políticas e econômicas que ocorreram no período, a principal obra referência da macroeconomia é o livro de John Maynard Keynes: *Teoria Geral do Emprego, do Juro e da Moeda* 1936, onde o autor traz os principais fundamentos da macroeconomia que é estudada hoje na academia e executada nos governos.

Um desses conceitos fundamentais que Keynes aborda é a noção de incerteza

De fato, sabemos muito pouco sobre o futuro. A base real para formar expectativas sobre o rendimento futuro de um investimento é extremamente frágil. Nossas decisões de investimento [...] dependem de um estado de confiança. Muitas vezes, sabemos que não sabemos; mas mesmo assim temos que agir. (Keynes, 1936, p. 161)

Com essa noção de incerteza definida por Keynes podemos relacionar com aquela nossa questão fundamental, gestores mundiais, sejam eles públicos ou privados, buscam maneiras de observar dados históricos e com um certo intervalo de confiança tentar "prever o futuro", para justamente, combater a incerteza.

A incerteza gera perguntas, e encontrar as respostas para essas perguntas vai muito além da impressão pessoal do gestor. Os gestores precisam de informação para suas decisões, e

¹ escassez: natureza limitada dos recursos da sociedade (Mankiw, 2025, p. 1)

para Laudon e Laudon (2022) os sistemas de informação são essenciais para alcançar objetivos estratégicos dos negócios. Na era digital, o grande volume de dados gerados pelos sistemas de informação podem ser usados como fontes, praticamente inesgotáveis de dados.

Esses grandes volumes de dados, gerados pelos sistemas de informação, são chamados de *big data*. Para (Vasconcelos, 2017, p. 9) "O *big data* caracterizado por grandes bases de dados com um número elevado de preditores relativos às observações disponíveis". Contudo, somente ter os dados não é o suficiente, e converter esse grande volume de dados em informações não é uma tarefa simples, e exige técnicas sofisticadas de coleta, tratamento e modelagem. Os processos de coleta e tratamento, apesar de fundamentais, serão usados somente como passos anteriores ao da modelagem, que é o enfoque desse texto.

1.1 Problema de pesquisa

Avaliar modelos na previsão de variáveis econômicas não é um processo novo, muitos autores já usaram diversas vezes esses modelos.

Em sua dissertação, Azevedo (2020) usou o modelo modelo de vetores auto-regressivos (VAR) para análise de séries temporais com variáveis macroeconômicas. Já Fialho *et al.* (2024) usaram o VAR para entender a dinâmica entre incerteza, spread bancário, crédito, consumo, rendimento e taxa de desocupação.

Ciquini *et al.* (2023) avaliou o uso do modelo auto-regressivo de médias móveis (do inglês *AutoRegressive Integrated Moving Average* - ARIMA) para tomada de decisões econômicas. Agora Silva *et al.* (2025) apoiaram-se no ARIMA para a predição do PIB brasileiro.

Alves (2009) em sua dissertação de mestrado abordou modelos de fatores dinâmicos (do inglês *Dynamic Factor Models* - DFM) para entender o núcleo da inflação brasileira. Por outro lado Moura *et al.* (2020) avaliou os ciclos econômicos brasileiros usando uma combinação entre o DFM e o VAR.

Castelli (2022) abordou o uso do modelo de amostragem de dados mistos (do inglês *Mixed Data Sampling* - MIDAS) para prever o PIB com a pesquisa industrial mensal. Assim como Micheletti (2024) usou modelos de *ensemble stacking*² (dentre eles o MIDAS) para prever o PIB.

A maioria desses autores trabalharam com o que se chamam modelos tradicionais de predição, esses modelos se baseiam em variáveis e proposições bem definidas, o que pode

² *ensemble stacking*: modelos combinados

não ser o caso na era do *big data*. Nesse contexto, em que os modelos tradicionais encontram-se limitados, que a inovação surge, nesse caso o uso de técnicas de IA para modelar variáveis econômicas.

Diante do disso a presente pesquisa tende a seguir os passos de Kava (2022) e de Rebelo (2022) que comparam, em suas dissertações, modelos de IA com os chamados modelos tradicionais. Contudo, a nossa pesquisa se diferencia dos trabalhos produzidos por testar outros modelos e focar especificamente no PIB brasileiro, para isso norteia-se pela seguinte pergunta: Como desenvolver um modelo preditivo baseado em IA para efetivamente estimar o PIB brasileiro, considerando as diferenças e semelhanças significativas entre os modelos tradicionais VAR, ARIMA, DFM e MIDAS.

1.2 Objetivos

1.2.1 Objetivo Geral

Desenvolver um modelo preditivo baseado em IA para efetivamente estimar o PIB brasileiro, considerando as diferenças e semelhanças significativas entre os modelos tradicionais VAR, ARIMA, DFM e MIDAS.

1.2.2 Objetivos Específicos

- a) Caracterizar os modelos econométricos tradicionais (VAR, ARIMA, DFM e MIDAS) e de IA para a predição do PIB;
- b) Identificar as diferentes variáveis determinantes na estimativa do PIB;
- c) Desenvolver um ciclo de vida para a produção de um novo modelo econométrico de IA para a predição do PIB;
- d) Comparar o desempenho dos modelos de IA e tradicionais usando diferentes métricas, como desempenho computacional, precisão e interpretabilidade.

1.3 Justificativa

O presente trabalho justifica-se empiricamente, pois permite que gestores, sejam eles públicos ou privados, utilizem-se de ferramentas estatísticas para tomarem decisões fundamentadas. "A tomada de decisões empresariais é uma tarefa complexa e fundamental para a

sobrevivência de uma organização"(Santana *et al.*, 2023, p. 3).

Portanto, a tomada de decisões pode ser fundamentada através dos modelos. Os modelos, mesmo que sejam uma simplificação da realidade, podem aumentar a confiança dos agentes. Segundo Keynes (1936), essa confiança é um fator que afeta as decisões de investimento.

Já contribuição teórica desse trabalho está alinhada com a avaliação dos diferentes modelos estatísticos para a predição econômica, além é claro, de explorar as novas fronteiras da ciência, com a avaliação de modelos inovadores como os que usam a IA.

Embora Kava (2022), Castelli (2022), Rebelo (2022), Vasconcelos (2017), Carmo e Lopacinski (2023), entre outros. Já se debruçaram sobre a análise macroeconômica utilizando modelos de IA, ainda falta investigar onde modelos baseados em IA se encaixam na predição do PIB brasileiro, portanto este estudo pretende preencher essa lacuna, investigando se a construção de um modelo baseado em IA consegue prever o PIB brasileiro com eficiência, utilizando como métrica, o desempenho relativo aos modelos chamados tradicionais.

O presente trabalho busca mesclar diferentes modelos, ranqueando seu desempenho, e possibilitando a identificação dos modelos mais adequados para previsão econômica. Para isso é necessário a avaliação métricas estatísticas comuns, semelhante ao que Castelli (2022) fez, ao comparar modelos de IA com modelos tradicionais, aplicando métricas como coeficiente de determinação (R^2), Erro Médio Absoluto (MAE), Erro Quadrático Médio (MSE) para classificar os modelos.

2 REVISÃO DE LITERATURA

A presente sessão busca avaliar os estudos até então construídos que perpassam sobre as temáticas correlatas, desde a evolução dos modelos preditivos, a variável estudada: o Produto Interno Bruto (PIB), o uso de modelos preditivos em variáveis macroeconômicas, por fim a avaliação e comparação de modelos preditivos.

Dado esse contexto, a presente revisão de literatura se estruturará da seguinte forma, primeiramente iremos tratar sobre predição econômica de um modo geral e seus principais autores, logo em seguida discutiremos sobre nossa variável foco o PIB, posteriormente classificaremos os modelos em tradicionais e não-tradicionais, onde será descrito cada modelo o conceito, o histórico, o modelo matemático e a aplicação do mesmo no contexto de predição do PIB. Após essa conceituação será analisado as métricas de comparação dos modelos, e como elas vem sendo aplicadas. Após a conceituação e análise das métricas de avaliação, serão abordados os trabalhos acadêmicos que já compararam modelos tradicionais e não tradicionais.

2.1 Predição Econômica: O PIB

A predição de variáveis econômicas não é uma tarefa nova, na realidade estipular o comportamento de variáveis econômicas ao decorrer do tempo é um desejo dos economistas desde o início do século XX. Em seu artigo, Frisch (1929) ¹ trata do conceito da teoria dinâmica, que se subdivide em analítica e histórica, a primeira lida com as leis que regem as flutuações das variáveis, já a segunda trata de aplicar as leis para descrever/prever as variáveis. Essa conceituação teórica de Frisch (1929) é justamente o que hoje é considerado como econometria, e foi a base para os futuros modelos econométricos e suas aplicações.

Contudo, a economia ficou mais complexa desde 1929, conforme Almeida (2001) a economia do início século XX passou por sua fase madura de industrialização incorporou uma grande quantidade de inovações tecnológicas advindos da Segunda Revolução Industrial. Ainda segundo o autor, "a estrutura da produção foi radicalmente transformada pelas mudanças introduzidas nos padrões de trabalho (especialização) e pelos avanços tecnológicos, que aumentaram dramaticamente o produto per capita."(Almeida, 2001, p. 2).

Esse processo se repetiu durante a Terceira Revolução Industrial, Júnior (2017) aponta que esse processo não foi hegemônico, mas foi caracterizado por uma revolução tecno-

¹ Frisch é considerado um dos fundadores da econometria moderna, é a ele atribuído a formulação do termo econometria

científica, não só nas fábricas como na maioria das atividades sócio-econômicas. Durante esse período houve intensas mudanças na atividade produtiva. Contudo alguns autores apontam que a humanidade passou por mais uma revolução, a Quarta Revolução Industrial, ou também chamada de Indústria 4.0.

O termo indústria 4.0² é citado pela primeira vez na feira de Hannover como uma nova política Alemã para industrialização (Kagermann *et al.*, 2013). Um dos autores defensores de uma nova fase da indústria é Martins (2021), onde ele argumenta que a Indústria 4.0 traz muitas mudanças no contexto onde ela é aplicada, como novos modelos de negócio e mercados cada vez mais exigentes.

Mas não somente a economia ficou mais complexa, o advento da indústria 4.0 trouxe a possibilidade de coletar e processar grandes volumes de dados através do que chamamos de sistemas de informação. Que para Laudon e Laudon (2022) são essenciais para alcançar objetivos estratégicos dos negócios. Essas informações são fundamentais para toda decisão, seja ela do setor público ou privado.

A eficácia das políticas depende do uso de todas as informações disponíveis em qualquer momento, incluindo informações prospectivas, como desempenho do mercado de ações e a incerteza da política econômica, disponíveis no ponto de estimativa. (Ghosh e Ranjan, 2023, p. 19)

Nesse sentido da importância das informações, muitos indicadores econômicos foram criados, melhorados ou superados, tanto no sentido microeconômico dentro das firmas, assim como indicadores macroeconômicos dos grandes agregados. E um desses indicadores macroeconômicos que evoluiu com o tempo busca estimar a produção total interna de uma localidade, o chamado PIB. Segundo o Instituto Brasileiro de Geografia e Estatística (IBGE) "o PIB é a soma de todos os bens e serviços finais produzidos por um país, estado ou cidade, geralmente em um ano." (IBGE, 2026, p. 1).

O Banco Central do Brasil trás dois conceitos para o PIB: "a preços de mercado, (o PIB) mede o total de bens e serviços produzidos pelas unidades produtoras residentes destinados ao consumo final (exclui o consumo intermediário)." (Banco Central do Brasil, 2026, p. 1). Além disso o Banco Central do Brasil (2026) trás também a ideia do PIB em reais correntes que se refere ao valor dos bens e serviços finais produzidos em determinado período e valorados a preços de mercado do respectivo período, ou seja sem retirar a inflação. Ambos representam

² Indústria 4.0: é a transformação digital na indústria, onde a mesma integra tecnologias como a própria Inteligência Artificial

a totalidade de bens e serviços produzidos, e tem o mesmo quantitativo quando analisados no mesmo ano base, mas quando se analisa em períodos de tempo diferentes o PIB a preços de mercado é considerado o PIB real, pois exige um cálculo para retirar a inflação das medições do PIB, enquanto o PIB em reais correntes sempre se refere ao valor nominal do PIB naquela data, esse geralmente é o valor divulgado pelas bases de dados, como o próprio Banco Central ou o IBGE.

O conceito internacional de PIB é semelhante com os conceitos do Banco Central do Brasil e do IBGE. Segundo o U.S. Bureau of Economic Analysis (2026) o PIB mede o valor dos bens e serviços finais produzidos, sem contar os bens e serviços intermediários. A agência estadunidense de divulgação e análise econômica também trás o motivo pelo qual o PIB é tão importante afinal "as mudanças no PIB são o indicador mais popular da saúde econômica geral do país"(U.S. Bureau of Economic Analysis, 2026, p. 1)

Nesse sentido o PIB funciona como um termômetro da atividade econômica, e se indicadores refletem a realidade, é lógico pensar que conforme a economia fica complexa, seus indicadores os acompanham, assim como as tentativas de tentar prever seu comportamento.

E nesse contexto temos a predição do PIB, que é algo estudado por diversos pesquisadores, muitos dos quais veremos no decorrer dessa revisão de literatura, mas também de órgãos e instituições públicas e privadas, como é o caso do Instituto de Pesquisa Econômica Aplicada (IPEA) que pontua a importância da predição do PIB "para a definição dos parâmetros para o planejamento fiscal e orçamentário do setor público, bem como para a formação de expectativas no setor privado."(Santos e Nollau, 2022, p. 6).

Dado toda essa evolução, é natural perceber a complexificação desse indicador, desde o século XX com o início da econometria, até os dias atuais com os grandes volumes de dados e a necessidade de decisões fundamentadas, esses fenômenos complexos atuais implicam que métodos tradicionais de predição podem não conseguir descrever a realidade com a mesma precisão da época da qual foram elaborados.

Deste modo, chegamos a um momento de inflexão. Complexidade sistêmica combinada ao grande volume de dados pode fazer com que modelos econométricos tradicionais³ não consigam representar a realidade, pois, até que ponto uma simplificação pode representar realmente o comportamento econômico.

Dessa forma, se o tradicional não tem o comportamento esperado recorre-se ao

³ No presente trabalho trataremos que os modelos econométricos tradicionais são aqueles baseados na linearidade das variáveis, ausência de multicolinearidade, homocedasticidade e normalidade dos resíduos

inovador. Essa inovação, no contexto dos modelos econométricos, vem através da incorporação de modelos estatísticos que suportam a complexidade econômica, além de tecnologias computacionais que conseguem tratar esse volume de dados gerados pelos sistemas de informação.

2.2 Modelos preditivos

Antes de partirmos para inovação devemos entender o que de fato são esses modelos preditivos. Tomando como princípio o texto de Frisch (1929) a econometria surge justamente para aplicar as leis que regem a economia. Para o autor é a teoria dinâmica histórica, que busca evidenciar as relações entre as variáveis, não por suposição cega, mas sim, baseando-se em séries temporais já existentes. Frisch (1929) trata do que ainda viria se tornar a econometria moderna, ademais, existem diversos tipos de modelos econométricos, e os modelos preditivos fazem parte desse conjunto. Portanto se faz necessário identificar exatamente do que se tratam esses modelos.

Para Assunção (2012, p. 8) esses modelos "correspondem a uma equação (ou regra) na qual através de informações históricas ou atuais predize-se um determinado evento futuro a respeito de um indivíduo". Deste modo, a partir do conceito de Assunção (2012) entendemos que independente do modelo: Sempre haverá uma entrada (*input*) de variáveis, sejam elas históricas ou contemporâneas; Haverá também, um processamento desses dados pelo modelo, seja por uma equação matemática ou um preceito estabelecido; E sempre ocasionará em uma saída (*output*), e no caso de modelos preditivos, essa saída terá por objetivo estipular uma variável no tempo futuro.

Com essa definição, retomamos nossos objetivos, como desejamos estimar o PIB nossa saída sempre será um valor numérico que estimará como o PIB brasileiro se comporta. Portanto as únicas variações possíveis nos modelos são: a estrutura; e as variáveis de entrada. Durante a explanação dos modelos trataremos especificamente sobre suas estruturas e estradas, e poderemos nos debruçar melhor sobre o que diferencia cada modelo preditivo.

Entendido o que são modelos preditivos partiremos para diferenciar modelos tradicionais dos de IA, assim como a explanação específica de cada modelo usado no presente estudo, seu histórico, sua construção matemática, por fim a aplicação desses modelos na predição do PIB. Para atendermos esses pontos e concluir nossos objetivos deveríamos seguir algum tipo de sequência lógica para apresentar tais modelos, a abordagem mais simples seria em uma sequência temporal de surgimento, contudo, muitos modelos complexos surgiram antes de versões mais simplificadas. Dessa forma optamos por apresentar os modelos em uma sequência didática,

primeiro tratando dos modelos tradicionais, em seguida os que são baseados em IA, de um forma que julgamos facilitar o entendimento.

2.2.1 Modelos Tradicionais: Uma explicação

Os modelos tradicionais, são modelos simples, geralmente associados a métodos lineares de aprendizado de máquina⁴ "tem esse nome porque assumem que a função que define $E(Y|X)$ é linear nos preditores $X_1, X_2, \dots, X_p$." (Vasconcelos, 2017, p. 14). Rebelo (2022) ainda aponta que os modelos chamados tradicionais possuem uma interpretabilidade natural⁵, e não possuem a necessidade de um método de interpretação adicional.

Segundo Braga (2025) os modelos tradicionais dominaram o mundo, quando o assunto era predição de variáveis durante muitos anos. Entretanto conforme a complexidade econômica aumentava, novas alternativas foram surgindo, para a autora "Apesar da eficácia desses modelos tradicionais em determinados cenários, os avanços computacionais e a crescente disponibilidade de dados favorecem o desenvolvimento de abordagens mais sofisticadas" (Braga, 2025, p. 12).

Dado o tempo em que os modelos tradicionais eram as únicas opções, essas técnicas ganharam muitas variações, algumas mais sofisticadas, outras mais simplificadas, dessa forma, para o presente estudo nos limitaremos a abordar quatro modelos tradicionais, um modelo temporal univariado (ARIMA), um modelo temporal multivariado (VAR), um modelo baseado em fatores dinâmicos (DFM) e um modelo de frequência mista (MIDAS). A escolha desses modelos se deve a diferença entre como eles processam as entradas, sendo excelente para apresentar como métodos diferentes se comportam na previsão de uma variável macroeconômica como o PIB.

2.2.1.1 ARIMA

Seguindo a proposta didática, começaremos pelo ARIMA, no sentido de simplicidade de interpretação e complexidade em geral, o ARIMA é o modelo mais simples que será tratado nesse trabalho, a sigla ARIMA vem do inglês *AutoRegressive Integrated Moving Average*

⁴ Muitos autores argumentam que o aprendizado de máquina, ou *machine learning* é um parte da grande área da IA, o que de certa forma toda econometria tradicional poderia ser enquadrada como Inteligência Artificial, mas na realidade o que chamamos de IA são modelos não-lineares modernos, mas trataremos disso mais profundamente na subseção 2.2.2

⁵ A definição de Rebelo (2022) de certa forma é mais precisa, pois modelos não-lineares como árvores de decisão são classificadas como modelos tradicionais pela sua interpretabilidade.

(ARIMA) que significa Média Móvel Integrada Autorregressiva, a sua simplicidade se deve ao fato de que ele tenta prever a variável estudada usando sua própria série histórica. Nesse caso usaremos a série histórica do PIB para prever o possível valor futuro do mesmo.

O modelo ARIMA nos servirá como um ótimo parâmetro de comparação, por se tratar de um modelo simples, com baixo custo computacional e alta interpretabilidade, ele poderá ser usado para avaliar outros modelos testados. Se um modelo complexo com alto custo computacional e interpretabilidade baixa, se sair pior ou semelhante ao ARIMA na previsão do PIB, poderá ser um indicador que aquele método não apresenta uma relação custo-benefício favorável, levando a crer que o modelo não é adequado⁶ para a predição do PIB.

Segundo Braga (2025) o modelo ARIMA é sistematizado em 1970 no livro de Box e Jenkins (1970). Neste livro os autores afirmam que os modelos do tipo ARIMA fazem parte do conjunto a cujo a d -ésima diferença da série é um processo estacionário misto autorregressivo de média móvel (Box e Jenkins, 1970). Além disso os autores apontam a necessidade desses modelos em aplicações reais.

Muitas séries temporais empíricas (por exemplo, séries de preços de ações) se comportam como se não tivessem uma média fixa. No entanto, elas exibem homogeneidade no sentido de que, além do nível local, ou talvez nível local e tendência, uma parte da série se comporta de forma muito semelhante a qualquer outra parte. Modelos que descrevem tal comportamento não estacionário homogêneo podem ser obtidos assumindo que alguma diferença adequada do processo é estacionária. (Box e Jenkins, 1970, p. 88, tradução nossa)

No sentido de definição e contexto para nosso trabalho, o modelo ARIMA tem um grande potencial para a predição do PIB, pois o comportamento sazonal⁷ do PIB, torna ele uma variável parecida com a descrita no exemplo de Box e Jenkins (1970), sem uma média fixa aparente, mas uma certa homogeneidade de nível local e tendência, semelhante ao decorrer da série. Contudo Box e Jenkins (1970) não somente descreveram em que caso o modelo ARIMA seria adequado, mas também sua formulação matemática e metodologia de aplicação.

O modelo ARIMA(p,d,q) pode ser representado pela seguinte forma geral (Box e Jenkins, 1970, p. 94):

$$\phi(B)z_t = \phi(B)\nabla^d z_t = 0_0 + 0(B)a_t \quad (2.1)$$

⁶ Isso parte de um pressuposto simples, porém para descartar completamente o modelo, seriam necessários outros testes, com outros dados para efetivar com clareza essa suposição, porém isso fugiria do escopo do nosso trabalho.

⁷ Observaremos as variações do PIB nos nossos resultados.

onde

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$$

$$O(B) = 1 - 0_1 B - 0_2 B^2 - \dots - 0_p B^p$$

Em que:

- a) $\phi(B)$ operador autorregressivo (AR)⁸
- b) $\phi(B) = \phi(B)\nabla^d$ operador autorregressivo generalizado
- c) $O(B)$ operador de média móvel

Desse modo utilizaremos a formulação de Box e Jenkins (1970) para a predição do PIB, assim como os testes que comprovam a aplicabilidade do ARIMA no contexto do PIB. Todavia o trabalho de submeter a predição do PIB ao modelo ARIMA já foi realizado por outros autores.

Nesse sentido, revisaremos o trabalho de Silva *et al.* (2025) que apoiaram-se no ARIMA para a predição do PIB brasileiro, no trabalho foi analisado a série histórica do PIB brasileiro de 1990 até 2023⁹ sendo uma fonte metodológica e comparativa para nossa pesquisa.

O primeiro passo dos autores na aplicação do modelo foi uma análise visual da série temporal, os autores consideraram o comportamento de volatilidade do PIB, com crescimentos e decrescimentos, propondo a possibilidade de uso do modelo ARIMA. Para confirmar essa hipótese eles aplicaram o teste Dickey-Fuller aumentado (ADF)¹⁰ em que evidenciou-se ADF=-0.848 e o Valor-p= 0.804, como o Valor-p é superior ao valor crítico de 0.05, indica-se que não se pode rejeitar a hipótese nula de que a série possui uma raiz unitária, indicando que a série não é estacionária no estado original.

A partir do resultados da não estacionaridade seria necessária a diferenciação da série original para tornar a série estacionária, isso implica no uso do modelo ARIMA (p, d, q) com d = 1. Após a primeira diferenciação os autores obtiveram um teste ADF e um Valor-p¹¹ que configuram uma série estacionária confirmando a abertura para utilização do modelo ARIMA.

Após a confirmação do uso do modelo ARIMA, os autores utilizaram a metodologia Box-Jenkins, essa metodologia é "um processo sistemático de identificar, estimar e diagnosticar

⁸ Assume-se que é estacionário.

⁹ Enquanto o recorte de Silva *et al.* (2025) foi de cerca de 33 anos (1990-2023), o nosso será relativamente menor, de 2007 à 2022 (15 anos), devido a disponibilidades de outras variáveis que não somente o PIB.

¹⁰ A fim de organizar nossa pesquisa trataremos de forma compilada todos os testes na sessão ??, nela esmiuçaremos os testes que comprovam a utilização dos modelos, assim como os testes que serão usados para comparar os diferentes modelos.

¹¹ A fim de curiosidade os valores dos teste foram: teste ADF (Série Diferenciada): -3.771 e um Valor-p: 0.00321.

modelos de séries temporais ARIMA" (Silva *et al.*, 2025, p. 6). São quatro passos para aplicação dessa metodologia: identificação, estimação, diagnóstico e previsão.

Na fase de identificação os autores usam a Função de Autocorrelação (FAC) e a Função de Autocorrelação Parcial (FACP) para determinar a estrutura do modelo. A seleção do modelo é feita a partir de critérios de informação, como o Critério de Informação de Akaike (AIC) e Critério de Informação Baysiano (BIC). Para a avaliação dos resíduos¹² usaram o teste Ljung-Box e o teste Jarque-Bera. O último passo é a previsão, passo esse que os autores fizeram uma extrapolação de 6 anos¹³ e compararam com a estimativa do PIB realizada pelo Fundo Monetário Internacional (FMI).

Na fase de identificação os testes FAC e FACP apresentaram ambos com um pico no lag 1, com um decaimento nos lags seguintes. O pico no lag 1 no teste FAC apresenta um comportamento de Média Móvel (MA) fora do intervalo de confiança, assim apresentam que o parâmetro (q) da MA seria igual a 1. Já no teste FACP o pico no lag 1, sugere um comportamento de Auto-Regressivo (AR) de ordem 1, ou seja ($p = 1$). Configurando o modelo obtido sendo ARIMA(1,1,1).

Contudo os autores não somente estimaram o modelo ARIMA(1,1,1). No processo de estimativa, os autores testaram outros quatro modelos com $p - value < 0.05$. Contudo dentre esses que foram testados, o modelo ARIMA(1,1,1) obteve os resultados mais competitivos, quanto menor melhor, nos critérios AIC e BIC¹⁴

No sentido dos resíduos os autores aplicaram o teste de Ljung-Box¹⁵, onde foi confirmado a ausência de autocorreção significativa, além disso foi aplicado o teste de Jarque-Bera para verificar a distribuição dos resíduos, contudo o teste indicou que os resíduos não seguem uma distribuição normal, o que por si só não é um problema, que apesar de preferível, a não normalidade dos resíduos não descarta o modelo ARIMA(1,1,1). A partir da análise gráfica e da Função de Autocorrelação dos Resíduos (FAC) os autores chegaram a conclusão que o modelo ARIMA ajustado foi eficiente para remover a estrutura de autocorrelação dos dados, restando somente um ruído branco.

Para validar o modelo os autores compararam a projeção do ARIMA(1,1,1) para os 6 anos seguintes com a projeção feita pelo FMI, como justificava para tal comparação os

¹² Os autores apresentam que o comportamento dos resíduos devem ser independentes, não podem apresentar uma autocorrelação significativa e idealmente devem apresentar uma distribuição normal.

¹³ De 2024 à 2029.

¹⁴ A fim de curiosidade os valores dos testes são: AIC=1.878.932 e BIC=1.884.038.

¹⁵ Estatística de Ljung-Box = 10,69, valor-p = 0,38

autores elencaram como o FMI utiliza em sua projeções mais variáveis, com complexidade maior. Dessa forma, o modelo ARIMA apresentou uma capacidade satisfatória para capturar a estrutura temporal do PIB brasileiro. Porém os autores ainda elencam possíveis falhas do modelo, como as limitações ao modelar choques econômicos e o viés potencialmente otimista do ARIMA em comparação as projeções do FMI.

Os autores apontam que

Apesar da utilidade do ARIMA como ferramenta inicial para análise e previsão de séries temporais econômicas, suas estimativas devem ser interpretadas com cautela e, preferencialmente, complementadas por métodos qualitativos e modelos econométricos que considerem o amplo espectro de variáveis que afetam o crescimento do PIB. Essa integração entre abordagens quantitativas e qualitativas potencializa a confiabilidade das projeções e contribui para decisões mais fundamentadas no âmbito da política econômica. (Silva *et al.*, 2025, p. 15)

A conclusão dos autores vai de encontro com o objetivo que propomos para o ARIMA no presente trabalho: atuar como um modelo inicial e de comparação com os modelos seguintes, como uma métrica de simplicidade e eficiência em comparar os padrões do PIB no decorrer do tempo.

Mas não é somente no Brasil que o modelo ARIMA é utilizado, este modelo continua sendo apresentado como alternativa relevante dentro da predição econômica univariada em todo o mundo. A dissertação de mestrado de Li (2024) é uma prova de como o modelo ainda vem sendo utilizado e testado até nos dias presentes, em economias complexas como a estadunidense.

Em seu trabalho Li (2024) avalia o desempenho de diferentes modelos em cenários de choques econômicos, especificamente o mais recente do período¹⁶ que abrangeu a pandemia do COVID-19. Nesse trabalho um dos modelos testados foi o próprio modelo ARIMA para a predição do *Gross Domestic Product* (GDP)¹⁷ ele foi utilizado no mesmo sentido que pretendemos utilizá-lo como um modelo comparativo de teste, para avaliar o desempenho de outros modelos avaliados.

Os dados da dissertação foram obtidos do *Federal Reserve Economic Data* (FRED)¹⁸. A partir dos testes realizados comprovou-se que "O PIB é uma série temporal estacionária ao nível de significância de 5% pelo ADF"(Li, 2024, p.22, tradução nossa) confirmando uma série estacionária, assim $d=0$. Na aplicação dos testes FAC e FACP a autora identifica que os picos

¹⁶ O recorte de tempo de Li (2024) foi de 1960 até 2023

¹⁷ O GDP é o equivalente ao nosso PIB

¹⁸ Dados Econômicos da Reserva Federal, trata-se de uma banco de dados americanos com dados financeiros, econômicos e demográficos dos Estados Unidos da América (EUA)

ficaram em 0 para a FAC (MA) e também para FACP (AR) com o lag em 0, configurando o modelo ARIMA(0, 0, 0). No sentido da estatística de Ljung-Box também não apresentou "evidências significativas contra as autocorrelações de defasagem serem 0"(Li, 2024, p.25, tradução nossa).

Ao aplicar os diferentes testes e modificar os parâmetros do ARIMA para os dados de treinamento, comprovou-se que o modelo que mais se aproximou do resultado esperado foi o ARIMA(1, 0, 2), e dentre os modelos de *benchmark* foi o que obteve os melhores resultados¹⁹. O modelo ARIMA performa de uma maneira satisfatória inclusive contra os modelos de multivariados complexos testados²⁰.

Assim como apontado por Silva *et al.* (2025) o modelo ARIMA ainda tem suas limitações. A partir dos resultados de Li (2024) conseguimos ver essas limitações, que comparado a alguns modelos multivariados o modelo ARIMA falha em capturar a realidade com precisão devido a suas simplificações.

De todo modo, podemos confirmar o ARIMA como o candidato perfeito como modelo de teste, configurado com um baixo custo computacional, desempenho formidável e relativa aplicação simplificada. O modelo ARIMA será utilizado em nosso trabalho como modelo comparativo. Veremos mais sobre a aplicação do ARIMA no capítulo 4 onde veremos o desempenho do mesmo semelhante ao olhar de Silva *et al.* (2025), mas com o princípio comparativo de Li (2024).

O modelo ARIMA, e no geral todos os modelos univariados têm um problema, a limitação estrutural do modelo. Afinal variáveis complexas, como o próprio PIB, sofrem de influências de diferentes fatores - de todas as naturezas, desde dados intimamente ligados a variável escolhida, até dados que parecem não ter relação alguma. Entretanto para afirmar ou rejeitar essa disposição, são necessários testes de correlação e modelos que realmente suportem indicar um certo grau de predição usando relações que não são univariadas. Esses modelos serão tratados a partir desse ponto no presente estudo.

¹⁹ Os modelos de *benchmark* foram: o modelo ETS e a regressão de transformada de Fourier, e obtiveram resultados parecidos, mas ligeiramente piores que o ARIMA

²⁰ No caso dessa dissertação os modelos complexos eram do tipo PCA, que são multivariados e mais complexos do que o ARIMA, mesmo assim o modelo performou melhor nos dados de treinamento e validação melhor que modelos de complexidade maior

2.2.1.2 VAR

O modelo VAR é o primeiro modelo multivariado que nos debruçaremos em sua composição, utilização e aplicabilidade à predição do PIB. Seguindo nossa trilha didática, espera-se que o modelo VAR seja naturalmente mais complexo que modelos univariados - como o ARIMA. E de certa forma é isso que acontece, mas não quer dizer que a interpretabilidade do modelo, no sentido natural, se altere. Muito pelo contrário o VAR continua sendo um modelo intuitivo e explicável no âmbito das relações entre variáveis.

Nesse contexto de sistemas complexo de relações, há uma infinidade de variáveis que podem ser aplicadas. Modelos que conseguem identificar essas relações, mesmo que de forma limitada²¹, são essenciais, não se trata mais de modelar a relação da variável e sua série temporal, mas sim identificar a relação de diferentes variáveis umas com as outras e com o tempo.

Entendido onde os modelos multivariados se encaixam na predição estatística, falaremos sobre o modelo escolhido, o VAR. O acrônimo VAR vem de *Vector Autoregression* trata-se de um modelo estatístico descrito pela primeira vez por Sims (1980), surgindo da necessidade de modelar sistemas multivariados reais²², não em situações puramente hipotéticas e teóricas.

Sims (1980) ajustou séries temporais trimestrais do período pós-guerra dos EUA e da Alemanha Ocidental sobre dinheiro, Produto Nacional Bruto (PNB)²³, taxa de desemprego, nível de preços e índice de preços de importação, usando uma autoregressão vetorial sem restrições.

Esse trabalho nos forneceu a metodologia para aplicar o VAR sem as restrições teóricas fortes de identificação estrutural de modelos anteriores. A partir dessa aplicação Sims (1980) apresentou as características do que hoje chamamos de VAR. Trata-se de um sistema de equações multivariadas que evita impor conhecimentos *a priori*, ou seja, o modelo trata todas as variáveis como endógenas²⁴.

Sims (1980) discorre sobre a aplicabilidade do VAR, e aponta que modelos anteriores, mesmo os multivariados, assumem a exogeneidade das variáveis. Segundo o autor esses modelos dificultam capturar interdependências dinâmicas entre variáveis como as interações entre o lado

²¹ Ao aplicar o VAR não é possível lidar com a "infinidade" de variáveis, somente com algumas dezenas no máximo, contudo existem modelos mais avançados - ainda tradicionais - que lidam bem com centenas de variáveis, veremos esses em breve.

²² Inclusive surge em um contexto de modelar variáveis macroeconômicas - como o PIB - afinal o título do ensaio de Sims (1980) é justamente Macroeconomia e Realidade

²³ O PNB diferencia-se do PIB, pois o PNB leva em conta renda líquida enviada e recebida do exterior, ou seja para nações com muitas multinacionais a tendência é $\text{PNB} > \text{PIB}$, já em nações dependentes de empresas estrangeiras em solo nacional a tendência é $\text{PIB} > \text{PNB}$

²⁴ Variáveis endógenas são aquelas determinadas dentro do próprio sistema de equações.

real (produção) e o lado monetário da economia (inflação dos preços).

O modelo VAR descrito por Sims (1980) apesar de conceitualmente definido, ainda sofreu modificações, o modelo atual que usaremos pode ser visualizado pelas equações 2.2 e 2.3, em suas variações com menor e maior defasagem, consultadas de (Costa, s.d.).

Uma série temporal multivariada $\mathbf{r}_t = (r_{1t}, r_{2t}, \dots, r_{kt})'$ composta por k componentes no tempo t é um processo VAR(1), que segue o modelo:

$$r_t = \phi_0 + \Phi r_{t-1} + a_t \quad (2.2)$$

onde

- a) ϕ_0 é um vetor de dispersão k ;
- b) Φ é uma matriz $k \times k$; e
- c) a_t é um ruído branco formado por uma sequência de vetores aleatórios independentes, distribuídos de forma idêntica, com média 0 e matriz de covariância Σa .

Já para modelos com uma defasagem maior, usá-se o VAR(p), nele uma série temporal multivariada $\mathbf{r}_t = (r_{1t}, r_{2t}, \dots, r_{kt})'$ com $p > 0$:

$$r_t = \phi_0 + \Phi_1 r_{t-1} + \dots + \Phi_p r_{t-p} + a_t \quad (2.3)$$

onde

- a) ϕ_0 é um vetor de dispersão k ;
- b) Φ são matrizes $k \times k$ para $j = 1, \dots, p$; e
- c) a_t é um ruído branco formado por uma sequência de vetores aleatórios independentes, distribuídos de forma idêntica, com média 0 e matriz de covariância Σa .

Com o contexto de surgimento do VAR e sua definição matemática, partiremos para a aplicação do VAR na literatura, ao contrário do que fizemos no ARIMA de analisar somente o PIB, referente ao Brasil, e o GDP referente aos EUA. No modelo VAR buscaremos uma análise um pouco mais detalhada com diferentes variáveis em outros contextos.

Trataremos da relação entre variáveis reais, monetárias e da incerteza da com texto de Fialho *et al.* (2024). Observaremos o PIB per capita sob uma análise regional brasileira do ponto de vista de Oliveira e Junior (2024). Por último recorreremos a literatura internacional, para observar como uma variação do modelo VAR é utilizada para estimar o crescimento do GDP estadunidense proposto por Koop *et al.* (2025).

No primeiro trabalho abordado, a proposta dos autores é investigar "a causalidade de Granger entre incerteza, spread bancário e consumo das famílias no Brasil, utilizando um modelo VAR com dados mensais de janeiro de 2013 a janeiro de 2024"(Fialho *et al.*, 2024, p. 1). Nesse trabalho foram selecionadas 6 séries de variáveis, dentre elas: Consumo Aparente - produção doméstica acrescida de importações e deduzido as exportações; Spread Médio para Pessoa Física - diferença entre a taxa média de juros de novas operações de crédito e o custo de captação referencial médio; Incerteza - índice de Incerteza da Política Econômica (EPU); Rendimento - rendimento bruto real médio, recebido no mês de referência, a série foi deflacionada usando o (IPCA); Concessão de Crédito pessoa física - valor das novas operações de crédito realizadas no período de referência; Taxa de desocupação - Percentual de pessoas economicamente ativas que estavam procurando trabalho, percentual de pessoas desocupadas em relação as pessoas na força de trabalho.

Segundo Fialho *et al.* (2024) as variáveis foram submetidas ao modelo VAR devido a capacidade do modelo de lidar com múltiplas variáveis pertencentes a séries temporais, e considerando as mesmas como endógenas. Justamente vem de encontro com a proposta de Sims (1980), confirmando a aplicação do modelo. A metodologia justifica-se pela possibilidade de modelar a interação entre variáveis reais e monetárias, não com uma teoria *a priori*, mas sim buscando investir a interação entre as variáveis. Para confirmar a adequação estatística dos dados, foram aplicados dois testes: Dickey-Fuller e Phillips-Perron para verificar a estacionariedade.

Para os autores

VAR é um modelo com n variáveis e n equações que expressa cada variável como uma função linear de seus próprios valores passados, dos valores defasados das demais variáveis empregadas e de um termo de erro serialmente não correlacionado. (Fialho *et al.*, 2024, p. 6).

O conceito exposto por Fialho *et al.* (2024) segue a mesma equação 2.2 apresentada anteriormente.

Para o prosseguimento da utilização do modelo VAR é necessário que as variáveis sejam estacionárias, o que foi testado utilizando a estatística Dickey-Fuller. A um nível de significância de 10% quatro variáveis não são estacionárias: spread médio pessoa física ($p = 0.6054$); incerteza ($p = 0.0844$); concessão de crédito pessoa física ($p=0.7486$ e taxa de desocupação ($p= 0.6635$). Para testar a hipótese nula em que as séries possuem raízes unitárias, foi utilizado o teste Phillips-Perron, que apresentou spread médio pessoa física ($p =0.4832$); incerteza ($p = 0.0583$); concessão de crédito pessoa física ($p=0.9137$) e taxa de desocupação

($p=0.6320$). Com esses resultados, o próximo passo foi realizar o mesmo teste com as variáveis defasadas²⁵, o que implicou no cumprimento da suposição de estacionariedade e de inexistência de raiz unitária para as variáveis.

Com o cumprimento das suposições estatísticas, seria necessário determinar o número de defasagens para o modelo, afinal se "forem muito pequenas o modelo terá problemas de sobrespecificação e, caso sejam muito grandes, perdem-se graus de liberdade"(Fialho *et al.*, 2024, p. 7). Pelos critérios Akaike, Schwartz e Hannan-Quinn o número ideal de defasagens seria 2. Os resultados obtidos demonstram que o modelo satisfaz a estabilidade do VAR, pois todas as raízes pertencem ao círculo unitário (são menores que 1). No diagnóstico dos resíduos, a partir do Multiplicador de Lagrange, com a hipótese nula de não autocorrelação, sendo comprovada a 1% de significância. Os resíduos apresentados oscilam em torno de zero no tempo, indicando a inexistência de uma tendência sistemática nos resíduos. A partir desses expostos, foi confirmado que o modelo VAR estimado é adequado para a análise proposta.

Os resultados obtidos apontam que

Os resultados obtidos demonstram que o rendimento, o crédito e o spread bancário têm um impacto com significância no consumo das famílias. Especificamente, as variáveis rendimento e crédito mostraram-se positivamente correlacionadas com o consumo, enquanto o spread bancário teve um efeito negativo. A incerteza, embora também afete o consumo, exerce uma influência menos pronunciada comparada às variáveis financeiras. Da mesma forma, a taxa de desocupação mostrou-se negativamente correlacionada com o consumo, embora de forma menos significativa. (Fialho *et al.*, 2024, p. 11-12).

No sentido de utilização para o nosso trabalho já é possível obter-se uma ideia de como as variáveis devem se relacionar. Contudo o maior significado do estudo de Fialho *et al.* (2024) certamente é a demonstração de como diferentes variáveis, sejam elas reais ou monetárias, interagem entre si. Essa relação é fundamental para entender a dinâmica econômica. A partir desses pressupostos, absorveremos esses resultados para nosso trabalho: a capacidade do VAR de tratar da interdependência de diversas variáveis.

Por outro lado, para avaliarmos o uso do VAR no contexto do PIB brasileiro, analisaremos o trabalho de Oliveira e Junior (2024), apesar dos autores não usarem o montante completo do PIB, mas sim a versão fracionada pela população, o PIB *per capita*, este estudo trabalha com um outro cenário do que o visto até então, a relação dos investimentos públicos em infraestrutura e a renda da população. Outro diferencial desse trabalho é a análise de choques, para estimar o comportamento real de uma economia dinâmica.

²⁵ A fim de curiosidade todos os testes tiveram um p-valor de 0 ao utilizar as variáveis defasadas

O período de estudo de Oliveira e Junior (2024) foi o recorte dos anos de 1994 a 2015, com preços atualizados ao ano de 2015. Esse estudo compreendeu duas regiões brasileiras distintas: Sul e Nordeste. As variáveis coletadas para estas regiões foram: o PIB extraído do IPEA; e a população do IBGE. Com ambas em mãos os autores calcularam o PIB *per capita* para as duas regiões.

No sentido do gasto com infraestrutura os autores coletaram três variáveis principais: gasto com comunicação, energia e transporte. Esses dados foram coletados de cada estado das regiões Sul e Nordeste, advindos da Declaração de contas Anuais (DCA) ou do Quadro de Detalhamento das Contas Contábeis (QDCC). Além disso todas as séries foram transformadas em base logarítmica para interpretação natural da elasticidade.

Os autores apontam que a metodologia de Sims (1980) permite verificar "as causalidades de Granger entre as variáveis, decomposição da variância dos resíduos e a função impulso-resposta"(Oliveira e Junior, 2024, p. 7). Sendo na visão deles um método que os auxiliará no entendimento das inter-relações das variáveis estudadas. Além disso, os autores ainda ressaltam que esse modelo lhes permitem avaliar como as variáveis reagem a inovações individuais no sistema, mas também como cada inovação passa a explicar os desvios sucessivos na série temporal das variáveis do modelo.

Ao realizarem os testes ADF e Phillips Perron (PP) ao nível de significância de 5%, todas variáveis apresentaram raízes unitárias, entretanto após a primeira diferenciação, com exceção da série dos gastos com infraestrutura de comunicação na região sul, todas as séries se comportaram como estacionárias. No caso da comunicação na região sul, mesmo na segunda diferença a série não se tornou estacionária, o que ocasionou na decisão dos pesquisadores em descartá-la desse modelo.

Já na determinação do número de defasagens do modelo, para a região nordeste todas os critérios apresentaram uma defasagem ótima sendo igual a 1. No entanto na região, dois critérios apresentaram defasagem ótima igual a 1, dois critérios igual a 4. Os autores optaram pela utilização de ordem 1 de defasagem para região Sul, assim como na região Nordeste.

Para a confirmação a ordem de defasagens os autores testaram a hipótese dos resíduos autocorrelacionados usando o critério dos Multiplicadores de Lagrange (Teste LM), o que confirmou a ordem de defasagens igual a 1 para ambas as regiões, já que o teste rejeitou a autocorrelação dos resíduos.

Os autores utilizaram o método de Johansen para verificar relações de longo prazo entre as variáveis, e a um nível de 5% de significância pela estatística traço, foi rejeitado a hipótese nula de inexistência de cointegração. A existência de um vetor cointegração implica na relação de longo prazo entre variáveis, portanto foi necessário a adição do Modelo Vetorial de Correção de Erro (VEC) junto ao Vetores Autoregressivos (VAR).

A estabilidade do modelo VAR/VEC é necessária, e para isso todas as raízes do polinômio devem estar dentro do círculo unitário, o que foi constatado nos testes, configurando assim a não existência de possíveis trajetórias explosivas.

Com esses testes o modelo foi estimado para as regiões Sul e Nordeste, de forma em que o PIB *per capita* como endógeno ao modelo e as variáveis de gastos com infraestrutura como exógenas. Os resultados apontaram que para a região nordeste uma variação de 1% do gasto com transporte pode ocasionar uma variação de 0.07% do PIB *per capita*. No caso da energia, com a mesma variação de 1%, espera-se uma variação de 0.01% do PIB *per capita*. No caso da região Sul as mesmas variação de 1% no gasto de transporte e energia espera-se ocasionar uma variação de 0.005% e 0.007% respectivamente.

Contudo vale ressaltar que no coeficiente relacionado ao gasto com transporte e energia da região Sul apresentou um coeficiente com sinal positivo, indicando que um aumento no gasto com transporte ocasionaria em uma redução do PIB *per capita*, porém a estatística não se apresenta como significativa.

Para além disso, também foi testada a variação que ocorre no PIB *per capita* quanto outras variáveis também flutuam. Na região Nordeste em um primeiro momento a variância do erro de previsão do PIB *per capita* foi auto-explicada em cerca de 92%, contudo ao longo do período, o erro auto-explicado se reduziu, com 12 meses a frente, somente 68% da variância do erro de previsão é explicada pelo PIB *per capita*, enquanto os gastos de de transporte explicam 11%, de energia 1,4% e de comunicação 18%. No caso da região Sul, a variância foi explicada em 98% pelos seus próprios valores. Mas após os mesmos 12 meses, os gastos com energia passam a explicar 75% da variância do erro e os gastos com transporte cerca de 2%.

Com essas relações foi possível simular um choque nos gastos e observar o comportamento do PIB *per capita*, a partir disso foi constatado que no caso do Nordeste gastos com transportes apresentaram efeitos positivos sobre o PIB *per capita*. Para a região sul o gasto com energia que apresenta esses efeitos significativos, enquanto o transporte é pouco significativo.

Oliveira e Junior (2024) concluíram o trabalho levando a consideração da hetero-

geneidade das regiões brasileiras, trazendo como medidas em diferentes setores podem trazer impactos significantes, ou não, para a renda da região. A partir desse artigo e conectando com nosso objetivo da presente pesquisa notamos uma vantagem do VAR, e dos modelos tradicionais multivariados no geral, a explicabilidade, enquanto modelos como ARIMA conseguem identificar tendências e estimar o comportamento de uma única variável no futuro, modelo como o VAR conseguem estimar o impacto da dinâmica entre as variáveis, nesse caso sendo uma ferramenta poderosa para a tomada de decisão.

Na mesma linha de Oliveira e Junior (2024), Koop *et al.* (2025) usaram o VAR para a estimar a renda, porém a renda estadunidense. Contudo o modelo proposto pelos autores é uma versão mais robusta do VAR, o chamado *Bayesian Mixed-frequency VAR* ²⁶ ou MF-VAR. Não entraremos a fundo na metodologia de Koop *et al.* (2025), apesar de mais complexa, ainda seguirá alguns pressupostos do modelo VAR vistos anteriormente.

Contudo, em outros aspectos será completamente diferente, talvez o mais explicito deles seja o tamanho do modelo, enquanto um modelo VAR tradicional terá poucos parâmetros - tentando evitar a hiper-parametrização, perda de graus de liberdade e a possível multicolinearidade. O modelo proposto por EUA Koop *et al.* (2025) de predição em tempo real do PIB estadual tem 50 equações. Outro ponto relevante é a frequência dos dados, como no exemplo constatado pelos autores "O crescimento do PIB estadual (estadunidense) está disponível em frequência anual até 2004, antes do *Bureau of Economic Analysis* (BEA)²⁷ começar a produzir estimativas trimestrais a partir de 2005." (Koop *et al.*, 2025, p. 6, tradução nossa). Entretanto vale ressaltar que esse comportamento é recorrente. Tanto em variáveis de natureza distintas - como financeiras e reais - assim como variáveis que trocam de frequência com o decorrer da série temporal. Isso pode ser explicado por mudança metodológica na coleta de dados, ou pela simples melhoria na capacidade de coleta de dados pelos órgãos responsáveis, de uma frequência anual para trimestral, como a ocorrida.

Isso conversa com ideia inicial de nosso trabalho, um modelo capaz de estimar o PIB brasileiro, contudo é importante compreender as limitações de coleta que existem, apesar de vivermos a era da *big-data*, nem sempre foi assim. Portanto não se pode esperar séries históricas completas, sem erros de coleta, ou mudanças metodológicas. Isso é válido para economias desenvolvidas pelo mundo, como a estadunidense, ou para economias emergentes

²⁶ Vetor Autorregressivo de frequência misturada Bayesiano, trata-se de um modelo com capacidade de modelar diversas variáveis, com frequências de observações diferentes

²⁷ Departamento de Análise Econômica, trata-se do órgão que fornece indicadores macroeconômicos dos Estados Unidos

como a brasileira.

Outra ressalva no trabalho de Koop *et al.* (2025) é a mudança de paradigma, enquanto o trabalho original de Sims (1980) e as aplicações de Oliveira e Junior (2024) e Fialho *et al.* (2024) são frequentistas, baseadas na estatística tradicional. Koop *et al.* (2025) precisaram utilizar uma abordagem Bayesiana, em que pressupostos a prior sobre a distribuição dos parâmetros antes dos dados são exigidos²⁸. No trabalho de Koop *et al.* (2025) para conseguirem estimar um modelo VAR com essa quantidade de equações, chamados de grandes VAR, o poder computacional e o tempo de execução começam a se tornar um fator relevante na escolha de um modelo. Para a modelagem computacional, os autores utilizaram o *Markov Chain Monte Carlo* (MCMC), que é frequentemente utilizada como algoritmo para modelos Bayesianos, contudo o MCMC tradicional, com a quantidade de parâmetros e frequências distintas presentes, seria muito lento para a previsão do PIB em tempo real, os autores então adaptaram o algoritmo tradicional para a modelagem específica do VAR proposto.

Entretanto, mesmo com todas essas restrições e adaptações, o modelo de Koop *et al.* (2025) conseguiu estimar o PIB mensal dos estados estadunidense, com um certo grau de precisão. Para avaliação do modelo, os autores utilizaram o *Root Mean Square Error* (RMSE) dos valores estimados comparado aos valores medidos trimestralmente pelo próprio BEA. Vale ressaltar que para os erros dos três primeiros meses a média dos estados foi de $m1 = 1.71$, $m2 = 1.71$ e $m3 = 1.48$. Esse resultado indica uma boa capacidade de estimar o crescimento do PIB estadual dado as circunstâncias. Mas, a qualidade desse trabalho mais evidente é a capacidade interpretativa e possibilidade de estimar choques no espaço - devido a dinâmica estadual estar contida dentro do modelo. Esse grau de modelagem não seria possível em um modelo VAR tradicional.

Nesse contexto, nota-se que o modelo VAR pesquisado por Koop *et al.* (2025) tem qualidades evidentes. Tendo isso em mente, vale ressaltar que a utilização do VAR com uma abordagem Bayesiana não se restringe a economia americana. Na realidade muitos estudos já utilizaram essa abordagem para modelagem macroeconômica brasileira. Como os estudos de Azevedo (2020), Serrano (2014), Borges (2018), Rosa (2025).

Tal perspectiva reflete como o VAR e suas variações são modelos robustos para a predição de variáveis macroeconômicas, o modelo tradicional com suas limitações e suas vantagens de modelagem e rápida execução. E suas variações que suportam um maior número

²⁸ Não discutiremos sobre qual abordagem é melhor, dentro da estatística e econometria do séc. XXI ambas abordagens são relevantes e se complementam na resolução de problemas quantitativos reais

de variáveis e distintas frequências temporais.

Todavia, para utilizar-se do VAR nesse contexto foi necessário adaptações no paradigma estatístico para a modelagem do problema, a seguir veremos dois modelos que lidam com isso naturalmente o DFM que foi idealizado para lidar com grande quantitativo de variáveis e o MIDAS que suporta diferentes frequências nas séries temporais, com isso concluiremos a sessão de modelos tradicionais e partiremos para os modelos baseados em Inteligência Artificial (IA)

2.2.1.3 MIDAS

Aplicar um modelo econométrico consiste em etapas, que vão desde a coleta, tratamento, testagem, aplicação, validação e predição. A maioria dessas etapas é administrada pelo pesquisador, se uma variável não passa nos testes, o estatístico pode simplesmente removê-la, ou tratá-la como exógena, se o modelo não tem uma boa acurácia, pode a sua vontade mudá-lo, e é assim para maioria das etapas. Contudo uma dessas etapas, apesar de muito importante, ela é suscetível a erros e variações que muitas vezes não podem ser controladas pelo pesquisador, estamos falando da coleta. Os dados disponíveis, mesmo aqueles de bases oficiais podem conter vícios de medições, dados faltantes e é claro diferentes frequências.

Como os estudiosos da área não podem simplesmente deixar de realizar a pesquisa, novas técnicas cada vez mais sofisticadas surgem para solucionar esse tipo de problema, como visto anteriormente no MF-VAR, existem maneiras de adaptar modelos existentes para as condições da realidade dos dados, mas também surgem modelos específicos para lidar com certas condições frequentes da economia real.

Uma dessas condições, é ironicamente a frequência. Nesse sentido, em algumas bases, uma variável é semanal, naquela é mensal, em outra anual, e assim para qualquer regularidade imaginável. Por exemplo, o censo demográfico no Brasil só ocorre a cada 10 anos, os dados entre esses anos são estimativas. Outro exemplo, a taxa SELIC que é definida a cada 45 dias, muito mais frequente que um censo, mas parece ser uma eternidade comparada aos preços das ações que tem frequência praticamente imediata. Nesse sentido um modelo que consegue incorporar o comportamento econômico com diferentes frequências é algo relevante. Nesse contexto, surge o MIDAS.

MIDAS envolve regressores com diferentes frequências de amostragem e, portanto, não são modelos autorregressivos, já que a noção de autorregressão pressupõe implicitamente que os dados são amostrados na mesma frequência no passado. (Ghysels *et al.*, 2004, p. 1)

Portanto, o MIDAS se difere dos modelos até agora estudados, tendo em vista que só analisemos modelos autorregressivos.

A responsabilidade sobre o início do desenvolvimento do modelo MIDAS recai justamente sobre os autores da citação anterior, no trabalho de Ghysels *et al.* (2004), com a obra intitulada de "*The MIDAS Touch: Mixed Data Sampling Regression Models*"²⁹. O contexto do surgimento do MIDAS é justamente a necessidade de um modelo capaz de delinear as diferentes frequências na realidade. Os autores trazem como exemplo o mercado de ações, análise de risco e também a predição macroeconômica pensando na limitação dos dados,

o interesse em regressões MIDAS também pode surgir por limitações na disponibilidade de dados. Por exemplo, alguns dados macroeconômicos são amostrados mensalmente, como séries de preços e agregados monetários, enquanto outras séries são amostradas trimestralmente ou anualmente, normalmente séries de atividade real como o PIB e seus componentes. (Ghysels *et al.*, 2004, p. 1)

Tendo em vista que o objeto do presente trabalho são os diferentes sistemas de predição, e um modelo pensado para solucionar um problema real da predição com variáveis macroeconômicas é um forte candidato a observação. Mas o que de fato esse modelo faz? "As regressões MIDAS são basicamente regressões de forma reduzida e com parâmetros bem ajustados, que envolvem processos amostrados em diferentes frequências." (Ghysels *et al.*, 2004, p. 4)

Uma regressão linear simples MIDAS pode ser expressa na equação 2.4 proposta por Ghysels *et al.* (2004).

$$Y_t = \beta_0 + \beta_1 B(L^{\frac{1}{m}}) X_{t-1}^{(m)} + \varepsilon_t^{(m)} \quad (2.4)$$

onde

- a) Y_t é a variável de baixa frequência a ser estimada;
- b) β_0 é o intercepto;
- c) β_1 é o coeficiente que mede a influência das variável explicativa sobre a variável dependente;
- d) $B(L^{\frac{1}{m}}) = \sum_{j=0}^{j_{max}} B(j) L^{\frac{j}{m}}$ é um polinômio de comprimento $L^{\frac{1}{m}}$ no operador $L^{\frac{1}{m}} x_t = x_{t-\frac{j}{m}}$;
- e) $X_{t-1}^{(m)}$ é a variável explicativa de alta frequência;
- f) $\varepsilon_t^{(m)}$ é o termo do erro.

²⁹ O nome faz referência a mitologia atrelada ao toque de Midas, associado a habilidade de transformar tudo em sucesso/riqueza

Imaginemos modelar a o PIB trimestral utilizando o Índice de Preços ao Consumidor Amplo (IPCA) mensal, em uma regressão linear simples, cada mês do IPCA deveria ser modelado como uma variável independente a parte, o que a depender da frequência da variável, se tornaria inviável, com alto risco de sobreajuste. Outra solução seria simplesmente adaptar a frequência mais alta para a mais baixa, por exemplo, calcular a média do IPCA para os meses de observação, porém fazer isso implicaria na perda de informações. O que modelos MIDAS fazem é incorporar as variáveis com frequências diversas em uma função de pesos parametrizados para as defasagens.

Porém escalando o problema, para múltiplas variáveis, a modelagem da maneira tradicional se torna praticamente inviável. Isso vale também para o modelo MIDAS apresentado, o mesmo não foi feito para um conjunto de variáveis. Como pretendemos aplicar em dados reais, e como o modelo MIDAS foi criado justamente nesse contexto, devemos observar sua formulação. Sua forma geral, que representa toda família de modelos MIDAS está representado na equação 2.5 também proposta por Ghysels *et al.* (2004).

$$Y_{t+1} = B_0 + f\left(\sum_{i=1}^K \sum_{j=1}^L B_{ij}(L^{\frac{1}{m_i}})g(X_t^{(m_i)}, \beta), \beta\right) + \varepsilon_t + 1 \quad (2.5)$$

onde

- a) Y_{t+1} é a variável dependente no período $t + 1$;
- b) B_0 é o intercepto;
- c) $X_t^{(m_i)}$ são as variáveis explicativas do modelo;
- d) $L^{\frac{1}{m_i}}$ é o operador de defasagem fracionária;
- e) $B_{ij}(L^{\frac{1}{m_i}})$ é um polinômio de defasagem que determina o impacto de lags específicos de X sobre Y ;
- f) $g(X_t^{(m_i)}, \beta)$ é a função de ponderação dos pesos;
- g) $\sum_{i=1}^K \sum_{j=1}^L$ são os somatórios que acumulam a informação;
- h) $f(\dots, \beta)$ é a função de ligação global³⁰;
- i) ε_{t+1} é o resíduo no período $t + 1$.

A partir dessa forma geral podemos modelar uma variedade de problemas que envolvem variáveis de frequência mista, inclusive, e especialmente situações envolvendo variáveis

³⁰ Normalmente f é linear, mas na forma geral isso não é obrigatório, ou seja f pode ser uma função não-linear, portanto podem haver modelos MIDAS aplicados a problemas não-lineares, essa possibilidade coloca em cheque a posição do MIDAS nesta sessão do presente trabalho, porém consideramos o MIDAS como um modelo tradicional pela sua ampla aplicação em problemas lineares

macroeconômicas como o PIB. Portanto a partir desse momento veremos aplicações do modelo MIDAS para a predição macroeconômica.

Castelli (2022) abordou o uso do modelo de amostragem de dados mistos (do inglês *Mixed Data Sampling* - MIDAS) para prever o PIB com a pesquisa industrial mensal. Assim como Micheletti (2024) usou modelos de *ensemble stacking*³¹ (dentre eles o MIDAS) para prever o PIB.

2.2.1.4 DFM

Pensando nos modelos até então apresentados, existe uma certa progressão em complexidade e capacidade do modelo, mas todos os apresentados tem um problema específico, a dificuldade em lidar com muitas variáveis. O modelo ARIMA é univariado, o VAR tradicional consegue lidar com uma dezena de variáveis diferentes, o modelo MIDAS até consegue trabalhar com algumas dezenas de variáveis, porém pode sofrer com a multicolinearidade e o custo computacional, nesse sentido um modelo capaz de incorporar dezenas ou até mesmo centenas de elementos diferentes em um mesmo sistema preditivo teria um apelo respeitável na economia real, é justamente nessa necessidade de modelos que comportam um grande número de variáveis que surge a família dos *Dynamic Factor Model* (DFM).

A noção de utilizar fatores dinâmicos para predição econômica é atribuída a Geweke (1977)³². Os DFM surgem como modelos para abarcar a economia em expansão, e ser capaz de modelar dinâmicas que outros modelos falham na incorporação. Os DFM's se mostraram úteis para sintetizar informações de variáveis observadas em diferentes frequências, estimar o ciclo econômico latente, fazer previsões em tempo real e a longo prazo, e estimar probabilidades de recessão e pontos de virada."(Doz e Fuleky, 2019, p. 2).

A forma geral de um modelo DFM pode ser vista na equação 2.7 apresentada por Doz e Fuleky (2019).

$$x_t = \mu + \Lambda_0 f_t + \Lambda_1 f_{t-1} + \dots + \Lambda_s f_{t-s} + e_t, \quad (2.6)$$

³¹ *ensemble stacking*: modelos combinados

³² Se pensarmos em uma sequência histórica seria: ARIMA - 1970, DFM - 1977, VAR - 1980 e por último o MIDAS - 2004. No presente trabalho não optamos por apresentar modelos em uma sequência histórica, mas sim de forma didática, pensando justamente no nível de complexidade dos modelos, apesar de ser um critério subjetivo a depender do leitor, mas também podemos refletir que estamos apresentando os modelos em uma sequência de capacidades, em que cada modelo consegue fazer um pouco mais do que o anterior, mesmo cada um tendo seu melhor caso de uso. Contudo vale ressaltar a curiosidade, como um modelo mais complexo como o DFM surge antes de modelos mais "simples" comparativamente como o VAR ou o MIDAS.

ou na forma reduzida

$$x_t = \mu + \Lambda(L)F_t + e_t, \quad (2.7)$$

Em que

- a) x_t representa o vetor das N variáveis observadas no instante t;
- b) μ é o vetor de interceptos das variáveis observadas;
- c) $\Lambda(L)$ é a matriz de polinômios de defasagens;
- d) F_t é o vetor dos r fatores comuns latentes;
- e) e_t representa o vetor dos componentes idiossincráticos³³.

Dentre os modelos apresentados, tanto em nível de complexidade computacional, assim como a interpretabilidade dos modelos, não no sentido de seus resultados, mas sim de sua construção o DFM é o modelo mais complexo dentre os modelos tradicionais estudados no presente trabalho, desse modo, e seguindo nossa proposta didática ele é o último modelo tradicional que abordaremos. Inclusive a escolha do DFM ser o último é que também o DFM consegue englobar outros modelos em sua composição, inclusive na subsecção 2.2.2 trataremos de um modelo DFM que o autor usou modelos de IA em sua composição, deixando o limiar de tradicionais e de IA mais nebuloso, mas também apresentando um potencial, a combinação de modelos.

Alves (2009) em sua dissertação de mestrado abordou modelos de fatores dinâmicos (do inglês *Dynamic Factor Models* - DFM) para entender o núcleo da inflação brasileira. Por outro lado Moura *et al.* (2020) avaliou os ciclos econômicos brasileiros usando uma combinação entre o DFM e o VAR.

2.2.2 Modelos de IA: Uma explicação

Os modelos que chamamos de IA, são na realidade modelos não-lineares modernos³⁴, estes não assumem a linearidade nos parâmetros dos preditores do modelo, isso ocasiona implicações na interpretabilidade dos modelos (Vasconcelos, 2017, p. 22). Apesar do termo Inteligência Artificial ter seu uso mais evidente pelos algoritmos baseados em redes neurais e aprendizado profundo, ainda existem modelos que não tem a mesma notoriedade popular que

³³ Não chamamos e_t de vetor de erros, pois no contexto do DFM não se trata só de erro de medição ou ruídos, mas sim a parte da variável que não é explicada por fatores comuns

³⁴ Existem modelos considerados tradicionais não-lineares como as árvores de decisão, porém sua interpretabilidade é natural

tais algoritmos³⁵, mas que podem ser tratados como IA, por possuírem características de falta interpretabilidade natural e não linearidade nos preditores, como é o exemplo do Random Forest que trataremos nesse trabalho.

De uma maneira técnica os modelos de IA "utilizam funções específicas que permitem realizar previsões mediante a atribuição de pesos, que são medidos e alterados por uma função de ativação que busca diminuir o erro de um modelo, que tende a ser muito mais preditivo do que analítico."(Carmo e Lopacinski, 2023, p.10). A partir da definição de Carmo e Lopacinski (2023) e de Vasconcelos (2017) já entendemos o contexto onde esses modelos se encaixam, são modelos que buscam estimar a variável escolhida com maior precisão, mas para isso o pesquisador sacrifica a interpretabilidade natural do modelo, e de certa forma, também seu poder decisivo.

O poder preditivo de um modelo de IA permite que modelos possuam muitas variáveis, e capturem um comportamento dinâmico e entrelaçado das observações, algo que a simples análise humana e pressupostos lineares não seriam capazes de observar. Por outro lado, a decisão de utilizar ou não uma variável, dos pesos que cada valor possui e da interpretação após treinamento foge do controle do pesquisador, sendo de certa forma, atribuído ao modelo essa tarefa. Assim fica evidente onde modelos de IA tem maior possibilidade: problemas complexos, com muitas variáveis, diversos fatores dinâmicos, com alto grau de correlação e que a interpretação é menos importante que a capacidade preditiva.

Usando um exemplo prático, estimar o PIB é um ótimo candidato a modelos de IA, muitas variáveis podem ser usada como preditoras, dinamismo frequente e alto grau de correlação entre elas, se trata de um problema complexo, onde de certa forma pouco interessa a relação interna entre as variáveis, mas muito se interessa o desempenho do próprio PIB. Por outro lado, um modelo para estimar o grau de encadeamentos de uma economia, apesar de ter uma complexidade tremenda e uma grande quantidade de preditores, o que importa nesse tipo de modelo é sua interpretabilidade, e nesse sentido, modelos tradicionais no aspecto da interpretação, provavelmente atenderiam melhor os requisitos dado a natureza do problema.

³⁵ O uso do termo Inteligência Artificial se popularizou com os modelos grandes de linguagem - LLM (do inglês, *Large Language Models*), mas os algoritmos de IA surgem anteriormente a esses modelos. O nome vem justamente da ideia que essa classe de algoritmos tenta simular o comportamento humano, porém seu funcionamento não poderia ser mais diferente, como veremos na presente sessão. Outro fator que influencia o nome IA, é a representação visual do Percéptron, menor unidade das redes neurais, em que seu diagrama lembra a forma de um neurônio humano, que propriamente inspirou o nome redes neurais, e consequentemente, ajudou a popularizar o termo Inteligência Artificial

2.2.2.1 *Redes Neurais*

Os modelos baseado em redes neurais são naturalmente complexos, mas tentaremos explicar de uma forma descomplicada como esses modelos surgiram, as inspirações, a aplicação teórica e aplicações práticas para a predição econômica.

Por definição rede neural trata-se de uma modelo baseado em rede composto por diversas camadas, cada camada é composta por nós, e cada nó é calculado usando os nós da camada anterior, e a saída é calculada usando os nós da última camada oculta. Não existe interpretação para esses nós, que são computados usando retropropagação (Ghosh e Ranjan, 2023).

Todavia, redes, nós e retropropagação são conceitos avançados para entender de fato que o são redes neurais. De uma maneira mais humana, redes neurais são utilizadas "para replicar o funcionamento do pensamento humano artificialmente e encontrar respostas ou hipóteses tal qual um humano faria, porém, evitando seus erros e agilizando processos que podem demorar muito tempo quando biologicamente realizados." (Carmo e Lopacinski, 2023, p. 8). A replicação do pensamento humano não ocorre tentando simular as reações físico-químicas que acontecem em nossos cérebros, na realidade trata-se de uma abstração do pensamento humano através de funções matemáticas, uma sequência de combinações lineares que conseguem resolver problemas não-lineares.

Dessa forma o objetivo desse tipo de modelo é justamente "extrair combinações lineares por meio das covariáveis e então modelar a variável que se deseja prever como uma função não linear destas covariáveis." (Kava, 2022, p. 40-41). Isso ocorre por meio da união de pequenos modelos preditivos simples. Esses modelos chamados de neurônios artificiais, são os responsáveis por essa predição. O primeiro neurônio artificial, ou também chamado de perceptron foi descrito inicialmente por Rosenblatt (1958)³⁶. A representação visual pode ser verificada na figura 1. Esse modelo consistia em modelo que soma as entradas, obtendo um valor intermediário chamado de z , que passa por uma função de ativação, o perceptron utiliza uma

³⁶ Chamar o perceptron de Rosenblatt (1958) de primeira IA pode ser um eufemismo, até porque a ideia de IA é mais antiga remetendo as reflexões de Alan Turing, mas principalmente se comparamos aos modelos de redes neurais atuais que são muito mais complexos que o perceptron. Contudo a ideia estava lá, e ela realmente veio a se tornar os modelos computacionais sofisticados que temos no mundo contemporâneo. Mas pensando no perceptron estritamente como modelo matemático criado em 1958, ele surge antes do ARIMA, que é de 1970. Claro ambos tem propostas diferentes, o ARIMA é um modelo autorregressivo univariado, já o perceptron é um classificador linear simples, mas mesmo assim se ignorarmos esse fato por um momento, o modelo que é vendido como inovador, surge como ideia antes de muitos dos modelos tradicionais, mas isso é mais uma reflexão sobre a evolução das técnicas de modelagem do que propriamente uma discussão sobre predição econômica, mas fica a reflexão sobre os modelos vendidos como "inovadores".

função sinal como ativação, mas outros tipos de modelos utilizam outras funções de ativação (Ekman, 2021).

A representação matemática de um perceptron é definida por:

$$f(x) = \phi \left(\sum_{i=0}^n w_i x_i \right) \quad (2.8)$$

com


$x_0 = 1$ (Bias ou viés)

x_i = Entrada

w_i = Pesos

ϕ = Função de ativação

Figura 1 – Perceptron



Fonte: Elaborado pelo autor (2026).

Contudo um perceptron por si só, não consegue resolver problemas não-lineares, afinal a combinação de entradas e saídas realizando uma operação linear não pode ter uma resposta para um problema não-linear. Mas a verdadeira solução para problemas não-lineares começa a partir da combinação de dois perceptrons. Intuitivamente, um perceptron é um classificador linear simples, mas combinando os resultados das respostas de dois perceptrons,

que são lineares, com um terceiro neurônio combinando essas respostas, consegue-se resolver problemas não-lineares. Nesse contexto surge a ideia de redes.

Retomando o conceito de Ghosh e Ranjan (2023) entendemos o que são as redes, e o que são os nós, se tratam dos neurônios conectados e os pesos calculados de cada um. Contudo um conceito relevante que ainda não foi discutido, justamente esse conceito que permitiu a evolução do modelo de Rosenblatt (1958) para as redes multicamadas que existem hoje. O nome desse conceito é a retropropagação, conhecido também como *backpropagation* que é justamente o que permite o aprendizado nessa arquitetura.

Após a invenção do perceptron havia ainda um espaço grande entre um único neurônio e as redes neurais multicamadas. O perceptron tem uma limitação relevante já citada, só consegue resolver problemas que são linearmente separáveis, isso acontece pela maneira como o aprendizado do modelo de Rosenblatt (1958) funciona. As entradas do perceptron eram multiplicadas com o peso e somadas com o viés, passada a uma função sinal ou degrau ³⁷ que resultava na saída. O aprendizado ocorria da seguinte forma: se a saída fosse igual a saída esperada, nenhum peso era alterado, se a saída fosse diferente da saída esperada os pesos eram modificados, até o modelo se ajustar a saída esperada.

Intuitivamente a limitação é explícita, mas para ficar mais evidente suponhamos o problema clássico das redes neurais, resolver o problema do ou-exclusivo, o XOR³⁸. A característica do XOR é que quando as entradas binárias são diferentes o resultado é 1, e quando as entradas são iguais o resultado é 0, conforme a tabela verdade:

Tabela 1 – Tabela verdade da operação XOR

A	B	$A \oplus B$
0	0	0
0	1	1
1	0	1
1	1	0

Fonte: Elaboração própria.

Minsky e Papert (1969) provaram que o perceptron de Rosenblatt (1958) não conse-

³⁷ A diferença dessas duas funções está na interpretação do 0, enquanto a função sinal tem a seguinte relação $\text{sgn}(x) \begin{cases} -1 & \text{se } x < 0; \\ 0 & \text{se } x = 0; \\ 1 & \text{se } x > 0. \end{cases}$ Já a função degrau considera o 0 como um valor positivo $H(x) \begin{cases} -1 & \text{se } x < 0; \\ 1 & \text{se } x \geq 0, \end{cases}$ ambas podem ser usadas no perceptron e ambas tem o mesmo problema que discutiremos no decorrer do texto

³⁸ O XOR parece ser um problemas simples, mas essa operação é fundamental dentro da computação, sendo utilizada em áreas fundamentais, como a criptografia, mascarás de bits, armazenamento digital, construção de processadores, construção de redundância, etc. Calcular o XOR significa perceber o comportamento computacional, mas para além disso o comportamento humano, que não é linear, assim como, o XOR também não é

guiria resolver um problema que não fosse linearmente separável, como o do XOR, imaginemos o XOR como um problema gráfico, enquanto um problema linear precisa de apenas uma reta para classificar corretamente os valores, para solucionar o XOR seriam necessários duas retas ou mais para classificar corretamente. E é exatamente nesse ponto em que o perceptron falha. A partir da constatação de Minsky e Papert (1969) o mundo viveu uma era conhecida como o "inverno da IA", onde o modelo mais elegante criado até então ficaria estagnado.

Mas essa configuração mudou com a adoção de um método de aprendizado que mudou totalmente a forma como a IA era construída, a retropropagação. A popularização do seu uso é atribuída a Rumelhart *et al.* (1986) que aplicaram o conceito de retropropagação em redes neurais. "O procedimento ajusta repetidamente os pesos das conexões na rede para minimizar uma medida da diferença entre o vetor de saída real da rede e o vetor de saída desejado." (Rumelhart *et al.*, 1986, p. 533, tradução nossa).

Esse marco inicia a construção dos modelos mais avançados de IA, os modelos criados por Rumelhart *et al.* (1986) são redes neurais totalmente conectadas, significa que todos os neurônios de uma camada se conectam com os da camada seguinte. E baseada na arquitetura do *feedforward* em que os dados fluem em uma única direção da entrada para a saída, sem loops, ou recursão.


A elegância dessa solução é impressionante, porém aplicar ela a perceptrons combinados não é tão simples, existem algumas alterações do modelo de Rosenblatt (1958). A primeira alteração é a noção de função de ativação, enquanto o perceptron utiliza a função sinal/degrau, a retropropagação não permite o uso desse tipo de função, essas funções não são deriváveis por serem descontínuas em $x=0$, e o conceito que permite a retropropagação é justamente o uso de derivadas, portanto a primeira alteração é a troca por uma função contínua e derivável, como por exemplo a função sigmoide ³⁹ representada na equação 2.9 e na figura 2.

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.9)$$

A segunda alteração é a que permite a combinação dos neurônios, enquanto o perceptron usa o erro direto para recalcular os pesos, redes multicamadas essa noção não é

³⁹ Existem outras funções que podem ser usadas como ativação, como a ReLU (Unidade Linear Retificada), a TanH (Tangente Hiperbólica), a Softmax, a linear, etc. Não entraremos em detalhes sobre cada uma das funções de ativação, mas elas são uma das decisões que o pesquisador deve tomar ao usar redes neurais, o tipo de função de ativação, o número de camadas, a taxa de aprendizado são o que chamamos de hiperparâmetros do modelo, e o ajuste deles permite um desempenho melhor ou pior a depender dos dados e do problema.

Figura 2 – Função Sigmoide



Fonte: Elaborado pelo autor (2026).

direta. O erro da camada de saída deve ser utilizado para calcular os pesos da camada oculta anterior, com esses pesos calculados, calcular o erro da camada imediatamente precedente, e assim conseguinte até a primeira camada, esse processo é a retropropagação do erro, camada por camada. Esse processo é repetido inúmeras vezes até os pesos se ajustarem e o erro total for minimizado e é dessa maneira que a rede aprende.

Mas como esse erro é minimizado? É com essa pergunta que conectamos com a necessidade da função de ativação ser derivável. Retomamos o conceito do cálculo: A derivada mede a taxa de variação instantânea de uma grandeza em relação a outra, de uma forma geométrica a derivada representa a inclinação da reta tangente ao gráfico função em um ponto específico do plano.

Nesse sentido o conceito de derivada para esse algoritmo funciona como uma bússola. Imaginemos que nossa função do erro é quadrática, como na equação 2.10,

$$E = \frac{1}{2}(y - \hat{y})^2 \quad (2.10)$$


Onde:

- y representa o valor observado;
- $\hat{y}$ representa o valor predito;
- E representa o erro quadrático.

A visualização dessa função pode ser verificado na figura 3.


Podemos usar o conceito da derivada para encontramos os valores de $\hat{y}$ que minimizam o erro E . Ajustando os coeficientes utilizando a derivada como ponteiro, procurando o melhor valor para que o erro seja minimizado, conforme a figura 4.

Figura 3 – Função de erro quadrático.



Fonte: Elaborado pelo autor (2026).

Figura 4 – Função de erro quadrático e segmentos de retas tangentes representando a derivada em diferentes pontos.




Fonte: Elaborado pelo autor (2026).

Porém a função de erro de uma rede neural não é uma simples função quadrática, afinal se fosse a solução seria trivial, o gráfico seria algo mais parecido com o representado na figura 5, mas mesmo assim a representação é imprecisa, pois redes neurais profundas contam com muitas entradas e camadas, possuem n-dimensões e é praticamente impossível conceber uma representação visual do erro dessas redes. Porém, mesmo que imprecisas, essas representações nos permitem entender a ideia por trás da retropropagação, o chamado gradiente descendente.

O gradiente descendente "É um método iterativo no qual começamos com um palpite inicial da solução e depois refinamos gradualmente."(Ekman, 2021, p. 45, tradução nossa). Para funções simples de uma variável o gradiente descendente é o algoritmo que usa as derivadas das

Figura 5 – Superfície de erro



Fonte: Elaborado pelo autor (2026).

funções para minimizar o erro, por outro lado

Se tivermos uma função de n variáveis, então nosso gradiente consistirá em n derivadas parciais, e podemos calcular o próximo passo como $x - \eta \nabla y$, onde tanto x quanto ∇y são vetores com n elementos. (Ekman, 2021, p. 47, tradução nossa)

Uma maneira mais intuitiva de se entender o gradiente descendente seria com uma analogia: O gradiente descendente é como um animal cego e com sede encima de um terreno acidentado, ele não sabe onde tem água, e não sabe onde está, porém ele sabe que a água fica nos vales, e pode usar suas patas para identificar a inclinação do terreno, ele procurará maneiras de sempre ir descendo, e quando chegar no vale encontrará água.

E com essa analogia já entendemos também um dos problemas dessa arquitetura, os mínimos locais. Se o animal encontra uma depressão na montanha, que não tem água, mas que para todos os lados é necessário subir primeiro para posteriormente descer o animal cego acaba morrendo de sede. De certa forma é assim que funciona o gradiente descendente, quando encontra mínimos locais, o algoritmo "pensa" estar na solução ótima, mas é apenas um mínimo local⁴⁰.

⁴⁰ Existem estudos dedicados a minimizar esses problemas, como encontrar uma taxa de aprendizado ótimo, para evitar mínimos locais e mesmo assim encontrar soluções adequadas, mas essas análises fogem do escopo de nosso trabalho, mas vale a leitura do livro de Ekman (2021) para entender mais sobre redes neurais, funções de ativação, gradiente descendente e outros conteúdos sobre redes neurais na teoria e na prática

Com essa noção de como surgiram os modelos baseados em redes neurais, posteriormente com a evolução das técnicas de IA surgem os algoritmos de *deep learning* (aprendizado profundo), esses modelos não são diferentes das redes neurais estudadas no presente trabalho, a principal diferença é a escala. No *deep learning* são muitas camadas, imagine da seguinte forma, com zero camadas ocultas temos uma regressão logística ou um perceptron, com uma camada oculta temos as redes neurais, com duas ou mais temos o que chamamos de *deep neural networks* que são redes neurais com muitas camadas ocultas. Esses algoritmos que rodam as grandes tecnologias de IA atualmente, como visão computacional, chatbots, carros autônomos, etc. Contudo também apresentam os mesmos problemas apresentados de uma forma geral, a interpretabilidade, mínimos locais, sobreajuste.

Redes com arquiteturas gigantescas podem resolver problemas complexos, porém não tem a interpretabilidade que modelos simples possuem. Nesse ponto toma se a decisão, por exemplo, em um carro autônomo, importa se a IA decide trocar de pista pela proximidade com o retrovisor ou com a roda de outro carro? Se a resposta for não, não existe um problema, pois o resultado foi alcançado, o carro trocou de pista no momento certo e evitou um acidente, não importa se foi pelo retrovisor, pela roda, ou por qualquer outro fator. Nesse sentido a predição econômica caminha pela mesma estrada, e uma pergunta deve ser feita o processo de como eu cheguei no resultado importa? se a resposta for sim, talvez redes neurais não sejam o modelo mais adequado, mas se for não elas apresentam um grande potencial, conforme veremos a seguir.

A partir desse exposto vimos de uma forma simplificada⁴¹ como redes neurais surgiram e como elas funcionam por baixo dos panos, agora podemos ver as aplicações desses modelos para predição econômica.

Começaremos por Vasconcelos (2017) que utilizou modelos de redes neurais em sua tese, diferente de nosso trabalho o autor realizou sua pesquisa em dados de 41 países de 2001 à 2015 (Segundo o autor em alguns casos a série pode até ser mais extensa devido a disponibilidade), essa escolha se deu principalmente por serem membros da Organização para a Cooperação e Desenvolvimento Econômico (OCDE), mais alguns países que apesar de não serem membros possuem relevância econômica e/ou tinham a disponibilidade de dados.

As variáveis selecionadas pelo autor são: pib, seus componentes, comércio internaci-

⁴¹ A formulação matemática dos modelos de IA existe, e vai muito além da forma geral do perceptron apresentada na equação 2.8, na realidade redes neurais profundas envolvem um conhecimento profundo sobre otimização e álgebra linear, que apesar de extremamente relevantes na compreensão do funcionamento das redes neurais, foge completamente do escopo de uma monografia de economia explicar algebricamente o funcionamento dessas redes. Dessa forma sugerimos novamente a leitura de Ekman (2021) que explica de forma mais detalhada, mais do que poderíamos no presente trabalho, o a lógica matemática das redes neurais.

onal, preços, câmbio, juros, títulos públicos, câmbio, mercado futuro, índices de bolsa, demais indicadores de negócios público e privado, qualidade do crédito, operações de crédito do governo em detalhes, operações financeiras como BIS, reservas, balança comercial, fluxo de capitais, CDS⁴², VIX⁴³, preços de commodities. Essas variáveis⁴⁴ são de frequência trimestral. Os dados foram coletados a partir de conjunto de bases (Banco Mundial, OCDE, BIS, Bloomberg)

O autor comparou diversos modelos nesse teste, modelos de equações individuais, Fatores comuns, modelos mistos de quadrados mínimos ordinários, Lasso e regressão em árvore e métodos de *machine learning* como *Support Vector Machine*, *Random Forest* e *deep learning*.

O objetivo do autor era verificar as relações entre Política fiscal, mercado internacional e as flutuações do produto dos países, no sentido de desempenho o autor constatou que os modelos baseados em *deep learning* conseguiram superar os modelos tradicionais de equações individuais e de fatores comuns, porém se saíram piores que os modelos mistos construídos, assim como teria se saído pior que os outros modelos de *machine learning* analisados na tese.

No sentido todos os modelos apontaram a interpretação de que o mercado internacional foi mais determinante do que a política fiscal. O autor aponta que redes neurais são sim métodos robustos para predição de modelos macroeconômicos. Porém conforme os resultados apontados fica evidente que redes neurais tem falhas estruturais como a interpretabilidade e não são necessariamente a melhor solução para todos os problemas.

Carmo e Lopacinski (2023) também comparou modelos, eles os classificaram entre clássicos e contemporâneos. O trabalho examinou dois modelos: regressão linear simples; e redes neurais multicamadas. Assim aplicaram ambos modelos à predição da remuneração média mensal paga aos empregados nas 27 unidades da federação brasileira. Para isso os dados foram extraídos do IBGE através do Sistema de Recuperação Automática de dados (SIDRA). O estudo aponta um desempenho superior das redes neurais em comparação a regressão linear no critério da precisão. Contudo, os autores levantaram o mesmo ponto de Vasconcelos (2017) que a interpretabilidade das redes neurais é limitada.

Do ponto de vista analítico, a análise de regressão linear é mais dinâmica e informativa que a RNA MLP⁴⁵. Pois, ao identificar os coeficientes do modelo de regressão e seus sinais, é possível compreender o impacto de cada variável independente significativa na explicação do comportamento da variável de estudo. Ao passo que, a RNA MLP somente permite avaliar qual o grau de

⁴² *Credit Default Swap* que é um indicador de risco de crédito.

⁴³ Índice de volatilidade.

⁴⁴ Para mais detalhes sobre as variáveis recomendamos a consulta do material original de Vasconcelos (2017)

⁴⁵ Redes Neurais Artificiais *Multilayer Perceptron*

importância das variáveis explicativas do modelo. (Carmo e Lopacinski, 2023, p. 17)

Carmo e Lopacinski (2023) demonstraram que as redes neurais possuem uma capacidade modelar todas as variáveis, enquanto outros métodos como a regressão linear só consideram as variáveis significantes para o modelo. Outro ponto elencado pelos autores é a capacidade de modelar problemas não lineares, sendo uma vantagem em relação ao modelo tradicional da regressão linear.

Os autores pontuam que ambos métodos tem vantagens e desvantagens, enquanto modelos tradicionais possuem rigor metodológico e capacidade interpretativa, modelos contemporâneos, como redes neurais podem ser considerada mais flexíveis, adaptando-se a tendências não-lineares, e até a dados incompletos, porém devido a sua complexidade arquitetural possuem baixa interpretabilidade.

Amaral *et al.* (2023) também realizaram testes de modelos baseados em redes neurais, porém ao invés de comparar a outras técnicas tradicionais, os autores testaram diferentes configurações de redes neurais. A principal diferença dos modelos até então apresentados é o métodos de treinamento, enquanto as redes neurais estudadas são do tipo totalmente conectada baseadas no *feedforward* as três redes testadas por Amaral *et al.* (2023) são do tipo *Recurrent Neural Network* (RNN)⁴⁶.

As RNN são um tipo de rede neural que foi desenvolvida para identificar padrões em um banco de dados. Através dos algoritmos da rede neural, ele é capaz de identificar, dentro de uma sequência de informações, similaridades de palavras, de texto, imagens e números, utilizando esses padrões para aprender e futuramente entender o que o está sendo “apresentado”. (Amaral *et al.*, 2023, p. 11)

Para além disso os autores utilizaram um tipo de RNN mais sofisticada, a chamada RNN de Memória *Long-Short Term* (LTS), segundo os autores na arquitetura desse tipo de RNN é possível armazenar memórias de longo e curto prazo. Sendo uma arquitetura adequada para séries temporais econômicas que sofrem influências de curto e longo prazo.

No trabalho os autores testaram três modelos de redes neurais: univariado *stacked*⁴⁷; multivariado; e univariado bidirecional⁴⁸. Os dados foram extraídos do banco central do Brasil e

⁴⁶ Redes Neurais Recorrentes

⁴⁷ Esse tipo de modelo "possui uma arquitetura de mais de uma camada de neurônio escondida, no qual cada camada contém múltiplas células de memória." (Amaral *et al.*, 2023, p. 13).

⁴⁸ Em modelos Univariados bidirecionais, ao invés de um único modelo, existem dois. O primeiro aprende a sequência da entrada e o segundo o inverso, proporcionando um maior quantitativo de informações para o treinamento. (Amaral *et al.*, 2023)

do IBGE no período de janeiro de 2002 até março de 2023. O conjunto de dados compreende: taxa SELIC⁴⁹; IPCA; PIM⁵⁰; e taxa de câmbio.

Os resultados apontados pelos autores indicaram um desempenho relevante das RNN LTS. O melhor dos três modelos foi o multivariado, que apresentou os menores indicadores de erros, possuindo um maior grau de explicabilidade. O segundo com melhor desempenho foi o modelo univariado *stacked*, em que os modelos que usaram a taxa SELIC como entrada, obtiveram os melhores resultados. E o pior dos modelos foi o univariado bidirecional, que não obteve resultados satisfatórios, não superando em nenhuma variável o modelo univariado *stacked*.

A reflexão proposta pelo autor é que mesmo com uma quantidade limitada de dados o modelo baseado em RNN LTS multivariado teve desempenho satisfatório para predição de variáveis econômicas. Mas que mesmo o modelo obtendo um resultado aceitável, ainda assim é necessário uma análise de indicadores históricos e fáticos por um profissional técnico da área.

A partir do exposto de Amaral *et al.* (2023) foi possível notar outro tipo de arquitetura para redes neurais, essa com uma adequação relevante para séries históricas, porém ainda assim com as limitações inerentes a esse tipo de modelo, que apesar de terem uma explicabilidade alta dos fatores envolvidos no modelo e uma capacidade de captar relações quase que imperceptíveis nas variáveis econômicas, ainda se faz necessário o aval do técnico economista, implicando que a interpretabilidade de um modelo é algo importante.

Como nos outros modelos, é importante olhar como a literatura internacional utiliza os modelos. Entretanto, dessa vez, vamos utilizar o material de Ghosh e Ranjan (2023), que realizaram um trabalho com redes neurais para predição do GDP da Índia de janeiro de 2003 a dezembro de 2019. Esse material se assemelha com o que desejamos produzir com o presente trabalho, claro por tratarem de uma série histórica semelhante, mas especialmente, pois tanto o Brasil como a Índia são membros da lista de países emergentes, o que implica em economias complexas com características parecidas.

Os dados do trabalho foram extraídos do Banco da Reserva da Índia ou da CEIC⁵¹, foram analisadas 13 variáveis mais o GDP como variável a ser predita. O modelo proposto pelos pesquisadores da Índia tratava-se de uma combinação de modelos para o *nowcasting*⁵², o

⁴⁹ Sistema Especial de Liquidação e Custódia (SELIC)

⁵⁰ Produto Industrial Mensal (PIM)

⁵¹ Trata-se de uma base de dados de indicadores macroeconômicos globais

⁵² *nowcasting* é uma técnica de predição de variáveis de alta frequência, no contexto do estudo predizer o GDP usando variáveis diárias/semanais

modelo principal é um DFM, como visto anteriormente, para estimar valores para cada indicador econômico com base nos valores históricos desses indicadores foram utilizados três variações de modelo: *Random Forest*, ARIMA, Prophet⁵³. E como modelo ponte, que conecta os fatores dinâmicos estimados com o GDP, temos o AR(1) e as redes neurais.

Os resultados obtidos pelos pesquisadores apontam que o modelo Prophet se saiu melhor no *nowcasting* do GDP, e que para previsões a partir de um mês as redes neurais apresentaram uma melhoria significativa em relação ao modelo AR(1), mas que para longos períodos, mais de um ano, o erro só aumentou, indicando que esse tipo de modelo de *nowcasting* não é o mais indicado para predição em longos períodos.

Apesar da semelhança dos dados e do contexto de aplicação, o trabalho de Ghosh e Ranjan (2023) busca uma outra técnica de predição, buscando a alta frequência das variáveis e informações rápidas para tomadas de decisões fundamentadas. A partir do exposto dos autores é possível notar como diferentes modelos podem ser combinados para encontrar a melhor solução, nesse contexto as redes neurais foram usadas como modelo ponte, não como modelo principal, mas mesmo assim obtiveram resultados melhores que um modelo consolidado como o AR(1) para o *nowcasting*.

A partir dessa exposição de autores fica claro como métodos atuais como as redes neurais tem ganhado espaço dentro da predição econômica, não se tratam de modelos milagrosos que conseguem resolver todos os problemas do mundo. Esses modelos tem sim uma liberdade maior, não se restringindo a metodologias rígidas conforme Carmo e Lopacinski (2023), mas ainda assim dependem de um pesquisador conduzindo e interpretando seus resultados (Amaral *et al.*, 2023).

Vimos também que talvez sua maior potencialidade não seja como o perceptron de Rosenblatt (1958), mas sim a combinação com outras técnicas e variações, criando modelos com alta capacidade preditiva e robustez conforme Amaral *et al.* (2023) e Ghosh e Ranjan (2023) demonstraram.

⁵³ O modelo Random Forest ainda veremos mais sobre o mesmo no presente trabalho. O modelo Prophet não será contemplado profundamente, mas afim de curiosidade esse é um procedimento baseado em modelos aditivos com ampla capacidade para aplicação em *nowcasting* por conseguir ajustar tendências não-lineares usando a sazonalidade (Ghosh e Ranjan, 2023).

2.2.2.2 *Random Forest*

Até o presente momento vimos diversos modelos, suas histórias e aplicações, desde os ditos tradicionais, até modelos modernos baseados em IA, nesse sentido abordaremos mais um modelo atual as Florestas Aleatórias, ou mais conhecido como *Random Forest* do inglês.

A criação do *Random Forest* é atribuída a Breiman (2001). Trata-se da designação de uma "combinação de preditores em forma de árvore, de modo que cada árvore depende dos valores de um vetor aleatório amostrado de forma independente e com a mesma distribuição para todas as árvores da floresta."(Breiman, 2001, p. 1, tradução nossa). De uma forma mais simplificada, o *Random Forest* é uma técnica que consiste em criar vários pequenos modelos com preditores escolhidos de forma aleatória, a resposta advém de uma combinação das respostas de todos os modelos, que no caso de modelos regressivos é dada pela média dos valores.

De uma maneira técnica o *Random Forest*

É um classificador que consiste em uma coleção de classificadores em forma de árvore $\{h(\mathbf{x}, \theta_k), k = 1, \dots\}$, onde os $\{\theta_k\}$ são vetores aleatórios independentes e identicamente distribuídos, e cada árvore dá um voto unitário para a classe mais popular na entrada $\mathbf{x}$. (Breiman, 2001, p. 6, tradução nossa)

A força desse algoritmo é lidar com a grande quantidade de dados e capturar o comportamento de uma maneira que cada variável tem um pedaço da relevância. Nos modelos *Random Forest* do tipo de regressão⁵⁴ o resultado final do modelo será a média do resultado de cada uma das árvores. Essa noção é confirmada por Landowska *et al.* (2025) onde o autor pontua como o algoritmo do "constrói múltiplas árvores de decisão e agrega seus resultados, o que lhe permite lidar com conjuntos de dados de alta dimensão, reduzir o overfitting e fornecer insights valiosos sobre a importância das variáveis."(Landowska *et al.*, 2025, p. 5).

Lemos e Souza (2025) explica que o *Random Forest* é um modelo baseado árvores de regressão, que são um tipo de árvores de decisão. Nesse tipo de modelo "cada nó representa uma condição de decisão baseada em uma variável preditora, fornecendo um valor numérico, que normalmente é a média dos valores observados nas amostras que atingem aquele nó."(Lemos e Souza, 2025, p. 8). Segundo Landowska *et al.* (2025) o *Random Forest* leva vantagem em comparação a modelos econométricos tradicionais, pois conseguem lidar com relação não lineares e interações complexas entre as variáveis.

⁵⁴ Em classificações binárias no *Random Forest*, existe um sistema de votação, onde a maioria vence, um modelo democrático, se a maior quantidade de árvores forem um tipo de resposta, a resposta do modelo como um todo é o resultado da maioria

A equação que representa o modelo preditivo do *Random Forest* esta disposta na equação 2.11 apresentada por Vasconcelos (2017).

$$f(X) = \sum_{m=1}^M c_m I(X \in \mathbb{R}_m) \quad (2.11)$$

O random forest como modelo predito de variáveis macroeconômicas foi utilizado por Landowska *et al.* (2025) no contexto da predição do GDP, por Lemos e Souza (2025) para uma abordagem utilizando as atas do COPOM e por Kava (2022) em sua dissertação como um dos modelos candidatos a predição de variáveis macroeconômicas brasileiras.

Existem centenas de outros modelos que seriam excelentes oportunidades de análises e comparações, porém como tudo na economia os recursos são finitos, e apesar das necessidades humanas ilimitadas, o *Random Forest* será o último modelo a ser abordado no presente trabalho. A partir desse ponto não trataremos mais sobre a literatura produzida como um relato do que foi feito, mas sim nos utilizaremos dessa fundação teórica como alicerces para a construção, aplicação e comparação dos modelos nas sessões futuras.

3 METODOLOGIA

3.1 Delineamento de pesquisa

Com base nos objetivos da presente pesquisa, a mesma se classifica como explicativa. Esse tipo de pesquisa "têm como preocupação central identificar os fatores que determinam ou que contribuem para a ocorrência dos fenômenos." (Gil, 2002, p. 87). Ao analisarmos o desempenho dos diferentes modelos econométricos voltados para a predição do PIB brasileiro, estamos buscando identificar e compreender os diferentes fatores que explicam esse desempenho, enquadrando-a como explicativa.

Sobre os procedimentos de coleta de dados, a presente pesquisa se enquadra como documental, por utilizar-se de dados que não receberam um tratamento e estão dispostos em repositórios digitais de dados. Segundo Gil (2002) a pesquisa documental apropria-se de diversas fontes, não somente material impresso em bibliotecas, onde os documentos utilizados podem ter um tratamento analítico ou não.

Por fim, ao se tratar de uma pesquisa que compara diferentes modelos econométricos, assim como avalia o desempenho dos mesmos, seguindo o rigor matemático e estatístico, ela se enquadra como uma pesquisa predominantemente quantitativa onde apropria-se do método comparativo e estatístico. Para Lakatos e Marconi (2003) o método estatístico trata-se da redução dos fenômenos a termos quantitativos e a manipulação estatística, onde possibilita a generalizações sobre sua natureza, ocorrência ou significado. Já "o método comparativo é usado tanto para comparações de grupos." (Lakatos e Marconi, 2003, p. 107, 108).

3.2 Procedimento de coleta de dados

As variáveis foram escolhidas baseadas na dissertação de Rebelo (2022), descritas mais evidentemente na sessão 2. As variáveis escolhidas podem ser verificadas na tabela 2. Os dados utilizados na pesquisa foram extraídos de duas APIs (*Application Programming Interface*, no português, Interface de programação de aplicações). A relação variável - Fonte - URL da API pode ser verificada na mesma tabela.

A primeira fonte foi a API de dados agregados do IBGE, onde nela existem informações econômicas, sociais e demográficas do Brasil.

ou sistema, permitindo a interoperabilidade e o enriquecimento a partir dos dados abertos disponibilizados. (Silva e Silva, 2024, p. 2).

A segunda API utilizada foi a API do BACEN (Banco Central do Brasil), onde foram extraídos dados financeiros. Segundo o próprio BACEN (2025) o "catálogo de dados, permite que os usuários encontrem os conjuntos de informações de seu interesse, entendam sua estrutura e suas limitações, e tenham acesso ao caminho para os dados."

O período analisado foi de 2007 à 2022, devido a disponibilidade de datas nas bases de dados.

3.3 Procedimento de análise de dados

A análise dos dados é um processo muito importante ao usar modelos matemáticos, conforme Kilkenny e Robinson (2018) a qualidade das respostas depende diretamente dos dados usados ¹. Ou seja, não basta ter fontes confiáveis como o (BACEN, 2025) e o (IBGE, 2025a), é necessário um procedimento confiável de ponta a ponta. Para esse processamento dos dados, foi utilizado a linguagem de programação *Python* ² e suas bibliotecas.

O primeiro processo de tratamento foi a conversão dos tipos nativos das APIs para um formato adequado para análise com Python, isso foi feito através da biblioteca Pandas. "Pandas é uma biblioteca de Python de estruturas de dados e ferramentas estatísticas, inicialmente desenvolvida para aplicações de finanças quantitativas." (McKinney, 2010, p. 1, *tradução nossa*).

O segundo passo de tratamento foi a inflação dos dados para 2022, último ano da série, isso foi feito através de um índice de preços, que pode verificado na equação 3.1. O IBGE (2025b) traz a definição de deflator do PIB, porém que se aplica as demais variáveis, em que um deflator é a variação do valor corrente da variável no tempo (t) em relação ao valor da varável do ano (t) a preços do ano anterior, ou seja a variação percentual em relação ao mesmo período do ano anterior.

$$\text{Valor real} = \frac{\text{Valor Nominal}}{\text{índice de Preços}} \times 100 \quad (3.1)$$

O terceiro passo de tratamento foi o treinamento dos modelos. Nesse passo foram utilizados as bibliotecas Scikit-learn e Tensorflow, os modelos foram treinados com dados de 2007 à 2017, totalizando 10 anos na série histórica (dados de treinamento), e deixando os últimos

¹ O termo coloquial em inglês para essa situação se chama GIGO ou *Garbage In Garbage Out*, que em tradução livre - lixo entra lixo sai.

² Python é amplamente utilizado em computação científica e numérica (Python, 2023)

Tabela 2 – Fontes de dados utilizadas nas APIs do IBGE e BACEN

Indicador	Fonte	URL / Endpoint da API
PIB	IBGE	https://servicodados.ibge.gov.br/api/v3/agregados/6784/periodos/-20/variaveis/9808?localidades=N1[all]
Deflator do PIB	IBGE	https://servicodados.ibge.gov.br/api/v3/agregados/6784/periodos/-20/variaveis/9811?localidades=N1[all]
população (milhões)	IBGE	Aindanaocoletado
índice de direitos de propriedade	IBGE	Aindanaocoletado
índice de eficiência jurídica	IBGE	Aindanaocoletado
índice de integridade governamental	IBGE	Aindanaocoletado
índice de despesa governamental	IBGE	Aindanaocoletado
despesa pública em educação (% PIB)	IBGE	Aindanaocoletado
despesa pública em saúde (% PIB)	IBGE	Aindanaocoletado
despesa pública em proteção ambiental (% PIB)	IBGE	Aindanaocoletado
índice de carga fiscal	IBGE	Aindanaocoletado
índice de saúde fiscal	IBGE	Aindanaocoletado
dívida pública (% PIB)	IBGE	Aindanaocoletado
índice de liberdade empresarial	IBGE	Aindanaocoletado
índice de liberdade laboral	IBGE	Aindanaocoletado
taxa de desemprego	IBGE	Aindanaocoletado
índice de liberdade monetária	IBGE	Aindanaocoletado
taxa de inflação	IBGE	Aindanaocoletado
índice de liberdade comercial	IBGE	Aindanaocoletado
balança corrente	IBGE	Aindanaocoletado
Taxa aduaneira	IBGE	Aindanaocoletado
índice de liberdade investimento	IBGE	Aindanaocoletado
investimento direto estrangeiro (% PIB)	IBGE	Aindanaocoletado
índice de liberdade financeira	IBGE	Aindanaocoletado

5 anos (2017 à 2022) para a testagem dos resultados do modelo. Para Santos e Nola (2022) as eficácias dos modelos nos dados de treinamento não são importantes, o que é relevante é como o modelo se sai com os dados de teste, ou seja, se o modelo consegue ser extensivo no período fora da amostra.

O último passo foi o cálculo das métricas de avaliação dos modelos, para esse passo foram avaliadas três dimensões: acurácia, interpretabilidade e custo computacional.

Para a acurácia foram escolhidas as métricas que foram utilizadas por Rebelo (2022): o Erro Quadrático Médio (EQM) descrito na equação 3.2; Erro Absoluto Médio (EAM) descrito na equação 3.3; a Raiz do Erro Quadrático Médio (REQM) descrito na equação 3.4; e por fim, o erro percentual absoluto médio (EPAM) descrito na equação 3.5.

$$EQM = \frac{1}{n} \sum_{i=1}^n (y_i \hat{y}_i)^2 \quad (3.2)$$

$$EQM = \frac{1}{n} \sum_{i=1}^n |y_i \hat{y}_i| \quad (3.3)$$

$$REQM = \sqrt{EQM} \quad (3.4)$$

$$EPAM = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i \hat{y}_i}{y_i} \right| \times 100 \quad (3.5)$$

Para Kava (2022) a interpretabilidade está diretamente relacionada a facilidade que um ser humano tem de entender os resultados de um modelo. Para essa dimensão foram usadas as métricas: Efeitos Locais Acumulados (ELA) descrito na equação 3.6; e a interação ente preditores através da estatística-H, descrita na equação 3.7, ambas descritas por Kava (2022).

$$\tilde{f}_{j, ELA}(x) = \sum_{k=1}^{k_j(x)} \frac{1}{n_k(k)} \sum_{i: X_j \in N_j(k)} [\hat{f}(z_{k,j}, x_j^{(i)}) - \hat{f}(z_{k-1,j}, x_j^{(i)})] \quad (3.6)$$

$$H_j^2 = \frac{\sum_{i=1}^n [\hat{f}(x^{(i)}) - PD_J(X_J^{(I)}) - PD_{-J}(X_{-J}^{(I)})]^2}{\sum_{i=1}^n \hat{f}^2(x^{(i)})} \quad (3.7)$$

A última dimensão é o custo computacional, essa se baseará principalmente no tempo de execução dos modelos, e na contagem de operações com ponto flutuantes - FLOPs (do inglês, FLOating Point Operations) em ambas as métricas, quanto mais alto o valor, maior é o custo computacional.

3.4 Constructo da pesquisa

A estrutura do constructo pode ser verificado na tabela 3

Tabela 3 – Constructo da pesquisa

Pergunta de Pesquisa			
Em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro?			
Objetivo Geral			
Analisar em que medida modelos preditivos baseados em IA, comparados aos modelos tradicionais VAR, ARIMA, DFM e MIDAS, conseguem estimar o PIB brasileiro.			
Objetivos específicos	variáveis/dados à coletar	Como analisar	Fonte.
Caracterizar os modelos econométricos tradicionais (VAR, ARIMA, DFM e MIDAS) e de IA para a predição do PIB.	Modelos econométrico com capacidade de prever séries temporais.	Buscar através da literatura modelos já utilizados com esses fins.	Castelli (2022), Azevedo (2020), Azevedo (2020), Ciquini <i>et al.</i> (2023), Silva e Silva (2024), Alves (2009), Moura <i>et al.</i> (2020) e Micheletti (2024).
Identificar as diferentes variáveis determinantes na estimativa do PIB.	Variáveis com possível influência no PIB com facilidade de coleta e atualização recorrente.	Procurar na literatura quais variáveis são utilizadas para a predição do PIB.	Rebelo (2022), IBGE (2025a) e BACEN (2025).
Aplicar diferentes modelos econométricos tradicionais e de IA para a predição do PIB.	Modelos econométricos e variáveis encontradas nos primeiros dois objetivos.	treinar os diferentes modelos usando os dados coletados através da linguagem de programação Python e suas bibliotecas de estatística.	Castelli (2022), Azevedo (2020), Azevedo (2020), Ciquini <i>et al.</i> (2023), Silva e Silva (2024), Alves (2009), Moura <i>et al.</i> (2020) e Micheletti (2024).
Comparar o desempenho dos modelos de IA e econométricos tradicionais usando diferentes métricas, como desempenho computacional, precisão e interpretabilidade.	erro Quadrático Médio (EQM), Erro Absoluto Médio (EAM), a Raiz do Erro Quadrático Médio (REQM), erro percentual absoluto médio (EPAM), Efeitos Locais Acumulados (ELA), estatística-H, tempo de execução e FLOPs	Submeter os modelos a testes nas métricas de acurácia, interpretabilidade e custo computacional.	Rebelo (2022) e Kava (2022).

4 RESULTADOS

5 CONCLUSÕES E TRABALHOS FUTUROS

REFERÊNCIAS

- ALMEIDA, P. R. d. A economia internacional no século xx: um ensaio de síntese. **Revista Brasileira de Política Internacional**, Centro de Estudos Globais da Universidade de Brasília, v. 44, n. 1, p. 112–136, Jan 2001. ISSN 0034-7329. Disponível em: <https://doi.org/10.1590/S0034-73292001000100008>.
- ALVES, A. P. d. A. **Núcleo da inflação como fator comum do IPCA: uma abordagem do modelo de fator dinâmico generalizado**. Dissertação (Mestrado) – Universidade de São Paulo, 2009.
- AMARAL, C. P.; SANTOS, D. R. dos; LIMA, E. R.; BARCELLOS, T. Previsão de variáveis econômicas com aprendizado de máquina: previsão com redes neurais. **OBSERVATÓRIO DE LA ECONOMÍA LATINOAMERICANA**, v. 21, n. 9, p. 11279–11299, 2023.
- ASSUNÇÃO, F. **Estratégias para tratamento de variáveis com dados faltantes durante o desenvolvimento de modelos preditivos**. 2012.
- AZEVEDO, S. H. A. de. **Modelagem de séries temporais macroeconômicas com vetores autorregressivos aumentados com fator e transição suave sob um enfoque bayesiano**. Dissertação (Mestrado) – [sn], 2020.
- BACEN, B. C. do B. **Portal de Dados Abertos do Banco Central do Brasil**. 2025. <https://dadosabertos.bcb.gov.br>. Acesso em: 16 out. 2025.
- Banco Central do Brasil. **SGS 1207 – Sistema Gerenciador de Séries Temporais**. Banco Central do Brasil, 2026. Disponível em: <https://dadosabertos.bcb.gov.br/dataset/1207-sgs>.
- BORGES, B. K. Ensaio sobre previsão de séries macroeconômicas para o brasil utilizando modelos var bayesianos. 2018.
- BOX, G. E.; JENKINS. **Time series analysis: forecasting and control**. [S. l.]: Holden Day, inc, 1970.
- BRAGA, I. A. D. **Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning**. 2025.
- BREIMAN, L. Random forests. **Machine learning**, Springer, v. 45, n. 1, p. 5–32, 2001.
- CARMO, C. R. S.; LOPACINSKI, G. P. Modelagem e previsão de fenômenos socioeconômicos: Uma análise comparativa entre métodos clássicos e contemporâneos. **Revista GeTeC**, v. 13, 2023.
- CASTELLI, A. d. C. Modelo midas de projeção do pib brasileiro utilizando a pesquisa industrial mensal. 2022.
- CIQUINI, O.; BORBA, A. A. de; GODEGUEZ, P. A. Modelo arima para decisões econômicas. **Proceeding Series of the Brazilian Society of Computational and Applied Mathematics**, v. 10, n. 1, 2023.
- COSTA, H. C. **Vector Autoregression (VAR) Tutorial**. s.d. Acesso em: 21 abr. 2026. Disponível em: https://rstudio-pubs-static.s3.amazonaws.com/520691_9092a79ca10245b7bd0d5741d51aa6f8.html.

DOZ, C.; FULEKY, P. Dynamic factor models. **Macroeconomic forecasting in the era of big data: Theory and practice**, Springer, p. 27–64, 2019.

EKMAN, M. **Learning deep learning: Theory and practice of neural networks, computer vision, natural language processing, and transformers using TensorFlow**. [S. l.]: Addison-Wesley Professional, 2021.

FIALHO, T. M. M.; CORDEIRO, L. M. C.; TIMOTIO, J. G. M.; REZENDE, L. P. F. de; BOITRAGO, P. R. P. Incerteza, consumo das famílias no brasil e spread bancário: uma análise com o vetor autorregressivo (var). Universidade Federal de Minas Gerais, 2024.

FRISCH, R. Statikk og dynamikk i den økonomiske teori. 1). **Nationaløkonomisk Tidsskrift**, v. 37, 1929. Disponível em: <https://tidsskrift.dk/nationaloekonomisktidsskrift/article/download/57252/77814>.

GEWEKE, J. The dynamic factor analysis of economic time series. **Latent variables in socio-economic models**, North-Holland, 1977.

GHOSH, S.; RANJAN, A. A machine learning approach to gdp nowcasting: An emerging market experience. **Bulletin of Monetary Economics and Banking**, Bank Indonesia, Central Banking Research Department, v. 26, p. 33–54, 2023.

GHYSELS, E.; SANTA-CLARA, P.; VALKANOV, R. **The MIDAS Touch: Mixed Data Sampling Regression Models**. [S. l.], 2004. First draft: February 2002. This version: June 22, 2004.

GIL, A. C. **Como Elaborar Projetos de Pesquisa**. 4. ed. São Paulo: Editora Atlas, 2002.

IBGE, I. B. de Geografia e E. **API de dados agregados do IBGE**. 2025. <https://servicodados.ibge.gov.br/api/v3/agregados>. Acesso em: 16 out. 2025.

IBGE, I. B. de Geografia e E. **Deflator do Produto Interno Bruto - Séries Históricas**. 2025. <https://serieestatisticas.ibge.gov.br/series.aspx?t=pib&vcodigo=scn54>. Acesso em: 16 out. 2025.

IBGE, I. B. de Geografia e E. **O que é o PIB?** 2026. Acessado em: 11 abr. 2026. Disponível em: <https://www.ibge.gov.br/explica/pib.php>.

JÚNIOR, M. F. F. A terceira revolução industrial e o novo paradigma produtivo: Algumas considerações sobre o desenvolvimento industrial brasileiro nos anos 90. **Revista da FAE**, v. 3, n. 2, fev. 2017. Disponível em: <https://revistafae.fae.edu/revistafae/article/view/501>.

KAGERMANN, H.; WAHLSTER, W.; HELBIG, J. *et al.* Recommendations for implementing the strategic initiative industrie 4.0: Final report of the industrie 4.0 working group. **Forschungsunion: Berlin, Germany**, p. 12–25, 2013.

KAVA, L. E. **Além da caixa preta: aprendizagem de máquina interpretável para previsão de séries temporais macroeconômicas brasileiras**. Dissertação (Mestrado) – Universidade Federal de Santa Catarina, 2022.

KEYNES, J. M. **A Teoria Geral do Emprego, do Juro e da Moeda**. [S. l.]: Atlas, 1936.

KILKENNY, M. F.; ROBINSON, K. M. Data quality: “garbage in – garbage out”. **Health Information Management Journal**, v. 47, n. 3, p. 103–105, 2018. PMID: 29719995. Disponível em: <https://doi.org/10.1177/1833358318774357>.

KOOP, G.; MCINTYRE, S.; MITCHELL, J.; RAFTAPOSTOLOS, A. Monthly gdp growth estimates for the u.s. states. 2025. Disponível em: <https://arxiv.org/abs/2501.04607>.

LAKATOS, E. M.; MARCONI, M. de A. **Fundamentos de metodologia científica**. 5. ed. São Paulo: Editora Atlas, 2003.

LANDOWSKA, A.; KŁOPOTEK, R. A.; FILIP, D.; RACZKOWSKI, K. **GDP-GFCF Dynamics Across Global Economies: A Comparative Study of Panel Regressions and Random Forest**. 2025. Disponível em: <https://arxiv.org/abs/2504.20993>.

LAUDON, K.; LAUDON, J. **Sistemas de Informação Gerenciais: Administrando a Empresa Digital**. Bookman, 2022. ISBN 9788582606032. Disponível em: <https://books.google.com.br/books?id=NIehEAAQBAJ>.

LEMO, D. C. d. A.; SOUZA, S. A. d. Atas do copom como fonte de previsão do pib: Uma aplicação de processamento de linguagem natural. In: **Nome do Evento**. Cidade: [S. n.], 2025.

LI, K. **Forecasting US GDP from 1960 to 2023 using PCA**. 2024. Disponível em: <http://dissertations.umi.com/ucla:23601>.

MANKIW, N. G. **Introdução à economia**. [S. l.]: Bookman Editora, 2025.

MARTINS, G. S. **Indústria 4.0-contribuições tecnológicas para quarta revolução industrial**. [S. l.], 2021.

MCKINNEY, W. Data structures for statistical computing in python. **Proceedings of the 9th Python in Science Conference**, p. 51–56, 2010. Disponível em: <https://doi.org/10.25080/Majora-92bf1922-00a>.

MICHELETTI, A. D. Avaliação de um modelo ensemble stacking de machine learning para previsão do pib do brasil. 2024.

MINSKY, M.; PAPERT, S. **Perceptions: An introduction to computational geometry**. [S. l.]: The MIT press, 1969. 311 p.

MOURA, B. A.; TIRYAKI, G. F.; TEIXEIRA, D. N. Fragilidade fiscal e os ciclos econômicos no brasil pós-plano real: evidências de um modelo de fator dinâmico associado à análise var. **Nova Economia**, SciELO Brasil, v. 30, n. 2, p. 517–549, 2020.

OLIVEIRA, M. C.; JUNIOR, S. d. S. P. **Gastos Públicos com Infraestrutura e Disparidades Regionais: Impactos no PIB per capita das Regiões Sul e Nordeste do Brasil**. Natal, RN, 2024.

PYTHON. **Python Language Reference, version 3.12**. [S. l.], 2023. Disponível em: <https://www.python.org/doc/>. Acesso em: 16 out. 2025.

REBELO, M. A. C. **Interpretabilidade de modelos Machine Learning para a previsão macroeconômica**. Dissertação (Mestrado) – Universidade de Lisboa (Portugal), 2022.

ROSA, Y. C. d. Efeito dinâmico dos gastos tributários sobre a produtividade total dos fatores no Brasil. Idp, 2025.

ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. **Psychological review**, American Psychological Association, v. 65, n. 6, p. 386, 1958.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. **nature**, Nature Publishing Group UK London, v. 323, n. 6088, p. 533–536, 1986.

SANTANA, A. A.; SILVA, C. R. da; TIMOTEO, L. C. da S.; OLIVEIRA, R. M. de; NARCISO, R. Aprimorando a tomada de decisões empresariais: o papel dos dados, análises de negócios e novas tecnologias. **Revista Ilustração**, v. 4, n. 2, p. 75–83, 2023.

SANTOS, F.; NOLAU, I. **Previsão de inflação: análise preliminar de desempenho de técnicas de machine learning**. [S. l.], 2022.

SERRANO, F. M. **Impacto regional da política monetária no Brasil: uma abordagem bayesiana**. Dissertação (Dissertação (Mestrado em Teoria Econômica)) – Faculdade de Economia, Administração e Contabilidade, Universidade de São Paulo, São Paulo, 2014. Acesso em: 29 abr. 2026. Disponível em: <https://doi.org/10.11606/D.12.2014.tde-16032015-132813>.

SILVA, P. N.; SILVA, G. V. P. d. Dados abertos do ibge: Recuperação na api de dados agregados. **Encontros Bibli**, SciELO Brasil, v. 29, p. e96185, 2024.

SILVA, T. R. d.; CLERICUZI, A. Z.; CARVALHO, J. N. d. Modelagem de séries temporais utilizando arima: Previsão futura do PIB brasileiro. **International Contemporary Management Review**, v. 6, n. 2, p. e385, Aug. 2025. Disponível em: <https://icmreview.com/icmr/article/view/385>.

SIMS, C. A. Macroeconomics and reality. **Econometrica: journal of the Econometric Society**, JSTOR, p. 1–48, 1980.

U.S. Bureau of Economic Analysis. **Gross Domestic Product**. U.S. Bureau of Economic Analysis, 2026. Disponível em: <https://www.bea.gov/data/gdp/gross-domestic-product>.

VASCONCELOS, B. F. B. de. **Poder preditivo de métodos de Machine Learning com processos de seleção de variáveis: uma aplicação às projeções de produto de países**. Tese (Tese de Doutorado) – Universidade de Brasília, Brasília, Brasil, ago. 2017. Faculdade de Economia, Administração, Contabilidade e Gestão de Políticas Públicas (FACE), Departamento de Economia (FACE ECO), Programa de Pós-Graduação em Economia. Disponível em: <http://dx.doi.org/10.26512/2017.03.D.23995>.

VASCONCELOS, M. **Atlas de Economia**. 2. ed. São Paulo: Editora Atlas, 2020. Define conceitos de macroeconomia e apresenta indicadores econômicos.