International Contemporary Management Review

ICMR –Volume 06, Número 02, p. 01-16, 2025
ISSN: 2595-0428 - ARTIGO CIENTÍFICO-

MODELAGEM DE SÉRIES TEMPORAIS UTILIZANDO ARIMA: PREVISÃO FUTURA DO PIB BRASILEIRO

Date of receipt: 7/28/2025
Date of acceptance for publication: 8/25/2025

DOI: 10.54033/icmrv6n2-045

Thiago Raimundo da Silva[1], Adriana Zenaide Clericuzi[2], Joelson Nogueira de Carvalho[3]

RESUMO

O Produto Interno Bruto (PIB) de um país representa a soma de todos os bens e serviços finais produzidos em seu território durante um intervalo temporal específico, posicionando-se como um indicador macroeconômico primordial para avaliar o desempenho econômico agregado. A evolução do PIB oferece subsídios fundamentais para a formulação de políticas econômicas, visto que sua previsão reduz as incertezas associadas ao ambiente econômico e permite a antecipação de tendências por parte dos tomadores de decisão. Neste estudo, foi empregada a metodologia Box-Jenkins, por meio da utilização de modelos auto-regressivos integrados de médias móveis (ARIMA), para a modelagem e previsão do PIB brasileiro. O processo metodológico contemplou as etapas de tratamento e limpeza dos dados, identificação da estrutura de dependência temporal, estimação dos parâmetros e validação do modelo ajustado. As projeções realizadas para o período de 2025 a 2029 indicam um cenário de estabilidade acompanhado de um leve crescimento do PIB nacional. O modelo ARIMA apresentou performance satisfatória para a previsão em curto prazo, reafirmando sua adequação e aplicabilidade na análise de séries temporais de indicadores macroeconômicos.

Palavras-chave: ARIMA. Produto Interno Bruto. Previsão. Box-Jenkins.

TIME SERIES MODELING USING ARIMA: FUTURE FORECASTING OF BRAZILIAN GDP

ABSTRACT

The Gross Domestic Product (GDP) of a country represents the sum of all final goods and services produced in its territory during a specific time interval, positioning itself as a primary macroeconomic indicator for evaluating aggregate economic performance. The evolution of GDP provides fundamental support for the formulation of economic policies, since its forecasting reduces uncertainties associated with the economic environment and allows decision-makers to

[1] Graduando de Sistemas de Informação, Universidade Federal da Paraíba (UFPB), Mamanguape - Paraíba, Brasil. E-mail: thiago.raimundo@dcx.ufpb.br
[2] Doutora em Engenharia de Produção área de concentração em Sistemas de Informação, Universidade Federal da Paraíba (UFPB), Mamanguape - Paraíba, Brasil. E-mail: adrianaclericuzi@dcx.ufpb.br
[3] Doutor em Engenharia de Processos área de concentração em Computação, Universidade Federal da Paraíba (UFPB), Mamanguape, Paraíba - Brasil. E-mail: joelson@dcx.ufpb.br

anticipate trends. In this study, the Box-Jenkins methodology was employed, through the use of Autoregressive Integrated Moving Average (ARIMA) models, for the modeling and forecasting of Brazilian GDP. The methodological process encompassed the stages of data treatment and cleaning, identification of the temporal dependence structure, parameter estimation, and validation of the adjusted model. The projections carried out for the period from 2025 to 2029 indicate a scenario of stability accompanied by slight growth in the national GDP. The ARIMA model presented satisfactory performance for short-term forecasting, reaffirming its adequacy and applicability in the analysis of time series of macroeconomic indicators.

Keywords: ARIMA. Gross Domestic Product. Forecasting. Box-Jenkins.

MODELADO DE SERIES DE TIEMPO USANDO ARIMA: PRONÓSTICO FUTURO DEL PIB BRASILEÑO

RESUMEN

El Producto Interno Bruto (PIB) de un país representa la suma de todos los bienes y servicios finales producidos en su territorio durante un intervalo de tiempo específico, posicionándose como indicador macroeconómico primordial para la evaluación del desempeño económico agregado. La evolución del PIB proporciona subsidios fundamentales para la formulación de políticas económicas, ya que su pronóstico reduce las incertidumbres asociadas al entorno económico y permite a los tomadores de decisiones anticipar tendencias. En este estudio, se empleó la metodología Box-Jenkins, mediante la utilización de modelos autorregresivos integrados de medias móviles (ARIMA), para la modelación y pronóstico del PIB brasileño. El proceso metodológico abarcó las etapas de tratamiento y limpieza de los datos, identificación de la estructura de dependencia temporal, estimación de parámetros y validación del modelo ajustado. Las proyecciones realizadas para el período de 2025 a 2029 indican un escenario de estabilidad acompañado de un leve crecimiento del PIB nacional. El modelo ARIMA presentó un rendimiento satisfactorio para pronósticos de corto plazo, reafirmando su adecuación y aplicabilidad en el análisis de series temporales de indicadores macroeconómicos.

Palabras clave: ARIMA. Producto Interno Bruto. Pronóstico. Box-Jenkins.

1 INTRODUÇÃO

O Produto Interno Bruto (PIB) constitui uma métrica central na avaliação da conjuntura econômica de uma nação, sendo amplamente reconhecido como um dos principais indicadores macroeconômicos. O PIB corresponde ao valor agregado de todos os bens e serviços finais produzidos no território nacional em um intervalo de tempo específico. A análise sistemática desse

indicador é essencial para a compreensão das dinâmicas econômicas, fornecendo subsídios técnicos para a formulação de políticas públicas e para a tomada de decisões estratégicas por agentes governamentais e empresariais (Dornbusch e Fischer, 2003; Mendes, 2004; Passos, 2005).

Além disso, o PIB serve como um importante instrumento para mensurar a atividade econômica de um país, permitindo a comparação entre diferentes economias e a identificação de tendências e padrões. A decomposição do PIB em seus componentes - consumo, investimento, gastos governamentais e saldo comercial - oferece uma visão detalhada da estrutura econômica nacional, possibilitando a identificação de áreas de oportunidade e de desafios (Giambiagi, 2008). A adoção de técnicas avançadas de análise de dados, incluindo modelagem econométrica e análise de séries temporais. Essas abordagens possibilitam não apenas a identificação de relações causais entre o PIB e variáveis econômicas correlatas, como também proporcionam subsídios robustos para a previsão de tendências futuras.

Este projeto tem como objetivo empregar técnica de modelagem de séries temporais, com foco na implementação e avaliação do modelo ARIMA, para analisar e prever o comportamento do PIB do Brasil ao longo dos próximos anos, utilizando dados históricos.

2 SÉRIES TEMPORAIS

Séries temporais consistem em sequências de observações quantitativas coletadas em intervalos regulares ao longo do tempo, referentes a uma única variável. Esse registro sistemático viabiliza a organização dos dados de modo a possibilitar a análise de padrões, a investigação de tendências e a geração de previsões baseadas em comportamentos históricos (Bueno, 2008; Ehlers, 2009). O principal foco das análises de séries temporais está na decomposição e na modelagem de seus componentes estruturais: tendência, definida pelo movimento persistente de crescimento ou decréscimo na série; sazonalidade, evidenciada por padrões recorrentes em intervalos específicos; e componentes aleatórios, atribuídos a flutuações que não são explicadas por tendências ou sazonalidades identificáveis.

O maior desafio metodológico reside na correta identificação e separação dessas componentes, uma vez que seus comportamentos podem variar em função do intervalo temporal

analisado ou da presença de fatores externos, o que pode impactar significativamente a precisão dos modelos preditivos e o entendimento dos fenômenos subjacentes.

2.1 MODELO AUTO-REGRESSIVO (AR) E MÉDIA MÓVEL (MA)

O modelo Auto-Regressivo (AR) de grau p é uma abordagem muito comum para modelagem de séries temporais. Ele se baseia na ideia de que uma variável é gerada por um processo estocástico estacionário que contém seus valores passados. Em outras palavras, o valor da variável depende de uma combinação ponderada de seus valores anteriores. Pode-se representar um processo auto-regressivo por :

$$Yt=\phi 1Yt-1+\phi 2Yt-2+...+\phi pYt-p+Et \qquad (1)$$

onde:

Yt é o valor da série no tempo t.

O valor p é a ordem do processo (AR(p))

$\phi 1,\phi 2,...,\phi p$ são os parâmetros auto-regressivos e Et é o termo de erro assumido como tendo valor igual a 0, variância = σE^2 é a covariância igual a 0 (para todos $t \neq s$) $\forall t \neq s$.

Cada observação do processo Yt é uma variável aleatória que é afetada por inúmeros eventos ao mesmo tempo, de modo que se possa dizer que tem-se uma sequência de variáveis aleatórias que juntas formam a trajetória de Y. A escolha de quantos valores devem ser considerados é definida pelo parâmetro (p) e é crucial para o sucesso do modelo AR, esse valor pode ser definido com base em alguns critérios que ajudam a balancear o modelo e sua complexidade. O modelo Auto-Regressivo (AR) é eficaz em contextos em que se observa uma forte dependência temporal entre as observações, característica frequentemente encontrada em séries econômicas.

Por sua vez, o modelo de Média Móvel constitui uma abordagem alternativa para a modelagem de séries temporais, pressupondo que os valores observados podem ser representados como uma média ponderada dos resíduos (ou choques aleatórios) ocorridos em períodos anteriores.

A estrutura geral do modelo MA pode ser formalizada da seguinte forma:

$$MMA(t) = (P(t) + P(t-1) + ... + P(t-n+1)) / n \qquad (2)$$

onde:

MMA(t): Valor da média móvel no período t
P(t): Preço de fechamento no período t
n: Número de períodos utilizados no cálculo

Como o modelo de Média Móvel (MA) leva em consideração os erros erro provenientes de períodos anteriores, torna-se muito útil para capturar os choques na série temporal. Segundo Gujarati e Porter (2011, p. 764) "Resumindo, um processo média móvel é apenas uma combinação linear de termos de erro de ruído branco".

2.2 MODELO ARIMA (p,d,q)

A modelagem ARIMA é uma extensão dos modelos AR e MA incorporando um componente de diferenciação para lidar com séries não estacionárias sendo uma dos mais populares modelos que utilizam apenas dados históricos de séries temporais para assim expressar como a série reage de acordo com a variação estocástica anterior. A representação geral de um modelo ARIMA (p,d,q) é dada por:

$$Y_t = C + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q} + \epsilon_t \qquad (3)$$

sendo:

Y_t é o valor da série temporal no tempo t.
C é uma constante.
$\phi_1,...,\phi_p$ são coeficientes auto-regressivos (AR).
$\theta_1,...,\theta_p$ são os coeficientes de média móvel (MA)
ϵ_t é o erro residual, ou seja, o ruído branco, no tempo t

Os AR e MA são metodologias adequadas para análise de séries temporais que apresentam

propriedades de fraca estacionariedade, ou seja, aquelas em que a média e a variância permanecem constantes ao longo do tempo, e a covariância depende apenas do deslocamento temporal, sendo invariável em relação ao tempo absoluto. No entanto, quando as séries não atendem plenamente a esses pressupostos, é possível aplicar operações de diferenciação para transformar a série em estacionária, permitindo, assim, a utilização apropriada desses modelos. Para Gujarati e Porter (2011) "Se tivermos de diferenciar uma série temporal d diversas vezes para torná-la estacionária e aplicar-lhe o modelo ARMA (p,q), diremos que a série temporal original e ARIMA (p,d,q), ou seja, ela é uma série temporal auto-regressiva integrada de médias móveis".

2.3 METODOLOGIA BOX-JENKINS

A Metodologia Box-Jenkins é um processo sistemático para identificar, estimar e diagnosticar modelos de séries temporais ARIMA. A metodologia é amplamente utilizada em econometria e estatística para modelar séries temporais e envolve quatro etapas principais: identificação, estimação, diagnóstico e previsão. Usa-se a Função de Autocorrelação (FAC) e a Função de Autocorrelação Parcial (FACP) para determinar a estrutura do modelo, identificando os parâmetros p, d e q do modelo ARIMA. Segundo (Morettin, 2017) "A identificação do particular modelo ARIMA a ser ajustado aos dados é talvez a fase mais crítica do processo iterativo".

A seleção do modelo de séries temporais mais apropriado é realizada por meio de critérios de informação, tais como o Critério de Informação de Akaike (AIC) e o Critério de Informação Bayesiano (BIC). Após a estimação do modelo, procede-se à avaliação dos resíduos, que devem ser independentes, não apresentar autocorrelação significativa e seguir, idealmente, uma distribuição normal. A presença de autocorrelação nos resíduos pode ser avaliada por meio do teste de Ljung-Box, permitindo verificar a adequação do ajuste do modelo aos dados observados.

Após a validação do modelo é feita a previsão para o período de análise. Essa etapa depende das anteriores e só será implementada caso as anteriores atestem a eficácia do modelo de previsão. No caso do presente artigo essa etapa foi deixada de lado uma vez que os dados da previsão serão apresentados no tópico de resultado.

2.4 FUNÇÃO DE AUTOCORRELAÇÃO (FAC)

A Função de Autocorrelação (FAC) quantifica o grau de correlação entre os valores de uma série temporal e suas versões defasadas em diferentes lags. Essa função é fundamental para identificar padrões estruturais na série, tais como comportamentos sazonais e propriedades de estacionariedade, auxiliando na especificação e validação de modelos de séries temporais. Conforme destaca Box et al. (2015, p. 29) "A função de autocorrelação [...] revela como a correlação entre quaisquer dois valores da série muda à medida que sua separação muda."

2.5 FUNÇÃO DE AUTOCORRELAÇÃO PARCIAL (FACP)

A Função de Autocorrelação Parcial (FACP) mede a correlação entre a série temporal e seus próprios valores defasados, removendo o efeito das autocorrelações em defasagens intermediárias. Tem papel fundamental na identificação da ordem p de um processo autorregrassivo conforme explica Box et al. (2015, p. 64)

Na prática, normalmente não sabemos a ordem do processo auto-regressivo inicialmente, e a ordem precisa ser especificada a partir dos dados. O problema é análogo a decidir o número de variáveis independentes a serem incluídas em uma regressão múltipla. A função de autocorrelação parcial é uma ferramenta que explora o fato de que, enquanto um processo AR (p) tem uma função de autocorrelação de extensão infinita, as autocorrelações parciais são zero além do defasamento p.

2.6 TESTE LJUNG-BOX

O Teste Ljung-Box verifica se há autocorrelação significativa em um conjunto de dados de séries temporais. É um teste estatístico usado para avaliar se um modelo ajustado capturou adequadamente a estrutura de correlação da série. Como afirma (Morettin, 2020)

Apos a estimação do modelo selecionado, podemos faser testes residuais do mesmo tipo que são utilizados em modelos ARIMA, com um número de graus de liberdade igual ão número de autocorrelaçãos utilizadas, menos o numero de hiperparametros estimados.

2.7 TESTE JARQUE-BERA

O Teste Jarque-Bera é um teste de normalidade que avalia se os dados seguem uma distribuição normal com base na assimetria (skewness) e curtose (kurtosis). Tal como descreve Tiryaki e Andrade (2017) "É um teste de normalidade dos dados que incorpora simultaneamente os conceitos de as-simetria e curtose."

2.8 CRITÉRIO DE INFORMAÇÃO DE AKAIKE (AIC)

O Critério de Informação de Akaike (AIC), ou CIA em ingles, é usado para selecionar entre modelos estatísticos, equilibrando a qualidade do ajuste com a simplicidade do modelo. Em conformidade com (Gujarati; Porter, 2011c, p. 490) "[...] o critério de informação de Akaike impõe uma medida corretiva mais dura que R^2 pelo acréscimo de regressores. Ao compararmos dois ou mais modelos, o modelo com o valor mais baixo de CIA é preferido."

2.9 CRITÉRIO DE INFORMAÇÃO BAYESIANO (BIC)

O Critério de Informação Bayesiano (BIC), ou CIS em ingles, é semelhante ao AIC, mas impõe uma penalidade maior para modelos complexos. Em conformidade com (Gujarati; Porter, 2011d, p. 491) "Como o CIA, quanto mais baixo o valor do CIS, melhor o modelo. Novamente, como o CIA, o CIS pode ser usado para comparar o desempenho do modelo quando as previsões são feitas dentro e fora da amostra."

3 METODOLOGIA

A metodologia proposta neste artigo consiste na aplicação do modelo ARIMA, parametrizado como ARIMA (p,d,q), para a estimação do Produto Interno Bruto (PIB) do Brasil em horizontes futuros. O modelo destaca-se por sua robustez na modelagem de séries temporais que apresentam padrões de autocorrelação e tendência, sendo amplamente difundido na literatura devido à metodologia sistematizada por Box e Jenkins, a qual orienta a identificação, estimação e

validação de modelos desse tipo. Esse método é particularmente aplicável à projeção do PIB, pois permite capturar padrões sazonais e tendências, fornecendo previsões confiáveis para planejamentos econômicos e decisões de políticas públicas.

3.1 IDENTIFICAÇÃO DO PROBLEMA E OBJETIVO DA PESQUISA

O primeiro passo consiste em definir claramente o problema de pesquisa, que neste caso é uma previsão do PIB do Brasil. Os objetivos específicos incluem:

- Analisar a série temporal do PIB brasileiro.
- Aplique o modelo ARIMA para prever o PIB para os próximos anos.
- Avaliar a precisão da absorção gerada pelo modelo.

3.2 COLETA DE DADOS

Os dados necessários para a análise foram coletados da base de dados do banco mundial, que é uma instituição financeira global que faz parte do Sistema das Nações Unidas, fundada em 1944 com o objetivo de ajudar as economias devastadas pela Segunda Guerra Mundial. Sua sede está localizada em Washington, DC, nos Estados Unidos. Atualmente, conta com 189 países membros e tem como objetivo acelerar o seu crescimento e desenvolvimento através da oferta de empréstimos a países pobres e emergentes.

O site para download do banco de dados é público, o endereço é: https://data.worldbank.org/indicator/NY.GDP.MKTP.CD

3.3 ANÁLISE DOS DADOS

O período de análise será definido, abrangendo a série histórica de 1990 até 2023, para garantir uma série temporal robusta. Após o levantamento dos dados iniciou-se o processo de determinar se o modelo ARIMA (p,d,q) é adequado, para isso deve-se observar o comportamento do gráfico para verificar as características da série temporal e determinar se a mesma é ou não estacionária, além de identificar possíveis tendências, sazonalidades ou ciclos. Foi observado na

Figura 1 que o PIB apresentada tendências de crescimento entre os anos 2000 e 2010, depois disso veio uma tendência decrescente e que voltou a ter um padrão de crescimento após o ano de 2017, mas com certa volatilidade, não sendo possível observar alguma sazonalidade, mas sendo notado um ciclo de crescimento e receção ao longo das décadas.

Figura 1. Progressão do PIB (1990-2023)

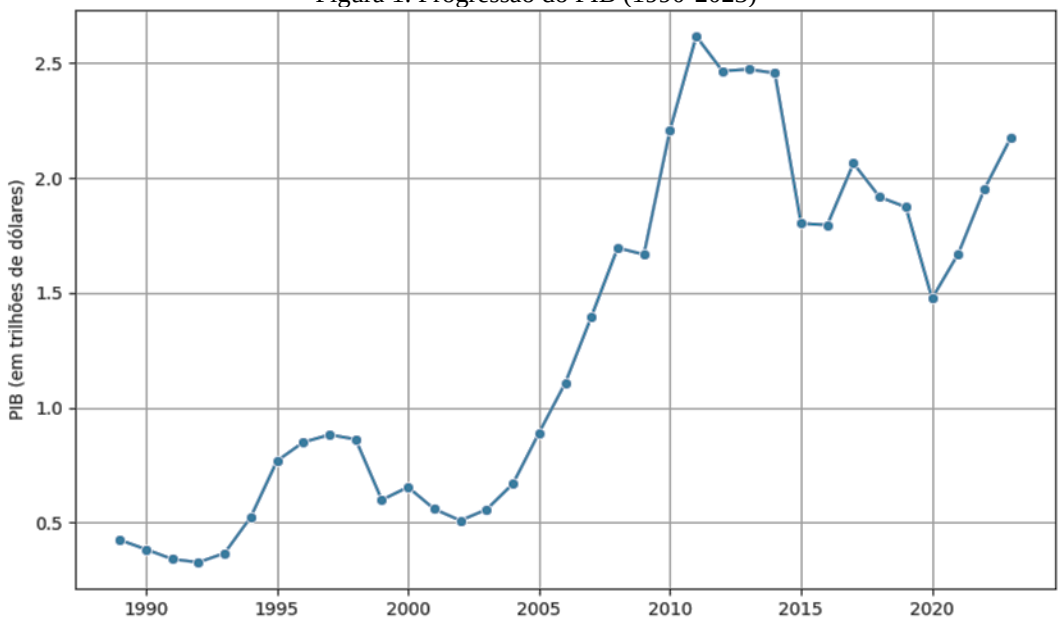

Fonte: De autoria própria

A Seguir, foi aplicado o teste de Dickey Fuller Aumentado (ADF) na série temporal a fim de verificar se a mesma é estacionária, os valores estatísticos encontrados após a aplicação foram o valor do teste ADF sendo: -0.848, além disso o Valor-p foi de: 0.804. O valor do teste ADF é maior que os valores críticos e o valor-p é bem acima de 0.05, o que indica que não se pode rejeitar a hipótese nula de que a série possui uma raiz unitária, com base nisso conclui-se que a série não é estacionária no estado original.

Com base nos resultados da não estacionaridade recorreu-se à diferenciação da série original para remover a tendência e tornar os dados estacionários. A diferenciação implica na não utilização do modelo ARMA comprovando a necessidade do uso do modelo ARIMA (p,q,d) com valor do parâmetro (d) sendo igual a 1. Após a aplicação da primeira diferenciação os valores obtidos foram uma estatística do Teste ADF (Série Diferenciada): -3.771 sendo menor que o valor

crítico de 1% e um Valor-p:0.00321 bem menor que 0.05 indicando a rejeição da hipótese nula. A partir desse ponto a série diferenciada é estacionária com 95% de confiança.

3.5 IDENTIFICAÇÃO DO MODELO ARIMA (p,q,d)

Nesta etapa envolveu analisar as funções de autocorrelação (FAC) e autocorrelação parcial (FACP) para ajudar a identificar os parâmetros (Auto-regressivo) e (Média Móvel).

Figura 2. Grafico das funções de autocorrelação (FAC) e autocorrelação parcial (FACP)

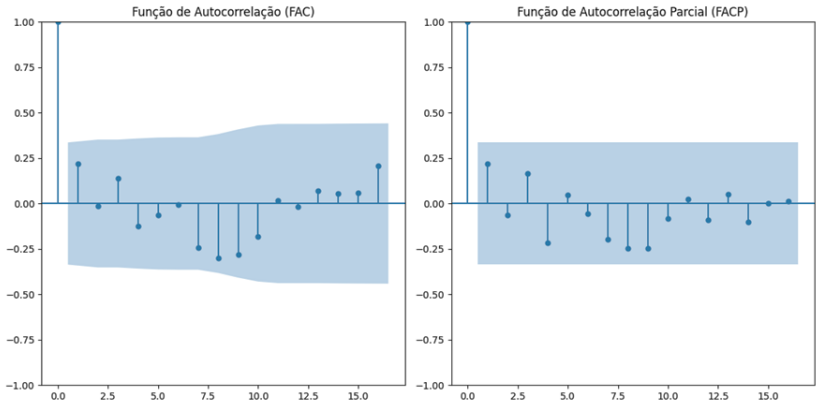

Fonte: De autoria própria.

Observando a Figura 2 a função de Autocorrelação (FAC) à esquerda apresenta um pico no lag 1, seguido por um decaimento nos lags subsequentes indicando um comportamento de média móvel (MA) no modelo com primeiro lag significativamente fora do intervalo de confiança, representado por uma banda azul, isso indica que uma boa escolha para o parâmetro de (q) da Média Móvel seria igual a 1. por sua vez, a função de autocorrelação parcial (FACP) à direita também apresenta um grande pico no lag q seguido por um decaimento onde os outros lags estão dentro do intervalo de confiança, sendo assim, um grande pico no lag 1 com sugere que o componente auto-regressivo AR é de ordem 1 assim o valor p=1 parece ser uma boa escolha para o parâmetro AR. Conforme evidenciado, seguindo a análise da FAC e FACP tem se o primeiro modelo a ser analisado, o modelo ARIMA(1,1,1)

3.6 ESTIMATIVA DO MODELO

Dos valores verificados, foram encontrados quatro modelos concorrentes os quais são significativos apresentando p-value inferior a 0,05. Dentre eles o modelo ARIMA(1,1,1) apresentou o melhor ajuste para a série de PIB possuindo um AIC competitivo em relação aos outros modelos, tendo o parâmetro MA(1) estatisticamente significativo, indicando que a média dos resíduos tem impacto relevante, como pode ser visto na Tabela 1. Modelos com menores valores de AIC e BIC são preferíveis, pois indicam um melhor ajuste com menor complexidade. Os parâmetros mais significativos (p-value < 0.05) sugerem um modelo que está capturando melhor a dinâmica da série.

Tabela 1. Comparação dos modelos ARIMA

MODELO	PARÂMETRO	P-VALOR	AIC	BIC
	MA (1) = 0.7325	0.015	1.878.932	1.884.038
ARIMA (2, 1, 1)	MA (1) = 0.8437	0.021	1.882.184	1.888.289
ARIMA (3, 1, 1)	MA (1) = 0.7387	0.020	1.881.501	1.889.133
ARIMA (0, 1, 1)	MA (1) = 0.2793	0.143	1.877.420	1.880.473

Fonte: De autoria própria.

3.7 VERIFICAÇÃO DO MODELO

Tendo ajustado o modelo ARIMA (1,1,1) seguindo os parâmetros encontrados, os resíduos foram analisados para avaliar a adequação do modelo, a análise ocorreu por meio do gráfico de autocorrelação dos resíduos e do teste de Ljung-Box. A figura 3 mostra os gráficos de resíduos e a função de autocorrelação (FAC) dos resíduos que não mostraram padrões significativos, indicando que o modelo capturou bem a estrutura da série temporal e que os resíduos eram essencialmente ruído branco.

O teste de Ljung-Box confirmou a ausência de autocorrelação significativa nos resíduos (estatística de Ljung-Box = 10,69, valor-p = 0,38), reforçando que o modelo ARIMA foi capaz de modelar a dependência temporal de maneira satisfatória. Além disso, também foi aplicado o teste de de Jarque-Bera a fim de verificar se os resíduos seguem uma distribuição normal, apesar dos resultados positivos anteriores, o teste de indicou que os resíduos não seguem uma distribuição

normal (estatística JB = 11.66, valor-p = 0.0029). Embora a normalidade dos resíduos seja uma suposição desejável, a não normalidade não invalida necessariamente o modelo, desde que os resíduos não apresentem autocorrelação significativa.

Figura 3. Gráfico dos resíduos do modelo ARIMA e da FAC dos resíduos

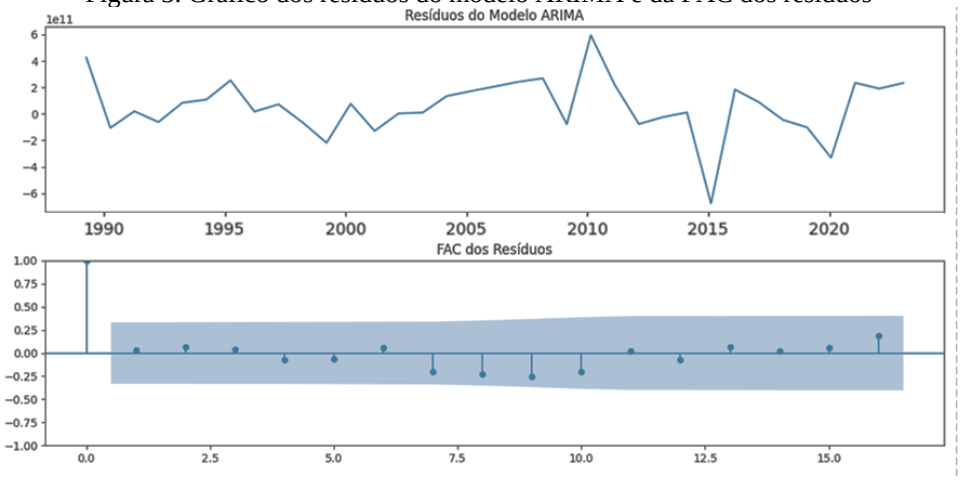

Fonte: De autoria própria.

Os resíduos do modelo foram visualizados para avaliar se apresentavam padrões sistemáticos que o modelo poderia não ter capturado. O gráfico dos resíduos mostrou uma distribuição aleatória ao longo do tempo, sem tendência evidente ou sazonalidade persistente. Isso é um bom indicador de que o modelo ARIMA ajustado foi eficiente em remover a estrutura autocorrelacionada dos dados, deixando apenas o ruído aleatório.

Além disso, a Função de Autocorrelação dos Resíduos (FAC) foi utilizada para verificar a presença de autocorrelação nos resíduos. Nenhum dos lags apresentou correlação significativa fora do intervalo de confiança (indicados pelas barras do gráfico FAC), confirmando que os resíduos podem ser considerados ruídos brancos. Isso sugere que não há padrões remanescentes que o modelo não tenha capturado, validando a suposição de independência dos resíduos.

4 RESULTADOS E DISCUSSÕES

Com a validação do modelo ARIMA (1,1,1) foi realizada a projeção para os próximos 6 anos que compreendem os anos de 2024 a 2029 como mostrado na Tabela 2.

Tabela 2. Valores da provisão do PIB do modelo ARIMA em comparação a previsão do FMI. Valores em trilhão de dólares.

ANO DE PREVISÃO	PIB ARIMA	PREVISÃO FMI
2024	2,2	2,2
2025	2,195	2,1
2026	2,228	2,1
2027	2,205	2
2028	2,221	2
2029	2,221	2

Fonte: De autoria própria.

Os valores encontrados na previsão, representados na Figura 3, apresentam uma estabilidade no PIB sem que houvesse quedas ou picos muito acentuados.

Figura 4. Representação da projeção dos valores do PIB estimados pelo modelo ARIMA

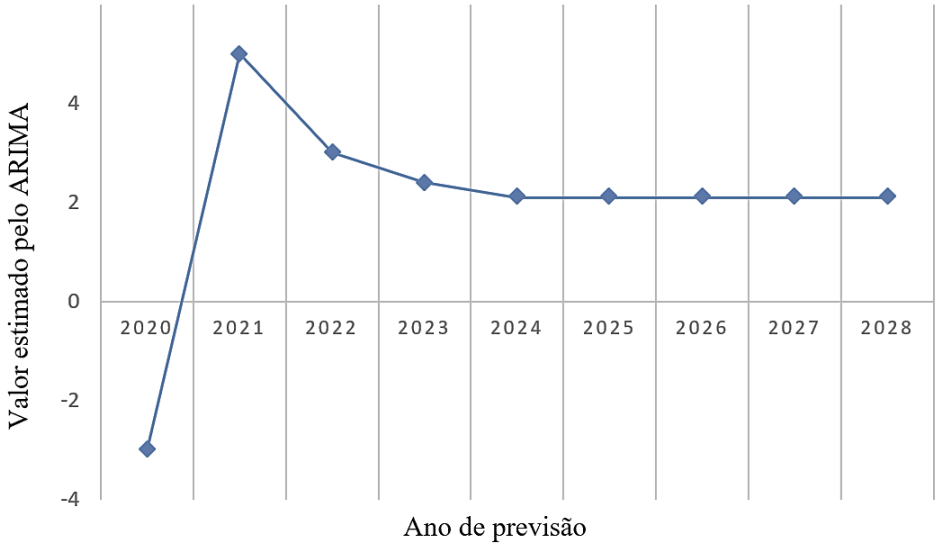

Fonte: De autoria própria.

Tendo a projeção do PIB feita pelo modelo ARIMA(1,1,1) foi realizada uma comparação dos resultados com os números estipulados pelo FMI (Internacional Monetary Fund), tendo em vista que as previsões do FMI incorporam uma análise mais ampla, incluindo dados econômicos globais, tendências de mercado, riscos geopolíticos, e outras variáveis macroeconômicas que podem afetar o desempenho econômico de um país, as suas previsões têm uma maior credibilidade a ao comparar a proximidades obtido com os dados do modelo ARIMA pode-se visualizar o quão próximas estão as previsões de ambos. A projeção do modelo ARIMA sugere um crescimento

mais acelerado do PIB, atingindo um valor estimado de 2.21 trilhões em 2029, enquanto o FMI prevê um crescimento mais gradual, com o PIB atingindo 2 trilhões no mesmo período.

5 CONCLUSÃO

A aplicação do modelo ARIMA (1,1,1) demonstrou capacidade satisfatória para capturar a estrutura temporal do PIB brasileiro, evidenciada pela eliminação significativa da dependência serial e pela produção de resíduos similares a ruído branco. Os resultados obtidos indicam a robustez do modelo na representação dos padrões históricos da série, validando sua utilização em tarefas de previsão quantitativa.

Contudo, ressalta-se que a abordagem puramente estatística do ARIMA, embora eficaz para detectar e extrapolar tendências lineares e padrões intrínsecos, apresenta limitações diante de cenários econômicos sujeitos a choques exógenos e dinâmicas não capturadas nos dados históricos. Ao comparar as previsões ARIMA com as projeções do FMI, observa-se uma discrepância atribuída à ausência de variáveis explicativas e ao viés potencialmente otimista do modelo auto-regressivo. O FMI emprega modelos estruturais mais abrangentes, incorporando fatores macroeconômicos, contextuais e geopolíticos, o que confere maior robustez em ambientes de incerteza.

Portanto, conclui-se que, apesar da utilidade do ARIMA como ferramenta inicial para análise e previsão de séries temporais econômicas, suas estimativas devem ser interpretadas com cautela e, preferencialmente, complementadas por métodos qualitativos e modelos econométricos que considerem o amplo espectro de variáveis que afetam o crescimento do PIB. Essa integração entre abordagens quantitativas e qualitativas potencializa a confiabilidade das projeções e contribui para decisões mais fundamentadas no âmbito da política econômica.

REFERÊNCIAS

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. **Time Series Analysis: Forecasting and Control**. 5. ed. Hoboken: Wiley, 2016

BUENO, R. de L. da S. **Econometria de séries temporais.** Cengage Learning, 2008.

DORNBUSCH, R.; FISCHER, S. **Introdução à Economia.** Rio de Janeiro: Campus, 2003.

EHLERS, R. S. **Análises de séries temporais.** Universidade Federal do Paraná - Departamento de Estatística, v. 5, 2009.

GIAMBIAGI, F.; ALEM, A. **Finanças Públicas.** Rio de Janeiro: Elsevier, 2008.

GUJARATI, D. N.; PORTER, D. C. **Econometria básica.** 5th ed. Porto Alegre: AMGH, 2011.

MENDES, J. T. G. **Economia: fundamentos e aplicações.** São Paulo: Prentice Hall, 2004.

MORETTIN, P. A. **Análise de séries temporais** - volume 2. São Paulo: Editora Blucher, 2020.

MORETTIN, P. A. **Econometria Financeira Um Curso em Séries Temporais Financeiras.** São Paulo: Editora Blucher, 2017.

PASSOS, C. R. M.; NOGAMI, O. **Princípios de Economia.** 5. ed. São Paulo: Pioneira, 2005.

TIRYAKI, G. F.; ANDRADE, C. S. M. **Econometria na prática.** Rio de Janeiro: Editora Alta Books, 2017.