

Insper Instituto de Ensino e Pesquisa
Mestrado Profissional em Economia

Isis Aparecida Drezza Braga

Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning

São Paulo - SP

2025

Isis Aparecida Drezza Braga

Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning

Dissertação apresentada ao programa de Mestrado Profissional em Economia como requisito parcial para obtenção do título de Mestre em Economia.

Inspere Instituto de Ensino e Pesquisa
Mestrado Profissional em Economia

Orientador: Prof. Dr. Ruy Monteiro Ribeiro

São Paulo - SP

2025

Isis Aparecida Drezza Braga

Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning/ Isis Aparecida Drezza Braga. - São Paulo - SP: 2025

45 p.

: Insper Instituto de Ensino e Pesquisa
Mestrado Profissional em Economia , 2025.

Orientador: Prof. Dr. Ruy Monteiro Ribeiro

1. Palavra-chave 1. 2. Palavra-chave 2. 3. Palavra-chave 3. I. Autor. II.
Título.

Isis Aparecida Drezza Braga

Forecasting do PIB e da Inflação do Brasil: usando técnicas de machine learning

Dissertação apresentada ao programa de Mestrado Profissional em Economia como requisito parcial para obtenção do título de Mestre em Economia.

Banca examinadora

Prof. Dr. Ruy Monteiro Ribeiro
Orientador(a)

Professor
Examinador(a)

São Paulo - SP
2025

Resumo

Este estudo explora o uso de técnicas modernas de machine learning para aprimorar as previsões do PIB e da inflação no Brasil. A análise utiliza um conjunto abrangente de indicadores macroeconômicos, incluindo variáveis nacionais, fornecidas pelo Banco Central do Brasil, e internacionais. Modelos como Random Forest, Lasso e CatBoost são implementados, sendo avaliados em comparação com métodos tradicionais, como modelos autoregressivos (AR) e Random Walk. Além disso, o impacto das expectativas do Boletim Focus na precisão preditiva é investigado, utilizando métricas como o erro médio quadrático raiz (RMSE) e o *Teste Diebold Mariano* para identificar diferenças estatisticamente significativas entre os modelos. Adicionalmente, a análise de importância das variáveis permite avaliar a contribuição das expectativas para o desempenho preditivo. O estudo busca não apenas quantificar os benefícios das técnicas modernas de machine learning, mas também compreender como a incorporação de variáveis prospectivas pode enriquecer as previsões econômicas em cenários complexos e dinâmicos como o do Brasil.

Palavras-chave: PIB, Inflação, Forecast, Machine Learning.

Abstract

This study explores the use of modern machine learning techniques to improve GDP and inflation forecasts in Brazil. The analysis employs a comprehensive set of macroeconomic indicators, including national variables provided by the Central Bank of Brazil and international data. Models such as Random Forest, Lasso, and CatBoost are implemented and compared with traditional methods, such as autoregressive (AR) models and Random Walk. Furthermore, the impact of the expectations from the Boletim Focus on predictive accuracy is investigated, using metrics like the root mean squared error (RMSE) and the Diebold-Mariano test to identify statistically significant differences among models. In addition, a feature importance analysis evaluates the contribution of expectations to model performance. This study aims not only to quantify the benefits of modern machine learning techniques but also to understand how incorporating prospective variables can enrich economic forecasts in complex and dynamic environments such as Brazil.

Keywords: GDP, Inflation, Forecast, Machine Learning.

JEL Classification: C53, C55, E37, E47

Sumário

1	INTRODUÇÃO	8
2	REVISÃO DA LITERATURA	11
3	METODOLOGIA	13
3.1	Estrutura Analítica	13
3.2	Modelos Empregados	13
3.3	Escolha dos Hiperparâmetros	14
3.3.1	Random Forest	15
3.3.2	CatBoosting	15
3.3.3	Lasso	15
3.3.4	Considerações Finais	15
3.4	Métricas de Avaliação	16
3.5	Comparação de Desempenho com o Boletim Focus	16
3.6	Análise Adicional: Importância das Variáveis	16
4	DADOS	17
4.1	Variáveis e Horizonte de Previsão	17
4.2	Base de Dados e Transformações	17
4.3	Testes de Quebras Estruturais	18
4.4	Divisão da Amostra e Estimação Recursiva	19
4.5	Implementação Computacional	19
5	RESULTADOS	20
5.1	Resultados: Previsão da Inflação	20
5.2	Resultados: Previsão do PIB	25
6	CONCLUSÃO	30
	REFERÊNCIAS	32
	APÊNDICE A – TABELA DE VARIÁVEIS MACROECONÔMICAS UTILIZADAS	34
	APÊNDICE B – DESCRIÇÃO DOS MODELOS	44
B.1	Random Walk	44
B.2	AR (AutoRegressive)	44

B.3	Lasso	44
B.4	Random Forest	44
B.5	CatBoost	45

1 Introdução

A previsão de indicadores macroeconômicos, como o Produto Interno Bruto (PIB) e a inflação, desempenha um papel crucial na formulação de políticas econômicas e na orientação de decisões estratégicas por governos, bancos centrais e instituições financeiras. Em economias emergentes como o Brasil, a tarefa é especialmente desafiadora devido à volatilidade inflacionária, incertezas econômicas e vulnerabilidade a choques externos, que tornam as previsões mais complexas (GARCIA; MEDEIROS; VASCONCELOS, 2017).

A inflação e o PIB são influenciados por diversos fatores, como política monetária, fiscal, choques de oferta e demanda, bem como as expectativas dos agentes econômicos (FRIEDMAN, 1968; WOODFORD, 2003). A teoria das expectativas racionais (MUTH, 1961) argumenta que os agentes utilizam todas as informações disponíveis para formar previsões, o que justificaria a inclusão das expectativas do Boletim Focus como variáveis explicativas. No entanto, estudos mais recentes indicam que as previsões do Boletim Focus podem perder acurácia em horizontes mais longos, sendo superadas por métodos de machine learning (GARCIA; MEDEIROS; VASCONCELOS, 2017). Esse resultado pode estar relacionado a vieses sistemáticos, como comportamento gregário (herding behavior) ou à subutilização de informações relevantes por parte dos agentes. Assim, um dos objetivos deste estudo é verificar se a inclusão das expectativas do Boletim Focus melhora de fato a previsão macroeconômica ou se modelos de machine learning conseguem superá-las.

Modelos econométricos tradicionais, como os autoregressivos (AR) e o modelo de passeio aleatório (Random Walk - RW), são amplamente utilizados para previsão de variáveis macroeconômicas (ATKESON; OHANIAN, 2001). Apesar de sua simplicidade, essas abordagens apresentam limitações em cenários de alta dimensionalidade e relações não lineares (ARAÚJO; GAGLIANONE, 2022). Estudos recentes apontam que o aprendizado de máquina (Machine Learning - ML) supera métodos tradicionais em diversas aplicações macroeconômicas (MEDEIROS et al., 2021), capturando padrões complexos e interações não lineares entre variáveis.

Embora modelos de machine learning frequentemente apresentem melhor desempenho preditivo, sua interpretação econômica ainda é um desafio, pois não seguem a estrutura teórica dos modelos econométricos tradicionais, como a curva IS-LM ou a Curva de Phillips. Apesar disso, sua capacidade de capturar relações não lineares e interações complexas os torna particularmente eficazes para prever variáveis altamente voláteis, como a inflação. Já para o PIB, que sofre com revisões constantes e depende de um conjunto mais amplo de fatores (STOCK; WATSON, 2016), as expectativas do mercado, capturadas pelo Boletim Focus, mostraram-se mais confiáveis na previsão econômica.

Os resultados deste estudo indicam que, para a previsão da inflação, os modelos de machine learning apresentam desempenho superior aos métodos tradicionais e às previsões do Boletim Focus, especialmente em horizontes curtos e médios. No entanto, para a previsão do PIB, as expectativas do mercado capturadas pelo Boletim Focus se mostraram mais precisas do que os modelos baseados apenas em dados históricos e aprendizado de máquina. Esses achados reforçam a importância das expectativas econômicas e sugerem que, enquanto modelos de ML são poderosos para variáveis altamente voláteis, previsões macroeconômicas de longo prazo ainda se beneficiam da incorporação da percepção do mercado.

Este estudo busca responder a duas questões centrais:

1. Os modelos de machine learning superam os métodos econométricos tradicionais na previsão da inflação e do PIB no Brasil?
2. A incorporação das expectativas do Boletim Focus melhora a acurácia das previsões em diferentes horizontes temporais?

No caso da inflação, este trabalho dá continuidade à agenda de pesquisa (GARCIA; MEDEIROS; VASCONCELOS, 2017), ao testar novos algoritmos — em especial o CatBoosting — e utilizar um período mais recente. Dessa forma, contribui para a literatura ao verificar se os avanços recentes em machine learning mantêm ou ampliam a superioridade preditiva observada em estudos anteriores.

Como contribuição adicional, este trabalho introduz o modelo CatBoost nas previsões macroeconômicas no Brasil, explorando sua eficiência computacional e sua capacidade de mitigar target leakage por meio do Ordered Boosting. Diferentemente de outros métodos de boosting, como XGBoost e LightGBM, o CatBoost utiliza uma abordagem específica para tratamento de categóricas e garante estabilidade preditiva, sendo particularmente eficaz em conjuntos de dados menores e com correlação alta entre variáveis (PROKHORENKOVA et al., 2018). Além disso, pesquisas recentes demonstram sua superioridade em aplicações financeiras e econômicas.

Este estudo utiliza uma base de dados composta por variáveis macroeconômicas brasileiras e internacionais cobrindo o período de 2004 a 2024. As variáveis são transformadas conforme as práticas consagradas na literatura, e a estacionariedade é verificada por meio do teste KPSS. As expectativas do Boletim Focus são incorporadas para horizontes de previsão de 1 a 12 meses.

O restante do trabalho está organizado da seguinte forma: a Seção 2 apresenta a revisão da literatura, abordando o avanço do uso de machine learning na previsão macroeconômica, com ênfase na aplicação por bancos centrais. A Seção 3 detalha a metodologia e a escolha dos modelos. Na Seção 4, são descritos os dados e os procedimentos

de pré-processamento. A Seção 5 apresenta e discute os resultados obtidos. Por fim, a Seção 6 sintetiza as principais contribuições do estudo e sugere direções para pesquisas futuras.

2 Revisão da Literatura

A previsão de indicadores macroeconômicos, como a inflação e o Produto Interno Bruto (PIB), tem sido objeto de extensivos estudos, especialmente em economias emergentes, como a brasileira (GARCIA; MEDEIROS; VASCONCELOS, 2017).

Historicamente, modelos econométricos tradicionais dominaram essa área de pesquisa. No entanto, os avanços em machine learning e o aumento na disponibilidade de dados têm transformado significativamente esse campo, permitindo a captura de padrões não lineares e aumentando a acurácia preditiva (ARAUJO; GAGLIANONE, 2022). Entre os modelos mais amplamente utilizados, destacam-se os Autoregressivos (AR) e o Random Walk (RW), que se sobressaem pela simplicidade e pela capacidade de capturar padrões históricos. Estudos indicam que essas abordagens frequentemente superam modelos baseados em relações instáveis, como a curva de Phillips (ATKESON; OHANIAN, 2001). Contudo, essas metodologias enfrentam limitações em contextos de alta volatilidade e elevada dimensionalidade, característicos de economias emergentes (MARCELLINO; STOCK; WATSON, 2006). Para lidar com esses desafios, modelos fatoriais dinâmicos surgiram como uma alternativa robusta, ao extrair fatores comuns de um amplo conjunto de variáveis. Esses modelos demonstraram-se eficazes no nowcasting do PIB em economias desenvolvidas, como a europeia (STOCK; WATSON, 2002).

Apesar da eficácia desses modelos tradicionais em determinados cenários, os avanços computacionais e a crescente disponibilidade de dados favorecem o desenvolvimento de abordagens mais sofisticadas. O uso de machine learning tornou-se essencial para a previsão de variáveis macroeconômicas (GARCIA; MEDEIROS; VASCONCELOS, 2017), superando limitações de linearidade e permitindo a exploração de interações complexas entre variáveis. Métodos como LASSO, Random Forest e CatBoost destacam-se pela capacidade de selecionar variáveis relevantes e capturar padrões não lineares (BREIMAN, 2001; TIBSHIRANI, 1996). Esses modelos também oferecem flexibilidade ao lidar com grandes volumes de dados e variáveis correlacionadas.

Estudos recentes evidenciam que Random Forests e redes neurais são altamente competitivos na previsão da inflação global, esses modelos frequentemente apresentam desempenho superior a métodos lineares, especialmente durante recessões, conforme observado por (MEDEIROS; SCHÜTTE; SOUSSI, 2022). No entanto, essas técnicas enfrentam desafios como overfitting, alta demanda computacional e dificuldades na interpretação de seus resultados. Esses desafios se tornam ainda mais relevantes para o PIB, cujos determinantes são mais complexos do que os da inflação e podem depender fortemente de fatores qualitativos capturados pelas expectativas de mercado. Além disso, abordagens

bayesianas não paramétricas, como Gaussian Processes, têm sido exploradas para aumentar a precisão preditiva e incorporar incertezas de forma mais robusta (CLARK et al., 2018).

O nowcasting tem ganhado relevância na literatura, especialmente devido à integração de dados alternativos, como transações eletrônicas e pesquisas de opinião (GONÇALVES, 2022). No contexto brasileiro, a inclusão de dados de pagamentos eletrônicos resultou em melhorias significativas na previsão do PIB (GONÇALVES, 2022). Por exemplo, a utilização de séries temporais de dados bancários e indicadores de alta frequência permitiu identificar mudanças rápidas nas condições econômicas, fornecendo informações valiosas para políticas públicas.

Os avanços em machine learning também vêm sendo explorados em bancos centrais ao redor do mundo, com diversas aplicações práticas. Segundo (ARAÚJO et al., 2022), técnicas como aprendizado supervisionado, não supervisionado e processamento de linguagem natural (NLP) têm sido amplamente utilizadas para aprimorar análises econômicas e financeiras, melhorar a supervisão financeira e integrar dados não estruturados em previsões macroeconômicas. Além disso, o estudo destaca que métodos como Random Forest, Gradient Boosting e redes neurais recorrentes demonstram eficiência em lidar com grandes volumes de dados, reduzindo o tempo de análise e aumentando a precisão em contextos de alta complexidade, como a supervisão de riscos financeiros. Apesar das contribuições significativas, desafios como interpretabilidade, viés nos dados e integração com processos decisórios permanecem como barreiras para uma adoção mais ampla.

Apesar dos avanços obtidos, desafios importantes persistem, como a interpretação dos modelos de machine learning e a integração de expectativas de mercado e dados alternativos (ARAÚJO; GAGLIANONE, 2022). A falta de explicabilidade desses modelos ainda é um obstáculo para sua adoção por formuladores de políticas econômicas. Recentemente, instituições como o Federal Reserve e organizações internacionais, como o Fundo Monetário Internacional (FMI), têm adotado técnicas avançadas para previsões macroeconômicas (DAUPHIN KAMIL DYBCZAK; ZHANG, 2022). O FMI, por exemplo, utiliza modelos fatoriais dinâmicos e machine learning para prever o crescimento econômico de diversos países (DAUPHIN KAMIL DYBCZAK; ZHANG, 2022), enquanto o Federal Reserve emprega nowcasting baseado em modelos fatoriais para monitorar a economia em tempo real e subsidiar decisões de política monetária (CASCALDI-GARCIA; MODUGNO, 2023).

Embora as técnicas de machine learning ofereçam contribuições promissoras, é fundamental abordar os desafios de interpretação e integração de dados. Este estudo busca contribuir para esse debate ao avaliar como diferentes abordagens de machine learning interagem com variáveis macroeconômicas e ao propor estratégias que combinem precisão preditiva com aplicabilidade no contexto brasileiro. Ademais, a inclusão de expectativas de mercado é abordada como elemento essencial para avançar a literatura existente.

3 Metodologia

Nesta seção, detalhamos a abordagem metodológica utilizada para prever a inflação e o PIB no Brasil. Este estudo emprega um conjunto de modelos que conciliam rigor econométrico e flexibilidade do machine learning, permitindo capturar tanto relações lineares quanto não lineares nos dados. Além disso, utilizamos as previsões do Boletim Focus como um benchmark empírico, permitindo avaliar se os modelos desenvolvidos oferecem ganhos preditivos sobre as expectativas formadas pelo mercado. A estrutura analítica empregada baseia-se em previsões diretas, conforme detalhado a seguir.

3.1 Estrutura Analítica

A previsão macroeconômica neste estudo adota uma abordagem de previsão direta, amplamente utilizada em estudos empíricos (MARCELLINO; STOCK; WATSON, 2006; CLARK et al., 2018). Conforme destacado por esses autores, essa abordagem modela variáveis de interesse, como PIB ou inflação h períodos à frente (Y_{t+h}), como função de preditores disponíveis no tempo t . A abordagem de previsão direta evita a modelagem explícita da dinâmica temporal dos preditores, reduzindo a complexidade da estimação em um ambiente de alta dimensionalidade. Além disso, estudos como (MARCELLINO; STOCK; WATSON, 2006; ATKESON; OHANIAN, 2001) destacam que previsões diretas frequentemente superam abordagens iterativas em horizontes curtos e médios.

A formulação básica do modelo é dada por:

$$Y_{t+h} = T(x_t) + u_{t+h}, \quad (3.1)$$

onde $T(x_t)$ pode ser uma função linear ou não linear, $x_t = (x_{1t}, \dots, x_{qt})' \in \mathbb{R}^q$ representa um vetor de q preditores, e u_{t+h} é o erro da previsão. O conjunto x_t inclui variáveis macroeconômicas e fatores derivados de grandes volumes de dados, respeitando a disponibilidade em tempo real para evitar *look-ahead bias* (MARCELLINO; STOCK; WATSON, 2006).

3.2 Modelos Empregados

Os modelos escolhidos refletem um equilíbrio entre abordagens tradicionais, amplamente utilizadas na literatura econométrica, e técnicas modernas de machine learning que capturam relações não lineares. Os modelos estatísticos (Random Walk e Autoregressivo) servem como benchmarks fundamentais para avaliar o desempenho das técnicas mais sofisticadas. Já os métodos de machine learning foram selecionados com base na capacidade

de lidar com alta dimensionalidade e não linearidade dos dados, aspectos cruciais para previsões macroeconômicas, conforme discutido por (MEDEIROS et al., 2021).

Além desses modelos, as previsões do Boletim Focus são empregadas como referência empírica, amplamente utilizado em estudos macroeconômicos para avaliar a acurácia de previsões geradas por modelos econométricos e de machine learning (GARCIA; MEDEIROS; VASCONCELOS, 2017). O Boletim Focus fornece expectativas de mercado para algumas variáveis macroeconômicas, incluindo inflação e PIB, baseando-se em um conjunto de projeções submetidas semanalmente por instituições financeiras. Sua inclusão permite verificar se as metodologias propostas oferecem ganhos preditivos em relação às previsões formadas pelo consenso do mercado. Essa abordagem segue a estratégia de pesquisas anteriores, como (GARCIA; MEDEIROS; VASCONCELOS, 2017), que analisaram a acurácia preditiva de previsões macroeconômicas utilizando diferentes técnicas.

A função $T(x_t)$ é estimada utilizando uma variedade de modelos, escolhidos por sua relevância na literatura e complementaridade metodológica:

- **Previsões do Boletim Focus:** Utilizadas como benchmark empírico, representando as expectativas do mercado para inflação e PIB.
- **Random Walk (RW):** Referência básica que assume que $Y_{t+h} = Y_t + \epsilon_{t+h}$ (ATKESON; OHANIAN, 2001).
- **Autoregressivo (AR):** Modelos lineares que capturam dependências temporais diretas, amplamente utilizados em séries estacionárias (BOX; JENKINS, 1970).
- **Lasso:** Combina seleção de variáveis e regularização, ajustando o modelo com a penalização L_1 (TIBSHIRANI, 1996).
- **Random Forest (RF):** Método de aprendizado não linear que reduz a variância combinando previsões de múltiplas árvores de decisão (BREIMAN, 2001).
- **CatBoost:** Algoritmo de *boosting* que inova no tratamento de variáveis categóricas e no controle de *target leakage* (PROKHORENKOVA et al., 2018).

3.3 Escolha dos Hiperparâmetros

A seleção de hiperparâmetros é um elemento crucial para garantir um bom desempenho preditivo dos modelos de machine learning. No entanto, em algumas circunstâncias, o ajuste manual ou a utilização de valores padrão pode ser suficiente para obter bons resultados, reduzindo custos computacionais sem perdas significativas de desempenho. Nesta seção, detalhamos as escolhas metodológicas para os modelos Random Forest, CatBoosting e Lasso.

3.3.1 Random Forest

Para o modelo de Random Forest, optamos por utilizar os valores padrão da função `randomForest()` no R. Essa decisão baseia-se na literatura, que demonstra que os hiperparâmetros padrão do Random Forest frequentemente resultam em um desempenho robusto sem necessidade de ajustes adicionais (PROBST; WRIGHT; BOULESTEIX, 2018; BERNARD; HEUTTE; ADAM, 2009).

De acordo com (PROBST; WRIGHT; BOULESTEIX, 2018), os valores padrão dos pacotes de software frequentemente fornecem soluções próximas do ótimo global. Além disso, (BERNARD; HEUTTE; ADAM, 2009) mostram que o impacto da escolha do hiperparâmetro *mtry* tende a ser pequeno em muitos casos, reforçando a viabilidade da escolha padrão.

3.3.2 CatBoosting

Para o modelo CatBoosting, selecionamos manualmente os hiperparâmetros com base na literatura e em testes empíricos. Utilizamos *iterations* = 1000, *depth* = 6 e *learning_rate* = 0.03, seguindo recomendações comuns para aplicações de séries temporais (PROKHORENKOVA et al., 2018). Essa configuração demonstrou desempenho superior aos modelos tradicionais e a outros métodos de machine learning testados, eliminando a necessidade de otimização adicional.

Além disso, como o tempo de treinamento com essa configuração já alcança aproximadamente 12 horas por execução, a busca automatizada de hiperparâmetros via *Optuna* ou *Grid Search* foi considerada inviável devido ao alto custo computacional. Trabalhos futuros podem explorar ajustes adaptativos ou estratégias alternativas para refinamento de hiperparâmetros.

3.3.3 Lasso

Para a estimação do modelo Lasso, utilizamos a função `cv.glmnet()` do pacote `glmnet` no R, que emprega validação cruzada para determinar automaticamente o valor ótimo da penalização λ (FRIEDMAN; HASTIE; TIBSHIRANI, 2010). Essa abordagem permite equilibrar parcimônia e capacidade preditiva sem a necessidade de otimizações adicionais, garantindo um modelo mais eficiente e interpretável.

3.3.4 Considerações Finais

As escolhas metodológicas apresentadas foram fundamentadas em boas práticas descritas na literatura e em testes empíricos. Em particular, a decisão de não realizar uma otimização extensiva para o Random Forest e o CatBoosting foi tomada com base na avali-

ação do custo-benefício, dado o tempo computacional envolvido. Trabalhos futuros podem explorar ajustes adicionais para verificar potenciais melhorias marginais no desempenho preditivo.

3.4 Métricas de Avaliação

- **Root Mean Squared Error (RMSE):** mede a magnitude média dos erros de previsão, penalizando desvios maiores de maneira quadrática. Esta característica torna a métrica especialmente útil ao lidar com dados macroeconômicos, onde erros extremos podem ter impactos significativos.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (3.2)$$

3.5 Comparação de Desempenho com o Boletim Focus

Para avaliar a performance preditiva dos modelos utilizados, comparamos seus resultados às previsões disponibilizadas pelo Boletim Focus, que servem como referência empírica amplamente utilizada na literatura (GARCIA; MEDEIROS; VASCONCELOS, 2017). A comparação será feita utilizando as mesmas métricas de erro, particularmente o Root Mean Squared Error (RMSE), e será complementada por testes estatísticos, como o de Diebold-Mariano, para avaliar se as diferenças entre os erros de previsão dos modelos e do Boletim Focus são estatisticamente significativas (DIEBOLD; MARIANO, 1995). Esse teste permite identificar se algum modelo possui desempenho superior de maneira robusta.

3.6 Análise Adicional: Importância das Variáveis

O modelo de CatBoost é utilizado para calcular a importância das variáveis preditivas, permitindo avaliar se as expectativas do Boletim Focus contribuem significativamente para a previsão de inflação e PIB. Essa análise fornece insights sobre a relevância das informações incorporadas pelo mercado financeiro nas projeções macroeconômicas. Caso essas variáveis se mostrem altamente relevantes, isso indicaria que os modelos conseguem capturar informações preditivas valiosas contidas no Boletim Focus.

4 Dados

Este estudo utiliza séries temporais mensais e trimestrais de dois indicadores macroeconômicos fundamentais da economia brasileira: a inflação, medida pelo Índice de Preços ao Consumidor Amplo (IPCA), e o Produto Interno Bruto (PIB) acumulado dos últimos 12 meses. Os dados foram obtidos junto ao Instituto Brasileiro de Geografia e Estatística (IBGE).

4.1 Variáveis e Horizonte de Previsão

As variáveis dependentes consideradas neste estudo são:

- A variação percentual mensal do IPCA;
- O crescimento trimestral do PIB acumulado ao longo do ano.

O horizonte de previsão (h) varia de 1 a 12 meses para a inflação mensal, e é trimestral no caso do PIB, abrangendo o período de janeiro de 2004 a junho de 2024. No total, foram utilizadas 246 observações mensais para a inflação e 82 observações trimestrais para o PIB. Este intervalo contempla diferentes fases do ciclo econômico brasileiro, incluindo o boom das commodities e a pandemia de COVID-19, o que permite testar a robustez dos modelos sob variados regimes macroeconômicos.

4.2 Base de Dados e Transformações

O conjunto de dados contém 132 variáveis contemporâneas mensais, incluindo índices de preços, taxas de juros, mercado financeiro, atividade econômica, mercado de trabalho, dívida pública, comércio internacional e variáveis internacionais, conforme (ARAUJO; GAGLIANONE, 2022). Além disso, foram adicionadas 32 variáveis de expectativas econômicas cobrindo projeções de inflação e PIB. As principais fontes incluem:

- Banco Central do Brasil (BCB);
- Índice de Incerteza Econômica (EPU) de (BAKER; BLOOM; DAVIS, 2016);
- Fundação Getulio Vargas (FGV);
- IBGE;
- IpeaData;

- Bloomberg.

No caso do PIB, este estudo utiliza exclusivamente os dados trimestrais revisados, conforme disponibilizados pelo IBGE, sem incorporar variáveis de alta frequência (como produção industrial, vendas no varejo ou indicadores financeiros diários). Essa escolha implica uma abordagem distinta do nowcasting, com foco na avaliação da capacidade preditiva dos modelos a partir de informações já consolidadas, evitando as incertezas associadas a estimativas em tempo real e às revisões subsequentes das estatísticas oficiais.

A fim de garantir a estacionariedade das séries temporais, aplicamos as transformações necessárias conforme o procedimento descrito por (ARAUJO; GAGLIANONE, 2022). No apêndice A, apresentamos todas as variáveis utilizadas juntamente com suas respectivas transformações. Consideramos seis possíveis transformações:

1. Sem transformação;
2. Δx_t ;
3. $\Delta^2 x_t$;
4. $\ln(x_t)$;
5. $\Delta \ln(x_t)$;
6. $\Delta^2 \ln(x_t)$.

A verificação da estacionariedade foi realizada através do teste de Kwiatkowski-Phillips-Schmidt-Shin (KPSS), utilizando um nível de significância de 5%. Após as transformações, as variáveis contemporâneas foram defasadas em até $s = 4$ períodos, resultando em um total de 528 séries temporais transformadas. Com a adição de interceptos e variáveis de expectativa, o conjunto final contém 661 potenciais preditores para a inflação e o PIB.

4.3 Testes de Quebras Estruturais

Foram realizados testes de quebras estruturais para identificar mudanças significativas na dinâmica da inflação e do PIB. Os testes foram conduzidos com o método *Zivot-Andrews*, que permite detectar quebras estruturais endógenas em séries temporais:

- Para a inflação, foi identificada uma quebra estrutural no período de agosto de 2020 a março de 2021, relacionada aos efeitos econômicos da pandemia de COVID-19;
- Para o PIB, a quebra estrutural foi detectada a partir de 2014, refletindo mudanças econômicas associadas ao fim do boom das commodities e início de uma recessão prolongada no Brasil.

Para modelar essas quebras estruturais, foram incluídas duas variáveis dummy no conjunto de treinamento:

- D_{IPCA} : variável dummy indicando os meses entre agosto de 2020 e março de 2021 (1 durante o período de quebra, 0 caso contrário);
- D_{PIB} : variável dummy indicando os meses a partir de 2014 (1 após 2014, 0 caso contrário).

4.4 Divisão da Amostra e Estimação Recursiva

A amostra foi dividida em:

- **Treinamento** ($T_1 = 120$ meses, de janeiro de 2004 a dezembro de 2013, para a inflação; $T_1 = 40$ trimestres, de janeiro de 2004 a dezembro de 2013, para o PIB): utilizada para estimar os modelos;
- **Teste** ($T_2 = 126$ meses, janeiro de 2014 a junho de 2024, para a inflação; $T_2 = 42$ trimestres, de março de 2014 a junho de 2024, para o PIB): usada para avaliar as previsões fora da amostra.

Para o horizonte $h = 1$, o período de avaliação inclui 126 previsões (janeiro de 2014 a junho de 2024). Já para $h = 12$, o período de avaliação compreende 120 previsões (janeiro de 2016 a junho de 2024).

Os modelos foram reestimados mensalmente em um esquema de estimação recursiva. Inicialmente, os modelos foram estimados com as primeiras T_1 observações, gerando previsões fora da amostra. Novas observações foram adicionadas sequencialmente, os modelos foram reestimados, e novas previsões geradas, repetindo-se o processo até o final do conjunto de teste.

Além disso, foram realizados testes de robustez excluindo o período posterior a pandemia de COVID-19 (março de 2020 a junho de 2024) para avaliar a estabilidade dos modelos e verificar se os resultados permaneciam consistentes fora de um cenário de alta volatilidade. Os resultados indicaram que, mesmo com a exclusão desse período, as previsões mantiveram padrões semelhantes, reforçando a robustez dos modelos.

4.5 Implementação Computacional

Os exercícios empíricos foram implementados utilizando as linguagens de programação **R** (versão 4.1.0, 64 bits) e **Python**, integrando ferramentas robustas para análise e previsão.

5 Resultados

Este capítulo apresenta os resultados obtidos com os modelos de previsão de inflação e PIB no Brasil, comparando técnicas avançadas de machine learning com métodos tradicionais, como modelos autorregressivos (AR) e random walk (RW). Também analisamos o impacto da inclusão das expectativas do Boletim Focus nos modelos preditivos e como isso influencia a acurácia em diferentes horizontes temporais. Por fim, introduzimos as métricas utilizadas, como o RMSE normalizado, e descrevemos o desempenho dos modelos.

5.1 Resultados: Previsão da Inflação

Os resultados mostram que os modelos de machine learning, como CatBoosting e Random Forest, consistentemente superaram o benchmark do Boletim Focus em horizontes curtos e médios. A Tabela 1 apresenta os RMSEs normalizados para todos os modelos e horizontes analisados, onde valores inferiores a 1 indicam desempenho superior ao benchmark.

O CatBoosting destacou-se com o menor RMSE normalizado em 5 dos 8 primeiros horizontes (H1-H8). Por exemplo, em H3, o CatBoosting obteve um RMSE normalizado de 0,966, indicando uma redução de erro de 3,4% em relação ao benchmark. Esse desempenho reflete a capacidade do modelo de capturar interações complexas e padrões não lineares nas variáveis econômicas. Além disso, a inclusão das expectativas do Boletim Focus contribuiu para ganhos adicionais em alguns horizontes, como H5 e H6.

O Random Forest também apresentou resultados competitivos, especialmente em horizontes curtos e médios. Em H2 e H6, os RMSEs normalizados foram de 0,907 e 0,924, respectivamente, representando ganhos de 9,3% e 7,6% em relação ao benchmark. Apesar de ligeiramente inferior ao CatBoosting em alguns casos, o Random Forest demonstrou maior consistência em sua performance.

O RW, apresentou RMSEs normalizados superiores a 1 em todos os horizontes analisados. Esses resultados estão alinhados com a literatura, que destaca as limitações desses métodos em capturar a complexidade das dinâmicas econômicas, especialmente em períodos de maior volatilidade (GARCIA; MEDEIROS; VASCONCELOS, 2017).

Os modelos regulares, como o Lasso e o Complete Subset Regression (CSR), tiveram desempenho inferior nos horizontes longos. No caso do Lasso, o RMSE normalizado em H12 foi de 1,915, quase o dobro do benchmark, indicando dificuldades em lidar com variáveis correlacionadas e padrões não lineares. O CSR apresentou um aumento gradual no RMSE à medida que o horizonte aumentava, refletindo limitações similares.

A Tabela 1 sintetiza o desempenho dos modelos em todos os 12 horizontes. Observa-se que o CatBoosting manteve-se como o modelo mais eficiente em horizontes curtos e médios, enquanto o Random Forest ofereceu desempenho similar em muitos desses períodos. Em contraste, os métodos tradicionais e regulares mostraram uma deterioração acentuada, especialmente em horizontes longos. Esses resultados reforçam o potencial dos modelos de machine learning como ferramentas robustas para previsões de curto e médio prazo, particularmente quando integrados às expectativas do Boletim Focus.


Tabela 1 – RMSE Normalizado pelo Focus para os horizontes de H1 a H12.

Modelo	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10	H11	H12
Focus (Benchmark)	0.353	0.411	0.427	0.437	0.459	0.461	0.446	0.432	0.413	0.395	0.396	0.394
AR	0.977	0.968	0.982	1.005	0.967	0.949	0.971	0.991	1.030	1.079	1.078	1.101
Catboosting com expectativa	0.982	0.925	0.958	0.967	0.921	0.914	0.934	0.976	1.030	1.087	1.096	1.086
Catboosting	0.986	0.917	0.966	0.970	0.923	0.908	0.938	0.973	1.000	1.070	1.080	1.090
CSR com expectativa	0.866	0.955	0.966	1.015	0.986	0.980	1.013	1.104	1.170	1.211	1.285	1.272
CSR	0.912	0.952	0.989	1.047	1.015	1.011	1.015	1.072	1.156	1.285	1.338	1.329
Lasso com expectativa	0.833	0.989	1.172	1.207	1.092	1.221	1.148	1.357	1.433	1.530	1.963	2.117
Lasso	0.939	1.291	1.385	1.441	1.569	1.277	1.228	1.301	1.360	1.456	1.787	1.915
RF com expectativa	0.931	0.912	0.952	0.967	0.929	0.912	0.946	0.980	1.020	1.080	1.090	1.110
RF	0.972	0.907	0.963	0.984	0.930	0.924	0.942	0.974	1.015	1.077	1.082	1.096
RW	1.060	1.110	1.181	1.266	1.256	1.233	1.250	1.244	1.236	1.268	1.293	1.336

Notas: Os valores destacados em negrito e/ou com sombreamento correspondem aos melhores desempenhos de cada horizonte. RMSE: Raiz do Erro Quadrático Médio. Modelos "com expectativa" incluem variáveis de expectativas do Boletim Focus.

A inclusão das variáveis de expectativas do Boletim Focus revelou-se crucial para melhorar o desempenho preditivo dos modelos de inflação. Como ilustrado na Figura 1, as variáveis de expectativas destacaram-se como os principais determinantes na previsão da inflação, seguidas pela incerteza global e pela inflação passada. Esse resultado reforça a importância das políticas de comunicação do Banco Central, dado que o alinhamento das expectativas de mercado pode ser uma ferramenta poderosa para estabilizar a inflação. Além disso, a relevância limitada das variáveis do mercado de trabalho sugere que, no Brasil, as dinâmicas inflacionárias podem ser mais influenciadas por expectativas e choques de oferta do que por fatores como desemprego, uma característica frequentemente observada em economias emergentes.

Figura 1 – Importância Médias das Famílias de Variáveis para Previsão da Inflação (H1 a H12) com Modelos CatBoosting.



Os resultados do Teste Diebold-Mariano, apresentados na Tabela 2, indicam que os modelos de Machine Learning (ML), como Catboosting e Random Forest, apresentam desempenho estatisticamente diferente ao benchmark Focus em horizontes médios e longos (H5 a H12), evidenciado por p-valores significativamente baixos. Em horizontes curtos (H1 a H4), no entanto, a diferença entre os modelos de ML e o benchmark é menos expressiva, sugerindo uma convergência no desempenho preditivo.

Tabela 2 – Teste Diebold- Mariano

Modelo	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10	H11	H12
Focus (Benchmark)												
AR	0.79	0.61	0.67	0.88	0.34	0.15	0.50	0.86	0.60	0.19	0.11	0.02
Catboosting com expectativa	0.77	0.23	0.24	0.29	0.02	0.01	0.04	0.49	0.38	0.02	0.01	0.01
Catboosting	0.84	0.20	0.39	0.33	0.02	0.01	0.04	0.48	0.84	0.05	0.02	0.01
CSR com expectativa	0.04	0.52	0.47	0.75	0.76	0.63	0.73	0.04	0.00	0.00	0.00	0.00
CSR	0.25	0.56	0.86	0.36	0.69	0.77	0.72	0.13	0.01	0.00	0.00	0.00
Lasso com expectativa	0.01	0.87	0.05	0.07	0.22	0.07	0.03	0.00	0.00	0.00	0.01	0.01
Lasso	0.35	0.03	0.00	0.00	0.07	0.01	0.01	0.00	0.00	0.00	0.01	0.00
RF com expectativa	0.28	0.17	0.23	0.31	0.03	0.01	0.13	0.64	0.52	0.03	0.01	0.00
RF	0.70	0.17	0.39	0.65	0.04	0.03	0.09	0.53	0.73	0.07	0.04	0.01
RW	0.54	0.23	0.02	0.01	0.01	0.01	0.00	0.01	0.01	0.02	0.00	0.00


Por outro lado, o modelo AR apresentou p-valores altos na maioria dos horizontes, indicando que seu desempenho é estatisticamente equivalente ao benchmark. Esses resultados evidenciam que os modelos de ML e de regressão linear regularizada, especialmente quando utilizam variáveis de expectativa, são ferramentas eficazes para aprimorar as previsões de médio e longo prazo, enquanto o Focus mantém relevância em horizontes mais curtos.

Uma análise comparativa foi conduzida para avaliar o impacto da exclusão das variáveis de expectativas nas previsões de inflação. Os resultados mostram que, ao remover essas variáveis, há um aumento significativo na importância relativa de outras famílias de variáveis. Conforme ilustrado na Figura 2, os destaques incluem as categorias Energia e Setor Público, que apresentaram incrementos percentuais de 336% e 227%, respectivamente.

Esses resultados reforçam o papel das variáveis de expectativas como controles fundamentais na modelagem inflacionária, atuando para reduzir a volatilidade e melhorar a precisão preditiva dos modelos. A maior importância atribuída às variáveis relacionadas a Energia e Setor Público sugere que, na ausência das variáveis de expectativas, choques de oferta e questões fiscais tornam-se ainda mais determinantes na dinâmica inflacionária.

Além disso, os achados corroboram a literatura existente sobre a relevância dos choques de oferta, especialmente em economias emergentes, que são altamente sensíveis a flutuações nos preços de commodities. Nesse contexto, a inclusão das variáveis de expectativas não apenas fornece uma proxy robusta para as condições de mercado antecipadas, mas também atua como um amortecedor contra a influência desproporcional de outras variáveis mais voláteis.

Figura 2 – Incremento da importância das outras famílias de variáveis ao remover as variáveis de expectativas do modelo.



Esses resultados destacam a importância de avaliar cuidadosamente o papel de variáveis proxies em modelos preditivos. A ausência das variáveis de expectativas pode levar a um modelo mais sensível a flutuações de curto prazo em variáveis exógenas, reduzindo sua robustez preditiva. Portanto, o controle por expectativas é essencial para garantir previsões mais consistentes e alinhadas à realidade econômica.

Para garantir que os resultados obtidos não sejam influenciados de forma desproporcional pelo choque extraordinário causado pela pandemia da COVID-19, replicamos as análises excluindo o período entre 2020 e 2024. Os resultados são apresentados na Tabela 3. Mesmo sem os efeitos desse choque excepcional, os modelos de machine learning que incorporam as expectativas mantiveram desempenho superior em horizontes médios de previsão.

Os valores de RMSE normalizado mostram que os modelos baseados em expectativas, como Catboosting com Expectativas, CSR com Expectativas, e RF com Expectativas, superam consistentemente os métodos tradicionais, como o modelo autoregressivo (AR) e o passeio aleatório (RW), bem como seus equivalentes sem expectativas.

Esses resultados indicam que os ganhos preditivos associados às variáveis de expectativas não dependem de eventos extraordinários, como a pandemia, mas refletem

características estruturais da dinâmica inflacionária no Brasil. Essa robustez reforça a relevância da inclusão dessas variáveis, independentemente do período analisado.

Tabela 3 – Desempenho dos Modelos de Previsão de Inflação (Excluindo 2020-2024)

Modelo	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10	H11	H12
Focus (Benchmark)	0.443	0.430	0.415	0.404	0.386	0.371	0.358	0.348	0.361	0.370	0.390	0.399
AR	1.117	0.927	0.878	0.820	0.870	0.974	1.075	1.122	1.110	1.070	0.972	0.906
Catboosting com expectativa	0.613	0.694	0.755	0.801	0.853	0.874	0.913	0.932	0.908	0.902	0.858	0.850
Catboosting	0.956	0.901	0.903	0.895	0.982	0.992	1.027	1.043	0.992	0.951	0.872	0.844
CSR com expectativa	0.545	0.667	0.723	0.775	0.860	0.878	0.939	0.956	0.950	0.955	0.934	0.933
CSR	0.596	0.726	0.783	0.860	0.964	0.991	1.004	0.968	0.941	0.934	0.932	0.979
Lasso com expectativa	0.571	0.718	0.846	0.865	1.050	1.053	1.027	1.043	1.028	1.016	0.999	0.983
Lasso	0.676	0.883	0.979	1.038	1.169	1.093	1.086	1.138	1.050	1.057	1.021	1.074
RF com expectativa	0.581	0.691	0.741	0.794	0.843	0.883	0.918	0.956	0.923	0.909	0.882	0.869
RF	0.619	0.723	0.787	0.853	0.898	0.914	0.948	0.948	0.916	0.910	0.867	0.859
RW	0.696	0.911	0.952	1.049	1.198	1.240	1.277	1.234	1.069	1.032	1.008	1.021

Notas: Os valores destacados em negrito e/ou com sombreamento correspondem aos melhores desempenhos de cada horizonte (H1 a H12). RMSE: Raiz do Erro Quadrático Médio. Modelos "com expectativa" incluem variáveis de expectativas do Boletim Focus.

Os modelos baseados em machine learning que utilizam expectativas demonstraram melhor capacidade de capturar relações complexas entre variáveis macroeconômicas, como esperado. Em particular, o desempenho destacado de modelos como o Catboosting com Expectativas e o CSR com Expectativas em horizontes médios sugere que as expectativas fornecem informações relevantes para antecipar movimentos inflacionários, mesmo fora de períodos de choques econômicos extremos.

Além disso, esses resultados corroboram com a literatura que defende o uso de métodos híbridos, os quais combinam técnicas avançadas de aprendizado de máquina com insights teóricos provenientes da macroeconomia tradicional. Ao incorporar as expectativas de agentes econômicos, os modelos não apenas alcançam maior precisão preditiva, mas também fornecem uma base interpretativa alinhada com teorias econômicas consagradas.

Os resultados apresentados nesta seção reforçam a validade do uso de variáveis de expectativas em modelos preditivos de inflação e destacam as vantagens dos métodos de machine learning para lidar com a complexidade inerente às relações econômicas. A robustez desses resultados em diferentes períodos históricos confirma que as abordagens modernas podem oferecer insights importantes tanto para a academia quanto para a formulação de políticas públicas.

5.2 Resultados: Previsão do PIB

A previsão do PIB representa um desafio significativo devido à sua natureza complexa e às frequentes revisões de dados. Diferentemente da inflação, que responde

mais rapidamente a choques econômicos, o PIB reflete um conjunto mais amplo de fatores, incluindo política fiscal, investimento e dinâmica global. Assim, prever sua trajetória exige a consideração de múltiplas fontes de incerteza.

Os modelos de machine learning apresentaram um desempenho competitivo, ainda que não tenham superado consistentemente o benchmark do Boletim Focus. No entanto, esse resultado deve ser interpretado à luz do fato de que as expectativas do mercado frequentemente já incorporam um conjunto amplo de informações disponíveis. Assim, a performance próxima ao Focus sugere que os modelos conseguiram capturar padrões relevantes na dinâmica do PIB, embora não necessariamente validem a superioridade desse benchmark.

A Tabela 4 apresenta os valores do RMSE normalizado, indicando que o CatBoosting e o Random Forest tiveram um desempenho comparável ao Focus em alguns horizontes de previsão. Em particular, o CatBoost se destacou em horizontes longos (H9-H12), onde sua capacidade de modelar não linearidades mostrou-se vantajosa.

Os modelos Random Walk (RW) e Autoregressivo (AR) apresentaram desempenho inferior ao Focus na maioria dos horizontes, o que reforça a necessidade de abordagens mais sofisticadas para a previsão do PIB. No entanto, para previsões de curto prazo (H1-H2), o RW obteve resultados comparáveis aos modelos de Machine Learning, sugerindo que a dinâmica do PIB em horizontes mais curtos pode ser capturada de forma eficaz por modelos mais simples

Tabela 4 – RMSE Normalizado pelo Focus para os horizontes de H1 a H12.

Modelo	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10	H11	H12
Focus (Benchmark)	3.095	3.728	4.059	4.302	4.158	4.235	4.480	4.705	4.796	4.840	4.853	4.797
AR	1.278	1.225	1.329	1.468	1.478	1.400	1.235	1.092	1.078	1.119	1.234	1.277
Catboosting com expectativa	1.156	1.094	1.038	1.001	1.098	1.128	1.060	1.024	0.997	0.963	0.972	0.991
Catboosting	1.160	1.089	1.013	0.998	1.056	1.095	1.041	1.034	1.002	0.996	0.980	1.012
CSR com expectativa	1.327	1.302	1.253	1.325	1.473	1.482	1.576	1.525	1.399	1.339	1.523	1.413
CSR	1.336	1.312	1.267	1.315	1.428	1.463	1.568	1.517	1.398	1.328	1.523	1.396
Lasso com expectativa	1.182	1.273	1.135	1.061	1.203	1.389	1.468	1.479	1.460	1.301	1.167	1.363
Lasso	1.140	1.239	1.132	1.045	1.154	1.350	1.332	1.359	1.370	1.237	1.168	1.328
RF com expectativa	1.147	1.101	1.021	0.999	1.133	1.162	1.094	1.038	0.998	0.992	0.995	1.019
RF	1.156	1.095	1.019	0.978	1.082	1.098	1.082	1.029	1.013	1.004	1.016	1.031
RW	1.020	1.095	1.116	1.175	1.144	1.146	1.132	1.142	1.160	1.149	1.146	1.129


Notas: O RMSE foi normalizado em relação ao benchmark Focus. Valores inferiores a 1 indicam que o modelo superou o desempenho do Focus, enquanto valores superiores indicam desempenho inferior. Os valores destacados em negrito e/ou com sombreamento correspondem aos melhores desempenhos de cada horizonte (H1 a H12). RMSE: Raiz do Erro Quadrático Médio. Modelos "com expectativa" incluem variáveis de expectativas do Boletim Focus.

A análise de importância das variáveis, conforme Figura 3 revelou que a inclusão das expectativas do Boletim Focus nos modelos reduziu a influência de fatores como taxa

de juros e setor externo. Esse resultado sugere que as previsões de mercado já sintetizam informações fundamentais sobre a trajetória econômica futura, reforçando a relevância do Focus como benchmark preditivo.

Além disso, ao remover as expectativas do Focus dos modelos, a importância relativa de variáveis como atividade econômica e comércio internacional aumentou consideravelmente. Isso reforça o papel das expectativas como agregadores eficientes de informações para a previsão do PIB.

Figura 3 – Importância Médias das Famílias de Variáveis para Previsão do PIB (H1 a H12) com Modelos CatBoosting



O teste de Diebold-Mariano, conforme Tabela 5, indicou que, embora o Catboosting e o Random Forest apresentem variações nos RMSEs em alguns horizontes de tempo, essas diferenças não foram estatisticamente significativas em nenhum dos horizontes analisados. Esse resultado sugere que, do ponto de vista estatístico, não há evidências suficientes para afirmar que um modelo supera consistentemente o outro. Essa constatação reforça a necessidade de abordagens híbridas e da incorporação de variáveis prospectivas que possam fornecer informações adicionais à previsão do PIB.

Tabela 5 – Teste Diebold- Mariano

Modelo	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10	H11	H12
Focus (Benchmark)												
AR	0.092	0.056	0.032	0.001	0.001	0.001	0.013	0.208	0.487	0.312	0.128	0.083
Catboosting com expectativa	0.06	0.243	0.673	0.992	0.293	0.122	0.436	0.764	0.971	0.633	0.729	0.922
Catboosting	0.053	0.311	0.885	0.984	0.533	0.242	0.573	0.671	0.983	0.957	0.804	0.898
CSR com expectativa	0.074	0.076	0.075	0.019	0.006	0.002	0.001	0.001	0.004	0.021	0.017	0.019
CSR	0.078	0.066	0.063	0.023	0.014	0.004	0.001	0.001	0.004	0.027	0.016	0.027
Lasso com expectativa	0.101	0.022	0.144	0.522	0.097	0.024	0.001	0.001	0.002	0.03	0.123	0.012
Lasso	0.12	0.041	0.185	0.651	0.22	0.043	0.024	0.004	0.007	0.049	0.109	0.019
RF com expectativa	0.047	0.062	0.758	0.989	0.15	0.05	0.238	0.64	0.978	0.919	0.951	0.827
RF	0.037	0.112	0.804	0.816	0.349	0.207	0.304	0.724	0.884	0.962	0.843	0.721
RW	0.866	0.486	0.324	0.24	0.187	0.137	0.09	0.082	0.086	0.072	0.093	0.127

Para avaliar a robustez dos modelos, replicamos a análise excluindo o período da pandemia de COVID-19 (2020-2024). A Tabela 6, evidencia que os resultados mantiveram um padrão semelhante, sugerindo que a dificuldade em superar o Focus não se deve exclusivamente a choques atípicos, mas sim à própria dinâmica da previsão do PIB. Esse achado reforça que modelos híbridos, combinando aprendizado de máquina com métodos tradicionais, podem ser uma abordagem promissora para futuras pesquisas.

Tabela 6 – Desempenho dos Modelos de Previsão de PIB (Excluindo 2020-2024)

Modelo	H1	H2	H3	H4	H5	H6	H7	H8	H9	H10	H11	H12
Focus (Benchmark)	1.403	1.828	2.166	2.500	2.919	3.237	3.516	3.771	3.962	4.022	4.115	4.218
AR	1.129	1.5829	1.855	2.138	1.851	1.645	1.647	1.676	1.706	1.777	1.908	2.384
Catboosting com expectativa	1.798	1.5184	1.416	1.346	1.347	1.279	1.189	1.141	1.105	1.087	1.082	1.055
Catboosting	1.828	1.5782	1.397	1.271	1.245	1.221	1.148	1.120	1.087	1.089	1.096	1.056
CSR com expectativa	1.069	1.1753	1.383	1.687	1.837	1.716	1.796	1.857	1.888	1.991	2.179	2.182
CSR	1.035	1.1627	1.418	1.691	1.744	1.662	1.670	1.728	1.810	1.936	2.223	2.225
Lasso com expectativa	1.211	1.2698	1.482	1.633	1.310	1.379	1.892	1.712	1.951	1.522	1.511	1.218
Lasso	1.240	1.3524	1.466	1.436	1.391	1.523	1.436	1.311	1.568	1.451	1.515	1.230
RF com expectativa	1.682	1.4863	1.441	1.403	1.363	1.270	1.194	1.153	1.111	1.102	1.067	1.057
RF	1.657	1.4515	1.353	1.275	1.228	1.180	1.144	1.131	1.110	1.103	1.071	1.048
RW	0.860	0.9711	1.029	1.136	1.125	1.129	1.149	1.139	1.136	1.180	1.167	1.141

Notas: Os valores destacados em negrito e/ou com sombreamento correspondem aos melhores desempenhos de cada horizonte (H1 a H12). RMSE: Raiz do Erro Quadrático Médio. Modelos 'com expectativa' incluem variáveis de expectativas do Boletim Focus.

Além disso, os resultados encontrados reforçam uma evidência recorrente na literatura: a importância do uso de dados de alta frequência para a previsão do PIB. A limitação metodológica deste estudo — centrado exclusivamente em dados mensais e trimestrais consolidados — ajuda a explicar por que os modelos de machine learning não conseguiram superar o benchmark do Focus de forma significativa. Assim, os achados corroboram a ideia

de que a maior acurácia em previsões de PIB frequentemente está associada à incorporação de indicadores de alta frequência, como produção industrial, confiança do consumidor e dados financeiros em tempo real, elementos comumente presentes nas abordagens de nowcasting.

Os resultados indicam que a previsão do PIB continua sendo um desafio para qualquer abordagem, mas a aplicação de técnicas modernas de machine learning pode complementar metodologias tradicionais ao identificar padrões complexos na dinâmica econômica. O fato de os modelos de aprendizado de máquina não terem superado o Focus de maneira consistente sugere que as expectativas do mercado já desempenham um papel informativo relevante na previsão do crescimento econômico.

Isso reforça a necessidade de abordagens híbridas, que combinem insights de modelos tradicionais com a flexibilidade dos métodos de machine learning para capturar melhor as relações econômicas subjacentes.

Para pesquisas futuras, recomenda-se a exploração de dados alternativos, como indicadores de alta frequência (ex.: transações eletrônicas e notícias econômicas), que podem captar nuances não acessíveis por modelos tradicionais. Além disso, o uso de abordagens bayesianas não paramétricas pode fornecer estimativas mais robustas em cenários de alta incerteza.

Com essas estratégias, espera-se que modelos preditivos de PIB possam atingir um nível mais alto de precisão, combinando a expertise de agentes econômicos com o poder de modelagem de técnicas avançadas de machine learning.

6 Conclusão

Este estudo investigou a aplicação de técnicas de machine learning para a previsão da inflação e do PIB no Brasil, comparando seu desempenho com métodos tradicionais e com as expectativas do Boletim Focus. Os resultados mostraram que os modelos de machine learning superaram o Focus na previsão da inflação, especialmente em horizontes curtos e médios. Já para o PIB, os modelos apresentaram desempenho similar ao Focus, evidenciando a complexidade inerente a esse processo preditivo.

Embora os modelos de machine learning não tenham superado sistematicamente o Focus na previsão do PIB, essa conclusão não deve ser vista como uma limitação, mas sim como uma confirmação da eficiência das expectativas do mercado na agregação de informações macroeconômicas. Esse resultado sugere que a incorporação de abordagens híbridas combinando modelos econométricos tradicionais com algoritmos de aprendizado de máquina pode ser um caminho promissor para melhorar previsões futuras.

Adicionalmente, os achados reforçam a evidência de que o uso de dados de alta frequência pode ser um fator determinante para ganhos substantivos na previsão do PIB. Como este estudo utilizou apenas dados mensais e trimestrais consolidados, é provável que a ausência de indicadores em tempo real, como produção industrial, confiança do consumidor e dados financeiros diários, tenha limitado o desempenho dos modelos. Essa constatação corrobora a literatura de nowcasting, que destaca a importância de informações mais granulares para capturar variações na atividade econômica de forma mais precisa.

A análise de importância das variáveis revelou ainda que as expectativas econômicas desempenham um papel crucial na previsão da inflação, reduzindo a necessidade de modelos excessivamente complexos. Essa descoberta reforça a relevância do monitoramento de expectativas na formulação de políticas econômicas e na modelagem preditiva.

Apesar dos avanços obtidos, este estudo enfrenta algumas limitações. A dependência de dados macroeconômicos retrospectivos pode restringir a aplicabilidade em contextos com menor disponibilidade de informações. Além disso, o impacto de escolhas específicas de hiperparâmetros e métodos de seleção de variáveis sugere que refinamentos futuros podem ampliar ainda mais a precisão dos modelos.

Como contribuição para a literatura, este trabalho reforça a viabilidade e os benefícios de incorporar métodos modernos de machine learning em economias emergentes. Também destaca a importância de variáveis prospectivas, como as expectativas do Boletim Focus, para enriquecer análises macroeconômicas. Para aplicações práticas, as evidências apresentadas sugerem que formuladores de políticas públicas e instituições financeiras poderiam integrar essas abordagens em suas ferramentas de análise para apoiar decisões

estratégicas em cenários de alta volatilidade e incerteza.

Pesquisas futuras poderiam explorar combinações híbridas entre machine learning e modelos econométricos tradicionais, aproveitando a força dos dois paradigmas. Além disso, a ampliação do estudo para outros indicadores macroeconômicos e diferentes contextos econômicos pode contribuir para uma compreensão ainda mais abrangente do potencial dessas técnicas.

Em resumo, este estudo avança na fronteira das previsões econômicas no Brasil, demonstrando que a sinergia entre dados de qualidade, variáveis prospectivas e métodos estatísticos avançados é essencial para enfrentar os desafios de modelagem em economias complexas e dinâmicas.

Referências

ARAUJO, D. et al. Machine learning applications in central banking. **IFC Bulletin**, v. 57, November 2022. Organizado pelo Irving Fisher Committee e pelo Bank of Italy, com apoio do European Central Bank e do South African Reserve Bank. Disponível em: <https://www.bis.org/ifc/publ/ifcb57_01_rh.pdf>.

ARAUJO, G. S.; GAGLIANONE, W. P. **Machine Learning Methods for Inflation Forecasting in Brazil: New Contenders Versus Classical Models**. [S.l.], 2022. Disponível em: <<https://www.bcb.gov.br/pec/wps/ingl/wps561.pdf>>.

ATKESON, A.; OHANIAN, L. E. Are phillips curves useful for forecasting inflation? **Federal Reserve Bank of Minneapolis Quarterly Review**, v. 25, n. 1, p. 2–11, 2001.

BAKER, S. R.; BLOOM, N.; DAVIS, S. J. Measuring economic policy uncertainty. **The Quarterly Journal of Economics**, Oxford University Press, v. 131, n. 4, p. 1593–1636, 2016.

BERNARD, S.; HEUTTE, L.; ADAM, S. Influence of hyperparameters on random forest accuracy. In: **Multiple Classifier Systems**. Springer, 2009. p. 171–180. Disponível em: <https://link.springer.com/content/pdf/10.1007/978-3-642-02326-2_18.pdf>.

BOX, G. E.; JENKINS, G. M. **Time series analysis: Forecasting and control**. [S.l.]: Holden-Day, 1970.

BREIMAN, L. Random forests. **Machine learning**, Springer, v. 45, n. 1, p. 5–32, 2001.

CASCALDI-GARCIA, M. L. D.; MODUGNO, M. Lessons from nowcasting gdp across the world. **Federal Reserve Board**, n. 1385, 2023.

CLARK, T. E. et al. Forecasting us inflation using bayesian nonparametric models. **Journal of Business & Economic Statistics**, Taylor & Francis, v. 36, n. 3, p. 412–425, 2018.

DAUPHIN KAMIL DYBCZAK, M. M. M. T. S. N. S. Y. W. J.-F.; ZHANG, H. Nowcasting gdp: A scalable approach using dynamic factor models, machine learning, and novel data. **International Monetary Fund**, n. 2022/052, 2022.

DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. **Journal of Business & Economic Statistics**, v. 13, n. 3, p. 253–263, 1995.

FRIEDMAN, J.; HASTIE, T.; TIBSHIRANI, R. **Regularization Paths for Generalized Linear Models via Coordinate Descent**. 2010. 1–22 p. Disponível em: <<https://cran.r-project.org/web/packages/glmnet/glmnet.pdf>>.

FRIEDMAN, M. The role of monetary policy. **The American Economic Review**, American Economic Association, v. 58, n. 1, p. 1–17, 1968.

GARCIA, M.; MEDEIROS, M. C.; VASCONCELOS, G. Real-time inflation forecasting with high-dimensional models: The case of brazil. **International Journal of Forecasting**, Elsevier, v. 33, n. 4, p. 679–693, 2017.

GONÇALVES, R. N. C. Nowcasting brazilian gdp with electronic payments data. **Banco Central do Brasil**, n. 564, 2022.

MARCELLINO, M.; STOCK, J. H.; WATSON, M. W. A comparison of direct and iterated multistep ar methods for forecasting macroeconomic time series. **Journal of Econometrics**, Elsevier, v. 135, n. 1-2, p. 499–526, 2006.

MEDEIROS, M. C.; SCHÜTTE, E. C. M.; SOUSSI, T. S. Global inflation: Implications for forecasting and monetary policy. **SSRN Electronic Journal**, 2022. Disponível em: <<https://ssrn.com/abstract=4145665>>.

MEDEIROS, M. C. et al. Forecasting inflation in a data-rich environment: The benefits of machine learning methods. **Journal of Business and Economic Statistics**, Taylor & Francis, v. 39, p. 98–119, 2021. PDF file. Supplementary Material.

MUTH, J. F. Rational expectations and the theory of price movements. **Econometrica**, The Econometric Society, v. 29, n. 3, p. 315–335, 1961.

PROBST, P.; WRIGHT, M. N.; BOULESTEIX, A.-L. Hyperparameters and tuning strategies for random forest. **arXiv preprint arXiv:1804.03515**, 2018. Disponível em: <<https://arxiv.org/abs/1804.03515>>.

PROKHORENKOVA, L. et al. **CatBoost: Unbiased Boosting with Categorical Features**. 2018. Disponível em: <<https://arxiv.org/abs/1706.09516>>.

STOCK, J. H.; WATSON, M. W. Macroeconomic forecasting using diffusion indexes. **Journal of Business & Economic Statistics**, Taylor & Francis, v. 20, n. 2, p. 147–162, 2002.

STOCK, J. H.; WATSON, M. W. Dynamic factor models, factor-augmented vector autoregressions, and structural vector autoregressions in macroeconomics. **Handbook of Macroeconomics**, Elsevier, v. 2, p. 415–525, 2016.

TIBSHIRANI, R. Regression shrinkage and selection via the lasso. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 58, n. 1, p. 267–288, 1996.

WOODFORD, M. **Interest and Prices: Foundations of a Theory of Monetary Policy**. Princeton, NJ: Princeton University Press, 2003.

APÊNDICE A – Tabela de Variáveis Macroeconômicas Utilizadas

Categoria	Nome	Fonte	Unidade Original	tcode
Inflação	IPCA (índice de preços ao consumidor)	IBGE	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, preços de mercado)	IBGE	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, preços administrados)	IBGE	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, bens comercializáveis)	BCB	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, bens não comercializáveis)	BCB	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, serviços)	BCB	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, bens industriais)	BCB	%p.m.	1
Inflação	IPCA (índice de preços ao consumidor, alimentação no domicílio)	BCB	%p.m.	1
Inflação	Índice de difusão do IPCA	BCB	%	1
Inflação	IPCA-15 (índice de preços ao consumidor amplo-15)	IBGE	%p.m.	1
Inflação	IPC-Fipe (índice de preços ao consumidor)	Fipe	%p.m.	1
Inflação	IPC-Br (índice de preços ao consumidor)	FGV	%p.m.	1
Inflação	IGP-DI (índice geral de preços)	FGV	%p.m.	1
Inflação	IGP-M (índice geral de preços)	FGV	%p.m.	1
Inflação	IGP-10 (índice geral de preços)	FGV	%p.m.	1

Categoria	Nome	Fonte	Unidade Original	tcode
Inflação	INCC (índice nacional de custo da construção)	FGV	%p.m.	1
Inflação	Núcleo IPC-Br (núcleo de inflação)	FGV	%p.m.	1
Inflação	Núcleo IPCA - Exclusão EX0 (núcleo de inflação)	BCB	%p.m.	1
Inflação	Núcleo IPCA - Exclusão EX1 (núcleo de inflação)	BCB	%p.m.	1
Inflação	Núcleo IPCA - Ponderação dupla (núcleo de inflação)	BCB	%p.m.	1
Inflação	Núcleo IPCA - Médias podadas suavizadas (núcleo de inflação)	BCB	%p.m.	1
Taxas de Juros	Taxa nominal de juros Selic	BCB	%p.a.	2
Taxas de Juros	Taxa nominal de juros Selic	Bloomberg	%p.a.	2
Taxas de Juros	Taxa de juros de longo prazo (TJLP)	BCB	%p.a.	2
Taxas de Juros	Títulos do Tesouro dos EUA, rendimento nominal 3 meses	Bloomberg	%p.a.	2
Taxas de Juros	Títulos do Tesouro dos EUA, rendimento nominal 2 anos	Bloomberg	%p.a.	2
Taxas de Juros	Títulos do Tesouro dos EUA, rendimento nominal 10 anos	Bloomberg	%p.a.	2
Taxas de Juros	TIPS (Títulos do Tesouro dos EUA protegidos contra inflação, 5 anos)	Bloomberg	%p.a.	2
Taxas de Juros	Brasil Cetip DI Depósitos Interbancários	Bloomberg	%p.a.	2
Taxas de Juros	Brasil Taxa de Juros de Longo Prazo (BNDES)	Bloomberg	%p.a.	2
Dinheiro	Base monetária Brasil	Bloomberg	R\$	5
Dinheiro	Oferta de dinheiro M1 Brasil	Bloomberg	R\$	5
Dinheiro	Oferta de dinheiro M2 Brasil	Bloomberg	R\$	6
Dinheiro	Oferta de dinheiro M3 Brasil	Bloomberg	R\$	6

Categoria	Nome	Fonte	Unidade Original	tcode
Dinheiro	Oferta de dinheiro M4 Brasil	Bloomberg	R\$	6
Dinheiro	Depósitos totais de poupança no Brasil	Bloomberg	R\$ milhões	6
Bancos	Spread médio de novas operações de crédito não direcionado	BCB	pontos base	2
Bancos	Percentual de operações de crédito vencidas em 90 dias	BCB	%	2
Mercados de Capital	Ibovespa (Brasil)	Bloomberg	Índice	5
Mercados de Capital	Taxa de câmbio USD-BRL	Bloomberg	R\$	2
Mercados de Capital	Taxa de câmbio EUR-BRL	Bloomberg	R\$	2
Mercados de Capital	MSCI países emergentes (EM, US\$)	Bloomberg	Índice	5
Câmbio e Risco	Índice do dólar dos EUA (DXY)	Bloomberg	Índice	5
Câmbio e Risco	Títulos corporativos dos EUA (Moody's BAA)	Bloomberg	%p.a.	2
Câmbio e Risco	Índice de volatilidade VIX (S&P 500)	Bloomberg	Índice	1
Trabalho	Taxa de desemprego (aberta)	IBGE	%	3
Trabalho	Taxa de desemprego Brasil (IBGE)	Bloomberg	%	2
Trabalho	Taxa de desemprego masculina no Brasil	Bloomberg	%	2
Trabalho	Taxa de desemprego total no Brasil	Bloomberg	%	2
Trabalho	Taxa de desemprego Brasil (FMI)	Bloomberg	%	2
Trabalho	Emprego na indústria de manufatura (CNI)	Bloomberg	%	2
Trabalho	Horas trabalhadas na indústria brasileira	Bloomberg	%	2
Trabalho	Emprego formal criado - Sul	MTb	Unidades	2
Trabalho	Emprego formal criado - Sudeste	MTb	Unidades	2

Categoria	Nome	Fonte	Unidade Original	tcode
Trabalho	Emprego formal criado - Norte	MTb	Unidades	2
Trabalho	Emprego formal criado - Nordeste	MTb	Unidades	2
Trabalho	Emprego formal criado - Centro-Oeste	MTb	Unidades	2
Trabalho	Salário mínimo	MTb	R\$	5
Trabalho	Rendimento total disponível (acumulado em 12 meses)	BCB	R\$ milhões	6
Indústria	Produção industrial (extração mineral)	IBGE	Índice	5
Indústria	Produção industrial (indústria de manufatura)	IBGE	Índice	5
Indústria	Produção industrial (bens de capital)	IBGE	Índice	5
Indústria	Produção industrial (bens intermediários)	IBGE	Índice	5
Indústria	Produção industrial (bens de consumo)	IBGE	Índice	5
Indústria	Produção industrial (bens duráveis)	IBGE	Índice	5
Indústria	Produção industrial (bens semiduráveis e não duráveis)	IBGE	Índice	5
Indústria	Utilização da capacidade (indústria de manufatura, FGV)	FGV	%	5
Indústria	Produção de aço	BCB	Índice	5
Indústria	Produção de veículos (total)	Anfavea	Unidades	5
Indústria	Produção de caminhões	Anfavea	Unidades	5
Indústria	Produção de ônibus	Anfavea	Unidades	5
Vendas	Índice de volume de vendas no comércio varejista (total)	IBGE	Índice	5
Vendas	Índice de volume de vendas no comércio varejista (combustíveis e lubrificantes)	IBGE	Índice	5
Vendas	Índice de volume de vendas no comércio varejista (hipermercados, supermercados, alimentos, bebidas e tabaco)	IBGE	Índice	5

Categoria	Nome	Fonte	Unidade Original	tcode
Vendas	Índice de volume de vendas no comércio varejista (têxteis, vestuário e calçados)	IBGE	Índice	5
Vendas	Índice de volume de vendas no comércio varejista (móveis e eletrodomésticos)	IBGE	Índice	5
Vendas	Índice de volume de vendas no comércio varejista (veículos, motocicletas e peças)	IBGE	Índice	5
Vendas	Vendas de veículos (total)	Anfavea	Unidades	5
Vendas	Vendas de veículos domésticos	Anfavea	Unidades	5
Energia	Consumo de energia elétrica (comercial)	Eletrobras	GWh	5
Energia	Consumo de energia elétrica (residencial)	Eletrobras	GWh	5
Energia	Consumo de energia elétrica (industrial)	Eletrobras	GWh	5
Energia	Consumo de energia elétrica (outros)	Eletrobras	GWh	5
Energia	Consumo total de energia elétrica	Eletrobras	GWh	5
Setor Público	Resultado primário do setor público consolidado (fluxo mensal)	BCB	R\$ milhões	2
Setor Público	Resultado primário do setor público consolidado (acumulado em 12 meses)	BCB	R\$ milhões	3
Setor Público	Resultado primário do setor público consolidado (acumulado em 12 meses, % PIB)	BCB	%	2
Setor Público	Dívida líquida do setor público (total, governo federal e banco central, % PIB)	BCB	%	3
Setor Público	Dívida líquida do setor público (interna, governo federal e banco central, % PIB)	BCB	%	3
Setor Público	Dívida líquida do setor público (externa, governo federal e banco central, % PIB)	BCB	%	2
Setor Público	Dívida líquida do setor público (total, setor público consolidado, saldos em reais)	BCB	R\$ milhões	6

Categoria	Nome	Fonte	Unidade Original	tcode
Setor Público	Dívida líquida do setor público (interna, setor público consolidado, saldos em reais)	BCB	R\$ milhões	6
Setor Público	Dívida líquida do setor público (externa, setor público consolidado, saldos em reais)	BCB	R\$ milhões	2
Atividade Econômica	IBC-BR (índice de atividade econômica do banco central)	BCB	Índice	5
Atividade Econômica	PIB (acumulado nos últimos 12 meses, preços correntes)	BCB	R\$ milhões	6
Atividade Econômica	Índice de confiança do consumidor	Fecomercio	Índice	2
Exterior	Importações - Balanço de Pagamentos - mensal	BCB	US\$	5
Exterior	Importações - mercadorias gerais - Balanço de Pagamentos - mensal	BCB	US\$	5
Exterior	Importações - ouro não monetário - Balanço de Pagamentos - mensal	BCB	US\$	5
Exterior	Exportações - Balanço de Pagamentos - mensal	BCB	US\$	5
Exterior	Exportações - mercadorias gerais - Balanço de Pagamentos - mensal	BCB	US\$	5
Exterior	Exportações - ouro não monetário - Balanço de Pagamentos - mensal	BCB	US\$	5
Exterior	Reservas internacionais (total)	BCB	US\$ milhões	6
Exterior	Conta corrente (mensal, líquida)	BCB	US\$ milhões	2
Exterior	Conta corrente (acumulada em 12 meses, em relação ao PIB)	BCB	%	2

Categoria	Nome	Fonte	Unidade Original	tcode
Governo e Transações Internacionais	Contribuição Social sobre o Lucro Líquido (CSSL)	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Receita do PIS e PASEP	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Receita líquida do governo central do Brasil	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Receita do governo central do Brasil do Banco Central	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Despesas totais do governo central do Brasil	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Receita bruta do Tesouro Nacional do Brasil	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Receita do Imposto de Importação do Brasil	Bloomberg	%p.m.	2
Governo e Transações Internacionais	Impostos de renda do BNDES Brasil	Bloomberg	%p.m.	2
Governo e Transações Internacionais	Receita do Tesouro Nacional do Brasil de Produtos Industrializados	Bloomberg	%	2
Governo e Transações Internacionais	Receita do governo central do Brasil da Previdência Social	Bloomberg	%	2
Governo e Transações Internacionais	Receita do Tesouro Nacional do Brasil do Imposto de Importação	Bloomberg	%	2

Categoria	Nome	Fonte	Unidade Original	tcode
Governo e Transações Internacionais	Conta Corrente do Brasil	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Balança comercial FOB	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Dívida Fiscal Líquida Pública do Brasil como porcentagem do PIB	Bloomberg	%	2
Governo e Transações Internacionais	Dívida Fiscal Líquida Pública do Brasil	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Dívida doméstica do governo federal brasileiro	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Dívida doméstica do governo e Banco Central do Brasil	Bloomberg	US\$ milhões	2
Governo e Transações Internacionais	Dívida dos estados brasileiros com estrangeiros	Bloomberg	%	2
Governo e Transações Internacionais	Dívida das cidades brasileiras	Bloomberg	%	2
Governo e Transações Internacionais	Dívida das cidades brasileiras com estrangeiros	Bloomberg	%	2
Commodities	Índice CRB de todas as commodities	Bloomberg	Índice	5
Commodities	Índice CRB de alimentos	Bloomberg	Índice	5
Commodities	Índice CRB de metais	Bloomberg	Índice	5
Commodities	Índice Báltico seco	Bloomberg	Índice	5

Categoria	Nome	Fonte	Unidade Original	tcode
Commodities	Preço do petróleo (Brent, Europa)	Bloomberg	US\$ / barril	5
Commodities	Preço do petróleo (WTI, Oklahoma-EUA)	Bloomberg	US\$ / barril	5
Incerteza Global	Índice de incerteza da política econômica da Austrália	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica do Brasil	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica do Canadá	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica do Chile	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da China	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da França	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Alemanha	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Grécia	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Índia	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Irlanda	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Itália	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica do Japão	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Coreia	Bloomberg	Índice	2

Categoria	Nome	Fonte	Unidade Original	tcode
Incerteza Global	Índice de incerteza da política econômica da Holanda	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Rússia	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica da Espanha	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica de Singapura	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica do Reino Unido	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica dos EUA	Bloomberg	Índice	2
Incerteza Global	Índice de incerteza da política econômica do México	Bloomberg	Índice	2

Tabela 7 – Tabela de variáveis macroeconômicas e financeiras.

APÊNDICE B – Descrição dos Modelos

B.1 Random Walk

O modelo de *Random Walk* (RW) foi introduzido por Bachelier (1900) e amplamente utilizado em previsões econômicas como referência (*benchmark*). Ele assume que os valores futuros de uma série temporal são iguais aos valores presentes, acrescidos de um erro aleatório. Sua formulação é dada por:

$$y_{t+1} = y_t + \epsilon_{t+1},$$

onde $\epsilon_{t+1} \sim N(0, \sigma^2)$ é um termo de erro branco (ATKESON; OHANIAN, 2001).

B.2 AR (AutoRegressive)

O modelo autoregressivo (*AutoRegressive* - AR) é uma ferramenta fundamental para modelagem de séries temporais, que assume que o valor atual de uma variável é uma combinação linear de seus valores passados e de um termo de erro. A formulação geral de um modelo AR(p) é:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t,$$

onde $\phi_1, \phi_2, \dots, \phi_p$ são os coeficientes autoregressivos, p é a ordem do modelo, e $\epsilon_t \sim N(0, \sigma^2)$ é o termo de erro branco (BOX; JENKINS, 1970).

B.3 Lasso

O *Least Absolute Shrinkage and Selection Operator* (Lasso), introduzido por (TIBSHIRANI, 1996), combina regularização e seleção de variáveis. Sua função objetivo é:

$$\hat{\beta} = \arg \min_{\beta} \left(\sum_{i=1}^n (y_i - X_i \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right),$$

onde λ controla a penalização aplicada aos coeficientes. O Lasso é amplamente utilizado em contextos de alta dimensionalidade, proporcionando maior interpretabilidade e robustez em relação a modelos tradicionais.

B.4 Random Forest

O *Random Forest* (RF), proposto por (BREIMAN, 2001), é um método de aprendizado baseado em árvores de decisão. Ele combina múltiplas árvores para reduzir a variância

das previsões e capturar relações não lineares e complexas entre os preditores. Cada árvore é ajustada a um subconjunto aleatório dos dados (*bagging*), e a previsão final é obtida pela média (para variáveis contínuas) ou pelo voto majoritário (para variáveis categóricas).

A formulação geral do RF é:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x),$$

onde: - $T_b(x)$: Previsão da b -ésima árvore; - B : Número total de árvores na floresta; - x : Vetor de preditores.

O RF introduz aleatoriedade adicional ao processo de construção das árvores, selecionando aleatoriamente um subconjunto de variáveis em cada nó para determinar a melhor divisão. Isso melhora sua capacidade de generalização e reduz o risco de sobreajuste (BREIMAN, 2001).

B.5 CatBoost

O CatBoost é um modelo de *gradient boosting* desenvolvido para lidar com problemas de alta dimensionalidade e variáveis categóricas de forma eficiente. Proposto por (PROKHORENKOVA et al., 2018), ele utiliza técnicas como *ordered boosting* para evitar *target leakage* e *mean encoding* com ruído para mitigar *overfitting*.

Sua formulação segue a técnica de minimização de perda:

$$L(\theta) = \sum_{i=1}^N \ell(y_i, f(x_i; \theta)),$$

onde: - ℓ : Função de perda (como o erro quadrático ou a entropia cruzada); - $f(x_i; \theta)$: Predição do modelo; - θ : Parâmetros ajustáveis.

Além disso, o CatBoost é otimizado para lidar com conjuntos de dados com alta cardinalidade de variáveis categóricas, utilizando codificação eficiente e ajustes baseados em informações acumuladas durante o treinamento. Sua robustez e eficiência o tornam especialmente útil para previsões macroeconômicas e outras aplicações estruturadas (PROKHORENKOVA et al., 2018).