FUNDAÇÃO GETULIO VARGAS
ESCOLA DE ECONOMIA DE SÃO PAULO

ALEXANDRE DA COSTA CASTELLI

MODELO *MIDAS* DE PROJEÇÃO DO PIB BRASILEIRO UTILIZANDO A PESQUISA INDUSTRIAL MENSAL

SÃO PAULO

2022

ALEXANDRE DA COSTA CASTELLI

MODELO *MIDAS* DE PROJEÇÃO DO PIB BRASILEIRO UTILIZANDO A PESQUISA INDUSTRIAL MENSAL

Dissertação apresentada à Escola de Economia de São Paulo da Fundação Getulio Vargas como requisito para obtenção do título de Mestre em Economia.

Orientador: Prof. Dr. Rogério Mori.

SÃO PAULO

2022

Castelli, Alexandre da Costa.

Modelo midas de projeção do PIB brasileiro utilizando a pesquisa industrial mensal / Alexandre da Costa Castelli. - 2022.

38 f.

Orientador: Rogerio Mori.

Dissertação (mestrado profissional MPFE) – Fundação Getulio Vargas, Escola de Economia de São Paulo.

1. Modelos econométricos. 2. Produto Interno Bruto - Brasil. 3. Macroeconomia. 4. Previsão econômica. I. Mori, Rogerio. II. Dissertação (mestrado profissional MPFE) – Escola de Economia de São Paulo. III. Fundação Getulio Vargas. IV. Título.

CDU 330.55(81)

Ficha Catalográfica elaborada por: Raphael Figueiredo Xavier CRB SP-009987/O
Biblioteca Karl A. Boedecker da Fundação Getulio Vargas - SP

ALEXANDRE DA COSTA CASTELLI

MODELO *MIDAS* DE PROJEÇÃO DO PIB BRASILEIRO UTILIZANDO A PESQUISA INDUSTRIAL MENSAL

Dissertação apresentada à Escola de Economia de São Paulo da Fundação Getulio Vargas como requisito para obtenção do título de Mestre em Economia.

Campo de Conhecimento: Economia.

Data de aprovação: 29/03/2022

Banca examinadora:

Prof. Dr. Rogério Mori (Orientador)
Fundação Getulio Vargas

Prof. Dr. Emerson Fernandes Marçal
Fundação Getulio Vargas

Prof. Dr. Diogo de Prince Mendonça
Universidade Federal de São Paulo

AGRADECIMENTOS

Ao meu orientador, Prof. Dr. Rogério Mori, agradeço pela parceria e atenção durante a realização deste trabalho.

Aos membros da banca, Prof. Dr. Emerson Fernandes Marçal e Prof. Dr. Diogo de Prince Mendonça, agradeço pelas diversas contribuições apresentadas.

À minha esposa Claudia e ao nosso filho Jack agradeço pelo carinho, companheirismo e motivação em todos os momentos.

Estendo os agradecimentos a todos que contribuíram com minha formação, conjunto este composto por professores e amigos pelos quais guardo especial sentimento e respeito.

RESUMO

A projeção de indicadores econômicos é um fator importante para a tomada de decisão, seja no setor público, seja no setor privado. Por exemplo, bancos centrais utilizam suas estimativas para monitorar em tempo real o estado da economia e fundamentar suas decisões, enquanto os analistas do mercado financeiro utilizam as projeções para avaliar uma empresa e suas ações. Pensando no aprimoramento dessas projeções, novos modelos e métodos econométricos têm sido desenvolvidos e este trabalho pretende oferecer uma visão geral sobre a teoria e um modelo de amostragem de dados mistos (*MIDAS*, na sigla em inglês). Os modelos *MIDAS* permitem que dados amostrados em frequências diferentes sejam usados na mesma regressão, incorporando as informações dos dados de frequência mais alta na regressão de frequência mais baixa. O modelo proposto utiliza as informações da Pesquisa Industrial Mensal para projetar o próximo resultado do PIB brasileiro. Ao final do trabalho são realizadas avaliações estatísticas entre os resultados das diferentes abordagens *MIDAS*, definindo a que mais se aproxima dos resultados oficiais.

Palavras-chave: projeção. PIB. amostragem de dados mistos. *MIDAS*.

ABSTRACT

The forecast of economic indicators is an important factor for decision making, whether in the public or private sector. For example, central banks use their estimates to monitor the state of the economy in real time and inform their decisions, while financial market analysts use forecasts to evaluate a company and its actions. Thinking about improving these predictions, new models and econometric methods have been developed and this work intends to offer an overview of the theory and a mixed data sampling model MIDAS. MIDAS models allow data sampled at different frequencies to be used in the same regression, incorporating information from higher frequency data into the lower frequency regression. The proposed model uses information from the Monthly Industrial Survey to predict the next Brazilian GDP result. At the end of the work, statistical evaluations are carried out between the results of the different MIDAS approaches, defining the one that is closest to the official results.

Keywords: forecasting. GDP. mixed-data sampling. MIDAS.

LISTA DE FIGURAS

Figura 1 – Gráfico Step Weighting 21
Figura 2 – Gráfico Almon (PDL) Weighting 22
Figura 3 – Gráfico Exponential Almon Weighting 22
Figura 4 – Gráfico Beta Weighting 23
Figura 5 – Gráfico U-MIDAS 24
Figura 6 – Gráfico Auto/GETS 24
Figura 7 – Gráfico Auto/GETS IS 25
Figura 8 – Avaliação gráfica entre projeções 25
Figura 9 – Avaliação gráfica incluindo o IBC-Br 27
Figura 10 – Avaliação gráfica da Auto/GETS IS 29
Figura 11 – Avaliação gráfica do IBC-Br 30

LISTA DE TABELAS

Tabela 1 – Avaliação estatística entre projeções 26
Tabela 2 – Avaliação estatística incluindo o IBC-Br 27

SUMÁRIO

1 INTRODUÇÃO 10

2 REFERENCIAL TEÓRICO 12

3 METODOLOGIA 16

3.1 Dados 16

3.2 Abordagens 17

3.2.1 *Step Weighting* 17

3.2.2 *Almon (PDL) Weighting* 17

3.2.3 *Exponential Almon Weighting* 17

3.2.4 *Beta Weighting* 18

3.2.5 *U-MIDAS* 18

3.2.6 *Auto/GETS* 18

4 RESULTADOS 21

4.1 Avaliação entre projeções 25

4.2 Avaliação incluindo o IBC-Br 26

5 CONCLUSÃO 29

Referências 31

APÊNDICE A – REGRESSÕES 32

1 INTRODUÇÃO

O Produto Interno Bruto (PIB) representa a soma de todos os bens e serviços finais produzidos numa determinada região durante um determinado período. Cada país calcula o seu PIB na sua respectiva moeda e considera apenas os bens e serviços finais, excluindo da conta o consumo de bens intermediários.

O PIB é um dos indicadores mais utilizados na macroeconomia com o objetivo de quantificar a atividade econômica de uma região. Portanto, o PIB não é o total da riqueza existente em um país, mas sim um indicador de fluxo de novos bens e serviços finais produzidos durante um período. Caso um país não produza nada, o PIB para esse determinado período será nulo.

Dada a relevância do PIB, a projeção de indicadores econômicos tornou-se um fator importante na tomada de decisão, tanto no setor público quanto no privado. Governos e empresas utilizam as projeções para determinar estratégias, planos plurianuais e orçamentos para o próximo ano. Os analistas do mercado financeiro utilizam as projeções para avaliar uma empresa e suas ações.

De forma geral, um modelo de projeção de indicadores econômicos envolve a amostra de dados com a mesma frequência de publicação. A ideia de construir modelos que combinem dados de diferentes frequências de amostragem é relativamente nova e tem ampla aplicabilidade em macroeconomia e finanças.

Os chamados modelos de *Nowcasting*[1] podem explorar informações de uma grande quantidade de séries de dados em diferentes frequências e com diferentes atrasos de publicação. Sinais sobre a direção da mudança do PIB podem ser extraídos dessas informações antes que o resultado oficial seja publicado.

Dentre as principais técnicas de *Nowcasting* destaca-se a amostragem de dados mistos (*MIDAS*, na sigla em inglês), que tem por objetivo incorporar os dados de frequência mais alta na regressão de frequência mais baixa. A metodologia começou a ser desenvolvida

[1] O termo é uma contração de “agora“ e “previsão“ e tem origem na meteorologia. Enquanto os meteorologistas conhecem as condições do tempo hoje e precisam prever o futuro, os economistas precisam prever o presente, o futuro próximo ou o passado recente de um indicador econômico.

por Ghysels et al. (2004) mas atualmente existe uma vasta literatura sobre o assunto. Por exemplo, Ghysels et al. (2006), Andreou et al. (2010) e Andreou et al. (2013).

E tendo em vista que a precisão e a confiabilidade das projeções podem ser aprimoradas com o uso de modelos e métodos econométricos adequados, o presente trabalho pretende oferecer uma visão geral sobre a teoria e um modelo *MIDAS* de projeção do PIB brasileiro.

O modelo proposto projeta o crescimento do PIB agregando os dados da Pesquisa Industrial Mensal - Produção Física (PIM-PF), isto é, utiliza dados de uma série temporal mensal para projetar um indicador econômico trimestral. Também são realizadas comparações estatísticas entre os resultados das diferentes abordagens *MIDAS* e, finalmente, é definida a abordagem que mais se aproxima dos resultados oficiais.

2 REFERENCIAL TEÓRICO

Os modelos econométricos normalmente exigem que os dados do regressor possuam a mesma frequência e estrutura da variável dependente. Essa restrição, contudo, nem sempre é atendida na prática, pois as principais publicações ocorrem em frequências anuais, trimestrais, mensais ou até mesmo diárias. Utilizando abordagens *MIDAS*, o trabalho publicado por Ghysels and Marcellino (2018) fornece uma visão geral da teoria e de suas aplicações em tópicos macroeconômicos e financeiros.

Anteriormente, existiam duas principais abordagens para as estimativas que utilizavam dados de frequência mista:

- A abordagem de agregação simples, que envolve a introdução da soma ou média dos dados de frequência mais alta na regressão de frequência mais baixa. Essa abordagem adiciona um único coeficiente para cada variável de alta frequência, aplicando implicitamente uma ponderação igual a cada valor na soma.
- A abordagem de coeficientes individuais, que envolve a adição desses componentes individuais dos dados de alta frequência à regressão, permitindo um coeficiente separado para cada componente de alta frequência. Essa abordagem adiciona um grande número de coeficientes à regressão.

As abordagens *MIDAS* situam-se entre esses dois extremos, permitindo pesos não iguais, mas reduzindo o número de coeficientes por meio de funções que ajustam os parâmetros dos dados de frequência mais alta. Especificamente, o modelo em consideração é:

$$y_t = X_t'\beta + f(\{X_{t/S}^H\}, \theta, \lambda) + \epsilon_t \tag{2.1}$$

Onde:

- y_t é a variável dependente, amostrada em uma frequência baixa, na data t.
- X_t' é o conjunto de regressores amostrados na mesma baixa frequência que y_t.

- $\{X^H_{t/S}\}$ é um conjunto de regressores amostrados em uma frequência mais alta com valores S para cada valor de baixa frequência.
- f é uma função que descreve o efeito dos dados de frequência mais alta na regressão de frequência mais baixa.
- β, λ e θ são vetores de parâmetros estimados.

A abordagem de coeficientes individuais adiciona cada um dos componentes de frequência mais alta como um regressor na regressão de frequência mais baixa. No caso simples em que incluímos apenas dados de alta frequência correspondentes à observação de baixa frequência atual, temos:

$$y_t = X_t'\beta + \sum_{\tau=0}^{S-1} X^H_{(t-\tau)/S}{}'\theta_\tau + \epsilon_t \tag{2.2}$$

Onde:

- $X^H_{(t-\tau)/S}$ são os τ períodos de alta frequência de dados anteriores a t.

Alternativamente, a abordagem de agregação simples adiciona uma soma igualmente ponderada (ou média) dos dados de alta frequência como um regressor na regressão de baixa frequência:

$$y_t = X_t'\beta + \left(\sum_{\tau=0}^{S-1} X^H_{(t-\tau)/S}\right)'\lambda + \epsilon_t \tag{2.3}$$

A abordagem estima um único λ associado ao novo regressor. Visto de forma diferente, a abordagem de agregação simples pode ser pensada como aquela em que as defasagens de maior frequência do componente entram na regressão de baixa frequência com um coeficiente comum λ.

Para uma regressão trimestral com uma série mensal de frequência mais alta, há três meses em cada trimestre, então a abordagem de coeficientes individuais adiciona três regressores à regressão de baixa frequência. O primeiro regressor contém valores para o primeiro mês no trimestre correspondente (janeiro, abril, julho ou outubro), o segundo regressor tem valores para o segundo mês no trimestre correspondente (fevereiro, maio,

agosto ou novembro) e o terceiro regressor contém valores para o terceiro mês do trimestre relevante (março, junho, setembro ou dezembro).

A abordagem de agregação simples adiciona o único regressor contendo a soma dos valores mensais ao longo do trimestre correspondente. Para as observações do primeiro trimestre, o regressor conterá a soma dos valores mensais de janeiro, fevereiro e março de maior frequência para aquele trimestre. Da mesma forma, o regressor conterá a soma dos valores de outubro, novembro e dezembro nas observações do quarto trimestre.

Podemos pensar nessas duas abordagens como sendo dois extremos. A abordagem de agregação simples é parcimoniosa, mas coloca restrições de pesos iguais bastante significativas nos dados defasados de alta frequência. A abordagem de coeficientes individuais oferece a maior flexibilidade, mas requer um grande número de coeficientes e isso, em certos casos, é uma desvantagem pois satura-se rapidamente a equação com muitos regressores (maldição da dimensionalidade).

Em contrapartida, as abordagens *MIDAS* oferecem funções de ponderação que ocupam o meio-termo entre as abordagens tradicionais citadas. Essas funções de ponderação reduzem o número de parâmetros do modelo, colocando restrições sobre os efeitos das defasagens das variáveis de alta frequência.

Modelos semelhantes têm sido aplicados principalmente em bancos centrais, que usam as estimativas para monitorar o estado da economia em tempo real como uma *proxy* para as medidas oficiais. O trabalho de Armesto et al. (2010) do *Federal Reserve Bank of St. Louis* mostra um exemplo de aplicação, projetando taxas trimestrais do PIB utilizando dados mensais de crescimento do emprego.

Dentre as principais aplicações podemos citar o modelo do *Federal Reserve Bank of Atlanta*, denominado *GDPNow*[2], que foi construído agregando projeções de 13 subcomponentes que compõem o PIB dos Estados Unidos. O modelo não é considerado uma projeção oficial, é melhor visto como uma estimativa em execução do crescimento real do PIB com base nos dados econômicos disponíveis para o trimestre atual.

À medida que mais dados de fontes mensais se tornam disponíveis, a projeção do *GDPNow* para um determinado trimestre evolui e geralmente se torna mais precisa. Não são feitos ajustes subjetivos no *GDPNow*, a estimativa é baseada exclusivamente nos

[2] `https://www.atlantafed.org/cqer/research/gdpnow`

resultados matemáticos do modelo.

Outro exemplo de aplicação é o modelo do *Federal Reserve Bank of New York*, que também publica uma projeção do PIB dos Estados Unidos, denominada *Nowcast Report*[3], mas com uma metodologia diferente da utilizada pelo *Federal Reserve Bank of Atlanta*.

Enquanto o *GDPNow* utiliza informações de 13 subcomponentes do PIB, o *Nowcast Report* utiliza uma estrutura de *big data* que captura as características da dinâmica dos dados macroeconômicos, analisando informações como notícias, imitando a maneira como os mercados financeiros utilizam as tecnologias de processamento de linguagem natural.

[3] `https://www.newyorkfed.org/research/policy/nowcast`

3 METODOLOGIA

As séries temporais utilizadas no modelo abrangem o período amostral de janeiro de 2002 (data em que a série atual da PIM-PF foi reformulada) a dezembro de 2021.

3.1 DADOS

O Sistema IBGE de Recuperação Automática (SIDRA) é o repositório das principais informações utilizadas no trabalho. O objetivo do SIDRA é armazenar tabelas contendo os dados agregados das pesquisas que o IBGE realiza. Um dado agregado pode ser obtido, por exemplo, através do somatório dos valores de quesitos contidos em um questionário respondido pelos informantes da pesquisa, e está associado às unidades de um nível territorial, a um período de tempo e, muitas vezes, a um conjunto de classificações que o qualificam. Pode ser obtido também através de cálculos estatísticos, como no caso dos indicadores econômicos.

O Sistema de Contas Nacionais Trimestrais apresenta os valores correntes e os índices de volume (1995 = 100) para o Produto Interno Bruto a preços de mercado. A série é ajustada sazonalmente, possibilitando o cálculo das taxas de variação em relação ao trimestre imediatamente anterior.

A Pesquisa Industrial Mensal - Produção Física produz indicadores de curto prazo desde a década de 1970 relativos ao comportamento do produto real das indústrias extrativa e de transformação. O principal objetivo do índice é servir como uma medida aproximada da evolução de curto prazo do valor adicionado da indústria, dado um determinado período de referência. A PIM-PF fornece a variação percentual da indústria geral em relação ao mês imediatamente anterior com ajuste sazonal.

O Índice de Atividade Econômica do Banco Central (IBC-Br) tem como objetivo mensurar a evolução contemporânea da atividade econômica do país e contribuir para a elaboração de estratégia de política monetária. A construção do IBC-Br foi motivada pela inexistência de indicador agregado de atividade econômica de frequência mensal que permitisse sintetizar e avaliar, em maior frequência, o estado da economia, em contexto de

decisões de política monetária.

3.2 ABORDAGENS

As abordagens foram implementadas na versão 12 do *software EViews*, que possui ferramentas integradas para trabalhos com dados amostrados em diferentes frequências.

3.2.1 *STEP WEIGHTING*

O método de ponderação mais simples emprega uma função degrau. Nesta abordagem, os coeficientes dos dados de alta frequência são restritos pela função, com atrasos de alta frequência dentro de um determinado degrau η.

Dessa forma, o número de coeficientes de alta frequência do modelo aumenta com o número de defasagens de alta frequência, mas em comparação com uma abordagem de coeficiente individual, o número de coeficientes é reduzido por um fator de aproximadamente $1/\eta$.

3.2.2 *ALMON (PDL) WEIGHTING*

A ponderação de defasagem *Almon* (também chamada de defasagem distribuída polinomial ou *PDL*, na sigla em inglês) é amplamente usada para colocar restrições nos coeficientes de defasagem em modelos autorregressivos e é uma candidata natural para a ponderação de frequência mista.

Para cada defasagem de alta frequência os coeficientes da regressão são modelados como um polinômio de defasagem dimensional. É importante ressaltar que o número de coeficientes a serem estimados depende da ordem polinomial e não do número de defasagens de alta frequência.

3.2.3 *EXPONENTIAL ALMON WEIGHTING*

Um método alternativo à ponderação de defasagem *Almon* é a Ponderação Exponencial *Almon*, que restringe o número de polinômios à segunda ordem mas inclui pesos exponenciais. Os pesos podem diminuir lentamente ou rapidamente com a defasagem e

essa taxa de declínio determina quantas defasagens serão incluídas na regressão. Este modelo é conhecido por ser bastante flexível e altamente não linear.

3.2.4 *BETA WEIGHTING*

A ponderação beta foi introduzida por Ghysels et al. (2007) e é baseada na função de ponderação beta normalizada. A função beta também é extremamente flexível e não linear, podendo assumir várias formas, incluindo aumento ou diminuição gradual, plana, curvada ou em forma de U, dependendo dos valores dos parâmetros.

3.2.5 *U-MIDAS*

A abordagem *Unrestricted MIDAS* adiciona cada um dos componentes de frequência mais alta como um regressor na regressão de frequência mais baixa. Isto é, o método de ponderação é simplesmente a técnica de coeficientes individuais citada anteriormente. Em contraste com outros métodos, não há restrições no polinômio de latência implícito na regressão de baixa frequência.

Embora extremamente flexível, o *U-MIDAS* requer uma estimativa de um grande número de coeficientes. Assim, essa abordagem não minimiza o problema de exigir um grande número de coeficientes, mas pode ser usada em casos onde um pequeno número de defasagens é necessário e é frequentemente usado para fins comparativos.

3.2.6 *AUTO/GETS*

O esquema de ponderação *Auto/GETS* é uma extensão do *U-MIDAS* que usa um algoritmo de seleção de variável para reduzir o número de coeficientes individuais, excluindo defasagens individuais que não são estatisticamente relevantes.

A abordagem *Auto/GETS* também permite testar a inclusão de variáveis indicadoras, tais como indicadoras de impulso, indicadoras de degrau e indicadoras de tendência. E nesses casos, denominaremos de *Auto/GETS IS* (*Indicator Saturation* em inglês).

Tradicionalmente, a análise de *outliers* e quebras estruturais na análise de regressão é realizada testando-se a significância estatística de um conjunto de variáveis indicadoras relacionadas. Mais recentemente, os avanços no poder de computação e o desenvolvimento

da modelagem *General-to-Specific* (*GETS*) permitem o teste de indicadores em cada observação da amostra.

Em vez de usar um esquema de ponderação para reduzir o número de variáveis, o problema da dimensionalidade é controlado por meio do algoritmo de seleção de variável, que determina quais das variáveis de alta frequência serão incluídas na regressão.

O algoritmo segue as etapas sugeridas por Sucarrat and Escribano (2011), que por sua vez se baseia no trabalho de Hoover and Perez (1999). As referidas etapas são:

1. O Modelo Geral Irrestrito (*GUM*, na sigla em inglês) com todas as variáveis de pesquisa é estimado e analisado com um conjunto de testes de diagnóstico.

2. Vários caminhos de pesquisa são definidos, um para cada variável de pesquisa insignificante no *GUM*.

3. Para cada caminho, a variável insignificante definida no item 2 é removida e, em seguida, uma série de outras etapas de remoção de variável é realizada, cada vez removendo a variável mais insignificante, e cada vez verificando se o modelo atual passa no conjunto de testes de diagnóstico. Se os testes de diagnóstico falharem após a remoção de uma variável, essa variável será colocada de volta no modelo e impedida de ser removida novamente ao longo deste caminho. A remoção de variável termina quando não houver mais variáveis insignificantes, ou seja, quando não for possível remover uma variável sem falhar nos testes de diagnóstico.

4. Uma vez que todos os caminhos foram calculados, os modelos finais produzidos pelos caminhos são comparados usando uma seleção de critérios de informação. O melhor modelo é então selecionado.

Para o conjunto de testes de diagnóstico realizados no *GUM* e em cada caminho, o algoritmo inclui:

- Teste *AR-LM*, que é um teste de estatística Q sobre os resíduos de nível na significância e número de defasagens especificados.

- Teste *ARCH-LM*, que é um teste de estatística Q nos residuais quadrados na significância e número de defasagens especificados.

- Teste de normalidade *Jarque-Bera*.
- Teste Abrangente Parcimonioso (*PET*, na sigla em inglês) para modelos diferentes do *GUM*.
- Teste F da significância geral dos regressores removidos em comparação com o *GUM*.

O algoritmo permite casos em que há mais variáveis de pesquisa do que observações na amostra, que é uma situação normalmente impossível devido à singularidade da matriz do regressor. Nesses casos, o algoritmo é dividido em blocos, sendo que cada bloco tem seu próprio *GUM* com um subconjunto dos regressores de pesquisa. O algoritmo funciona em cada bloco individualmente e, em seguida, combina as variáveis selecionadas individualmente de cada bloco em um novo *GUM* e é executado mais uma vez.

4 RESULTADOS

A seguir serão apresentados os principais resultados das regressões realizadas e no Apêndice A estão as tabelas com as informações completas. No geral, as regressões utilizaram uma amostra ajustada que compreende o período que vai do quarto trimestre de 2002 ao terceiro trimestre de 2021, totalizando 76 observações, e foram analisadas as doze primeiras defasagens de alta frequência e a primeira defasagem baixa frequência.

A regressão *Step Weighting* utilizou uma função degrau de comprimento 3, isto é, cada grupo de 3 *lags* subsequentes possui o mesmo valor para o coeficiente. O valor projetado para a variação do PIB do quarto trimestre de 2021 foi 0,28%, conforme mostra a Figura 1.

Figura 1 – Gráfico Step Weighting

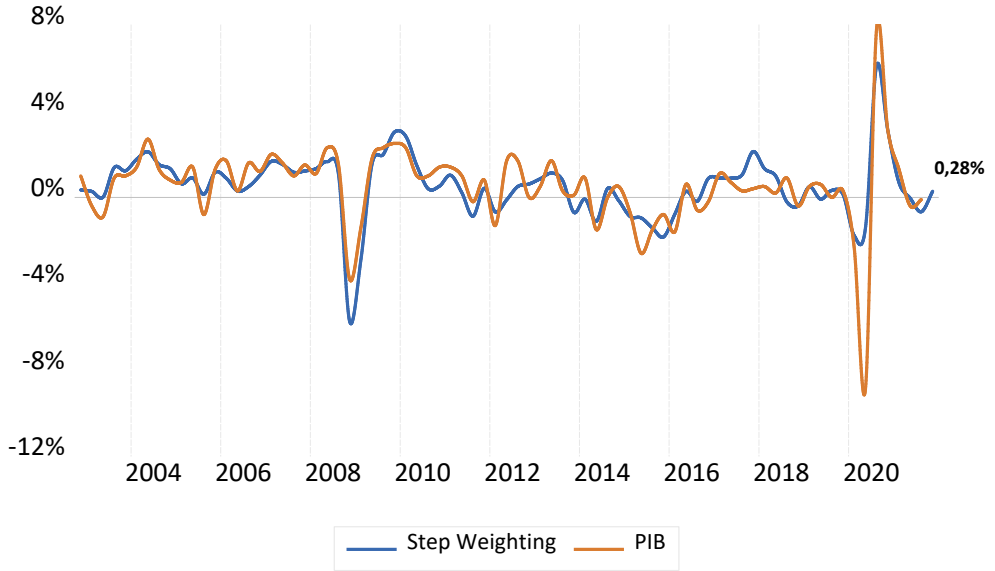

Fonte: Elaboração própria

A regressão *Almon (PDL) Weighting* utilizou um polinômio de grau 3. O valor projetado para a variação do PIB do quarto trimestre de 2021 foi 0,17%, conforme mostra Figura 2.

Figura 2 – Gráfico Almon (PDL) Weighting

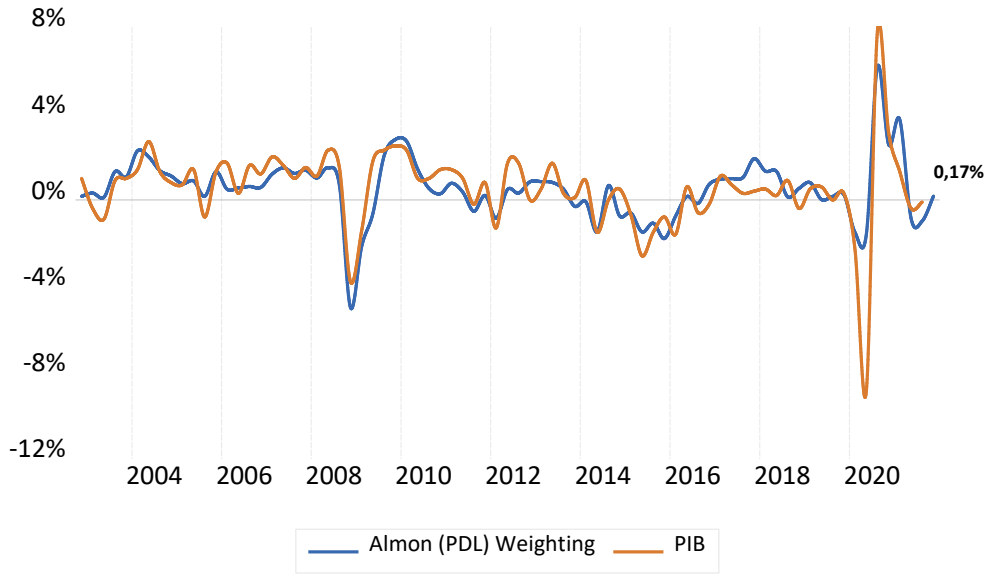

Fonte: Elaboração própria

A regressão *Exponential Almon Weighting* alcançou a convergência após 4 iterações. O valor projetado para a variação do PIB do quarto trimestre de 2021 foi 0,88%, conforme mostra a Figura 3.

Figura 3 – Gráfico Exponential Almon Weighting

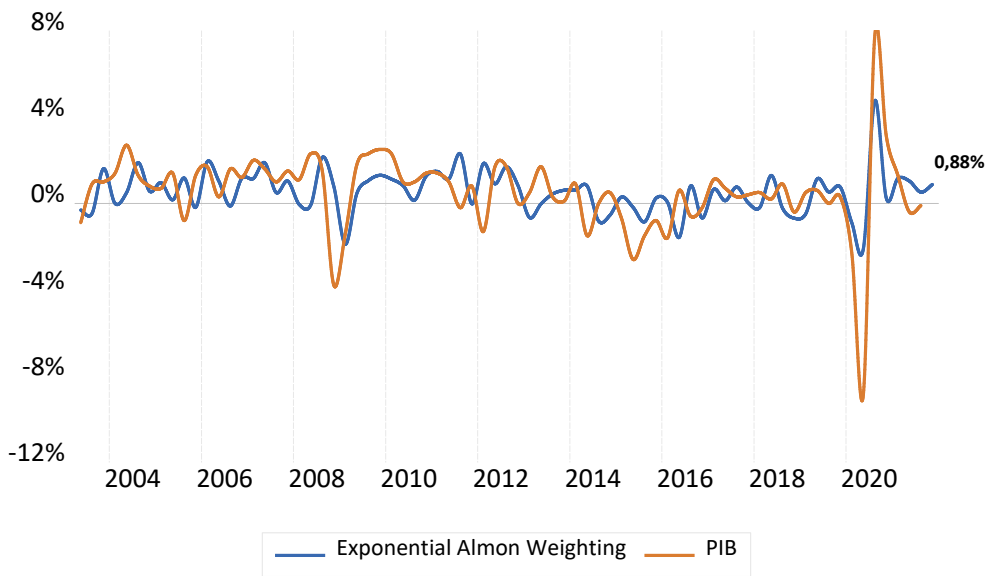

Fonte: Elaboração própria

A regressão *Beta Weighting* alcançou a convergência após 6 iterações. O valor projetado para a variação do PIB do quarto trimestre de 2021 foi -0,26%, conforme mostra a Figura 4.

Figura 4 – Gráfico Beta Weighting

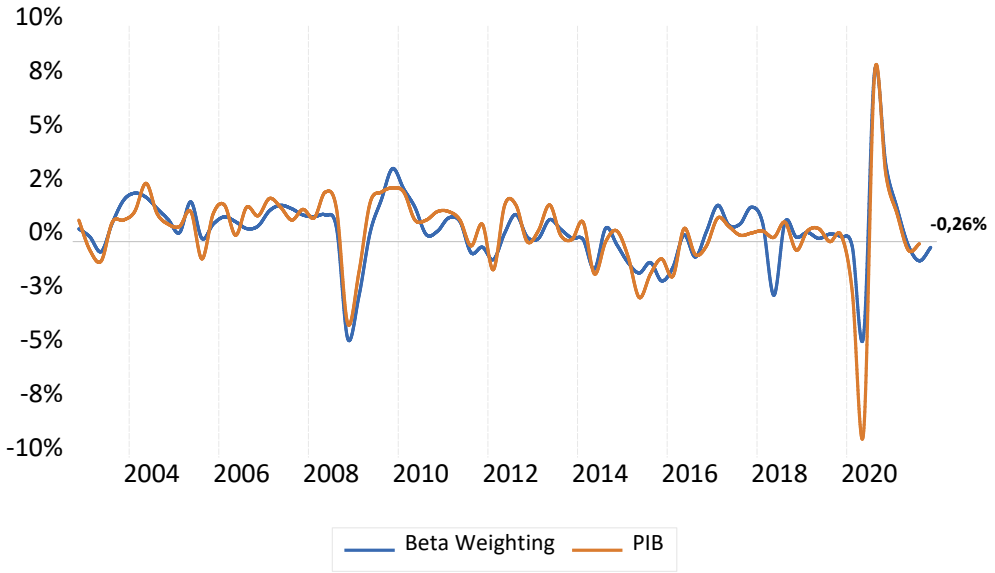

Fonte: Elaboração própria

O valor projetado pela abordagem *U-MIDAS* para a variação do PIB do quarto trimestre de 2021 foi 0,19%, conforme mostra a Figura 5.

Figura 5 – Gráfico U-MIDAS

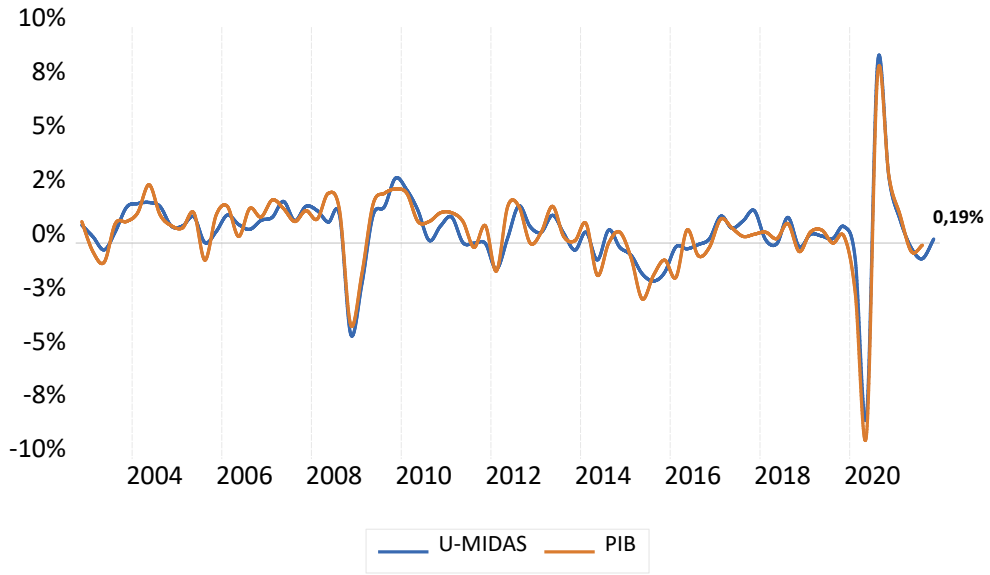

Fonte: Elaboração própria

O valor projetado pela abordagem *Auto/GETS* para a variação do PIB do quarto trimestre de 2021 foi 0,25%, conforme mostra a Figura 6.

Figura 6 – Gráfico Auto/GETS

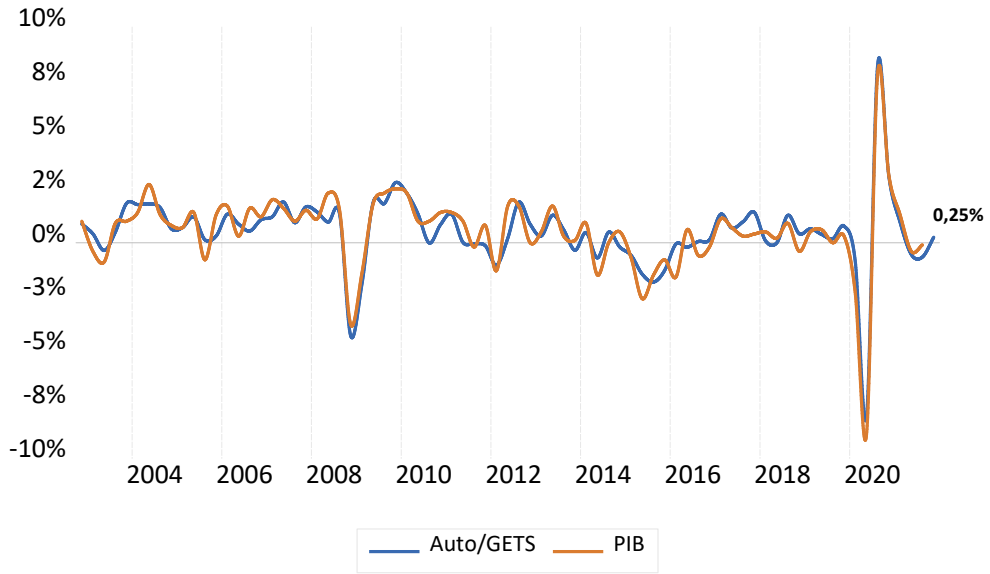

Fonte: Elaboração própria

O valor projetado pela abordagem *Auto/GETS IS*, que inclui a análise de variáveis

indicadoras de saturação, para a variação do PIB do quarto trimestre de 2021 foi 1,10%, conforme mostra a Figura 7.

Figura 7 – Gráfico Auto/GETS IS

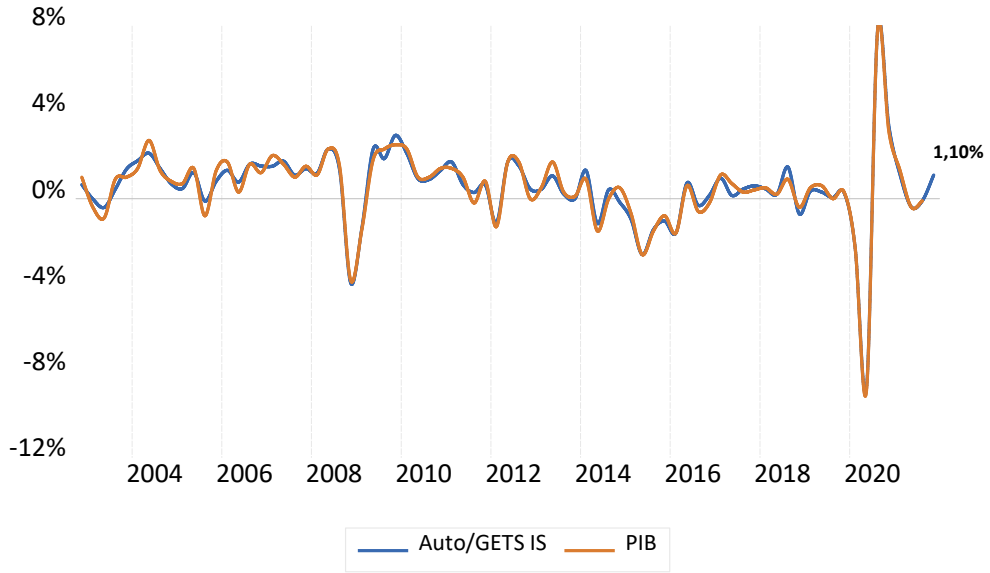

Fonte: Elaboração própria

4.1 AVALIAÇÃO ENTRE PROJEÇÕES

Analisando todas as séries em apenas um gráfico, é possível perceber que a regressão *Exponential Almon Weighting* foi a que mais se distanciou do resultados oficiais do PIB, conforme mostra a Figura 8.

Figura 8 – Avaliação gráfica entre projeções

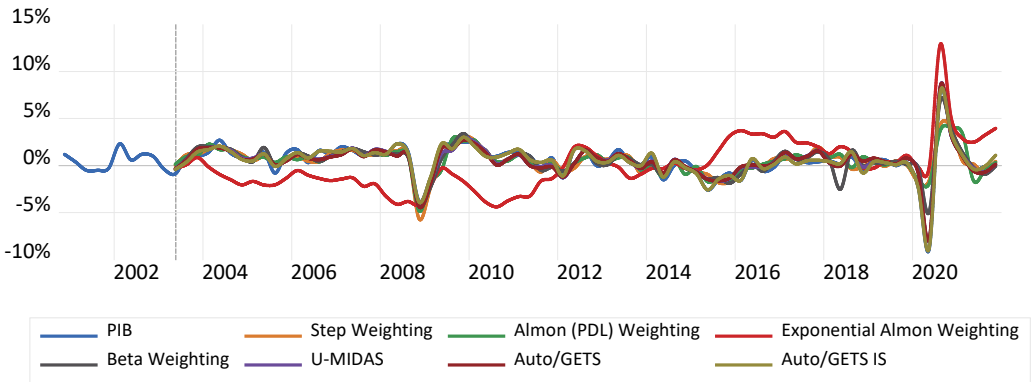

Fonte: Elaboração própria

Ao contrário da avaliação gráfica, da avaliação estatística conseguimos obter análises comparativas mais detalhadas entre as séries temporais projetadas. A Tabela 1 mostra os resultados de indicadores de medida da distância entre o valor real do PIB e os valores projetados de cada abordagem. Neste caso, quanto menor o valor do indicador, melhor a precisão da projeção.

Tabela 1 – Avaliação estatística entre projeções

Forecast Evaluation
Date: 02/19/22 Time: 16:25
Sample: 2003Q2 2021Q4
Included observations: 75
Evaluation sample: 2003Q2 2021Q4
Number of forecasts: 7

Evaluation statistics

Forecast	RMSE[4]	MAE[5]	SMAPE[6]	Theil U[7]
Step Weighting	0.011807	0.007253	82.80623	0.344864
Almon (PDL) Weighting	0.012343	0.007965	85.27721	0.363931
Exponential Almon Weighting	0.029846	0.024227	157.8733	0.653602
Beta Weighting	0.008645	0.006199	73.34842	0.239095
U-MIDAS	0.006151	0.004957	69.98433	0.163478
Auto/GETS	0.006285	0.005011	71.97920	0.167410
Auto/GETS IS	0.003186	0.002508	42.89580	0.082914

Fonte: Elaboração própria

A regressão *Exponential Almon Weighting* foi a que obteve os piores resultados, ratificando a avaliação gráfica, e a *Auto/GETS IS* obteve os melhores.

4.2 AVALIAÇÃO INCLUINDO O IBC-BR

Por se tratar de indicador agregado de atividade, a taxa de crescimento do IBC-Br é frequentemente comparada à do PIB. E por ser frequentemente comparado ao PIB, o IBC-Br torna-se um candidato natural para comparações com os resultados das projeções.

[4]RMSE é o erro quadrático médio.
[5]MAE é erro médio absoluto.
[6]SMAPE é o erro percentual médio absoluto simétrico.
[7]Theil U é coeficiente de desigualdade de Theil.

O índice tem frequência mensal, mas foi transformado em taxas de crescimento trimestrais para fins comparativos, conforme mostra a Figura 9.

Figura 9 – Avaliação gráfica incluindo o IBC-Br

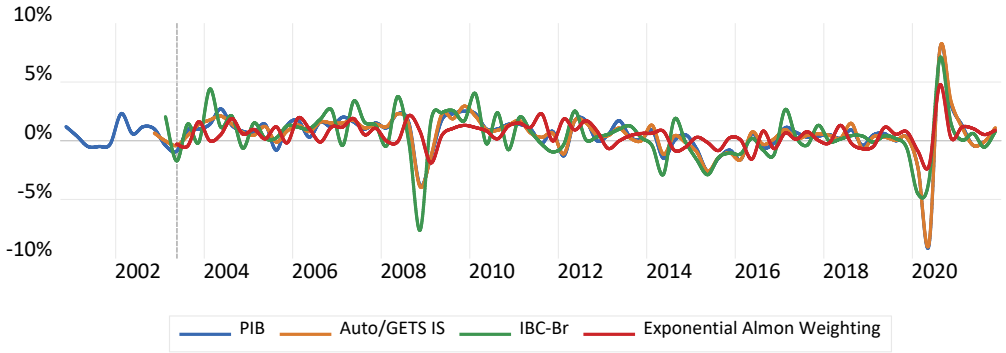

Fonte: Elaboração própria

Também foram realizados testes estatísticos, desta vez envolvendo o IBC-Br e as regressões que obtiveram os melhores e os piores resultados das avaliações. Os resultados das avaliações são mostrados na Tabela 2.

Tabela 2 – Avaliação estatística incluindo o IBC-Br

Forecast Evaluation
Date: 02/19/22 Time: 16:42
Sample: 2003Q2 2021Q4
Included observations: 75
Evaluation sample: 2003Q2 2021Q4
Number of forecasts: 3

Evaluation statistics

Forecast	RMSE	MAE	SMAPE	Theil U
Exponential Almon Weighting	0.015569	0.011231	120.1178	0.505264
IBC-Br	0.013867	0.010436	103.3109	0.347351
Auto/GETS IS	0.003051	0.002389	41.99287	0.079352

Fonte: Elaboração própria

Devido às particularidades do cálculo do IBC-Br e das estimativas do PIB, as comparações com as projeções dos modelos seriam mais próximas se realizadas em horizontes mais longos (anuais) porque são mais apropriadas do que em horizontes mais

curtos (trimestrais), de acordo com o Comitê de Política Monetária (2018). Ainda assim, o IBC-Br como projeção do PIB obteve resultados intermediários, situando-se entre a regressão *Exponential Almon Weighting* e a *Auto/GETS IS*.

5 CONCLUSÃO

Em geral, há um consenso de que a exploração de dados em diferentes frequências é importante para projeções de curto prazo, mas há desacordo sobre qual seria a abordagem preferida para modelagem usando dados de frequência mista. A escolha do modelo deve ser baseada na aplicação empírica específica.

No entanto, qualquer um dos modelos de dados de frequência mista é, em geral, melhor do que o uso de dados agregados temporalmente, pois permite explorar em tempo hábil toda a informação disponível.

No caso em estudo, que é a projeção do PIB brasileiro utilizando a Pesquisa Industrial Mensal, a regressão *MIDAS* que apresentou os melhores resultados foi a *Auto/GETS IS*, superando o IBC-Br como projeção do PIB, conforme mostram as Figuras 10 e 11.

Figura 10 – Avaliação gráfica da Auto/GETS IS

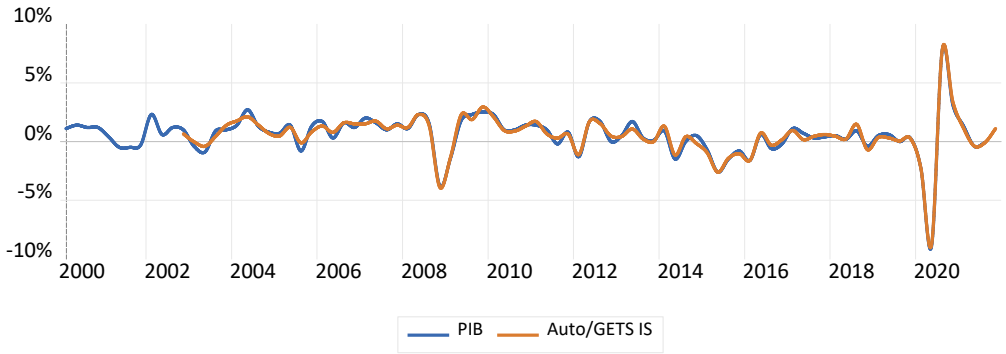

Fonte: Elaboração própria

Figura 11 – Avaliação gráfica do IBC-Br

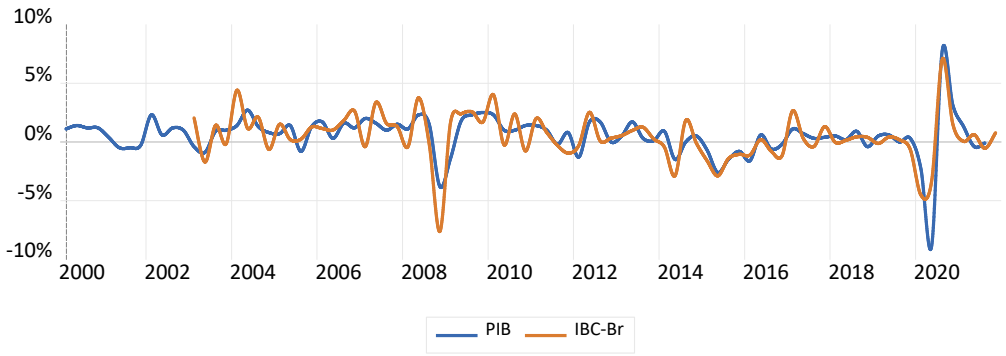

Fonte: Elaboração própria

Ainda que o IBC-Br e o PIB sejam indicadores agregados de atividade econômica com trajetórias similares no médio prazo, existem características que os diferenciam tanto do ponto de vista conceitual quanto metodológico: o IBC-Br, de frequência mensal, permite acompanhamento mais tempestivo da evolução da atividade econômica, enquanto o PIB, de frequência trimestral, descreve quadro mais abrangente da economia. Além disso, o processo de dessazonalização pode contribuir para ampliar as diferenças pontuais entre os dois indicadores, ensejando cautela em comparações nos horizontes mais curtos.

REFERÊNCIAS

Andreou, E., E. Ghysels, and A. Kourtellos (2010). Regression models with mixed sampling frequencies. *Journal of Econometrics 158*(2), 246–261.

Andreou, E., E. Ghysels, and A. Kourtellos (2013). Should macroeconomic forecasters use daily financial data and how? *Journal of Business & Economic Statistics 31*(2), 240–251.

Armesto, M. T., K. M. Engemann, M. T. Owyang, et al. (2010). Forecasting with mixed frequencies. *Federal Reserve Bank of St. Louis Review 92*(6), 521–36.

Comitê de Política Monetária, C. (2018). *Relatório de inflação*, Volume 20. Banco Central do Brasil.

Ghysels, E. and M. Marcellino (2018). *Applied Economic Forecasting Using Time Series Methods*. Oxford University Press.

Ghysels, E., P. Santa-Clara, and R. Valkanov (2004). The midas touch: Mixed data sampling regression models.

Ghysels, E., P. Santa-Clara, and R. Valkanov (2006). Predicting volatility: getting the most out of return data sampled at different frequencies. *Journal of Econometrics 131*(1-2), 59–95.

Ghysels, E., A. Sinko, and R. Valkanov (2007). Midas regressions: Further results and new directions. *Econometric reviews 26*(1), 53–90.

Hoover, K. D. and S. J. Perez (1999). Data mining reconsidered: encompassing and the general-to-specific approach to specification search. *The econometrics journal 2*(2), 167–191.

Sucarrat, G. and A. Escribano (2011). Automated model selection in finance: General-to-specific modelling of the mean and volatility specifications. In *Working paper, Department of Economics*. Citeseer.

APÊNDICE A – REGRESSÕES

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 10:31
Sample (adjusted): 2002Q4 2021Q3
Included observations: 76 after adjustments
Method: Step (3 steps)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.004809	0.001452	3.312032	0.0015
PIB(-1)	−0.242138	0.118218	−2.048239	0.0443
Page: MONTHLY Series: PIM Lags: 12				
STEP01	0.315790	0.037598	8.399152	0.0000
STEP02	0.299272	0.052850	5.662629	0.0000
STEP03	0.101280	0.044229	2.289897	0.0250
STEP04	0.054965	0.037108	1.481224	0.1430

R-squared	0.622649	Mean dependent var	0.005145
Adjusted R-squared	0.595695	S.D. dependent var	0.018541
S.E. of regression	0.011789	Akaike info criterion	−5.967565
Sum squared resid	0.009729	Schwarz criterion	−5.783560
Log likelihood	232.7675	Hannan-Quinn criter.	−5.894028
Durbin-Watson stat	2.030020		

MONTHLY\PIM	Lag	Coefficient	Distribution
	0	0.315790	*
	1	0.315790	*
	2	0.315790	*
	3	0.299272	*
	4	0.299272	*
	5	0.299272	*
	6	0.101280	*
	7	0.101280	*
	8	0.101280	*
	9	0.054965	*
	10	0.054965	*
	11	0.054965	*

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 10:42
Sample (adjusted): 2002Q4 2021Q3
Included observations: 76 after adjustments
Method: PDL/Almon (polynomial degree: 3)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.005315	0.001477	3.598254	0.0006
PIB(-1)	−0.352513	0.111139	−3.171824	0.0022
Page: MONTHLY Series: PIM Lags: 12				
PDL01	0.245787	0.061002	4.029190	0.0001
PDL02	0.030503	0.024204	1.260267	0.2117
PDL03	−0.004567	0.001819	−2.510132	0.0143

R-squared	0.596472	Mean dependent var	0.005145
Adjusted R-squared	0.573738	S.D. dependent var	0.018541
S.E. of regression	0.012105	Akaike info criterion	−5.926811
Sum squared resid	0.010404	Schwarz criterion	−5.773474
Log likelihood	230.2188	Hannan-Quinn criter.	−5.865530
Durbin-Watson stat	1.993951		

MONTHLY\PIM	Lag	Coefficient	Distribution
	0	0.271724	*
	1	0.288526	*
	2	0.296195	*
	3	0.294730	*
	4	0.284131	*
	5	0.264398	*
	6	0.235532	*
	7	0.197531	*
	8	0.150397	*
	9	0.094129	*
	10	0.028727	*
	11	−0.045809	*

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 10:45
Sample (adjusted): 2003Q2 2021Q3
Included observations: 74 after adjustments
Method: Exp-Almon
Optimization method: initial OPG iterations followed by BFGS
Coefficient covariance computed using observed Hessian
Convergence achieved after 4 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.000840	0.002104	0.398994	0.6911
PIB(-1)	0.929189	0.201222	4.617738	0.0000
Page: MONTHLY Series: PIM(-5) Lags: 12				
SLOPE	−1.057763	0.391048	−2.704946	0.0086
EXPPDL01	−1.270517	0.542080	−2.343781	0.0220
EXPPDL02	0.077836	0.042708	1.822505	0.0727

R-squared	0.301397	Mean dependent var	0.005203
Adjusted R-squared	0.260898	S.D. dependent var	0.018754
S.E. of regression	0.016123	Akaike info criterion	−5.351925
Sum squared resid	0.017937	Schwarz criterion	−5.196245
Log likelihood	203.0212	Hannan-Quinn criter.	−5.289822
Durbin-Watson stat	2.123162		

MONTHLY\PIM(-5)	Lag	Coefficient	Distribution
	0	−0.582978	*
	1	−0.206673	*
	2	−0.085610	*
	3	−0.041435	*
	4	−0.023433	*
	5	−0.015484	*
	6	−0.011955	*
	7	−0.010785	*
	8	−0.011369	*
	9	−0.014003	*
	10	−0.020152	*
	11	−0.033886	*

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 10:51
Sample (adjusted): 2002Q4 2021Q3
Included observations: 76 after adjustments
Method: Beta
Optimization method: initial OPG iterations followed by BFGS
Coefficient covariance computed using observed Hessian
Convergence achieved after 6 iterations

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.004647	0.001136	4.090838	0.0001
PIB(-1)	−0.254904	0.085522	−2.980574	0.0040
Page: MONTHLY Series: PIM Lags: 12				
SLOPE	2.397745	0.234666	10.21771	0.0000
BETA01	1.052418	0.018136	58.03065	0.0000
BETA02	2.698389	0.410879	6.567363	0.0000
BETA03	0.018879	0.019814	0.952829	0.3440

R-squared	0.768810	Mean dependent var	0.005145
Adjusted R-squared	0.752297	S.D. dependent var	0.018541
S.E. of regression	0.009228	Akaike info criterion	−6.457501
Sum squared resid	0.005961	Schwarz criterion	−6.273496
Log likelihood	251.3851	Hannan-Quinn criter.	−6.383964
Durbin-Watson stat	1.547896		

MONTHLY\PIM	Lag	Coefficient	Distribution
	0	0.121646	*
	1	0.457365	*
	2	0.401483	*
	3	0.341796	*
	4	0.283623	*
	5	0.229028	*
	6	0.179220	*
	7	0.135118	*
	8	0.097581	*
	9	0.067570	*
	10	0.046407	*
	11	0.036906	*

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 10:54
Sample (adjusted): 2002Q4 2021Q3
Included observations: 76 after adjustments
Method: U-MIDAS

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.003591	0.000952	3.770329	0.0004
PIB(-1)	0.094547	0.126926	0.744898	0.4591
Page: MONTHLY Series: PIM Lags: 12				
LAG1	0.164450	0.029449	5.584303	0.0000
LAG2	0.280915	0.041300	6.801869	0.0000
LAG3	0.517965	0.033959	15.25264	0.0000
LAG4	0.252032	0.035097	7.181007	0.0000
LAG5	0.149377	0.054560	2.737835	0.0081
LAG6	0.032405	0.076414	0.424069	0.6730
LAG7	0.026000	0.044924	0.578755	0.5649
LAG8	0.069284	0.044828	1.545569	0.1273
LAG9	0.030257	0.037547	0.805852	0.4234
LAG10	0.065101	0.030520	2.133079	0.0369
LAG11	0.024592	0.041063	0.598876	0.5514
LAG12	0.027360	0.032885	0.831991	0.4086

R-squared	0.889559	Mean dependent var	0.005145
Adjusted R-squared	0.866402	S.D. dependent var	0.018541
S.E. of regression	0.006777	Akaike info criterion	−6.985732
Sum squared resid	0.002848	Schwarz criterion	−6.556387
Log likelihood	279.4578	Hannan-Quinn criter.	−6.814145
Durbin-Watson stat	2.053647		

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 10:55
Sample (adjusted): 2002Q4 2021Q3
Included observations: 76 after adjustments
Method: Auto/Gets
6 MIDAS terms selected

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.003394	0.000803	4.227589	0.0001
PIB(-1)	0.170261	0.043143	3.946461	0.0002
Page: MONTHLY Series: PIM				
LAG1	0.169429	0.028553	5.933739	0.0000
LAG2	0.281289	0.039872	7.054863	0.0000
LAG3	0.517720	0.030947	16.72943	0.0000
LAG4	0.245353	0.028488	8.612507	0.0000
LAG5	0.132379	0.038075	3.476811	0.0009
LAG10	0.057470	0.027649	2.078540	0.0414

R-squared	0.883861	Mean dependent var	0.005145
Adjusted R-squared	0.871905	S.D. dependent var	0.018541
S.E. of regression	0.006636	Akaike info criterion	−7.093321
Sum squared resid	0.002994	Schwarz criterion	−6.847981
Log likelihood	277.5462	Hannan-Quinn criter.	−6.995271
Durbin-Watson stat	2.164827		

Dependent Variable: PIB
Method: MIDAS
Date: 02/19/22 Time: 11:03
Sample (adjusted): 2002Q4 2021Q3
Included observations: 76 after adjustments
Method: Auto/Gets
9 MIDAS terms selected, 16 indicators selected

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.003570	0.001118	3.193512	0.0025
PIB(-1)	−0.133727	0.063030	−2.121634	0.0390
@ISPERIOD("2008Q2")	0.019731	0.004328	4.559097	0.0000
@ISPERIOD("2012Q2")	0.017055	0.004259	4.004808	0.0002
@ISPERIOD("2015Q2")	−0.012038	0.004102	−2.934703	0.0051
@ISPERIOD("2016Q1")	−0.018969	0.004341	−4.369791	0.0001
@ISPERIOD("2020Q1")	−0.011152	0.004955	−2.250627	0.0289
@AFTER("2008Q3")	0.015295	0.003492	4.380437	0.0001
@AFTER("2010Q3")	0.015933	0.003496	4.557152	0.0000
@TRENDBR("2006Q2")	0.007094	0.001981	3.581712	0.0008
@TRENDBR("2006Q3")	−0.008796	0.002144	−4.101795	0.0002
@TRENDBR("2012Q4")	0.004312	0.000963	4.475573	0.0000
@TRENDBR("2014Q1")	−0.017948	0.004319	−4.156017	0.0001
@TRENDBR("2014Q2")	0.016716	0.004079	4.098366	0.0002
@TRENDBR("2016Q2")	−0.003509	0.001037	−3.382243	0.0014
@TRENDBR("2017Q4")	0.014761	0.003051	4.838267	0.0000
@TRENDBR("2018Q2")	−0.016370	0.003416	−4.791566	0.0000
@TRENDBR("2020Q2")	0.007659	0.001676	4.568821	0.0000
Page: MONTHLY Series: PIM				
LAG1	0.131994	0.021333	6.187212	0.0000
LAG2	0.321171	0.030170	10.64552	0.0000
LAG3	0.525516	0.020587	25.52596	0.0000
LAG4	0.244183	0.019329	12.63270	0.0000
LAG5	0.233450	0.033580	6.952131	0.0000
LAG6	0.160129	0.040042	3.999010	0.0002
LAG8	0.145621	0.028435	5.121230	0.0000
LAG10	0.043573	0.018133	2.402956	0.0201
LAG11	0.078233	0.026839	2.914879	0.0054

R-squared	0.972253	Mean dependent var	0.005145
Adjusted R-squared	0.957530	S.D. dependent var	0.018541
S.E. of regression	0.003821	Akaike info criterion	−8.024977
Sum squared resid	0.000715	Schwarz criterion	−7.196953
Log likelihood	331.9491	Hannan-Quinn criter.	−7.694059
Durbin-Watson stat	2.509615		