

Atas do COPOM como Fonte de Previsão do PIB: Uma Aplicação de Processamento de Linguagem Natural

Daniel Catrib de Azevedo Lemos^{†, a} Sergio Aquino de Souza^{‡, b}

^aUniversidade Federal do Ceará - UFC

^bCAEN/DTE/Universidade Federal do Ceará e Banco Central do Brasil

Resumo Este artigo investiga o potencial de informações textuais extraídas das atas do Comitê de Política Monetária (COPOM) do Banco Central do Brasil para aprimorar a previsão do Produto Interno Bruto (PIB) trimestral. Utilizam-se técnicas de Processamento de Linguagem Natural (PLN), com ênfase em representações vetoriais de palavras (Word2Vec), combinadas a modelos de regressão tradicionais e de aprendizado de máquina. Três estratégias distintas de vetorização textual foram comparadas: texto pré-processado, texto com stemming e embeddings pré-treinados adaptados. Os preditores textuais foram incorporados a modelos preditivos com validação cruzada temporal e janela deslizante, respeitando a causalidade dos dados. Os resultados mostram que modelos como Lasso, Elastic Net, Random Forest e Gradient Boost, alimentados por embeddings derivados de texto pré-processado e texto stemmizado, superam consistentemente modelos tradicionais autorregressivos (AR(2)). Este trabalho contribui para a literatura ao evidenciar o valor preditivo de documentos institucionais e ao propor uma metodologia robusta para incorporar dados textuais em previsões macroeconômicas no contexto brasileiro.

Palavras-chave: Previsão macroeconômica; Processamento de Linguagem Natural (PLN); Word2Vec; Modelos de aprendizado de máquina; Atas do COPOM.

Abstract This paper investigates the potential of textual information extracted from the minutes of the Monetary Policy Committee (COPOM) of the Central Bank of Brazil to improve quarterly Gross Domestic Product (GDP) forecasting. Natural Language Processing (NLP) techniques are employed, focusing on word vector representations (Word2Vec), combined with regularized regression models and machine learning algorithms. Three distinct text vectorization strategies are compared: preprocessed text, stemmed text and adapted pre-trained embeddings. Textual predictors are incorporated into forecasting models using a rolling window and time-series cross-validation, ensuring temporal causality. Results show that models such as Lasso, Elastic Net, Random Forest and Gradient Boost, powered by embeddings derived from pre-processed and stemmed text, consistently outperform traditional autoregressive models (AR(2)). This work contributes to the literature by highlighting the predictive value of institutional documents and proposing a robust methodology for integrating textual data into macroeconomic forecasting in the Brazilian context.

Keywords: Macroeconomic forecast; Natural Language Processing; Word2Vec; Machine Learning Models; COPOM Minutes.

Área ANPEC: Macroeconomia, Economia Monetária e Finanças

Códigos JEL: E37, E47, C53.

[†]dcatrib@gmail.com

[‡]srgdesouz@gmail.com

1. Introdução

A previsão macroeconômica, especialmente do Produto Interno Bruto (PIB), é um pilar para a formulação de políticas e a tomada de decisões no setor público e privado. Tradicionalmente, esses modelos baseiam-se em variáveis macroeconômicas quantitativas. Estas, ao capturarem a dinâmica econômica através de dados numéricos, permitem a construção de cenários e a antecipação de tendências. O avanço do Big Data e os progressos no Processamento de Linguagem Natural (PLN) têm aberto novas e promissoras possibilidades para a incorporação de informações qualitativas. Elementos como o sentimento geral e as preocupações específicas, extraídos de vastos documentos textuais, revelam-se cada vez mais capazes de fornecer sinais antecipados sobre a atividade econômica.

A capacidade de transformar dados textuais em representações numéricas tem impulsionado significativamente o desempenho de modelos preditivos em diversas áreas de pesquisa. Atualmente, a riqueza informacional contida em documentos textuais pode ser quantificada e integrada a modelos preditivos de maneira eficaz, graças às inovações nas técnicas de vetorização. Evidências recentes demonstram o crescente e variado uso dessas informações em múltiplos campos de pesquisa. Conforme [Getzkow et al. \(2019\)](#), a quantidade de texto digital disponível de diversas fontes, como notícias, mídias sociais, documentos financeiros e discursos políticos, vem impulsionando o uso de texto como fonte de dados na pesquisa econômica e em outras ciências, abrangendo desde a previsão de tendências de mercado até a análise de posicionamento político e o estudo do comportamento do consumidor.

Os recentes avanços em modelos de embedding de palavras, como Word2Vec ([Mikolov et al., 2013b](#)), GloVe ([Pennington et al., 2014](#)), entre outros, facilitaram a representação de palavras como vetores informativos, capturando relações semânticas e contextuais. Devido à alta dimensionalidade inerente aos dados textuais, utilizam-se modelos de regularização após a análise textual, visando à seleção de variáveis relevantes ([Getzkow et al., 2019](#); [Lima et al., 2021](#); [Ash e Hansen, 2023](#)). O objetivo principal da regularização é reduzir a complexidade do modelo e prevenir o overfitting ([Elliott e Timmermann, 2013](#); [Athey, 2019](#)).

Em economia, a aplicação dessas técnicas tem-se expandido rapidamente. A análise de texto nos permite ir além do óbvio para entender não apenas o sentimento do consumidor e do mercado, mas também para decifrar posicionamentos ideológicos, percepções de risco e até mesmo vieses implícitos que influenciam decisões econômicas e sociais. O artigo de [Ash e Hansen \(2023\)](#) oferece uma visão abrangente sobre os métodos empregados na análise algorítmica de texto dentro do campo da economia. Além disso, explora as questões computacionais e de escalabilidade inerentes à manipulação de grandes volumes de dados textuais, sublinhando a relevância de algoritmos eficientes para extrair informações semânticas e contextuais valiosas. Alguns trabalhos têm empregado a análise textual para extrair informações sobre vieses ideológico. [Groseclose e Milyo \(2005\)](#) e [Gentzkow e Shapiro \(2010\)](#), por exemplo, aplicaram essa técnica em veículos de comunicação. Outro estudo, [Ash et al. \(2024\)](#), utilizou a análise textual para investigar a influência de atitudes de gênero no sistema judiciário dos EUA.

No contexto deste artigo, [Bana \(2022\)](#) propõe um modelo inovador de Processamento de Linguagem Natural (NLP) para prever o salário associado a anúncios de emprego a partir de seu conteúdo textual, utilizando Word2Vec. [Lima et al. \(2021\)](#) apresentou uma nova metodologia destinada a extrair informação preditiva das atas do Federal Reserve (FED), construindo um dicionário que varia ao longo do tempo. Afastando-se das abordagens tradicionais que empregam um conjunto fixo de palavras, os autores utilizam aprendizado de máquina supervisionado para identificar dinamicamente os termos mais preditivos dentro das atas, gerando novos preditores para a previsão macroeconômica. [Araujo et al. \(2025\)](#) utiliza documentos de comunicação do Banco Central Europeu para melhorar a previsão da inflação, propondo uma abordagem de processamento de texto que utiliza Continuous Bag of Words (CBOW) do Word2Vec, que é treinada para prever uma palavra-alvo com base em seu contexto circundante.

Neste artigo propõe-se uma metodologia que utiliza a vetorização de documentos textuais para prever o crescimento do PIB trimestral brasileiro. Este estudo sugere e avalia a utilização de preditores textuais, derivados de atas de reuniões do Comitê de Política Monetária (COPOM) do Banco Central do Brasil, em modelos de previsão do crescimento. Argumenta-se que a linguagem utilizada nesses documentos pode

refletir as percepções e expectativas dos formuladores de política sobre o estado atual e futuro da economia, oferecendo um poderoso complemento aos indicadores econômicos tradicionais. Para tanto, emprega-se uma metodologia rigorosa de validação temporal e compara-se a performance de diversos modelos preditivos.

É importante destacar que o objetivo principal e a contribuição deste trabalho não consistem em identificar o melhor modelo preditivo para o crescimento do produto. Em vez disso, o foco está em evidenciar a relevância e o poder preditivo das atas do Comitê de Política Monetária do Banco Central, em comparação a um modelo tradicional da literatura (AR(2)). Essas atas contêm linguagem técnica, detalhes e discussões aprofundadas sobre o cenário macroeconômico e as perspectivas futuras, sendo uma fonte rica de informação qualitativa, com grande potencial para aprimorar os modelos preditivos tradicionais.

Foram utilizadas diferentes estratégias de pré-processamento e "embeddings" pré-treinados, permitindo avaliar a capacidade de cada abordagem em extrair os sinais econômicos mais relevantes e, em última instância, aprimorar a acurácia da previsão do PIB. Os resultados deste trabalho não apenas contribuem para a literatura sobre previsão econômica baseada em texto no contexto brasileiro, mas também oferecem perspectivas valiosas sobre a metodologia mais eficaz para transformar dados textuais complexos em indicadores preditivos.

O restante deste artigo está organizado da seguinte forma: a Seção 2 descreve a metodologia de preparação dos dados, a extração de preditores textuais e a estrutura dos modelos de previsão. A Seção 3 apresenta os resultados da avaliação dos modelos. Finalmente, a Seção 4 conclui o estudo e sugere direções para pesquisas futuras.

2. Metodologia

A metodologia empregada neste estudo envolve o tratamento e vetorização dos dados com o modelo Skip-gram, a aplicação de modelos preditivos de aprendizado de máquina, a definição de métricas de avaliação, a análise de um modelo variante no tempo e o uso de validação cruzada adaptada à série temporal.

2.1 Dados, pré-processamento e vetorização

Neste estudo foram utilizados três modelos distintos de representação textual para a incorporação de informações das atas das reuniões do COPOM, no período de 2003 a 2025, utilizados na previsão do PIB trimestral calculado pelo Instituto Brasileiro de Geografia e Estatística (IBGE). Apesar de se dispor de dados desde janeiro de 2000, optou-se por iniciar a base de dados a partir da ata de abril de 2003. Essa decisão se deve à padronização das atas a partir dessa data, o que simplifica significativamente as etapas de pré-processamento e garante maior consistência na qualidade dos dados textuais.

A variável dependente utilizada neste estudo é a variação do PIB trimestral, calculada a partir dos dados do Instituto Brasileiro de Geografia e Estatística (IBGE) no período de 2003Q2 a 2025Q1. Adota-se o padrão da literatura (Stock e Watson, 2007; Diebold e Shin, 2018; Lima et al., 2021) e calcula-se a variação logarítmica anualizada, dada por $400 \times \ln(Y_t/Y_{t-1})$.

Para garantir a compatibilidade entre a frequência dos dados PIB, que é trimestral, e a periodicidade das reuniões do COPOM, que são realizadas a cada 45 dias atualmente (e com maior frequência no início da série), as atas correspondentes foram agrupadas para se alinhar aos trimestres do PIB (Tabela 1). Essa abordagem é inerente a contextos de "nowcasting" e previsão de curto prazo, permitindo a integração de dados de diferentes níveis de agregação para a análise (Gentzkow e Shapiro, 2010; Gentzkow et al., 2019; Lima et al., 2021; Ash et al., 2024). As atas de maio e junho de 2003, por exemplo, foram agrupadas e atribuídas ao segundo trimestre do mesmo ano (2003Q2).

Tabela 1
Agregação das Reuniões do COPOM por Trimestre (8 primeiras agregações)

TRIMESTRE	REUNIÕES	MÊS
2003Q2	84 ^a e 85 ^a Reuniões	Maio e Junho
2003Q3	86 ^a , 87 ^a e 88 ^a Reuniões	Julho, Agosto e Setembro
2003Q4	89 ^a , 90 ^a e 91 ^a Reuniões	Outubro, Novembro e Dezembro
2004Q1	92 ^a , 93 ^a e 94 ^a Reuniões	Janeiro, Fevereiro e Março
2004Q2	95 ^a , 96 ^a e 97 ^a Reuniões	Abril, Maio e Junho
2004Q3	98 ^a , 99 ^a e 100 ^a Reuniões	Julho, Agosto e Setembro
2004Q4	101 ^a , 102 ^a e 103 ^a Reuniões	Outubro, Novembro e Dezembro
2005Q1	104 ^a , 105 ^a e 106 ^a Reuniões	Janeiro, Fevereiro e Março

Nesse processo de agregação, todos os documentos (atas) correspondentes a um determinado período foram concatenados e tratados como uma única unidade textual. Assim, nos trimestres que continham múltiplas atas, o conteúdo integral de cada uma foi unificado. Após essa consolidação, o texto resultante passou por etapas de pré-processamento. Subsequentemente, foram gerados "embeddings" que servem como representações vetoriais densas desses documentos textuais agregados, os quais serão empregados nos modelos de previsão.

O primeiro modelo de representações vetoriais (Modelo 1) utiliza um processo de pré-processamento do texto para reduzir o vocabulário a um conjunto de palavras significativas. No primeiro momento eliminamos os cabeçalhos e nomes próprios. As etapas seguintes incluíram a remoção de "stopwords", hífens, apóstrofes, números e palavras com dois ou menos caracteres. O segundo modelo (Modelo 2) parte da base de texto pré-processado do Modelo 1 e adiciona uma etapa de "stemming". O "stemming" é uma técnica que reduz as palavras aos seus radicais (ou "stems"), agrupando variações morfológicas de uma mesma palavra (Taddy, 2019). Esta etapa visa consolidar o vocabulário e capturar a essência semântica das palavras, independentemente de suas flexões.

As Figuras 1 e 2 apresentam uma representação em nuvem de palavras gerada a partir do corpus das atas das reuniões do COPOM, após a aplicação das etapas de agrupamento e pré-processamento descritas. Esta representação permite uma rápida compreensão do vocabulário mais frequente e, conseqüentemente, dos temas predominantes e das preocupações recorrentes expressas pelos membros do Comitê ao longo do período analisado. Palavras com maior destaque na nuvem indicam maior frequência de ocorrência, refletindo a ênfase em termos relacionados a variáveis macroeconômicas, decisões de política monetária e análises de cenário.




Figura 1
Nuvem de palavras Modelo 1



Figura 2
Nuvem de palavras Modelo 2

Diferentemente dos modelos anteriores, que constroem representações vetoriais ("embeddings") a partir do zero com base nos dados do corpus, o Modelo 3 emprega uma estratégia de aprendizado por transferência ("transfer learning"). Esta é uma técnica consolidada em aprendizado de máquina e PLN, que permite utilizar o conhecimento adquirido em uma tarefa ou domínio (tarefa-fonte) para melhorar o desempenho em uma

nova tarefa (tarefa-alvo) (Jurafsky e Martin, 2023). Especificamente, para a fase de pré-treinamento, o Modelo 3 inicia com a base de vetores de palavras "GoogleNews-vectors-negative300.bin", que contém 3 milhões de vetores de 300 dimensões treinados em um vasto corpus de notícias do Google. Após a inicialização com esses vetores pré-treinados, o modelo é refinado, ou seja, submetido à fase de "fine-tuning", com os dados processados pela mesma metodologia utilizada no Modelo 1. Esta abordagem capitaliza o conhecimento lexical e semântico adquirido de um grande corpus genérico ("transfer learning"), adaptando-o, subsequentemente, ao domínio específico das atas do COPOM. A eficácia desse paradigma de pré-treinamento e "fine-tuning", utilizando "embeddings" pré-treinadas para capturar informações contextuais e aplicá-las em novos domínios, tem sido amplamente demonstrada em diversas aplicações de PLN (Bana, 2022).

Os diferentes modelos permitem comparar o impacto de diferentes estratégias de pré-processamento e da inclusão de conhecimento pré-treinado na qualidade das representações textuais. Pode-se analisar como a redução do vocabulário e o "stemming" (Modelos 1 e 2) afetam a capacidade dos modelos de capturar informações relevantes dos documentos, enquanto o Modelo 3 permite avaliar os benefícios de iniciar com um conhecimento léxico amplo e adaptá-lo, permitindo discutir se um modelo de representação vetorial específico (construído do zero) ou um modelo de representação vetorial genérico adaptado (pré-treinado) possui maior capacidade preditiva.

Para mitigar o "looking-ahead bias" e garantir a comparabilidade entre as variáveis preditoras, as variáveis dependentes, incluindo as médias dos vetores de palavras extraídos das atas, são padronizadas para apresentar média zero e variância unitária. Este processo é realizado utilizando a média e o desvio padrão de cada variável, calculados estritamente com base nos dados disponíveis até o tempo t da previsão.

2.2 Skip-gram

Para a vetorização das palavras, emprega-se o método Skip-gram (Mikolov et al., 2013b). Este método gera representações vetoriais (embeddings) para palavras, projetando-as em um espaço vetorial de alta dimensão. A proximidade entre os vetores nesse espaço indica similaridade semântica entre as palavras. As vantagens do Skip-gram incluem sua eficácia em capturar o contexto de uso das palavras e sua capacidade de ser treinado em vastos conjuntos de dados (Jurafsky e Martin, 2023).

O objetivo do modelo é maximizar a probabilidade logarítmica de observar palavras contextuais, dadas as palavras centrais, conforme a seguinte equação:

$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j}|w_t), \quad (1)$$

onde T é o número total de palavras no corpus, w_t e w_{t+j} representam a palavra central na posição t e as palavras de contexto na posição $t+j$. O índice j varia de $-c$ a c , excluindo 0, onde c é o tamanho da janela de contexto.

O logaritmo da probabilidade de observar a palavra de contexto w_{t+j} dado a palavra central w_t é utilizado para facilitar os cálculos e transformar produtos em somas. O símbolo de somatório ($\sum$) indica que estamos somando as probabilidades (ou melhor, os logaritmos das probabilidades) para todas as palavras do corpus e para todas as palavras de contexto dentro da janela.

A probabilidade é calculada usando a função softmax:

$$p(w_o|w_l) = \frac{\exp(v'_{w_o} \top v_{w_l})}{\sum_{w=1}^W \exp(v'_w \top v_{w_l})} \quad (2)$$

O Skip-gram pega uma palavra central e prevê as palavras que a cercam. Ao fazer isso repetidamente em um corpus, o modelo aprende a associar palavras que aparecem em contextos semelhantes. Essas associações são representadas pelos vetores de palavras, que capturam as relações semânticas entre elas. Palavras com

significados e usos semelhantes terão vetores próximos no espaço vetorial.

A capacidade do Skip-gram de aprender essas representações contextuais é fundamental para o trabalho. Isso se traduz na possibilidade de inferir o sentimento ou a conotação de um documento, baseando-se nas palavras que o compõem (Jurafsky e Martin, 2023). Por exemplo, documentos que contêm uma predominância de palavras associadas a termos positivos ou de crescimento (cujos vetores estariam próximos no espaço semântico) tenderão a indicar um contexto favorável ao crescimento econômico. Inversamente, a presença de palavras com conotação negativa ou de estagnação sugeriria um cenário oposto. Essa habilidade de mapear a semântica das palavras para um espaço vetorial permite quantificar e analisar a tonalidade de documentos, fornecendo um poderoso previsor para o crescimento.

Além disso, o Skip-gram é amplamente reconhecido pelo seu baixo custo computacional no aprendizado de representações de vetores distribuídos (embeddings) para palavras. Essa eficiência permite o treinamento em grandes volumes de dados textuais (Mikolov et al., 2013a).

2.3 Modelos de Previsão

A metodologia de previsão empregada neste estudo fundamenta-se em uma abordagem de janela deslizante ("rolling window") combinada com validação cruzada temporal. Essa estratégia permite que o modelo se adapte às características contextuais e à evolução temporal do corpus. A cada iteração da janela deslizante, o modelo é treinado em um período de tempo e , subsequentemente, avaliado em um horizonte de previsão futuro. A equação de previsão para o crescimento do PIB, denotado por y_{t+h} , é estruturada da seguinte forma:

$$y_{t+h} = W_t' \beta_h + D_{i,t}' \phi_h + \varepsilon_{t+h} \quad (3)$$

Onde:

- y_{t+h} representa a taxa de crescimento do Produto Interno Bruto (PIB) no período $t + h$, sendo h o horizonte de previsão à frente ($h = 1, 2, 3$ ou 4 trimestres).
- W_t é um vetor de variáveis de controle que inclui as defasagens do próprio crescimento do PIB (y_{t-1}, y_{t-2}). Estas variáveis capturam a persistência e a dinâmica. Desta forma, todos os modelos apresentados neste artigo possuem duas defasagens da variável dependente, sendo o AR(2) um caso particular em que $D_{i,t}$ é excluído.
- $D_{i,t}$ denota o vetor de novos preditores derivados dos dados textuais. Estes preditores são construídos a partir de técnicas de processamento de linguagem natural (PLN), como representações densas (embeddings) de documentos. O subscrito i indica que diferentes formulações ou modelos textuais podem gerar distintos conjuntos de preditores.
- β_h e ϕ_h são os vetores de coeficientes a serem estimados para o horizonte de previsão h , associados às variáveis de controle e aos preditores textuais, respectivamente.
- ε_{t+h} é o termo de erro, representando os resíduos não explicados pelo modelo.

A estimativa dos coeficientes β_h e ϕ_h é realizada para cada horizonte de previsão h e para cada janela deslizante, permitindo que os pesos dos preditores se ajustem à medida que novas informações temporais se tornam disponíveis. Diferentes algoritmos de regressão, incluindo modelos lineares regularizados (Lasso, Ridge, Elastic Net) e não lineares (Random Forest, Gradient Boosting), são empregados para avaliar a capacidade preditiva dos modelos.

Tais metodologias são relevantes para a construção de modelos preditivos em cenários onde a quantidade de potenciais variáveis explicativas é vasta. A utilização desses modelos é motivada pela dificuldade em

selecionar preditores eficazes e pela necessidade de lidar com a alta dimensionalidade dos dados. Modelos tradicionais, como os Mínimos Quadrados Ordinários (MQO), tornam-se inviáveis ou apresentam alta variância quando o número de preditores é grande, possivelmente maior que o tamanho da amostra (Garcia et al., 2017).

A base de dados empregada no estudo foi segmentada em duas partes iguais, com a primeira metade compreendendo 44 observações. Este subconjunto inicial foi utilizado para a estimação dos modelos em quatro diferentes configurações de dados, permitindo a geração de previsões para horizontes temporais de 1, 2, 3 e 4 trimestres subsequentes, respectivamente. Isso assegura que as previsões para cada horizonte sejam baseadas em informações disponíveis no período de estimação, simulando um ambiente de previsão em tempo real.

2.3.1 Fator

O modelo de fator é uma abordagem de modelagem de fatores latentes baseada em Componentes Principais (PCA), seguida por uma seleção de fatores baseada em significância estatística (via MQO) para previsão de séries temporais. O objetivo principal desse modelo é reduzir a dimensionalidade dos vetores que representam características extraídas de texto ($D_{i,t}$), extraíndo um número menor de fatores latentes (ou componentes principais) que capturam a maior parte da variância nos dados originais.

A escolha do número ótimo de fatores utiliza a regra proposta por Lima et al. (2021). Primeiramente, emprega-se a regra de Ahn e Horenstein (2013) para determinar a quantidade ideal de fatores, que é definida pela abordagem da razão dos autovalores. Complementarmente, o modelo refina essa seleção ao incluir apenas os fatores que apresentarem um p-valor menor ou igual a 0.01 (Bai e Ng, 2008).

2.3.2 Ridge

Uma alternativa em relação ao modelo de fatores são os modelos de encolhimento. A ideia é encolher os coeficientes não relevantes a valores próximos ou iguais a zero (Garcia et al., 2017). O primeiro método de encolhimento a surgir foi a regressão Ridge, introduzida por Hoerl e Kennard (1970) com o objetivo de propor um procedimento de estimação que ajude a contornar as dificuldades associadas às estimativas de mínimos quadrados usuais quando os vetores preditores não são ortogonais. A regressão Ridge minimiza a soma dos quadrados dos resíduos impondo uma penalidade L_2 :

$$\hat{\beta}^{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\} \quad (4)$$

O grau do encolhimento dos coeficientes é controlado pelo parâmetro λ . À medida que λ aumenta, os coeficientes se tornam cada vez menores, embora sem jamais atingir exatamente zero. Essa penalidade é útil quando há muitas variáveis de entrada correlacionadas, pois ajuda a mitigar o problema de coeficientes instáveis e com alta variância que podem surgir em modelos de mínimos quadrados padrão (Hastie et al., 2009), contornando o problema da multicolinearidade.

2.3.3 Lasso

O próximo modelo de encolhimento a surgir foi o Lasso, proposto por Tibshirani (1996). Diferentemente do Ridge, o Lasso tem a capacidade de zerar os coeficientes irrelevantes, removendo variáveis automaticamente. Além disso, o Lasso gera modelos mais interpretáveis em relação ao Ridge. A principal diferença está na penalidade. Enquanto o Ridge utiliza a penalidade $\lambda \sum_{j=1}^p \beta_j^2$ (L_2), o Lasso utiliza a L_1 , onde $\lambda \sum_{j=1}^p |\beta_j|$:

$$\hat{\beta}^{\text{lasso}} = \arg \min_{\beta} \left\{ \frac{1}{2} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\} \quad (5)$$

Quando há forte multicolinearidade, o Lasso pode se tornar instável, escolhendo apenas uma variável no modelo e ignorando as demais, sem se importar qual é selecionada, podendo descartar variáveis importantes (Bai e Ng, 2008; Zou e Hastie, 2005). Enquanto o Lasso é excelente para criar modelos esparsos e lidar com muitas variáveis, suas fragilidades residem na forma como ele gerencia preditores correlacionados e nas características de viés e consistência de suas estimativas em certos contextos.

2.3.4 Elastic Net

Como forma de combinar as vantagens do Ridge e do Lasso, Zou e Hastie (2005) propôs o Elastic Net (EN), que é uma combinação entre os dois modelos. A parte L_1 do EN realiza a seleção de variáveis, enquanto a parte L_2 estabiliza a solução, o que é especialmente benéfico quando há alta correlação entre os preditores (Masini et al., 2021). Já o parâmetro α determina a mistura entre as duas penalidades. Quando $\alpha = 1$, o EN se torna a regressão Ridge pura, que aplica encolhimento (L_2) aos coeficientes. Já quando $\alpha = 0$, o EN se torna o Lasso puro.

$$\hat{\beta}^{\text{en}} = \arg \min_{\beta} \left\{ \frac{1}{2} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \left[\alpha \sum_{j=1}^p \beta_j^2 + (1 - \alpha) \sum_{j=1}^p |\beta_j| \right] \right\} \quad (6)$$

A seleção do parâmetro α se dá através da validação cruzada. É escolhido uma grade de valores possíveis de α entre 0 e 1, e selecionado o valor que apresenta o menor erro na validação cruzada.

2.3.5 Random Forest

Random Forest (RF) é uma metodologia de aprendizado de máquina que foi proposta inicialmente por Breiman (2011). Ela é baseada em árvores de regressão, que são um tipo de árvore de decisão utilizadas para prever valores contínuos (numéricos). O modelo de árvores de regressão é não paramétrico, baseado no particionamento binário recursivo do espaço de covariáveis X , construindo uma estrutura em forma de árvore. Cada nó representa uma condição de decisão baseada em uma variável preditora, fornecendo um valor numérico, que normalmente é a média dos valores observados nas amostras que atingem aquele nó. Conforme Garcia et al. (2017) o modelo de predição baseado em árvores de regressão pode ser representado por:

$$\pi_{t+h} = H_T(x_t; \psi) + u_{t+h} = \sum_{i \in T} \beta_i B_{Ji}(x_t; \theta_i) + u_{t+h}, \quad (6)$$

$$B_{Ji}(x_t; \theta_i) = \prod_{j \in J} I(x_{j,t}; c_j)^{\frac{n_{i,j}(1+n_{i,j})}{2}} \times [1 - I(x_{j,t}; c_j)]^{(1-n_{i,j})(1+n_{i,j})}, \quad (7)$$

$$I(x_{j,t}; c_j) = \begin{cases} 1 & \text{if } x_{j,t} \leq c_j \\ 0 & \text{caso contrário} \end{cases} \quad (8)$$

$$n_{i,j} = \begin{cases} -1 & \text{se o caminho da folha } i \text{ não passa pelo nó pai } j \\ 0 & \text{se o caminho até a folha } i \text{ passa pelo filho à direita do nó pai } j \\ 1 & \text{se o caminho até a folha } i \text{ passa pelo filho à esquerda do nó pai } j \end{cases} \quad (9)$$

Random Forest é baseada na agregação por bootstrap ("bagging") de árvores de regressão construídas aleatoriamente, uma técnica que reduz a variância de uma função de predição estimada (Hastie et al., 2009). Suponha que existam B subconjuntos obtidos por reamostragem bootstrap, e denote-se a árvore de regressão estimada para cada um desses subconjuntos por $H_{J_b T_b}(\cdot; \psi_b)$ (Garcia et al., 2017; Masini et al., 2021). A predição final é definida como:

$$\hat{\pi}_{t+h} = \frac{1}{B} \sum_{b=1}^B H_{J_b T_b}(x_t; \psi_b) \quad (7)$$

2.3.6 Gradient Boosting

O Gradient Boosting (GB), introduzido por Friedman (2001), constitui uma técnica robusta e flexível de aprendizado de máquina, pertencente à categoria dos métodos de boosting. Embora originalmente concebido para problemas de classificação, sua aplicabilidade se estende eficientemente para tarefas de regressão, atuando como um método geral para aprimorar o desempenho de abordagens de aprendizado supervisionado mais simples (Athey, 2019; Hastie et al., 2009).

Essa técnica pode ser interpretada como uma "aproximação de função gulosa" (greedy function approximation), notabilizando-se pela sua capacidade de modelar interações complexas entre variáveis e de realizar seleção automática de atributos. O Gradient Boosting constrói seu modelo preditivo de forma iterativa, onde, em cada etapa, um novo modelo base é adicionado sequencialmente para corrigir os resíduos do modelo precedente. As "árvores impulsionadas" (boosted trees) são uma modalidade comum dentro desse algoritmo, empregando árvores de regressão como modelos de base.

O processo de modelagem do GB pode ser formalizado pela seguinte equação

$$\begin{aligned} \hat{Y}_{t+h} &= \bar{Y} + \sum_{m=1}^M v \rho_m \hat{u}_{t_m} \\ &= \bar{Y} + \sum_{m=1}^M v \hat{\rho}_m \sum_{k \in \mathcal{T}_m} \hat{\beta}_{km} B_{J_{mk}}(X_t; \hat{\theta}_{km}). \end{aligned} \quad (8)$$

A calibração do algoritmo é crucial e, para tanto, recomenda-se a utilização de um parâmetro de shrinkage (v) entre 0 e 1 para controlar a taxa de aprendizado. Valores de (v) próximos de 1 aceleram a convergência e otimizam o ajuste na amostra de treinamento, mas aumentam significativamente o risco de overfitting e, consequentemente, a degradação do desempenho fora da amostra. Para mitigar o overfitting e preservar uma taxa de convergência adequada, uma taxa de aprendizado entre 0.1 e 0.2 é comumente aconselhada (Masini et al., 2021). No presente estudo, foi empregada uma taxa de convergência de 0.1, visando à robustez dos resultados.

2.4 Métricas de Avaliação

Neste trabalho, utilizam-se três tipos de métricas de avaliação, o Raiz do Erro Quadrático Médio (RMSE), Erro Absoluto Médio (MAE), RMSE e MAE relativos. São métricas amplamente utilizadas para avaliar a precisão de previsões e o desempenho de modelos (Elliott e Timmermann, 2013).

RMSE é dado por:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (9)$$

O MAE , por sua vez, é medido por:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (10)$$

Enquanto o RMSE oferece uma medida absoluta do erro, a sua normalização pelo RMSE de um modelo benchmark o converte no RMSE Relativo, dado por:

$$RMSE \text{ Relativo} = \frac{RMSE_{\text{Modelo Analisado}}}{RMSE_{\text{Benchmark}}} \quad (11)$$

Esta métrica avalia o desempenho preditivo do modelo proposto em comparação com um padrão estabelecido. Um valor inferior a 1 indica que o modelo analisado supera o benchmark, enquanto um valor superior a 1 sugere performance inferior. O RMSE Relativo viabiliza uma avaliação comparativa objetiva, destacando a eficiência ou as limitações do modelo em relação a abordagens de referência.

Um indicador análogo é construído para o MAE:

$$MAE \text{ Relativo} = \frac{MAE_{\text{Modelo Analisado}}}{MAE_{\text{Benchmark}}} \quad (12)$$

2.5 Modelo de representação vetorial variante no tempo

A principal característica que confere dinamismo ao modelo e permite sua adaptação às mudanças contextuais do corpus é a utilização de um modelo de representação vetorial variante no tempo. Diferentemente de modelos estáticos que utilizam uma representação vetorial fixa, com modelo pré-treinado em todo o conjunto de dados, esta abordagem reconstrói o conjunto de representações vetoriais a cada iteração da janela deslizante.

Essa reconstrução e ajuste contínuos dos modelos Word2Vec em cada janela de tempo permitem que o sistema incorpore as nuances e evoluções semânticas do discurso nas atas do COPOM ao longo do tempo. Além disso, garante que se usem apenas informações disponíveis no período, evitando o "look-ahead bias". Assim, o modelo consegue capturar a relevância temporal das palavras e suas relações, fornecendo preditores que se adaptam às condições dinâmicas do mercado e da comunicação institucional [Lima et al. \(2021\)](#).

2.6 Validação cruzada

Em análises de séries temporais, a validação cruzada tradicional, que realiza divisões aleatórias dos dados, é inadequada devido à dependência temporal inerente às observações. Para contornar essa questão, utiliza-se a validação cruzada temporal para garantir que as divisões dos dados mantenham a ordem cronológica, ou seja, os dados de treinamento precedem estritamente os dados de teste.

O procedimento é realizado por meio de uma janela deslizante ("rolling window"), onde a cada iteração, o conjunto de treinamento é expandido para incluir novos dados sequenciais, e o conjunto de teste consiste nos pontos imediatamente posteriores. Assim, assegura-se que a previsão de um ponto no tempo seja feita apenas com base em informações passadas ([Elliott e Timmermann, 2013](#); [Diebold e Shin, 2018](#)).

No nosso caso, os dados foram divididos em cinco partes. Na primeira iteração, um subconjunto inicial dos dados é designado como o conjunto de treinamento, compreendendo as observações mais antigas da série temporal. O conjunto de teste para esta dobra consiste nas observações imediatamente posteriores ao fim do conjunto de treinamento, ou seja, o próximo período de tempo. Nas iterações subsequentes, o conjunto

de treinamento é progressivamente expandido para incluir os dados que foram previamente utilizados no conjunto de teste da iteração anterior, além de novas observações sequenciais.

Este método de janela deslizante garante que, em cada validação, o modelo é exposto a uma quantidade crescente de dados, imitando a realidade onde mais informações se tornam disponíveis com o passar do tempo. O ciclo continua até que todas as cinco dobras tenham sido processadas, fornecendo uma avaliação robusta do desempenho preditivo do modelo em diferentes horizontes temporais, sempre respeitando a causalidade temporal. Esta técnica de validação cruzada temporal garante que a ordem cronológica dos dados é preservada em cada dobra da validação.

Para a seleção dos parâmetros de regularização utilizados na validação cruzada, adota-se o método proposto por [Friedman et al. \(2010\)](#). Inicialmente, determina-se o valor máximo de λ ($\lambda_{\max}$), para o qual o vetor de coeficientes $\tilde{\beta} = 0$. Quando $\tilde{\beta} = 0$, vemos pela equação:

$$\tilde{\beta}_j \leftarrow \frac{S\left(\frac{1}{N} \sum_i x_{ij}(y_i - \tilde{y}_i^{(j)}), \lambda \alpha\right)}{1 + \lambda(1 - \alpha)} \quad (13)$$

que $\tilde{\beta}_j$ permanecerá zero se $\left(\frac{1}{N}\right) |\langle x_j, y \rangle| < \lambda \alpha$. Assim, $N\alpha\lambda_{\max} = \max_j |\langle x_j, y \rangle|$. A estratégia de seleção envolve a escolha de um valor mínimo $\lambda_{\min}$, definido como o produto de ε e $\lambda_{\max}$ ($\lambda_{\min} = \varepsilon\lambda_{\max}$) e a construção de uma sequência de K valores de λ que decrescem de $\lambda_{\max}$ para $\lambda_{\min}$ em uma escala logarítmica. Os valores típicos para os parâmetros ε e K são 0.001 e 100, respectivamente.

3. Resultados

Esta seção apresenta e discute os resultados obtidos da comparação entre diversos modelos de previsão do Produto Interno Bruto (PIB) trimestral. A avaliação foi realizada para diferentes horizontes de tempo (1, 2, 3 e 4 trimestres à frente), utilizando o RMSE e o MAE como métricas primárias. Adicionalmente, empregou-se o RMSE Relativo, que compara a performance de cada modelo com a de um modelo autorregressivo (AR(2)) como "benchmark" ([Chauvet e Potter, 2013](#); [Lima et al., 2021](#)).

A escolha do modelo AR(2) como "benchmark" para a previsão do PIB real reflete uma constatação importante da literatura, como evidenciado por [Chauvet e Potter \(2013\)](#). Em sua pesquisa, que analisou o crescimento do PIB real americano utilizando dados em tempo real, o modelo univariado AR(2) frequentemente se mostrou um modelo difícil de ser superado. Essa performance o estabelece como um ponto de referência para comparações.

Nesse processo de comparação, a validação estatística das diferenças observadas no desempenho preditivo é crucial. A significância estatística das diferenças de desempenho entre os modelos e o "benchmark" AR(2) foi avaliada através do teste de [Clark e West \(2007\)](#). Este teste é particularmente relevante pois permite determinar se a superioridade observada de um modelo sobre o outro é estatisticamente robusta. Um p-valor baixo (geralmente abaixo de 0.10, 0.05 ou 0.01) indica que a diferença de desempenho não é aleatória, mas sim estatisticamente significativa.

3.1 Treinamento dos Modelos e Geração de Vetores

Inicialmente, foram treinados modelos Word2Vec (skip-gram) em diferentes versões do corpus de texto, incluindo texto pré-processado e texto "stemizado", além de um modelo Word2Vec pré-treinado com o corpus do Google News. A dimensão dos vetores resultantes para os modelos Word2Vec foi de 300, para garantir a comparabilidade, já que a base pré-treinada utiliza essa dimensão.

3.2 Desempenho dos Modelos por Horizonte de Previsão

As Tabelas 2 a 5 detalham as métricas de desempenho para cada modelo e método de vetorização de texto, abrangendo MAE, RMSE, RMSE Relativo e o p-valor do teste de Clark-West para cada horizonte de previsão. De forma geral, observa-se que a maioria dos modelos que incorporam vetores de texto apresenta

desempenho superior ao modelo AR2. Isso é evidenciado pelos valores de RMSE Relativo inferiores a 1, que indicam menor erro de previsão em comparação ao "benchmark". O teste de Clark-West complementa essa análise ao verificar se as diferenças de desempenho são estatisticamente significativas, testando a hipótese nula de que os modelos possuem a mesma capacidade preditiva.

Para o horizonte de 1 trimestre (Tabela 2), o modelo Gradient Boost com vetorização Modelo 1 (texto pré-processado) alcançou o menor RMSE (8.9613) entre os modelos com significância estatística, representando uma melhoria de 6.74% em relação ao AR2 (RMSE Relativo de 0.9326). O Elastic Net com vetorização Modelo 2 (texto "stemizado") apresentou o menor MAE (4.7066) e RMSE Relativo de 0.9702, indicando redução de 2.98% no erro. Diversos modelos demonstram não apenas superioridade numérica, mas também significância estatística: Gradient Boost (Modelos 1 e 3), Elastic Net (Modelo 2) e Random Forest (Modelo 3) apresentam p-valores significativos no teste de Clark-West, confirmando que suas diferenças em relação ao AR2 são estatisticamente válidas.

Tabela 2
Desempenho dos Modelos para Previsão do PIB - Horizonte 1 Trimestre(s)

MODELO	Vetorização	RMSE	RMSE Rel.	MAE	MAE Rel.	p-valor CW
AR(2)		9.6102	1.0000	5.0036	1.0000	
Random Forest	Modelo 1	8.6257	0.8976	4.8169	0.9627	0.1133
Gradient Boost	Modelo 1	8.9613	0.9326	5.3969	1.0786	0.0705*
Random Forest	Modelo 3	9.0111	0.9377	4.9996	0.9992	0.0383**
Random Forest	Modelo 2	8.9674	0.9331	4.8800	0.9753	0.1258
Elastic Net	Modelo 2	9.3238	0.9702	4.7066	0.9406	0.0227**
Gradient Boost	Modelo 3	9.3623	0.9742	5.4710	1.0934	0.0542*
Lasso	Modelo 2	9.4836	0.9858	4.8857	0.9764	0.1069
Gradient Boost	Modelo 2	9.4907	0.9876	5.4621	1.0916	0.1243
Elastic Net	Modelo 3	9.6969	1.0090	5.3151	1.0622	0.0833*
Factor	Modelo 2	9.6469	1.0038	5.0653	1.0123	0.1648
Elastic Net	Modelo 1	10.4485	1.0872	5.7451	1.1482	0.6506
Lasso	Modelo 3	10.3238	1.0743	5.1516	1.0296	0.7220
Ridge	Modelo 3	10.6421	1.1074	6.8651	1.3720	0.0422**
Ridge	Modelo 2	10.8371	1.1277	7.2480	1.4486	0.0138**
Lasso	Modelo 1	10.8507	1.1291	5.6106	1.1213	0.9242
Factor	Modelo 3	10.1074	1.0517	5.3814	1.0755	0.5066
Factor	Modelo 1	11.8438	1.2324	5.8413	1.1674	0.0568*
Ridge	Modelo 1	19.6581	2.0456	11.8441	2.3672	0.0714*

Nota: O RMSE Relativo é a razão entre o RMSE do modelo e o RMSE do modelo AR(2).

O MAE Relativo é a razão entre o MAE do modelo e o MAE do modelo AR(2).

Indicadores de significância para o p-valor do teste de Clark-West: * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

No horizonte de 2 trimestres (Tabela 3), o modelo Lasso com vetorização Modelo 1 obteve o menor RMSE (8.5071), proporcionando uma redução substancial de 14.23% no erro (RMSE Relativo de 0.8577). O modelo Random Forest com vetorização Modelo 1 exibiu o menor MAE (4.8949) estatisticamente significativo, embora com RMSE Relativo de 0.8710. Múltiplos modelos apresentam tanto superioridade preditiva (RMSE Relativo < 1) quanto significância estatística: Lasso (Modelo 3), Random Forest (Modelos 1, 2 e 3) e Gradient Boost (Modelos 1 e 2) demonstram p-valores altamente significativos ($p < 0.01$ ou $p < 0.05$), validando estatisticamente sua superioridade sobre o AR(2).

Para o horizonte de 3 trimestres (Tabela 4), o Random Forest (Modelo 1) registrou o menor RMSE (8.6052), com redução de 7.01% no erro (RMSE Relativo de 0.9299), enquanto o Random Forest (Modelo 2) alcançou o menor MAE (5.1705) e RMSE Relativo de 0.9574. O desempenho dos modelos de "ensemble" (Random Forest e Gradient Boost) continua robusto, com a maioria apresentando RMSE Relativo inferior a 1 e significância estatística confirmada pelo teste de Clark-West.

Tabela 3
Desempenho dos Modelos para Previsão do PIB - Horizonte 2 Trimestre(s)

MODELO	Vetorização	RMSE	RMSE Rel.	MAE	MAE Rel.	p-valor CW
AR(2)		9.9189	1.0000	5.3969	1.0000	
Lasso	Modelo 1	8.5071	0.8577	5.1617	0.9564	0.0653*
Random Forest	Modelo 1	8.6392	0.8710	4.8949	0.9070	0.0096***
Random Forest	Modelo 2	8.9042	0.8977	5.0383	0.9336	0.0117**
Lasso	Modelo 2	8.8860	0.8959	5.1775	0.9593	0.0681*
Gradient Boost	Modelo 1	8.9607	0.9034	5.6831	1.0531	0.0223**
Gradient Boost	Modelo 2	9.0295	0.9103	5.6044	1.0384	0.0097***
Elastic Net	Modelo 2	9.1091	0.9184	5.3554	0.9923	0.0688*
Elastic Net	Modelo 1	9.2045	0.9280	5.5793	1.0338	0.0605*
Elastic Net	Modelo 3	9.3131	0.9389	5.4932	1.0178	0.0228**
Random Forest	Modelo 3	9.2822	0.9358	5.6976	1.0557	0.0236**
Factor	Modelo 2	9.3014	0.9377	4.8664	0.9017	0.1352
Lasso	Modelo 3	9.7732	0.9853	5.5748	1.0330	0.0252**
Gradient Boost	Modelo 3	9.9510	1.0032	6.1251	1.1349	0.0487**
Factor	Modelo 3	10.0009	1.0083	5.5194	1.0227	0.2014
Factor	Modelo 1	13.6927	1.3805	6.8946	1.2775	0.0810*
Ridge	Modelo 3	10.7439	1.0832	7.6496	1.4174	0.0247**
Ridge	Modelo 2	16.6749	1.6811	8.4095	1.5582	0.0136**
Ridge	Modelo 1	19.0560	1.9212	11.9662	2.2173	0.0124**

Nota: O RMSE Relativo é a razão entre o RMSE do modelo e o RMSE do modelo AR(2).

O MAE Relativo é a razão entre o MAE do modelo e o MAE do modelo AR(2).

Indicadores de significância para o p-valor do teste de Clark-West: * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

Finalmente, no horizonte de 4 trimestres (Tabela 5), o modelo Random Forest com vetorização Modelo 2 destacou-se com os menores RMSE (8.8397) e MAE (4.8934), proporcionando redução de 3.90% no erro (RMSE Relativo de 0.9610) e significância estatística (p-valor = 0.0101). Os modelos de regressão regularizada Lasso (Modelos 1 e 3) e de "ensemble" Random Forest (Modelos 1 e 2) mantiveram tanto a superioridade preditiva (RMSE Relativo < 1) quanto a significância estatística em relação ao AR(2), mesmo neste horizonte de previsão mais desafiador.

A análise detalhada dos resultados revela nuances importantes na interpretação das métricas. É fundamental que um modelo apresente não apenas um RMSE Relativo inferior a 1 (indicando melhor desempenho que o benchmark AR(2)), mas também um p-valor significativo no teste de Clark-West (confirmando que essa diferença não é por acaso, mas estatisticamente robusta).

Nesse sentido, observa-se que, enquanto muitos modelos se encaixam nesse critério, alguns casos merecem atenção. Por exemplo, alguns modelos Ridge demonstram p-valores significativos no teste de Clark-West, indicando que são estatisticamente diferentes do AR(2). Contudo, em diversas instâncias, seu RMSE Relativo é superior a 1, o que significa que, apesar da diferença estatística, seu poder preditivo é, na verdade, inferior ao do AR2. Isso sugere que a regularização L2, empregada pelo Ridge, que encolhe os coeficientes sem necessariamente levá-los a zero (não realizando seleção de variáveis estrita), pode não ser a abordagem mais eficaz para este conjunto de dados, especialmente se houver muitas "features" textuais irrelevantes ou redundantes.

Em contrapartida, modelos que realizam ou favorecem a seleção de variáveis, como Lasso (regularização L1, que pode zerar coeficientes e, portanto, realizar seleção de variáveis) e Elastic Net (combinação de L1 e L2), demonstram um desempenho mais consistente e frequentemente superior. Sua capacidade de identificar e manter apenas as variáveis textuais mais informativas, desprezando o ruído e a redundância, revela-se uma vantagem crucial em ambientes de alta dimensionalidade como o processamento de texto. Essa seleção de variáveis contribui diretamente para a robustez e interpretabilidade dos modelos, justificando

Tabela 4
Desempenho dos Modelos para Previsão do PIB - Horizonte 3 Trimestre(s)

MODELO	Vetorização	RMSE	RMSE Rel.	MAE	MAE Rel.	p-valor CW
AR(2)		9.2540	1.0000	5.2107	1.0000	
Random Forest	Modelo 1	8.6052	0.9299	5.2538	1.0083	0.0306**
Random Forest	Modelo 2	8.8602	0.9574	5.1705	0.9923	0.0183**
Random Forest	Modelo 3	9.0635	0.9794	5.6147	1.0775	0.0366**
Gradient Boost	Modelo 1	9.1680	0.9907	6.1577	1.1817	0.0265**
Elastic Net	Modelo 3	9.3793	1.0136	5.7889	1.1109	0.1921
Elastic Net	Modelo 2	9.4768	1.0241	5.5993	1.0746	0.2035
Gradient Boost	Modelo 2	9.4830	1.0247	5.6014	1.0750	0.0588*
Gradient Boost	Modelo 3	9.5686	1.0340	6.3829	1.2249	0.0313**
Lasso	Modelo 3	9.5770	1.0349	5.5356	1.0623	0.4177
Lasso	Modelo 1	9.8493	1.0643	6.0150	1.1543	0.4997
Lasso	Modelo 2	9.9506	1.0753	5.7671	1.1068	0.4918
Factor	Modelo 2	9.8086	1.0599	5.1820	0.9945	0.1620
Elastic Net	Modelo 1	10.2695	1.1097	6.6206	1.2706	0.3873
Factor	Modelo 3	10.3223	1.1154	5.9257	1.1372	0.2151
Ridge	Modelo 3	11.2299	1.2136	8.4788	1.6272	0.1273
Factor	Modelo 1	14.6706	1.5853	7.5518	1.4493	0.0589*
Ridge	Modelo 1	20.6934	2.2351	13.0104	2.4968	0.0241**
Ridge	Modelo 2	21.5857	2.3336	10.8283	2.0781	0.0319**

Nota: O RMSE Relativo é a razão entre o RMSE do modelo e o RMSE do modelo AR(2).

O MAE Relativo é a razão entre o MAE do modelo e o MAE do modelo AR(2).

Indicadores de significância para o p-valor do teste de Clark-West: * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

sua superioridade nos resultados.

O modelo AR(2), utilizado como linha de base, foi superado em todos os horizontes de previsão, confirmando a necessidade de incorporar informações textuais e aplicar modelos mais sofisticados. Os modelos Fator, embora projetados para redução de dimensionalidade, em geral não apresentaram RMSE Relativo consistentemente inferior a 1, indicando limitações em superar o “benchmark” AR(2) de forma sistemática.

Tabela 5
Desempenho dos Modelos para Previsão do PIB - Horizonte 4 Trimestre(s)

MODELO	Vetorização	RMSE	RMSE Rel.	MAE	MAE Rel.	p-valor CW
AR(2)		9.1985	1.0000	5.3299	1.0000	
Random Forest	Modelo 2	8.8397	0.9610	4.8934	0.9181	0.0101**
Random Forest	Modelo 1	8.9434	0.9723	5.4148	1.0159	0.0178**
Lasso	Modelo 1	9.1396	0.9936	5.3775	1.0089	0.0833*
Lasso	Modelo 3	9.1401	0.9937	5.5632	1.0438	0.0235**
Random Forest	Modelo 3	9.2824	1.0091	6.1151	1.1473	0.0203**
Gradient Boost	Modelo 1	9.3931	1.0212	6.3259	1.1868	0.0210**
Lasso	Modelo 2	9.2818	1.0091	5.7708	1.0827	0.0743*
Elastic Net	Modelo 2	9.5180	1.0347	5.9549	1.1172	0.2124
Gradient Boost	Modelo 2	9.4700	1.0295	5.8223	1.0924	0.0321**
Factor	Modelo 2	10.0283	1.0902	5.5117	1.0341	0.2178
Elastic Net	Modelo 1	9.7578	1.0608	6.4941	1.2185	0.0989*
Elastic Net	Modelo 3	10.0357	1.0910	6.2858	1.1793	0.4555
Gradient Boost	Modelo 3	10.1170	1.0999	6.6378	1.2454	0.0556*
Factor	Modelo 3	10.5354	1.1453	6.2797	1.1782	0.2756
Ridge	Modelo 3	10.5933	1.1516	8.5227	1.6010	0.1102
Factor	Modelo 1	14.8086	1.6090	7.7851	1.4606	0.0357**
Ridge	Modelo 2	23.1323	2.5148	11.7239	2.2000	0.0117**
Ridge	Modelo 1	24.5205	2.6657	14.6000	2.7429	0.0072***

Nota: O RMSE Relativo é a razão entre o RMSE do modelo e o RMSE do modelo AR(2).

O MAE Relativo é a razão entre o MAE do modelo e o MAE do modelo AR(2).

Indicadores de significância para o p-valor do teste de Clark-West: * p < 0.10, ** p < 0.05, *** p < 0.01.

3.3 Análise Comparativa Agregada

Para fornecer uma visão concisa dos modelos de melhor desempenho, a Tabela 6 resume os modelos que alcançaram os menores RMSE e MAE para cada horizonte de previsão. A Tabela 6 evidencia que modelos como Random Forest (especialmente com vetorização Modelo 1 e Modelo 2) e Lasso (com vetorização Modelo 1) são os que consistentemente entregam os menores RMSEs. Para o MAE, Random Forest (Modelo 2) e Elastic Net (Modelo 2) são recorrentes entre os melhores. A presença constante de modelos que incorporam "features" textuais e empregam técnicas de regularização, ou "ensemble", demonstra a relevância e o valor preditivo da análise textual para a previsão do PIB. A significativa redução dos erros em comparação com o AR(2), frequentemente acompanhada de significância estatística, valida a superioridade dessas abordagens.

Tabela 6
Resumo dos Modelos de Melhor Desempenho por Horizonte de Previsão

Horiz.	Métrica	Melhor Modelo	Vetoriz.	RMSE	RMSE Rel.	MAE	MAE Rel.	p-valor CW
1	RMSE	Gradient Boost	Modelo 1	8.9613	0.9326	5.3969	1.0786	0.0705*
1	MAE	Elastic Net	Modelo 2	9.3238	0.9702	4.7066	0.9406	0.0227**
2	RMSE	Lasso	Modelo 1	8.5071	0.8577	5.1617	0.9564	0.0653*
2	MAE	Random Forest	Modelo 1	8.6392	0.8710	4.8949	0.9070	0.0096***
3	RMSE	Random Forest	Modelo 1	8.6052	0.9299	5.2538	1.0083	0.0306**
3	MAE	Random Forest	Modelo 2	8.8602	0.9574	5.1705	0.9923	0.0183**
4	RMSE	Random Forest	Modelo 2	8.8397	0.9610	4.8934	0.9181	0.0101**
4	MAE	Random Forest	Modelo 2	8.8397	0.9610	4.8934	0.9181	0.0101**

Nota: O RMSE Relativo é a razão entre o RMSE do modelo e o RMSE do modelo AR(2).

O MAE Relativo é a razão entre o MAE do modelo e o MAE do modelo AR(2).

Indicadores de significância para o p-valor do teste de Clark-West: * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$.

4. Conclusão

Este estudo evidenciou que informações textuais contidas nas atas do COPOM podem ser efetivamente exploradas como preditores para a previsão do crescimento do PIB brasileiro. Por meio de representações vetoriais de palavras geradas com Word2Vec, combinadas a modelos de aprendizado de máquina e técnicas de validação cruzada temporal, foi possível capturar sinais semânticos relevantes dos documentos institucionais.

A metodologia baseada no Word2Vec demonstrou vantagens computacionais importantes em relação a modelos mais complexos de Processamento de Linguagem Natural. Seu baixo custo de treinamento e a capacidade de ser ajustado dinamicamente a janelas de tempo específicas tornaram a abordagem particularmente adequada para aplicações em séries temporais, onde atualizações frequentes são desejáveis.

Outro aspecto central do estudo foi a ênfase na reprodutibilidade. Toda a metodologia foi desenhada para evitar viés de antecipação ("look-ahead bias") e garantir que apenas informações disponíveis até o momento da previsão fossem utilizadas. A combinação de pré-processamento, vetorização sequencial e validação cruzada temporal assegura que os resultados possam ser replicados em outros contextos ou com novas versões das atas.

Os resultados empíricos revelaram que os modelos Random Forest, Gradient Boost, Lasso e Elastic Net, especialmente quando alimentados por "embeddings" derivados de textos pré-processados ou "stemizados", superaram de forma consistente o "benchmark" autorregressivo (AR(2)) em todos os horizontes de previsão. Em contrapartida, o uso de "embeddings" pré-treinados (como os do Google News) mostrou desempenho inferior, sugerindo que a adaptação ao vocabulário e ao contexto específico das atas do COPOM é mais adequada. Assim, concluímos que iniciar o treinamento dos "embeddings" a partir de dados específicos do domínio, em vez de utilizar bases genéricas, resulta em maior precisão preditiva.

Os resultados confirmam que a vetorização textual treinada especificamente sobre o corpus das atas do

COPOM, aliada a modelos de aprendizado de máquina, é uma estratégia eficaz para incorporar informação qualitativa na previsão macroeconômica. Além disso, viabiliza um "nowcasting" robusto do PIB trimestral brasileiro, permitindo estimativas em tempo real que antecedem a divulgação oficial dos dados pelo IBGE em aproximadamente 45-60 dias. Esta capacidade de antecipação temporal representa um diferencial competitivo significativo para formuladores de política econômica, analistas de mercado e pesquisadores acadêmicos. A abordagem utilizada neste estudo equilibra desempenho preditivo, viabilidade computacional e rigor metodológico.

Em trabalhos futuros, a exploração de outras metodologias de vetorização de texto pode representar um caminho promissor para aprimorar a capacidade preditiva dos modelos. Nesse sentido, abordagens que capturam nuances semânticas e contextuais mais complexas merecem consideração, tais como o GloVe (Pennington et al., 2014), que integra informações estatísticas globais do corpus para gerar embeddings mais robustas, e os modelos baseados em Transformers, como BERT (Devlin et al., 2019) e GPT (Radford et al., 2018). Esses últimos produzem representações contextuais mais precisas e apresentam potencial significativo para captar as sutilezas da linguagem das atas do COPOM, podendo contribuir para melhorar acurácia das previsões.

Referências

- Ahn, S. C. & Horenstein, A. R. (2013). Eigenvalue ratio test for the number of factors, . *Econometrica* 81(3): 1203–1227.
- Araujo, D. K. G., Bokan, N., Comazzi, F. A. & Lenza, M. (2025). Word2prices: embedding central bank communications for inflation prediction, *BIS Working Papers* (1253).
- Ash, E., Chen, D. L. & Ornaghi, A. (2024). Gender attitudes in the judiciary: evidence from u.s. circuit courts, *American Economic Journal: Applied Economics* 16(1): 314–350.
- Ash, E. & Hansen, S. (2023). Text algorithms in economics, *Annual Review of Economics* 15: 659–688.
- Athey, S., a. I. G. W. (2019). Machine learning methods that economists should know about, *Annual Review of Economics* 11(1): 685–725.
- Bai, J. & Ng, S. (2008). Forecasting economic time series using targeted predictors, *Journal of Econometrics* 146(2): 304–317.
- Bana, S. H. (2022). work2vec: Using language models to understand wage premia, *Stanford Digital Economy Lab Working Paper* .
- Breiman, L. (2011). Random forests, *Machine Learning* 45: 5–32.
- Chauvet, M. & Potter, S. (2013). Forecasting output. in g. elliott a. timmermann (eds.), *Handbook of economic forecasting*, Amsterdam: Elsevier 2: 141–194.
- Clark, T. E. & West, K. D. (2007). Approximately normal tests for equal predictive accuracy in nested models, *Journal of Econometrics* 138(1): 291–311.
- Devlin, J., Chang, M. W., Lee, K. & Toutanova, K. (2019). Bert: Pre-training of deep bidirectional transformers for language understanding, *arXiv preprint arXiv:1810.04805* .
- Diebold, F. X. & Shin, M. (2018). Machine learning for regularized survey forecast combination: Partially-egalitarian lasso and its derivatives, *National Bureau of Economic Research Working Paper* (24967).
- Elliott, G. & Timmermann, A. (2013). Handbook of economic forecasting, Amsterdam: Elsevier.

- Friedman, J. (2001). Greedy function approximation: A gradient boosting machine, *Annals of Statistics* 29: 1189–1232.
- Friedman, J., Hastie, T. & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent, *Journal of Statistical Software* 33(1): 1–22.
- Garcia, M. G. P., Medeiros, M. C. & Vasconcelos, G. F. R. (2017). Real-time inflation forecasting with high-dimensional models: The case of Brazil, *International Journal of Forecasting* 33(3): 679–693.
- Gentzkow, M. & Shapiro, J. (2010). What drives media slant? Evidence from U.S. daily newspapers, *Econometrica* 78(1): 35–71.
- Getzkow, M., Kelly, B. & Taddy, M. (2019). Text as data, *Journal of Economic Literature* 57(3): 535–574.
- Groseclose, T. & Milyo, J. (2005). A measure of media bias, *The Quarterly Journal of Economics* 120(4): 1191–1237.
- Hastie, T., Tibshirani, R. & Friedman, J. (2009). The elements of statistical learning: Data mining, inference, and prediction, 2. ed. New York, NY: Springer.
- Hoerl, A. E. & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems, *Technometrics* 12(1): 55–69.
- Jurafsky, D. & Martin, J. H. (2023). Speech and language processing: An introduction to natural language processing, computational linguistics, and speech recognition with language models, 3rd ed. draft.
- Lima, L., Godeiro, L. & Mohsin, M. (2021). Time-varying dictionary and the predictive power of Fed minutes, *Computational Economics* 57(1): 149–181.
- Masini, R. P., Medeiros, M. C. & Mendes, E. F. (2021). Machine learning advances for time series forecasting, *Journal of Economic Surveys* 37(1): 76–111.
- Mikolov, T., Chen, K., Corrado, G. & Dean, J. (2013a). Distributed representations of words and phrases and their compositionality, *In Advances in neural information processing systems* 26.
- Mikolov, T., Chen, K., Corrado, G. & Dean, J. (2013b). Efficient estimation of word representations in vector space, *In: 1st international conference on learning representations ICLR 2013 - workshop track proceedings*.
- Pennington, J., Socher, R. & Manning, C. (2014). Glove: global vectors for word representation, *In Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)* p. 1532–43.
- Radford, A., Narasimhan, K., Salimans, T. & Sutskever, I. (2018). Improving language understanding by generative pre-training, *OpenAI*.
- Stock, J. H. & Watson, M. W. (2007). Forecasting economic time series. In G. Elliott, C. W. J. Granger, and A. Timmermann (eds.), *Handbook of Economic Forecasting*, Amsterdam: Elsevier 1: 339–390.
- Taddy, M. (2019). Business data science: Combining machine learning and economics to optimize, automate, and accelerate business decisions, *New York: McGraw-Hill Education*.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso, *Journal of the Royal Statistical Society. Series B (Statistical Methodology)* 58: 267–288.
- Zou, H. & Hastie, T. (2005). Regularization and variable selection via the elastic net, *Journal of the Royal Statistical Society. Series B (Statistical Methodology)* 67(2): 301–320.

A. Figuras Adicionais

Este apêndice apresenta figuras complementares que ilustram visualmente os resultados e discussões abordadas nas seções anteriores, fornecendo uma perspectiva mais detalhada do desempenho dos modelos e das características das previsões.

A Figura A1 oferece uma visão agregada da performance dos modelos em diferentes horizontes de previsão. Ela destaca visualmente os modelos que não apenas superam o benchmark AR2 (RMSE Relativo < 1.0), mas também o fazem de forma estatisticamente significativa (p-valor < 0.10 no teste de Clark-West), conforme detalhado na análise de resultados. Este gráfico permite uma rápida identificação dos modelos mais robustos em termos de acurácia e significância estatística ao longo do tempo.

As Figuras A2 a A5 ilustram as previsões geradas pelos modelos para cada um dos quatro horizontes (1, 2, 3 e 4 trimestres à frente). Essas visualizações comparam graficamente as curvas de previsão de modelos selecionados com a série real do PIB, permitindo observar a capacidade de cada modelo em capturar a dinâmica e as flutuações da variável alvo.




Figura A1
Performance dos Modelos por Horizonte (P-valor < 0.10 e RMSE Relativo < 1.0)




Figura A2

**Comparação de Modelos para Previsão do PIB -
Período 1 Trimestre(s)**




Figura A3

**Comparação de Modelos para Previsão do PIB -
Período 2 Trimestre(s)**




Figura A4

**Comparação de Modelos para Previsão do PIB -
Período 3 Trimestre(s)**




Figura A5

**Comparação de Modelos para Previsão do PIB -
Período 4 Trimestre(s)**