UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA DE PRODUÇÃO E TRANSPORTES

TRABALHO DE CONCLUSÃO DE CURSO DE GRADUAÇÃO

AVALIAÇÃO DE UM MODELO *ENSEMBLE STACKING* DE *MACHINE LEARNING* PARA PREVISÃO DO PIB DO BRASIL

Augusto Dezoti Micheletti

Orientador: Michel José Anzanello, Ph.D

PORTO ALEGRE
Janeiro/2024

RESUMO

A previsão do Produto Interno Bruto (PIB) é fundamental para a comparação de perspectivas entre países e a elaboração de políticas governamentais. Em um contexto de um mundo VUCA (volátil, incerto, complexo e ambíguo) no qual o Brasil está inserido como uma economia emergente, percebe-se que os modelos tradicionais de previsão enfrentam desafios. De tal forma, o presente estudo analisa um modelo *ensemble stacking* de *machine learning* (ML) a partir de dois modelos base (*random forest* e *gradient boosting*) para a previsão do PIB brasileiro. Apoiado em análises gráficas e quantitativas, constatou-se que os modelos de ML utilizados são aderentes ao desafio da previsão do PIB, principalmente em horizontes temporais mais curtos (1 e 3 meses). Porém o modelo *ensemble stacking* não demonstrou resultados significativamente melhores que os seus modelos base, não justificando o seu emprego nesse contexto, uma vez que demanda maior processamento computacional e apoia-se em maior complexidade metodológica.

Palavras-chave: *Previsão do PIB; Previsões Macroeconômicas; Machine Learning; Ensemble Stacking; Random Forest; Gradient Boosting.*

1. INTRODUÇÃO

O Produto Interno Bruto (PIB) é uma medida amplamente utilizada para avaliar a saúde e o desempenho econômico de um país (INTERNATIONAL MONETARY FUND, 2014), consistindo no valor total de todos os bens e serviços produzidos em um determinado período e fornecendo uma visão abrangente da atividade econômica (ROSSETTI, 2003). Ele mede a produção, o consumo e o investimento em uma economia, permitindo que os formuladores de políticas econômicas (*policy makers*), analistas e investidores acompanhem o crescimento econômico ao longo do tempo. O PIB é um indicador crucial, pois reflete a capacidade de um país gerar riqueza e proporcionar bem-estar aos seus cidadãos (INTERNATIONAL MONETARY FUND, 2014). É usado como uma métrica fundamental para comparar o desempenho econômico entre países e avaliar o impacto das políticas governamentais.

Nesse contexto, um tópico importante são as previsões econômicas, através das quais acadêmicos e *policy makers* buscam formas de predizer os principais indicadores da economia, identificando sinais de pontos de virada, principalmente em momentos de crise, para que possam tomar melhores decisões (FRALE et al., 2010). Rebelo (2022) afirma que a previsão

quantitativa do PIB é fundamental na elaboração de políticas monetárias e orçamentais, garantindo decisões mais eficazes. Nessa linha, Medeiros et al. (2021) ressaltam a importância de prever corretamente a inflação para decisões econômicas racionais, apontando como exemplo negativo o Banco Central Europeu (BCE) que fez previsões sistematicamente e substancialmente erradas, impactando negativamente em políticas monetárias.

Existem diversos métodos para geração de previsões econômicas, abrangendo desde métodos qualitativos fundamentalistas até métodos econométricos quantitativos. Recentemente, mesmo em tempos de uma economia com períodos instáveis (como pandemia da COVID-19 e guerra da Ucrânia), mas ainda assim com alta disponibilidade de dados, vem se destacando técnicas de *machine learning* (ML) para a previsão de indicadores econômicos, aproveitando-se do grande poder computacional disponível para previsões mais assertivas (SAGER, 2023).

Medeiros et al. (2021) constatam que há um desafio para as abordagens tradicionais de previsão de indicadores macroeconômicos, uma vez que elas não capturam as complexas interações não lineares entre variáveis da economia. Assim, os autores propõem diferentes modelos de ML aplicados à previsão da inflação dos Estados Unidos, obtendo resultados significativamente melhores que os *benchmarks* lineares. Já no contexto de economias emergentes, que são mais instáveis do que economias bem estabelecidas, tanto Cepni et al. (2019) quanto Sager (2023) concluíram que, para os casos estudados, havia modelos de ML com desempenho superior a métodos tradicionais na previsão do PIB.

Assim, este estudo dá prosseguimento aos recentes estudos de ML aplicados à previsão de indicadores macroeconômicos. O objetivo do presente estudo é avaliar, no contexto da previsão do PIB do Brasil, um modelo do tipo *ensemble stacking*, utilizando para tanto uma combinação de dois modelos de *machine learning*: *random forest regression* e *gradient boosting regression*. A escolha desses dois modelos se dá pelo fato de terem apresentaram os melhores desempenhos individuais na literatura acerca do tema, como em Adriansson et al. (2015), Yoon (2021), Medeiros et al. (2021) e Sager (2023). Como objetivos específicos tem-se a avaliação de variáveis explicativas, a previsão do PIB tanto nos modelos individuais quanto nos combinados e a avaliação dos resultados através de análises gráficas e métricas de erro, buscando-se identificar vantagens do modelo combinado frente aos individuais em diferentes horizontes de previsão.

Tal estudo é relevante no aspecto prático, uma vez que divulgações do PIB com atraso (por exemplo, o PIB referente ao primeiro trimestre de 2023 foi divulgado apenas em junho do mesmo ano no relatório de Contas Nacionais Trimestrais do IBGE) ou imprecisas pode impedir uma avaliação em tempo real da saúde econômica, prejudicando decisões de políticas econômicas, dentre outras (KAGOHARA, 2015). Sob perspectiva teórica, contribui ao avançar com testes de validações de técnicas avançadas de ML em um ambiente caracterizado por elevado volume e complexidade de dados.

Além dessa introdução (seção 1), o artigo está estruturado em outras 4 seções; A seção 2 apresenta o referencial teórico, conceituando os principais temas abordados durante o trabalho, trazendo as soluções já propostas por outros autores para a problemática apresentada; A seção 3 traz a metodologia utilizada neste trabalho, descrevendo os conceitos matemáticos por trás dos modelos; A seção 4 apresenta a análise dos resultados obtidos e finalmente, a seção 5 conclui o trabalho, retomando o objetivo proposto e resultados atingidos, propondo sugestões para trabalhos futuros.

2. REFERENCIAL TEÓRICO

Nesta seção serão abordados trabalhos anteriores no contexto da previsão de indicadores macroeconômicos, tendo como ênfase o indicador central deste estudo, o Produto Interno Bruto. Na primeira parte serão expostas obras de referência em modelos de previsão do PIB nos formatos tradicionais e com o uso de ML, em seguida serão trazidos casos que avaliaram o uso de modelos de ML do tipo *ensemble* para essa previsão e por fim, serão apresentados estudos voltados à seleção de variáveis.

2.1. MODELOS TRADICIONAIS PARA PREVISÃO DO PIB

A capacidade de prever os principais indicadores da economia, como o PIB, é extremamente importante para a identificação de tendências e elaboração de políticas públicas eficazes. Nesse sentido, a forma mais tradicional de realizar essas previsões é a partir de modelos econométricos clássicos como o *vector autoregressive* (VAR), *mixed-data sampling* (MIDAS) e variações desses métodos, como o *factor* MIDAS (FAMIDAS), *mixed frequency* VAR (MF-VAR) entre outros (FRALE et al., 2010).

O VAR é um modelo estatístico autorregressivo multivariado que captura as interações entre variáveis ao longo do tempo, além da parte autorregressiva, que considera os dados passados para as previsões futuras. O artigo de Sims (1980) foi o pioneiro a aplicar o VAR para a

previsão de indicadores econômicos, tendo sucesso ao ser mais preciso que métodos como o modelo de mínimos quadrados ordinários (OLS). Seguindo o trabalho de Sims (1980), ao longo do tempo inúmeros outros autores utilizaram e adaptaram o modelo VAR, visando aumentar a precisão das predições do PIB.

Schorfheide et al. (2015) formalizaram o uso do MF-VAR, uma adaptação do VAR original que permite utilizar dados de variáveis com frequências mistas para a previsão de indicadores macroeconômicos, como o PIB. O estudo indica que há melhoras nas previsões para o curto prazo (um trimestre a frente), mas não indica ganhos significativos na previsão de horizontes de um a dois anos. Aplicando esse mesmo método no contexto brasileiro, Borges et al. (2018) tiveram constatações semelhantes, com resultados indicando que incluir dados de granularidade mensal na previsão do PIB trimestral brasileiro demonstrou melhora para previsões de até dois trimestres; para horizontes maiores que esses não houve incremento de qualidade entre as previsões do VAR convencional e o MF-VAR.

Alves et al. (2015) propuseram um novo algoritmo que usa uma combinação de diferentes modelos MF-VAR como base, capaz de lidar com desafios de falta de dados em séries temporais de algumas variáveis, variáveis com frequências distintas e ainda é capaz de lidar com informações em tempo real. Ao aplicar o algoritmo na previsão do PIB brasileiro, constataram que o algoritmo superava o tradicional VAR em termos de *nowcasting* (antecipação da divulgação do PIB), porém não tiveram melhorias percebidas para o *forecasting* (previsão de períodos futuros).

Com propósitos semelhantes, o MIDAS, assim como o MF-VAR, é um modelo de regressão que utiliza variáveis em diferentes frequências para a previsão de indicadores. O método foi proposto por Ghysels et al. (2004) com foco nos campos da macroeconomia e finanças, e assume que dados em diferentes frequências carregam informações diferentes sobre a variável predita (sendo dados de alta frequência mais sensíveis a mudanças repentinas e dados de baixa frequência mais sensíveis a tendências de longo prazo). Zuanazzi et al. (2014) aplicaram o MIDAS e o *unrestricted* MIDAS (UMIDAS) no contexto da previsão do PIB trimestral brasileiro a partir do uso de séries financeiras e econômicas como preditores, obtendo resultados melhores que o benchmark modelo autorregressivo de médias móveis (ARMA).

Sousa (2022), na busca de um modelo capaz de lidar com momentos disruptivos na economia, como a crise do COVID-19, propõe uma adaptação do MIDAS, nomeada MIDAS *rolling regression*, que introduz parâmetros variantes no tempo. Na aplicação feita com os

dados do PIB do estado do Rio Grande do Sul, o modelo proposto apresentou resultados superiores ao MIDAS e outras variações já conhecidas do método. Já Marcellino et al. (2007) introduzem o FAMIDAS, uma adaptação do MIDAS original que lida melhor com o problema nomeado *ragged edge*, o qual deriva do fato das variáveis possuírem datas de publicação diferentes além de granularidades distintas. O FAMIDAS diferencia os passos de estimação de fatores e previsão de fatores. Assim como o MF-VAR, o modelo, que foi aplicado à previsão do PIB alemão, apresentou ganhos para o curto prazo, mas não se sustenta como vantajoso na previsão de períodos maiores.

Além dos modelos mais usados (VAR, MIDAS e suas variações), ao longo do tempo houveram outras propostas e contribuições no que tange a previsões macroeconômicas. Giannone et al. (2008) desenvolveram um modelo para avaliar o impacto do uso de dados mensais para a previsão de um indicador trimestral de PIB; para isso utilizam uma análise de componentes principais (PCA) seguida de um suavizador Kalman. Como resultado, os autores constatam que seu método utilizando variáveis com alta frequência de atualização teve melhores resultados de previsão quando comparado a métodos que utilizam dados de mesma frequência.

2.2. MODELOS DE *MACHINE LEARNING* PARA PREVISÃO DO PIB

Ainda que os modelos econométricos estejam em constante evolução e sendo utilizados amplamente para a previsão de indicadores macroeconômicos, vêm se destacando no meio acadêmico técnicas de ML para esse objetivo, Tais técnicas se aproveitam da grande quantidade de dados e alto poder computacional disponível para previsões mais assertivas, principalmente em tempos de uma economia com períodos instáveis, como durante a pandemia da COVID-19 e a guerra da Ucrânia (SAGER, 2023).

Medeiros et al. (2021) observaram que as abordagens tradicionais de previsão de indicadores macroeconômicos enfrentam um desafio, pois não conseguem considerar adequadamente as complexas interações não lineares entre as variáveis econômicas. Portanto, propuseram diversos modelos de ML para prever a taxa de inflação nos Estados Unidos. Os resultados indicam que o *random forest* foi o modelo mais preciso, uma vez que tem um algoritmo próprio de seleção de variáveis, além de captar as relações não lineares entre as variáveis estudadas e a inflação, resultando em previsões mais precisas do que abordagens tradicionais. Os resultados de Adriansson et al. (2015) apontam para a mesma direção, quando

os autores partiram dos dados da Pesquisa de Tendência Econômica Sueca para prever o PIB trimestral da Suécia utilizando o *random forest*, concluindo que há benefícios preditivos em utilizar esse método em séries temporais econômicas.

Cepni et al. (2019) analisaram a utilidade de diversos métodos de ML como o *elastic net* e o *least absolute shrinkage and selection operator (*LASSO) para a previsão do PIB de economias emergentes. Os autores utilizam esses métodos principalmente na seleção de preditores e aliam tais preditores à um *dynamic factor model* (DFM), obtendo resultados melhores ao utilizar os dados com dimensão reduzida pelos métodos de ML do que sem essa etapa. Com propósitos semelhantes, Yoon (2020) faz um estudo que compara as previsões do PIB japonês geradas pelos métodos *gradient boosting* e *random forest* às previsões do Fundo Monetário Internacional (FMI) e do Banco do Japão, constatando que modelos de *gradient boosting* superaram a acurácia das tradicionais instituições na maioria do período. Porém, em 2009, ano após uma crise econômica global, as previsões do FMI foram mais assertivas que os modelos. O autor ainda conclui que enquanto os modelos econométricos são superiores em determinar a relação causal entre as variáveis preditoras e o indicador de interesse, os modelos de ML demostram ter maior poder de previsão.

Bantis et al. (2022) avaliaram a inclusão de dados provenientes do *Google Trends*, uma ferramenta que informa a quantidade de acessos que um certo termo de busca teve no *Google*, na construção de modelos de previsão do PIB do Brasil e dos Estados Unidos utilizando algoritmos de ML como o LASSO e o *elastic net*. A pesquisa teve resultados positivos ao constatar que o uso desses dados, que se enquadram na categoria de *big data*, aumentou a acurácia da previsão do PIB nos dois casos analisados.

A literatura sobre ML aplicado à previsão de indicadores macroeconômicos do Brasil é recente. Nolau et al. (2022) avaliaram o uso de algoritmos de aprendizado de máquina para a previsão da inflação e PIB do Brasil, concluindo que para a inflação, os métodos testados superaram os *benchmarks* nas previsões de curto prazo (até três meses), porém para o PIB ocorreu o contrário, onde eles superaram apenas no médio prazo (três a doze meses). Já Sager (2023) compara diferentes modelos de ML com o ARIMA para a previsão do crescimento do PIB brasileiro, concluindo que o modelo de melhor desempenho para o curto prazo foi o *random forest*, mas nenhum modelo testado obteve melhor resultado que o modelo auto-regressivo integrado de médias móveis (ARIMA) para horizontes de tempo mais longos.

2.3. MODELOS *ENSEMBLE* DE *MACHINE LEARNING*

Ensemble learning é um termo geral utilizado para métodos que combinam múltiplos indutores, isto é, múltiplos modelos com bases individuais. Assim, os métodos ensemble são considerados o estado da arte das soluções para os desafios de ML, uma vez que ao fazer a combinação de múltiplas previsões, assumindo que os erros de um modelo individual tendem a ser compensados pelos outros modelos. Portanto, espera-se que a previsão final do modelo combinado seja superior aos modelos simples (SAGI et al., 2018).

Existem três principais tipos de *ensemble learners*: *bagging*, *boosting* e *stacking*. *Bagging* envolve fazer múltiplas regressões em formato de árvore de decisão com diferentes amostras do mesmo conjunto de dados e fazer uma média das previsões. *Boosting* é uma técnica sequencial, onde cada nova regressão corrige os erros das anteriores, fazendo uma média ponderada das regressões feitas, dando mais peso para as últimas, obtendo-se a previsão final. *Stacking* utiliza diferentes tipos de modelos no mesmo conjunto de dados e ao final utiliza um outro modelo (geralmente linear) que aprende a agregar as previsões da melhor forma, utilizando como input as saídas dos modelos originais (BROWNLEE, 2021).

Buscando avaliar as vantagens desse método, Ribeiro et al. (2020) conduziram um estudo que visava comparar a acurácia de métodos de previsão de curto prazo dos preços de commodities agrícolas, tendo demonstrado vantagem para os modelos ensemble frente aos modelos individuais. A conclusão do estudo foi que os modelos ensemble apresentaram ganhos estatisticamente significativos, reduzindo erros de previsão nas séries temporais estudadas quando comparados com as referências de modelos individuais, que foram o *support vector machine* (SVM), *multilayer perceptron neural network* (MLP) e *K-nearest neighbors* (KNN).

Longo et al. (2022) propõem um *ensemble learner* para a previsão do PIB dos Estados Unidos, combinando um modelo de rede neural recorrente (RNN) com um modelo de fator dinâmico. Os resultados mostraram que o modelo combinado proposto melhorou as previsões principalmente em momentos de instabilidade, como em 2008 na crise financeira global, quando reduziu significativamente o erro de previsão para o trimestre e após o pico da COVID-19, quando previu de forma assertiva a recuperação da economia.

Soybilgen et al. (2021) utilizaram modelos *ensemble* de ML baseados em árvores (*bagged decision trees*, *random forests* e *stochastic gradient tree boosting*) para fazer o *nowcasting* do PIB dos Estados Unidos. Ao extraírem fatores dinâmicos de 10 grupos de variáveis

macroeconômicas para alimentar o modelo, concluíram que o *ensemble learner* proposto supera modelos tradicionais lineares na previsão de curto prazo.

2.4. SELEÇÃO DE VARIÁVEIS

A existência de um número expressivo de dados disponíveis para análises e aplicações de modelos de previsão se torna uma oportunidade, mas também um desafio, pois muitos desses dados podem ser irrelevantes ou redundantes, o que pode elevar o custo para coleta dos dados, aumentar o tempo de processamento computacional, diminuir acurácia e reduzir a interpretabilidade dos resultados. Para a solução desses desafios, principalmente em se tratando de aplicações de ML, existem métodos de seleção de variáveis explicativas (*feature selection*) que visam reduzir o número de variáveis necessárias nos modelos, mantendo ou até melhorando sua eficácia (CAI et al., 2018).

Anzanello et al. (2013) propuseram um método de identificação do melhor subconjunto de variáveis para previsões no contexto industrial a partir da geração de índices de importância derivados da regressão *partial least square* (PLS), resultando na eliminação de variáveis irrelevantes. O método proposto reteve menos variáveis quando comparado aos métodos comparativos e aumentou em 6% a acurácia de predição nos bancos de dados testados, superando a acurácia do tradicional método *Stepwise*.

Che et al. (2017) propuseram um novo método para seleção de variáveis, o *normalization of maximum relevance and minimum common redundancy* (N-MRMCR-MI), que pode ser utilizado em bancos de dados de diferentes áreas de estudo onde os dados não são lineares. Quando comparados em previsões utilizando diferentes modelos de previsão via ML, o método supera algoritmos considerados o estado da arte em seleção de variáveis, como o *joint mutual information* (JMI) e o *normalized mutual information feature selection* (NMIFS), reduzindo a redundância e aumentando a relevância das variáveis selecionadas.

No contexto de seleção de variáveis para previsões macroeconômicas, Li et al. (2022) propõem um framework de três etapas para extrair as variáveis mais significativas para a previsão do PIB de determinadas regiões chinesas. As etapas propostas consistem em um cruzamento entre as *features* na busca de informações escondidas, seguido de uma análise de correlação utilizando os algoritmos *BorutaRF* e *Q-Learning* para capturar as variáveis de maior qualidade a partir de duas perspectivas distintas. O estudo constata que o processo de seleção de variáveis proposto aumenta a acurácia das previsões em mais de 10%, quando comparado ao uso de todas as variáveis originais.

Além dos trabalhos citados, existem autores que fizeram o uso de métodos de seleção de variáveis nativos dos modelos de regressão utilizados, como é o caso de Medeiros et al. (2021) com o uso do *random forest* para a previsão do PIB americano e de Cepni et al. (2019) com o uso do LASSO para previsão do PIB de economias emergentes, conforme exposto na seção 2.2.

3. PROCEDIMENTOS METODOLÓGICOS

3.1. DESCRIÇÃO DO CENÁRIO

No contexto de um mundo VUCA (volátil, incerto, complexo e ambíguo), o Brasil se destaca como um país emergente com uma economia em desenvolvimento e inserida em cadeias globais de valor. Além disso, sua trajetória tem sido influenciada por eventos atípicos, como a pandemia de COVID-19 e instabilidades geopolíticas. É nesse cenário de aparente imprevisibilidade que este estudo se encaixa, objetivando prever o PIB do Brasil utilizando técnicas avançadas de ML para antecipar flutuações econômicas, contribuindo assim para uma melhor tomada de decisões. Dado o histórico de turbulência econômica no país e as interconexões com a economia global, uma previsão precisa do PIB se torna uma condição essencial para orientar políticas econômicas, estratégias de investimento e adaptações diante de perturbações inesperadas.

3.2. CLASSIFICAÇÃO DA PESQUISA

Gerhardt et al. (2009) classificam pesquisas em quatro critérios: natureza, abordagem, objetivos e procedimentos. Esta pesquisa classifica-se, quanto à natureza, como aplicada, uma vez que trata da resolução de um problema específico, relacionado à previsão do PIB em um cenário complexo. Quanto à abordagem, classifica-se como quantitativa, pois utiliza métodos matemáticos e modelos de ML para a previsão. Em relação aos objetivos, trata-se de uma pesquisa explicativa, que trata de modelos de previsão de um indicador macroeconômico. Por fim, quanto ao procedimento, classifica-se como estudo de caso, visto que o estudo abrange técnicas consolidadas de análise em um banco de dados com vistas a traçar conclusões.

3.3. ETAPAS DA PESQUISA

Nesta subseção são abordados os passos metodológicos do estudo. O subitem 3.3.1. detalha a obtenção dos dados a serem modelados, assim como os tratamentos a que esses dados foram submetidos. Após isso, os subitens 3.3.2. e 3.3.3. trazem o mecanismo dos modelos individuais de ML utilizados (*random forest* e *gradient boosting*), quando também serão explicados os funcionamentos de seus algoritmos internos de avaliação de variáveis. O subitem 3.3.4. traz

então o procedimento para combinação de modelos através do *ensemble* do tipo *stacking*. Finalmente o subitem 3.3.5. traz brevemente os conceitos de *expanding window* e as métricas de avaliação dos modelos utilizadas no estudo. A Figura 1 traz uma representação das etapas do estudo, as quais são detalhadas na sequência.

Todas as etapas de tratamento, modelização e avaliação descritas nessa seção foram realizadas na linguagem de programação *Python* utilizando as seguintes bibliotecas: *Pandas, Numpy, Matplotlib, Seaborn* e *Sklearn.*

Figura 1 – Etapas do trabalho

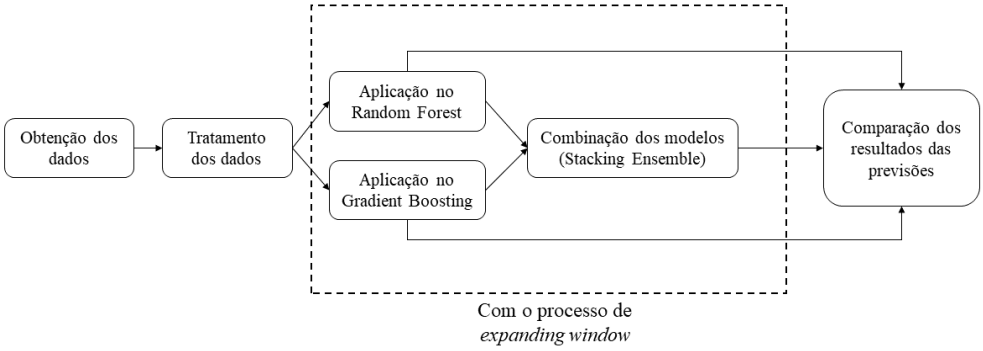

Fonte: Elaboração própria (2023)

3.3.1. COLETA E TRATAMENTO DOS DADOS

Neste estudo foram utilizadas diferentes variáveis independentes para atuarem como preditoras nos modelos de previsões propostos. Foram utilizadas 21 séries de dados (além do PIB mensal) de fontes públicas, baseadas nas proposições de Kagohara (2015), Medeiros et al. (2021) e Sager (2023), os quais trabalharam com previsões de indicadores macroeconômicos. Todas as séries têm uma divulgação mais adiantada do que a do PIB. As variáveis foram selecionadas de forma a evitar redundância e elas se relacionam com a macroeconomia de diferentes formas, incluindo aspectos da indústria, energia, serviços, indicadores financeiros, dentre outros, buscando-se uma visão global de aspectos que influenciam no PIB. Todas as séries têm periodicidade mensal, início em janeiro de 2002 e se estendem até agosto de 2023, totalizando 260 observações para cada variável. A lista completa de variáveis, assim como informações adicionais são apresentadas na Tabela 1.

Em relação ao tratamento desses dados, foi realizada a transformação de todas as variáveis em sua variação percentual (exceto IPCA e IBOVESPA que já estavam nesse formato), conforme demonstrado na equação (1), reduzindo a variabilidade e ruídos para as previsões

nos modelos e captando a interação entre as taxas de variação das *features*. Nota-se que a primeira observação (janeiro de 2002) é perdida nesse processo, restando assim 259 observações. Ao final, as previsões são revertidas para os valores originais através do produto cumulativo das variações percentuais multiplicado pelo valor inicial da janela, conforme demonstrado na equação (2), de forma a facilitar a análise gráfica e comparação das métricas.

$$variação\ \% = \frac{valor\ atual}{valor\ anterior} - 1 \qquad (1)$$

$$valor\ revertido = (1 + variação\ \%\ acumulada) * valor\ inicial\ original\ da\ janela \qquad (2)$$

Tabela 1 – Séries de dados utilizadas neste estudo

Temática	Variável	Unidade	Fonte
Contas Nacionais	**PIB Mensal**	R$ Milhões	BCB
Balança Comercial	**Índice de preços das exportações**	Índice (média 2018 = 100)	FUNCEX
	Índice de preços das importações	Índice (média 2018 = 100)	FUNCEX
	Importações (FOB)	US$	SECEX
	Exportações (FOB)	US$	SECEX
Commodities	**Preço Soja**	US$	FMI
	Preço Açúcar	US$	FMI
Energia	**Vendas, pelas distribuidoras, dos derivados combustíveis de petróleo**	Barris	ANP
	Consumo de Energia Elétrica	GWH	Eletrobras
Financeiro	**M0 - Base monetária restrita**	R$ Milhões	BCB
	M1 - Moeda em poder do público	R$ Milhões	BCB
	Média mensal EMBI+ Brasil (Emerging Markets Bond Index)	Índice (pontos base)	JP Morgan
	Taxa de juros - Over / Selic (Sistema Especial de Liquidação e de Custódia)	% a.m	BCB
	Ibovespa (Índice da Bolsa de Valores de São Paulo)	Variação % a.m	ANBIMA
Indústria	**Produção Setor - Indústria Geral**	Índice (Base 100)	IBGE
	Produção Categoria - Bens de consumo semiduráveis e não duráveis	Índice (Base 100)	IBGE

	Produção de Autoveículos Total	Unidades	ANFAVEA
Internacional	**Dólar**	R$	BCB
	Taxa de Juros PRIME USA	% a.m	FED
Preços	**IPCA - Índice Nacional de Preços ao Consumidor Amplo**	Variação % a.m	IBGE
Serviços	**ICC - Índice de Confiança do Consumidor**	Índice (Base 200)	Fecomercio-SP
Trabalho	**Estoque de empregos formais**	Unidades	Ministério da Economia

Fonte: Elaboração própria (2023)

3.3.2. MODELAGEM POR *RANDOM FOREST REGRESSION*

Random forest regression é um algoritmo supervisionado de ML que faz uma combinação de múltiplas árvores de decisão para uma regressão, formando uma floresta, e é utilizado neste estudo conforme foi descrito por Breiman (2001). De forma geral, o algoritmo possui três etapas principais:

i) Construção das árvores: constrói um conjunto de árvores de decisão independentes, onde cada árvore seleciona variáveis aleatoriamente e utiliza uma amostra aleatória dos dados de treinamento (*bootstrapping*).

ii) Treinamento das árvores: cada árvore é treinada para fazer previsões com base nas características dos dados de entrada. Elas dividem os dados em subconjuntos baseados nas características, criando uma estrutura hierárquica de decisões.

iii) Votação e previsão: cada árvore da floresta faz uma previsão individual e posteriormente são combinadas para formar uma previsão final.

Estas etapas fazem com que haja uma redução de *overfitting* no modelo, uma vez que a combinação das árvores com suas componentes aleatórias suaviza as previsões (BREIMAN, 2001). Matematicamente, uma *random forest* é definida pela equação (3),

$$f_{rf}^{K}(x) = \frac{1}{K}\sum_{k=1}^{K} T(x) \qquad (3)$$

onde f_{rf}^{K} é a variável predita, (x) o vetor de input com valores de diferentes variáveis em um dado conjunto dos dados de treino, K é o número de árvores de regressão e $T(x)$ é o resultado de cada árvore de regressão. A Figura 2 demonstra o funcionamento do algoritmo.

Por fim, ressalta-se que o *random forest* também foi utilizado para a avaliação das variáveis através do seu atributo de *feature importance* (importância de cada variável), que fornece uma pontuação de importância baseada na contribuição de cada variável no modelo, que é possível dada a natureza aleatória de escolha de variáveis e o *bootstrapping* realizado pelo algoritmo.

Figura 2 – Funcionamento do *random forest regression*

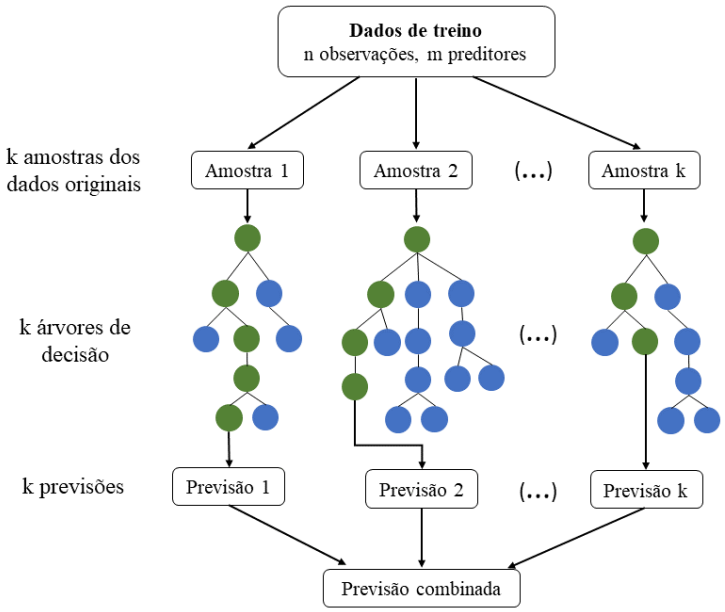

Fonte: Adaptado de Rodriguez-Galiano et al. (2016)

3.3.3. MODELAGEM POR *GRADIENT BOOSTING REGRESSION*

Gradient boosting regression é um algoritmo supervisionado de ML que faz uma combinação de múltiplos modelos-base fracos, isto é, de baixa complexidade (geralmente árvores de decisão), formando um modelo com mais acurácia e robustez. Nas proposições deste estudo, é implementado conforme foi descrito por Friedman (2001). De forma geral, o algoritmo possui três etapas principais:

i) Previsões iniciais: realizam-se previsões iniciais utilizando os modelos base (árvores de decisão), seguidos dos cálculos das perdas, isto é, a discrepância entre valores reais e previsões iniciais.

ii) Ajuste de um novo modelo: uma nova árvore de decisão é ajustada às perdas calculadas, buscando capturar padrões não explicados pelo modelo anterior.

iii) Iteração: a etapa anterior é repetida iterativamente, atualizando as previsões do modelo base e do modelo ajustado às perdas, visando minimizar o gradiente da função de perda em relação aos resíduos e assim, refinando as previsões ao longo das iterações.

Essas etapas fazem com que o modelo aprimore suas previsões progressivamente, fazendo dele um modelo sequencial aditivo, e não paralelo como o *random forest* (FRIEDMAN, 2001). Matematicamente, as iterações do algoritmo podem ser descritas como na equação (4):

$$f_t(x) = f_{t-1}(x) - \rho_t \frac{\partial \mathrm{L}(\mathrm{f(x)})}{\partial \mathrm{f(x)}}\Big|_{\mathrm{f(x)}=f_{t-1}(x)} \qquad (4)$$

onde $f_t(x)$ é o modelo conjunto após a iteração *t*, $L(f(x))$ é a função de perda, $\frac{\partial \mathrm{L}(\mathrm{f(x)})}{\partial \mathrm{f(x)}}$ é o gradiente da função de perda *L* e ρ_t é a taxa de aprendizado da iteração *t* (IZENMAN, 2008). A Figura 3 ilustra o funcionamento do algoritmo.

Figura 3 – Representação esquemática das iterações do *gradient boosting regression*

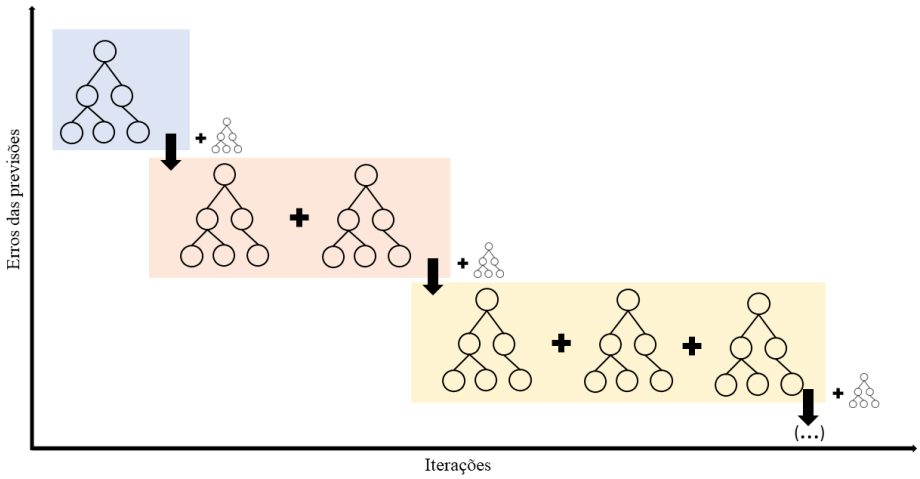

Fonte: Adaptado de Baturynska et al. (2020)

Por fim, ressalta-se que o *gradient boosting*, assim como o *random forest*, também foi utilizado para a avaliação das variáveis através do seu atributo de *feature importance*. Apesar de possuir o mesmo nome do modelo anterior, este último difere no funcionamento por atribuir a importância das variáveis com base na frequência que elas são utilizadas para tomar decisões nas árvores do conjunto, associando uma importância maior para as variáveis que reduzem mais os erros no processo iterativo de treinamento.

3.3.4. GERAÇÃO DO MODELO *ENSEMBLE* DO TIPO *STACKING*

Stacking ensemble learning são modelos que utilizam a combinação de dois ou mais modelos individuais, visando melhorar o desempenho da predição, e é utilizado neste estudo conforme descrito por Brownlee (2021). Pode-se descrever esse método em 3 etapas:

i) Treinamento dos modelos base: treinamento dos modelos base individualmente (no caso deste estudo, realização das etapas 3.3.2 e 3.3.3).

ii) Criação do meta-modelo: cria-se um modelo de agregação que combina as previsões dos modelos base de forma ponderada. Este meta-modelo é mais simples, deixando a complexidade nos modelos base. Neste estudo utiliza-se uma regressão linear para a combinação.

iii) Previsões: as saídas dos modelos base alimentam o meta-modelo, gerando as previsões.

Essas características fazem dos modelos *ensemble* do tipo *stacking* um método eficaz, pois exploram as diferentes capacidades dos modelos base para melhorar a precisão e generalização das previsões (BROWNLEE, 2021). A representação do modelo *ensemble* do tipo *stacking* encontra-se na Figura 4.

Figura 4 – Modelo *ensemble* do tipo *stacking* utilizado

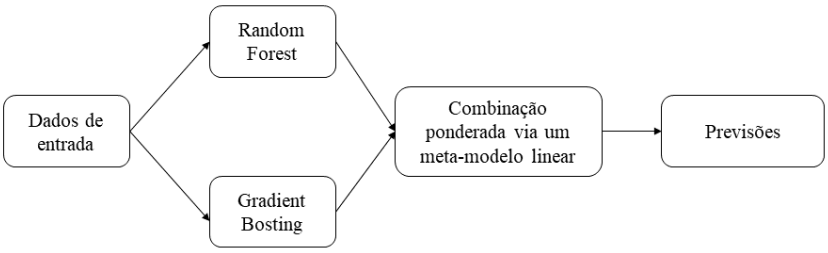

Fonte: Adaptado de Brownlee (2021)

3.3.5. *EXPANDING WINDOW* E MÉTRICAS DE AVALIAÇÃO

Ainda que os métodos de previsão utilizados no estudo sejam robustos à *overfitting*, pretende-se evitar esse problema através da técnica da *expanding window* conforme aplicado por Markudova et al. (2021). Este procedimento atua como uma validação cruzada adaptada para séries temporais, uma vez que ela impede que dados futuros sejam usados para prever

dados passados. O funcionamento, demonstrado na Figura 5, consiste em dividir os dados em conjuntos de treino (representado pelos círculos azuis) e teste (representado pelos círculos verdes) ao longo de toda a extensão da série, com um incremento progressivo no período de treinamento.

Neste estudo, o processo se inicia com um período de treino de 55 meses (os 55 primeiros meses), seguido por *n* meses subsequentes (onde *n* assume valores predefinidos de 1, 3, 6 ou 12 meses, representando os horizontes de previsão), que constituem o período de teste do modelo. De maneira iterativa, o período de treino é então incrementado em *i* meses, sendo *i* o mesmo valor de *n* para cada rodada do processo. Os valores de *n* (tamanho, em meses, do horizonte de previsão do teste) e *i* (incremento, em meses, do período de treino) são iguais e constantes, assumindo valores de 1, 3, 6 ou 12. Essa abordagem visa avaliar continuamente a capacidade de aprendizado e adaptabilidade do modelo a novos dados. O modelo é treinado exclusivamente com os dados de treino, sendo desafiado pelos dados "novos" do conjunto de teste. Ao realizar essa iteração ao longo de toda a extensão da série temporal, assegura-se uma avaliação menos suscetível às particularidades de pontos específicos no tempo.

Figura 5 – Funcionamento da técnica de *expanding window*

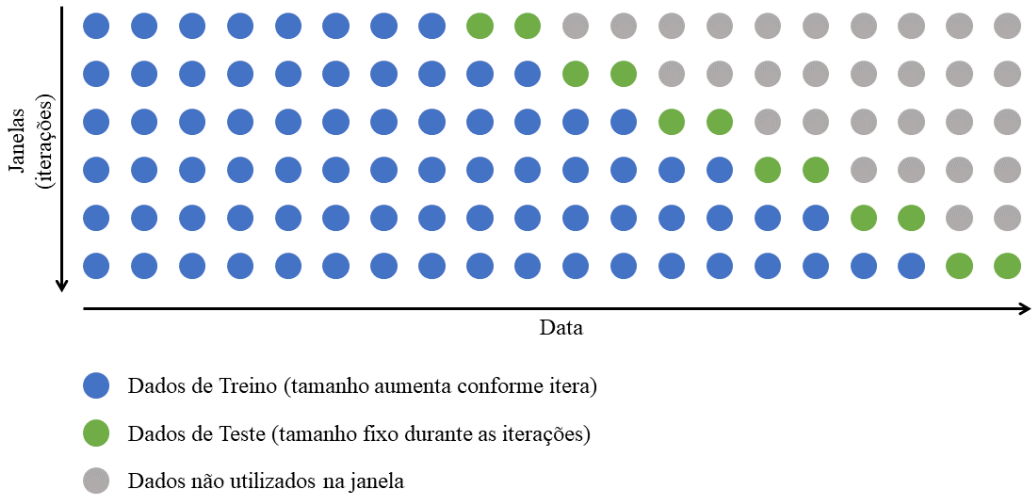

Fonte: Adaptado de Markudova et al. (2021)

Por fim, visando uma comparação quantitativa dos resultados que complementem a análise gráfica, utilizam-se três métricas de avaliação comumente utilizadas na literatura na porção de teste: Erro Médio Absoluto (MAE), Erro Percentual Absoluto Médio (MAPE) e Erro Quadrático Médio (RMSE), conforme descrito em González-Sopeña (2021).

O MAE, conforme descrito na equação (5), é a média da distância euclidiana (diferença absoluta) entre os valores observados (y_i) e os valores previstos ($\hat{y}_i$) fornecendo uma medida da magnitude média do erro entre as previsões e os valores reais de m amostras.

$$\mathrm{MAE} = \frac{1}{m} \sum_{i=1}^{m} | y_i - \hat{y}_i | \qquad (5)$$

O MAPE, conforme descrito na equação (6), é a média das porcentagens de erro absoluto entre os valores observados (y_i) e os valores previstos ($\hat{y}_i$), expresso como uma porcentagem, o que o torna uma medida relativa de erro adequada para comparar diferentes séries temporais.

$$\mathrm{MAPE} = \frac{1}{m} \sum_{i=1}^{m} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \qquad (6)$$

O RMSE, conforme descrito na equação (7), é a raiz da média dos quadrados das diferenças entre os valores observados (y_i) e os valores previstos ($\hat{y}_i$), enfatizando erros maiores e penalizando mais fortemente previsões distantes dos valores reais.

$$\mathrm{RMSE} = \sqrt{\frac{1}{m} \sum_{i=1}^{m} (y_i - \hat{y}_i)^2} \qquad (7)$$

4. RESULTADOS E DISCUSSÃO

Nesta seção, são apresentados os principais resultados do estudo da utilização de um modelo *ensemble stacking* aplicado à previsão do PIB brasileiro, com enfoque na comparação dessa metodologia com outros 2 modelos: *random forest regression* e *gradient boosting regression* em quatro horizontes de previsão diferentes: 1, 3, 6 e 12 meses. Os achados são expostos de maneira detalhada, buscando não apenas descrever as conclusões numéricas, mas também contextualizar o significado subjacente a esses resultados.

4.1. ANÁLISE EXPLORATÓRIA

A Figura 6 exibe a série temporal alvo deste estudo, ilustrando o PIB brasileiro de janeiro de 2002 até agosto de 2023. Percebe-se um evidente comportamento crescente ao longo do tempo. Além disso, ao analisar o desvio padrão da série, plotado em janelas de tamanho igual a 12 meses na Figura 7, percebe-se que ela mantém estabilidade até 2020, a partir de quando possui uma variação mais evidente (possivelmente em decorrência da pandemia de COVID-19).

Figura 6 – Série temporal do PIB brasileiro

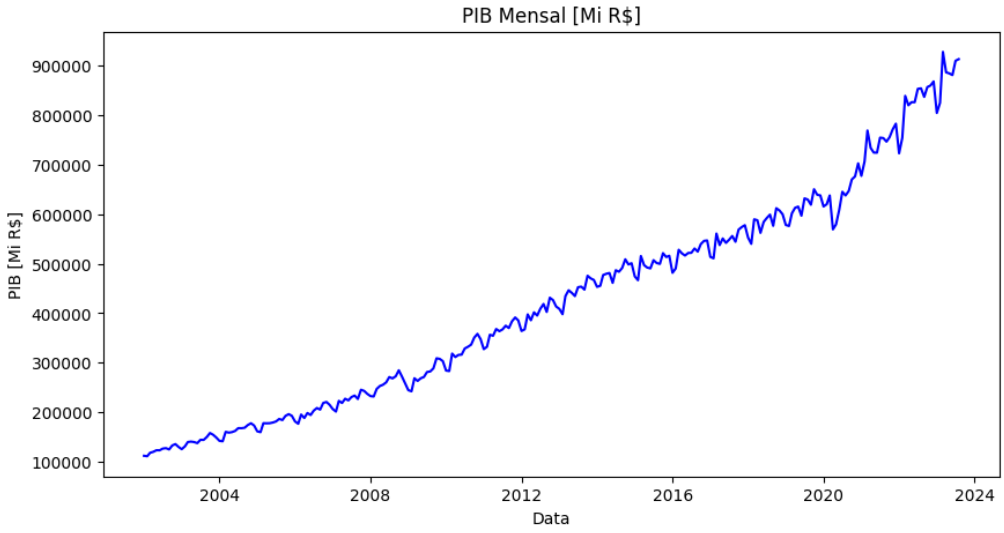

Fonte: Elaboração própria (2023)

Figura 7 – Desvio padrão do PIB brasileiro (em janelas de 12 meses)

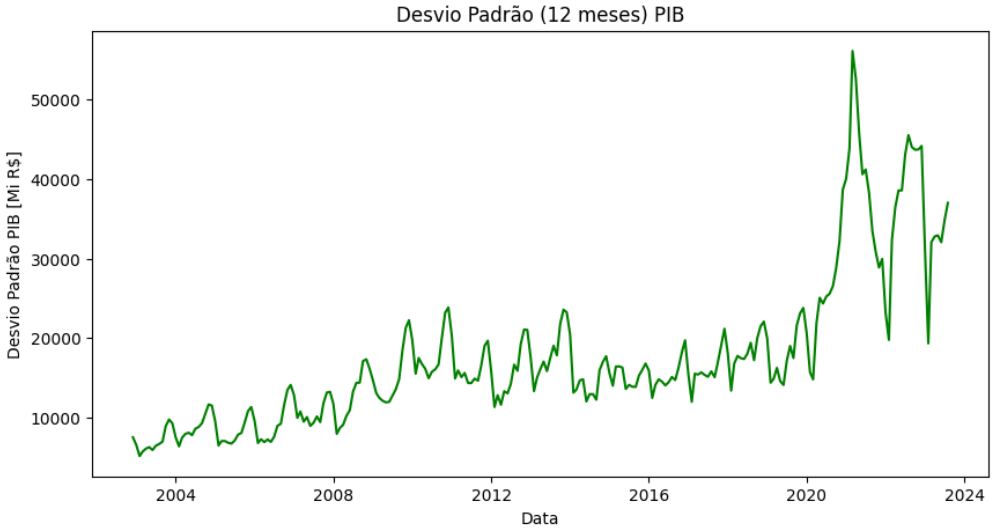

Fonte: Elaboração própria (2023)

Em seguida, na Figura 8, apresenta-se a série transformada em variação percentual, operação explicada na subseção 3.3.1. Esta série é utilizada em todos as modelagens. Porém, para fins de aplicação prática, visualização e comparação de resultados, todos os gráficos e métricas de erro utilizadas nesta seção serão transformadas nos valores originais.

Figura 8 – Série temporal da variação percentual do PIB brasileiro

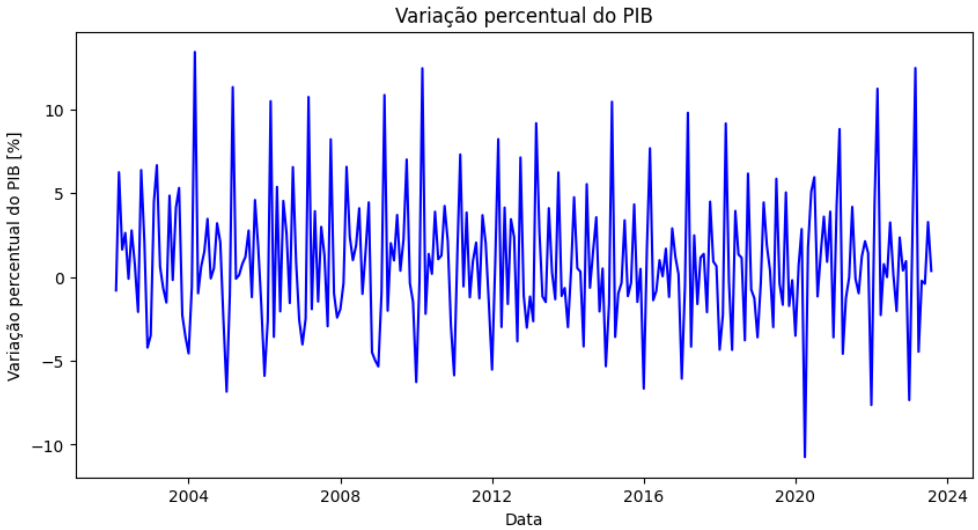

Fonte: Elaboração própria (2023)

4.2. COMPARAÇÃO PREVISTO *VERSUS* REALIZADO

A comparação entre as séries temporais prevista e realizada é essencial para avaliar a acurácia de um modelo preditivo e entender a capacidade do mesmo em antecipar flutuações e tendências reais. A análise visual desempenha um papel importante nesse processo, permitindo a identificação de padrões, divergências e consistências entre as previsões e os resultados observados. Considerando isso, as Figuras 9 a 11 demonstram, respectivamente para o *random forest*, *gradiente boosting* e *ensemble stacking*, os gráficos de valores previstos *versus* realizados do PIB brasileiro em Milhões de Reais, subdivididos nos quatro horizontes de previsão alvos deste estudo. É importante ressaltar que a série prevista é referente aos valores das janelas de teste do processo de *expanding window*; tais valores foram concatenados e plotados de forma sequencial para facilitar a visualização.

Figura 9 – Séries previstas pelo *random forest* e realizada do PIB mensal [Mi R$] em distintos horizontes de previsão

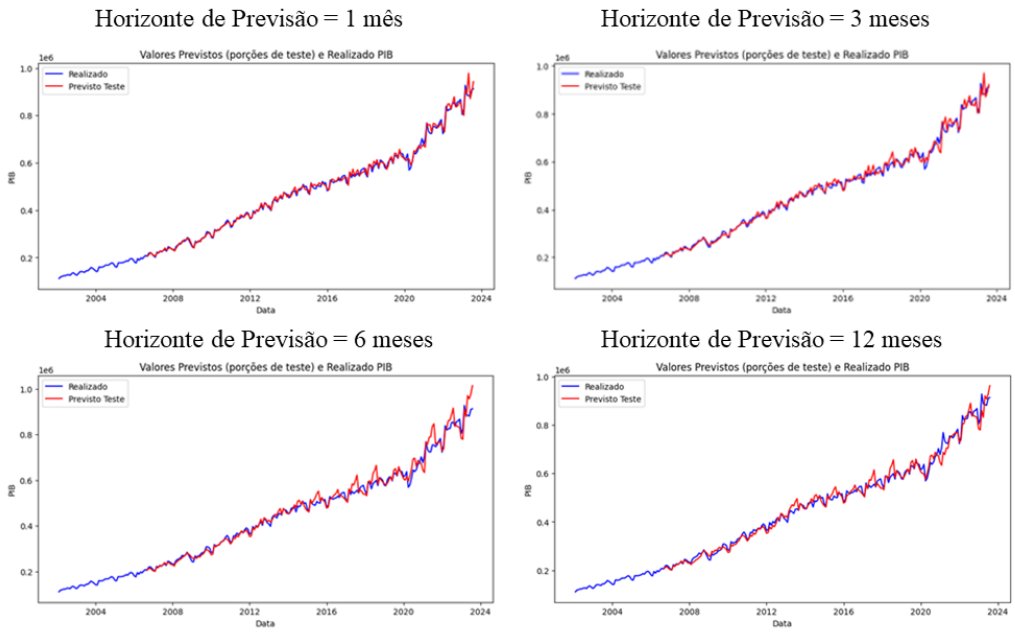

Fonte: Elaboração própria (2023)

Figura 10 – Séries previstas (pelo *gradient boosting*) e realizada do PIB [Mi R$] em distintos horizontes de previsão

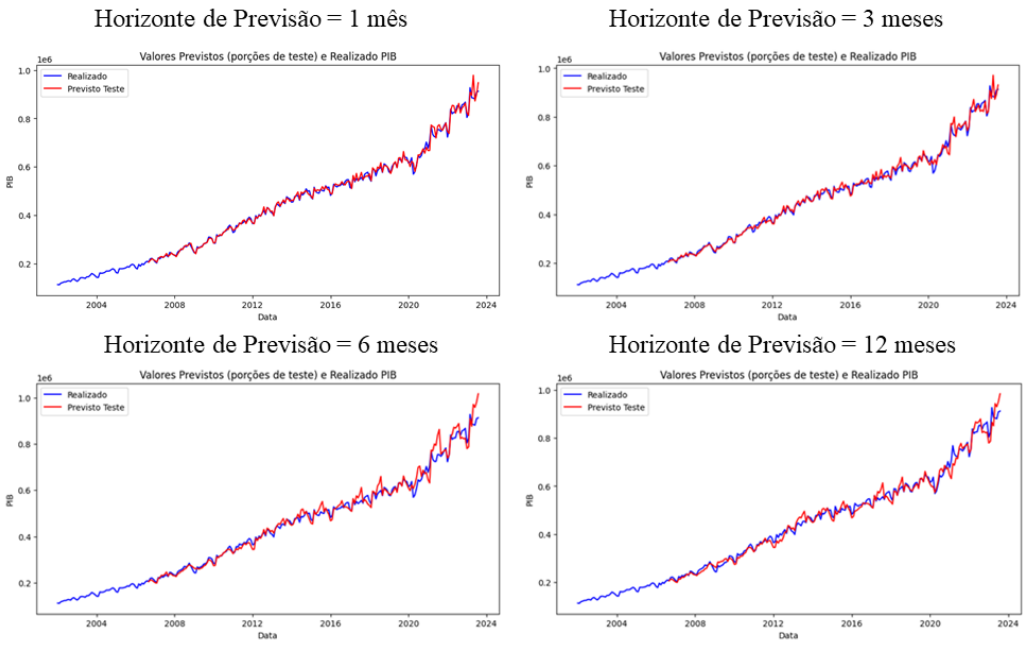

Fonte: Elaboração própria (2023)

Figura 11 – Séries previstas (pelo *ensemble stacking*) e realizada do PIB [Mi R$] em distintos horizontes de previsão

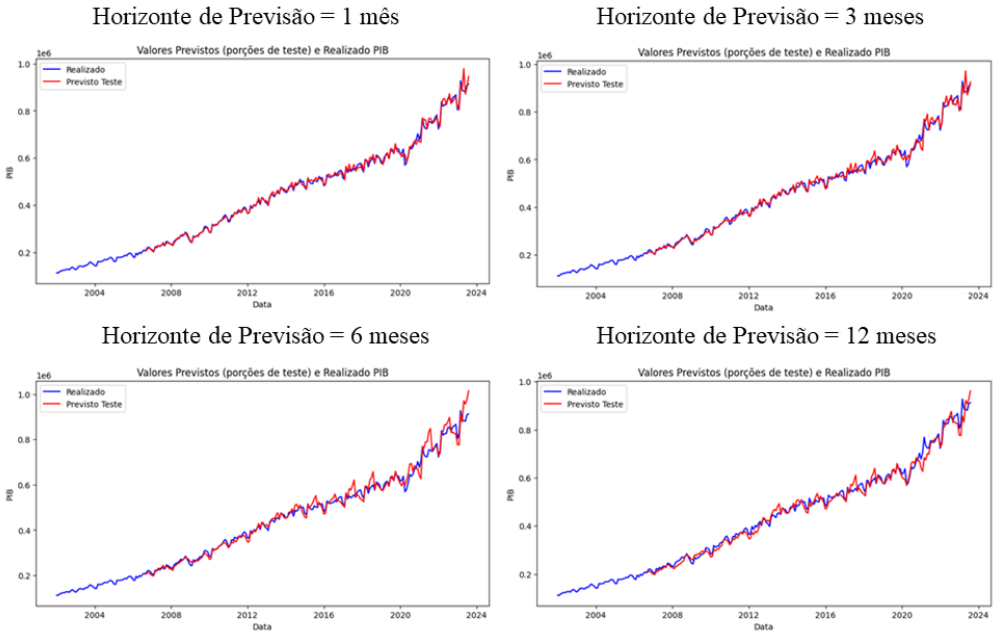

Fonte: Elaboração própria (2023)

Nota-se uma similaridade entre as séries previstas pelos modelos utilizados quando comparados em cada um dos quatro horizontes de previsão apresentados. Todas aparentam uma concordância entre os valores previstos e realizados, com destaque para os horizontes de previsão mais curtos (1 e 3 meses), que capturam as tendências e os padrões temporais de forma efetiva nos três modelos testados. Já para os horizontes de previsão mais longos (6 e 12 meses) existem desvios perceptíveis, uma vez que em alguns pontos há um descolamento entre as séries prevista e realizada, padrão que se repete para os três modelos testados. Analisando visualmente as previsões dos modelos contra os valores realizados apenas, não é possível identificar diferenças substanciais entre eles.

4.3. ANÁLISE DA DISPERSÃO DOS ERROS DE PREVISÃO

Embora a análise visual "previsto *versus* realizado" seja crucial para perceber a aderência dos modelos à série de dados estudada, é importante reconhecer que apenas essa abordagem não é suficiente para uma comparação completa dos modelos nos diversos horizontes de previsão. Portanto, além das métricas de erro que serão abordadas em seguida, complementa-se a avaliação gráfica com a dispersão temporal dos erros das previsões no período de teste, apresentadas nas Figuras 12 a 14 (uma para cada modelo analisado).

Essa abordagem visual proporciona uma representação dinâmica das discrepâncias entre os valores previstos e os valores realizados ao longo do tempo. A interpretação dos padrões de dispersão temporal é um instrumento para identificar tendências, sazonalidades ou eventos específicos que podem impactar o desempenho dos modelos de previsão. Destaca-se que o erro foi calculado pela diferença entre os valores previstos nas porções de teste e os valores realizados.

Figura 12 – Dispersão temporal dos erros de previsão (*random forest*) em distintos horizontes de previsão

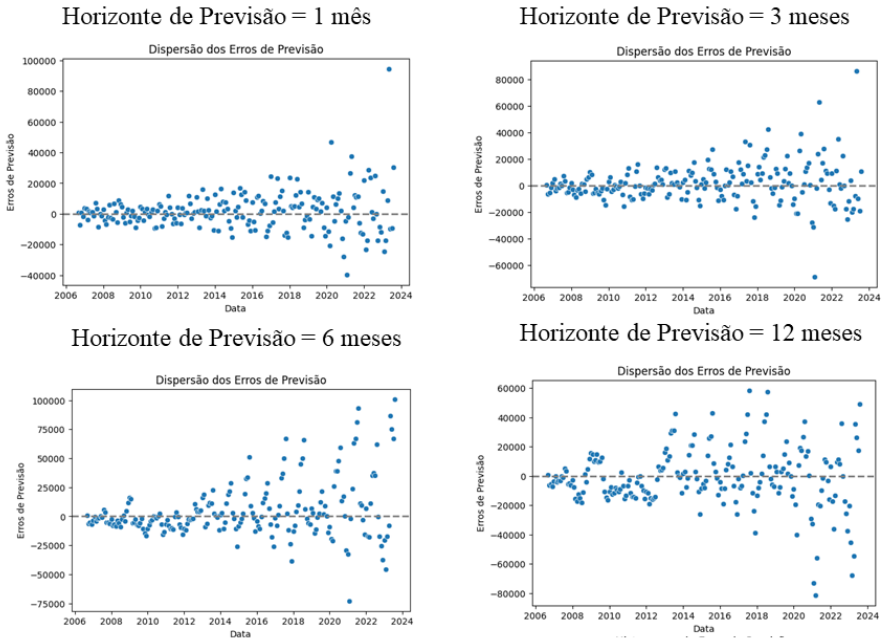

Fonte: Elaboração própria (2023)

Figura 13 – Dispersão temporal dos erros de previsão (*gradient boosting*) em distintos horizontes de previsão

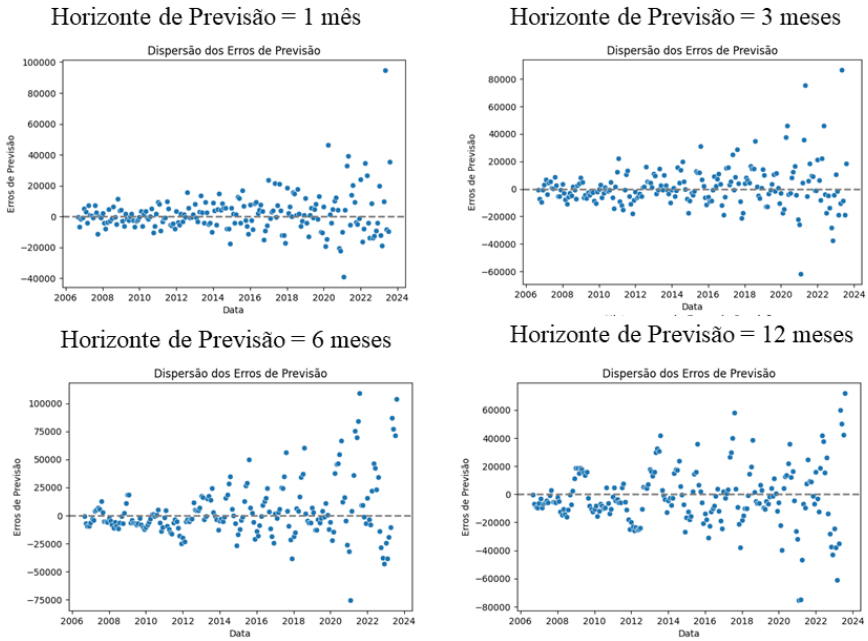

Fonte: Elaboração própria (2023)

Figura 14 – Dispersão temporal dos erros de previsão (*ensemble stacking*) em distintos horizontes de previsão

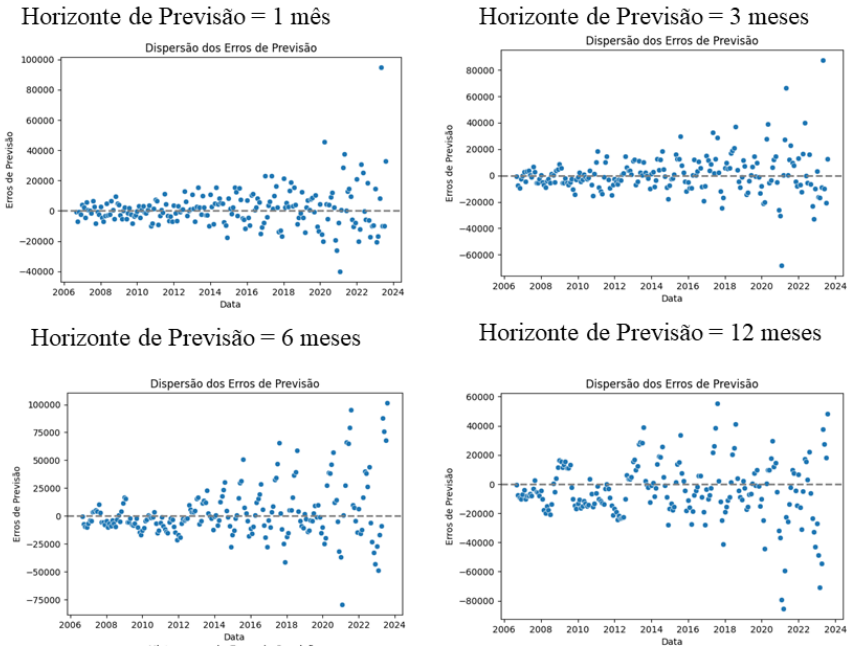

Fonte: Elaboração própria (2023)

Ao examinar os resultados de todos os modelos e horizontes de tempo avaliados, observa-se uma tendência de aumento na dispersão dos erros ao longo do tempo. Este padrão é justificável, uma vez que a magnitude dos valores na série temporal cresce progressivamente com o passar do tempo. Além disso, o desvio padrão da série também aumenta, contribuindo para uma maior variabilidade nos erros e, consequentemente, tornando mais desafiadora a tarefa dos modelos em manter uma precisão consistente nos períodos mais recentes.

Como comportamento geral, destaca-se que os erros associados a horizontes de previsão mais curtos tendem a exibir menor dispersão, enquanto horizontes mais longos apresentam maior variabilidade. Este fenômeno é coerente com a observação das séries previstas e realizadas, reforçando a ideia de que a complexidade do desafio preditivo aumenta proporcionalmente ao horizonte temporal considerado, conforme evidenciado por Hyndman et al. (2018). Vale ressaltar que, ao comparar os mesmos horizontes de previsão entre diferentes modelos, foi evidenciado um comportamento notavelmente semelhante, indicando consistência nas tendências observadas independentemente do método de modelagem empregado.

Como complemento às análises visuais já conduzidas sobre a dispersão temporal dos erros de previsão, geraram-se gráficos de *boxplots* ilustrando a distribuição dos erros de previsão dos períodos de teste, conforme evidenciado nas Figuras 15 a 17 (uma para cada modelo analisado).

A relevância de avaliar um *boxplot* está na capacidade de fornecer informações mais detalhadas sobre a distribuição estatística dos erros, destacando características como mediana, quartis e a presença de possíveis outliers. Enquanto a dispersão temporal oferece uma visão cronológica, os *boxplots* complementam essa perspectiva, permitindo uma compreensão mais profunda das características centrais e da variabilidade dos erros de previsão em cada horizonte avaliado. Assim, ao considerar ambos os aspectos, temporalidade e distribuição estatística, obtém-se uma visão mais abrangente e robusta do desempenho dos modelos em diferentes horizontes de previsão.

Figura 15 – *Boxplot* dos erros de previsão (*random forest*) em distintos horizontes de previsão

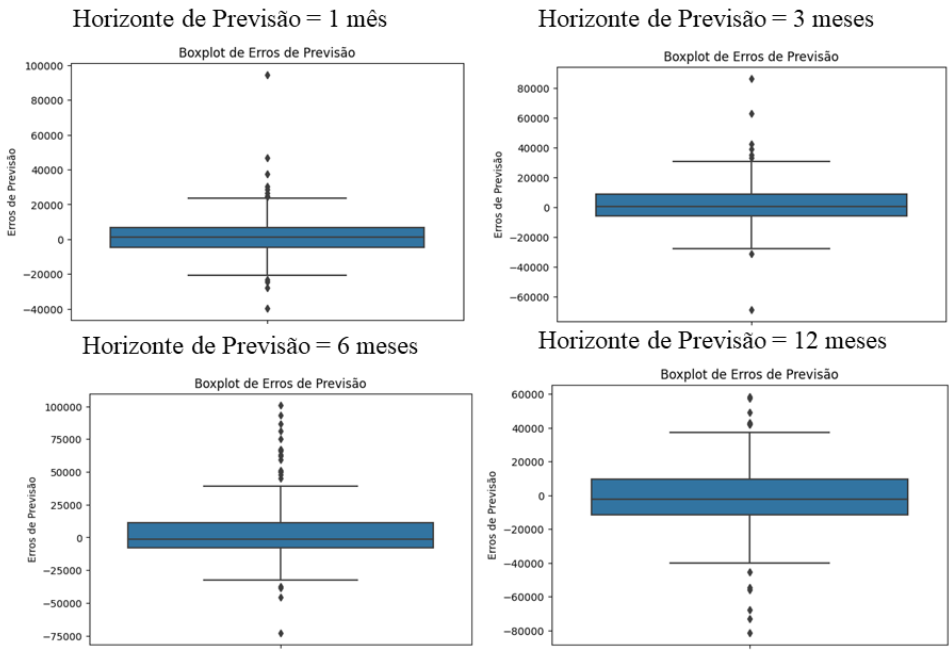

Fonte: Elaboração própria (2023)

Figura 16 – *Boxplot* dos erros de previsão (*gradient boosting*) em distintos horizontes de previsão

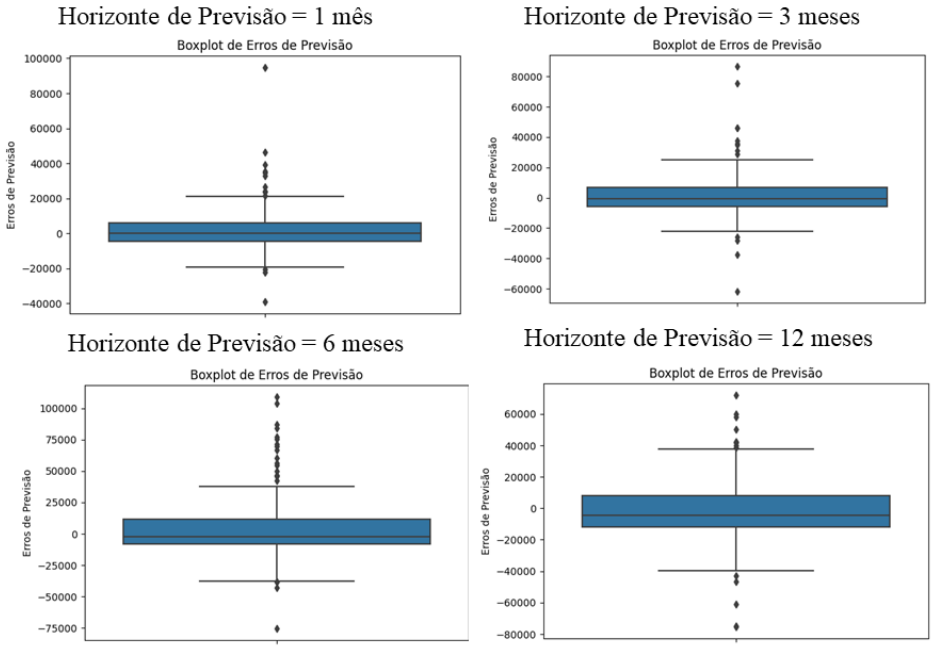

Fonte: Elaboração própria (2023)

Figura 17 – *Boxplot* dos erros de previsão (*ensemble stacking*) em distintos horizontes de previsão

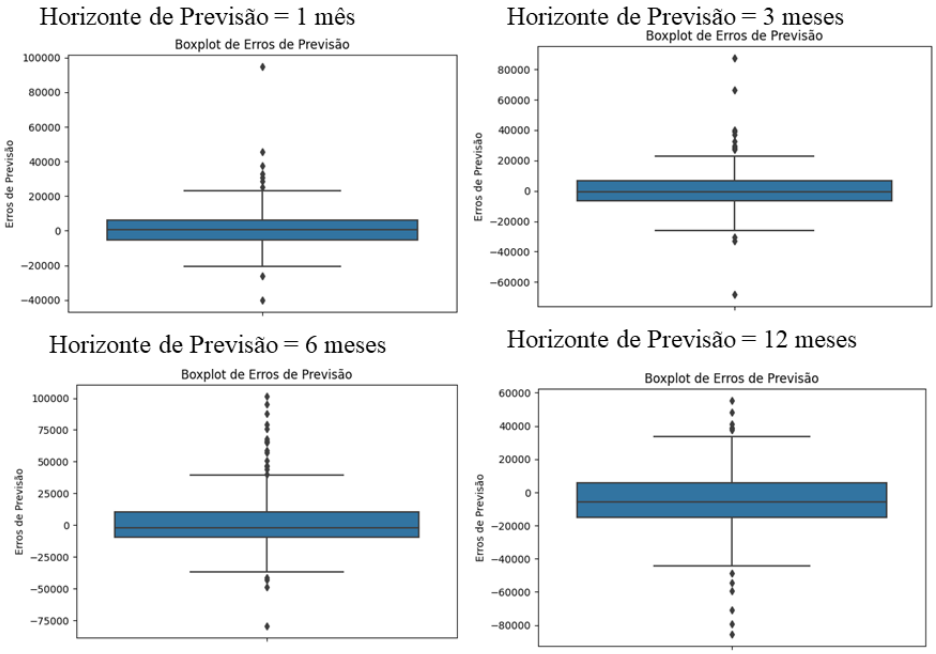

Fonte: Elaboração própria (2023)

Ao analisar os erros de previsão em todos os modelos e horizontes de tempo avaliados, destaca-se que os erros se concentram aproximadamente em torno do zero. Esse padrão sugere, possivelmente, a presença de pouco viés nos modelos, indicando uma capacidade geral de prever valores próximos aos observados. Como já verificado em análises anteriores, observa-se um comportamento geral em que os erros para horizontes de previsão mais curtos tendem a apresentar uma distribuição "achatada" nos *boxplots*, indicando menor dispersão entre o 1º e 3º quartil em comparação aos horizontes de previsão mais longos.

De forma geral, os modelos exibem padrões de comportamento bastante semelhantes, destacando uma uniformidade nas características dos erros entre os diferentes métodos de modelagem. Além disso, destaca-se maior presença de outliers positivos para os horizontes de 1, 3 e 6 meses, enquanto outliers negativos são mais proeminentes para o horizonte de 12 meses. Essa observação sugere uma possível falta de captação de tendências para períodos de previsão mais longos.

4.4. COMPARAÇÃO COM MÉTRICAS DE ERRO

Nesta subseção, conduz-se uma análise comparativa quantitativa dos modelos, fundamentada nas métricas destacadas na subseção 3.3.5 aplicadas nos períodos de teste de

previsões. Cada uma dessas métricas proporciona uma perspectiva única sobre a precisão das previsões, considerando diferentes aspectos como a magnitude dos erros relativos e a penalização de desvios mais significativos. Destaca-se que, dada a diversidade de métricas disponíveis, não existe uma única métrica capaz de determinar o melhor modelo de forma abrangente. Portanto, a avaliação abrangerá múltiplos critérios, proporcionando uma compreensão mais abrangente e contextualizada do desempenho dos modelos em relação à série temporal estudada.

Os resultados relativos ao MAE estão expostos na Tabela 2. Quanto menor o valor do MAE, melhor o desempenho do modelo, indicando uma menor discrepância média entre as previsões e os valores reais. Em termos práticos, um MAE mais baixo sugere que as previsões estão, em média, mais próximas dos valores reais, o que é desejável. Os valores são expressos em termos da unidade original dos dados, Milhões de Reais e destacou-se em verde o melhor modelo para cada horizonte de previsão.

Tabela 2 – MAE [Mi R$] de cada modelo em cada horizonte de previsão

	Horizonte de Previsão			
Modelo	**1 mês**	**3 meses**	**6 meses**	**12 meses**
Random Forest	6,109	7,372	10,638	11,886
Gradient Boosting	5,733	7,208	11,068	12,447
Ensemble Stacking	5,942	7,329	11,334	12,687

Fonte: Elaboração própria (2023)

É notável a semelhança entre o MAE dos modelos para os mesmos horizontes de previsão, assim como a tendência natural de aumento do mesmo à medida que esse horizonte aumenta. Para essa métrica o *gradient boosting* performou melhor para os horizontes de curto prazo e o *random forest* para o longo prazo, não tendo nenhum caso de melhor performance do *ensemble stacking* frente aos outros dois.

Os resultados referentes ao MAPE estão apresentados na Tabela 3. Assim como no MAE, a interpretação do MAPE segue a lógica de que quanto menor o valor, melhor é o desempenho do modelo, indicando uma menor discrepância média percentual entre as previsões e os valores reais. Em termos práticos, um MAPE mais baixo sugere que as previsões estão, em média, mais próximas dos valores reais, o que é considerado desejável em avaliações de precisão. Os valores do MAPE são expressos como uma porcentagem e novamente destaca-se em verde o modelo com o melhor desempenho para cada horizonte de previsão.

Tabela 3 – MAPE [%] de cada modelo em cada horizonte de previsão

	Horizonte de Previsão			
Modelo	**1 mês**	**3 meses**	**6 meses**	**12 meses**
Random Forest	1.46%	1.76%	2.48%	2.93%
Gradient Boosting	1.39%	1.77%	2.69%	3.14%
Ensemble Stacking	1.43%	1.77%	2.72%	3.25%

Fonte: Elaboração própria (2023)

É notável que os valores são relativamente baixos, indicando uma ótima capacidade preditiva. Segundo Lewis (1982), modelos com MAPE inferior a 10% são classificados como muito precisos quanto ao seu poder de previsão, portanto todos os modelos em todos os horizontes testados se enquadram nessa classificação.

Assim como no MAE, o MAPE tende a ser pior à medida que se aumenta o horizonte de previsão, e nesse caso novamente, o *gradient boosting* se mostrou melhor para o horizonte mais curto e o *random forest* nos mais longos, sem destaques para o *ensemble stacking*, apesar das proximidades dos valores.

Por fim, os resultados referentes ao RMSE estão apresentados na Tabela 4. Assim como nas métricas anteriores, a interpretação do RMSE segue a lógica de que quanto menor o valor, melhor é o desempenho do modelo. O RMSE é uma métrica que penaliza desvios mais significativos, uma vez que envolve o quadrado dos erros. Ainda assim, os valores do RMSE são de fácil interpretação, uma vez que são expressos nas unidades originais da série. Assim como nos outros, destaca-se em verde o modelo com o melhor desempenho para cada horizonte de previsão.

Tabela 4 – RMSE [Mi R$] de cada modelo em cada horizonte de previsão

	Horizonte de Previsão			
Modelo	**1 mês**	**3 meses**	**6 meses**	**12 meses**
Random Forest	8,011	10,146	16,116	16,079
Gradient Boosting	7,565	9,619	15,294	15,876
Ensemble Stacking	7,752	9,852	16,013	15,801

Fonte: Elaboração própria (2023)

Assim como no MAE, é notável a semelhança entre o RMSE dos modelos para os mesmos horizontes de previsão, assim como a tendência natural de aumento do mesmo à medida que esse horizonte aumenta. Para essa métrica o *gradiente boosting* performou melhor para os

horizontes de curto prazo e o *ensemble stacking* para o longo prazo, não tendo nenhum caso de melhor performance do *random forest* frente aos outros dois.

A análise das três métricas de erro na comparação entre os três modelos nos quatro horizontes de previsão modelizados indica uma relativa similaridade no desempenho preditivo. Os resultados não revelam um destaque notável para o modelo alvo principal deste estudo, o *ensemble stacking*, que demandou maior processamento computacional sem apresentar uma contrapartida nos resultados. Destaca-se, no entanto, que todos os modelos utilizados apresentaram desempenho satisfatório em relação às suas métricas de erro e análise visual, sendo esse fato mais evidente para as previsões de curto prazo (1 e 3 meses). Previsões de curto prazo podem ser consideradas as mais relevantes, uma vez que podem ser utilizadas na antecipação da divulgação dos resultados do PIB, o qual é caracterizado por considerável atraso em sua divulgação pelos órgãos oficiais.

4.5. AVALIAÇÃO DAS VARIÁVEIS EXPLICATIVAS

A determinação das variáveis mais relevantes a serem usadas nos modelos não constitui o foco central deste artigo. No entanto, na Tabela 5, apresentam-se os resultados da avaliação das cinco principais variáveis de cada modelo em termos de suas importâncias, conforme atribuída pelos algoritmos *random forest* e *gradient boosting* (o modelo *ensemble stacking* não possui um índice próprio de importância, uma vez que usa os outros dois modelos como base). Conforme discutido nas seções 3.3.2 e 3.3.3, esse índice de importância reflete a contribuição de cada variável para a formação das previsões e a redução dos erros de previsão, respectivamente. É fundamental observar que, embora variáveis com maior importância não necessariamente apresentem a maior relação ou impacto direto no PIB, são elas que mais contribuíram para cada modelo, considerando seus mecanismos de funcionamentos específicos.

Tabela 5 – Índice de importância das *top* 5 variáveis dos modelos *random forest* e *gradient boosting*

Variável	Importância (*random forest*)	Importância (*gradient boosting*)
Produção Categoria - Bens de consumo semiduráveis e não duráveis	57.19%	56.81%

Vendas, pelas distribuidoras, dos derivados combustíveis de petróleo	18.46%	17.71%
M1 - Moeda em poder do público	3.63%	4.48%
Produção de Autoveículos Total	2.73%	3.78%
Exportações (FOB)	2.56%	-
Importações (FOB)	-	2.52%

Fonte: Elaboração própria (2023)

É perceptível a semelhança entre os índices de importância atribuídos pelos dois modelos, justificada pela relativa equivalência na metodologia de cálculo desses índices, indicando assim que o indicador de produção de bens de consumo e as vendas de derivados de petróleo foram as variáveis que mais contribuíram para as previsões em ambos.

5. CONCLUSÕES

Nesta pesquisa, foi conduzida uma análise comparativa de um modelo *ensemble stacking* de *machine learning* para prever o PIB brasileiro em comparação com seus modelos base (*random forest regression* e *gradiente boosting regression*) em diferentes horizontes de previsão (1, 3, 6 e 12 meses). Os resultados dessa avaliação forneceram informações e análises relevantes, tanto no âmbito prático para antecipar a divulgação do PIB quanto no âmbito teórico para avaliar uma técnica avançada de aprendizado de máquina em um ambiente complexo de dados.

Foram conduzidas análises gráficas (previsto *versus* realizado e dispersão dos erros) e quantitativas (métricas de erro e avaliação da importância das variáveis) no contexto da comparação de modelos preditivos do PIB brasileiro. Essas diferentes análises apontaram para conclusões semelhantes: (a) os três modelos analisados apresentaram satisfatória capacidade preditiva nos diferentes horizontes de previsão; (b) os horizontes de previsão mais curtos (1 e 3 meses) apresentaram melhores resultados do que os mais longos (6 e 12 meses); (c) não houve destaque significativo para o modelo *ensemble stacking* nas análises executadas, sendo seus resultados semelhantes aos de seus modelos base.

Portanto, conclui-se que as técnicas de ML investigadas mostram-se adequadas para enfrentar o desafio da previsão do PIB, especialmente em horizontes temporais mais curtos, como 1 e 3 meses, cuja relevância é enfatizada pela demora na divulgação oficial do PIB. Contudo, o modelo *ensemble stacking* não apresentou melhorias significativas em relação aos seus modelos base, sugerindo que sua utilização neste contexto pode não ser justificada, dada a necessidade de maior poder computacional e a introdução de maior complexidade metodológica. Esse cenário levanta duas hipóteses plausíveis para tais resultados: a primeira sugere que os modelos utilizados, ambos baseados em estruturas de árvores, possuem mecanismos intrínsecos semelhantes, o que naturalmente levaria a resultados convergentes; enquanto a segunda hipótese considera que, uma vez que os modelos base já são *ensembles* (*boosting* e *bagging*) e sua integração em um *stacking* pode aumentar a complexidade sem proporcionar ganhos práticos discerníveis.

É fundamental destacar que este estudo não se trata de um trabalho conclusivo, mas sim de uma exploração comparativa no campo de previsões macroeconômicas utilizando ML, assim, nesse momento elencam-se recomendações para estudos futuros que podem enriquecer ainda mais essa temática de pesquisa. Primeiramente conduzir um processo iterativo de seleção de variáveis no modelo poderia auxiliar a diminuir o tempo de processamento computacional e eventuais redundâncias das *features*. Além disso, a condução de um processo de seleção de hiperparâmetros poderia melhorar ainda mais o desempenho dos modelos finais. Por fim, a utilização de outros modelos base (exemplos: regressão multilinear, SARIMAX, regressão Ridge, Regressão LASSO e suavização exponencial), outras variáveis explicativas e outras métricas de avaliação poderiam auxiliar no caminho para uma análise mais completa e eficaz das técnicas nesse campo de pesquisa.

6. REFERÊNCIAS

ADRIANSSON, N.; MATTSSON, I. Forecasting GDP Growth, or How Can Random Forests Improve Predictions in Economics? **Uppsala University Department of Statistics**, 2015.

ALVES, S. A. L.; FASOLO, A. M. Not Just Another Mixed Frequency Paper, Working Papers Series. **Departamento de Pesquisa do Banco Central do Brasil**, 2015.

ANZANELLO, M. J.; ZIMMER, J. Um novo método para seleção de variáveis preditivas com base em índices de importância. **Production**, v. 24, n. 1, p. 84–93, 2013.

BANTIS, E.; CLEMENTS, M. P.; URQUHART, A. Forecasting GDP growth rates in the United States and Brazil using Google Trends. **International Journal of Forecasting**, 2022.

BATURYNSKA, I.; MARTINSEN, K. Prediction of geometry deviations in additive manufactured parts: comparison of linear regression with machine learning algorithms. **Journal of Intelligent Manufacturing**, v. 32, 2020.

BORGES, B. K.; PORTUGAL, M. S. Previsão macroeconômica para o Brasil utilizando o modelo VAR com dados mistos. **Departamento de Economia, PPGE, Universidade Federal do Rio Grande do Sul**, 2018.

BREIMAN, L. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001.

BROWNLEE, J. **Ensemble Learning Algorithms With Python**. [s.l.] Machine Learning Mastery, p. 40–48, 2021.

CAI, J. et al. Feature selection in machine learning: A new perspective. **Neurocomputing**, v. 300, p. 70–79, 2018.

CEPNI, O.; GÜNEY, I. E.; SWANSON, N. R. Nowcasting and forecasting GDP in emerging markets using global financial and macroeconomic diffusion indexes. **International Journal of Forecasting**, v. 35, n. 2, p. 555–572, 2019.

CHE, J. et al. Maximum relevance minimum common redundancy feature selection for nonlinear data. **Information Sciences**, v. 409-410, p. 68–86, 2017.

FRALE, C.; MONTEFORTE, L. Famidas: A Mixed Frequency Factor Model with MIDAS Structure. **Department of the Treasury, Ministry of the Economy and of Finance, Working Papers**, 2010.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001.

GERHARDT, T. E.; SILVEIRA, D. T. **Métodos de Pesquisa**. [s.l.] PLAGEDER, 2009.

GHYSELS, E.; SANTA-CLARA, P.; VALKANOV, R. The MIDAS Touch: Mixed Data Sampling Regression Models. **University of North Carolina**, 2004.

GIANNONE, D.; REICHLIN, L.; SMALL, D. Nowcasting: The real-time informational content of macroeconomic data. **Journal of Monetary Economics**, v. 55, n. 4, p. 665–676, 2008.

GONZÁLEZ-SOPEÑA, J. M.; PAKRASHI, V.; GHOSH, B. An overview of performance evaluation metrics for short-term statistical wind power forecasting. **Renewable and Sustainable Energy Reviews**, v. 138, p. 110515, 2021.

HYNDMAN, R. J.; ATHANASOPOULOS, G. **Forecasting : Principles and Practice**. 2. ed. Heathmont, Vic.: Otexts, 2018.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. **Indicadores IBGE - Contas Nacionais Trimestrais**, 2023. Disponível em: <https://biblioteca.ibge.gov.br/visualizacao/periodicos/2121/cnt_2023_1tri.pdf>. Acesso em: 1 jul. 2023.

INTERNATIONAL MONETARY FUND. **Gross Domestic Product: An Economy's All**, 2014. Disponível em: <https://www.imf.org/en/Publications/fandd/issues/Series/Back-to-Basics/gross-domestic-product-GDP>. Acesso em: 1 jun. 2023.

IZENMAN, A. J. **Modern Multivariate Statistical Techniques : Regression, Classification, and Manifold Learning**. New York, Ny: Springer New York, 2008.

KAGOHARA, D. Avaliando técnicas de nowcasting: uma aplicação do PIB brasileiro. **Fundação Getúlio Vargas**, 2015.

LEWIS, C. D. **Industrial and business forecasting methods : a practical guide to exponential smoothing and curve fitting**. London: Butterworths Scientific, 1982.

LI, Q.; YAN, G.; YU, C. A Novel Multi-Factor Three-Step Feature Selection and Deep Learning Framework for Regional GDP Prediction: Evidence from China. **Sustainability**, v. 14, n. 8, p. 4408, 2022.

LONGO, L.; RICCABONI, M.; RUNGI, A. A neural network ensemble approach for GDP forecasting. **Journal of Economic Dynamics and Control**, v. 134, n. 104278, 2022.

MARCELLINO, M. G.; SCHUMACHER, C. Factor-MIDAS for Now- and Forecasting with Ragged-Edge Data: A Model Comparison for German GDP. **SSRN Electronic Journal**, 2007.

MARKUDOVA, D. et al. Preventive maintenance for heterogeneous industrial vehicles with incomplete usage data. **Computers in Industry**, v. 130, p. 103468, 2021.

MEDEIROS, M. C. et al. Forecasting Inflation in a Data-Rich Environment: The Benefits of Machine Learning Methods. **Journal of Business & Economic Statistics**, v. 39, p. 98–119, 2021.

NOLAU, I.; SANTOS, F. L. Previsão de inflação: análise preliminar de desempenho de técnicas de Machine Learning. **Instituto de Pesquisa Econômica Aplicada (IPEA)**, p. 1–31, 2022.

REBELO, M. A. C. Interpretabilidade de modelos Machine Learning para a previsão macroeconómica. **Universidade de Lisboa. Instituto Superior de Economia e Gestão**, 2022.

RIBEIRO, M. H. D. M.; COELHO, L. DOS S. Ensemble approach based on bagging, boosting and stacking for short-term prediction in agribusiness time series. **Applied Soft Computing**, v. 86, 2020.

RODRIGUEZ-GALIANO, V. et al. Modelling interannual variation in the spring and autumn land surface phenology of the European forest. **Biogeosciences**, v. 13, n. 11, p. 3305–3317, 2016.

ROSSETTI, J. P. **Introdução à economia**. 20. ed. [s.l.] Atlas, 2003.

SAGER, F. T. Previsão da taxa de crescimento do PIB do Brasil : Uma comparação entre machine learning e modelos arima. **Universidade Federal do Rio Grande do Sul**, 2023.

SAGI, O.; ROKACH, L. Ensemble learning: A survey. **Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery**, v. 8, n. 4, 2018.

SCHORFHEIDE, F.; SONG, D. Real-Time Forecasting With a Mixed-Frequency VAR. **Journal of Business & Economic Statistics**, v. 33, n. 3, p. 366–380, 2015.

SIMS, C. A. Macroeconomics and Reality. **Econometrica**, v. 48, n. 1, p. 1, 1980.

SOUSA, L. E. DE P. Previsão e Nowcasting do Crescimento Trimestral do PIB do Rio Grande do Sul via MIDAS. **Departamento de Economia, PPGE, Universidade Federal do Rio Grande do Sul**, 2022.

SOYBILGEN, B.; YAZGAN, E. Nowcasting US GDP Using Tree-Based Ensemble Models and Dynamic Factors. **Computational Economics**, v. 57, n. 1, p. 387–417, 2021.

YOON, J. Forecasting of Real GDP Growth Using Machine Learning Models: Gradient Boosting and Random Forest Approach. **Computational Economics**, v. 57, p. 247–265, 2021.

ZUANAZZI, P. T.; ZIEGELMANN, F. A. Previsões para o crescimento do PIB trimestral brasileiro com séries financeiras e econômicas mensais: uma aplicação de MIDAS. **Economia Aplicada**, v. 18, n. 2, p. 295–318, 2014.